

KHOA HỆ THỐNG THÔNG TIN



TIỂU LUẬN CUỐI KỲ

TÁC ĐỘNG KHÔNG ĐỒNG NHẤT VÀ HIỆU ỨNG LAN TỎA CỦA PHÍ GIẢM ÛN TẮC MANHATTAN LÊN THỊ TRƯỜNG GỌI XE CÔNG NGHỆ: TIẾP CẬN HỌC MÁY NHÂN QUẢ TRÊN KIẾN TRÚC LAKEHOUSE VỚI HÀNG TRĂM TRIỆU CHUYỂN ĐI

Heterogeneous and Spillover Effects of the Manhattan Congestion Relief Zone Toll on Ride-hailing Markets: A Causal Machine Learning Study on a Big Data Lakehouse

Môn học: Nghiên cứu Dữ liệu lớn trong kinh doanh

GVHD:

TS. Nguyễn Thôn Dã

HVTH:

Đình Nguyễn Tấn Nguyên – C25611252

LỜI CẢM ƠN

Tôi xin gửi lời cảm ơn đến TS. Nguyễn Thôn Dã, giảng viên môn Nghiên cứu Dữ liệu lớn trong kinh doanh. Các chương về kiến trúc Lakehouse, lưu trữ dạng cột, xử lý hiệu năng cao, dự báo và phân tích rủi ro trong bài giảng là khung sườn để tôi thiết kế pipeline và lựa chọn phương pháp cho đề án này.

Tôi cũng cảm ơn Ủy ban Taxi và Limousine thành phố New York đã công bố dữ liệu chuyển đi ở mức chi tiết từng chuyến, cùng cộng đồng phát triển DuckDB, Apache Spark, Apache Arrow, pandas, statsmodels, scikit-learn và LightGBM. Nếu không có các công cụ mã nguồn mở này, việc xử lý gần sáu trăm triệu bản ghi trên một máy tính cá nhân sẽ không khả thi.

Do giới hạn về thời gian và tài nguyên tính toán, đề án chắc chắn còn thiếu sót. Tôi mong nhận được góp ý của thầy để hoàn thiện nghiên cứu.

LỜI CAM KẾT

Tôi xin cam đoan đồ án môn học này là công trình nghiên cứu do tôi thực hiện dưới sự hướng dẫn của TS. Nguyễn Thôn Dã trong khuôn khổ môn học Nghiên cứu Dữ liệu lớn trong kinh doanh. Toàn bộ dữ liệu được tải trực tiếp từ kho dữ liệu công khai của Ủy ban Taxi và Limousine thành phố New York (NYC Taxi & Limousine Commission). Mọi con số, bảng biểu và hình ảnh trong báo cáo đều được tạo ra tự động từ các tệp kết quả của mã nguồn đính kèm, không có số liệu nào được nhập tay hay ước đoán.

Mã nguồn, dữ liệu trung gian ở các lớp Bronze, Silver, Gold và các tệp kết quả được lưu đầy đủ trong thư mục đồ án để người chấm có thể chạy lại và đối chiếu. Các tài liệu tham khảo được trích dẫn rõ nguồn. Nếu có sai phạm, tôi xin chịu hoàn toàn trách nhiệm.

Thành phố Hồ Chí Minh, năm 2026

Học viên thực hiện

Đinh Nguyễn Tấn Nguyên

TÓM TẮT

Ngày 05/01/2025, thành phố New York bắt đầu thu phí đối với phương tiện đi vào khu vực Manhattan từ đường 60 trở xuống, gọi là Congestion Relief Zone (CRZ). Với xe gọi công nghệ cỡ lớn như Uber và Lyft, mỗi chuyến có điểm đầu hoặc điểm cuối trong vùng bị cộng 1,50 USD; với taxi vàng là 0,75 USD. Đồ án đánh giá chính sách này bằng dữ liệu chuyến đi ở mức từng chuyến của NYC TLC trong 24 tháng, từ 01/2024 đến 12/2025.

Về kỹ thuật dữ liệu lớn, đồ án xây dựng một pipeline theo kiến trúc Lakehouse ba lớp Bronze–Silver–Gold bằng DuckDB và Parquet, chạy được trên máy có khoảng 3 GB RAM. Dữ liệu thô gồm 572.952.454 bản ghi (12,3 GB Parquet). Sau bảy quy tắc kiểm soát chất lượng còn 544.311.785 chuyến hợp lệ, được tổng hợp thành bảy bảng Gold. Vùng chịu phí không được gán tay mà suy ra từ tỷ lệ chuyển nội vùng bị thu phí trong quý I/2025, cho kết quả 38 vùng nằm trọn trong CRZ và 6 vùng vắt qua ranh giới.

Về suy luận nhân quả, đồ án kết hợp sai khác kép với hai chiều hiệu ứng cố định (TWFE), sai khác bậc ba khử mùa vụ (DDD), nghiên cứu sự kiện, kiểm soát tổng hợp (SCM) và học máy nhân quả (Double/Debiased ML, AIPW, DR-learner với LightGBM). Trên panel 237 vùng $\times$ 103 tuần, số chuyến HVFHV đón trong CRZ giảm 9,3% so với nhóm đối chứng theo TWFE (sai số chuẩn 0,62 điểm log) và 9,7% theo DDD. SCM cho mức giảm trung bình 6,5%; DML trên 4.630 cặp điểm đón – điểm trả thuộc vùng chồng lấn cho 8,4%. Tốc độ trung bình của chuyến đón trong CRZ tăng 0,41 dặm/giờ và thời gian chờ xe giảm 0,38 phút. Hai kết quả về ùn tắc này vững qua các phép thử giả được, còn các chỉ tiêu giá cước và thu nhập tài xế bị chi phối bởi xu hướng có sẵn từ trước nên không được diễn giải như tác động nhân quả.

Để kiểm tra giả định xu hướng song song, đồ án bổ sung 522.872.427 bản ghi của 2022–2023 và ước lượng nghiên cứu sự kiện theo tháng trên bốn năm. Kết quả làm thay đổi cách đọc về số chuyến: năm 2024 so với 2023, trước khi có phí, số chuyến CRZ đã giảm tương đối 7,8%, và sau khi trừ xu hướng tuyến tính, tác động năm 2025 chỉ còn +0,06%. Mức giảm 6–10% vì thế là cận trên; phần vượt xu hướng khoảng 0–2%. Tác động lên tốc độ (+0,15 dặm/giờ sau điều chỉnh) và thời gian chờ vẫn giữ chiều, với độ lớn nhỏ hơn.

Tổng phí CBD ghi nhận trong dữ liệu năm 2025 là 117,1 triệu USD từ HVFHV và 24,0 triệu USD từ taxi vàng. Phân tích lan tỏa cho thấy mức giảm lan ra các vùng lân cận ngoài ranh giới và nhỏ dần theo khoảng cách, nên dùng Manhattan phía bắc làm nhóm đối chứng duy nhất sẽ đánh giá thấp tác động.

Ba mô-đun mở rộng bám theo các chương còn lại của học phần. Thứ nhất, Apache Spark tái lập bảng Gold chính từ 544.311.785 dòng Silver; phép đối chứng từng ô với DuckDB phát hiện một lỗi ép kiểu im lặng ở bước hợp nhất, được sửa trước khi dựng báo cáo. Trên cùng phần cứng một nút, Spark chậm hơn DuckDB khoảng 2,2 lần; AQE, cắt tỉa phân vùng, Apache Arrow và Structured Streaming được đo trực tiếp. Thứ hai, về quản trị dữ liệu và rủi ro, 99,8% chuyển là duy nhất ở mức chi tiết của bản công bố, trong khi bảng vùng $\times$ ngày có quyền riêng tư vi phân với $\epsilon = 0,01$ vẫn giữ nguyên kết luận về số chuyển. Thứ ba, về giá trị kinh doanh, số chuyển Uber giảm 10,9% so với 5,0% của Lyft, và mô hình dự báo nhu cầu chính xác nhất cho phản thực tế trái chiều với DiD, một phần vì chuỗi đối chứng bị lan tỏa.

Từ khóa: dữ liệu lớn, Lakehouse, DuckDB, Apache Spark, phí ừn tắc, gọi xe công nghệ, sai khác kép, kiểm soát tổng hợp, Double Machine Learning, quyền riêng tư vi phân, quản trị dữ liệu, xu hướng trước chính sách.

ABSTRACT

On 5 January 2025 New York City started tolling vehicles entering Manhattan south of and including 60th Street, the Congestion Relief Zone (CRZ). High-volume for-hire trips that start or end in the zone pay USD 1.50 and yellow taxi trips USD 0.75. This case study evaluates the policy with trip-level records published by the NYC Taxi and Limousine Commission for January 2024 to December 2025.

A three-layer Bronze–Silver–Gold lakehouse built on DuckDB and Parquet processes 573.0 million raw records on a machine with about 3 GB of RAM. Treated zones are inferred from the data rather than assigned by hand. Identification combines two-way fixed-effects difference-in-differences, a seasonal triple-difference, event studies, synthetic control and double/debiased machine learning with LightGBM nuisances.

Ride-hailing pickups in the CRZ fall by 9.3% (TWFE) and 9.7% (seasonal DDD) relative to control zones; synthetic control gives 6.5% and AIPW on the overlap sample of origin–destination pairs gives 8.4%. Average speed of CRZ pickups rises by 0.41 mph and waiting time falls by 0.38 minutes, and both results survive placebo tests. Fare and driver-pay outcomes show strong pre-existing differential trends and are not given a causal interpretation. Effects spill over to neighbouring zones outside the boundary and fade with distance.

Adding 522.9 million records for 2022–2023 and estimating a monthly event study over four years changes the reading of the trip effect: CRZ trips were already falling relative to control zones before the toll, and after removing a linear pre-trend the 2025 effect is 0.06%. The 6–10% decline is therefore an upper bound, with roughly 0–2% attributable to the toll beyond the existing trend. Speed and waiting-time gains keep their sign after trend adjustment, with smaller magnitudes.

Three extension modules follow the remaining chapters of the course. Apache Spark independently rebuilds the main Gold table; the cell-by-cell comparison with DuckDB uncovered a silent type-coercion bug in the consolidation step, fixed before this report was built, and eight experiments measure adaptive query execution, caching, partition pruning, Arrow and Structured Streaming. A governance module shows that 99.8% of trips are unique at the published level of detail, while zone-by-

day counts released under differential privacy with $\epsilon = 0.01$ preserve the policy conclusion. A business module finds that the most accurate out-of-sample demand forecast yields a counterfactual of the opposite sign to DiD, partly because its control series is itself affected by spillovers.

Keywords: big data, lakehouse, DuckDB, Apache Spark, congestion pricing, ride-hailing, difference-in-differences, synthetic control, double machine learning, differential privacy, data governance, pre-trends.

MỤC LỤC

LỜI CẢM ƠN.....	2
LỜI CAM KẾT.....	3
TÓM TẮT.....	4
ABSTRACT.....	6
DANH MỤC TỪ VIẾT TẮT.....	18
DANH MỤC BẢNG BIỂU.....	19
DANH MỤC HÌNH ẢNH.....	23
CHƯƠNG 1. GIỚI THIỆU NGHIÊN CỨU.....	26
1.1. Bối cảnh nghiên cứu.....	26
1.1.1. Ùn tắc đô thị và ý tưởng định giá đường.....	26
1.1.2. Chính sách phí vùng giảm ùn tắc tại New York.....	26
1.1.3. Dữ liệu chuyển đi như một tài sản dữ liệu lớn.....	27
1.2. Vấn đề nghiên cứu.....	27
1.2.1. Tác động trung bình đã có ước lượng ban đầu, nhưng còn thô.....	27
1.2.2. Thách thức nhận dạng nhân quả.....	28
1.2.3. Thách thức kỹ thuật dữ liệu.....	28
1.3. Mục tiêu nghiên cứu.....	29
1.3.1. Mục tiêu tổng quát.....	29
1.3.2. Mục tiêu cụ thể.....	29
1.4. Câu hỏi nghiên cứu.....	30
1.4.1. Tám câu hỏi nghiên cứu.....	30
1.4.2. Mức độ chắc chắn kỳ vọng của từng câu trả lời.....	30
1.5. Phạm vi nghiên cứu.....	31
1.5.1. Phạm vi dữ liệu và thời gian.....	31
1.5.2. Phạm vi kết luận.....	31
1.6. Phương pháp nghiên cứu tổng quát.....	31
1.6.1. Kỹ thuật dữ liệu lớn.....	31
1.6.2. Suy luận nhân quả.....	32
1.6.3. Kiểm định độ tin cậy.....	32
1.6.4. Xử lý phân tán, quản trị dữ liệu và phân tích kinh doanh.....	32
1.7. Đóng góp của nghiên cứu.....	32
1.7.1. Đóng góp về phương pháp dữ liệu.....	32
1.7.2. Đóng góp về bằng chứng thực nghiệm.....	33
1.7.3. Đóng góp về tính minh bạch.....	33
1.8. Cấu trúc của báo cáo.....	33
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU.....	35
2.1. Kinh tế học định giá ùn tắc.....	35

2.1.1.	Ùn tắc như một ngoại tác.....	35
2.1.2.	Phản ứng của nhu cầu và độ co giãn.....	36
2.1.3.	Phân bổ gánh nặng của phí.....	36
2.2.	Kinh nghiệm quốc tế về phí ùn tắc theo vùng.....	37
2.2.1.	Singapore, London và Stockholm.....	37
2.2.2.	Điểm khác biệt của trường hợp New York.....	37
2.3.	Thị trường gọi xe công nghệ.....	38
2.3.1.	Cấu trúc thị trường hai phía.....	38
2.3.2.	Gọi xe và ùn tắc.....	38
2.3.3.	Khung quy định tại New York.....	38
2.4.	Kiến trúc và hạ tầng dữ liệu lớn.....	39
2.4.1.	Từ kho dữ liệu đến Lakehouse.....	39
2.4.2.	Tách rời lưu trữ và tính toán.....	39
2.4.3.	Định dạng lưu trữ dạng cột.....	39
2.4.4.	Bộ máy xử lý trong bộ nhớ và thực thi vector hóa.....	40
2.4.5.	Điều phối, tính lũy đẳng và khả năng tái lập.....	40
2.4.6.	Định dạng bảng giao dịch: Delta Lake và Apache Iceberg.....	40
2.4.7.	Xử lý luồng và giám sát gần thời gian thực.....	41
2.4.8.	Chi phí sở hữu và giá trị của dữ liệu.....	41
2.4.9.	Mô hình tính toán của Apache Spark.....	42
2.4.10.	Xử lý luồng có cấu trúc.....	42
2.5.	Chất lượng dữ liệu và quản trị dữ liệu.....	43
2.5.1.	Các chiều chất lượng dữ liệu.....	43
2.5.2.	Lệch lệch đồ.....	43
2.5.3.	Quyền riêng tư.....	44
2.5.4.	Danh mục dữ liệu, phả hệ và tính toàn vẹn.....	44
2.5.5.	k-ẩn danh và rủi ro tái nhận dạng.....	44
2.5.6.	Quyền riêng tư vi phân.....	45
2.5.7.	Phát hiện bất thường, bảo mật và phục hồi.....	45
2.6.	Suy luận nhân quả từ dữ liệu quan sát.....	46
2.6.1.	Khung kết quả tiềm năng.....	46
2.6.2.	Sai khác kép và hai chiều hiệu ứng cố định.....	46
2.6.3.	Nghiên cứu sự kiện.....	46
2.6.4.	Khử mùa vụ bằng sai khác bậc ba.....	47
2.6.5.	Kiểm soát tổng hợp.....	47
2.6.6.	Suy luận hoán vị và sai số chuẩn phân cụm.....	48
2.6.7.	Ước lượng hiệu ứng cố định nhiều chiều.....	48
2.7.	Học máy nhân quả.....	48

2.7.1.	Double/Debiased Machine Learning.....	48
2.7.2.	Ước lượng bền vững kép AIPW.....	49
2.7.3.	Tác động không đồng nhất: DR-learner, BLP và GATES.....	49
2.7.4.	LightGBM làm mô hình phụ.....	49
2.8.	Tổng quan các nghiên cứu liên quan.....	50
2.8.1.	Đánh giá phí ùn tắc ở các thành phố khác.....	50
2.8.2.	Gọi xe công nghệ và ùn tắc.....	51
2.8.3.	Đánh giá phí CRZ tại New York.....	51
2.8.4.	Học máy nhân quả trong giao thông và kinh doanh.....	52
2.8.5.	Tổng hợp.....	52
2.9.	Giá trị kinh doanh của dữ liệu lớn.....	53
2.9.1.	Dự báo nhu cầu và dự báo làm phản thực tế.....	53
2.9.2.	Thử nghiệm quy mô lớn và công suất thống kê.....	53
2.9.3.	Định giá động trong nền tảng gọi xe.....	53
2.9.4.	Định giá tài sản dữ liệu, ROI và TCO.....	54
2.10.	Khoảng trống nghiên cứu và khung phân tích.....	54
2.10.1.	Khoảng trống nghiên cứu.....	54
2.10.2.	Khung phân tích của đồ án.....	55
2.11.	Mô hình lý thuyết và giả thuyết nghiên cứu.....	55
2.11.1.	Cầu chuyển đi theo chi phí tổng quát.....	55
2.11.2.	Quan hệ tốc độ – lưu lượng.....	56
2.11.3.	Lan tỏa qua mạng lưới chuyển đi.....	56
2.11.4.	Phân bổ gánh nặng.....	57
2.12.	Tiểu kết Chương 2.....	57
CHƯƠNG 3. DỮ LIỆU, KIẾN TRÚC PIPELINE VÀ PHƯƠNG PHÁP NGHIÊN CỨU...		59
3.1.	Thiết kế nghiên cứu tổng thể.....	59
3.1.1.	Đơn vị phân tích.....	59
3.1.2.	Quy trình tổng thể.....	59
3.2.	Nguồn dữ liệu.....	61
3.2.1.	Dữ liệu chuyển đi của NYC TLC.....	61
3.2.2.	Quy mô dữ liệu theo tháng.....	61
3.2.3.	Lệch lược đồ.....	62
3.2.4.	Dữ liệu mở rộng cho giai đoạn trước chính sách 2022–2023.....	62
3.3.	Kiến trúc Lakehouse được triển khai.....	63
3.3.1.	Lớp Bronze.....	63
3.3.2.	Lớp Silver.....	63
3.3.3.	Xử lý theo khúc và giới hạn tài nguyên.....	64
3.3.4.	Dung lượng theo lớp.....	65

3.3.5.	Tổ chức thư mục của đồ án.....	65
3.3.6.	Truy vấn chuẩn hóa và gán cờ chất lượng.....	66
3.4.	Kiểm soát chất lượng dữ liệu.....	66
3.4.1.	Bảy quy tắc chất lượng.....	66
3.4.2.	Kết quả kiểm tra chất lượng.....	67
3.5.	Xác định vùng xử lý bằng dữ liệu.....	67
3.5.1.	Vấn đề ranh giới.....	67
3.5.2.	Thủ tục phân loại.....	68
3.5.3.	Khoảng cách và quan hệ kề.....	71
3.6.	Các bảng Gold và panel phân tích.....	71
3.6.1.	Bảy bảng Gold.....	71
3.6.2.	Các panel dùng cho suy luận nhân quả.....	72
3.7.	Thiết kế thực nghiệm hiệu năng.....	72
3.8.	Chiến lược nhận dạng nhân quả.....	73
3.8.1.	Đặc tả chính.....	73
3.8.2.	Các đặc tả bổ sung.....	73
3.8.3.	Kiểm soát tổng hợp.....	73
3.8.4.	Học máy nhân quả trên cặp OD.....	74
3.8.5.	Lan tỏa, giả dược và độ vững.....	74
3.8.6.	Định nghĩa biến kết quả.....	75
3.9.	Môi trường tính toán và khả năng tái lập.....	75
3.10.	Các mô-đun mở rộng.....	76
3.11.	Tiểu kết Chương 3.....	76
CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH.....		77
4.1.	Hiệu năng của pipeline dữ liệu lớn.....	77
4.1.1.	Định dạng lưu trữ.....	77
4.1.2.	Bộ máy xử lý.....	78
4.1.3.	Cắt tỉa cột và đẩy điều kiện lọc.....	79
4.1.4.	Tổng hợp về RQ1.....	79
4.2.	Mô tả dữ liệu sau xử lý.....	80
4.2.1.	Chỉ tiêu mô tả theo nhóm vùng.....	80
4.2.2.	Taxi vàng.....	80
4.3.	Diễn biến theo thời gian.....	82
4.3.1.	Số chuyển theo ngày.....	82
4.3.2.	Tăng trưởng cùng kỳ theo tuần.....	83
4.3.3.	Bản đồ thay đổi cùng kỳ.....	84
4.3.4.	So sánh HVFHV và taxi vàng trong CRZ.....	85
4.4.	Doanh thu phí, cấu trúc luồng và nhíp theo giờ.....	86

4.4.1.	Phí CBD ghi nhận trong dữ liệu.....	86
4.4.2.	Cấu trúc luồng giữa các nhóm vùng.....	87
4.4.3.	Nhịp theo giờ.....	88
4.4.4.	Thị phần hãng.....	89
4.4.5.	Luồng sân bay.....	89
4.5.	Tác động lên số chuyến.....	90
4.5.1.	Kết quả DiD trên panel vùng $\times$ tuần.....	90
4.5.2.	Nghiên cứu sự kiện theo tuần.....	91
4.5.3.	Tỷ lệ yêu cầu đi chung.....	93
4.6.	Tác động lên tốc độ và thời gian chờ.....	93
4.6.1.	Kết quả DiD.....	93
4.6.2.	Động thái theo tháng.....	94
4.6.3.	Tốc độ theo loại luồng và theo giờ.....	95
4.6.4.	Tốc độ theo giờ và loại ngày.....	96
4.7.	Giá cước, chi phí hành khách và thu nhập tài xế.....	97
4.7.1.	Kết quả DiD.....	97
4.7.2.	Phân phối chi phí hành khách.....	98
4.7.3.	Diễn biến giá theo tháng.....	99
4.7.4.	Thành phần quãng đường chuyển.....	101
4.8.	Phân tích trên panel cặp điểm đón – điểm trả.....	101
4.8.1.	Tác động theo loại luồng.....	101
4.8.2.	Nghiên cứu sự kiện theo tháng trên panel OD.....	102
4.9.	Tác động không đồng nhất theo thời gian trong ngày và trong tuần.....	103
4.9.1.	Theo khung giờ.....	103
4.9.2.	Ngày thường và cuối tuần.....	104
4.10.	Kiểm soát tổng hợp.....	104
4.11.	Học máy nhân quả và tác động không đồng nhất.....	107
4.11.1.	Kiểm tra chồng lấn.....	107
4.11.2.	Tác động trung bình.....	108
4.11.3.	Kiểm định không đồng nhất: BLP và GATES.....	108
4.11.4.	Đặc trưng của nhóm chịu tác động mạnh.....	109
4.11.5.	Tác động riêng theo từng vùng CRZ.....	111
4.12.	Hiệu ứng lan tỏa không gian.....	113
4.12.1.	Lan tỏa theo dải khoảng cách.....	113
4.12.2.	Lan tỏa theo quận.....	114
4.13.	Taxi vàng.....	115
4.14.	Kiểm định độ tin cậy.....	116
4.14.1.	Giả được theo thời gian.....	116

4.14.2.	Suy luận hoán vị.....	118
4.14.3.	Bảng độ vũng.....	118
4.14.4.	Giai đoạn trước chính sách mở rộng: khử mùa vụ và giả được theo năm....	120
4.14.5.	Độ nhạy với vi phạm xu hướng song song (Rambachan–Roth).....	122
4.15.	Đối chiếu kết quả với các giả thuyết lý thuyết.....	124
4.15.1.	H1b: liều – đáp ứng theo tỷ trọng phí.....	124
4.15.2.	H2b: độ lỗi của quan hệ tốc độ – lưu lượng.....	125
4.15.3.	H3: lan tỏa theo mức phơi nhiễm.....	126
4.15.4.	H4: thu nhập tài xế mỗi dặm giảm cơ học khi tốc độ tăng.....	127
4.15.5.	Tổng hợp.....	128
4.16.	Tổng hợp kết quả theo câu hỏi nghiên cứu.....	129
4.17.	Tiểu kết Chương 4.....	130
CHƯƠNG 5. XỬ LÝ PHÂN TÁN VỚI APACHE SPARK: ĐỐI CHỨNG CHÉO VÀ PHÂN TÍCH HIỆU NĂNG.....		131
5.1.	Thiết kế thực nghiệm.....	132
5.1.1.	Môi trường và cấu hình Spark.....	132
5.1.2.	Truy vấn chuẩn.....	132
5.1.3.	Các thực nghiệm.....	133
5.1.4.	Cách đo và giới hạn của phép đo.....	133
5.2.	Tái lập bảng Gold và đối chứng chéo.....	134
5.2.1.	Kết quả tái lập.....	134
5.2.2.	Đối chứng từng ô.....	134
5.2.3.	Nguyên nhân lỗi và cách sửa.....	135
5.3.	So sánh bộ máy và khả năng mở rộng.....	137
5.3.1.	Cùng truy vấn trên một tháng.....	137
5.3.2.	Mở rộng theo khối lượng dữ liệu.....	138
5.4.	Xáo trộn dữ liệu và thực thi truy vấn thích nghi.....	139
5.5.	Lưu đệm trong bộ nhớ và phá hệ của phép biến đổi.....	140
5.6.	Cắt tia phân vùng, đẩy điều kiện lọc và kế hoạch thực thi.....	141
5.7.	Trao đổi dữ liệu giữa Spark và Python qua Apache Arrow.....	143
5.8.	Xử lý luồng có cấu trúc để giám sát chính sách.....	143
5.8.1.	Thiết kế.....	143
5.8.2.	Kết quả.....	144
5.9.	Thảo luận: chọn công cụ theo quy mô.....	146
5.10.	Tiểu kết Chương 5.....	147
CHƯƠNG 6. QUẢN TRỊ DỮ LIỆU, QUYỀN RIÊNG TƯ VÀ QUẢN TRỊ RỦI RO.....		148
6.1.	Danh mục dữ liệu và siêu dữ liệu.....	148
6.2.	Phá hệ dữ liệu.....	150
6.3.	Tính toàn vẹn và chuỗi cung ứng dữ liệu.....	151

6.4.	Đối soát giữa các lớp và giám sát chất lượng.....	151
6.4.1.	Đối soát số dòng.....	151
6.4.2.	Biểu đồ kiểm soát tỷ lệ loại bỏ.....	152
6.5.	Phát hiện ngày bất thường.....	153
6.6.	Phát hiện chuyển đi bất thường.....	155
6.7.	Rủi ro tái nhận dạng trong dữ liệu công bố.....	157
6.8.	Quyền riêng tư vi phạm cho bằng công bố.....	159
6.9.	Bảo mật, Zero Trust và phục hồi sau sự cố.....	161
6.9.1.	Phân loại tài sản và nguyên tắc Zero Trust.....	161
6.9.2.	Mục tiêu thời gian phục hồi.....	162
6.10.	Số đăng ký rủi ro.....	163
6.11.	Tiểu kết Chương 6.....	163
CHƯƠNG 7. GIÁ TRỊ KINH DOANH VÀ CHIẾN LƯỢC DỮ LIỆU.....		164
7.1.	Tác động theo hãng và cạnh tranh trong vùng thu phí.....	164
7.2.	Dự báo nhu cầu và giới hạn của dự báo làm phản thực tế.....	165
7.2.1.	Thiết kế.....	165
7.2.2.	Kết quả.....	166
7.3.	Quy mô dữ liệu cần cho một thử nghiệm chính sách.....	168
7.4.	Định giá động: giá có phản ứng với nhu cầu trong ngày không?.....	169
7.5.	Phân khúc chuyển đi và hàm ý cá nhân hóa.....	170
7.6.	Giá trị và chi phí của tài sản dữ liệu.....	171
7.6.1.	Hạch toán tài nguyên.....	171
7.6.2.	Định giá tài sản dữ liệu.....	172
7.6.3.	Các sản phẩm dữ liệu có thể thương mại hóa.....	173
7.7.	Lộ trình chiến lược dữ liệu.....	173
7.8.	Tiểu kết Chương 7.....	174
CHƯƠNG 8. THẢO LUẬN KẾT QUẢ, HÀM Ý QUẢN TRỊ VÀ HẠN CHẾ.....		175
8.1.	Về kỹ thuật dữ liệu lớn.....	175
8.1.1.	Quy mô vừa phải và lựa chọn công cụ.....	175
8.1.2.	Chất lượng dữ liệu ảnh hưởng đến kết luận nhân quả.....	175
8.1.3.	Chi phí tính toán như một chỉ tiêu quản trị.....	176
8.2.	Về tác động lên số chuyển.....	176
8.2.1.	Độ lớn so với lý thuyết.....	176
8.2.2.	So sánh với nghiên cứu khác.....	177
8.2.3.	Luồng nào nhạy nhất.....	177
8.3.	Về tác động lên ùn tắc.....	177
8.3.1.	Tốc độ và thời gian chờ như bằng chứng trực tiếp.....	177
8.3.2.	Giới hạn của thước đo tốc độ.....	178

8.3.3.	Không đồng nhất theo giờ và theo ngày.....	178
8.4.	Về giá cước, chi phí hành khách và thu nhập tài xế.....	179
8.4.1.	Vì sao không kết luận.....	179
8.4.2.	Ý nghĩa đối với phương pháp.....	179
8.5.	Về hiệu ứng lan tỏa.....	179
8.6.	Về học máy nhân quả.....	180
8.6.1.	Chồng lấn là vấn đề trung tâm.....	180
8.6.2.	Giá trị của CATE.....	180
8.7.	Hàm ý quản trị và chính sách.....	181
8.7.1.	Đối với cơ quan quản lý.....	181
8.7.2.	Đối với doanh nghiệp nền tảng.....	181
8.7.3.	Đối với phân tích dữ liệu trong doanh nghiệp.....	181
8.8.	Hạn chế của nghiên cứu.....	182
8.9.	Tiểu kết Chương 5.....	183
CHƯƠNG 9. KẾT LUẬN VÀ KIẾN NGHỊ.....		184
9.1.	Kết luận tổng quát.....	184
9.2.	Trả lời các câu hỏi nghiên cứu.....	185
9.2.1.	RQ1: kiến trúc và chi phí xử lý.....	185
9.2.2.	RQ2: tác động lên số chuyển.....	185
9.2.3.	RQ3: tác động lên ùn tắc.....	185
9.2.4.	RQ4: không đồng nhất và lan tỏa.....	185
9.2.5.	RQ5: phân bổ gánh nặng.....	186
9.2.6.	RQ6: xử lý phân tán với Spark.....	186
9.2.7.	RQ7: quản trị dữ liệu, quyền riêng tư và rủi ro.....	186
9.2.8.	RQ8: giá trị kinh doanh.....	186
9.3.	Kiến nghị.....	187
9.3.1.	Kiến nghị chính sách.....	187
9.3.2.	Kiến nghị về phương pháp và dữ liệu.....	187
9.4.	Hướng nghiên cứu tiếp theo.....	188
9.5.	Kết luận cuối.....	188
TÀI LIỆU THAM KHẢO.....		189
PHỤ LỤC A. HỒ SƠ CHI TIẾT THEO VÙNG.....		194
A.1.	Nhóm CRZ (38 vùng).....	194
A.2.	Nhóm Vắt ranh giới (6 vùng).....	213
A.3.	Nhóm Manhattan phía bắc (24 vùng).....	216
A.4.	Quận ngoài: 60 vùng có lưu lượng lớn nhất.....	228
PHỤ LỤC B. BẢNG TỔNG HỢP 263 VÙNG TAXI.....		258
PHỤ LỤC C. CHỈ TIÊU THEO THÁNG VÀ NHÓM VÙNG.....		265

PHỤ LỤC D. LƯỒNG CHUYỂN THEO GIỜ.....	271
PHỤ LỤC E. HỆ SỐ ĐẦY ĐỦ CỦA CÁC NGHIÊN CỨU SỰ KIỆN.....	276
PHỤ LỤC F. KIỂM SOÁT TỔNG HỢP, HOÁN VỊ VÀ CHẤT LƯỢNG DỮ LIỆU.....	284
F.1. Kết quả giả dưng không gian của kiểm soát tổng hợp.....	284
F.2. Phân phối hoán vị.....	287
F.3. Chất lượng dữ liệu theo tháng.....	287
F.4. Danh mục tệp Bronze.....	288
F.5. Nhật ký thời gian theo phân vùng.....	289
PHỤ LỤC G. DANH MỤC TẬP KẾT QUẢ.....	292
PHỤ LỤC H. NHẬT KÝ XỬ LÝ PHÂN TÁN VÀ QUẢN TRỊ DỮ LIỆU.....	296
H.1. Tái lập bảng zone_day_pu bằng Spark theo phân vùng.....	296
H.2. Đối chứng chi tiết Spark – DuckDB.....	297
H.3. Bản kê dấu băm SHA-256 của lớp Bronze.....	298
H.4. Đối soát số dòng giữa các lớp.....	299
H.5. Phả hệ chi tiết theo bước.....	300
H.6. Kế hoạch logic của truy vấn có cắt tia phân vùng.....	301
H.7. Kết quả cửa sổ giờ của Structured Streaming.....	301
PHỤ LỤC I. MÃ NGUỒN.....	308
I.1. config.py.....	308
I.2. 00_download_data.py.....	309
I.3. 01_bronze_catalog.py.....	309
I.4. 02_zone_dimension.py.....	310
I.5. 03_silver_gold_month.py.....	312
I.6. 04_gold_consolidate.py.....	315
I.7. 05_benchmark.py.....	316
I.8. panels.py.....	318
I.9. causal.py.....	320
I.10. viz.py.....	321
I.11. 06_eda.py.....	322
I.12. 07_did_main.py.....	327
I.13. 08_synthetic_control.py.....	330
I.14. 09_dml_heterogeneity.py.....	332
I.15. 10_spillover_robustness.py.....	335
I.16. 11_appendix_tables.py.....	338
I.17. 12_pipeline_figures.py.....	339
I.18. 14_extra_analysis.py.....	341
I.19. 15_spark_pipeline.py.....	343
I.20. 15b_compare_outputs.py.....	351

I.21. 16_governance_risk.py.....	351
I.22. 17_business_analytics.py.....	358
I.23. 18_theory_sensitivity.py.....	362
I.24. 19_long_preperiod.py.....	364
I.25. 00_download_data_2022_2023.ps1.....	367
I.26. run_all.sh.....	367
I.27. requirements.txt.....	368

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Diễn giải
AIPW	Augmented Inverse Probability Weighting – ước lượng trọng số nghịch đảo xác suất tăng cường
AQE	Adaptive Query Execution – thực thi truy vấn thích nghi của Spark
ATE / ATT	Tác động trung bình / tác động trung bình trên nhóm được xử lý
BLP	Best Linear Predictor – bộ dự báo tuyến tính tốt nhất của CATE
CATE	Conditional Average Treatment Effect – tác động trung bình có điều kiện
CBD	Central Business District – khu thương mại trung tâm (tên cột phí trong dữ liệu TLC)
CLAN	Classification Analysis – so sánh đặc trưng giữa nhóm tác động cao và thấp
CRZ	Congestion Relief Zone – vùng giảm ùn tắc ở Manhattan
DAG	Directed Acyclic Graph – đồ thị có hướng không chu trình (kế hoạch thực thi của Spark)
DDD	Sai khác bậc ba (ở đây: khử mùa vụ theo nhóm $\times$ tuần trong năm)
DiD	Difference-in-Differences – sai khác kép
DML	Double/Debiased Machine Learning – học máy khử chệch kép
DP	Differential Privacy – quyền riêng tư vi phân
DR	Doubly Robust – bền vững kép
FE	Fixed Effects – hiệu ứng cố định
GATES	Group Average Treatment Effects – tác động trung bình theo nhóm
HVFHV / HVFHS	High Volume For-Hire Vehicle/Service – dịch vụ xe cho thuê số lượng lớn (Uber, Lyft)
KTC	Khoảng tin cậy
JVM	Java Virtual Machine – máy ảo Java, môi trường chạy của Spark
MAD	Median Absolute Deviation – độ lệch tuyệt đối trung vị
MAPE	Mean Absolute Percentage Error – sai số phần trăm tuyệt đối trung bình
MDE	Minimum Detectable Effect – tác động nhỏ nhất phát hiện được
MN	Manhattan
MTA	Metropolitan Transportation Authority – cơ quan vận tải đô thị New York
OD	Origin–Destination – cặp điểm đón và điểm trả
PLR	Partially Linear Regression – hồi quy tuyến tính từng phần
RDD	Resilient Distributed Dataset – tập dữ liệu phân tán có khả năng phục hồi
RMSPE	Root Mean Squared Prediction Error – căn bậc hai sai số dự báo bình phương trung bình
RPO / RTO	Recovery Point / Time Objective – điểm và thời gian phục hồi mục tiêu
SCM	Synthetic Control Method – phương pháp kiểm soát tổng hợp
SE	Standard Error – sai số chuẩn
SHA-256	Secure Hash Algorithm 256 bit – hàm băm mật mã dùng kiểm tra toàn vẹn tệp
TLC	NYC Taxi & Limousine Commission – Ủy ban Taxi và Limousine New York
TWFE	Two-Way Fixed Effects – hai chiều hiệu ứng cố định
YoY	Year over Year – so với cùng kỳ năm trước
ZSTD	Zstandard – thuật toán nén dùng cho tệp Parquet

DANH MỤC BẢNG BIỂU

Bảng 2.1. Hệ thống hóa các nghiên cứu liên quan và vị trí của đồ án.....	52
Bảng 2.2. Các giả thuyết suy ra từ mô hình lý thuyết.....	57
Bảng 3.1. Các bước của pipeline và tệp mã nguồn tương ứng.....	60
Bảng 3.2. Các cột của dữ liệu HVFHV được sử dụng.....	61
Bảng 3.3. Đặc điểm các tệp Bronze theo dịch vụ.....	62
Bảng 3.4. Dữ liệu mở rộng 01/2022–12/2023 ở lớp Bronze.....	62
Bảng 3.5. Tổng thời gian xử lý theo bước và thông lượng.....	65
Bảng 3.6. Dung lượng lưu trữ theo lớp.....	65
Bảng 3.7. Các quy tắc chất lượng dữ liệu áp dụng ở lớp Silver.....	66
Bảng 3.8. Kết quả kiểm soát chất lượng theo dịch vụ.....	67
Bảng 3.9. Số vùng theo nhóm và theo quận.....	69
Bảng 3.10. Sáu vùng vượt qua ranh giới CRZ và tỷ lệ chuyển nội vùng bị thu phí.....	70
Bảng 3.11. Các bảng Gold, khóa tổng hợp và số dòng.....	71
Bảng 3.12. Quy mô các panel dùng cho suy luận nhân quả.....	72
Bảng 3.13. Định nghĩa các biến kết quả.....	75
Bảng 3.14. Môi trường tính toán.....	75
Bảng 3.15. Các bước mở rộng của pipeline.....	76
Bảng 4.1. So sánh bốn định dạng lưu trữ trên 2.000.000 dòng HVFHV tháng 03/2024.....	77
Bảng 4.2. So sánh ba bộ máy xử lý trên cùng truy vấn tổng hợp một tháng HVFHV.....	78
Bảng 4.3. Tác động của cắt tỉa cột và đẩy điều kiện lọc trong DuckDB (1 tháng HVFHV)....	79
Bảng 4.4. Chỉ tiêu mô tả chuyển HVFHV theo nhóm vùng đón và năm.....	80
Bảng 4.5. Số chuyển taxi vàng (dữ liệu thô) theo nhà cung cấp, nhóm vùng đón và năm.....	81
Bảng 4.6. Phân bố thay đổi cùng kỳ số chuyển đón theo vùng (vùng có ít nhất 5.000 chuyển năm 2024).....	84
Bảng 4.7. Phí CBD ghi nhận trong dữ liệu theo tháng, năm 2025.....	86
Bảng 4.8. Tỷ trọng các luồng chính trong tổng số chuyển HVFHV (14 luồng lớn nhất).....	87
Bảng 4.9. Số chuyển HVFHV/ngày của các luồng có đầu sân bay (05/01 – 31/12).....	89
Bảng 4.10. Tác động lên log số chuyển HVFHV đón theo bốn đặc tả (panel 237 vùng × 103 tuần).....	90
Bảng 4.11. Trung bình hệ số DDD theo tháng của năm 2025 (HVFHV, log số chuyển đón). 92	
Bảng 4.12. Tác động lên tốc độ, thời gian chờ và quãng đường/chuyển (HVFHV, vùng × tuần).....	93
Bảng 4.13. Tác động lên giá cước, chi phí hành khách và thu nhập tài xế (HVFHV, vùng × tuần).....	97
Bảng 4.14. Tác động theo loại luồng trên panel cặp OD × tháng.....	101
Bảng 4.15. Tác động DiD theo khung giờ đón (panel vùng × khung giờ × tháng).....	103
Bảng 4.16. Tác động theo ngày thường và cuối tuần (panel vùng × ngày).....	104
Bảng 4.17. Các vùng có trọng số dương trong CRZ tổng hợp.....	105

Bảng 4.18. Ước lượng DML (PLR) và AIPW theo hai bộ biến kiểm soát.....	108
Bảng 4.19. Kiểm định BLP cho tác động không đồng nhất.....	108
Bảng 4.20. CLAN: đặc trưng trung bình của nhóm có tác động lên số chuyển mạnh nhất và yếu nhất.....	109
Bảng 4.21. Hồi quy tác động theo vùng lên đặc trưng vùng (37 vùng CRZ; $R^2 = 0,535$ và $0,356$).....	112
Bảng 4.22. Tác động theo dải khoảng cách tới CRZ (log số chuyển, so với vùng cách trên 10 km).....	113
Bảng 4.23. Tác động lên các vùng ngoài CRZ cách ranh giới không quá 5 km, theo quận (so với các vùng xa hơn).....	114
Bảng 4.24. Tác động lên taxi vàng (đối chứng: Manhattan phía bắc; panel vùng $\times$ tuần).....	115
Bảng 4.25. Giả được theo thời gian trên panel vùng $\times$ tuần (chính sách giả 07/07/2024, chỉ dữ liệu 2024).....	116
Bảng 4.26. Giả được theo thời gian trên panel cặp OD $\times$ tháng.....	117
Bảng 4.27. Độ vững của tác động lên log số chuyển HVFHV đón qua các đặc tả.....	118
Bảng 4.28. Giả được theo năm, tác động thô, tác động sau điều chỉnh xu hướng và gia tốc (panel vùng $\times$ tháng 2022–2025).....	121
Bảng 4.29. Giá trị phá vỡ theo hai lớp giới hạn của Rambachan–Roth.....	123
Bảng 4.30. Tác động lên số chuyển theo ngũ phân vị tỷ trọng phí trong giá (panel cặp OD $\times$ tháng).....	124
Bảng 4.31. Mức tăng tốc độ theo giờ $\times$ loại ngày hồi quy theo lưu lượng CRZ $\rightarrow$ CRZ năm 2024.....	125
Bảng 4.32. Tác động sau chính sách theo mức phơi nhiễm của các vùng ngoài CRZ.....	126
Bảng 4.33. Tác động lên số chuyển theo ngũ phân vị phơi nhiễm.....	126
Bảng 4.34. Tổng hợp kết quả kiểm định các giả thuyết lý thuyết.....	128
Bảng 4.35. Tổng hợp các ước lượng mức giảm số chuyển HVFHV chạm CRZ.....	129
Bảng 4.36. Đối chiếu câu hỏi nghiên cứu, kết quả và mức độ chắc chắn.....	129
Bảng 5.1. Cấu hình Spark dùng trong các thực nghiệm.....	132
Bảng 5.2. Tám thực nghiệm với Spark.....	133
Bảng 5.3. Tái lập bảng zone_day_pu bằng Spark trên toàn bộ lớp Silver.....	134
Bảng 5.4. Đối chứng Spark – DuckDB, lần 1 (trước khi sửa lỗi).....	135
Bảng 5.5. Đối chứng Spark – DuckDB, lần 2 (sau khi sửa lỗi).....	136
Bảng 5.6. DuckDB và Spark trên cùng truy vấn, 19.564.232 dòng HVFHV tháng 03/2025.....	137
Bảng 5.7. Thời gian truy vấn theo số tháng HVFHV năm 2025.....	138
Bảng 5.8. Thời gian truy vấn theo số phân vùng xáo trộn, có và không có AQE.....	139
Bảng 5.9. Thời gian ba truy vấn trước và sau khi lưu đệm DataFrame một tháng HVFHV (trung vị 2 lần).....	140
Bảng 5.10. Tác động của cắt tỉa phân vùng kiểu Hive và đẩy điều kiện lọc trong Spark.....	141
Bảng 5.11. Thời gian chuyển một DataFrame Spark sang pandas.....	143
Bảng 5.12. Số liệu của từng lô vi mô trong Structured Streaming.....	144

Bảng 6.1. Đối chiếu chủ đề quản trị dữ liệu và rủi ro của bài giảng với phần triển khai.....	148
Bảng 6.2. Danh mục dữ liệu của đồ án, tạo tự động từ siêu dữ liệu Parquet.....	148
Bảng 6.3. Số ngày bất thường theo dịch vụ và nhóm vùng, 2024–2025.....	154
Bảng 6.4. Hai mươi ngày bất thường nhất của số chuyến HVFHV đón trong CRZ.....	154
Bảng 6.5. Quy tắc nghiệp vụ và mức trùng với Isolation Forest.....	155
Bảng 6.6. Trung vị các đặc trưng của chuyến bình thường và bất thường.....	156
Bảng 6.7. Tỷ lệ chuyến nằm trong lớp tương đương nhỏ theo mức chi tiết của thuộc tính định danh gián tiếp.....	158
Bảng 6.8. Ước lượng TWFE log số chuyến khi bảng vùng $\times$ ngày được cộng nhiễu Laplace (40 lần lặp mỗi ϵ ; bản gốc: -9,27%).....	160
Bảng 6.9. Phân loại tài sản dữ liệu và biện pháp kiểm soát.....	161
Bảng 6.10. Thời gian phục hồi (RTO) đo từ nhật ký thực thi của pipeline.....	162
Bảng 6.11. Số đăng ký rủi ro của pipeline và của các kết luận.....	163
Bảng 7.1. Tác động của phí CRZ lên số chuyến theo hãng và thị phần của Uber (panel vùng $\times$ tuần).....	164
Bảng 7.2. Độ chính xác dự báo trên giai đoạn giữ lại và chênh lệch thực tế – dự báo sau chính sách.....	166
Bảng 7.3. Ước lượng và tác động nhỏ nhất phát hiện được theo độ dài giai đoạn sau chính sách.....	168
Bảng 7.4. Độ co giãn của giá cước mỗi dặm theo số chuyến và tốc độ giữa các giờ trong ngày	169
Bảng 7.5. Tác động trung bình theo nhóm (GATES) của số chuyến và tốc độ.....	170
Bảng 7.6. Tác động có điều kiện trung bình theo loại luồng.....	170
Bảng 7.7. Hạch toán tài nguyên của pipeline, đo từ nhật ký và siêu dữ liệu.....	171
Bảng 7.8. Các sản phẩm dữ liệu có thể xây dựng từ tài sản của đồ án.....	173
Bảng 7.9. Lộ trình chiến lược dữ liệu đề xuất cho một cơ quan quản lý vận tải.....	173
Bảng 8.1. Tổng hợp các hạn chế, ảnh hưởng và hướng khắc phục.....	182
Bảng B.1. Chỉ tiêu HVFHV theo vùng – Manhattan.....	258
Bảng B.2. Chỉ tiêu HVFHV theo vùng – Brooklyn.....	259
Bảng B.3. Chỉ tiêu HVFHV theo vùng – Queens.....	261
Bảng B.4. Chỉ tiêu HVFHV theo vùng – Bronx.....	262
Bảng B.5. Chỉ tiêu HVFHV theo vùng – Staten Island.....	263
Bảng B.6. Chỉ tiêu HVFHV theo vùng – EWR.....	263
Bảng C.1. Chỉ tiêu theo tháng – HVFHV, nhóm vùng đón CRZ.....	265
Bảng C.2. Chỉ tiêu theo tháng – HVFHV, nhóm vùng đón Vắt ranh giới.....	265
Bảng C.3. Chỉ tiêu theo tháng – HVFHV, nhóm vùng đón Manhattan phía bắc.....	266
Bảng C.4. Chỉ tiêu theo tháng – HVFHV, nhóm vùng đón Quận ngoại.....	266
Bảng C.5. Chỉ tiêu theo tháng – HVFHV, nhóm vùng đón Sân bay.....	267
Bảng C.6. Chỉ tiêu theo tháng – taxi vàng, nhóm vùng đón CRZ.....	267

Bảng C.7. Chỉ tiêu theo tháng – taxi vàng, nhóm vùng đón Vắt ranh giới.....	268
Bảng C.8. Chỉ tiêu theo tháng – taxi vàng, nhóm vùng đón Manhattan phía bắc.....	269
Bảng C.9. Chỉ tiêu theo tháng – taxi vàng, nhóm vùng đón Quận ngoại.....	269
Bảng C.10. Chỉ tiêu theo tháng – taxi vàng, nhóm vùng đón Sân bay.....	270
Bảng D.1. Luồng CRZ → CRZ theo giờ đón (HVFHV).....	271
Bảng D.2. Luồng CRZ → Quận ngoại theo giờ đón (HVFHV).....	271
Bảng D.3. Luồng Quận ngoại → CRZ theo giờ đón (HVFHV).....	272
Bảng D.4. Luồng CRZ → Manhattan phía bắc theo giờ đón (HVFHV).....	272
Bảng D.5. Luồng Manhattan phía bắc → CRZ theo giờ đón (HVFHV).....	273
Bảng D.6. Luồng Manhattan phía bắc → Manhattan phía bắc theo giờ đón (HVFHV).....	273
Bảng D.7. Luồng Quận ngoại → Quận ngoại theo giờ đón (HVFHV).....	274
Bảng D.8. Luồng CRZ → Sân bay theo giờ đón (HVFHV).....	275
Bảng E.1. Hệ số nghiên cứu sự kiện theo tuần, log số chuyển đón – HVFHV (TWFE, chuẩn hóa theo trung bình kỳ trước).....	276
Bảng E.2. Hệ số DDD theo tuần sau chính sách, log số chuyển đón – HVFHV.....	278
Bảng E.3. Hệ số nghiên cứu sự kiện theo tuần, log số chuyển đón – taxi vàng (TWFE, chuẩn hóa theo trung bình kỳ trước).....	279
Bảng E.4. Hệ số DDD theo tuần sau chính sách, log số chuyển đón – taxi vàng.....	281
Bảng E.5. Hệ số nghiên cứu sự kiện theo tháng cho sáu chỉ tiêu (HVFHV; hệ số chuẩn hóa, sai số chuẩn trong ngoặc).....	282
Bảng E.6. Hệ số DiD riêng của từng vùng CRZ (sai số chuẩn trong ngoặc).....	282
Bảng E.7. Hệ số nghiên cứu sự kiện theo tháng trên panel cặp OD (log số chuyển).....	283
Bảng F.1. Kết quả SCM cho 60 vùng giả được, sắp theo tỷ số RMSPE.....	284
Bảng F.2. Chuỗi chỉ số tuần của CRZ thực tế và CRZ tổng hợp.....	285
Bảng F.3. Các phân vị của phân phối hoán vị (500 lần).....	287
Bảng F.4. Kết quả kiểm soát chất lượng theo tháng – HVFHV.....	287
Bảng F.5. Kết quả kiểm soát chất lượng theo tháng – taxi vàng.....	288
Bảng F.6. Danh mục 48 tệp chuyển đi ở lớp Bronze.....	288
Bảng F.7. Thời gian xử lý của từng phân vùng.....	289
Bảng G.1. Danh mục các tệp bảng kết quả.....	292
Bảng G.2. Danh mục các tệp hình.....	294
Bảng H.1. Thời gian tái lập của 48 phân vùng tháng-dịch vụ.....	296
Bảng H.2. Đối chứng từng chỉ tiêu, trước khi sửa lỗi.....	297
Bảng H.3. Đối chứng từng chỉ tiêu, sau khi sửa lỗi.....	297
Bảng H.4. Dấu băm SHA-256 của 50 tệp nguồn.....	298
Bảng H.5. Kết quả ba phép đối soát cho 48 phân vùng.....	299
Bảng H.6. Các bảng Gold mà mỗi bước đọc, ghi và số sản phẩm tạo ra.....	300

DANH MỤC HÌNH ẢNH

Hình 3.1. Kiến trúc pipeline Lakehouse và các lớp phân tích của đồ án.....	60
Hình 3.2. Số bản ghi thô theo tháng của HVFHV và taxi vàng, 01/2024 – 12/2025.....	62
Hình 3.3. Thời gian xử lý mỗi phân vùng (Bronze → Silver → Gold) theo số dòng đầu vào.	64
Hình 3.4. Tỷ lệ bản ghi vi phạm từng quy tắc chất lượng theo dịch vụ.....	67
Hình 3.5. Phân nhóm 263 vùng taxi theo mức độ chịu phí CBD, xác định từ dữ liệu quý I/2025.....	69
Hình 3.6. Manhattan: vùng CRZ và sáu vùng vượt qua ranh giới (đánh số theo mã vùng TLC)	70
Hình 4.1. Dung lượng tệp và thời gian truy vấn tổng hợp theo định dạng lưu trữ.....	77
Hình 4.2. Thời gian và bộ nhớ đỉnh của ba bộ máy xử lý.....	78
Hình 4.3. Số chuyến HVFHV theo nhóm vùng đón, trung bình trượt 7 ngày, 01/2024 – 12/2025.....	82
Hình 4.4. Tăng trưởng cùng kỳ số chuyến HVFHV theo tuần ISO, 2025 so với 2024.....	83
Hình 4.5. Thay đổi cùng kỳ số chuyến HVFHV theo vùng đón (05/01 – 31/12), 2025 so với 2024.....	84
Hình 4.6. Chỉ số số chuyến đón trong CRZ theo tuần, HVFHV và taxi vàng (trung bình tuần năm 2024 = 100).....	85
Hình 4.7. Tổng phí CBD ghi nhận trong dữ liệu chuyến đi theo tháng và dịch vụ, năm 2025	86
Hình 4.8. Số chuyến HVFHV có điểm đầu hoặc điểm cuối trong CRZ, trung bình theo giờ đón.....	88
Hình 4.9. Thị phần Uber theo tháng trên toàn thành phố và trong các chuyến chạm CRZ.....	89
Hình 4.10. Nghiên cứu sự kiện theo tuần cho log số chuyến HVFHV đón trong CRZ (chuẩn hóa theo trung bình 52 tuần trước).....	91
Hình 4.11. Tác động theo tuần sau khi khởi mùa vụ nhóm (DDD): so sánh từng tuần năm 2025 với tuần cùng vị trí năm 2024.....	92
Hình 4.12. Nghiên cứu sự kiện theo tháng cho sáu chỉ tiêu (HVFHV, panel vùng × tuần, chuẩn hóa theo trung bình 2024).....	94
Hình 4.13. Tốc độ trung bình theo tháng của ba loại luồng chuyến HVFHV.....	95
Hình 4.14. Tốc độ trung bình của chuyến HVFHV nội vùng CRZ theo giờ đón, năm 2024 và 2025.....	96
Hình 4.15. Chênh lệch thay đổi tốc độ cùng kỳ theo giờ và loại ngày: luồng CRZ → CRZ từ luồng quận ngoài → quận ngoài.....	96
Hình 4.16. Phân phối tổng chi phí hành khách/chuyến từ mẫu 0,25% chuyến HVFHV, theo năm và loại chuyến.....	98
Hình 4.17. Giá cước cơ sở trên mỗi dặm theo tháng, chuyến chạm CRZ và không chạm CRZ	99
Hình 4.18. Thu nhập tài xế trên mỗi dặm theo tháng, chuyến chạm CRZ và không chạm CRZ	99

Hình 4.19. Thời gian chờ từ lúc gọi xe đến lúc đón theo tháng, chuyển chạm CRZ và không chạm CRZ.....	100
Hình 4.20. Tỷ lệ thu nhập tài xế trên giá cước cơ sở theo tháng.....	100
Hình 4.21. Phân bố quãng đường chuyển HVFHV theo loại chuyển và năm (mẫu 0,25%, 05/01 – 31/12).....	101
Hình 4.22. Nghiên cứu sự kiện theo tháng trên panel cặp OD: log số chuyển của cặp chạm CRZ so với cặp không chạm.....	102
Hình 4.23. Tác động DiD theo khung giờ đón lên log số chuyển và tốc độ.....	103
Hình 4.24. Kiểm soát tổng hợp: chỉ số số chuyển HVFHV đón trong CRZ thực tế và tổng hợp, cùng khoảng cách giữa hai chuỗi.....	104
Hình 4.25. Giả được theo không gian: khoảng cách SCM của CRZ so với của 60 vùng đối chứng lớn nhất.....	106
Hình 4.26. Phân phối tỷ số RMSPE sau/trước của các vùng giả được và vị trí của CRZ.....	106
Hình 4.27. Phân phối điểm xu hướng cross-fitted của cặp OD chạm và không chạm CRZ (bộ biến rút gọn).....	107
Hình 4.28. GATES: tác động trung bình theo nhóm ngũ phân vị của CATE ước lượng.....	109
Hình 4.29. CATE ước lượng theo quãng đường trung bình của cặp OD chạm CRZ.....	110
Hình 4.30. Tỷ trọng đóng góp (gain) của các đặc trưng trong mô hình CATE cho Δ log số chuyển.....	110
Hình 4.31. Tác động DiD riêng của từng vùng CRZ lên số chuyển đón (%).....	111
Hình 4.32. Tác động theo vùng CRZ so với quy mô vùng và độ sâu bên trong CRZ.....	112
Hình 4.33. Tác động theo dải khoảng cách tới ranh giới CRZ, phía điểm đón và phía điểm trả (so với vùng cách trên 10 km).....	113
Hình 4.34. Nghiên cứu sự kiện theo tuần cho log số chuyển taxi vàng đón trong CRZ.....	115
Hình 4.35. Phân phối hệ số DiD khi gán xử lý ngẫu nhiên cho các vùng đối chứng (500 lần) và ước lượng thật.....	118
Hình 4.36. Hệ số DiD log số chuyển qua các đặc tả, kèm khoảng tin cậy 95%.....	119
Hình 4.37. Hệ số nghiên cứu sự kiện khứ mùa vụ theo tháng, 2023–2025 (năm gốc 2022).....	121
Hình 4.38. Khoảng tin cậy của tác động theo $\tilde{M}$ trong lớp độ lớn tương đối.....	123
Hình 4.39. Kiểm định ba giả thuyết: liều – đáp ứng theo tỷ trọng phí (trái), tốc độ – lưu lượng (giữa), lan tỏa theo mức phơi nhiễm (phải).....	125
Hình 5.1. Thời gian truy vấn của DuckDB và Spark: một tháng (trái) và theo khối lượng dữ liệu (phải).....	137
Hình 5.2. Ảnh hưởng của số phân vùng xáo trộn đến thời gian truy vấn khi bật và tắt AQE.....	139
Hình 5.3. Thời gian truy vấn khi đọc lại từ Parquet và khi đọc từ bộ đệm trong bộ nhớ.....	140
Hình 5.4. Thời gian xử lý và số dòng của từng lô vi mô.....	144
Hình 5.5. Các cửa sổ 1 giờ do Structured Streaming phát ra quanh ngày bắt đầu thu phí.....	145
Hình 6.1. Phả hệ dữ liệu của đồ án: từ Bronze, Silver, các bảng Gold đến từng bước phân tích và sản phẩm.....	150

Hình 6.2. Biểu đồ kiểm soát tỷ lệ bản ghi bị loại theo tháng: giới hạn p nhị thức và giới hạn p' của Laney.....	152
Hình 6.3. Số chuyển HVFHV đón trong CRZ theo ngày, giá trị kỳ vọng và các ngày bất thường.....	153
Hình 6.4. Quãng đường và giá cước của chuyển bình thường và chuyển bị Isolation Forest đánh dấu.....	156
Hình 6.5. Rủi ro tái nhận dạng theo mức chi tiết của thuộc tính định danh gián tiếp.....	158
Hình 6.6. Đánh đổi giữa ngân sách riêng tư ϵ và ước lượng tác động lên số chuyển.....	160
Hình 7.1. Số chuyển thực tế và dự báo phản thực tế của mô hình được chọn (trên) và chênh lệch theo tháng (dưới).....	166
Hình 7.2. Giá trị tuyệt đối của ước lượng và MDE theo số tuần sau chính sách.....	168

CHƯƠNG 1. GIỚI THIỆU NGHIÊN CỨU

1.1. Bối cảnh nghiên cứu

1.1.1. Ùn tắc đô thị và ý tưởng định giá đường

Ùn tắc giao thông là một dạng ngoại tác điển hình. Khi một chiếc xe đi vào con đường đã đông, người lái chỉ tính thời gian và chi phí của chính mình, còn phần thời gian bị kéo dài thêm cho mọi xe khác thì không ai trả. Kết quả là đường phố bị sử dụng quá mức so với mức tối ưu xã hội. Ý tưởng đánh phí để người đi đường tự gánh chi phí biên mà họ gây ra đã có từ Pigou (1920) và được Vickrey (1969) phát triển thành lý thuyết định giá ùn tắc hiện đại. Trong gần một thế kỷ, ý tưởng này chủ yếu tồn tại trên giấy vì khó đo lường, khó thu phí và khó thuyết phục cử tri.

Điều kiện kỹ thuật đã thay đổi. Hệ thống thu phí điện tử, camera đọc biển số và thiết bị định vị trên từng xe cho phép thu phí theo vùng mà không cần trạm dừng. Singapore áp dụng từ năm 1975 và chuyển sang thu phí điện tử năm 1998, London từ năm 2003, Stockholm thử nghiệm năm 2006 rồi áp dụng chính thức năm 2007. Các nghiên cứu đánh giá những chương trình này (Leape, 2006; Eliasson, 2009; Börjesson và cộng sự, 2012) đều ghi nhận lưu lượng xe vào vùng thu phí giảm đáng kể, song cũng cho thấy kết quả phụ thuộc nhiều vào cấu trúc mạng lưới giao thông, mức phí và các phương thức thay thế sẵn có.

1.1.2. Chính sách phí vùng giảm ùn tắc tại New York

New York là thành phố đầu tiên ở Hoa Kỳ triển khai phí ùn tắc theo vùng. Từ ngày 05/01/2025, Cơ quan Vận tải Đô thị (MTA) thu phí đối với phương tiện đi vào Manhattan từ đường 60 trở xuống, được gọi là Congestion Relief Zone (CRZ). Xe con cá nhân trả phí theo ngày. Taxi và xe cho thuê không trả theo lượt vào vùng mà trả theo từng chuyến có liên quan đến vùng: theo công bố của MTA, mỗi chuyến của dịch vụ xe cho thuê số lượng lớn (HVFHV, tức Uber và Lyft) bị tính 1,50 USD, còn taxi vàng, taxi xanh và các xe cho thuê khác bị tính 0,75 USD. Khoản phí này được cộng vào hóa đơn của hành khách và xuất hiện trong dữ liệu chuyến đi dưới tên cột `cbd_congestion_fee`.

Trước chính sách, New York đã có một khoản phụ thu ùn tắc từ năm 2019 áp cho chuyến taxi và xe cho thuê đi qua Manhattan phía nam đường 96. Khoản phụ thu này

vẫn giữ nguyên trong năm 2025. Như vậy, phí CRZ là một cú sốc giá cộng thêm, có ranh giới địa lý rõ ràng và có ngày bắt đầu xác định. Đây là cấu trúc gần với một thí nghiệm tự nhiên: một nhóm khu vực chịu phí từ một thời điểm cụ thể, các khu vực khác thì không.

Trong dữ liệu năm 2025, khoảng 34,0% số chuyến HVFHV trên toàn thành phố có ghi nhận phí CBD. Con số này cho thấy chính sách chạm tới khoảng một phần ba thị trường gọi xe, dù CRZ chỉ chiếm một diện tích nhỏ của thành phố. Chính mức độ tập trung đó làm cho câu hỏi về tác động trở nên có ý nghĩa với cả hành khách, tài xế, doanh nghiệp nền tảng và cơ quan quản lý.

1.1.3. Dữ liệu chuyển đi như một tài sản dữ liệu lớn

Ủy ban Taxi và Limousine New York (TLC) công bố hồ sơ từng chuyến của taxi vàng, taxi xanh và xe cho thuê theo tháng dưới định dạng Parquet. Riêng nhóm HVFHV, mỗi tháng có khoảng 19–22 triệu chuyến, mỗi chuyến có thời điểm gọi xe, thời điểm đón, thời điểm trả, vùng đón, vùng trả, quãng đường, thời lượng, giá cước cơ sở, các loại phí, tiền tip và thu nhập của tài xế. Đây là dữ liệu có đủ các đặc trưng của dữ liệu lớn mà bài giảng của môn học nêu ra: khối lượng lớn, cập nhật đều đặn, có lịch lược đồ giữa các giai đoạn và có sai sót ở mức từng bản ghi.

Đồ án sử dụng 24 tháng dữ liệu HVFHV và taxi vàng, tổng cộng 572.952.454 bản ghi thô. Với quy mô này, cách làm quen thuộc là đọc toàn bộ vào pandas rồi phân tích không còn khả thi trên máy tính cá nhân. Việc đánh giá chính sách vì vậy đòi hỏi một kiến trúc xử lý dữ liệu đúng nghĩa: tách lớp lưu trữ và lớp tính toán, dùng định dạng cột nén, xử lý theo phân vùng, kiểm soát chất lượng tự động và chỉ đưa các bảng tổng hợp nhỏ vào bước mô hình hóa.

1.2. Vấn đề nghiên cứu

1.2.1. Tác động trung bình đã có ước lượng ban đầu, nhưng còn thô

Ngay sau khi chính sách có hiệu lực, một số nghiên cứu nhanh đã sử dụng dữ liệu TLC để đo mức thay đổi số chuyến gọi xe. Pandey, Guler và Gayah (2026) dùng sai khác kép và báo cáo tổng số chuyến của các công ty gọi xe giảm 5,95%, trong khi số yêu cầu đi chung giảm mạnh hơn nhiều. Các ước lượng như vậy trả lời câu hỏi "trung bình giảm bao nhiêu" nhưng để lại ba khoảng trống: tác động khác nhau thế nào

giữa các loại chuyển và khung giờ; phần nhu cầu bị mất có dịch chuyển sang các vùng lân cận hay không; và ai là người thực sự gánh khoản phí.

Ba khoảng trống này quan trọng vì chúng quyết định cách đọc con số trung bình. Nếu nhu cầu chỉ dịch chuyển điểm đón ra ngoài ranh giới vài trăm mét, mức giảm trong vùng không đồng nghĩa với giảm số người đi lại. Nếu vùng đối chứng bị ảnh hưởng gián tiếp, ước lượng sai khác kép sẽ bị chệch. Nếu nền tảng tăng giá cước cơ sở cùng lúc với phí, gánh nặng của hành khách lớn hơn mức phí danh nghĩa.

1.2.2. Thách thức nhận dạng nhân quả

Vùng CRZ không được chọn ngẫu nhiên. Đây là khu trung tâm thương mại và du lịch, có nhịp mùa vụ khác hẳn các quận ngoại: đông vào dịp lễ cuối năm, thưa vào mùa hè, nhạy với lượng khách du lịch và lịch làm việc tại văn phòng. Nếu so sánh đơn giản năm 2025 với năm 2024, ta trộn lẫn tác động của phí với xu hướng riêng của khu trung tâm. Nếu so sánh CRZ với vùng ngoại trong cùng tuần, ta phải giả định hai nhóm có xu hướng song song khi không có chính sách, một giả định cần được kiểm tra chứ không thể chấp nhận mặc nhiên.

Một thách thức khác là sự chồng lấn thấp giữa nhóm xử lý và nhóm đối chứng. Các cặp điểm đón – điểm trả chặng CRZ có quãng đường, tốc độ và giá cước khác biệt có hệ thống so với các cặp ở quận ngoại. Các phương pháp học máy nhân quả chỉ cho kết quả đáng tin trong vùng mà hai nhóm có đặc trưng tương tự nhau, và vùng này cần được xác định bằng dữ liệu.

1.2.3. Thách thức kỹ thuật dữ liệu

Ở góc độ kỹ thuật, vấn đề là làm sao biến gần sáu trăm triệu bản ghi thô thành các bảng phân tích đáng tin, trong điều kiện tài nguyên hạn chế, với quy trình có thể chạy lại và kiểm tra. Lược đồ dữ liệu thay đổi giữa hai năm (cột `cbd_congestion_fee` chỉ xuất hiện từ tháng 01/2025), một phần bản ghi có vùng không xác định hoặc giá trị bất thường, và ranh giới đường 60 cắt ngang một số vùng taxi. Mỗi lựa chọn xử lý ở đây đều ảnh hưởng đến kết quả nhân quả, nên cần được ghi lại và đo lường.

1.3. Mục tiêu nghiên cứu

1.3.1. Mục tiêu tổng quát

Đồ án nhằm đánh giá tác động nhân quả của phí vùng giảm ùn tắc Manhattan lên thị trường gọi xe công nghệ, bao gồm nhu cầu, điều kiện di chuyển, giá cước và thu nhập tài xế, đồng thời xây dựng một pipeline dữ liệu lớn theo kiến trúc Lakehouse đủ tin cậy để các ước lượng có thể được tái lập.

1.3.2. Mục tiêu cụ thể

- 1) Xây dựng pipeline Bronze–Silver–Gold xử lý toàn bộ dữ liệu HVFHV và taxi vàng 2024–2025, có kiểm soát chất lượng, ghi nhật ký và đo hiệu năng.
- 2) Xác định tập vùng chịu phí bằng dữ liệu thay vì gán tay, và nhận diện các vùng nằm vắt qua ranh giới.
- 3) Ước lượng tác động trung bình của phí lên số chuyến, tốc độ, thời gian chờ, giá cước, chi phí hành khách và thu nhập tài xế bằng nhiều thiết kế nhận dạng khác nhau.
- 4) Ước lượng tác động không đồng nhất theo loại luồng, khung giờ, ngày trong tuần và đặc trưng của cặp điểm đón – điểm trả bằng học máy nhân quả.
- 5) Đo hiệu ứng lan tỏa không gian sang các vùng lân cận ranh giới.
- 6) Kiểm tra độ tin cậy của các kết luận bằng giả được theo thời gian, giả được theo không gian, suy luận hoán vị và một loạt đặc tả thay thế.
- 7) Tái lập bảng phân tích chính bằng Apache Spark để đối chứng chéo với DuckDB, và đo tác động của các cơ chế xử lý phân tán (tối ưu truy vấn, xáo trộn, lưu đệm, cắt tía phân vùng, Arrow, xử lý luồng) trên chính dữ liệu của đề tài.
- 8) Đánh giá quản trị dữ liệu và rủi ro của tài sản dữ liệu: danh mục, phả hệ, tính toàn vẹn, giám sát chất lượng, phát hiện bất thường, rủi ro tái nhận dạng và khả năng công bố có quyền riêng tư vi phân.
- 9) Chuyển kết quả thành thông tin cho quyết định kinh doanh: tác động theo hãng, dự báo nhu cầu, quy mô dữ liệu cần cho thử nghiệm, định giá động và giá trị của tài sản dữ liệu.

1.4. Câu hỏi nghiên cứu

1.4.1. Tám câu hỏi nghiên cứu

- **RQ1.** Kiến trúc Lakehouse với DuckDB và Parquet có xử lý được toàn bộ dữ liệu trong điều kiện tài nguyên hạn chế không, và các lựa chọn định dạng, bộ máy xử lý ảnh hưởng thế nào đến chi phí tính toán?
- **RQ2.** Phí CRZ làm thay đổi số chuyến gọi xe có điểm đầu hoặc điểm cuối trong vùng bao nhiêu so với phản thực không có chính sách?
- **RQ3.** Phí có cải thiện điều kiện di chuyển, thể hiện qua tốc độ chuyển đi và thời gian chờ xe, hay không?
- **RQ4.** Tác động có khác nhau giữa loại luồng, khung giờ, ngày trong tuần và đặc trưng chuyển đi không, và có lan sang các vùng lân cận ranh giới không?
- **RQ5.** Phí được chuyển sang hành khách và tài xế như thế nào, và dữ liệu hiện có cho phép kết luận đến đâu về điểm này?
- **RQ6.** Một bộ máy xử lý phân tán trong bộ nhớ (Apache Spark) có tái lập đúng kết quả của bộ máy nhúng không, tốn thêm bao nhiêu tài nguyên trên cùng phần cứng, và các cơ chế của nó tác động đến hiệu năng ra sao?
- **RQ7.** Tài sản dữ liệu của đồ án có những rủi ro nào về toàn vẹn, chất lượng và quyền riêng tư, và có thể công bố dữ liệu tổng hợp bảo vệ quyền riêng tư mà vẫn giữ được kết luận chính sách không?
- **RQ8.** Kết quả tạo ra thông tin gì cho quyết định kinh doanh, và phương pháp nào đáng tin cho từng loại quyết định?

1.4.2. Mức độ chắc chắn kỳ vọng của từng câu trả lời

Các câu hỏi không có cùng mức độ trả lời được. RQ1 là câu hỏi kỹ thuật, được trả lời trực tiếp bằng số đo thời gian, dung lượng và bộ nhớ. RQ2 và RQ3 có cấu trúc nhận dạng rõ ràng, nên có thể trả lời bằng nhiều phương pháp độc lập để đối chiếu. RQ4 dựa trên các giả định mạnh hơn, đặc biệt là giả định chồng lấn trong học máy nhân quả. RQ5 khó nhất vì giá cước và thu nhập tài xế chịu ảnh hưởng của những thay đổi quy định và chiến lược giá khác diễn ra trong cùng giai đoạn. RQ6 và RQ7 lại là câu hỏi đo lường trực tiếp trên tài sản dữ liệu, nên có thể trả lời chắc chắn trong phạm vi

vì phần cứng và dữ liệu của đồ án. RQ8 kết hợp cả hai loại, và độ tin cậy của từng câu trả lời phụ thuộc vào thiết kế được dùng. Đồ án chủ động báo cáo cả những trường hợp dữ liệu không đủ để kết luận.

1.5. Phạm vi nghiên cứu

1.5.1. Phạm vi dữ liệu và thời gian

Dữ liệu gồm hồ sơ chuyển HVFHV và taxi vàng từ ngày 01/01/2024 đến ngày 31/12/2025, cùng bảng tra vùng và bản đồ 263 vùng taxi của TLC. Giai đoạn trước chính sách của phân tích chính kéo dài một năm (01/2024 – 04/01/2025), giai đoạn sau gần một năm (05/01/2025 – 31/12/2025). Dữ liệu 2022–2023 của cả hai dịch vụ được bổ sung để kiểm tra xu hướng trước chính sách trên ba năm (mục 3.2.4 và 4.14.4); các bảng Gold của phân tích chính không đổi. Đơn vị không gian nhỏ nhất là vùng taxi, vì TLC không công bố tọa độ chính xác để bảo vệ quyền riêng tư của hành khách.

Taxi xanh và xe cho thuê thông thường không được đưa vào vì quy mô nhỏ và phần lớn hoạt động ngoài Manhattan. Lưu lượng xe con cá nhân không có trong dữ liệu TLC, nên đồ án không đo trực tiếp tổng lưu lượng giao thông vào vùng mà đo gián tiếp qua tốc độ của các chuyến gọi xe.

1.5.2. Phạm vi kết luận

Kết luận của đồ án áp dụng cho thị trường gọi xe và taxi trong năm đầu thực hiện chính sách. Tác động dài hạn, tác động lên giao thông công cộng, chất lượng không khí và hoạt động kinh doanh trong vùng nằm ngoài phạm vi. Các ước lượng về giá cước và thu nhập tài xế được trình bày kèm cảnh báo về xu hướng có sẵn và không được dùng làm căn cứ chính cho khuyến nghị chính sách.

1.6. Phương pháp nghiên cứu tổng quát

1.6.1. Kỹ thuật dữ liệu lớn

Pipeline được tổ chức theo mô hình medallion của kiến trúc Lakehouse. Lớp Bronze giữ nguyên các tệp Parquet gốc và chỉ lập danh mục metadata. Lớp Silver chuẩn hóa hai nguồn về một lược đồ chung, gán cờ chất lượng và ghi lại các chuyển hợp lệ theo phân vùng dịch vụ – năm – tháng. Lớp Gold chứa bảy bảng tổng hợp phục vụ phân tích. DuckDB được dùng làm bộ máy tính toán nhúng, đọc Parquet trực tiếp

theo cột, giới hạn bộ nhớ 1,8 GB và tràn ra đĩa khi cần. Mỗi tháng HVFHV được chia thành bốn khúc theo ngày để vừa bộ nhớ và giới hạn thời gian của môi trường chạy.

1.6.2. Suy luận nhân quả

Thiết kế chính là sai khác kép trên panel vùng $\times$ tuần với hiệu ứng cố định vùng và tuần. Để xử lý mùa vụ riêng của khu trung tâm, đồ án bổ sung hiệu ứng cố định nhóm $\times$ tuần trong năm (sai khác bậc ba khử mùa vụ). Nghiên cứu sự kiện theo tuần và theo tháng cho phép quan sát động thái trước và sau chính sách. Kiểm soát tổng hợp xây dựng một "CRZ giả định" từ tổ hợp các vùng đối chứng. Học máy nhân quả (DML, AIPW, DR-learner) được áp dụng ở cấp cặp điểm đón – điểm trả để ước lượng tác động có điều kiện theo đặc trưng chuyển đi.

1.6.3. Kiểm định độ tin cậy

Mỗi kết luận chính đi kèm ít nhất một phép thử có thể bác bỏ nó: giả được theo thời gian với ngày chính sách giả 07/07/2024, giả được theo không gian trong kiểm soát tổng hợp, suy luận hoán vị với 500 lần gán xử lý ngẫu nhiên và bảng độ vững gồm 17 đặc tả thay thế. Những chỉ tiêu không vượt qua được các phép thử này được báo cáo là chưa xác định được tác động.

1.6.4. Xử lý phân tán, quản trị dữ liệu và phân tích kinh doanh

Ba mô-đun mở rộng bám theo các chương còn lại của bài giảng. Mô-đun xử lý phân tán chạy Apache Spark trên cùng lớp Silver, tái lập bảng Gold chính và so sánh từng ô với bản của DuckDB, rồi đo tám thực nghiệm về hiệu năng và cơ chế. Mô-đun quản trị dữ liệu và rủi ro áp dụng danh mục dữ liệu, phá hệ, dấu bẫy, đối soát, biểu đồ kiểm soát, phát hiện bất thường, k-ẩn danh và quyền riêng tư vi phân lên chính tài sản dữ liệu. Mô-đun phân tích kinh doanh ước lượng tác động theo hãng, so sánh dự báo nhu cầu với suy luận nhân quả, tính công suất thống kê theo độ dài giai đoạn quan sát và hạch toán tài nguyên.

1.7. Đóng góp của nghiên cứu

1.7.1. Đóng góp về phương pháp dữ liệu

Đồ án cho thấy một pipeline Lakehouse hoàn chỉnh cho gần sáu trăm triệu bản ghi có thể chạy trên máy tính cá nhân với khoảng 3 GB RAM, nhờ xử lý theo phân

vùng, đọc theo cột và tổng hợp sớm. Các thực nghiệm hiệu năng được đo trên chính dữ liệu của đề tài, không dùng số liệu tham khảo. Cách xác định vùng xử lý từ dữ liệu, dựa vào tỷ lệ chuyển nội vùng bị thu phí, là một thủ tục có thể áp dụng lại cho các chính sách có ranh giới không trùng với ranh giới đơn vị thống kê.

1.7.2. Đóng góp về bằng chứng thực nghiệm

Đồ án bổ sung cho ước lượng trung bình đã có bằng ba lớp bằng chứng: tác động lên tốc độ và thời gian chờ như thước đo trực tiếp của ùn tắc; tác động không đồng nhất theo loại luồng, khung giờ và đặc trưng chuyển đi; và hiệu ứng lan tỏa theo khoảng cách tới ranh giới. Đồ án cũng chỉ ra rằng việc chọn Manhattan phía bắc làm nhóm đối chứng dẫn đến đánh giá thấp tác động do chính các vùng này chịu ảnh hưởng gián tiếp. Thêm vào đó, với dữ liệu 2022–2025, đồ án cho thấy một phần lớn mức giảm số chuyển mà thiết kế một năm tìm thấy trùng với xu hướng có sẵn, trong khi tác động lên tốc độ và thời gian chờ vẫn đứng vững.

Về lý thuyết, đồ án xây dựng một mô hình đơn giản kết hợp cầu theo chi phí tổng quát, hàm tốc độ – lưu lượng, lan tỏa qua mạng chuyển đi và phân bổ gánh nặng, suy ra tám giả thuyết định lượng và kiểm định chúng bằng các đặc tả liệu – đáp ứng thiết kế riêng. Kết quả chỉ ra nơi mô hình chuẩn giải thích tốt và nơi nó cần được mở rộng.

1.7.3. Đóng góp về tính minh bạch

Toàn bộ số liệu trong báo cáo được sinh tự động từ tệp kết quả. Bộ mã nguồn gồm các bước đánh số từ 00 đến 17 có thể chạy lại từ đầu. Một lỗi ép kiểu trong chính pipeline, được phát hiện nhờ đối chứng với Spark, được báo cáo cùng cách sửa và phạm vi ảnh hưởng. Những kết quả không vững, như tác động lên giá cước, được báo cáo cùng lý do không vững thay vì bị lược bỏ.

1.8. Cấu trúc của báo cáo

Ngoài phần mở đầu, báo cáo gồm chín chương. Chương 1 giới thiệu bối cảnh, vấn đề, mục tiêu và câu hỏi nghiên cứu. Chương 2 trình bày cơ sở lý thuyết về định giá ùn tắc, thị trường gọi xe, kiến trúc dữ liệu lớn và các phương pháp suy luận nhân quả, đồng thời tổng quan các nghiên cứu liên quan. Chương 3 mô tả dữ liệu, kiến trúc pipeline, quy tắc chất lượng và chiến lược nhận dạng. Chương 4 trình bày kết quả, từ hiệu năng pipeline đến các ước lượng nhân quả và phép thử độ tin cậy. Chương 5 đưa

Apache Spark vào để đối chứng chéo và phân tích hiệu năng xử lý phân tán. Chương 6 đánh giá quản trị dữ liệu, quyền riêng tư và rủi ro. Chương 7 chuyển kết quả sang góc nhìn kinh doanh và chiến lược dữ liệu. Chương 8 thảo luận ý nghĩa, hàm ý quản trị và hạn chế. Chương 9 kết luận và nêu hướng nghiên cứu tiếp theo.

Phần phụ lục gồm hồ sơ chi tiết theo từng vùng, bảng theo tháng và theo khung giờ, bảng hệ số đầy đủ của các nghiên cứu sự kiện, danh mục tệp kết quả, nhật ký xử lý phân tán và quản trị dữ liệu, và toàn bộ mã nguồn của pipeline.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU

Chương này trình bày bốn nhóm cơ sở lý thuyết mà đồ án dựa vào: kinh tế học định giá ùn tắc và phân bổ gánh nặng của phí; đặc điểm của thị trường gọi xe công nghệ; kiến trúc và kỹ thuật dữ liệu lớn; và các phương pháp suy luận nhân quả từ dữ liệu quan sát, bao gồm học máy nhân quả. Phần cuối tổng quan các nghiên cứu thực nghiệm liên quan và rút ra khoảng trống mà đồ án hướng tới.

2.1. Kinh tế học định giá ùn tắc

2.1.1. Ùn tắc như một ngoại tác

Xét một đoạn đường có lưu lượng q xe mỗi giờ. Chi phí thời gian trung bình mà mỗi người đi đường phải chịu, ký hiệu $c(q)$, tăng theo q vì xe càng đông thì tốc độ càng chậm. Mỗi người khi quyết định có đi hay không chỉ so sánh lợi ích của chuyến đi với $c(q)$. Tuy nhiên, chiếc xe thứ q còn làm tăng thời gian của $q - 1$ xe khác. Chi phí biên xã hội vì vậy lớn hơn chi phí trung bình:

$$MSC(q) = c(q) + q \cdot c'(q) \quad (2.1)$$

Thành phần $q \cdot c'(q)$ là chi phí ngoại tác. Ở trạng thái cân bằng tự do, lưu lượng dừng tại điểm mà lợi ích biên của chuyến đi cuối cùng bằng $c(q)$, cao hơn mức tối ưu xã hội q^* tại đó lợi ích biên bằng $MSC(q)$. Walters (1961) là người đầu tiên ước lượng khoảng chênh lệch này bằng đường cong tốc độ – lưu lượng thực nghiệm. Vickrey (1969) mở rộng sang mô hình ùn tắc theo thời gian, trong đó người đi đường có thể dời giờ xuất phát, và chỉ ra rằng phí thay đổi theo thời gian có thể xóa gần hết hàng đợi mà không làm giảm nhiều số chuyến.

Mức phí Pigou tối ưu bằng đúng chi phí ngoại tác tại q^* :

$$\tau^* = q^* \cdot c'(q^*) \quad (2.2)$$

Trong thực tế, cơ quan quản lý không biết chính xác $c(q)$ và đường cầu, nên mức phí được chọn theo cân nhắc thực tiễn: đủ lớn để thay đổi hành vi, đủ đơn giản để người dân hiểu, và tạo đủ nguồn thu cho mục tiêu đầu tư. Phí CRZ ở New York được thiết kế chủ yếu theo ràng buộc nguồn thu cho hệ thống giao thông công cộng, nên

không có lý do để kỳ vọng mức phí này trùng với mức Pigou lý thuyết (Small và Verhoef, 2007).

2.1.2. Phản ứng của nhu cầu và độ co giãn

Tác động của phí lên số chuyến phụ thuộc vào độ co giãn của cầu theo tổng chi phí chuyển đi. Với chuyến gọi xe, tổng chi phí gồm giá cước, các khoản phí, tiền tip và thời gian chờ. Nếu gọi p là tổng chi phí bằng tiền và ε là độ co giãn của cầu theo giá, thì một khoản phí τ được chuyển hoàn toàn sang hành khách sẽ làm số chuyến thay đổi xấp xỉ:

$$\Delta q / q \approx \varepsilon \cdot \tau / p \quad (2.3)$$

Công thức này cho một phép kiểm tra hợp lý thô. Với chi phí trung bình của chuyến chạm CRZ khoảng vài chục USD và phí 1,50 USD, mức tăng chi phí danh nghĩa chỉ vài phần trăm. Một mức giảm số chuyến lớn hơn nhiều so với mức tăng này hàm ý hoặc cầu rất co giãn, hoặc chi phí thực tế tăng nhiều hơn mức phí danh nghĩa, hoặc có yếu tố khác cùng lúc làm giảm nhu cầu. Đồ án dùng lập luận này để đối chiếu các ước lượng thực nghiệm ở Chương 8.

Cầu đi lại còn có thể phản ứng theo những kênh không làm giảm số người đi: đổi phương thức sang tàu điện ngầm hoặc taxi (phí taxi thấp hơn), đổi điểm đón hoặc điểm trả ra ngoài ranh giới, đổi giờ đi, hoặc gộp nhiều việc vào một chuyến. Các kênh này tạo ra hiệu ứng lan tỏa không gian và thay thế giữa các dịch vụ, là lý do đồ án phân tích cả vùng lân cận và taxi vàng.

2.1.3. Phân bổ gánh nặng của phí

Lý thuyết phân bổ gánh nặng thuế (tax incidence) cho biết người chịu thuế thực sự không phụ thuộc vào ai là người nộp mà phụ thuộc vào độ co giãn tương đối của cung và cầu. Trong thị trường cạnh tranh, tỷ lệ chuyển giá sang người mua bằng $\varepsilon_S / (\varepsilon_S - \varepsilon_D)$, với ε_S là độ co giãn cung và ε_D là độ co giãn cầu ($\varepsilon_D < 0$). Khi cung rất co giãn, người mua gánh gần hết. Thị trường gọi xe không phải thị trường cạnh tranh hoàn hảo: nền tảng đặt giá bằng thuật toán, tài xế được trả theo công thức riêng và cơ quan quản lý quy định mức thu nhập tối thiểu của tài xế. Với độc quyền hoặc cạnh tranh không hoàn hảo, tỷ lệ chuyển giá có thể vượt 1 (over-shifting) nếu đường cầu đủ lồi.

Với phí CRZ, khoản 1,50 USD được ghi riêng trên hóa đơn và cộng vào tổng tiền của hành khách, nên phần chuyển giá trực tiếp là hoàn toàn. Câu hỏi thực chất là nền tảng có điều chỉnh giá cước cơ sở và phần trả cho tài xế hay không. Đây là câu hỏi thực nghiệm mà, như Chương 4 sẽ cho thấy, rất khó trả lời vì trong cùng giai đoạn còn nhiều yếu tố khác tác động lên giá cước.

2.2. Kinh nghiệm quốc tế về phí ùn tắc theo vùng

2.2.1. Singapore, London và Stockholm

Singapore là nơi đầu tiên áp dụng phí vào khu trung tâm, từ năm 1975 với hệ thống giấy phép khu vực, sau đó chuyển sang thu phí điện tử (Electronic Road Pricing) năm 1998 với mức phí thay đổi theo giờ và theo đoạn đường. London áp dụng phí ngày cho khu trung tâm từ tháng 2/2003. Leape (2006) tổng kết rằng lưu lượng xe vào vùng giảm rõ rệt ngay sau khi áp dụng và thời gian di chuyển trong vùng được cải thiện trong những năm đầu, nhưng một phần cải thiện về tốc độ bị xói mòn về sau do dung lượng đường bị dành cho các mục đích khác.

Stockholm là trường hợp được nghiên cứu kỹ nhất vì có giai đoạn thử nghiệm, trưng cầu ý dân rồi mới áp dụng chính thức. Eliasson (2009) thực hiện phân tích chi phí – lợi ích và kết luận lợi ích về thời gian vượt chi phí vận hành hệ thống. Börjesson và cộng sự (2012) theo dõi năm năm sau và thấy mức giảm lưu lượng được duy trì, trong khi sự ủng hộ của người dân tăng lên sau khi họ trải nghiệm kết quả. Một bài học chung là tác động ban đầu lên lưu lượng thường đáng kể, còn tác động lên tốc độ phụ thuộc vào cách dung lượng đường được quản lý sau đó.

2.2.2. Điểm khác biệt của trường hợp New York

Trường hợp New York có ba khác biệt đáng lưu ý. Thứ nhất, thị phần của xe gọi công nghệ trong giao thông khu trung tâm rất lớn, trong khi ở London năm 2003 hay Stockholm năm 2006 các nền tảng này chưa tồn tại. Thứ hai, taxi và xe cho thuê không trả phí ngày mà trả theo từng chuyến, tức là phí đánh trực tiếp vào giao dịch dịch vụ thay vì vào phương tiện. Thứ ba, dữ liệu từng chuyến của các dịch vụ này được công bố công khai theo tháng, cho phép đánh giá chính sách với độ phân giải mà các nghiên cứu trước không có.

2.3. Thị trường gọi xe công nghệ

2.3.1. Cấu trúc thị trường hai phía

Nền tảng gọi xe là thị trường hai phía: một phía là hành khách, phía kia là tài xế, nền tảng đứng giữa ghép cặp và đặt giá. Cramer và Krueger (2016) cho thấy tài xế Uber có tỷ lệ thời gian chờ khách cao hơn taxi truyền thống, một phần nhờ thuật toán ghép cặp. Cohen và cộng sự (2016) dùng dữ liệu hệ số tăng giá của Uber để ước lượng đường cầu và thặng dư người tiêu dùng, cho thấy dữ liệu giao dịch quy mô lớn có thể trả lời những câu hỏi kinh tế học vốn cần thực nghiệm tốn kém.

Trong thị trường hai phía, một cú sốc chi phí ở phía hành khách lan sang phía tài xế qua thời gian chờ và mức độ sử dụng xe. Nếu nhu cầu trong CRZ giảm, số xe rảnh tăng, thời gian chờ của hành khách giảm, còn thu nhập theo giờ của tài xế có thể giảm dù thu nhập theo chuyến không đổi. Vì vậy thời gian chờ là chỉ tiêu cần theo dõi bên cạnh tốc độ.

2.3.2. Gọi xe và ùn tắc

Erhardt và cộng sự (2019) ước lượng rằng sự phát triển của các công ty gọi xe tại San Francisco góp phần đáng kể vào mức gia tăng ùn tắc giai đoạn 2010–2016, qua việc tăng quãng đường xe chạy, kể cả quãng đường chạy không để đón khách. Kết quả này là một trong những lập luận chính để đưa xe gọi công nghệ vào diện chịu phí ùn tắc. Ở chiều ngược lại, tốc độ của xe gọi công nghệ phản ánh trực tiếp tình trạng đường phố, nên dữ liệu chuyển đi của chúng là nguồn quan sát ùn tắc có độ phủ rộng.

2.3.3. Khung quy định tại New York

Tại New York, TLC quản lý giấy phép và quy định mức thu nhập tối thiểu của tài xế HVFHV theo công thức dựa trên thời gian và quãng đường, được điều chỉnh định kỳ. Từ năm 2019, các chuyến đi qua Manhattan phía nam đường 96 đã chịu phụ thu ùn tắc cấp bang (2,75 USD cho xe cho thuê và 2,50 USD cho taxi). Các quy định này tạo ra những thay đổi giá và thu nhập không liên quan đến phí CRZ và là nguồn gây nhiễu mà thiết kế nhận dạng phải tính đến.

2.4. Kiến trúc và hạ tầng dữ liệu lớn

2.4.1. Từ kho dữ liệu đến Lakehouse

Chương 1 của bài giảng môn học mô tả ba kỷ nguyên của kiến trúc dữ liệu doanh nghiệp. Kho dữ liệu (data warehouse) tập trung dữ liệu có cấu trúc chặt chẽ, tối ưu cho báo cáo nhưng tốn kém và chậm thích ứng. Hồ dữ liệu (data lake) trên HDFS hoặc lưu trữ đối tượng cho phép lưu dữ liệu thô với nguyên lý schema-on-read, nhưng dễ trở thành "đầm lầy dữ liệu" khi thiếu quản trị. Lakehouse kết hợp hai hướng: dữ liệu nằm trên lưu trữ rẻ ở định dạng mở, còn lớp siêu dữ liệu và bộ máy truy vấn cung cấp tính năng quản lý lược đồ và hiệu năng gần với kho dữ liệu (Armbrust và cộng sự, 2021).

Mô hình medallion là cách tổ chức dữ liệu phổ biến trong Lakehouse. Lớp Bronze chứa dữ liệu thô đúng như khi thu nhận, không sửa đổi, để luôn có thể xử lý lại. Lớp Silver chứa dữ liệu đã làm sạch, chuẩn hóa lược đồ và gắn khóa nghiệp vụ. Lớp Gold chứa các bảng tổng hợp phục vụ trực tiếp cho phân tích và mô hình. Đồ án áp dụng đúng mô hình này.

2.4.2. Tách rời lưu trữ và tính toán

Nguyên lý tách rời lưu trữ và tính toán (mục 1.7 của bài giảng) cho phép lưu dữ liệu ở một nơi và đưa bộ máy tính toán đến đọc khi cần. Trong đồ án, dữ liệu nằm dưới dạng tệp Parquet trên ổ đĩa, còn DuckDB được khởi tạo trong từng tiến trình Python, đọc tệp, tính toán rồi giải phóng bộ nhớ. Không có máy chủ cơ sở dữ liệu thường trực. Cách làm này tương tự mô hình serverless trên đám mây, chỉ khác ở quy mô.

2.4.3. Định dạng lưu trữ dạng cột

Apache Parquet là định dạng lưu trữ dạng cột, kế thừa ý tưởng lưu trữ lồng nhau của hệ thống Dremel (Melnik và cộng sự, 2010). Một tệp Parquet được chia thành các nhóm dòng (row group); trong mỗi nhóm dòng, dữ liệu của từng cột được lưu liên nhau thành các khối (column chunk), mã hóa (dictionary, run-length) rồi nén. Chân tệp chứa lược đồ và thống kê min/max của từng cột trong từng nhóm dòng.

Cấu trúc này mang lại ba lợi ích cho phân tích. Thứ nhất là cắt tỉa cột (column pruning): truy vấn chỉ đọc các cột cần dùng. Thứ hai là đẩy điều kiện lọc xuống (predicate pushdown): bộ máy so sánh điều kiện với thống kê min/max để bỏ qua cả nhóm dòng không thể thỏa mãn. Thứ ba là nén hiệu quả vì dữ liệu cùng kiểu, cùng

miền giá trị nằm cạnh nhau. Mục 2.3 của bài giảng so sánh Parquet với Avro (dạng dòng, phù hợp ghi luồng) và ORC (dạng cột, phổ biến trong hệ sinh thái Hive). Đồ án đo trực tiếp các lợi ích này trên dữ liệu thật ở Chương 4.

2.4.4. Bộ máy xử lý trong bộ nhớ và thực thi vector hóa

MapReduce (Dean và Ghemawat, 2008) đặt nền móng cho xử lý phân tán nhưng ghi dữ liệu trung gian xuống đĩa sau mỗi bước. Spark (Zaharia và cộng sự, 2016) giữ dữ liệu trong bộ nhớ và phục hồi lỗi bằng phả hệ phép biến đổi, nhanh hơn nhiều cho các tác vụ lặp. Ở quy mô một máy, các bộ máy phân tích nhúng như DuckDB (Raasveldt và Mühleisen, 2019) áp dụng thực thi vector hóa: mỗi toán tử xử lý một lô vài nghìn giá trị của cùng một cột, tận dụng bộ nhớ đệm CPU, và có thể tràn dữ liệu ra đĩa khi vượt giới hạn bộ nhớ. Apache Arrow chuẩn hóa định dạng cột trong bộ nhớ, cho phép DuckDB, pandas và PyArrow trao đổi dữ liệu mà không phải sao chép.

Với bài toán của đồ án, dữ liệu một tháng HVFHV (khoảng 20 triệu dòng) vừa trên một máy, nhưng 24 tháng thì không. Chiến lược phù hợp là xử lý theo phân vùng với DuckDB và giới hạn bộ nhớ làm bộ máy chính. Đây cũng là tinh thần của mục 3.6 và 3.8 trong bài giảng: chọn công cụ theo quy mô thực tế để tối ưu chi phí tính toán. Đồ án vẫn chạy Spark trên cùng dữ liệu (Chương 5) để kiểm chứng nhận định này bằng số đo và để có một bộ máy độc lập đối chứng kết quả.

2.4.5. Điều phối, tính lũy đẳng và khả năng tái lập

Một pipeline dữ liệu lớn cần chạy lại được từng phần mà không làm hỏng kết quả, gọi là tính lũy đẳng (idempotency). Trong đồ án, mỗi phân vùng Silver và Gold được xác định duy nhất bởi bộ (dịch vụ, tháng, khúc) và được ghi đè hoàn toàn khi chạy lại. Mỗi phân vùng ghi một tệp nhật ký JSON chứa số dòng, số lỗi theo quy tắc và thời gian từng bước. Trình điều phối đơn giản chỉ chạy những phân vùng chưa có nhật ký. Cách làm này đạt được các tính chất quan trọng nhất của công cụ điều phối như Airflow (mục 3.7 của bài giảng) mà không cần hạ tầng riêng.

2.4.6. Định dạng bảng giao dịch: Delta Lake và Apache Iceberg

Parquet là định dạng tệp, không phải định dạng bảng. Khi nhiều tệp Parquet cùng tạo thành một bảng, cần một lớp siêu dữ liệu để biết tệp nào thuộc phiên bản nào của bảng, lược đồ hiện hành là gì và thao tác ghi nào đã hoàn tất. Delta Lake và Apache

Iceberg, được trình bày ở mục 2.4 của bài giảng, giải quyết việc này bằng nhật ký giao dịch: mỗi lần ghi tạo một bản ghi mới trong nhật ký, liệt kê các tệp được thêm và bớt. Nhờ đó bảng có tính nguyên tử (ACID), cho phép truy vấn theo phiên bản cũ (time travel) và tiến hóa lược đồ có kiểm soát.

Đồ án không dùng Delta Lake hay Iceberg vì hai lý do. Thứ nhất, dữ liệu TLC được công bố theo tháng và không bị sửa sau đó, nên bài toán chỉ có thao tác ghi thêm theo phân vùng, không có cập nhật hay xóa. Thứ hai, mỗi phân vùng Silver và Gold được ghi đè hoàn toàn bởi một tiến trình duy nhất, nên không có xung đột ghi đồng thời. Trong điều kiện đó, quy ước đặt tên theo phân vùng Hive kết hợp nhật ký JSON cho từng phân vùng đã đủ bảo đảm tính nhất quán. Nếu pipeline được mở rộng để nhiều người cùng ghi, hoặc để sửa dữ liệu lịch sử, chuyển sang một định dạng bảng giao dịch sẽ là bước cần thiết.

2.4.7. Xử lý luồng và giám sát gần thời gian thực

Mục 3.3 của bài giảng giới thiệu Apache Flink cho xử lý luồng thời gian thực. Với đánh giá chính sách, độ trễ theo tháng của dữ liệu TLC là chấp nhận được, nên xử lý theo lô là lựa chọn tự nhiên. Tuy nhiên, nếu cơ quan quản lý muốn giám sát chính sách hằng ngày, chẳng hạn phát hiện sớm ùn tắc dịch chuyển ra ngoài ranh giới, kiến trúc có thể được bổ sung một nhánh luồng: dữ liệu chuyển đi từ các nền tảng được đẩy qua hàng đợi thông điệp, Flink tính các chỉ tiêu cửa sổ trượt (số chuyển, tốc độ theo vùng và giờ), còn lớp Lakehouse tiếp tục là nơi lưu trữ dài hạn và tính toán nhân quả định kỳ. Các bảng Gold của đồ án được thiết kế chỉ chứa đại lượng cộng được, nên có thể được cập nhật tăng dần từ luồng mà không phải tính lại từ đầu.

2.4.8. Chi phí sở hữu và giá trị của dữ liệu

Chương 6 của bài giảng nhấn mạnh việc đo lường tổng chi phí sở hữu (TCO) và lợi tức đầu tư (ROI) của dự án dữ liệu lớn. Chi phí của một pipeline gồm lưu trữ, tính toán, nhân lực phát triển và vận hành. Giá trị đến từ các quyết định được cải thiện nhờ dữ liệu. Với đánh giá chính sách công, giá trị khó quy ra tiền trực tiếp, nhưng có thể nhìn qua câu hỏi: nếu không có dữ liệu và pipeline, cơ quan quản lý sẽ phải dựa vào khảo sát hoặc đếm xe tại vài điểm, tốn kém hơn nhiều và cho độ phân giải thấp hơn. Đồ án không định giá bằng tiền, nhưng báo cáo chi phí tính toán thực tế (số phút CPU, bộ nhớ, dung lượng) để làm cơ sở cho các ước tính như vậy.

2.4.9. Mô hình tính toán của Apache Spark

Spark được xây dựng quanh khái niệm tập dữ liệu phân tán có khả năng phục hồi (Resilient Distributed Dataset, RDD) (Zaharia và cộng sự, 2012). Một RDD là một tập bất biến được chia thành các phân vùng nằm trên nhiều nút. Mỗi RDD ghi lại phả hệ (lineage) của nó, tức chuỗi phép biến đổi từ dữ liệu nguồn. Khi một phân vùng bị mất do nút hỏng, Spark tính lại đúng phân vùng đó theo phả hệ thay vì phải sao chép dữ liệu ra nhiều nơi như HDFS. Đây là nền tảng của nguyên lý tính toán trong bộ nhớ mà mục 3.1 của bài giảng trình bày: dữ liệu trung gian được giữ trong RAM giữa các bước, chỉ ghi xuống đĩa ở ranh giới xáo trộn.

Các phép biến đổi được chia thành hai loại. Phép biến đổi hẹp (lọc, chiếu, tổng hợp cục bộ) chỉ cần dữ liệu của một phân vùng đầu vào, nên được gộp thành một giai đoạn (stage) chạy liên mạch. Phép biến đổi rộng (nhóm theo khóa, nối) cần dữ liệu từ mọi phân vùng, nên phải xáo trộn (shuffle): mỗi tác vụ ghi kết quả trung gian được chia theo giá trị băm của khóa xuống đĩa, và các tác vụ của giai đoạn sau đọc lại. Đồ thị có hướng không chu trình (DAG) của các giai đoạn là đơn vị lập lịch của Spark. Xáo trộn là thao tác tốn kém nhất, và số phân vùng xáo trộn là tham số hiệu năng quan trọng nhất mà người dùng phải chọn.

Spark SQL (Armbrust và cộng sự, 2015) bổ sung một tầng cao hơn. Truy vấn viết bằng SQL hoặc API DataFrame được dịch thành cây kế hoạch logic, bộ tối ưu Catalyst áp dụng các quy tắc như đẩy điều kiện lọc xuống, cắt tỉa cột và gộp phép chiếu, rồi sinh kế hoạch vật lý. Bộ máy Tungsten sinh mã Java cho cả một giai đoạn (whole-stage code generation) thay vì gọi từng toán tử. Từ Spark 3.0, thực thi truy vấn thích nghi (Adaptive Query Execution, AQE) cho phép tối ưu lại kế hoạch giữa các giai đoạn dựa trên thống kê thật của dữ liệu trung gian, chẳng hạn gộp các phân vùng xáo trộn quá nhỏ. Với PySpark, việc chuyển dữ liệu giữa JVM và Python có thể dùng Apache Arrow để truyền theo lô cột thay vì tuần tự hóa từng dòng.

2.4.10. Xử lý luồng có cấu trúc

Structured Streaming (Armbrust và cộng sự, 2018) coi một luồng dữ liệu là một bảng không giới hạn được nối thêm dòng liên tục. Người dùng viết truy vấn như trên bảng tĩnh, và Spark thực thi nó tăng dần theo các lô vi mô (micro-batch). Ba khái niệm then chốt là thời gian sự kiện (thời điểm sự việc xảy ra, khác với thời điểm dữ liệu

đến), cửa sổ thời gian (nhóm các sự kiện theo khoảng thời gian cố định hoặc trượt) và mốc nước (watermark), là ngưỡng trễ tối đa mà hệ thống chờ dữ liệu đến muộn trước khi đóng một cửa sổ và giải phóng trạng thái của nó. Trạng thái và vị trí đọc của luồng được ghi vào thư mục checkpoint, cho phép chạy tiếp sau sự cố mà không tính trùng hay bỏ sót.

So với Apache Flink ở mục 3.3 của bài giảng, vốn xử lý từng sự kiện với độ trễ mili giây, mô hình lô vi mô có độ trễ cao hơn nhưng dùng chung bộ máy và chung ngữ nghĩa với xử lý lô. Với bài toán giám sát chính sách, nơi độ trễ vài giây đến vài phút là chấp nhận được, lợi thế về tính thống nhất quan trọng hơn độ trễ.

2.5. Chất lượng dữ liệu và quản trị dữ liệu

2.5.1. Các chiều chất lượng dữ liệu

Wang và Strong (1996) phân loại chất lượng dữ liệu theo góc nhìn người sử dụng thành các nhóm: chất lượng nội tại (chính xác, khách quan), chất lượng theo ngữ cảnh (đầy đủ, kịp thời, phù hợp), chất lượng biểu diễn và khả năng truy cập. Với dữ liệu chuyển đi, lỗi thường gặp thuộc nhóm nội tại: vùng không xác định, quãng đường bằng 0, thời lượng âm, giá cước bất thường, tốc độ phi thực tế, thời điểm nằm ngoài tháng của tệp.

Mục 2.7 của bài giảng nhấn mạnh rằng kiểm soát chất lượng cần được tự động hóa và ghi lại, không phải một bước làm sạch thủ công. Đồ án cài đặt bảy quy tắc dưới dạng cờ 0/1 cho từng bản ghi, đếm số vi phạm theo quy tắc cho từng phân vùng, rồi chỉ giữ các bản ghi không vi phạm quy tắc nào. Cách này cho phép đo quy tắc nào loại nhiều dữ liệu nhất và kiểm tra việc loại dữ liệu có khác nhau giữa các nhóm hay không.

2.5.2. Lệnh lược đồ

Lệnh lược đồ (schema drift) xảy ra khi cấu trúc dữ liệu thay đổi theo thời gian. Trong dữ liệu TLC, cột `cbd_congestion_fee` chỉ xuất hiện từ tháng 01/2025. Nếu đọc gộp hai năm mà không xử lý, truy vấn sẽ lỗi hoặc cột sẽ nhận giá trị rỗng không kiểm soát. Lớp Bronze của đồ án phát hiện lệch lược đồ bằng cách so sánh lược đồ từng tháng với tháng đầu tiên, còn lớp Silver chuẩn hóa bằng cách gán phí bằng 0 cho các tháng trước chính sách, đúng với thực tế.

2.5.3. Quyền riêng tư

TLC chỉ công bố vị trí ở mức vùng taxi và không công bố định danh tài xế, biển số hay hành khách. Đây là một ví dụ về tổng quát hóa không gian để giảm rủi ro nhận dạng lại, phù hợp với tinh thần của GDPR và Nghị định 13/2023/NĐ-CP về bảo vệ dữ liệu cá nhân được nêu ở mục 2.8 của bài giảng. Đồ án không cố gắng khôi phục thông tin cá nhân và mọi kết quả đều ở mức tổng hợp. Chương 6 đo trực tiếp mức độ bảo vệ mà cách tổng quát hóa này đem lại.

2.5.4. Danh mục dữ liệu, phả hệ và tính toàn vẹn

Mục 2.6 của bài giảng mô tả hệ thống siêu dữ liệu và danh mục dữ liệu (data catalog) như xương sống của quản trị dữ liệu doanh nghiệp. Một danh mục trả lời câu hỏi dữ liệu nào tồn tại, nằm ở đâu, có cấu trúc gì và do ai tạo ra. Phả hệ dữ liệu (data lineage) trả lời câu hỏi một bảng được tạo ra từ những bảng nào qua những bước nào, và ngược lại, nếu một bảng thay đổi thì những kết quả nào bị ảnh hưởng. Hai thành phần này thường được duy trì bằng các công cụ chuyên dụng như Apache Atlas hoặc Unity Catalog; ở quy mô đồ án, chúng có thể được trích tự động từ siêu dữ liệu Parquet và từ mã nguồn.

Tính toàn vẹn của dữ liệu nguồn là một phần của an ninh chuỗi cung ứng số (mục 7.5 của bài giảng). Hàm băm mật mã như SHA-256 cho mỗi tệp một dấu vân tay 256 bit; chỉ cần một bit thay đổi, dấu vân tay thay đổi hoàn toàn. Lưu dấu băm khi nhận dữ liệu và kiểm tra lại trước khi xử lý là biện pháp tối thiểu để phát hiện tệp hỏng hoặc bị thay thế.

2.5.5. k-ẩn danh và rủi ro tái nhận dạng

Việc xóa định danh trực tiếp (tên, số điện thoại) không đủ để ẩn danh dữ liệu. Sweeney (2002) chỉ ra rằng tổ hợp một vài thuộc tính tưởng như vô hại, gọi là định danh gián tiếp (quasi-identifier), thường đủ để xác định duy nhất một người khi đối chiếu với nguồn thông tin khác. Mô hình k-ẩn danh yêu cầu mỗi bản ghi trùng với ít nhất k-1 bản ghi khác trên mọi định danh gián tiếp. De Montjoye và cộng sự (2013) cho thấy với dữ liệu di chuyển, chỉ bốn điểm không gian – thời gian đã đủ xác định duy nhất 95% người dùng. Riêng dữ liệu taxi New York, Douriez và cộng sự (2016) phân tích các rủi ro tái nhận dạng khi dữ liệu chuyển đi được công bố ở mức chi tiết cao và đề xuất các phương án làm thô dữ liệu.

2.5.6. Quyền riêng tư vi phân

Quyền riêng tư vi phân (Dwork và cộng sự, 2006; Dwork và Roth, 2014) định nghĩa quyền riêng tư như một tính chất của cơ chế công bố, không phải của dữ liệu. Một cơ chế ngẫu nhiên M đạt ϵ -quyền riêng tư vi phân nếu với mọi cặp tập dữ liệu D và D' chỉ khác nhau một bản ghi và mọi tập kết quả S , xác suất $M(D) \in S$ không vượt quá e^ϵ lần xác suất $M(D') \in S$. Nói cách khác, người quan sát kết quả không thể biết chắc một bản ghi cụ thể có trong dữ liệu hay không.

$$M(D) = f(D) + \text{Laplace}(\Delta f / \epsilon) \quad (2.4)$$

Cơ chế Laplace ở phương trình trên đạt bảo đảm này bằng cách cộng nhiễu Laplace có thang đo $\Delta f / \epsilon$, với Δf là độ nhảy của hàm f , tức mức thay đổi lớn nhất của f khi thêm hoặc bớt một bản ghi. Với phép đếm, $\Delta f = 1$. Tham số ϵ , gọi là ngân sách riêng tư, điều chỉnh sự đánh đổi: ϵ nhỏ bảo vệ tốt hơn nhưng nhiều hơn. Các ngân sách cộng dồn khi công bố nhiều kết quả trên cùng dữ liệu. Cục Điều tra Dân số Hoa Kỳ đã áp dụng phương pháp này cho điều tra dân số năm 2020 (Abowd, 2018).

2.5.7. Phát hiện bất thường, bảo mật và phục hồi

Phát hiện bất thường (mục 7.2 của bài giảng) có thể dựa trên thống kê hoặc học máy. Cách tiếp cận thống kê cổ điển là biểu đồ kiểm soát của Shewhart, trong đó biểu đồ p theo dõi tỷ lệ lỗi với giới hạn ± 3 độ lệch chuẩn nhị thức (Montgomery, 2019). Khi cỡ mẫu mỗi kỳ rất lớn, giới hạn nhị thức trở nên quá hẹp vì biến động thật giữa các kỳ lớn hơn nhiều so với biến động lấy mẫu; biểu đồ p' của Laney (2002) hiệu chỉnh bằng cách ước lượng độ phân tán thật từ khoảng biến động di chuyển. Về học máy, Isolation Forest (Liu, Ting và Zhou, 2008) cô lập các điểm bằng cây phân chia ngẫu nhiên; điểm bất thường là điểm bị cô lập sau ít lần chia, và thuật toán không cần nhãn.

Về bảo mật, kiến trúc Zero Trust (Rose và cộng sự, 2020) thay giả định "bên trong mạng là an toàn" bằng nguyên tắc xác thực và cấp quyền cho mọi yêu cầu, quyền tối thiểu và giả định đã bị xâm nhập. Về phục hồi sau sự cố (mục 7.7 của bài giảng), hai chỉ tiêu chuẩn là thời gian phục hồi mục tiêu (RTO), tức thời gian tối đa để khôi phục dịch vụ, và điểm phục hồi mục tiêu (RPO), tức lượng dữ liệu tối đa có thể mất.

2.6. Suy luận nhân quả từ dữ liệu quan sát

2.6.1. Khung kết quả tiềm năng

Gọi $Y_{it}(1)$ là kết quả của đơn vị i tại thời điểm t nếu chịu chính sách và $Y_{it}(0)$ là kết quả nếu không chịu. Tác động của chính sách lên đơn vị đó là $Y_{it}(1) - Y_{it}(0)$. Vấn đề cơ bản của suy luận nhân quả là ta chỉ quan sát được một trong hai kết quả. Đại lượng mục tiêu thường là tác động trung bình trên nhóm được xử lý (ATT):

$$ATT = E[Y_{it}(1) - Y_{it}(0) \mid D_i = 1, t \geq t_0] \quad (2.5)$$

Các phương pháp dưới đây là những cách khác nhau để xây dựng phản thực $E[Y_{it}(0) \mid D_i = 1, t \geq t_0]$ từ dữ liệu quan sát, mỗi cách dựa trên một giả định khác nhau.

2.6.2. Sai khác kép và hai chiều hiệu ứng cố định

Sai khác kép so sánh thay đổi trước – sau của nhóm xử lý với thay đổi trước – sau của nhóm đối chứng. Với nhiều đơn vị và nhiều thời kỳ, đặc tả hai chiều hiệu ứng cố định (TWFE) là:

$$Y_{it} = \alpha_i + \gamma_t + \beta \cdot D_{it} + \varepsilon_{it} \quad (2.6)$$

trong đó α_i hấp thụ mọi khác biệt không đổi theo thời gian giữa các đơn vị, γ_t hấp thụ mọi cú sốc chung của từng thời kỳ, $D_{it} = 1$ nếu đơn vị i thuộc nhóm xử lý và t sau chính sách. Hệ số β xác định ATT dưới giả định xu hướng song song: nếu không có chính sách, kết quả trung bình của hai nhóm sẽ biến động cùng nhau (Angrist và Pischke, 2009).

Khi mọi đơn vị xử lý bắt đầu chịu chính sách cùng một thời điểm, như trường hợp CRZ, TWFE không gặp vấn đề trọng số âm mà các nghiên cứu gần đây chỉ ra cho thiết kế có nhiều thời điểm xử lý (Goodman-Bacon, 2021; Callaway và Sant'Anna, 2021). Vấn đề chính ở đây là giả định xu hướng song song, vì khu trung tâm có mùa vụ và xu hướng riêng.

2.6.3. Nghiên cứu sự kiện

Nghiên cứu sự kiện thay biến D bằng một tập biến giả theo thời gian tương đối so với mốc chính sách:

$$Y_{it} = \alpha_i + \gamma_t + \sum_{k \neq -1} \beta_k \cdot 1[t - t_0 = k] \cdot T_i + \varepsilon_{it} \quad (2.7)$$

Các hệ số β_k với $k < 0$ là phép kiểm tra xu hướng trước chính sách: nếu chúng khác 0 một cách có hệ thống, giả định xu hướng song song đáng ngờ. Các hệ số với $k \geq 0$ mô tả động thái của tác động. Roth và cộng sự (2023) lưu ý rằng kiểm định tiên xu hướng có độ mạnh hạn chế, và việc không bác bỏ được không chứng minh xu hướng song song. Ngược lại, khi mẫu rất lớn, kiểm định gần như luôn bác bỏ, nên cần đọc độ lớn và hình dạng của các hệ số chứ không chỉ giá trị p. Rambachan và Roth (2023) đề xuất cách đánh giá độ nhạy của kết luận khi cho phép vi phạm xu hướng song song trong một giới hạn nhất định.

Việc chọn kỳ mốc ảnh hưởng đến cách đọc hình. Nếu kỳ mốc rơi vào một tuần có biến động bất thường, chẳng hạn tuần lễ cuối năm, toàn bộ đường hệ số bị dịch lên hoặc xuống. Đồ án vì vậy chuẩn hóa lại các hệ số theo trung bình của toàn bộ giai đoạn trước chính sách, và tính lại sai số chuẩn bằng phép biến đổi tuyến tính tương ứng của ma trận hiệp phương sai.

2.6.4. Khử mùa vụ bằng sai khác bậc ba

Khi nhóm xử lý có mùa vụ riêng, có thể bổ sung hiệu ứng cố định nhóm $\times$ tuần trong năm, ký hiệu $\delta_{\{g(i),w(t)\}}$. Khi đó β được xác định từ chênh lệch giữa năm sau và năm trước của khoảng cách xử lý – đối chứng trong cùng tuần của năm. Giả định cần thiết chuyển từ "xu hướng song song" sang "mùa vụ ổn định giữa hai năm". Nhược điểm là khi chỉ có một năm trước chính sách, thiết kế này không thể đồng thời kiểm soát cả mùa vụ nhóm lẫn xu hướng tuyến tính riêng của nhóm, vì hai thành phần gần như đa cộng tuyến hoàn toàn với biến xử lý.

2.6.5. Kiểm soát tổng hợp

Phương pháp kiểm soát tổng hợp (Abadie, Diamond và Hainmueller, 2010) xây dựng phản thực cho một đơn vị xử lý duy nhất bằng tổ hợp lồi của các đơn vị đối chứng:

$$\hat{Y}_{1t(0)} = \sum_j w_j \cdot Y_{jt}, \quad w_j \geq 0, \quad \sum_j w_j = 1 \quad (2.8)$$

Trọng số được chọn để khớp chuỗi kết quả trong giai đoạn trước chính sách. Ưu điểm là tính minh bạch: ta biết chính xác phản thực được tạo từ những vùng nào với trọng số bao nhiêu. Suy luận dựa vào kiểm định giả được theo không gian: lần lượt coi mỗi đơn vị đối chứng là đơn vị xử lý, tính tỷ số RMSPE sau/trước, rồi xem đơn vị xử

lý thật đứng ở đâu trong phân phối (Abadie, 2021). Ferman và Pinto (2021) phân tích trường hợp khớp trước chính sách không hoàn hảo và đề xuất phiên bản khử trung bình.

2.6.6. Suy luận hoán vị và sai số chuẩn phân cụm

Với dữ liệu panel, sai số của cùng một đơn vị qua các thời kỳ tương quan với nhau. Bertrand, Duflo và Mullainathan (2004) chỉ ra rằng bỏ qua tương quan này làm sai số chuẩn bị đánh giá thấp nghiêm trọng. Cách xử lý chuẩn là phân cụm sai số theo đơn vị (Cameron và Miller, 2015). Khi số cụm đủ lớn, sai số chuẩn phân cụm đáng tin. Suy luận hoán vị bổ sung một góc nhìn khác: gán ngẫu nhiên nhãn xử lý cho các đơn vị đối chứng nhiều lần để xây dựng phân phối của hệ số dưới giả thuyết không có tác động, không phụ thuộc vào giả định tiệm cận.

2.6.7. Ước lượng hiệu ứng cố định nhiều chiều

Với hàng trăm vùng và hàng trăm tuần, việc đưa biến giả cho từng vùng và từng tuần vào hồi quy tạo ra ma trận lớn không cần thiết. Định lý Frisch–Waugh–Lovell cho phép khử hiệu ứng cố định trước rồi mới hồi quy. Với nhiều chiều hiệu ứng cố định, phép khử được thực hiện bằng chiếu luân phiên: lần lượt trừ trung bình theo từng chiều cho tới khi hội tụ (Guimarães và Portugal, 2010; Correia, 2016). Đồ án tự cài đặt thuật toán này có hỗ trợ trọng số, kèm sai số chuẩn phân cụm CR1 với hiệu chỉnh bậc tự do.

2.7. Học máy nhân quả

2.7.1. Double/Debiased Machine Learning

Khi tác động phụ thuộc vào nhiều biến kiểm soát X theo dạng hàm chưa biết, mô hình tuyến tính từng phần (PLR) là:

$$Y = \theta \cdot D + g(X) + U, \quad D = m(X) + V \quad (2.9)$$

Chernozhukov và cộng sự (2018) chỉ ra rằng nếu ước lượng g và m bằng học máy rồi thay vào một cách ngây thơ, ước lượng θ sẽ bị chệch do chính sai số của học máy. Giải pháp gồm hai thành phần. Thứ nhất, dùng hàm điểm trực giao Neyman, tức là hồi quy phần dư của Y lên phần dư của D , để sai số bậc một của các ước lượng phụ không ảnh hưởng đến θ . Thứ hai, dùng cross-fitting: chia mẫu thành K phần, ước

lượng hàm phụ trên $K - 1$ phần và tính phần dư trên phần còn lại, để tránh quá khớp. Ước lượng thu được là:

$$\hat{\theta} = \sum_i (D_i - \hat{m}(X_i))(Y_i - \hat{g}(X_i)) / \sum_i (D_i - \hat{m}(X_i))^2 \quad (2.10)$$

2.7.2. Ước lượng bền vững kép AIPW

Ước lượng trọng số nghịch đảo xác suất tăng cường (AIPW) kết hợp mô hình kết quả $\mu_d(X) = E[Y | D = d, X]$ và mô hình xu hướng $e(X) = P(D = 1 | X)$. Điểm ảnh hưởng của từng quan sát là:

$$\varphi_i = \mu_1 - \mu_0 + D_i (Y_i - \mu_1) / \hat{e} - (1 - D_i)(Y_i - \mu_0) / (1 - \hat{e}) \quad (2.11)$$

Trung bình của φ_i là ước lượng ATE, nhất quán nếu một trong hai mô hình đúng. Điều kiện quan trọng là chồng lấn: $e(X)$ phải nằm xa 0 và 1. Khi các đơn vị xử lý và đối chứng khác nhau quá xa về X , $\hat{e}(X)$ tiến sát 0 hoặc 1, trọng số bùng nổ và ước lượng mất ổn định. Thực hành phổ biến là cắt bỏ các quan sát có $\hat{e}(X)$ ngoài khoảng $[0,05; 0,95]$ và báo cáo rõ tổng thể mà ước lượng đại diện.

2.7.3. Tác động không đồng nhất: DR-learner, BLP và GATES

Tác động trung bình có điều kiện CATE $\tau(x) = E[Y(1) - Y(0) | X = x]$ có thể ước lượng bằng DR-learner: hồi quy điểm ảnh hưởng φ_i lên X bằng một mô hình học máy (Kennedy, 2023). Vì $\tau(x)$ có thể chứa nhiễu, Chernozhukov, Demirer, Duflo và Fernández-Val (2018) đề xuất không suy luận trực tiếp trên $\hat{\tau}$ mà dùng nó như một chỉ số để kiểm định. Bộ dự báo tuyến tính tốt nhất (BLP) hồi quy φ lên hằng số và $\hat{\tau} - E[\hat{\tau}]$; hệ số của thành phần thứ hai khác 0 cho thấy có tác động không đồng nhất thật sự. GATES chia mẫu theo phân vị của $\hat{\tau}$ và ước lượng tác động trung bình trong từng nhóm. CLAN so sánh đặc trưng trung bình của nhóm có tác động cao nhất và thấp nhất.

2.7.4. LightGBM làm mô hình phụ

Các hàm phụ trong DML có thể được ước lượng bằng bất kỳ phương pháp học máy đủ linh hoạt nào. Đồ án chọn LightGBM (Ke và cộng sự, 2017), thuật toán tăng cường độ dốc dựa trên histogram với cây phát triển theo lá, vì tốc độ cao, xử lý tốt cả biến liên tục lẫn nhị phân và đã được kiểm chứng rộng rãi trên dữ liệu dạng bảng. Các siêu tham số được cố định trước (tốc độ học 0,03; 400 cây; 15 lá; tối thiểu 40 quan sát

mỗi lá) thay vì tinh chỉnh theo kết quả nhân quả, để tránh chọn mô hình theo đáp án mong muốn.

2.8. Tổng quan các nghiên cứu liên quan

2.8.1. Đánh giá phí ùn tắc ở các thành phố khác

Tài liệu về phí ùn tắc theo vùng hình thành qua ba thế hệ. Thế hệ thứ nhất đánh giá các chương trình ở Singapore, London và Stockholm bằng dữ liệu đếm xe tại điểm cố định và khảo sát hành trình (Olszewski và Xie, 2005; Santos và Shaffer, 2004; Leape, 2006; Eliasson, 2009; Börjesson và cộng sự, 2012). Ở London và Stockholm, lưu lượng xe vào vùng giảm khoảng một phần năm ngay sau khi áp dụng và tốc độ tăng rõ, nhưng ở London phần lợi ích về tốc độ mờ dần trong các năm sau. Điểm mạnh là đo trực tiếp lưu lượng; điểm yếu là độ phân giải không gian và thời gian thấp, khó tách tác động theo loại chuyển đi.

Thế hệ thứ hai dùng thiết kế bán thực nghiệm để đánh giá các kết quả thứ cấp. Gibson và Carnovale (2015) dùng biên giới của vùng Area C ở Milan để ước lượng tác động lên hành vi lái xe và ô nhiễm, kể cả ở khu vực ngay ngoài ranh giới. Percoco (2013) cũng cho Milan, Green, Heywood và Navarro (2020) cho London, và Simeonova và cộng sự (2021) cho Stockholm đánh giá tác động lên ô nhiễm không khí và sức khỏe, với kết quả không đồng nhất giữa các chất ô nhiễm. Thế hệ thứ ba dùng dữ liệu hành vi cá nhân và thử nghiệm ngẫu nhiên: Kreindler (2024) chạy thử nghiệm định giá theo giờ cao điểm ở Bangalore bằng dữ liệu GPS điện thoại và ước lượng lợi ích cân bằng của phí tối ưu là nhỏ vì cầu kém co giãn theo giờ khởi hành; Hanna, Kreindler và Olken (2017) khai thác việc bãi bỏ đột ngột quy định xe nhiều người ở Jakarta để đo tác động lan ra toàn mạng lưới.

Về cơ chế, Duranton và Turner (2011) cung cấp bằng chứng cho "quy luật cơ bản của ùn tắc": lưu lượng tăng gần tỷ lệ với năng lực đường, nên mọi cải thiện tốc độ đều có xu hướng bị nhu cầu cảm ứng bào mòn. Anderson (2014) cho thấy giao thông công cộng làm giảm đáng kể ùn tắc trên các trục song song, nghĩa là phương án thay thế bằng tàu điện ảnh hưởng lớn đến độ co giãn của cầu đi xe. Small, Winston và Yan (2005) ước lượng giá trị thời gian và độ tin cậy của người lái, tham số trung tâm trong phúc lợi của phí ùn tắc. Athey và Imbens (2017) nhận định rằng dữ liệu giao dịch quy

mô lớn đang thay đổi cách đánh giá chính sách, cho phép dùng sai khác kép và kiểm soát tổng hợp ở mức chi tiết mà trước đây không có.

2.8.2. Gọi xe công nghệ và ùn tắc

Nhóm tài liệu thứ hai nghiên cứu quan hệ giữa gọi xe công nghệ và ùn tắc. Erhardt và cộng sự (2019) ước lượng rằng các công ty gọi xe là nguyên nhân lớn nhất của mức tăng ùn tắc ở San Francisco giai đoạn 2010–2016. Schaller (2021) dùng dữ liệu của chính New York và các thành phố khác để chỉ ra rằng gọi xe làm tăng tổng số dặm xe chạy, kể cả khi tính cả chuyển đi chung, vì quãng đường xe chạy rỗng và vì chuyển gọi xe thay thế chủ yếu cho giao thông công cộng và đi bộ. Beojone và Geroliminis (2021) mô phỏng ở quy mô thành phố và cho thấy xe chạy rỗng để đón khách làm giảm hiệu quả của mạng lưới. Tirachini (2020) tổng hợp tài liệu quốc tế và kết luận rằng tác động rỗng của gọi xe lên ùn tắc phần lớn là tiêu cực khi không có chính sách quản lý.

Về kinh tế học nền tảng, Cramer và Krueger (2016) so sánh hiệu suất sử dụng xe của Uber và taxi, Cohen và cộng sự (2016) ước lượng đường cầu và thặng dư tiêu dùng từ dữ liệu giao dịch của Uber, và Castillo, Knoepfle và Weyl (2017) phân tích vai trò của định giá tăng đột biến. Rochet và Tirole (2003) cung cấp khung lý thuyết cho thị trường hai phía, còn Weyl và Fabinger (2013) cho khung chung về tỷ lệ chuyển thuế sang người mua trong các cấu trúc thị trường khác nhau, là cơ sở cho giả thuyết H5 ở mục 2.11.

2.8.3. Đánh giá phí CRZ tại New York

Vì chính sách có hiệu lực từ đầu năm 2025, tài liệu học thuật còn ít và phần lớn ở dạng bài làm việc. Cook và cộng sự (2025) dùng dữ liệu tốc độ của Google Maps từ 09/2024 đến 02/2025, so với năm thành phố đối chứng, và báo cáo tốc độ trung bình trong vùng tăng từ 8,2 lên 9,7 dặm/giờ, tức khoảng 15%, với mức tăng lớn hơn vào chiều ngày thường và tối cuối tuần, cùng mức tăng tốc độ trên các tuyến ngoài vùng có nhiều chuyển đi vào vùng. Pandey, Guler và Gayah (2026) dùng dữ liệu TLC và sai khác kép, báo cáo tổng số chuyển của các công ty gọi xe giảm 5,95%, số yêu cầu đi chung giảm 38,08% và số chuyển đi chung được ghép thành công giảm 50,87%, và cho rằng việc không có ưu đãi phí cho chuyển đi chung đã khuếch đại tác động lên loại chuyển này.

Hai nghiên cứu này bổ sung cho nhau nhưng đều để lại khoảng trống. Nghiên cứu thứ nhất đo tốc độ trên đường nhưng không đo cầu đi lại; nghiên cứu thứ hai đo cầu nhưng dừng ở tác động trung bình, không phân tích tốc độ theo chuyển, thời gian chờ, lan tỏa theo mức phơi nhiễm hay tác động không đồng nhất.

2.8.4. Học máy nhân quả trong giao thông và kinh doanh

Học máy nhân quả được dùng ngày càng nhiều trong marketing (mô hình uplift, được đề cập ở Chương 5 của bài giảng), định giá và đánh giá chính sách. Trong giao thông, các ứng dụng chủ yếu là ước lượng tác động không đồng nhất của thay đổi giá hoặc dịch vụ lên các nhóm hành khách. Một vấn đề ít được thảo luận là điều kiện chồng lấn: khi đơn vị xử lý khác biệt có hệ thống về không gian, mô hình xu hướng dễ phân tách gần hoàn hảo hai nhóm. Đồ án đo trực tiếp vấn đề này và so sánh kết quả với các bộ biến kiểm soát khác nhau.

2.8.5. Tổng hợp

Bảng dưới đây hệ thống hóa các nghiên cứu chính theo dữ liệu, phương pháp, kết quả chính và giới hạn, và đặt đồ án vào bối cảnh đó.

Bảng 2.1. Hệ thống hóa các nghiên cứu liên quan và vị trí của đồ án

Nghiên cứu	Bối cảnh, dữ liệu	Phương pháp	Kết quả chính	Giới hạn chính
Santos và Shaffer (2004); Leape (2006)	London; đếm xe	Mô tả trước – sau	Lưu lượng vào vùng giảm, tốc độ tăng	Không có nhóm đối chứng chặt
Olszewski và Xie (2005)	Singapore; dữ liệu lưu lượng	Mô hình lưu lượng	Phản ứng lưu lượng theo mức phí và giờ	Một thành phố, phí điện tử
Eliasson (2009); Börjesson và cs. (2012)	Stockholm; đếm xe, khảo sát	Thử nghiệm rời áp dụng lâu dài; CBA	Lưu lượng giảm bền vững, lợi ích ròng dương	Độ phân giải thấp
Percoco (2013); Gibson, Carnovale (2015)	Milan (Ecopass, Area C)	Sai khác kép, so sánh quanh ranh giới	Hành vi lái xe, ô nhiễm trong và ngoài vùng	Không tách loại chuyển
Green, Heywood, Navarro (2020)	London; trạm quan trắc	Sai khác kép	Tác động không đồng nhất lên các chất ô nhiễm	Chỉ kết quả môi trường
Simeonova và cs. (2021)	Stockholm; dữ liệu y tế	Sai khác kép	Giảm hen suyễn ở trẻ em	Chỉ kết quả sức khỏe
Hanna, Kreindler, Olken (2017)	Jakarta; dữ liệu Google Maps	Thử nghiệm tự nhiên	Ùn tắc tăng mạnh trên toàn mạng sau khi bỏ quy định	Chính sách khác (xe nhiều người)
Kreindler (2024)	Bangalore; GPS điện thoại	Thử nghiệm ngẫu nhiên + mô hình cân bằng	Cầu kém co giãn theo giờ; lợi ích phí tối ưu nhỏ	Phí theo cá nhân, không theo vùng
Duranton, Turner (2011)	Mỹ; lưu lượng đường	Biến công cụ	Quy luật cơ bản của ùn tắc	Không đánh giá phí
Anderson (2014)	Los Angeles; đình công tàu điện	Gián đoạn thời gian	Giao thông công cộng giảm ùn tắc	Không đánh giá phí
Erhardt và cs. (2019)	San Francisco; dữ liệu API	Mô hình mạng lưới	Gọi xe góp phần lớn vào tăng ùn tắc	Không đánh giá chính sách phí

Nghiên cứu	Bối cảnh, dữ liệu	Phương pháp	Kết quả chính	Giới hạn chính
Schaller (2021)	New York và các thành phố Mỹ	Tính toán số dặm xe chạy	Gọi xe, kể cả đi chung, làm tăng số dặm xe	Mô tả, không nhân quả
Beojone, Geroliminis (2021)	Mô phỏng quy mô thành phố	Mô hình vĩ mô mạng lưới	Xe chạy rỗng làm giảm hiệu quả mạng	Dựa trên mô phỏng
Cohen và cs. (2016); Castillo và cs. (2017)	Dữ liệu nội bộ Uber	Gián đoạn giá, lý thuyết	Đường cầu; vai trò của giá tăng đột biến	Không đánh giá chính sách công
Cook và cs. (2025)	New York; Google Maps	Sai khác kép với 5 thành phố đối chứng	Tốc độ trong vùng tăng khoảng 15%	Không đo cầu đi lại
Pandey, Guler, Gayah (2026)	New York; chuyển TLC	Sai khác kép	Chuyển gọi xe giảm 5,95%; đi chung giảm mạnh	Chỉ tác động trung bình
Đồ án này	New York; chuyển TLC 2024–2025, Lakehouse	DiD, DDD, SCM, DML, liều – đáp ứng	Số chuyển, tốc độ, chờ, lan tỏa, CATE, theo hãng	Tốc độ đo trên chuyển gọi xe

Nguồn: tác giả tổng hợp.

2.9. Giá trị kinh doanh của dữ liệu lớn

2.9.1. Dự báo nhu cầu và dự báo làm phản thực tế

Dự báo nhu cầu (mục 4.4 của bài giảng) là ứng dụng vận hành quen thuộc nhất của dữ liệu lớn. Các mô hình từ hồi quy có biến lịch, mô hình chuỗi thời gian đến học máy dạng cây đều được dùng, và được đánh giá bằng sai số trên dữ liệu giữ lại như MAPE hay RMSE (Hyndman và Athanasopoulos, 2021). Một cách dùng mở rộng là coi dự báo cho giai đoạn sau một sự kiện là phản thực tế. Brodersen và cộng sự (2015) chính thức hóa cách này bằng mô hình chuỗi thời gian cấu trúc Bayes với các chuỗi đối chứng làm biến giải thích (CausalImpact). Giả định then chốt là các chuỗi đối chứng không bị sự kiện ảnh hưởng.

2.9.2. Thử nghiệm quy mô lớn và công suất thống kê

Thử nghiệm có kiểm soát trực tuyến (A/B testing) là cách doanh nghiệp số đo tác động của thay đổi sản phẩm (Kohavi, Tang và Xu, 2020). Hai vấn đề thiết kế trung tâm là công suất thống kê và tính ổn định theo thời gian của tác động. Tác động nhỏ nhất phát hiện được (MDE) với công suất $1-\beta$ và mức ý nghĩa α xấp xỉ $(z_{1-\alpha/2} + z_1-\beta)$ nhân sai số chuẩn của ước lượng, tức khoảng 2,8 lần sai số chuẩn với $\alpha = 5\%$ và công suất 80% (Bloom, 1995). Về thời gian, tác động đo trong vài tuần đầu có thể khác tác động dài hạn do hiệu ứng mới lạ hoặc do người dùng thích nghi dần.

2.9.3. Định giá động trong nền tảng gọi xe

Định giá động (mục 6.4 của bài giảng) là việc điều chỉnh giá theo điều kiện cung cầu tức thời. Với nền tảng gọi xe, Castillo, Knoepfle và Weyl (2017) chỉ ra rằng tăng

giá khi cầu vượt cung không chỉ phân bổ xe cho người trả giá cao nhất mà còn ngăn hệ thống rơi vào trạng thái xe phải đi rất xa để đón khách. Giá cuối cùng khách trả vì vậy là tổng của thành phần theo thời gian, quãng đường và hệ số điều chỉnh theo cung cầu, cộng các khoản phí và thuế.

2.9.4. Định giá tài sản dữ liệu, ROI và TCO

Moody và Walsh (1999) đề xuất định giá thông tin theo ba cách tương tự định giá tài sản hữu hình: theo chi phí, theo giá thị trường và theo giá trị sử dụng, đồng thời nêu các đặc điểm riêng của thông tin như có thể dùng chung mà không hao mòn và giá trị tăng khi được kết hợp. Laney (2017) phát triển thành khung quản lý thông tin như tài sản. Mục 6.1 đến 6.5 của bài giảng đặt các khái niệm này trong bối cảnh dự án dữ liệu lớn, với ROI đo bằng giá trị quyết định và TCO gồm lưu trữ, tính toán, nhân lực và vận hành.

2.10. Khoảng trống nghiên cứu và khung phân tích

2.10.1. Khoảng trống nghiên cứu

- Ước lượng trung bình hiện có chưa được kiểm tra bằng các thiết kế khác nhau (khử mùa vụ, kiểm soát tổng hợp, học máy nhân quả) để xem kết quả nhạy thế nào với giả định.
- Chưa có bằng chứng về tác động lên tốc độ và thời gian chờ, hai thước đo gần trực tiếp với mục tiêu giảm ùn tắc.
- Chưa có phân tích lan tỏa không gian sang các vùng ngay ngoài ranh giới, nơi dễ xảy ra hành vi né phí.
- Chưa có phân tích tác động không đồng nhất theo đặc trưng chuyển đi kèm kiểm tra chồng lấn.
- Chưa có mô tả tái lập được về pipeline dữ liệu cần thiết để xử lý toàn bộ dữ liệu ở mức từng chuyến.
- Các đánh giá dựa trên dữ liệu lớn hiếm khi kiểm chứng chính bằng dữ liệu phân tích bằng một bộ máy độc lập, và hiếm khi đo rủi ro quyền riêng tư của dữ liệu mà chúng sử dụng.

2.10.2. Khung phân tích của đồ án

Khung phân tích gồm ba tầng. Tầng dữ liệu biến dữ liệu thô thành các bảng Gold có kiểm soát chất lượng và đo chi phí xử lý (RQ1). Tầng nhận dạng ước lượng tác động trung bình bằng các thiết kế độc lập và kiểm tra chéo (RQ2, RQ3). Tầng không đồng nhất phân rã tác động theo loại luồng, khung giờ, khoảng cách và đặc trưng chuyển đi (RQ4), và cuối cùng đánh giá dữ liệu cho phép kết luận đến đâu về phân bổ gánh nặng của phí (RQ5). Ba mô-đun mở rộng bao quanh ba tầng này: kiểm toán và đo chi phí xử lý phân tán (RQ6), quản trị dữ liệu và quyền riêng tư (RQ7), và chuyển kết quả thành thông tin kinh doanh (RQ8).

Nguyên tắc xuyên suốt là một kết luận chỉ được coi là vững khi nhiều thiết kế dựa trên các giả định khác nhau cho kết quả cùng chiều và tương đương về độ lớn, và khi các phép thử giả được không tạo ra một "tác động" có độ lớn tương đương.

2.11. Mô hình lý thuyết và giả thuyết nghiên cứu

Mục này xây dựng một mô hình đơn giản gồm bốn khối: cầu chuyển đi theo chi phí tổng quát, quan hệ tốc độ – lưu lượng, cơ chế lan tỏa qua mạng lưới chuyển đi và cơ chế phân bổ gánh nặng của phí. Mục đích không phải mô hình hóa toàn bộ thị trường, mà suy ra các giả thuyết có thể bác bỏ được bằng dữ liệu, trong đó có những dự báo định lượng về hình dạng của tác động chứ không chỉ về dấu. Các giả thuyết được kiểm định ở mục 4.15.

2.11.1. Cầu chuyển đi theo chi phí tổng quát

Gọi q_{od} là số chuyển gọi xe từ vùng o đến vùng d , p_{od} là giá hành khách trả, T_{od} là thời gian di chuyển và v là giá trị thời gian. Cầu có độ co giãn không đổi theo chi phí tổng quát:

$$q_{od} = A_{od} \cdot (p_{od} + v \cdot T_{od})^{-\varepsilon} \quad (2.12)$$

Khi chuyển đi chạm vùng thu phí, giá tăng thêm $\tau = 1,50$ USD. Nếu tạm bỏ qua thay đổi của thời gian di chuyển, thay đổi log số chuyển là:

$$\Delta \ln q_{od} \approx -\varepsilon \cdot \ln(1 + \tau / (p_{od} + v \cdot T_{od})) \quad (2.13)$$

Phương trình cho hai dự báo. **H1:** số chuyển chạm CRZ giảm. **H1b (liều – đáp ứng):** với ε không đổi giữa các cặp OD, mức giảm tỷ lệ thuận với $\ln(1 + \tau/p)$, nên

chuyển rẻ và ngắn, nơi phí chiếm tỷ trọng lớn trong giá, phải giảm mạnh hơn. Nếu dữ liệu không cho thấy gradient này, hoặc ϵ khác nhau giữa các nhóm chuyển (chẳng hạn chuyển ngắn có nhiều phương án thay thế hơn), hoặc thành phần thời gian $v \cdot T$ lớn đến mức làm phẳng quan hệ.

Với chuyển đi chung, mỗi hành khách là một bản ghi chuyển và chịu phí riêng, trong khi giá của chuyển đi chung thấp hơn chuyển đi riêng. Vì vậy τ/p của chuyển đi chung cao hơn, và **H5**: tỷ lệ yêu cầu đi chung giảm mạnh hơn tổng số chuyển.

2.11.2. Quan hệ tốc độ – lưu lượng

Theo hàm của Bureau of Public Roads (1964), thời gian di chuyển trên một đoạn đường phụ thuộc vào tỷ số lưu lượng V trên năng lực K :

$$T = T_0 \cdot [1 + \alpha \cdot (V/K)^\beta], \quad \alpha \approx 0,15; \quad \beta \approx 4 \quad (2.14)$$

Lấy vi phân, thay đổi log tốc độ $S = L/T$ khi lưu lượng giảm là:

$$\Delta \ln S \approx [\alpha \beta (V/K)^\beta / (1 + \alpha (V/K)^\beta)] \cdot (-\Delta \ln V) \quad (2.15)$$

Hệ số trong ngoặc tăng rất nhanh theo V/K vì β lớn. Hai dự báo: **H2**: tốc độ tăng khi lưu lượng vào vùng giảm. **H2b (độ lồi)**: cùng một mức giảm lưu lượng tạo ra mức tăng tốc độ lớn hơn ở các giờ có lưu lượng cao. Nói cách khác, lợi ích về tốc độ phải tập trung ở giờ đông, chứ không phân bố đều.

Mô hình cũng cho một dự báo động. Tốc độ tăng làm giảm thành phần $v \cdot T$ của chi phí tổng quát, kéo một phần lưu lượng quay lại, đúng cơ chế mà Duranton và Turner (2011) ghi nhận ở quy mô toàn quốc. **H6**: mức tăng tốc độ lớn nhất ngay sau khi áp dụng và giảm dần theo thời gian khi nhu cầu điều chỉnh.

2.11.3. Lan tỏa qua mạng lưới chuyển đi

Xét một vùng z nằm ngoài CRZ. Gọi e_z là tỷ trọng chuyển đón tại z có điểm trả trong CRZ trước chính sách (mức phơi nhiễm). Nếu chỉ các chuyển này bị phí tác động, với cùng tác động $\delta = \Delta \ln q$ của chuyển chạm CRZ, thì:

$$\Delta \ln q_z = \ln(1 + e_z \cdot (e^\delta - 1)) \approx e_z \cdot (e^\delta - 1) \quad (2.16)$$

H3 (lan tỏa theo liều): tác động lên vùng ngoài CRZ tỷ lệ thuận với e_z , với hệ số góc xấp xỉ $e^\delta - 1$. Nếu hệ số góc ước lượng lớn hơn đáng kể giá trị cơ học này, có

một kênh lan tỏa hành vi bổ sung, như hành khách thay đổi thói quen ở cả khu vực xung quanh hoặc tài xế tránh khu vực gần ranh giới.

2.11.4. Phân bổ gánh nặng

Phí được ghi thành một dòng riêng trên hóa đơn và nền tảng thu hộ, nên phần phí danh nghĩa đến thẳng hành khách. Câu hỏi là giá cơ sở có thay đổi không. Theo Weyl và Fabinger (2013), tỷ lệ chuyển thuế phụ thuộc vào độ cong của đường cầu và cấu trúc cạnh tranh, nên lý thuyết không cho một dự báo dấu chắc chắn cho giá cơ sở. Riêng thu nhập tài xế, quy định của TLC tính thu nhập tối thiểu theo quãng đường và thời gian, dạng $pay = a \cdot \text{dặm} + b \cdot \text{phút}$, nên:

$$pay / \text{dặm} = a + b \cdot 60 / S \quad (2.17)$$

H4: khi tốc độ S tăng, thu nhập tài xế mỗi dặm giảm một lượng cơ học $\approx b \cdot 60 \cdot (1/S_1 - 1/S_0)$, kể cả khi công thức trả lương không đổi. Đây là một kênh ít được chú ý: chính việc giảm ùn tắc làm giảm thu nhập mỗi dặm của tài xế khi thu nhập gắn với thời gian.

Bảng 2.2. Các giả thuyết suy ra từ mô hình lý thuyết

Giả thuyết	Khối mô hình	Dự báo	Cách kiểm định
H1	Cầu theo chi phí tổng quát	Số chuyển chậm CRZ giảm	DiD, SCM, DML (Chương 4)
H1b	Cầu, ε không đổi	Mức giảm tăng theo tỷ trọng phí τ/p	DiD theo ngũ phân vị τ/p
H2	Tốc độ – lưu lượng (BPR)	Tốc độ tăng	DiD tốc độ
H2b	Độ lỗi của BPR	Tăng tốc độ lớn hơn ở giờ lưu lượng cao	Hồi quy theo lưu lượng giờ
H3	Lan tỏa qua mạng chuyển đi	Tác động ngoài CRZ tỷ lệ với phơi nhiễm, hệ số góc $\approx e^{\delta} - 1$	DiD liên tục
H4	Thu nhập theo phút và dặm	Thu nhập/dặm giảm cơ học khi tốc độ tăng	So sánh dự báo cơ học với DiD
H5	Phí theo chuyển, không ưu đãi đi chung	Tỷ lệ đi chung giảm mạnh hơn tổng số chuyển	DiD tỷ lệ đi chung
H6	Nhu cầu cảm ứng	Tăng tốc độ lớn nhất lúc đầu rồi giảm dần	DiD theo độ dài giai đoạn sau

Nguồn: tác giả xây dựng.

2.12. Tiểu kết Chương 2

Chương 2 đã trình bày cơ sở kinh tế học của phí ùn tắc và phân bổ gánh nặng, đặc điểm của thị trường gọi xe, các khái niệm kiến trúc dữ liệu lớn được vận dụng (Lakehouse, medallion, Parquet, thực thi vector hóa, tính lũy đẳng), các phương pháp suy luận nhân quả (TWFE, nghiên cứu sự kiện, DDD, SCM, hoán vị), học máy nhân

quả (DML, AIPW, DR-learner, BLP, GATES), mô hình tính toán của Spark, các công cụ quản trị dữ liệu và quyền riêng tư (danh mục, phủ hệ, k-ẩn danh, quyền riêng tư vi phân, biểu đồ kiểm soát, Isolation Forest) và các khái niệm về giá trị kinh doanh của dữ liệu, cùng một mô hình lý thuyết gồm bốn khối cho tám giả thuyết kiểm định được. Tổng quan cho thấy đánh giá phí CRZ mới dừng ở tác động trung bình lên số chuyển. Chương 3 trình bày cách đồ án hiện thực hóa khung phân tích trên dữ liệu thật.

CHƯƠNG 3. DỮ LIỆU, KIẾN TRÚC PIPELINE VÀ PHƯƠNG PHÁP NGHIÊN CỨU

Chương này mô tả cụ thể những gì đồ án đã làm: nguồn dữ liệu, cách tổ chức pipeline, các quy tắc chất lượng, cách xác định vùng xử lý, các bảng Gold, các thực nghiệm hiệu năng và chiến lược nhận dạng nhân quả. Mọi con số trong chương là kết quả chạy thực tế của mã nguồn.

3.1. Thiết kế nghiên cứu tổng thể


3.1.1. Đơn vị phân tích

Dữ liệu gốc ở mức từng chuyến đi. Tuy nhiên, chính sách tác động theo không gian (vùng) và theo thời gian (ngày bắt đầu), nên đơn vị phân tích nhân quả chính là vùng đón khách $\times$ tuần. Tuần được định nghĩa từ Chủ nhật đến thứ Bảy, để tuần đầu tiên sau chính sách bắt đầu đúng vào Chủ nhật 05/01/2025 và không có tuần nào trộn lẫn ngày trước và sau chính sách. Ngoài ra, đồ án dùng ba đơn vị bổ trợ: vùng $\times$ ngày (để tách ngày thường và cuối tuần), vùng $\times$ khung giờ $\times$ tháng (để tách theo giờ) và cặp điểm đón – điểm trả $\times$ tháng (để phân loại luồng và áp dụng học máy nhân quả).

Việc tổng hợp từ chuyến lên vùng $\times$ tuần không làm mất thông tin cần cho các câu hỏi nghiên cứu, vì chính sách không thay đổi trong một vùng và trong một tuần. Nó còn giúp giảm kích thước dữ liệu mô hình từ hàng trăm triệu dòng xuống vài chục nghìn dòng, để có thể chạy hàng trăm hồi quy trong suy luận hoán vị.

3.1.2. Quy trình tổng thể

Hình 3.1 mô tả toàn bộ quy trình từ nguồn dữ liệu đến các lớp phân tích. Các bước được đánh số tương ứng với tệp mã nguồn trong thư mục code/.



Hình 3.1. Kiến trúc pipeline Lakehouse và các lớp phân tích của đồ án

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Bảng 3.1. Các bước của pipeline và tệp mã nguồn tương ứng

Bước	Tệp mã nguồn	Nội dung	Đầu ra chính
00	00_download_data.py / .ps1	Tải 50 tệp dữ liệu thô từ NYC TLC	data/raw
01	01_bronze_catalog.py	Danh mục metadata, lược đồ	t01-t03
02	02_zone_dimension.py	Bảng chiều vùng, xác định CRZ, quan hệ kề	dim_zone, t04-t05
03	03_silver_gold_month.py	Silver + Gold theo từng khúc tháng	silver/, gold/_parts
04	04_gold_consolidate.py	Hợp nhất Gold, nhật ký chất lượng	gold/*.parquet, t06-t08
05	05_benchmark.py	Thực nghiệm định dạng, bộ máy, cắt tỉa	t09-t12
06	06_eda.py	Phân tích khám phá	t13-t29, f01-f18
07	07_did_main.py	DiD, DDD, nghiên cứu sự kiện, OD, giờ	t30-t37, f19-f24
08	08_synthetic_control.py	Kiểm soát tổng hợp, giả được	t38-t40, f25-f27
09	09_dml_heterogeneity.py	DML, AIPW, CATE, BLP, GATES	t41-t47, f28-f31
10	10_spillover_robustness.py	Lan tỏa, giả được, hoán vị, độ vững	t48-t51, f32-f34
11	11_appendix_tables.py	Bảng phụ lục	a01-a03
12	12_pipeline_figures.py	Hình hiệu năng, sơ đồ kiến trúc	t52-t53, f00, f35-f37
13	13_build_report.py	Dựng báo cáo Word/PDF	report/

Nguồn: mã nguồn của đồ án.

3.2. Nguồn dữ liệu

3.2.1. Dữ liệu chuyển đi của NYC TLC

TLC công bố hồ sơ chuyển đi hằng tháng tại trang Trip Record Data. Đồ án dùng hai bộ: High Volume For-Hire Vehicle (HVFHV, gồm Uber, Lyft và các hãng nhỏ khác có trên 10.000 chuyến mỗi ngày) và Yellow Taxi. Mỗi tập là một tháng, định dạng Parquet. Bảng 3.2 liệt kê các cột được sử dụng của bộ HVFHV và cách đồ án dùng chúng.

Tổng cộng có 48 tập chuyển đi, với 483.060.132 bản ghi HVFHV (10,93 GB) và 89.892.322 bản ghi taxi vàng (1,42 GB). Hai tập phụ là bảng tra 265 mã vùng (taxi_zone_lookup.csv) và shapefile ranh giới vùng (taxi_zones.zip).


Bảng 3.2. Các cột của dữ liệu HVFHV được sử dụng

Cột	Ý nghĩa	Sử dụng trong đồ án
hvfhs_license_num	Mã giấy phép hãng (HV0003 = Uber, HV0005 = Lyft)	Thị phần hãng
request_datetime	Thời điểm hành khách gọi xe	Thời gian chờ
pickup_datetime / dropoff_datetime	Thời điểm đón / trả khách	Ngày, giờ, tuần, phân vùng
PULocationID / DOLocationID	Mã vùng đón / trả (1–263; 264, 265 là không xác định)	Nhóm xử lý, luồng OD
trip_miles, trip_time	Quãng đường (dặm), thời lượng (giây)	Tốc độ, quãng đường/chuyến
base_passenger_fare	Giá cước cơ sở trước phí và thuế	Giá/dặm, giá/chuyến
tolls, bcf, sales_tax	Phí cầu đường, phí quỹ xe đen, thuế bán hàng	Chi phí hành khách
congestion_surcharge	Phụ thu ùn tắc cấp bang (từ 2019)	Chi phí hành khách
airport_fee	Phí sân bay	Chi phí hành khách
cbd_congestion_fee	Phí CRZ (chỉ có từ 01/2025)	Xác định vùng, doanh thu phí
tips	Tiền tip	Tip/chuyến
driver_pay	Thu nhập tài xế cho chuyến, chưa gồm tip	Thu nhập/dặm, tỷ lệ trả tài xế
shared_request_flag	Hành khách có yêu cầu đi chung	Tỷ lệ yêu cầu đi chung

Nguồn: từ điển dữ liệu HVFHV của NYC TLC và lược đồ tập thực tế.

3.2.2. Quy mô dữ liệu theo tháng

Hình 3.2 cho thấy số bản ghi thô của từng tháng. HVFHV dao động từ 19,1 đến 22,1 triệu chuyến mỗi tháng và khá ổn định giữa hai năm, trong khi taxi vàng chỉ có từ 3,0 đến 4,6 triệu chuyến, tức nhỏ hơn khoảng 5,4 lần.



Hình 3.2. Số bản ghi thô theo tháng của HVFHV và taxi vàng, 01/2024 – 12/2025

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Bảng 3.3. Đặc điểm các tệp Bronze theo dịch vụ

Dịch vụ	Số dòng/tháng thấp nhất	Cao nhất	Trung bình	Row group/tệp (TB)	Số cột tối đa	Nén
HVFHV	19.128.392	22.108.438	20.127.506	19,8	25	ZSTD
Taxi vàng	2.964.624	4.591.845	3.745.513	4,0	20	ZSTD

Nguồn: kết quả tính toán của tác giả.

3.2.3. Lệnh lược đồ

Bước Bronze so sánh lược đồ của mỗi tháng với tháng 01/2024. Kết quả phát hiện đúng một thay đổi: cột `cbd_congestion_fee` được thêm vào ở cả 12 tháng HVFHV và 12 tháng taxi vàng của năm 2025. Không có cột nào bị bỏ hay đổi kiểu. Lớp Silver xử lý bằng cách đọc cột này khi có và gán 0 cho các tháng năm 2024, đúng với thực tế là chưa có phí.

Việc phát hiện lệnh lược đồ tự động có ý nghĩa thực tế: nếu TLC tiếp tục bổ sung cột trong tương lai, bước Bronze sẽ ghi nhận ngay mà không làm hỏng các bước sau.

3.2.4. Dữ liệu mở rộng cho giai đoạn trước chính sách 2022–2023

Bảng 3.4. Dữ liệu mở rộng 01/2022–12/2023 ở lớp Bronze

Dịch vụ	Số tệp	Số bản ghi	Dung lượng (MB)
HVFHV	24	444.906.103	10.735,8
Taxi vàng	24	77.966.324	1.193,0

Nguồn: t03x_bronze_summary_ext.csv.

Hạn chế lớn nhất của thiết kế ban đầu là chỉ có một năm trước chính sách, khiến không tách được xu hướng dài hạn khỏi mùa vụ và không chạy được giả được cho đặc tả khứ mùa vụ. Đồ án vì vậy bổ sung 24 tháng dữ liệu 2022–2023 của cả hai dịch vụ, gồm 522.872.427 bản ghi. Cùng với dữ liệu chính, tổng khối lượng được xử lý là 1.095.824.881 bản ghi trong 48 tháng. Lược đồ của các tệp 2022–2023 giống năm 2024 ngoại trừ kiểu số nguyên của cột vùng (int64 thay vì int32), được chuẩn hóa ở bước Silver.

Dữ liệu mở rộng đi qua cùng bảy quy tắc chất lượng; tỷ lệ bị loại là 4,20% với HVFHV và 4,47% với taxi vàng. Khác với giai đoạn chính, lớp Silver chỉ được ghi xuống đĩa cho 31 trong 154 phân vùng đầu tiên. Với phần còn lại, bảng chuyển đã làm sạch chỉ tồn tại trong bộ nhớ DuckDB trong lúc tính các phân vùng Gold. Lựa chọn này tăng thông lượng xử lý HVFHV từ khoảng 47.543 lên 164.827 bản ghi mỗi giây (3,5 lần) trên máy của đồ án, vì bước tốn kém nhất là ghi Parquet nén qua lớp chia sẻ thư mục của máy ảo, và không làm mất khả năng tái lập vì lớp Bronze được giữ nguyên. Các bảng Gold dài (2022–2025) được ghi riêng vào thư mục data/gold/long và không thay thế các bảng Gold chính, nên mọi kết quả của giai đoạn 2024–2025 ở các chương khác giữ nguyên.

3.3. Kiến trúc Lakehouse được triển khai

3.3.1. Lớp Bronze

Lớp Bronze giữ nguyên 50 tệp tải về trong thư mục data/raw, không đổi tên, không sửa nội dung. Bước 01 chỉ đọc siêu dữ liệu ở chân tệp Parquet (số dòng, số row group, lược đồ, phương thức nén) và một truy vấn min/max trên cột thời gian đón khách. Nhờ vậy, việc lập danh mục 48 tệp chuyển đi với hơn nửa tỷ dòng chỉ mất 41,7 giây.

3.3.2. Lớp Silver

Lớp Silver có ba nhiệm vụ. Thứ nhất, chuẩn hóa hai nguồn về một lược đồ chung gồm các trường: dịch vụ, mã hãng, thời điểm gọi, đón, trả, vùng đón, vùng trả, quãng đường, thời lượng, giá cước và các khoản phí, tiền tip, thu nhập tài xế, cờ đi chung. Với taxi vàng, thời lượng được tính từ hai mốc thời gian, thu nhập tài xế để trống. Thứ hai, gán bảy cờ chất lượng cho từng bản ghi. Thứ ba, sinh các trường dẫn xuất: ngày,


giờ, thứ, thời gian chờ (phút), tốc độ (dặm/giờ), nhóm vùng đón và trả, cờ chạm CRZ, tổng chi phí hành khách.

Dữ liệu Silver được ghi dưới dạng Parquet nén ZSTD với row group một triệu dòng, phân vùng theo đường dẫn `service=/year=/month=/part-k.parquet`. Cách đặt tên theo kiểu Hive cho phép DuckDB, Spark hay Polars đọc trực tiếp và cắt tĩa phân vùng khi truy vấn theo dịch vụ hoặc tháng.

3.3.3. Xử lý theo khúc và giới hạn tài nguyên

Máy chạy pipeline là một máy ảo Linux trên máy tính cá nhân của tác giả, có 2 lõi CPU và khoảng 3 GB RAM, mỗi lệnh bị giới hạn 180 giây. Thử nghiệm ban đầu cho thấy xử lý trọn một tháng HVFHV vượt giới hạn thời gian. Mỗi tháng HVFHV vì vậy được chia thành bốn khúc theo ngày đón (ngày 1–8, 9–16, 17–24 và phần còn lại); khúc cuối nhận thêm các bản ghi có thời điểm ngoài tháng hoặc rỗng để chúng vẫn được gắn cờ. Taxi vàng xử lý nguyên tháng. Tổng cộng có 120 phân vùng (96 khúc HVFHV và 24 tháng taxi vàng).

DuckDB được đặt giới hạn bộ nhớ 1,8 GB, 2 luồng, tắt bảo toàn thứ tự chèn và cho phép tràn ra thư mục tạm. Với cấu hình này, mỗi khúc HVFHV mất trung bình 46,8 giây (từ 27,1 đến 80,0 giây), mỗi tháng taxi vàng mất trung bình 22,0 giây. Hình 3.3 cho thấy thời gian tăng gần tuyến tính theo số dòng đầu vào.



Hình 3.3. Thời gian xử lý mỗi phân vùng (Bronze → Silver → Gold) theo số dòng đầu vào

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Bảng 3.5. Tổng thời gian xử lý theo bước và thông lượng

Dịch vụ	Kiểm tra chất lượng (s)	Ghi Silver (s)	Tạo Gold (s)	Tổng (s)	Dòng/giây
HVFBHV	217,6	3.613,3	661,3	4.491,8	107.543
Taxi vàng	26,8	412,9	89,4	529,0	169.929

Nguồn: kết quả tính toán của tác giả.

Bước ghi Silver chiếm phần lớn thời gian (80,2% tổng thời gian) vì phải nén và ghi toàn bộ dữ liệu. Bước kiểm tra chất lượng chỉ chiếm 4,9% nhờ DuckDB chỉ đọc các cột cần cho quy tắc. Toàn bộ pipeline Bronze → Gold cho hai dịch vụ mất 83,7 phút thời gian tính toán.

3.3.4. Dung lượng theo lớp

Bảng 3.6. Dung lượng lưu trữ theo lớp

Dịch vụ	Bronze (MB)	Silver (MB)	Silver / Bronze
HVFBHV	11.191,8	14.146,0	1,26
Taxi vàng	1.452,2	1.872,6	1,29

Nguồn: kết quả tính toán của tác giả.

Lớp Silver lớn hơn Bronze khoảng 28% dù đã loại bỏ các bản ghi lỗi. Nguyên nhân là Silver thêm mười trường dẫn xuất (ngày, giờ, thứ, thời gian chờ, tốc độ, hai nhóm vùng, cờ chạm CRZ, chi phí hành khách) và các cột chuỗi nhóm vùng. Đây là đánh đổi có chủ ý: tính một lần ở Silver thay vì tính lại ở mọi truy vấn phía sau. Tổng dung lượng lớp Gold chỉ khoảng nửa gigabyte, tức nhỏ hơn Silver hơn hai mươi lần.

3.3.5. Tổ chức thư mục của đồ án

Cấu trúc thư mục phản ánh trực tiếp các lớp của kiến trúc. Người chấm có thể tìm mọi đầu vào, đầu ra trung gian và kết quả theo quy ước dưới đây.

```

CongestionPricing_CaseStudy/
├── code/                               mã nguồn (00-14), config.py, panels.py, causal.py,
viz.py, run_all.sh
├── report/                             mã dựng báo cáo (lib.py, results.py, front.py, ch1-
ch6.py, appendix.py)
├── data/
│   ├── raw/                           Bronze: 50 tệp gốc của TLC (không sửa đổi)
│   ├── bronze/                        danh mục metadata của lớp Bronze
│   ├── silver/service=.../year=.../month=.../part-k.parquet  dữ liệu chuyển đã làm sạch
│   └── gold/                          dim_zone, zone_adjacency, 7 bảng tổng hợp, _parts/
theo khúc
├── outputs/
│   ├── tables/                        bảng kết quả CSV (t01-t59, a01-a03)
│   ├── figures/                       hình PNG (f00-f41)
│   ├── logs/                          nhật ký JSON của từng bước và từng phân vùng
└── report/                           báo cáo Word và PDF

```

3.3.6. Truy vấn chuẩn hóa và gắn cờ chất lượng

Trích đoạn dưới đây là phần lõi của bước Silver cho HVFHV: chuẩn hóa tên cột, gán giá trị mặc định cho các khoản phí trống và đặt phí CBD bằng 0 cho các tháng trước 2025. Toàn bộ được thực hiện trong DuckDB, dữ liệu không đi qua pandas.

```
SELECT 'hvfhv' AS service, hvfhs_license_num AS company_code,  
       request_datetime AS request_ts, pickup_datetime AS pickup_ts, dropoff_datetime AS  
dropoff_ts,  
       PULocationID AS pu, DOLocationID AS dl, trip_miles AS miles, trip_time::DOUBLE AS  
time_s,  
       base_passenger_fare AS fare, coalesce(tolls,0) AS tolls, coalesce(bcf,0) AS bcf,  
       coalesce(sales_tax,0) AS tax, coalesce(congestion_surcharge,0) AS cong_sur,  
       coalesce(airport_fee,0) AS airport_fee, {cbd} AS cbd_fee, coalesce(tips,0) AS  
tips, driver_pay,  
       (shared_request_flag = 'Y')::INT AS shared_req, (wav_request_flag = 'Y')::INT AS  
wav_req  
FROM read_parquet('{f}')  
-- {cbd} = coalesce(cbd_congestion_fee,0) nếu tháng ≥ 2025-01, ngược lại 0.0
```

Sau đó, mỗi quy tắc chất lượng là một biểu thức logic được ép kiểu thành số nguyên, ví dụ quy tắc Q3 là (miles IS NULL OR miles <= 0 OR miles > 100)::INT. Một câu lệnh tổng hợp duy nhất đếm số vi phạm của cả bảy quy tắc, rồi câu lệnh COPY ghi các dòng có tổng cờ bằng 0 ra Silver kèm các trường dẫn xuất. Các bảng Gold được tạo bằng GROUP BY ALL trên tệp Silver vừa ghi, trong cùng một tiến trình.

3.4. Kiểm soát chất lượng dữ liệu

3.4.1. Bảy quy tắc chất lượng

Bảng 3.7. Các quy tắc chất lượng dữ liệu áp dụng ở lớp Silver

Mã	Điều kiện loại bỏ	Tên cờ trong mã
Q1	Thời điểm đón nằm ngoài tháng của tệp hoặc rỗng	q_out_of_month
Q2	Vùng đón hoặc trả rỗng hoặc ngoài 1–263 (264, 265 là không xác định)	q_bad_zone
Q3	Quãng đường ≤ 0 hoặc > 100 dặm	q_bad_miles
Q4	Thời lượng < 60 giây hoặc > 4 giờ	q_bad_time
Q5	Giá cước cơ sở ≤ 0 hoặc > 1.000 USD	q_bad_fare
Q6	Tốc độ trung bình > 80 dặm/giờ	q_bad_speed
Q7	Thu nhập tài xế âm hoặc rỗng (chỉ HVFHV)	q_bad_pay

Nguồn: *config.py* và *03_silver_gold_month.py*.

Các ngưỡng được chọn theo tiêu chí vật lý và kinh doanh hiển nhiên, không tinh chỉnh theo kết quả. Chuyển dưới một phút thường là hủy chuyến; tốc độ trên 80 dặm/giờ trong nội thành là lỗi thiết bị; giá cước bằng 0 thường là chuyển điều chỉnh. Các vùng 264 và 265 là mã "không xác định" và "ngoài New York" của TLC, không gắn được với nhóm xử lý hay đối chứng.


3.4.2. Kết quả kiểm tra chất lượng

Bảng 3.8. Kết quả kiểm soát chất lượng theo dịch vụ

Dịch vụ	Bản ghi thô	Bị loại	Tỷ lệ loại (%)	Còn lại (Silver)
HVFHV	483.060.132	21.622.074	4,48	461.438.058
Taxi vàng	89.892.322	7.018.595	7,81	82.873.727

Nguồn: kết quả tính toán của tác giả.

Với HVFHV, 4,48% bản ghi bị loại và gần như toàn bộ là do quy tắc Q2: 21.092.054 bản ghi có vùng đón hoặc trả không xác định. Các quy tắc khác chỉ loại vài trăm nghìn bản ghi. Với taxi vàng, tỷ lệ loại cao hơn (7,81%) và phân bố đều hơn giữa các quy tắc, trong đó giá cước không hợp lệ (3.618.609 bản ghi) và quãng đường không hợp lệ (2.183.746 bản ghi) là hai nguyên nhân chính. Điều này phù hợp với việc dữ liệu taxi vàng được ghi từ đồng hồ tính cước, có nhiều chuyển điều chỉnh và hủy hơn so với dữ liệu nền tảng.



Hình 3.4. Tỷ lệ bản ghi vi phạm từng quy tắc chất lượng theo dịch vụ

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Phụ lục F trình bày số bản ghi bị loại theo từng tháng và từng quy tắc. Tỷ lệ loại ổn định qua các tháng, không có bước nhảy tại tháng 01/2025, nên việc làm sạch dữ liệu không tạo ra khác biệt giả giữa hai giai đoạn.

3.5. Xác định vùng xử lý bằng dữ liệu

3.5.1. Vấn đề ranh giới

Ranh giới CRZ là đường 60 và các tuyến đường ven sông. Ranh giới các vùng taxi của TLC được vẽ từ trước và không trùng với đường 60. Một số vùng nằm trọn


phía nam, một số vùng nằm trọn phía bắc, còn một số vùng bị đường 60 cắt ngang. Nếu gán tay danh sách vùng, sai sót ở các vùng vắt ranh giới sẽ làm lẫn đơn vị xử lý với đơn vị đối chứng.

3.5.2. Thủ tục phân loại

Đồ án dùng chính dữ liệu thu phí để phân loại. Với mỗi vùng, xét các chuyến HVFHV có điểm đón và điểm trả cùng nằm trong vùng đó (chuyến nội vùng) trong quý I/2025, sau ngày 05/01. Nếu vùng nằm trọn trong CRZ, gần như mọi chuyến nội vùng đều bị thu phí; nếu vùng nằm ngoài, gần như không chuyến nào bị thu; nếu vùng vắt ranh giới, tỷ lệ nằm ở khoảng giữa. Quy tắc phân loại:

- CRZ: tỷ lệ chuyến nội vùng bị thu phí $\geq 90\%$.
- Vắt ranh giới (CRZ_PARTIAL): tỷ lệ từ 10% đến dưới 90%.
- Manhattan phía bắc (MN_NORTH): các vùng Manhattan còn lại.
- Các quận ngoài (OUTER): Bronx, Brooklyn, Queens, Staten Island, trừ sân bay.
- Sân bay (AIRPORT): EWR (1), JFK (132), LaGuardia (138), được tách riêng vì có cấu trúc nhu cầu đặc thù.

Phân nhóm 263 vùng taxi theo mức độ chịu phí CBD (xác định từ dữ liệu quý I/2025)



Hình 3.5. Phân nhóm 263 vùng taxi theo mức độ chịu phí CBD, xác định từ dữ liệu quý I/2025

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Bảng 3.9. Số vùng theo nhóm và theo quận

Nhóm	Quận	Số vùng
Sân bay	EWR	1
Sân bay	Queens	2
CRZ	Manhattan	38
Vượt ranh giới	Manhattan	6
Manhattan phía bắc	Manhattan	25
Quận ngoài	Bronx	43
Quận ngoài	Brooklyn	61
Quận ngoài	Queens	67
Quận ngoài	Staten Island	20
Không xác định	Unknown	1

Nguồn: kết quả tính toán của tác giả.


Bảng 3.10. Sáu vùng vắt qua ranh giới CRZ và tỷ lệ chuyển nội vùng bị thu phí

Mã vùng	Tên vùng	Tỷ lệ thu phí HVFHV (%)	Tỷ lệ thu phí taxi vàng (%)	Số chuyển nội vùng HVFHV
43	Central Park	42,0	32,9	995
140	Lenox Hill East	14,4	13,0	7.341
141	Lenox Hill West	15,1	16,5	9.201
142	Lincoln Square East	48,6	39,3	8.533
143	Lincoln Square West	30,8	18,5	7.634
237	Upper East Side South	29,8	23,4	26.371

Nguồn: kết quả tính toán của tác giả.

Kết quả phân loại có độ tách rõ: 38 vùng CRZ có tỷ lệ thu phí nội vùng từ 94,3% đến 100,0%, trong khi mọi vùng Manhattan phía bắc đều dưới 3,2%. Sáu vùng vắt ranh giới gồm Công viên Trung tâm, Lenox Hill Đông và Tây, Lincoln Square Đông và Tây, Upper East Side Nam, đúng là các vùng nằm quanh đường 60 trên bản đồ Manhattan dưới đây. Tỷ lệ thu phí của taxi vàng ở các vùng này cho thứ tự tương tự, là một kiểm tra chéo độc lập. Các vùng vắt ranh giới không được đưa vào nhóm xử lý hay đối chứng của đặc tả chính; phần độ vững sẽ thử gộp chúng vào nhóm xử lý.

Manhattan: vùng CRZ và các vùng vắt qua ranh giới



Hình 3.6. Manhattan: vùng CRZ và sáu vùng vắt qua ranh giới (đánh số theo mã vùng TLC)

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

3.5.3. Khoảng cách và quan hệ kề

Từ shapefile, đồ án tính diện tích, tâm của từng vùng và khoảng cách từ đa giác vùng tới hợp các đa giác CRZ (đơn vị km, hệ tọa độ phẳng New York State Plane). Hai vùng được coi là kề nhau nếu khoảng cách giữa hai đa giác dưới 200 feet, ngưỡng đủ để bỏ qua một con phố ngăn cách. Thông tin khoảng cách được dùng để chia các vùng ngoài CRZ thành các dải 0–1 km, 1–2,5 km, 2,5–5 km, 5–10 km và trên 10 km phục vụ phân tích lan tỏa.

3.6. Các bảng Gold và panel phân tích

3.6.1. Bảy bảng Gold

Bảng 3.11. Các bảng Gold, khóa tổng hợp và số dòng

Bảng	Khóa	Số dòng	Sử dụng
zone_day_pu	dịch vụ × ngày × vùng đón	358.148	Panel chính, EDA
zone_day_do	dịch vụ × ngày × vùng trả	370.868	Lan tỏa phía điểm trả
grp_hour_day	dịch vụ × ngày × giờ × nhóm đón × nhóm trả	859.415	Luồng, tốc độ theo giờ
company_grp_day	dịch vụ × hãng × ngày × nhóm đón × nhóm trả	54.825	Thị phần hãng
zone_hour_month	dịch vụ × tháng × vùng đón × giờ	281.102	Không đồng nhất theo giờ
od_month	dịch vụ × tháng × vùng đón × vùng trả	2.230.151	Panel OD, DML
trip_sample	mẫu ngẫu nhiên 0,25% chuyến HVFHV, 1% taxi vàng	1.974.894	Phân phối từng chuyến

Nguồn: kết quả tính toán của tác giả.

Mọi bảng Gold (trừ mẫu chuyến) chỉ chứa các đại lượng cộng được: số chuyến, tổng giá cước, tổng thu nhập tài xế, tổng quãng đường, tổng thời lượng, tổng tip, tổng phí CBD, tổng chi phí hành khách, tổng thời gian chờ và số chuyến có thời gian chờ hợp lệ. Các chỉ tiêu trung bình như giá/dặm hay tốc độ được tính ở bước phân tích bằng tỷ số của tổng, đảm bảo trọng số đúng theo chuyến và cho phép tổng hợp tiếp lên bất kỳ cấp nào mà không sai lệch.

3.6.2. Các panel dùng cho suy luận nhân quả

Bảng 3.12. Quy mô các panel dùng cho suy luận nhân quả

Panel	Cấu trúc	Số quan sát	Số chuyển bao phủ
HVFHV vùng × tuần	237 vùng (37 xử lý, 200 đối chứng) × 103 tuần	24.411	425.139.263
Taxi vàng vùng × tuần	54 vùng (38 xử lý, 16 đối chứng) × 103 tuần	5.562	60.238.446
HVFHV vùng × ngày	237 vùng × 731 ngày	173.247	–
HVFHV cặp OD × tháng	9280 cặp × 24 tháng	222.720	342.491.463

Nguồn: kết quả tính toán của tác giả.

Panel vùng × tuần của HVFHV chỉ giữ các vùng CRZ, Manhattan phía bắc và quận ngoài có bình quân ít nhất 100 chuyển đón mỗi ngày trong năm 2024 và có dữ liệu ở mọi tuần. Ngưỡng này loại các vùng rất nhỏ như công viên, đảo, nghĩa trang, nơi log số chuyển dao động mạnh vì lý do ngẫu nhiên. Phần độ vững thử ngưỡng 50 và 300 chuyển. Với taxi vàng, ngưỡng là 20 chuyển mỗi ngày và nhóm đối chứng chỉ gồm Manhattan phía bắc; lý do được giải thích ở Chương 4.

Panel cặp OD × tháng giữ các cặp có bình quân ít nhất 300 chuyển mỗi tháng năm 2024 và có dữ liệu đủ 24 tháng, với cả hai đầu thuộc CRZ, Manhattan phía bắc hoặc quận ngoài. Kết quả có 1351 cặp CRZ → CRZ, 1180 cặp CRZ → ngoài, 1008 cặp ngoài → CRZ và 5741 cặp không chạm CRZ.

3.7. Thiết kế thực nghiệm hiệu năng

Để trả lời RQ1 bằng số đo thay vì nhận định chung, đề án thực hiện ba nhóm thực nghiệm trên chính dữ liệu HVFHV tháng 03/2024. Mỗi phép đo chạy trong một tiến trình Python riêng để đo bộ nhớ đỉnh (max RSS) và lặp ba lần, báo cáo trung vị.

- **Định dạng lưu trữ:** lấy 2 triệu dòng đầu, ghi ra CSV, CSV nén gzip, Parquet Snappy và Parquet ZSTD; đo dung lượng, thời gian ghi và thời gian chạy cùng một truy vấn tổng hợp theo vùng đón.
- **Bộ máy xử lý:** chạy cùng truy vấn (số chuyển, tổng giá cước, tổng thu nhập tài xế theo vùng đón) trên cả tháng (khoảng 21 triệu dòng) bằng DuckDB, pandas (đọc 3 cột rồi groupby) và PyArrow (đọc 3 cột rồi group_by).
- **Cắt tỉa cột và đẩy điều kiện lọc:** so sánh đọc 2 cột với đọc cả 24 cột, và lọc theo ngày (cột thời gian có thứ tự trong tệp) với lọc theo vùng (cột không có thứ tự).

3.8. Chiến lược nhận dạng nhân quả

3.8.1. Đặc tả chính

Với vùng z và tuần t , gọi $T_z = 1$ nếu z thuộc CRZ, $P_t = 1$ nếu tuần t bắt đầu từ 05/01/2025 trở đi và $D_{zt} = T_z \cdot P_t$. Đặc tả chính là:

$$Y_{zt} = \alpha_z + \gamma_t + \beta \cdot D_{zt} + \varepsilon_{zt} \quad (3.1)$$

với Y_{zt} là một trong các biến kết quả định nghĩa ở mục 3.8.6. Sai số chuẩn phân cụm theo vùng. Với log số chuyển, $100 \cdot (e^\beta - 1)$ là phần trăm thay đổi. Với các chỉ tiêu tỷ số (giá/dặm, tốc độ, thời gian chờ), β là thay đổi tuyệt đối theo đơn vị của biến.

3.8.2. Các đặc tả bổ sung

- **DDD mùa vụ:** thêm hiệu ứng cố định $T_z \times$ tuần trong năm (52 mức). Vì tuần 0 của năm 2025 cách tuần 0 của năm 2024 đúng 364 ngày, mỗi tuần năm 2025 được so với tuần cùng thứ tự và cùng ngày trong tuần của năm 2024.
- **TWFE có trọng số:** trọng số theo số chuyển bình quân ngày của vùng năm 2024, cho ước lượng đại diện cho chuyển đi thay vì cho vùng.
- **TWFE + xu hướng nhóm:** thêm biến $T_z \times (\text{số tuần kể từ mốc})/52$, cho phép nhóm xử lý có xu hướng tuyến tính riêng.
- **Nghiên cứu sự kiện theo tuần** (từ -52 đến +51) và **theo tháng** (từ -12 đến +11), hệ số được chuẩn hóa theo trung bình giai đoạn trước.
- **Panel cặp OD $\times$ tháng:** hiệu ứng cố định cặp và tháng, xử lý là cặp chạm CRZ, phân cụm theo vùng đón; tách riêng ba loại luồng CRZ $\rightarrow$ CRZ, CRZ $\rightarrow$ ngoài, ngoài $\rightarrow$ CRZ.
- **Không đồng nhất theo giờ:** panel vùng $\times$ khung giờ $\times$ tháng, ước lượng riêng cho năm khung giờ.
- **Không đồng nhất theo ngày:** panel vùng $\times$ ngày với tương tác $D \times$ cuối tuần.

3.8.3. Kiểm soát tổng hợp

Chuỗi xử lý là tổng số chuyển HVFHV đón trong các vùng CRZ theo tuần, chia cho trung bình năm 2024 để có chỉ số bằng 1. Mỗi vùng đối chứng cũng được chuẩn hóa như vậy. Trọng số không âm, tổng bằng 1, được tìm bằng quy hoạch toàn phương

SLSQP để cực tiểu tổng bình phương sai lệch trên các tuần năm 2024. Kiểm định giả được không gian lặp lại quy trình cho 60 vùng đối chứng có lưu lượng lớn nhất, mỗi lần coi một vùng là "xử lý" và dùng các vùng đối chứng còn lại làm nguồn.

3.8.4. Học máy nhân quả trên cặp OD

Đơn vị là cặp OD có ít nhất 3.600 chuyến trong năm 2024. Kết quả là thay đổi cùng kỳ $\Delta Y = Y(2025) - Y(2024)$ của log số chuyến, tốc độ và thu nhập tài xế/dặm. Xử lý $D = 1$ nếu cặp chạm CRZ. Biến kiểm soát chính (bộ "rút gọn") gồm các đặc trưng chuyển đi năm 2024: log lưu lượng, quãng đường và thời lượng trung bình, tiền tip trung bình, tỷ trọng Uber, tỷ trọng chuyến đêm và cờ chuyển nội vùng. Bộ "đầy đủ" thêm tốc độ, giá/dặm, thu nhập/dặm và biến giả quận của hai đầu.

Mọi mô hình phụ là LightGBM với cross-fitting 5 phần. Ước lượng gồm PLR (θ), AIPW trên vùng chồng lấn $\hat{e}(X) \in [0,05; 0,95]$ và DR-learner cho CATE với cross-fitting lần hai. Mẫu có 9.280 cặp OD, trong đó 3.539 cặp chạm CRZ. Không đưa khoảng cách tới CRZ vào X vì biến này gần như xác định hoàn toàn D .

3.8.5. Lan tỏa, giả được và độ vững

- **Lan tỏa không gian:** hồi quy log số chuyến đón và log số chuyến trả lên các biến giả (dải khoảng cách $\times$ sau chính sách), nhóm tham chiếu là các vùng cách CRZ trên 10 km. Phía điểm trả tách riêng khách đến từ ngoài CRZ và khách đến từ CRZ.
- **Giả được theo thời gian:** chỉ dùng dữ liệu năm 2024 và giả định chính sách bắt đầu 07/07/2024, cho cả panel vùng $\times$ tuần và panel OD $\times$ tháng, có và không có xu hướng nhóm.
- **Hoán vị:** 500 lần gán ngẫu nhiên 37 vùng đối chứng làm vùng xử lý, ước lượng lại TWFE chỉ trên các vùng đối chứng.
- **Bảng độ vững:** thay nhóm đối chứng, ngưỡng lưu lượng, định nghĩa nhóm xử lý, cửa sổ thời gian, trọng số, hiệu ứng cố định và cấp phân cụm.

3.8.6. Định nghĩa biến kết quả

Bảng 3.13. Định nghĩa các biến kết quả

Tên biến	Ý nghĩa	Cách tính từ bảng Gold
ln_n	log số chuyến đón	$\ln(\Sigma \text{ chuyến})$
fare_pm	Giá cước cơ sở/dặm (USD)	$\Sigma \text{ base_passenger_fare} / \Sigma \text{ trip_miles}$
pay_pm	Thu nhập tài xế/dặm (USD)	$\Sigma \text{ driver_pay} / \Sigma \text{ trip_miles}$
fare_pt, pay_pt	Giá cước, thu nhập tài xế mỗi chuyến	$\Sigma / \text{số chuyến}$
rider_pt	Tổng chi phí hành khách/chuyến (USD)	giá cước + phí cầu đường + BCF + thuế + phụ thu + phí sân bay + phí CBD
cbd_pt	Phí CBD/chuyến	$\Sigma \text{ cbd_congestion_fee} / \text{số chuyến}$
tips_pt	Tip/chuyến	$\Sigma \text{ tips} / \text{số chuyến}$
pay_share	Thu nhập tài xế/giá cước (%)	$100 \cdot \Sigma \text{ driver_pay} / \Sigma \text{ base_passenger_fare}$
mph	Tốc độ trung bình (dặm/giờ)	$\Sigma \text{ trip_miles} / (\Sigma \text{ trip_time} / 3600)$
miles_pt	Quãng đường/chuyến (dặm)	$\Sigma \text{ trip_miles} / \text{số chuyến}$
wait	Thời gian chờ đón (phút)	$\Sigma (\text{pickup} - \text{request}) / \text{số chuyến hợp lệ}$
shared_pct	Tỷ lệ yêu cầu đi chung (%)	$100 \cdot \Sigma \text{ shared_request} / \text{số chuyến}$

Nguồn: *panels.py*.

3.9. Môi trường tính toán và khả năng tái lập

Bảng 3.14. Môi trường tính toán

Thành phần	Phiên bản, cấu hình
Hệ điều hành	Linux (máy ảo trên Windows), 2 lõi CPU, khoảng 3 GB RAM
Python	3.10
DuckDB	1.5.5 (giới hạn bộ nhớ 1,8 GB, 2 luồng)
PyArrow / pandas	25.0.1 / 2.3.3
statsmodels / scikit-learn / LightGBM	0.15.0 / 1.7.2 / 4.7.0
pyshp / shapely / matplotlib	hiện hành / 2.1.2 / 3.10.9
Apache Spark (PySpark) / Java	3.5.3 / OpenJDK 11 (chế độ local[2], bộ nhớ driver 1.200 MB)
Hạt giống ngẫu nhiên	20250105 (mẫu chuyển, cross-fitting, hoán vị)

Nguồn: *requirements.txt* và *config.py*.

Toàn bộ pipeline chạy bằng một lệnh bash `code/run_all.sh` từ thư mục gốc của đồ án. Các bước sau bước 04 chỉ đọc các bảng Gold nên có thể chạy lại độc lập trong vài phút. Mọi phép ngẫu nhiên dùng cùng một hạt giống, nên kết quả chạy lại trùng khớp. Báo cáo này được dựng bằng bước 13, đọc trực tiếp các tệp CSV và PNG trong thư mục outputs.

3.10. Các mô-đun mở rộng

Bảng 3.15. Các bước mở rộng của pipeline

Bước	Nội dung	Kết quả ở
15_spark_pipeline.py	Tái lập bảng Gold bằng Spark, đối chứng từng ô; tám thực nghiệm hiệu năng và cơ chế	Chương 5
15b_compare_outputs.py	So sánh bảng kết quả trước và sau khi sửa lỗi thượng nguồn	Chương 5, 6
16_governance_risk.py	Danh mục, phá hệ, dấu bấm, đối soát, biểu đồ kiểm soát, bất thường, k-ẩn danh, quyền riêng tư vi phân, RTO	Chương 6
17_business_analytics.py	Tác động theo hãng, dự báo nhu cầu, công suất thống kê, định giá động, hạch toán tài nguyên	Chương 7
18_theory_sensitivity.py	Kiểm định giả thuyết lý thuyết (liều – đáp ứng, tốc độ – lưu lượng, lan tỏa theo phôi nhiễm, thu nhập tài xế)	Mục 4.15
19_long_preperiod.py	Nghiên cứu sự kiện theo tháng 2022–2025, giả được năm 2024, điều chỉnh xu hướng, độ nhạy Rambachan–Roth (RM, SD)	Mục 4.14.4, 4.14.5

Nguồn: thư mục code/.

Ba bước 15 đến 17 đọc cùng các lớp Silver và Gold như các bước phân tích nhân quả, nên không làm thay đổi kết quả của Chương 4, với một ngoại lệ có chủ đích: đối chứng ở bước 15 phát hiện một lỗi ép kiểu ở bước 04, bước 04 được sửa và các bước 06 đến 14 được chạy lại trước khi dựng báo cáo này. Thiết kế thực nghiệm chi tiết của từng mô-đun được trình bày ở đầu chương tương ứng, để mỗi chương có thể đọc độc lập.

3.11. Tiểu kết Chương 3

Chương 3 đã mô tả dữ liệu (572.952.454 bản ghi thô), kiến trúc Lakehouse ba lớp với xử lý theo khúc, bảy quy tắc chất lượng, thủ tục xác định vùng xử lý từ dữ liệu, bảy bảng Gold và bốn panel phân tích, cùng chiến lược nhận dạng gồm nhiều thiết kế bổ trợ nhau, cùng ba mô-đun mở rộng về xử lý phân tán, quản trị dữ liệu và phân tích kinh doanh. Chương 4 trình bày kết quả của phần phân tích nhân quả.

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH

Chương này trình bày kết quả theo thứ tự của câu hỏi nghiên cứu. Mục 4.1 báo cáo hiệu năng của pipeline (RQ1). Các mục 4.2 đến 4.4 mô tả dữ liệu sau xử lý. Các mục 4.5 đến 4.12 trình bày ước lượng nhân quả về số chuyển, tốc độ, thời gian chờ, giá và thu nhập (RQ2, RQ3, RQ5), tác động không đồng nhất và lan tỏa (RQ4). Mục 4.13 và 4.14 là các phép thử độ tin cậy. Mục 4.15 đối chiếu kết quả với các giả thuyết lý thuyết của mục 2.11, và mục 4.16 tổng hợp kết quả theo câu hỏi nghiên cứu.

4.1. Hiệu năng của pipeline dữ liệu lớn


4.1.1. Định dạng lưu trữ

Bảng 4.1. So sánh bốn định dạng lưu trữ trên 2.000.000 dòng HVFHV tháng 03/2024

Định dạng	Dung lượng (MB)	So với CSV	Thời gian ghi (s)	Truy vấn – trung vị (s)	Truy vấn – min–max (s)
CSV	302,5	1,000	52,2	2,628	2,419 – 2,644
CSV.gz	61,7	0,204	31,2	1,561	1,438 – 1,694
Parquet Snappy	53,2	0,176	13,3	0,196	0,177 – 0,341
Parquet ZSTD	46,0	0,152	10,8	0,208	0,202 – 0,254

Nguồn: kết quả tính toán của tác giả.

So sánh định dạng lưu trữ trên cùng lát cắt dữ liệu



Hình 4.1. Dung lượng tệp và thời gian truy vấn tổng hợp theo định dạng lưu trữ

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Parquet ZSTD chiếm 46,0 MB, bằng 15,2% dung lượng CSV không nén (302,5 MB). Nén gzip đưa CSV xuống 61,7 MB, tức vẫn lớn hơn Parquet ZSTD 1,34 lần. Khác biệt lớn hơn nằm ở thời gian truy vấn: cùng một phép tổng hợp theo vùng đón mất 2,63 giây trên CSV nhưng chỉ 0,21 giây trên Parquet ZSTD, nhanh hơn 12,7 lần.

Lý do là truy vấn chỉ cần hai cột trong khi CSV buộc phải đọc và phân tích cú pháp toàn bộ dòng.

Giữa hai kiểu nén của Parquet, ZSTD nhỏ hơn Snappy 13,5% còn thời gian truy vấn gần như tương đương (0,208 và 0,196 giây). Kết quả này là cơ sở để lớp Silver chọn ZSTD. Thời gian ghi CSV (52,2 giây) lâu hơn Parquet ZSTD (10,8 giây) cũng vì CSV phải chuyển mọi giá trị sang dạng văn bản.


4.1.2. Bộ máy xử lý

Bảng 4.2. So sánh ba bộ máy xử lý trên cùng truy vấn tổng hợp một tháng HVFHV

Bộ máy	Trung vị (s)	Nhanh nhất – chậm nhất (s)	Bộ nhớ đỉnh (MB)	Số nhóm
DuckDB (SQL)	2,08	1,83 – 3,75	164	261
Pandas (read_parquet 3 cột + groupby)	6,36	2,53 – 10,61	1.382	261
PyArrow (dataset + group_by)	1,71	1,63 – 1,75	741	261

Nguồn: kết quả tính toán của tác giả.

Ba bộ máy xử lý trên 1 tháng HVFHV đầy đủ (21,3 triệu dòng)



Hình 4.2. Thời gian và bộ nhớ đỉnh của ba bộ máy xử lý

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Ba bộ máy cho cùng 261 nhóm kết quả. Về thời gian, PyArrow (1,71 giây) và DuckDB (2,08 giây) tương đương, pandas chậm hơn (6,36 giây) và dao động mạnh giữa các lần chạy. Khác biệt quyết định là bộ nhớ: DuckDB chỉ dùng 164 MB vì xử lý luồng theo lô và không giữ toàn bộ cột trong bộ nhớ, trong khi PyArrow cần 741 MB và pandas cần 1.382 MB, tức gấp 8,4 lần DuckDB. Trên máy khoảng 3 GB RAM, pandas chỉ xử lý được vài tháng cùng lúc trước khi hết bộ nhớ, còn DuckDB có thể xử lý toàn bộ nhờ cơ chế tràn đĩa.

Kết quả này giải thích lựa chọn kiến trúc của đồ án: DuckDB đảm nhận toàn bộ các bước nặng (Silver, Gold), còn pandas chỉ được dùng ở bước phân tích trên các bảng Gold nhỏ.

4.1.3. Cắt tia cột và đẩy điều kiện lọc

Bảng 4.3. Tác động của cắt tia cột và đẩy điều kiện lọc trong DuckDB (1 tháng HVFHV)

Phép thử	Trung vị (s)	Bộ nhớ đỉnh (MB)	Giá trị đầu tiên trả về
Đọc 2 cột, không lọc	0,761	108	21280788
Đọc toàn bộ 24 cột (max từng cột)	6,260	124	HV0005
2 cột + lọc 1 ngày (pushdown theo min/max row group)	0,260	108	740231
2 cột + lọc theo vùng (không sắp xếp theo vùng)	0,498	108	240817

Nguồn: kết quả tính toán của tác giả.

Đọc toàn bộ 24 cột mất 6,26 giây, gấp 8,2 lần so với chỉ đọc hai cột (0,76 giây). Đây là lợi ích trực tiếp của lưu trữ dạng cột. Khi thêm điều kiện lọc một ngày trên cột thời gian đón, truy vấn còn nhanh hơn nữa (0,260 giây) vì thời gian đón trong tệp TLC gần như tăng dần: mỗi trong số 21 row group có khoảng thời gian đón hẹp, nên DuckDB bỏ qua được phần lớn row group nhờ thống kê min/max. Ngược lại, lọc theo vùng đón (0,498 giây) không nhanh hơn đáng kể so với đọc hai cột, vì mọi row group đều chứa đủ các vùng.

Hàm ý thực tiễn là thứ tự sắp xếp dữ liệu khi ghi quyết định hiệu quả của đẩy điều kiện lọc. Lớp Silver được phân vùng theo tháng và giữ thứ tự thời gian bên trong, phù hợp với các truy vấn theo thời gian là loại truy vấn chính của đồ án.

4.1.4. Tổng hợp về RQ1

Toàn bộ 572.952.454 bản ghi được xử lý từ Bronze đến Gold trong 83,7 phút thời gian tính toán trên 2 lõi CPU, với bộ nhớ DuckDB không vượt 1,8 GB. Trong các lựa chọn thiết kế, định dạng cột nén ZSTD và bộ máy thực thi vector hóa có giới hạn bộ nhớ là hai yếu tố làm cho việc này khả thi. Việc chia tháng thành khúc làm tăng số phân vùng nhưng không làm tăng tổng thời gian, vì thời gian tăng gần tuyến tính theo số dòng. Chương 5 so sánh thêm với Apache Spark trên cùng dữ liệu và cùng phần cứng.

4.2. Mô tả dữ liệu sau xử lý

4.2.1. Chi tiêu mô tả theo nhóm vùng

Bảng 4.4. Chi tiêu mô tả chuyển HVFHV theo nhóm vùng đón và năm

Nhóm vùng đón	Năm	Chuyến/ngày	Giá cước/chuyến	TN tài xế/chuyến	Dặm/chuyến	Phút/chuyến	Dặm/giờ	Chờ (phút)	Phí CBD/chuyến
Sân bay	2024	20.850	53,22	40,08	11,87	36,6	19,48	6,43	0,000
Sân bay	2025	20.495	56,51	42,06	11,56	36,4	19,04	6,41	0,602
CRZ	2024	162.857	28,79	20,41	4,39	20,8	12,70	4,46	0,000
CRZ	2025	155.451	31,07	21,47	4,44	20,6	12,94	4,34	1,475
Vắt ranh giới	2024	21.303	27,46	19,75	4,37	20,1	13,03	4,22	0,000
Vắt ranh giới	2025	20.725	28,94	20,66	4,38	20,1	13,05	4,16	0,943
Manhattan phía bắc	2024	57.746	23,32	18,26	4,63	18,5	15,04	4,53	0,000
Manhattan phía bắc	2025	56.674	23,63	18,72	4,55	18,3	14,95	4,70	0,318
Quận ngoài	2024	363.832	20,64	16,88	4,20	17,8	14,19	4,65	0,000
Quận ngoài	2025	382.564	20,72	17,15	4,11	17,5	14,08	4,89	0,109

Nguồn: kết quả tính toán của tác giả.

Các vùng CRZ là thị trường đậm đặc nhất tính theo diện tích. Năm 2024, bình quân mỗi ngày có 162.857 chuyến HVFHV đón khách trong CRZ, so với 363.832 chuyến ở toàn bộ các quận ngoài, dù diện tích quận ngoài lớn hơn hàng chục lần. Chuyến đón trong CRZ ngắn hơn về quãng đường (4,39 so với 4,20 dặm) nhưng đắt hơn (28,79 so với 20,64 USD giá cước cơ sở) và chậm hơn rõ rệt (12,70 so với 14,19 dặm/giờ).

Sang năm 2025, số chuyến/ngày đón trong CRZ giảm xuống 155.451 (-4,5%), trong khi ở quận ngoài tăng lên 382.564 (5,1%). Tốc độ trung bình trong CRZ tăng từ 12,70 lên 12,94 dặm/giờ, còn ở quận ngoài giảm từ 14,19 xuống 14,08. Thời gian chờ trong CRZ giảm từ 4,46 xuống 4,34 phút. Phí CBD trung bình trên mỗi chuyến đón trong CRZ năm 2025 là 1,475 USD, sát mức 1,50 USD vì gần như mọi chuyến đón trong CRZ đều bị tính phí. Đây là các so sánh thô trước – sau; phần nhân quả ở các mục sau sẽ tách chúng khỏi xu hướng chung.

4.2.2. Taxi vàng

Taxi vàng có cấu trúc không gian khác hẳn: năm 2024 có 23.080.269 chuyến đón trong CRZ nhưng chỉ 1.155.901 chuyến đón ở quận ngoài. Năm 2025, số chuyến taxi vàng đón trong CRZ tăng lên 25.064.739 (8,6%), còn ở quận ngoài tăng lên 2.841.391, tức hơn gấp đôi.

Bảng 4.5. Số chuyển taxi vàng (dữ liệu thô) theo nhà cung cấp, nhóm vùng đón và năm


VendorID	Nhóm vùng đón	2024	2025	Thay đổi (%)
1	CRZ	5.456.822	5.085.712	-6,8
1	Manhattan phía bắc	1.588.554	1.605.129	1,0
1	Quận ngoài	522.553	950.009	81,8
2	CRZ	18.568.906	22.276.852	20,0
2	Manhattan phía bắc	4.715.167	5.800.251	23,0
2	Quận ngoài	807.040	2.472.844	206,4
6	CRZ	238	6.279	2.538,2
6	Manhattan phía bắc	102	3.365	3.199,0
6	Quận ngoài	423	12.688	2.899,5
7	CRZ	110	302.434	274.840,0
7	Manhattan phía bắc	55	98.363	178.741,8
7	Quận ngoài	0	3.958	–

Nguồn: t27b_yellow_vendor_by_year_group.csv, tính trực tiếp từ lớp Bronze.

Bảng trên cho thấy mức tăng ở quận ngoài đến chủ yếu từ hai nhà cung cấp chính: VendorID 2 tăng từ 807.040 lên 2.472.844 chuyển, VendorID 1 từ 522.553 lên 950.009. Hai nhà cung cấp mới (VendorID 6 và 7) có xuất hiện nhiều hơn năm 2025 nhưng quy mô ở quận ngoài nhỏ. Dữ liệu không cho biết nguyên nhân của mức tăng này. Điều chắc chắn là nó không liên quan trực tiếp đến CRZ và làm cho các vùng quận ngoài không còn là đối chứng phù hợp cho taxi vàng. Đồ án vì vậy chỉ dùng Manhattan phía bắc làm nhóm đối chứng chính cho taxi vàng và báo cáo đặc tả gồm quận ngoài như một phép thử độ nhạy.

4.3. Diễn biến theo thời gian

4.3.1. Số chuyến theo ngày




Hình 4.3. Số chuyến HVFHV theo nhóm vùng đón, trung bình trượt 7 ngày, 01/2024 – 12/2025

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Hình 4.3 cho thấy nhịp mùa vụ rõ rệt ở cả ba nhóm: số chuyến giảm vào tuần lễ Tạ ơn và tuần cuối năm, tăng mạnh vào đầu tháng 12, giảm nhẹ vào mùa hè. Mùa vụ của CRZ mạnh hơn quận ngoài, đặc biệt là cú sọt vào tuần cuối năm khi văn phòng đóng cửa. Đây chính là loại khác biệt làm cho so sánh đơn giản trước – sau hay giả định xu hướng song song trở nên mong manh. Ngay sau ngày 05/01/2025, đường CRZ không có bước nhảy lớn; thay đổi thể hiện rõ hơn khi so sánh cùng kỳ.

4.3.2. Tăng trưởng cùng kỳ theo tuần




Hình 4.4. Tăng trưởng cùng kỳ số chuyển HVFHV theo tuần ISO, 2025 so với 2024

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

So sánh cùng tuần giữa hai năm loại bỏ phần lớn mùa vụ. Trung bình qua 50 tuần ISO, số chuyển đón trong CRZ thay đổi -4,54% so với cùng kỳ, Manhattan phía bắc -1,96% và quận ngoài 4,95%. Trong 49/50 tuần, tăng trưởng của CRZ thấp hơn quận ngoài. Khoảng cách xấp xỉ 9,5 điểm phần trăm này là ước lượng thô đầu tiên về tác động, trước khi kiểm soát các yếu tố khác. Manhattan phía bắc nằm ở giữa, gợi ý rằng khu vực này cũng chịu ảnh hưởng một phần.

4.3.3. Bản đồ thay đổi cùng kỳ

Thay đổi cùng kỳ số chuyến HVFHV theo vùng đón (từ 05/01)



Hình 4.5. Thay đổi cùng kỳ số chuyến HVFHV theo vùng đón (05/01 – 31/12), 2025 so với 2024

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.


Bảng 4.6. Phân bố thay đổi cùng kỳ số chuyến đón theo vùng (vùng có ít nhất 5.000 chuyến năm 2024)

Nhóm	Số vùng	Trung bình (%)	Trung vị (%)	Thấp nhất (%)	Cao nhất (%)
Sân bay	2	-2,33	-2,33	-7,23	2,57
CRZ	38	-5,12	-5,37	-10,56	-0,09
Vắt ranh giới	6	-3,09	-3,87	-6,62	1,87
Manhattan phía bắc	22	-0,95	-2,24	-8,17	25,93
Quận ngoài	188	5,75	5,85	-13,94	18,78

Nguồn: kết quả tính toán của tác giả.

Bản đồ cho thấy một mẫu hình không gian rất rõ: gần như toàn bộ Manhattan có màu xanh (giảm), còn phần lớn các quận ngoài có màu đỏ (tăng). Trong 38 vùng CRZ, 38 vùng giảm, mức giảm trung vị 5,37%. Các vùng Manhattan phía bắc giáp ranh giới cũng giảm, trong khi các vùng xa hơn ở phía bắc đảo gần như không đổi. Mẫu hình này là gợi ý đầu tiên về hiệu ứng lan tỏa được phân tích ở mục 4.11.

4.3.4. So sánh HVFHV và taxi vàng trong CRZ




Hình 4.6. Chỉ số số chuyến đón trong CRZ theo tuần, HVFHV và taxi vàng (trung bình tuần năm 2024 = 100)

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Trong CRZ, chỉ số của taxi vàng giai đoạn sau chính sách có trung bình 106,8, còn HVFHV là 93,9. Hai dịch vụ có mùa vụ giống nhau trong năm 2024 nhưng tách ra sau ngày 05/01/2025: taxi vàng, với mức phí thấp bằng một nửa, không giảm như HVFHV. Đây là bằng chứng mô tả về sự thay thế một phần từ gọi xe sang taxi trong vùng chịu phí.

4.4. Doanh thu phí, cấu trúc luồng và nhịp theo giờ

4.4.1. Phí CBD ghi nhận trong dữ liệu



Hình 4.7. Tổng phí CBD ghi nhận trong dữ liệu chuyển đi theo tháng và dịch vụ, năm 2025

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Bảng 4.7. Phí CBD ghi nhận trong dữ liệu theo tháng, năm 2025

Tháng	HVFHV (triệu USD)	Taxi vàng (triệu USD)	% chuyến HVFHV bị tính	% chuyến taxi vàng bị tính	Phí TB/chuyến bị tính HVFHV	Phí TB taxi vàng
2025-01	9,00	1,59	34,9	73,8	1,500	0,750
2025-02	9,73	1,82	35,0	74,3	1,500	0,750
2025-03	9,98	2,12	34,0	74,6	1,500	0,750
2025-04	9,85	2,02	34,8	74,3	1,500	0,750
2025-05	10,25	2,23	34,0	73,6	1,500	0,750
2025-06	9,46	2,12	33,3	74,0	1,500	0,750
2025-07	9,35	1,94	33,3	74,7	1,500	0,750
2025-08	8,88	1,75	32,6	74,1	1,500	0,750
2025-09	9,84	2,11	35,5	74,2	1,500	0,750
2025-10	10,72	2,16	35,2	73,9	1,500	0,750
2025-11	10,09	1,98	33,9	73,2	1,500	0,750
2025-12	9,97	2,17	31,6	72,4	1,500	0,750

Nguồn: kết quả tính toán của tác giả.

Cộng cả năm, dữ liệu ghi nhận 117,13 triệu USD phí CBD từ HVFHV và 24,03 triệu USD từ taxi vàng. Phí trung bình trên mỗi chuyến bị tính đúng bằng 1,50 USD với HVFHV và 0,75 USD với taxi vàng ở mọi tháng, khớp với biểu phí của MTA và cho thấy phí được áp dụng liên tục suốt năm 2025. Khoảng 34,0% chuyến HVFHV và

73,9% chuyển taxi vàng bị tính phí, phản ánh việc taxi vàng tập trung ở Manhattan hơn nhiều so với HVFHV.

Cần lưu ý rằng đây là phí ghi nhận trên hóa đơn chuyển đi, không phải số tiền MTA thực thu, vì đồ án không có dữ liệu đối soát giữa các hãng và MTA. Tuy vậy, con số cho thấy quy mô đáng kể của nguồn thu từ riêng hai dịch vụ này.

4.4.2. Cấu trúc luồng giữa các nhóm vùng


Bảng 4.8. Tỷ trọng các luồng chính trong tổng số chuyển HVFHV (14 luồng lớn nhất)

Nhóm đón	Nhóm trả	Tỷ trọng 2024 (%)	Tỷ trọng 2025 (%)	Thay đổi (điểm %)
Quận ngoài	Quận ngoài	48,76	50,93	+2,16
CRZ	CRZ	15,82	14,68	-1,14
CRZ	Quận ngoài	4,81	4,71	-0,10
Quận ngoài	CRZ	4,03	3,97	-0,06
Manhattan phía bắc	Manhattan phía bắc	3,82	3,79	-0,03
Quận ngoài	Sân bay	2,40	2,36	-0,04
Manhattan phía bắc	Quận ngoài	2,36	2,38	+0,01
Quận ngoài	Manhattan phía bắc	2,35	2,36	+0,01
CRZ	Sân bay	2,06	2,10	+0,04
CRZ	Manhattan phía bắc	1,86	1,60	-0,26
Manhattan phía bắc	CRZ	1,80	1,56	-0,24
Sân bay	Quận ngoài	1,51	1,46	-0,05
Vắt ranh giới	CRZ	1,49	1,37	-0,12
CRZ	Vắt ranh giới	1,45	1,35	-0,09

Nguồn: kết quả tính toán của tác giả.

Luồng nội bộ CRZ (CRZ → CRZ) là luồng lớn thứ hai, chiếm 15,82% tổng số chuyển năm 2024 và giảm xuống 14,68% năm 2025, mức giảm lớn nhất trong mọi luồng (-1,14 điểm phần trăm). Luồng giữa CRZ và Manhattan phía bắc theo cả hai chiều cũng giảm. Luồng nội bộ các quận ngoài tăng 2,16 điểm phần trăm. Luồng CRZ ra sân bay gần như không đổi, phù hợp với thực tế là chuyển ra sân bay có giá cao và ít nhạy với một khoản phí nhỏ.

4.4.3. Nhịp theo giờ




Hình 4.8. Số chuyến HVFHV có điểm đầu hoặc điểm cuối trong CRZ, trung bình theo giờ đón

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Số chuyến chạm CRZ giảm ở mọi giờ nhưng không đều. Mức giảm lớn nhất rơi vào khung đêm muộn: giờ 23, 1, 0 giảm lần lượt 10,1%, 9,1%, 9,0%. Khung sáng sớm và giờ đi làm buổi sáng giảm ít nhất (giờ 8, 5, 9: -1,2%, -1,1%, -0,4%). Chuyến đi làm có ít phương án thay thế về thời gian, còn chuyến giải trí buổi tối linh hoạt hơn.

4.4.4. Thị phần hãng



Hình 4.9. Thị phần Uber theo tháng trên toàn thành phố và trong các chuyến chậm CRZ

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Thị phần Uber trung bình năm 2024 là 74,8% và giảm xuống 71,8% trong giai đoạn 03–12/2025, phần còn lại chủ yếu thuộc về Lyft. Sự thay đổi xảy ra từ tháng 03/2025, tức hai tháng sau khi phí có hiệu lực, và diễn ra tương tự ở cả chuyến chậm CRZ lẫn toàn thành phố. Vì vậy khó quy nó cho phí CRZ; khả năng cao hơn là do chiến lược cạnh tranh giữa hai hãng. Đồ án không đưa thay đổi này vào phần kết luận nhân quả, nhưng đây là một ví dụ về các cú sốc đồng thời mà thiết kế đối chứng phải hấp thụ.

4.4.5. Luồng sân bay

Bảng 4.9. Số chuyến HVFHV/ngày của các luồng có đầu sân bay (05/01 – 31/12)

Nhóm đón	Nhóm trả	Chuyến/ngày 2024	Chuyến/ngày 2025	Thay đổi (%)
Sân bay	Sân bay	737	577	-21,65
Sân bay	CRZ	8.028	8.085	+0,71
Sân bay	Vắt ranh giới	805	811	+0,76
Sân bay	Manhattan phía bắc	1.791	1.736	-3,08
Sân bay	Quận ngoài	9.482	9.293	-2,00
CRZ	Sân bay	12.960	13.411	+3,48
Vắt ranh giới	Sân bay	1.432	1.485	+3,66
Manhattan phía bắc	Sân bay	3.030	3.014	-0,52
Quận ngoài	Sân bay	15.078	15.025	-0,35

Nguồn: t58_airport_flows.csv.

Chuyến từ CRZ ra sân bay tăng 3,48% và chuyến từ sân bay vào CRZ tăng 0,71%, trong khi các luồng sân bay với quận ngoài gần như không đổi hoặc giảm nhẹ. Luồng sân bay là loại chuyến dài, giá cao (trên 50 USD giá cước cơ sở), nên khoản phí 1,50 USD chỉ chiếm vài phần trăm chi phí và hành khách ít có phương án thay thế tiện lợi khi mang hành lý. Kết quả này là một phép thử tự nhiên cho lập luận về độ co giãn: nơi phí chiếm tỷ trọng nhỏ, số chuyến gần như không phản ứng.

4.5. Tác động lên số chuyến

4.5.1. Kết quả DiD trên panel vùng × tuần

Bảng 4.10. Tác động lên log số chuyến HVFHV đón theo bốn đặc tả (panel 237 vùng × 103 tuần)

Biến kết quả	TB nhóm xử lý trước	TWFE	DDD mùa vụ	TWFE có trọng số	TWFE + xu hướng nhóm
log số chuyến đón	—	-0,097*** (0,006)	-0,102*** (0,006)	-0,083*** (0,007)	0,010 (0,010)


Ghi chú: hệ số (sai số chuẩn phân cụm theo vùng, 237 cụm); *** $p < 0,01$; ** $p < 0,05$; * $p < 0,1$. Nguồn: *t30_did_main.csv*.

Đặc tả TWFE cho hệ số -0,0972 với sai số chuẩn 0,0062, tương ứng số chuyến đón trong CRZ giảm 9,27% so với phản thực. Khoảng tin cậy 95% là [8,15%; 10,37%] mức giảm. DDD mùa vụ, so sánh mỗi tuần năm 2025 với tuần cùng vị trí năm 2024, cho mức giảm 9,66%, rất gần TWFE. Điều này cho thấy mùa vụ riêng của CRZ không làm lệch ước lượng trung bình cả năm, dù nó ảnh hưởng mạnh đến từng tuần.

Khi có trọng số theo lưu lượng năm 2024, mức giảm còn 7,93%. Mức nhỏ hơn cho thấy các vùng CRZ có lưu lượng lớn giảm ít hơn các vùng CRZ nhỏ về tỷ lệ phần trăm. Ước lượng không trọng số đại diện cho vùng, ước lượng có trọng số đại diện cho chuyến đi.

Đặc tả có xu hướng tuyến tính riêng cho nhóm xử lý cho kết quả khác hẳn: hệ số 0,0104 ($p = 0,309$), tức không có mức giảm. Đặc tả này không nên được đọc là bằng chứng ngược chiều. Như mục 4.13 sẽ cho thấy, khi áp dụng cùng đặc tả cho một ngày chính sách giả trong năm 2024, nó cũng tạo ra các "tác động" lớn và có ý nghĩa thống kê, nghĩa là xu hướng tuyến tính đang hấp thụ mùa vụ chứ không phải xu hướng thực. Với chỉ một năm trước chính sách, không thể tách xu hướng dài hạn khỏi mùa vụ một cách đáng tin.

4.5.2. Nghiên cứu sự kiện theo tuần




Hình 4.10. Nghiên cứu sự kiện theo tuần cho log số chuyển HVFHV đón trong CRZ (chuẩn hóa theo trung bình 52 tuần trước)

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Hình 4.10 trình bày hệ số theo tuần đã chuẩn hóa sao cho trung bình giai đoạn trước bằng 0. Trong giai đoạn trước, các hệ số dao động quanh 0 với biên độ lớn quanh các dịp lễ (độ lệch chuẩn 7,96 điểm log $\times 100$), nhưng không có xu hướng đơn điệu rõ ràng trong phần lớn năm. Kiểm định Wald chung bác bỏ giả thuyết mọi hệ số trước chính sách bằng nhau ($p < 0,001$), điều dễ hiểu với sai số chuẩn rất nhỏ và mùa vụ lễ hội mạnh.

Sau chính sách, trung bình các hệ số tuần là -9,72 điểm log $\times 100$, với 41/51 tuần có khoảng tin cậy nằm hoàn toàn dưới 0. Mức giảm xuất hiện ngay từ các tuần đầu tiên và duy trì suốt năm, không có dấu hiệu mờ dần. Đây là động thái phù hợp với một cú sốc giá cố định.



Hình 4.11. Tác động theo tuần sau khi khử mùa vụ nhóm (DDD): so sánh từng tuần năm 2025 với tuần cùng vị trí năm 2024

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Hình 4.11 cho góc nhìn bổ sung: mỗi điểm là tác động của một tuần năm 2025 khi so với tuần tương ứng năm 2024. Với HVFHV, 51/51 tuần có hệ số âm, trung bình -10,16 điểm log $\times 100$, và 50 tuần có khoảng tin cậy nằm hoàn toàn dưới 0. Đường của HVFHV nằm trong khoảng từ -19,3 đến -1,2 điểm, khá ổn định.

Bảng 4.11. Trung bình hệ số DDD theo tháng của năm 2025 (HVFHV, log số chuyển đón)

Tháng	Số tuần	TB hệ số DDD $\times 100$	% thay đổi tương ứng	Số tuần hệ số âm
2025-01	4	-10,81	-10,25	4
2025-02	4	-9,10	-8,70	4
2025-03	5	-8,63	-8,27	5
2025-04	4	-9,56	-9,12	4
2025-05	4	-10,72	-10,17	4
2025-06	5	-12,59	-11,83	5
2025-07	4	-14,63	-13,61	4
2025-08	5	-11,72	-11,06	5
2025-09	4	-5,61	-5,45	4
2025-10	4	-6,53	-6,32	4
2025-11	5	-9,81	-9,34	5
2025-12	3	-12,11	-11,40	3

Ghi chú: tuần được gán vào tháng của ngày bắt đầu tuần. Nguồn: t31_event_study_weekly_ln_n.csv.

Tổng hợp theo tháng, tác động DDD thấp nhất vào tháng 2025-09 (-5,45%) và mạnh nhất vào tháng 2025-07 (-13,61%). Không tháng nào có tác động trung bình dương. Biến động giữa các tháng phản ánh một phần sai lệch mùa vụ giữa hai năm (ví dụ vị trí của các ngày lễ trong tuần), nên không nên diễn giải từng tháng riêng lẻ.

4.5.3. Tỷ lệ yêu cầu đi chung

Tỷ lệ chuyển có yêu cầu đi chung trong các vùng CRZ trước chính sách là 3,03%. TWFE ước lượng tỷ lệ này giảm 0,489 điểm phần trăm (sai số chuẩn 0,095), DDD cho 0,528 điểm. So với mức nền, đây là mức giảm tương đối khoảng 16,2%, lớn hơn nhiều so với mức giảm tổng số chuyển. Kết quả cùng chiều với Pandey, Guler và Gayah (2026): phí tính theo chuyển chứ không theo hành khách làm chuyển đi chung, vốn có giá thấp, chịu tỷ lệ tăng chi phí lớn hơn.

4.6. Tác động lên tốc độ và thời gian chờ

4.6.1. Kết quả DiD

Bảng 4.12. Tác động lên tốc độ, thời gian chờ và quãng đường/chuyển (HVFHV, vùng × tuần)

Biến kết quả	TB nhóm xử lý trước	TWFE	DDD mùa vụ	TWFE có trọng số	TWFE + xu hướng nhóm
Tốc độ trung bình (dặm/giờ)	12,96	0,406*** (0,020)	0,400*** (0,020)	0,397*** (0,022)	0,750*** (0,052)
Thời gian chờ đón (phút)	4,49	-0,377*** (0,018)	-0,389*** (0,019)	-0,343*** (0,015)	-0,286*** (0,046)
Quãng đường / chuyển (dặm)	4,49	0,143*** (0,008)	0,141*** (0,008)	0,131*** (0,008)	-0,087*** (0,018)


Ghi chú: như Bảng DiD số chuyển. Nguồn: *t30_did_main.csv*.

Tốc độ trung bình của chuyển đón trong CRZ tăng 0,406 dặm/giờ theo TWFE và 0,400 dặm/giờ theo DDD, trên mức nền 12,96 dặm/giờ, tức tăng khoảng 3,1%. Khác với số chuyển, đặc tả có xu hướng nhóm cho mức tăng còn lớn hơn (0,750 dặm/giờ), nên kết luận về tốc độ không phụ thuộc vào cách xử lý xu hướng. Lưu ý tốc độ đo trên chuyển đón trong CRZ bao gồm cả đoạn đường ngoài vùng của các chuyển đi ra ngoài; phần 4.6.3 xem riêng chuyển nội vùng.

Thời gian chờ giảm 0,377 phút theo TWFE và 0,389 phút theo DDD, trên nền 4,49 phút, tức giảm khoảng 8,4%. Kết quả này phù hợp với cơ chế thị trường hai phía đã nêu ở Chương 2: khi nhu cầu trong vùng giảm, xe rảnh nhiều hơn và thời gian ghép cặp ngắn lại. Tốc độ đường phố cao hơn cũng rút ngắn thời gian xe chạy đến điểm đón.

4.6.2. Động thái theo tháng

Nghiên cứu sự kiện theo tháng (HVFHV, vùng $\times$ tuần, mốc: TB 12 tháng 2024)



Hình 4.12. Nghiên cứu sự kiện theo tháng cho sáu chỉ tiêu (HVFHV, panel vùng $\times$ tuần, chuẩn hóa theo trung bình 2024)


Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Hình 4.12 cho thấy hai kiểu động thái khác nhau. Với tốc độ, các hệ số năm 2024 dao động quanh 0 và có một bước nhảy rõ ngay tháng 01/2025; chênh lệch giữa trung bình ba tháng đầu sau và ba tháng cuối trước chính sách là 0,702 dặm/giờ. Với thời gian chờ, bước nhảy là -0,305 phút. Đây là dạng động thái mà một cú sốc chính sách thật sự tạo ra.

Với giá cước/dặm, thu nhập tài xế/dặm và chi phí hành khách/chuyến, hình ảnh hoàn toàn khác: các hệ số tăng đều đặn suốt năm 2024 rồi tiếp tục xu hướng đó sang

năm 2025, không có bước nhảy tại mốc chính sách. Chênh lệch ba tháng sau so với ba tháng trước còn âm (-0,316 USD/dặm với giá cước, -0,836 USD/chuyến với chi phí hành khách), vì quý IV/2024 là giai đoạn giá cao của mùa lễ. Như vậy, khoảng cách giá giữa CRZ và vùng đối chứng đã nới rộng từ trước chính sách. Các hệ số DiD dương cho giá ở mục 4.7 phản ánh chủ yếu xu hướng này.


4.6.3. Tốc độ theo loại luồng và theo giờ



Hình 4.13. Tốc độ trung bình theo tháng của ba loại luồng chuyển HVFHV

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Chuyến nội vùng CRZ có tốc độ trung bình 7,70 dặm/giờ vào tháng 12/2024 và tăng lên 9,15 dặm/giờ vào tháng 01/2025, cao hơn cả tháng 01/2024 (8,91 dặm/giờ). Hai luồng đối chứng không có bước nhảy tương tự. Sau quý I/2025, tốc độ trong CRZ dần trở lại nhịp mùa vụ quen thuộc, giảm vào mùa thu và cuối năm, nhưng vẫn ở mức ngang hoặc cao hơn cùng kỳ năm trước trong phần lớn các tháng.




Hình 4.14. Tốc độ trung bình của chuyến HVFHV nội vùng CRZ theo giờ đón, năm 2024 và 2025

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Theo giờ, tốc độ trung bình cả năm của chuyến nội vùng CRZ tăng nhiều nhất vào buổi chiều và tối (từ 14 đến 18 giờ, mức tăng 0,13 dặm/giờ), là khung giờ đông nhất và chậm nhất. Vào đêm và rạng sáng, khi đường đã thông thoáng, tốc độ gần như không đổi. Mẫu hình này đúng như lý thuyết dự báo: giảm lưu lượng có tác dụng lớn nhất khi đường gần mức bão hòa.

4.6.4. Tốc độ theo giờ và loại ngày



Hình 4.15. Chênh lệch thay đổi tốc độ cùng kỳ theo giờ và loại ngày: luồng CRZ → CRZ trừ luồng quận ngoài → quận ngoài

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Hình 4.15 là một sai khác kép mô tả ở cấp luồng: với mỗi giờ và loại ngày, lấy thay đổi tốc độ cùng kỳ của chuyển nội vùng CRZ trừ đi thay đổi tương ứng của chuyển nội bộ quận ngoài. Vào ngày thường, chênh lệch dương ở hầu hết các giờ, lớn nhất vào tối muộn (giờ 20–23: trung bình 0,35 dặm/giờ) và âm nhẹ vào khung 06–07 giờ. Vào cuối tuần, chênh lệch dương ở mọi giờ, trung bình 0,27 dặm/giờ.

Kết quả cuối tuần ở đây khác với tương tác $D \times$ cuối tuần trên panel vùng $\times$ ngày, vốn cho tốc độ cuối tuần gần như không đổi. Hai phép đo khác nhau về đối tượng: panel vùng $\times$ ngày tính mọi chuyển đón trong CRZ, kể cả chuyển đi ra quận ngoài qua cầu và đường cao tốc, còn hình này chỉ tính chuyển có cả hai đầu trong CRZ. Tốc độ trên đường phố nội vùng cuối tuần có cải thiện, nhưng phần đường ngoài vùng của chuyển đi ra ngoài thì không. Đây là ví dụ cho thấy việc chọn đơn vị đo ảnh hưởng thế nào đến kết luận về không đồng nhất.

4.7. Giá cước, chi phí hành khách và thu nhập tài xế

4.7.1. Kết quả DiD

Bảng 4.13. Tác động lên giá cước, chi phí hành khách và thu nhập tài xế (HVFHV, vùng $\times$ tuần)

Biến kết quả	TB nhóm xử lý trước	TWFE	DDD mùa vụ	TWFE có trọng số	TWFE + xu hướng nhóm
Giá cước cơ sở / dặm (USD)	6,44	0,291*** (0,025)	0,289*** (0,025)	0,301*** (0,028)	-0,371*** (0,029)
Giá cước cơ sở / chuyển (USD)	28,68	2,022*** (0,102)	2,008*** (0,102)	2,054*** (0,107)	-2,470*** (0,190)
Tổng chi phí hành khách / chuyển (USD)	35,84	3,651*** (0,109)	3,635*** (0,109)	3,650*** (0,118)	-1,515*** (0,218)
Phí CBD / chuyển (USD)	0,00	1,375*** (0,009)	1,375*** (0,009)	1,348*** (0,013)	1,373*** (0,009)
Tiền tip / chuyển (USD)	1,53	0,104*** (0,006)	0,104*** (0,006)	0,107*** (0,008)	-0,210*** (0,019)
Thu nhập tài xế / dặm (USD)	4,59	0,040*** (0,009)	0,040*** (0,009)	0,027** (0,011)	-0,394*** (0,021)
Thu nhập tài xế / chuyển (USD)	20,45	0,775*** (0,040)	0,768*** (0,040)	0,719*** (0,043)	-2,239*** (0,125)
Thu nhập tài xế / giá cước (%)	71,53	-2,336*** (0,112)	-2,335*** (0,112)	-2,611*** (0,107)	-1,331*** (0,129)


Ghi chú: như Bảng DiD số chuyển. Nguồn: *t30_did_main.csv*.

Phí CBD/chuyển của các vùng CRZ tăng 1,375 USD, đúng với cơ chế phí: không phải mọi chuyển đón trong CRZ đều bị tính trong mọi tuần (một phần nhỏ chuyển có dữ liệu phí bằng 0), nên mức trung bình thấp hơn 1,50 USD một chút. Tổng chi phí

hành khách/chuyến tăng 3,651 USD theo TWFE, gấp 2,66 lần mức phí. Giá cước cơ sở tăng 2,022 USD/chuyến, thu nhập tài xế tăng 0,775 USD/chuyến, còn tỷ lệ thu nhập tài xế trên giá cước giảm 2,34 điểm phần trăm.

Nếu đọc các con số này như tác động nhân quả, ta sẽ kết luận rằng nền tảng đã tăng giá cước cơ sở trong CRZ cùng lúc với phí, khiến hành khách chịu gần gấp đôi mức phí danh nghĩa, trong khi phần tăng thêm chủ yếu thuộc về nền tảng. Tuy nhiên, kết luận này không đứng vững. Như Hình 4.12 cho thấy, giá cước và chi phí hành khách của CRZ đã tăng nhanh hơn vùng đối chứng trong suốt năm 2024. Khi cho phép xu hướng nhóm, dấu của tác động lên giá cước đảo ngược (-2,470 USD/chuyến). Phép thử giả được ở mục 4.13 còn cho thấy một "tác động" giả vào tháng 07/2024 có độ lớn tương đương. Vì vậy, đồ án không kết luận về tác động của phí lên giá cước cơ sở và thu nhập tài xế.

4.7.2. Phân phối chi phí hành khách




Hình 4.16. Phân phối tổng chi phí hành khách/chuyến từ mẫu 0,25% chuyến HVFHV, theo năm và loại chuyến


Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Trên mẫu 1.145.311 chuyến, trung vị chi phí của chuyến chạm CRZ tăng từ 31,51 lên 34,47 USD, phân vị 90 tăng từ 70,76 lên 78,14 USD. Với chuyến không chạm CRZ, trung vị gần như không đổi (18,28 và 17,97 USD). Toàn bộ phân phối của chuyến chạm CRZ dịch sang phải nhiều hơn mức phí, nhất quán với bảng DiD, nhưng như đã phân tích, phần vượt mức phí không thể tách khỏi xu hướng có sẵn.

4.7.3. Diễn biến giá theo tháng




Hình 4.17. Giá cước cơ sở trên mỗi dặm theo tháng, chuyến chạm CRZ và không chạm CRZ
Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.



Hình 4.18. Thu nhập tài xế trên mỗi dặm theo tháng, chuyến chạm CRZ và không chạm CRZ
Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.


Hai hình trên xác nhận trực quan kết luận của mục 4.7.1. Giá cước/dặm của chuyến chạm CRZ có xu hướng tăng và mùa vụ mạnh, với đỉnh vào tháng 12 của cả hai năm. Thu nhập tài xế/dặm của cả hai loại chuyến đi cùng nhau trong phần lớn thời gian, phản ánh công thức thu nhập tối thiểu do TLC quy định áp dụng chung cho mọi

chuyển. Không có bước nhảy nào tại tháng 01/2025 đủ lớn để tách khỏi dao động mùa vụ.



Hình 4.19. Thời gian chờ từ lúc gọi xe đến lúc đón theo tháng, chuyến chậm CRZ và không chậm CRZ

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.




Hình 4.20. Tỷ lệ thu nhập tài xế trên giá cước cơ sở theo tháng

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

4.7.4. Thành phần quãng đường chuyển

Phân bố quãng đường chuyển HVFHV (mẫu 0,25%), 05/01-31/12



Hình 4.21. Phân bố quãng đường chuyển HVFHV theo loại chuyển và năm (mẫu 0,25%, 05/01 – 31/12)

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Một lo ngại khi so sánh giá và tốc độ trung bình là thành phần chuyển thay đổi: nếu chuyển ngắn giảm mạnh hơn, giá trung bình mỗi chuyến tăng và tốc độ trung bình thay đổi mà không phản ánh thay đổi trên từng loại chuyển. Hình 4.21 cho thấy thành phần quãng đường của chuyến chạm CRZ thay đổi rất ít: tỷ trọng chuyến dưới 1 dặm từ 8,26% lên 8,41%, chuyến 5–10 dặm từ 21,91% lên 22,07%. Thay đổi thành phần vì vậy không đủ lớn để giải thích mức tăng giá cước/chuyến hay tốc độ. Điều này củng cố kết luận rằng mức tăng tốc độ là thay đổi thực trên đường, còn mức tăng giá chủ yếu đến từ xu hướng giá có sẵn chứ không phải từ dịch chuyển thành phần.

4.8. Phân tích trên panel cặp điểm đón – điểm trả

4.8.1. Tác động theo loại luồng

Bảng 4.14. Tác động theo loại luồng trên panel cặp OD × tháng


Biến kết quả	Tất cả chuyến chạm CRZ	CRZ → CRZ	CRZ → ngoài	ngoài → CRZ
log số chuyến	-0,105*** (0,006)	-0,117*** (0,006)	-0,096*** (0,007)	-0,099*** (0,012)
Tốc độ (dặm/giờ)	0,307*** (0,019)	0,205*** (0,017)	0,340*** (0,021)	0,405*** (0,037)
Tỷ lệ đi chung (%)	-0,920*** (0,071)	-0,787*** (0,095)	-0,937*** (0,099)	-1,079*** (0,100)
Giá cước/chuyến	1,216*** (0,076)	1,507*** (0,107)	1,041*** (0,101)	1,032*** (0,090)
TN tài xế/chuyến	0,264*** (0,035)	0,070 (0,044)	0,442*** (0,041)	0,315*** (0,059)
Chi phí hành khách/chuyến	2,833*** (0,082)	3,148*** (0,117)	2,646*** (0,114)	2,629*** (0,098)
Phí CBD/chuyến	1,454*** (0,005)	1,463*** (0,004)	1,451*** (0,006)	1,446*** (0,006)

Ghi chú: hiệu ứng cố định cặp và tháng; sai số chuẩn phân cụm theo vùng đón. Nhóm đối chứng là các cặp không chạm CRZ. Nguồn: t35_did_od_pairs.csv.

Trên panel cặp OD, số chuyển của các cặp chạm CRZ giảm 9,97% so với các cặp không chạm, gần với ước lượng trên panel vùng $\times$ tuần. Mức giảm lớn nhất thuộc luồng nội vùng CRZ $\rightarrow$ CRZ (11,06%), tiếp theo là ngoài $\rightarrow$ CRZ (9,41%) và CRZ $\rightarrow$ ngoài (9,18%). Luồng nội vùng gồm các chuyển ngắn, giá thấp, nên khoản phí 1,50 USD chiếm tỷ lệ lớn nhất trong chi phí chuyển đi; các chuyển này cũng dễ được thay bằng đi bộ, xe đạp hoặc tàu điện ngầm.

Tốc độ tăng ở mọi loại luồng, nhưng tăng ít nhất ở luồng nội vùng (0,205 dặm/giờ) và nhiều hơn ở luồng CRZ $\rightarrow$ ngoài (0,340 dặm/giờ). Một cách giải thích là chuyển đi ra ngoài có phần lớn quãng đường trên các trục chính và cầu, nơi lưu lượng xe con cá nhân giảm mạnh nhờ phí ngày, còn chuyển nội vùng chịu nhiều ảnh hưởng của đèn tín hiệu và người đi bộ, vốn không đổi.

4.8.2. Nghiên cứu sự kiện theo tháng trên panel OD



Hình 4.22. Nghiên cứu sự kiện theo tháng trên panel cặp OD: log số chuyển của cặp chạm CRZ so với cặp không chạm

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Các hệ số năm 2024 dao động trong khoảng -3,6 đến 4,4 điểm log $\times 100$ quanh mức trung bình. Từ tháng 01/2025, các hệ số chuyển sang âm và có xu hướng sâu thêm theo thời gian, đạt -22,3 điểm ở tháng thấp nhất. Mức giảm sâu dần có thể phản ánh việc hành khách điều chỉnh thói quen từ từ, nhưng cũng có thể một phần là do xu hướng giảm có sẵn của các cặp chạm CRZ; với một năm dữ liệu trước chính sách, hai giải thích này không tách được hoàn toàn.

4.9. Tác động không đồng nhất theo thời gian trong ngày và trong tuần


4.9.1. Theo khung giờ

Bảng 4.15. Tác động DiD theo khung giờ đón (panel vùng × khung giờ × tháng)

Khung giờ	log số chuyển	Tốc độ	Thời gian chờ	Giá cước/dặm	Tốc độ nền
00–05	-0,113*** (0,011)	0,339*** (0,052)	-0,413*** (0,034)	0,305*** (0,024)	18,52
06–09	-0,071*** (0,007)	0,067* (0,036)	-0,336*** (0,019)	0,283*** (0,024)	15,06
10–15	-0,093*** (0,006)	0,427*** (0,029)	-0,268*** (0,020)	0,298*** (0,028)	11,83
16–19	-0,098*** (0,007)	0,489*** (0,025)	-0,429*** (0,025)	0,265*** (0,030)	10,59
20–23	-0,112*** (0,008)	0,513*** (0,028)	-0,496*** (0,022)	0,285*** (0,030)	12,95

Ghi chú: hiệu ứng cố định vùng và tháng, ước lượng riêng từng khung giờ; phân cụm theo vùng. Nguồn: t33.

Tác động DiD theo khung giờ (HVFHV, vùng×khung giờ×tháng)



Hình 4.23. Tác động DiD theo khung giờ đón lên log số chuyển và tốc độ

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Số chuyển giảm ít nhất vào khung 06–09 giờ (6,89%) và nhiều nhất vào khung 00–05 giờ (10,71%) và 20–23 giờ (10,58%). Kết quả khớp với phân tích mô tả ở mục 4.4.3: chuyển đi làm buổi sáng ít co giãn, chuyển buổi tối và đêm khuya linh hoạt hơn.

Tốc độ tăng mạnh nhất vào buổi chiều và tối (16–19 giờ: 0,489; 20–23 giờ: 0,513 dặm/giờ) và gần như không tăng vào khung 06–09 giờ (0,067 dặm/giờ, $p = 0,064$). Giờ cao điểm buổi sáng có dòng xe chủ yếu là xe đi làm và xe giao hàng, ít phản ứng với phí; còn chiều tối là lúc giảm lưu lượng tạo ra khác biệt lớn nhất về tốc độ.

4.9.2. Ngày thường và cuối tuần


Bảng 4.16. Tác động theo ngày thường và cuối tuần (panel vùng × ngày)

Biến kết quả	D (ngày thường)	D × cuối tuần	Tổng cuối tuần
log số chuyển	-0,109*** (0,015)	0,037 (0,040)	-0,072
Tốc độ (dặm/giờ)	0,637*** (0,035)	-0,820*** (0,090)	-0,182
Thời gian chờ (phút)	-0,331*** (0,024)	-0,126** (0,055)	-0,456
Giá cước/dặm	0,350*** (0,038)	-0,208*** (0,066)	0,143

Ghi chú: hiệu ứng cố định vùng và ngày; phân cụm theo vùng. Nguồn: t34_heterogeneity_weekend.csv.

Mức giảm số chuyển không khác biệt có ý nghĩa giữa ngày thường và cuối tuần. Tốc độ tăng 0,637 dặm/giờ vào ngày thường, nhưng tương tác với cuối tuần là -0,820, nên vào cuối tuần tốc độ gần như không đổi hoặc giảm nhẹ. Một cách giải thích là đường phố cuối tuần vốn ít bảo hòa hơn, nên giảm lưu lượng ít cải thiện tốc độ; ngoài ra thành phần phương tiện vào vùng cuối tuần (khách du lịch, mua sắm) có thể ít nhạy với phí hơn ngày thường.

4.10. Kiểm soát tổng hợp



Hình 4.24. Kiểm soát tổng hợp: chỉ số số chuyển HVFHV đón trong CRZ thực tế và tổng hợp, cùng khoảng cách giữa hai chuỗi

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.


Bảng 4.17. Các vùng có trọng số dương trong CRZ tổng hợp

Mã vùng	Tên vùng	Quận	Nhóm	Trọng số
112	Greenpoint	Brooklyn	Quận ngoài	0,319
236	Upper East Side North	Manhattan	Manhattan phía bắc	0,193
106	Gowanus	Brooklyn	Quận ngoài	0,141
52	Cobble Hill	Brooklyn	Quận ngoài	0,071
166	Morningside Heights	Manhattan	Manhattan phía bắc	0,069
33	Brooklyn Heights	Brooklyn	Quận ngoài	0,068
263	Yorkville West	Manhattan	Manhattan phía bắc	0,055
255	Williamsburg (North Side)	Brooklyn	Quận ngoài	0,039
202	Roosevelt Island	Manhattan	Manhattan phía bắc	0,029
93	Flushing Meadows-Corona Park	Queens	Quận ngoài	0,008
217	South Williamsburg	Brooklyn	Quận ngoài	0,008

Nguồn: kết quả tính toán của tác giả.


Tối ưu hóa chọn 11 vùng đối chứng với trọng số dương, trong đó năm vùng có trọng số lớn nhất là Greenpoint, Upper East Side North, Gowanus, Cobble Hill, Morningside Heights (79,3% tổng trọng số). Đây là các vùng đô thị đậm đặc có nhịp mùa vụ gần CRZ nhất. RMSPE giai đoạn trước là 0,0265 (trên thang chỉ số bằng 1), tức sai số khớp khoảng 2,6%.

Sau chính sách, chuỗi CRZ thực tế nằm dưới chuỗi tổng hợp trong phần lớn các tuần. Khoảng cách trung bình là -0,0671, tương ứng mức giảm trung bình 6,50% so với phản thực. RMSPE sau chính sách tăng lên 0,0788, tỷ số sau/trước là 2,97. Khoảng cách có xu hướng rộng dần vào cuối năm 2025. Phiên bản khử trung bình cho kết quả trùng khớp, vì sau khi chuẩn hóa mỗi chuỗi theo trung bình năm 2024, thành phần mức đã bằng nhau giữa chuỗi xử lý và mọi vùng đối chứng.



Hình 4.25. Giả được theo không gian: khoảng cách SCM của CRZ so với của 60 vùng đối chứng lớn nhất

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.



Hình 4.26. Phân phối tỷ số RMSPE sau/trước của các vùng giả được và vị trí của CRZ


Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Kiểm định giả được không gian cho hai kết luận khác nhau tùy thống kê được dùng. Theo tỷ số RMSPE sau/trước, CRZ đứng ở mức giá trị $p = 0,180$, tức 10/60 vùng giả được có tỷ số cao hơn. Theo độ lớn khoảng cách trung bình sau chính sách, giá trị p là 0,016: không vùng giả được nào có khoảng cách trung bình lớn bằng CRZ.

Sự khác biệt đến từ bản chất của hai thống kê. Tỷ số RMSPE nhạy với độ khớp trước chính sách: một vùng nhỏ khớp rất tốt (RMSPE trước nhỏ) chỉ cần lệch vừa phải cũng có tỷ số cao. Ba vùng có tỷ số cao nhất là Jamaica, Mott Haven/Port Morris, East New York, với khoảng cách sau chính sách lần lượt 0,036, 0,041, 0,019; nhiều vùng trong nhóm tỷ số cao có khoảng cách dương, tức tăng trưởng nhanh hơn phản thực. Khoảng cách trung bình mới là đại lượng trực tiếp của câu hỏi "CRZ có giảm nhiều hơn mức ngẫu nhiên không". Theo thống kê này, kết quả SCM có ý nghĩa ở mức 5%.

4.11. Học máy nhân quả và tác động không đồng nhất

4.11.1. Kiểm tra chồng lấn



Hình 4.27. Phân phối điểm xu hướng cross-fitted của cặp OD chạm và không chạm CRZ (bộ biến rút gọn)

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Kiểm tra chồng lấn là bước đầu tiên và cho kết quả quan trọng. Với bộ biến đầy đủ (18 đặc trưng, gồm quận và tốc độ, giá/dặm năm 2024), mô hình xu hướng phân tách hai nhóm gần như hoàn hảo: AUC = 0,9959, chỉ 12,0% cặp OD (1.114 cặp) có $\hat{e}(X)$ trong khoảng $[0,05; 0,95]$. Nói cách khác, với đặc trưng vị trí, ta luôn đoán đúng một cặp có chạm CRZ hay không, và không còn đơn vị đối chứng tương đồng để so sánh.

Với bộ biến rút gọn (7 đặc trưng chuyển đi, không có thông tin vị trí trực tiếp), AUC giảm xuống 0,9496 và 49,9% cặp (4.630 cặp, trong đó 2.722 cặp chạm CRZ)

nằm trong vùng chồng lấn. Đồ án dùng bộ rút gọn làm đặc tả chính và ghi rõ rằng ước lượng đại diện cho tổng thể cặp OD trong vùng chồng lấn, không phải cho mọi cặp OD.

4.11.2. Tác động trung bình

Bảng 4.18. Ước lượng DML (PLR) và AIPW theo hai bộ biến kiểm soát

Bộ biến	Kết quả	AUC xu hướng	Số cặp chồng lấn	PLR θ (SE)	AIPW ATE (SE)
rút gọn	Δ log số chuyển ($\times 100$)	0,950	4.630	-8,384 (0,289)	-8,784 (0,310)
rút gọn	Δ tốc độ (dặm/giờ)	0,950	4.630	0,347 (0,011)	0,339 (0,013)
rút gọn	Δ thu nhập tài xế/dặm	0,950	4.630	-0,040 (0,003)	-0,036 (0,004)
đầy đủ	Δ log số chuyển ($\times 100$)	0,996	1.114	-4,108 (0,513)	-3,536 (0,554)
đầy đủ	Δ tốc độ (dặm/giờ)	0,996	1.114	0,387 (0,029)	0,430 (0,036)
đầy đủ	Δ thu nhập tài xế/dặm	0,996	1.114	-0,048 (0,007)	-0,053 (0,007)

Ghi chú: LightGBM, cross-fitting 5 phần; AIPW trên vùng $\hat{e}(X) \in [0,05; 0,95]$. Nguồn: t41b.

Với bộ rút gọn, PLR cho $\theta = -8,38$ và AIPW cho ATE = -8,78 điểm log $\times 100$, tức số chuyển của cặp chạm CRZ giảm khoảng 8,4% so với phản thực cùng kỳ. Chênh lệch thô (không kiểm soát) là -10,49. Như vậy, việc kiểm soát đặc trưng chuyển đi thu hẹp khoảng cách một phần nhưng mức giảm vẫn rõ rệt và nằm trong khoảng của các ước lượng DiD. Với bộ đầy đủ, ước lượng nhỏ hơn (-3,54), nhưng ước lượng này chỉ dựa trên 1.114 cặp OD đặc biệt có đặc trưng vị trí trung gian, nên không đại diện.

Với tốc độ, cả hai bộ biến đều cho mức tăng trong khoảng 0,34 đến 0,43 dặm/giờ, rất gần kết quả DiD. Với thu nhập tài xế/dặm, DML cho giá trị âm nhỏ (-0,036 USD/dặm), trái dấu với DiD vùng $\times$ tuần. Sự không nhất quán về dấu này là thêm một lý do để không kết luận về thu nhập tài xế.

4.11.3. Kiểm định không đồng nhất: BLP và GATES


Bảng 4.19. Kiểm định BLP cho tác động không đồng nhất

Kết quả	β_1 (ATE)	β_2 (không đồng nhất)	t của β_2
Δ log số chuyển	-0,0878 (0,0031)	0,655 (0,070)	9,33
Δ tốc độ	0,3387 (0,0131)	0,613 (0,075)	8,20
Δ thu nhập/dặm	-0,0360 (0,0038)	0,666 (0,086)	7,76

Ghi chú: sai số chuẩn vừng phương sai thay đổi (HCO). Nguồn: t42_dml_blp.csv.

Hệ số β_2 của cả ba kết quả đều dương và có t-thống kê lớn (từ 7,8 đến 9,3), nghĩa là CATE ước lượng mang tín hiệu thật về sự khác biệt tác động giữa các cặp OD, không chỉ là nhiễu. Giá trị β_2 nhỏ hơn 1 (khoảng 0,64) cho thấy CATE ước lượng có phương sai lớn hơn phương sai thật và cần được co về trung bình khi diễn giải.

GATES: tác động trung bình theo nhóm ngũ phân vị của CATE ước lượng



Hình 4.28. GATES: tác động trung bình theo nhóm ngũ phân vị của CATE ước lượng

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

GATES cho log số chuyến trải từ -13,97 ở nhóm thấp nhất đến -5,24 ở nhóm cao nhất ($\times 100$), mọi nhóm đều âm. Với tốc độ, tác động trải từ 0,157 đến 0,475 dặm/giờ, mọi nhóm đều dương. Không có nhóm nào có tác động ngược dấu, nên không đồng nhất ở đây là khác biệt về độ lớn chứ không phải về chiều.


4.11.4. Đặc trưng của nhóm chịu tác động mạnh

Bảng 4.20. CLAN: đặc trưng trung bình của nhóm có tác động lên số chuyến mạnh nhất và yếu nhất

Đặc trưng	Nhóm giảm mạnh nhất (G1)	Nhóm giảm ít nhất (G5)
Quãng đường/chuyến (dặm)	4,824	5,426
Thời lượng/chuyến (phút)	19,340	25,393
Tốc độ 2024	14,152	12,376
Giá cước/dặm 2024	5,801	6,173
log lưu lượng 2024	9,250	9,079
Tỷ trọng Uber	0,735	0,714
Tỷ trọng chuyến đêm	0,237	0,377
Tỷ lệ chạm CRZ	0,365	0,680

Nguồn: kết quả tính toán của tác giả.


Nhóm có mức giảm số chuyến mạnh nhất (G1, theo τ thấp nhất) có tốc độ năm 2024 cao hơn (14,15 so với 12,38 dặm/giờ), thời lượng chuyến ngắn hơn (19,3 so với 25,4 phút) và ít chuyến đêm hơn. Nhóm giảm ít nhất (G5) có tỷ lệ chuyến đêm cao hơn và thời lượng dài hơn. Điểm đáng chú ý là tỷ lệ cặp chạm CRZ ở G5 (0,68) cao hơn G1 (0,37): CATE được ước lượng cho mọi cặp, kể cả cặp đối chứng, nên G1 bao gồm nhiều cặp không chạm CRZ có đặc trưng khiến chúng sẽ rất nhạy nếu bị tính phí.



Hình 4.29. CATE ước lượng theo quãng đường trung bình của cặp OD chạm CRZ

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Theo quãng đường, CATE trung bình của cặp chạm CRZ là -9,63 ở nhóm chuyển ngắn nhất (trung bình 1,38 dặm) và -6,80 ở nhóm dài nhất (9,07 dặm). Chuyển ngắn nhạy hơn, khớp với lập luận tỷ lệ phí trên chi phí chuyển đi ở Chương 2, dù độ dốc không lớn.




Hình 4.30. Tỷ trọng đóng góp (gain) của các đặc trưng trong mô hình CATE cho Δ log số chuyển

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Trong mô hình CATE, tiền tip trung bình (24,8% gain), quãng đường (20,3%) và log lưu lượng (17,4%) là ba đặc trưng đóng góp nhiều nhất. Tiền tip trung bình có thể đóng vai trò đại diện cho mức thu nhập của hành khách và loại chuyến đi (công tác, giải trí). Chỉ số gain chỉ phản ánh mức độ mô hình sử dụng đặc trưng, không phải quan hệ nhân quả của đặc trưng đó.

4.11.5. Tác động riêng theo từng vùng CRZ




Hình 4.31. Tác động DiD riêng của từng vùng CRZ lên số chuyến đón (%)

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Thay vì một hệ số chung, có thể ước lượng một hệ số riêng cho mỗi vùng CRZ bằng tương tác $D \times \text{vùng}$ trong cùng mô hình TWFE. Kết quả rất đồng nhất về chiều: cả 37/37 vùng có hệ số âm, và 37 vùng có khoảng tin cậy 95% nằm hoàn toàn dưới 0. Tốc độ tăng ở 37/37 vùng. Mức giảm số chuyến trải từ 4,3% (Hudson Sq) đến 14,7% (Alphabet City).

Hình 4.31 cho thấy bốn vùng giảm mạnh nhất là Alphabet City, Stuy Town/Peter Cooper Village, East Village, Gramercy, phần lớn là khu dân cư ở phía đông nam Manhattan. Bốn vùng giảm nhẹ nhất là Union Sq, Midtown East, Midtown Center, Hudson Sq, phần lớn là khu văn phòng và đầu mối giao thông, nơi nhu cầu đi lại ít linh hoạt hơn.

Tác động theo vùng CRZ và đặc trưng vùng



Hình 4.32. Tác động theo vùng CRZ so với quy mô vùng và độ sâu bên trong CRZ

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Bảng 4.21. Hồi quy tác động theo vùng lên đặc trưng vùng (37 vùng CRZ; $R^2 = 0,535$ và $0,356$)


Biến giải thích	Tác động lên log số chuyến	Tác động lên tốc độ
Hằng số	-0,3534*** (0,1142)	0,9807*** (0,3795)
log chuyến/ngày 2024	0,0076 (0,0104)	-0,0669** (0,0341)
% chuyến có đích trong CRZ	-0,0000 (0,0007)	0,0038 (0,0028)
Độ sâu trong CRZ (km)	-0,0090 (0,0108)	0,0689** (0,0331)
Giá cước/chuyến 2024 (USD)	0,0070*** (0,0010)	-0,0104** (0,0044)

Ghi chú: WLS với trọng số nghịch đảo phương sai của hệ số vùng; sai số chuẩn HC1. Nguồn: t55.

Hồi quy tác động theo vùng lên đặc trưng vùng cho thấy biến giải thích mạnh nhất cho mức giảm số chuyến là giá cước trung bình năm 2024: vùng có giá cước/chuyến cao hơn 1 USD giảm ít hơn 0,70 điểm log $\times 100$ ($p = < 0,001$). Kết quả này nhất quán với lập luận tỷ lệ phí trên giá: nơi chuyển đi đắt, phí cố định 1,50 USD là một tỷ lệ nhỏ. Quy mô vùng và độ sâu bên trong CRZ không giải thích được mức giảm số chuyến. Với tốc độ, vùng càng sâu bên trong CRZ tăng tốc độ càng nhiều (0,069 dặm/giờ mỗi km, $p = 0,037$), phù hợp với việc lưu lượng giảm mạnh nhất ở lõi vùng thu phí.

4.12. Hiệu ứng lan tỏa không gian

4.12.1. Lan tỏa theo dải khoảng cách



Hình 4.33. Tác động theo dải khoảng cách tới ranh giới CRZ, phía điểm đón và phía điểm trả (so với vùng cách trên 10 km)

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Bảng 4.22. Tác động theo dải khoảng cách tới CRZ (log số chuyến, so với vùng cách trên 10 km)

Dải	Số vùng	Chuyến đón	Chuyến trả	Trả, khách từ ngoài CRZ	Trả, khách từ CRZ
CRZ	37	-0,115*** (0,006)	-0,112*** (0,007)	-0,097*** (0,008)	-0,030*** (0,009)
Vết ranh giới	6	-0,095*** (0,012)	-0,078*** (0,012)	-0,056*** (0,014)	-0,020 (0,016)
0-1 km	12	-0,040** (0,017)	-0,035* (0,021)	-0,037* (0,020)	0,056** (0,027)
1-2,5 km	17	-0,064*** (0,011)	-0,053*** (0,011)	-0,044*** (0,009)	0,005 (0,016)
2,5-5 km	25	-0,035*** (0,013)	-0,032*** (0,010)	-0,027*** (0,009)	0,005 (0,021)
5-10 km	57	-0,018*** (0,005)	-0,010 (0,006)	-0,008 (0,006)	-0,020* (0,011)

Ghi chú: panel vùng $\times$ tuần, hiệu ứng cố định vùng và tuần; phân cụm theo vùng. Nguồn: *t48_spillover_bands.csv*.

So với các vùng cách CRZ trên 10 km, số chuyến đón trong CRZ giảm 10,83%. Mức giảm lan ra ngoài ranh giới và nhỏ dần theo khoảng cách: dải 0-1 km giảm 3,95%, dải 1-2,5 km giảm 6,20%, dải 2,5-5 km giảm 3,46% và dải 5-10 km giảm 1,77%. Các vùng vết ranh giới giảm gần bằng CRZ. Phía điểm trả có mẫu hình tương tự.

Mẫu hình giảm dần theo khoảng cách có hai hàm ý. Thứ nhất, một phần lớn chuyến đi của các vùng lân cận có đầu kia trong CRZ, nên chúng cũng chịu phí; đây là lan tỏa qua mạng lưới chuyến đi chứ không phải hiệu ứng riêng của vùng. Thứ hai,

dùng các vùng Manhattan phía bắc làm nhóm đối chứng sẽ đánh giá thấp tác động vì chính nhóm này bị ảnh hưởng; mục 4.14 xác nhận điều này.

Kết quả đáng chú ý nhất là cột cuối: số chuyển từ CRZ trả khách ở dải 0–1 km ngoài ranh giới tăng 5,75% ($p = 0,041$), trong khi số chuyển từ CRZ trả khách trong CRZ giảm. Nhìn từ phía hành khách, chuyển CRZ → CRZ bị tính phí giống chuyển CRZ → ngoài, nên động cơ né phí không nằm ở đây. Một cách giải thích hợp lý hơn là một phần hành khách chọn đích đến ngay bên ngoài ranh giới khi có lựa chọn tương đương, hoặc các chuyển nội vùng dài được thay bằng chuyển kết thúc ở vùng lân cận. Bảng chứng này gợi ý nhưng chưa đủ để kết luận về hành vi né phí có chủ đích.

4.12.2. Lan tỏa theo quận

Bảng 4.23. Tác động lên các vùng ngoài CRZ cách ranh giới không quá 5 km, theo quận (so với các vùng xa hơn)

Quận	Số vùng trong 5 km	Hệ số log số chuyển đón	% thay đổi
Manhattan	19	-0,0827*** (0,0155)	-7,94
Brooklyn	28	-0,0371*** (0,0075)	-3,64
Queens	13	0,0006 (0,0117)	0,06

Nguồn: *t56_spillover_by_borough.csv*.


Lan tỏa không đều giữa các quận. Các vùng Manhattan ngoài CRZ trong bán kính 5 km giảm 7,94%, các vùng Brooklyn gần CRZ giảm 3,64%, còn các vùng Queens gần CRZ không thay đổi có ý nghĩa (0,06%, $p = 0,959$). Một giải thích khả dĩ là mức độ gắn kết của chuyển đi với khu trung tâm khác nhau giữa các quận, nhưng đồ án chưa kiểm tra trực tiếp giả thuyết này. Không có vùng Bronx nào nằm trong bán kính 5 km.

4.13. Taxi vàng

Bảng 4.24. Tác động lên taxi vàng (đối chứng: Manhattan phía bắc; panel vùng × tuần)

Biến kết quả	TB nhóm xử lý trước	TWFE	DDD mùa vụ	TWFE có trọng số	TWFE + xu hướng nhóm
log số chuyến đón	—	-0,250** (0,101)	-0,248** (0,102)	-0,005 (0,029)	-0,153*** (0,050)
Giá cước cơ sở / dặm (USD)	6,43	0,240*** (0,049)	0,240*** (0,050)	0,115** (0,046)	-0,383*** (0,049)
Giá cước cơ sở / chuyến (USD)	17,82	-0,689*** (0,178)	-0,668*** (0,181)	-0,434*** (0,109)	-1,382*** (0,145)
Tổng tiền thanh toán trừ tip / chuyến (USD)	20,70	-0,288 (0,179)	-0,265 (0,183)	-0,012 (0,090)	-0,870*** (0,146)
Phí CBD / chuyến (USD)	0,00	0,524*** (0,009)	0,524*** (0,009)	0,502*** (0,012)	0,549*** (0,010)
Tốc độ trung bình (dặm/giờ)	10,53	-0,427*** (0,149)	-0,424*** (0,149)	-0,033 (0,072)	0,402*** (0,126)
Quãng đường / chuyến (dặm)	2,83	-0,328*** (0,063)	-0,325*** (0,064)	-0,134*** (0,043)	-0,009 (0,046)

Ghi chú: như Bảng DiD số chuyển. Nguồn: t30_did_main.csv.



Hình 4.34. Nghiên cứu sự kiện theo tuần cho log số chuyến taxi vàng đón trong CRZ

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Kết quả của taxi vàng kém ổn định hơn nhiều so với HVFHV. Với nhóm đối chứng là Manhattan phía bắc, TWFE không trọng số cho hệ số -0,250 ($p = 0,017$), nhưng TWFE có trọng số theo lưu lượng cho -0,0051 ($p = 0,863$), tức gần như không có tác động tính theo chuyến. Ước lượng không trọng số bị chi phối bởi một số vùng CRZ nhỏ có số chuyến taxi dao động mạnh. Khi gộp cả quận ngoài vào nhóm đối chứng, hệ số không trọng số là -0,671 và có trọng số là -0,085; con số không trọng số

rất lớn phản ánh sự bùng nổ số chuyến taxi vàng ở các quận ngoài đã nói ở mục 4.2.2, không phải tác động của phí.

Diễn giải thận trọng nhất là số chuyến taxi vàng trong CRZ không giảm tương ứng với HVFHV. Kết hợp với chỉ số mô tả ở Hình 4.6, điều này phù hợp với giả thuyết một phần hành khách chuyển từ gọi xe sang taxi, loại phương tiện chịu phí thấp bằng một nửa và có thể đón ngay trên đường phố. Tốc độ taxi vàng có hệ số -0,427 ($p = 0,006$) trong đặc tả không trọng số nhưng không có ý nghĩa trong đặc tả có trọng số; đồ án không đưa ra kết luận về tốc độ từ dữ liệu taxi vàng.

4.14. Kiểm định độ tin cậy

4.14.1. Giả được theo thời gian

Bảng 4.25. Giả được theo thời gian trên panel vùng $\times$ tuần (chính sách giả 07/07/2024, chỉ dữ liệu 2024)

Biến	Giả được 07/2024	Giả được + xu hướng	Thật 01/2025	Thật + xu hướng
log số chuyến	-0,037*** (0,006)	0,093*** (0,007)	-0,097*** (0,006)	0,010 (0,010)
Giá cước/dặm	0,309*** (0,019)	-0,121*** (0,019)	0,291*** (0,025)	-0,371*** (0,029)
TN tài xế/dặm	0,168*** (0,009)	-0,074*** (0,011)	0,040*** (0,009)	-0,394*** (0,021)
Giá cước/chuyến	1,719*** (0,105)	-1,973*** (0,106)	2,022*** (0,102)	-2,470*** (0,190)
TN tài xế/chuyến	0,968*** (0,060)	-1,372*** (0,073)	0,775*** (0,040)	-2,239*** (0,125)
Chi phí hành khách/chuyến	1,950*** (0,117)	-2,334*** (0,125)	3,651*** (0,109)	-1,515*** (0,218)
Tốc độ	-0,136*** (0,022)	-0,448*** (0,042)	0,406*** (0,020)	0,750*** (0,052)
Thời gian chờ	-0,001 (0,026)	-0,098*** (0,031)	-0,377*** (0,018)	-0,286*** (0,046)
Dặm/chuyến	0,041*** (0,009)	-0,239*** (0,015)	0,143*** (0,008)	-0,087*** (0,018)

Ghi chú: TWFE, phân cụm theo vùng. Nguồn: *t49_placebo_time.csv*.

Phép thử giả được đặt ra câu hỏi: nếu áp dụng đúng quy trình ước lượng cho một ngày không có chính sách, ta có tìm thấy "tác động" không? Kết quả phân loại các biến thành hai nhóm rõ rệt.

Nhóm thứ nhất gồm tốc độ và thời gian chờ. Giả được cho tốc độ là -0,136, ngược dấu với tác động thật (0,406). Giả được cho thời gian chờ là -0,001 ($p = 0,977$), gần bằng 0, trong khi tác động thật là -0,377. Hai kết quả về điều kiện di chuyển vì vậy vượt qua phép thử.

Nhóm thứ hai gồm giá cước, thu nhập tài xế và chi phí hành khách. Giả được cho giá cước/chuyến là 1,719 USD, có ý nghĩa thống kê và cùng độ lớn với tác động thật (2,022 USD). Tình hình tương tự với thu nhập tài xế và giá/dặm. Khi thêm xu hướng

nhóm, các hệ số giả được đối dấu và vẫn có ý nghĩa. Như vậy, các biến giá có cả xu hướng lẫn mùa vụ riêng giữa CRZ và vùng đối chứng, đủ để tạo ra "tác động" giả với mọi đặc tả thử nghiệm. Đây là cơ sở để đồ án không diễn giải nhân quả các hệ số về giá.

Với số chuyển, giả được cho hệ số -0,037, tức CRZ đã tăng chậm hơn đối chứng khoảng 3,6% giữa nửa đầu và nửa cuối năm 2024. Con số này nhỏ hơn nhiều so với tác động thật (-0,097), nhưng không bằng 0. Một phần của nó là mùa vụ (nửa cuối năm có mùa lễ, khi CRZ có biên độ dao động lớn hơn), phần còn lại có thể là xu hướng. Điều này cho thấy ước lượng TWFE có thể đánh giá cao mức giảm, và các ước lượng SCM và DML, vốn thấp hơn, là cận dưới hợp lý.


Bảng 4.26. Giả được theo thời gian trên panel cặp OD × tháng

Biến	Giả được 07/2024	Giả được + xu hướng	Thật 01/2025	Thật + xu hướng
log số chuyển	-0,034*** (0,004)	0,020*** (0,007)	-0,105*** (0,006)	-0,018*** (0,007)
Giá cước/chuyển	1,330*** (0,078)	-1,693*** (0,097)	1,216*** (0,076)	-2,078*** (0,137)
TN tài xế/chuyển	0,825*** (0,044)	-1,088*** (0,060)	0,264*** (0,035)	-2,227*** (0,090)
Chi phí hành khách/chuyển	1,476*** (0,086)	-1,910*** (0,107)	2,833*** (0,082)	-0,957*** (0,152)
Giá cước/dặm	0,403*** (0,028)	-0,531*** (0,042)	0,405*** (0,028)	-0,609*** (0,050)
TN tài xế/dặm	0,257*** (0,017)	-0,334*** (0,026)	0,056*** (0,010)	-0,663*** (0,039)
Tốc độ	-0,193*** (0,017)	-0,049 (0,033)	0,307*** (0,019)	0,906*** (0,032)

Ghi chú: hiệu ứng cố định cặp và tháng; phân cụm theo vùng đón. Nguồn: *t49b_placebo_time_od.csv*.

Trên panel cặp OD, kết luận tương tự. Tốc độ có giả được -0,193 (âm) và giả được có xu hướng -0,049 ($p = 0,138$), trong khi tác động thật dương với mọi đặc tả (0,307 và 0,906). Số chuyển có giả được -0,034 so với tác động thật -0,105; với xu hướng nhóm, tác động thật còn -0,018 và giả được là 0,020. Mọi đặc tả đều cho tác động thật âm hơn giả được tương ứng.

4.14.2. Suy luận hoán vị



Hình 4.35. Phân phối hệ số DiD khi gán xử lý ngẫu nhiên cho các vùng đối chứng (500 lần) và ước lượng thật

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Khi gán ngẫu nhiên nhân xử lý cho 37 trong số 200 vùng đối chứng, hệ số DiD có trung bình 0,0002 và độ lệch chuẩn 0,0076; 95% giá trị nằm trong $[-0,0149; 0,0150]$. Ước lượng thật -0,0972 nằm xa ngoài phân phối này, giá trị p hoán vị hai phía là 0,0020, bằng mức nhỏ nhất có thể đạt với 500 lần lặp. Không một cách gán ngẫu nhiên nào tạo ra mức giảm lớn như CRZ.


4.14.3. Bảng độ vững

Bảng 4.27. Độ vững của tác động lên log số chuyển HVFHV đón qua các đặc tả

Đặc tả	Hệ số (SE)	% thay đổi	Số vùng (xử lý)	Số quan sát
Cơ sở: CRZ vs MN bắc + quận ngoài, vùng ≥ 100 chuyển/ngày	-0,0972*** (0,0062)	-9,27	237 (37)	24.411
Đối chứng chỉ Manhattan phía bắc	-0,0413** (0,0157)	-4,04	58 (37)	5.974
Đối chứng chỉ các quận ngoài	-0,1038*** (0,0060)	-9,86	216 (37)	22.248
Đối chứng chỉ Brooklyn và Queens	-0,1013*** (0,0064)	-9,63	157 (37)	16.171
Ngưỡng vùng ≥ 50 chuyển/ngày	-0,0971*** (0,0063)	-9,26	242 (38)	24.926
Ngưỡng vùng ≥ 300 chuyển/ngày	-0,0948*** (0,0062)	-9,04	224 (37)	23.072
Gộp vùng vắt ranh giới vào nhóm xử lý	-0,0945*** (0,0059)	-9,01	243 (43)	25.029

Đặc tả	Hệ số (SE)	% thay đổi	Số vùng (xử lý)	Số quan sát
Bỏ tuần lễ cuối năm (20/12–05/01)	-0,1005*** (0,0062)	-9,56	237 (37)	23.463
Bỏ 4 tuần đầu sau chính sách	-0,1032*** (0,0066)	-9,81	237 (37)	23.463
Chỉ 01–06/2025 là giai đoạn sau	-0,0843*** (0,0057)	-8,09	237 (37)	18.486
Chỉ 07–12/2025 là giai đoạn sau	-0,1107*** (0,0083)	-10,48	237 (37)	18.249
Có trọng số theo lưu lượng 2024	-0,0826*** (0,0067)	-7,93	237 (37)	24.411
Thêm xu hướng tuyến tính riêng của nhóm xử lý	0,0104 (0,0102)	1,04	237 (37)	24.411
DDD: thêm FE nhóm × tuần-trong-năm	-0,1016*** (0,0061)	-9,66	237 (37)	24.411
FE quận × tuần (so sánh trong cùng quận)	-0,0413** (0,0157)	-4,04	58 (37)	5.974
Phân cụm theo quận thay vì vùng (5 cụm, chỉ tham khảo)	-0,0972*** (0,0105)	-9,27	237 (37)	24.411
Panel vùng × ngày	-0,0986*** (0,0060)	-9,39	237 (37)	173.247

Nguồn: *t51_robustness_ln_n.csv*.



Hình 4.36. Hệ số DiD log số chuyển qua các đặc tả, kèm khoảng tin cậy 95%

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Trong 17 đặc tả, 16 đặc tả cho hệ số âm. Ngoại lệ duy nhất là đặc tả có xu hướng tuyến tính nhóm, đã được chỉ ra là không đáng tin qua phép thử giả được. Thay đổi ngưỡng lưu lượng (50 hay 300 chuyển/ngày), gộp vùng vắt ranh giới vào nhóm xử lý, bỏ tuần lễ cuối năm, bỏ bốn tuần đầu hay dùng panel theo ngày đều cho mức giảm trong khoảng 7,9% đến 10,5%.

Khi chỉ dùng Manhattan phía bắc làm đối chứng, mức giảm còn 4,04%, so với 9,86% khi chỉ dùng quận ngoài. Khác biệt này khớp với kết quả lan tỏa ở mục 4.12:


Manhattan phía bắc bị ảnh hưởng gián tiếp nên không phải đối chứng sạch. Đặc tả hiệu ứng cố định quận $\times$ tuần, vốn chỉ so sánh trong nội bộ Manhattan, cho đúng kết quả của đặc tả đối chứng Manhattan phía bắc vì hai đặc tả dùng cùng một biến thiên.

Tác động trong nửa cuối năm 2025 (10,48%) lớn hơn nửa đầu (8,09%), nhất quán với nghiên cứu sự kiện trên panel OD. Phân cụm theo quận thay vì vùng làm sai số chuẩn tăng lên nhưng với chỉ 5 cụm, kết quả này chỉ có tính tham khảo.

4.14.4. Giai đoạn trước chính sách mở rộng: khử mùa vụ và giả được theo năm

Với dữ liệu 2022–2025, đồ án ước lượng một nghiên cứu sự kiện theo tháng trên panel 237 vùng $\times$ 48 tháng (37 vùng CRZ), có hiệu ứng cố định vùng, tháng và nhóm xử lý $\times$ tháng trong năm. Năm 2022 là năm gốc: mỗi hệ số β_m đo chênh lệch CRZ – đối chứng của tháng m so với cùng tháng năm 2022, nên mùa vụ riêng của CRZ đã được khử. Ba năm 2023, 2024 và 2025 cho 36 hệ số, trong đó 24 hệ số trước chính sách cho phép kiểm tra trực tiếp hai điều mà thiết kế ban đầu không kiểm tra được: năm 2024 có khác năm 2023 không (giả được với chính sách giả 01/2024), và xu hướng trước chính sách có ổn định không.

Bốn đại lượng được báo cáo. Giả được là chênh lệch trung bình năm 2024 so với 2023. Tác động thô là chênh lệch 2025 so với 2024, tương đương đặc tả DDD mùa vụ của mục 4.5. Tác động sau điều chỉnh xu hướng ngoại suy xu hướng tuyến tính theo tháng ước lượng từ 24 tháng 2023–2024. Gia tốc là chênh lệch của thay đổi năm 2025 so với thay đổi năm 2024, tức một sai khác bậc hai theo năm, đúng khi xu hướng tương đối thay đổi đều mỗi năm.



Hình 4.37. Hệ số nghiên cứu sự kiện khử mùa vụ theo tháng, 2023–2025 (năm gốc 2022)

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Bảng 4.28. Giá được theo năm, tác động thô, tác động sau điều chỉnh xu hướng và gia tốc (panel vùng × tháng 2022–2025)

Biến kết quả	Giá được 2024–2023	Tác động thô 2025–2024	Sau điều chỉnh xu hướng	SE	Gia tốc	SE
log số chuyển	-0,081***	-0,102***	0,001	0,008	-0,020***	0,005
Tốc độ (dặm/giờ)	0,179***	0,397***	0,147***	0,029	0,218***	0,026
Thời gian chờ (phút)	-0,063***	-0,386***	-0,250***	0,025	-0,323***	0,029
Giá cước cơ sở/dặm (USD)	0,222***	0,290***	0,102***	0,015	0,068***	0,014
Thu nhập tài xế/dặm (USD)	-0,069***	0,039***	0,124***	0,013	0,108***	0,012
Chi phí hành khách/chuyến trừ phí CBD (USD)	1,854***	2,254***	0,607***	0,063	0,401***	0,081
Thu nhập tài xế/giá cước (%)	-3,268***	-2,360***	0,850***	0,222	0,909***	0,238
Tỷ lệ yêu cầu đi chung (%)	-0,518***	-0,518***	-0,379***	0,121	0,000	0,158

*Nguồn: t90_long_placebo_trend.csv. Sai số chuẩn phân cụm theo vùng; *, **, *** tương ứng $p < 0,1$; 0,05; 0,01.*

Kết quả quan trọng nhất của mục này là về số chuyển. Hình 4.37 và chuỗi chỉ số theo tháng cho thấy số chuyển HVFHV trong CRZ đã giảm tương đối so với nhóm đối chứng một cách đều đặn từ năm 2023, trước khi có chính sách: độ dốc trước chính sách là -0,85 điểm log mỗi tháng. Giá được 2024 so với 2023 là -7,8%, gần bằng tác động thô 2025 so với 2024 (-9,7%). Khi ngoại suy xu hướng tuyến tính, tác động còn

0,06% (sai số chuẩn 0,80 điểm log), không khác 0. Với giả định thay đổi hằng năm không đổi, gia tốc là -2,0% ($p < 0,001$).

Nói cách khác, phần lớn mức giảm khoảng 6–10% mà các thiết kế dựa trên một năm trước chính sách tìm thấy trùng với một xu hướng giảm tương đối đã có từ trước. Phạm vi tác động tương thích với dữ liệu ba năm là từ khoảng 0 (nếu xu hướng tháng tiếp diễn tuyến tính) đến khoảng 2% (nếu thay đổi năm tiếp diễn đều), và chỉ lên tới mức của thiết kế ban đầu nếu xu hướng giảm tương đối tự dừng lại đúng vào tháng 01/2025. Không có lý do độc lập nào để tin vào khả năng cuối cùng. Đây là một điều chỉnh lớn so với kết luận ban đầu về số chuyển và được đưa vào các chương thảo luận và kết luận.

Tốc độ và thời gian chờ cho bức tranh khác. Tốc độ cũng có xu hướng tăng tương đối trước chính sách (giả được 0,18 dặm/giờ), nhưng tác động thô năm 2025 (0,40 dặm/giờ) lớn gấp đôi, và sau điều chỉnh xu hướng vẫn còn 0,15 dặm/giờ (sai số chuẩn 0,029); gia tốc là 0,22 dặm/giờ. Thời gian chờ gần như không có xu hướng trước (giả được -0,06 phút) và giảm 0,39 phút năm 2025; sau điều chỉnh xu hướng còn 0,25 phút. Hai biến này vì vậy vẫn cho bằng chứng về tác động của chính sách, với độ lớn nhỏ hơn ước lượng ban đầu: khoảng một phần ba đến một nửa đối với tốc độ và khoảng hai phần ba đối với thời gian chờ.

Với giá cước và thu nhập tài xế, dữ liệu dài hơn xác nhận nhận định của mục 4.14.1: cả hai có xu hướng trước chính sách mạnh và giả được có ý nghĩa. Sau điều chỉnh xu hướng, giá cước cơ sở mỗi dặm tăng 0,102 USD và thu nhập tài xế mỗi dặm tăng 0,124 USD, nhưng chiều của các ước lượng này thay đổi tùy cách mô hình hóa xu hướng (so với tháng cuối trước chính sách, chúng lần lượt là -0,104 và -0,109), nên đồ án giữ kết luận không xác định.

4.14.5. Độ nhạy với vi phạm xu hướng song song (Rambachan–Roth)

Rambachan và Roth (2023) đề xuất thay câu hỏi "xu hướng song song có đúng không" bằng câu hỏi "xu hướng song song phải sai đến mức nào thì kết luận mới đổi". Hai lớp giới hạn được dùng. Với lớp độ lớn tương đối (RM), biến động của độ lệch xu hướng sau chính sách giữa hai tháng liên tiếp không vượt quá $\bar{M}$ lần biến động lớn nhất quan sát được trước chính sách. Với lớp độ trơn (SD), độ lệch so với xu hướng


tuyến tính ngoại suy có sai phân bậc hai không vượt quá $\bar{M}$ mỗi tháng. Giá trị phá vỡ là $\bar{M}$ hoặc M nhỏ nhất làm khoảng tin cậy chứa 0.

Đồ án cài đặt phiên bản đơn giản hóa và bảo thủ của hai lớp này: độ chênh lớn nhất có thể được cộng trực tiếp vào hai đầu khoảng tin cậy thông thường, thay vì dùng khoảng tin cậy tối ưu có độ dài cố định của các tác giả. Khoảng thu được vì vậy rộng hơn khoảng của Rambachan và Roth, và giá trị phá vỡ là cận dưới của giá trị phá vỡ thật. Tác động theo RM được chuẩn hóa so với tháng cuối trước chính sách (12/2024) như trong bài gốc.

Bảng 4.29. Giá trị phá vỡ theo hai lớp giới hạn của Rambachan–Roth

Biến kết quả	Tác động (RM)	max $ \Delta\beta $ trước	$\bar{M}$ phá vỡ	Tác động (SD)	M phá vỡ
log số chuyển	-0,032	0,165	0,013	0,001	0,0000
Tốc độ (dặm/giờ)	0,082	0,468	0,010	0,147	0,0030
Thời gian chờ (phút)	-0,426	0,671	0,085	-0,250	0,0066
Giá cước cơ sở/dặm (USD)	-0,104	0,631	0,016	0,102	0,0024
Thu nhập tài xế/dặm (USD)	-0,109	0,372	0,035	0,124	0,0033
Chi phí hành khách/chuyến trừ phí CBD (USD)	0,210	2,636	0,004	0,607	0,0159
Thu nhập tài xế/giá cước (%)	0,275	3,265	0,000	0,850	0,0136
Tỷ lệ yêu cầu đi chung (%)	0,135	1,145	0,000	-0,379	0,0046

Nguồn: *t90_long_placebo_trend.csv*, *t91_rr_relative_magnitudes.csv*, *t91b_rr_smoothness.csv*.



Hình 4.38. Khoảng tin cậy của tác động theo $\bar{M}$ trong lớp độ lớn tương đối

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Một giá trị phá vỡ $\bar{M} \geq 1$ nghĩa là kết luận vẫn đứng vững kể cả khi độ lệch xu hướng sau chính sách biến động mạnh như tháng biến động nhất trước chính sách; đây là mốc mà Rambachan và Roth dùng để đánh giá một kết quả là vững. Không biến nào đạt mốc này; giá trị phá vỡ lớn nhất là 0,085 (Thời gian chờ (phút)). Nguyên nhân chính là biến động tháng sang tháng của các hệ số trước chính sách rất lớn so với tác động, ví dụ với số chuyển biến động lớn nhất là 0,165 điểm log, chủ yếu ở các tháng Một khi mùa vụ của năm gốc 2022 (đợt dịch đầu năm) không lặp lại. Lớp RM dùng biến động lớn nhất làm thước đo nên rất khắt khe khi có một vài tháng ngoại lệ.

Lớp SD phù hợp hơn với dữ liệu này vì nó cho phép xu hướng tuyến tính và chỉ giới hạn độ cong. Với tốc độ, tác động sau điều chỉnh xu hướng chỉ mất ý nghĩa khi độ cong của xu hướng vượt 0,0030 dặm/giờ mỗi tháng²; với thời gian chờ là 0,0066 phút mỗi tháng². Với số chuyển, tác động sau điều chỉnh xu hướng không khác 0 ngay cả khi $M = 0$. Kết hợp với mục 4.14.4, bằng chứng về tốc độ và thời gian chờ đứng vững trước giả định xu hướng tuyến tính, còn bằng chứng về số chuyển thì không.

4.15. Đối chiếu kết quả với các giả thuyết lý thuyết

Mục này kiểm định tám giả thuyết của mục 2.11. Với H1, H2, H5 và H6, bằng chứng đã có ở các mục trước. Với H1b, H2b, H3 và H4, bước 18 của pipeline ước lượng thêm các đặc tả được thiết kế riêng cho từng dự báo.

4.15.1. H1b: liều – đáp ứng theo tỷ trọng phí

Bảng 4.30. Tác động lên số chuyển theo ngũ phân vị tỷ trọng phí trong giá (panel cặp OD × tháng)

Ngũ phân vị τ/p	Số cặp OD	Chi phí chuyển 2024 (USD)	τ/p (%)	Quãng đường TB (dặm)	Tác động (%)	SE	ϵ ngụ ý
1	708	50,21	2,99	7,51	-8,44***	0,0064	2,99
2	708	40,97	3,66	6,04	-10,32***	0,0077	3,03
3	707	35,38	4,24	4,63	-9,77***	0,0070	2,48
4	708	29,21	5,13	3,26	-11,23***	0,0071	2,38
5	708	20,94	7,16	1,62	-10,07***	0,0072	1,53

Nguồn: *t83_dose_response_fee_share.csv*. Mỗi ngũ phân vị so với toàn bộ cặp không chạm CRZ; FE cặp và tháng; cụm theo vùng đón.

Tỷ trọng phí tăng từ 3,0% ở nhóm chuyển đắt nhất (trung bình 7,5 dặm) lên 7,2% ở nhóm rẻ nhất (1,6 dặm), tức hơn gấp đôi. Nếu ϵ không đổi, tác động ở nhóm cuối phải lớn gấp đôi nhóm đầu. Thực tế, tác động chỉ đi từ -8,4% đến trong khoảng -9,8% đến -11,2% ở bốn nhóm còn lại. Hồi quy có trọng số của tác động theo $\ln(1 + \tau/p)$ cho

hệ số góc -0,410 (sai số chuẩn 0,228): đúng dấu dự báo nhưng chỉ có ý nghĩa ở mức 10%, và nhỏ hơn nhiều so với mức mà ϵ không đổi ngụ ý.


Vì vậy H1b chỉ được ủng hộ yếu. Độ co giãn ngụ ý giảm từ 3,0 ở chuyển dài xuống 1,5 ở chuyển ngắn. Thành phần thời gian $v \cdot T$ trong chi phí tổng quát không giải thích được điều này: chuyển dài có $v \cdot T$ lớn, nên tỷ trọng phí trong chi phí tổng quát còn nhỏ hơn tỷ trọng trong giá, và độ co giãn ngụ ý của chuyển dài lẽ ra còn cao hơn nữa. Hai cách giải thích còn lại là độ co giãn khác nhau giữa các nhóm khách (chuyển dài chạm CRZ chủ yếu là chuyển giữa CRZ và quận ngoài, với cơ cấu khách khác chuyển ngắn trong trung tâm), và phản ứng theo địa điểm: hành khách phản ứng với việc phải đi vào vùng có phí như một sự kiện rời rạc, hơn là với tỷ lệ phí trên giá. Kết luận thận trọng là mô hình ϵ đồng nhất không mô tả tốt dữ liệu: tác động gần như không đổi ở mức khoảng 9–12% ở mọi nhóm, thay vì tăng theo tỷ trọng phí.

4.15.2. H2b: độ lỗi của quan hệ tốc độ – lưu lượng

Bảng 4.31. Mức tăng tốc độ theo giờ $\times$ loại ngày hồi quy theo lưu lượng CRZ $\rightarrow$ CRZ năm 2024

Đặc tả	Biến	Hệ số	SE	p	R ²
Tuyến tính theo lưu lượng	Lưu lượng tương đối	0,123**	0,062	0,046	0,087
Bậc hai theo lưu lượng	Lưu lượng tương đối	-0,334	0,243	0,169	0,156
Bậc hai theo lưu lượng	Lưu lượng tương đối ²	0,432*	0,222	0,051	0,156
Tuyến tính + cuối tuần	Lưu lượng tương đối	0,107*	0,058	0,062	0,169
Tuyến tính + cuối tuần	Cuối tuần	0,069**	0,031	0,024	0,169

Nguồn: *t84b_speed_gain_vs_flow_models.csv*; 48 ô giờ $\times$ loại ngày; sai số chuẩn HC1.



Hình 4.39. Kiểm định ba giả thuyết: liều – đáp ứng theo tỷ trọng phí (trái), tốc độ – lưu lượng (giữa), lan tỏa theo mức phơi nhiễm (phải)

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Đơn vị quan sát là 48 ô giờ $\times$ loại ngày. Biến phụ thuộc là mức tăng tốc độ của chuyển CRZ $\rightarrow$ CRZ so với chuyển trong quận ngoài (sai khác kép mô tả ở mục 4.6.4), biến giải thích là lưu lượng chuyển CRZ $\rightarrow$ CRZ trung bình mỗi giờ năm 2024, chuẩn hóa về giờ cao nhất. Hệ số tuyến tính là 0,123 (p 0,046), tương quan hạng Spearman 0,33: ở sáu giờ có lưu lượng cao nhất, tốc độ tăng trung bình 0,31 dặm/giờ, so với 0,21 ở sáu giờ thấp nhất. Số hạng bậc hai dương (0,432, p 0,051) phù hợp với độ lồi mà hàm BPR dự báo, dù chỉ ở mức ý nghĩa 10%.

H2b được ủng hộ ở mức vừa phải. Với 48 quan sát và biến giải thích là lưu lượng gọi xe chứ không phải tổng lưu lượng mọi phương tiện, độ chính xác không thể cao; nhưng cả dấu, hình dạng và thứ tự hạng đều khớp với dự báo. Kết quả này cũng giải thích vì sao mức tăng tốc độ tập trung ở chiều tối ngày thường như mục 4.6.4 đã mô tả.

4.15.3. H3: lan tỏa theo mức phơi nhiễm

Bảng 4.32. Tác động sau chính sách theo mức phơi nhiễm của các vùng ngoài CRZ

Mẫu	Biến	Hệ số (sau $\times$ phơi nhiễm)	SE	Số vùng	Phơi nhiễm P10–P90 (%)
Mọi vùng ngoài CRZ	log số chuyển	-0,259***	0,033	206	1,8–20,5
Mọi vùng ngoài CRZ	Tốc độ (dặm/giờ)	0,626***	0,092	206	1,8–20,5
Bỏ vùng vắt ranh giới	log số chuyển	-0,305***	0,049	200	1,8–18,0
Bỏ vùng vắt ranh giới	Tốc độ (dặm/giờ)	0,679***	0,155	200	1,8–18,0
Chỉ quận ngoài	log số chuyển	-0,220***	0,055	179	1,7–12,1
Chỉ quận ngoài	Tốc độ (dặm/giờ)	1,001***	0,202	179	1,7–12,1

Nguồn: *t85_spillover_dose_response.csv*. Phơi nhiễm = tỷ trọng chuyển đón tại vùng có điểm trả trong CRZ năm 2024; FE vùng và tuần; cụm theo vùng.

Bảng 4.33. Tác động lên số chuyển theo ngũ phân vị phơi nhiễm

Nhóm phơi nhiễm	Phơi nhiễm TB (%)	Tác động so với nhóm 1 (%)	SE
1 (tham chiếu)	1,7	0	–
2	2,9	0,78	0,0064
3	3,9	-0,18	0,0057
4	7,8	-0,74	0,0073
5	24,1	-5,94***	0,0099

Nguồn: *t85b_spillover_by_exposure_bin.csv*.

Hệ số của tương tác sau chính sách $\times$ phơi nhiễm trên 206 vùng ngoài CRZ là -0,259 (sai số chuẩn 0,033): vùng có phơi nhiễm cao hơn 10 điểm phần trăm mất thêm

khoảng 2,6% số chuyển. Kết quả vững khi bỏ vùng vắt ranh giới và khi chỉ dùng quận ngoài. Chiều của tác động khớp với H3.

Độ lớn thì không khớp với dự báo cơ học. Với tác động lên chuyển chậm CRZ trên panel OD là $\delta = -0,105$, hệ số góc cơ học là $e^{\delta} - 1 = -0,100$. Hệ số ước lượng lớn gấp khoảng 2,6 lần. Bảng theo ngũ phân vị cho thấy lý do: bốn nhóm phơi nhiễm thấp gần như không đổi so với nhau, toàn bộ tác động tập trung ở nhóm phơi nhiễm cao nhất (trung bình 24,1%), với mức giảm 5,9%. Nhóm này gồm các vùng sát ranh giới, nơi không chỉ chuyển vào CRZ mà cả chuyển nội bộ trong khu vực cũng giảm. Như vậy, lan tỏa có hai thành phần: thành phần cơ học theo phơi nhiễm, và một thành phần hành vi tập trung ở vùng lân cận ranh giới, lớn hơn thành phần cơ học.

Về tốc độ, tương tác phơi nhiễm cũng dương (0,626): vùng có nhiều chuyển vào CRZ được lợi về tốc độ nhiều hơn, vì một phần hành trình của các chuyển này nằm trong vùng đường đã thông thoáng hơn. Kết quả này nhất quán với phát hiện của Cook và cộng sự (2025) rằng tốc độ tăng cả trên các tuyến ngoài vùng có nhiều chuyển đi vào vùng.

4.15.4. H4: thu nhập tài xế mỗi dặm giảm cơ học khi tốc độ tăng

Ước lượng b , thu nhập tài xế cho mỗi phút, bằng hồi quy thu nhập mỗi dặm theo số phút mỗi dặm trên panel vùng $\times$ tuần năm 2024 với hiệu ứng cố định vùng và tuần, cho $b = 0,718$ USD/phút (sai số chuẩn 0,037). Với tốc độ trước chính sách 12,96 dặm/giờ và mức tăng 0,41 dặm/giờ, dự báo cơ học là thu nhập mỗi dặm thay đổi -0,101 USD. Hệ số DiD quan sát được lại là 0,040 USD (sai số chuẩn 0,009), ngược dấu với dự báo.

Kết quả này có hai cách đọc, và cả hai đều quan trọng. Thứ nhất, nó cho thấy nếu hệ số DiD đúng, phải có một yếu tố khác làm tăng thu nhập mỗi dặm trong CRZ đủ để lấn át hiệu ứng cơ học của tốc độ, chẳng hạn nền tảng tăng tỷ lệ chia cho tài xế trong vùng có phí để giữ nguồn cung. Thứ hai, và phù hợp hơn với các phép thử ở mục 4.14, hệ số DiD của thu nhập mỗi dặm chịu xu hướng có sẵn, nên phép so sánh này là một lý do độc lập nữa để không diễn giải nó như tác động nhân quả. H4 vì vậy chưa kiểm định được bằng dữ liệu hiện có; giá trị của nó là cho biết thành phần cơ học cần được tách ra trước khi đánh giá bất kỳ thay đổi nào của thu nhập tài xế.

4.15.5. Tổng hợp

Bảng 4.34. Tổng hợp kết quả kiểm định các giả thuyết lý thuyết

Giả thuyết	Dự báo	Bảng chứng	Kết luận
H1	Số chuyển giảm	-9,3% (TWFE, một năm trước); 0,1% sau điều chỉnh xu hướng 2023–2024	Ứng hộ một phần: không tách được khỏi xu hướng có sẵn
H1b	Giảm theo tỷ trọng phí	Hệ số góc -0,41, $p \approx 0,07$; gradient yếu hơn nhiều so với dự báo	Ứng hộ yếu
H2	Tốc độ tăng	+0,41 dặm/giờ; +0,15 sau điều chỉnh xu hướng 2023–2024	Ứng hộ
H2b	Tăng nhiều hơn ở giờ đông	Hệ số 0,123, p 0,046; số hạng bậc hai dương	Ứng hộ vừa phải
H3	Lan tỏa theo phơi nhiễm	Hệ số -0,26, lớn gấp 2,6 lần dự báo cơ học	Ứng hộ về chiều; có thêm kênh hành vi
H4	Thu nhập/dặm giảm cơ học	Dự báo -0,10 USD, DiD 0,04 USD (chịu tiền xu hướng)	Chưa kiểm định được
H5	Đi chung giảm mạnh hơn	Tỷ lệ đi chung -16% so với mức nền; giả được 2024–2023 bằng tác động 2025–2024 (-0,52 điểm %)	Ứng hộ một phần: có xu hướng có sẵn
H6	Tăng tốc độ giảm dần	0,67 dặm/giờ sau 4 tuần; 0,41 sau 52 tuần	Ứng hộ

Nguồn: tác giả tổng hợp từ t30, t80, t83–t86, t90.

Ba giả thuyết được ủng hộ rõ (tốc độ tăng, lan tỏa theo phơi nhiễm về chiều, lợi ích tốc độ giảm dần), bốn được ủng hộ một phần và một chưa kiểm định được. Điểm yếu lớn nhất so với mô hình là H1: dữ liệu 2022–2025 cho thấy số chuyển CRZ đã giảm tương đối từ trước, nên dự báo cơ bản nhất của mô hình cầu không được xác nhận chắc chắn. Hai điểm khác mô hình không giải thích tốt là hình dạng của liều – đáp ứng theo giá (tác động gần như không đổi theo tỷ trọng phí) và độ lớn của lan tỏa ở vùng sát ranh giới. Cả hai đều chỉ ra cùng một hướng mở rộng mô hình: phản ứng của hành khách không chỉ phụ thuộc vào mức tăng giá của từng chuyến, mà vào việc chuyến đi đó có gần với khu vực trung tâm hay không, một dạng phản ứng theo địa điểm mà mô hình cầu theo từng cặp OD không nắm được.

4.16. Tổng hợp kết quả theo câu hỏi nghiên cứu

Bảng 4.35. Tổng hợp các ước lượng mức giảm số chuyển HVFHV chạm CRZ

Phương pháp	Mức giảm số chuyển (%)	KTC 95% / suy luận
TWFE, vùng × tuần	9,27	[8,15; 10,37]
DDD mùa vụ	9,66	[8,57; 10,73]
TWFE có trọng số	7,93	[6,71; 9,13]
Panel cặp OD × tháng	9,97	[8,97; 10,95]
Kiểm soát tổng hợp	6,50	p (khoảng cách) = 0,016
DML – AIPW (vùng chồng lấn)	8,41	[7,85; 8,96]
Đối chứng chỉ Manhattan phía bắc (bị lan tỏa)	4,04	[0,98; 7,01]
Pandey, Guler, Gayah (2026) – tham chiếu	5,95	–
Dữ liệu 2022–2025, điều chỉnh xu hướng 2023–2024 (mục 4.14.4)	-0,06	[-1,63; 1,49]
Dữ liệu 2022–2025, gia tốc so với thay đổi năm 2024	2,02	[0,96; 3,07]

Nguồn: kết quả tính toán của tác giả.

Bảng trên đặt các ước lượng cạnh nhau. Mọi thiết kế dựa trên một năm trước chính sách đều cho thấy số chuyển giảm trong khoảng từ khoảng 6% đến 10%, và ước lượng tham chiếu của Pandey, Guler và Gayah (2026) nằm ở cận dưới của khoảng này. Hai dòng cuối, dùng dữ liệu 2022–2025, cho thấy phần lớn mức giảm này trùng với xu hướng giảm tương đối đã có từ năm 2023: sau điều chỉnh xu hướng, tác động không khác 0, và theo sai khác bậc hai theo năm, phần tăng thêm chỉ khoảng 2%. Vì vậy, khoảng 6–10% nên được hiểu là cận trên của tác động, đạt được chỉ khi xu hướng giảm tương đối trước đó tự dừng lại đúng lúc chính sách bắt đầu.

Bảng 4.36. Đối chiếu câu hỏi nghiên cứu, kết quả và mức độ chắc chắn

Câu hỏi	Nội dung	Kết quả chính	Mức độ chắc chắn
RQ1	Pipeline Lakehouse, DuckDB, Parquet	572.952.454 bản ghi trong 83,7 phút; Parquet ZSTD nhỏ hơn CSV 6,6 lần; DuckDB dùng ít bộ nhớ nhất	Cao
RQ2	Số chuyển	Giảm 6–10% với một năm trước chính sách; với dữ liệu 2022–2025, mức giảm trùng phần lớn với xu hướng có sẵn, phần vượt xu hướng khoảng 0–2%	Thấp về độ lớn
RQ3	Tốc độ, thời gian chờ	Tốc độ +0,41 dặm/giờ và thời gian chờ -0,38 phút (một năm trước chính sách); vẫn có ý nghĩa sau điều chỉnh xu hướng 2023–2024 với độ lớn nhỏ hơn	Cao về chiều, trung bình về độ lớn
RQ4	Không đồng nhất, lan tỏa	Giảm mạnh hơn vào đêm, chuyển ngắn; tốc độ tăng mạnh chiều tối; lan tỏa giảm dần tới 5–10 km	Trung bình
RQ5	Giá, thu nhập tài xế	Phí chuyển trực tiếp sang hành khách; tác động lên giá cước cơ sở và thu nhập tài xế không xác định được do xu hướng có sẵn	Thấp

Nguồn: kết quả tính toán của tác giả.

4.17. Tiểu kết Chương 4

Chương 4 cho thấy pipeline xử lý được toàn bộ dữ liệu với chi phí tính toán thấp và các lựa chọn kỹ thuật có tác động đo được. Về nhân quả, với một năm trước chính sách, mọi thiết kế đều cho thấy số chuyển gọi xe chạm CRZ giảm, tốc độ tăng và thời gian chờ giảm, nhất quán giữa các phương pháp và vượt qua suy luận hoán vị. Khi mở rộng giai đoạn trước chính sách về 2022, kết luận phân hóa: tốc độ và thời gian chờ vẫn cải thiện sau khi điều chỉnh xu hướng có sẵn, với độ lớn nhỏ hơn; còn mức giảm số chuyển phần lớn trùng với xu hướng giảm tương đối của CRZ đã có từ năm 2023, nên tác động nhân quả lên số chuyển không phân biệt được rõ với xu hướng đó. Tác động không đồng nhất theo khung giờ, loại luồng và khoảng cách, và lan ra các vùng lân cận theo mức phơi nhiễm. Các chỉ tiêu giá cước và thu nhập tài xế bị chi phối bởi xu hướng có sẵn nên không thể kết luận. Chương 8 thảo luận ý nghĩa của các kết quả này, sau khi Chương 5 đến 7 bổ sung phần xử lý phân tán, quản trị dữ liệu và phân tích kinh doanh.

CHƯƠNG 5. XỬ LÝ PHÂN TÁN VỚI APACHE SPARK: ĐỐI CHỨNG CHÉO VÀ PHÂN TÍCH HIỆU NĂNG

Chương 4 đã cho thấy toàn bộ pipeline chạy được trên DuckDB, một bộ máy phân tích nhúng chạy trên một nút. Chương này đưa vào bộ máy thứ hai, Apache Spark, là nền tảng xử lý phân tán trong bộ nhớ được Chương 3 của bài giảng trình bày như công cụ trung tâm của phân tích dữ liệu lớn. Mục đích không phải thay DuckDB bằng Spark, mà trả lời ba câu hỏi mà một đồ án chỉ dùng một bộ máy không trả lời được.

Câu hỏi thứ nhất là tính đúng. Một bảng Gold do một bộ máy tạo ra có thể sai vì lỗi logic, lỗi ép kiểu hoặc lỗi của chính bộ máy, và những lỗi này thường không lộ ra khi chỉ nhìn vào kết quả phân tích. Tái lập cùng bảng bằng một bộ máy độc lập rồi so từng ô là một phép kiểm thử sai phân (differential testing) mạnh hơn nhiều so với đọc lại mã. Câu hỏi thứ hai là chi phí: mô hình phân tán của Spark tốn thêm bao nhiêu thời gian và bộ nhớ khi chạy trên đúng phần cứng mà DuckDB đã dùng. Câu hỏi thứ ba là cơ chế: các thành phần mà lý thuyết nêu ra, gồm bộ tối ưu Catalyst, thực thi truy vấn thích nghi, lưu đệm, cắt tia phân vùng, Apache Arrow và xử lý luồng có cấu trúc, tác động đo được đến đâu trên dữ liệu thật của đồ án.

Ba câu hỏi này gộp lại thành câu hỏi nghiên cứu RQ6. Mục 5.1 mô tả thiết kế thực nghiệm. Mục 5.2 trình bày kết quả tái lập và đối chứng chéo, trong đó có một lỗi thật của pipeline được phát hiện nhờ Spark. Các mục 5.3 đến 5.8 lần lượt phân tích hiệu năng và từng cơ chế. Mục 5.9 thảo luận hàm ý cho việc chọn công cụ.

5.1. Thiết kế thực nghiệm

5.1.1. Môi trường và cấu hình Spark

Bảng 5.1. Cấu hình Spark dùng trong các thực nghiệm

Thành phần	Cấu hình
Phiên bản	Apache Spark 3.5.3 qua PySpark, OpenJDK 11
Chế độ triển khai	local[2]: driver và executor trong cùng một JVM, 2 luồng tác vụ
Bộ nhớ driver	1.200 MB (spark.driver.memory)
Phân vùng xáo trộn mặc định	8 (spark.sql.shuffle.partitions); thực nghiệm 5.4 thay đổi từ 1 đến 1.000
Thực thi truy vấn thích nghi	Bật (spark.sql.adaptive.enabled = true); thực nghiệm 5.4 so sánh khi tắt
Múi giờ phiên	UTC, để trường thời gian không bị dịch khi đọc Parquet
Thư mục làm việc	SPARK_WORK trên đĩa cục bộ của máy ảo (Spark cần quyền xóa tệp tạm)
Dữ liệu vào	Lớp Silver: 120 tệp Parquet ZSTD, phân vùng service=/year=/month=

Nguồn: `code/15_spark_pipeline.py`.

Spark chạy ở chế độ local trên cùng máy ảo 2 lõi, khoảng 3 GB RAM đã dùng cho DuckDB. Lựa chọn này có chủ đích. Nếu chạy Spark trên một cụm nhiều nút, mọi khác biệt về thời gian sẽ trộn lẫn hiệu quả của bộ máy với lượng phần cứng được thêm vào. Giữ nguyên phần cứng cho phép tách riêng chi phí của mô hình lập trình phân tán: khởi động JVM, lập kế hoạch qua Catalyst, chia tác vụ, xáo trộn dữ liệu qua đĩa và tuần tự hóa giữa Python và JVM. Chế độ local vẫn đi qua đúng các thành phần này, chỉ khác là các executor nằm trong cùng một tiến trình.

Một chi tiết vận hành đáng ghi lại: lần chạy đầu tiên, Spark không khởi động được vì máy ảo không phân giải được tên máy của chính nó, và sau đó không xóa được tệp tạm vì thư mục dự án được gắn từ Windows với quyền chỉ ghi, không xóa. Hai lỗi này được xử lý bằng biến môi trường SPARK_LOCAL_HOSTNAME và bằng cách đặt thư mục làm việc của Spark trên đĩa cục bộ. Chúng minh họa một điểm mà bài giảng nhấn mạnh ở mục 3.7: chi phí thật của một bộ máy phân tán nằm nhiều ở vận hành, không chỉ ở thời gian tính toán.

5.1.2. Truy vấn chuẩn

Mọi phép so sánh bộ máy dùng cùng một truy vấn: dựng bảng Gold zone_day_pu từ lớp Silver, tức tổng hợp theo dịch vụ, ngày và vùng đón với 17 chỉ tiêu cộng được. Truy vấn này được chọn vì nó là đầu vào của panel vùng $\times$ tuần, panel chính của toàn bộ phân tích nhân quả ở Chương 4. Nếu bảng này sai, gần như mọi ước lượng đều sai theo.


```

SELECT service, d, pu AS zone,
       count(*) AS n, sum(fare) AS fare, sum(driver_pay) AS pay, sum(miles) AS miles,
       sum(time_s) AS time_s, sum(tips) AS tips, sum(CAST(cbd_fee AS DOUBLE)) AS cbd,
       sum(rider_cost) AS rider_cost, sum(cong_sur) AS cong_sur, sum(tolls) AS tolls,
       sum(wait_min) AS wait_sum, count(wait_min) AS wait_n, sum(shared_req) AS
shared_req,
       sum(CAST(cbd_fee > 0 AS INT)) AS n_cbd, sum(CAST(do_grp = 'CRZ' AS INT)) AS
n_to_crz,
       sum(CAST(company_code = 'HV0003' AS INT)) AS n_uber,
       sum(CAST(company_code = 'HV0005' AS INT)) AS n_lyft
FROM silver GROUP BY service, d, pu

```

Truy vấn được viết bằng SQL chuẩn để chạy nguyên văn trên cả DuckDB và Spark SQL. Với Spark, đồ án viết thêm một bản tương đương bằng API DataFrame để kiểm tra xem hai cách diễn đạt có cho cùng một kế hoạch thực thi và cùng hiệu năng không.

5.1.3. Các thực nghiệm

Bảng 5.2. Tám thực nghiệm với Spark

Thực nghiệm	Biến thay đổi	Đại lượng đo	Mục
E1. Tái lập và đối chứng	Toàn bộ 48 tháng-dịch vụ	Chênh lệch từng ô giữa Spark và DuckDB	5.2
E2. So sánh bộ máy	DuckDB, Spark DataFrame, Spark SQL; 1 tháng	Thời gian lần 1, trung vị 3 lần, bộ nhớ đỉnh	5.3
E3. Mở rộng theo khối lượng	1, 2, 3, 4, 6 tháng HVFHV	Thời gian, thông lượng dòng/giây	5.3
E4. Xáo trộn và AQE	1–1.000 phân vùng; AQE bật/tắt	Thời gian truy vấn	5.4
E5. Lưu đệm	3 truy vấn, trước và sau persist()	Thời gian, dung lượng bộ đệm	5.5
E6. Cắt tia phân vùng	5 điều kiện lọc trên toàn Silver	Số tệp, dung lượng, số dòng được quét	5.6
E7. Apache Arrow	toPandas() có/không Arrow	Thời gian chuyển đổi	5.7
E8. Luồng có cấu trúc	14 tệp ngày quanh 05/01/2025	Độ trễ và thông lượng từng lô vi mô	5.8

Nguồn: tác giả thiết kế.

5.1.4. Cách đo và giới hạn của phép đo

Mỗi phép đo thời gian được lặp ba lần trong cùng một phiên. Lần đầu bao gồm chi phí biên dịch mã (whole-stage code generation của Spark, JIT của JVM) và đọc tệp từ đĩa lần đầu; các lần sau hưởng lợi từ bộ đệm trang của hệ điều hành. Báo cáo trình bày cả lần đầu và trung vị ba lần vì hai con số trả lời hai câu hỏi khác nhau: lần đầu gần với một tác vụ chạy theo lịch, trung vị gần với một phiên phân tích tương tác.

Bộ nhớ được đo khác nhau cho hai bộ máy vì kiến trúc khác nhau. DuckDB chạy trong tiến trình Python, nên bộ nhớ đỉnh là kích thước tập thường trú lớn nhất (max RSS) của tiến trình đó. Spark chạy trong một JVM riêng, nên bộ nhớ đỉnh là VmHWM của tiến trình JVM, đọc từ /proc; phía Python chỉ giữ kết quả. Thời gian khởi động phiên Spark được đo riêng và không cộng vào thời gian truy vấn.

Giới hạn chính là mọi phép đo đều trên một máy ảo dùng chung tài nguyên với hệ điều hành chủ, nên có dao động giữa các lần chạy. Chẳng hạn, thực nghiệm cắt tía phân vùng chạy hai lần trong ngày cho thời gian quét toàn bộ Silver khác nhau đáng kể. Vì vậy, chương này tập trung vào các khác biệt lớn (nhiều lần) và vào xu hướng, không diễn giải các chênh lệch nhỏ.

5.2. Tái lập bảng Gold và đối chứng chéo

5.2.1. Kết quả tái lập

Bảng 5.3. Tái lập bảng zone_day_pu bằng Spark trên toàn bộ lớp Silver

Dịch vụ	Số tháng	Dòng Silver	Tổng thời gian (s)	Trung vị/tháng (s)	Triệu dòng/giây	JVM đỉnh (MB)
HVFHV	24	461.438.058	189,8	6,92	2,43	1.071
Taxi vàng	24	82.873.727	33,9	1,36	2,45	936

Nguồn: t60_spark_repro_partitions.csv, t60b_spark_repro_totals.csv.

Spark đọc 544.311.785 dòng Silver của 48 tháng-dịch vụ và ghi ra 48 phân vùng Parquet của bảng zone_day_pu trong tổng cộng 223,7 giây, không tính 6,2 giây khởi động phiên. Thời gian mỗi tháng HVFHV có trung vị 6,92 giây; tháng chậm nhất mất 18,57 giây, là tháng được xử lý đầu tiên trong một phiên, khi JVM chưa biên dịch mã nóng. Thông lượng chung khoảng 2,4 triệu dòng mỗi giây. JVM cần khoảng 1.071 MB ở đỉnh, vừa trong giới hạn 1.200 MB của driver.

Con số này không so sánh trực tiếp được với thời gian của bước 03, vì bước 03 dựng cùng lúc bảy bảng Gold và mẫu chuyển đi (tổng 755 giây cho phần Gold). Phép so sánh cùng điều kiện được trình bày ở mục 5.3. Điểm cần giữ lại ở đây là việc tái lập toàn bộ một bảng Gold bằng một bộ máy đọc lập chỉ tốn vài phút, rẻ hơn rất nhiều so với giá trị của thông tin mà nó mang lại, như mục tiếp theo cho thấy.

5.2.2. Đối chứng từng ô

Hai bản của zone_day_pu được nối theo khóa (dịch vụ, ngày, vùng). Cả hai có đúng 358.148 dòng và không có khóa nào chỉ xuất hiện ở một bên. Với mỗi chỉ tiêu, đồ án tính số ô lệch về giá trị rỗng, chênh lệch tuyệt đối lớn nhất và chênh lệch tương đối lớn nhất. Bảng dưới đây trình bày kết quả của lần đối chứng đầu tiên, trước khi sửa lỗi.

Bảng 5.4. Đối chứng Spark – DuckDB, lần 1 (trước khi sửa lỗi)

Chỉ tiêu	HVFHV: lệch tuyệt đối / tương đối lớn nhất	Taxi vàng: lệch tuyệt đối / tương đối lớn nhất
n	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
fare	7,0e-09 / 1,2e-14	1,2e-09 / 6,2e-15
pay	3,7e-09 / 1,4e-14	(cột rỗng)
miles	2,2e-09 / 1,2e-14	5,2e-10 / 6,2e-15
time_s	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
tips	6,3e-10 / 8,4e-15	1,0e-09 / 1,9e-14
cbd	0 (khớp tuyệt đối)	0,05 / 6,25%
rider_cost	6,1e-08 / 4,8e-14	2,7e-09 / 1,3e-14
cong_sur	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
tolls	9,0e-09 / 1,6e-13	7,8e-10 / 4,4e-14
wait_sum	9,0e-10 / 9,4e-15	(cột rỗng)
wait_n	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
shared_req	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
n_cbd	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
n_to_crz	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
n_uber	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
n_lyft	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)

Nguồn: *t61a_spark_validation_truoc_sua.csv*.

Kết quả chia thành ba loại. Loại thứ nhất là các chỉ tiêu đếm và các tổng của giá trị nguyên hoặc bội của 0,5 (số chuyển, thời lượng, phí CBD của HVFHV, số chuyển theo hãng): khớp tuyệt đối. Loại thứ hai là các tổng số thực như giá cước, quãng đường, tiền tip: lệch tương đối cỡ $1e-14$ đến $1e-13$. Đây không phải lỗi. Phép cộng số thực dấu phẩy động không có tính kết hợp, và hai bộ máy cộng theo thứ tự khác nhau vì chia dữ liệu thành các lô và luồng khác nhau. Độ lệch ở mức vài đơn vị của chữ số có nghĩa thứ mười bốn đúng bằng sai số làm tròn tích lũy dự kiến của số thực 64 bit.

Loại thứ ba là một chỉ tiêu duy nhất lệch thật: phí CBD của taxi vàng. Tổng phí theo Spark là 24.026.395,50 USD, theo DuckDB là 24.028.170,60 USD, lệch tối đa 0,05 USD trên một ô, tức 6,25% giá trị ô đó. Bản Spark khớp với tổng tính trực tiếp từ các tệp Silver, nên lỗi nằm ở phía DuckDB.

5.2.3. Nguyên nhân lỗi và cách sửa

Truy vết cho thấy lỗi không nằm ở truy vấn tổng hợp mà ở bước hợp nhất (bước 04). Bước 03 ghi mỗi khúc tháng ra một tệp Parquet riêng. Ở các tháng năm 2024, trước khi có phí, cột phí được gán hằng số 0,0, và DuckDB suy ra kiểu DECIMAL(2,1) cho hằng số này; tổng của nó trong tệp Gold có kiểu DECIMAL(38,1). Ở các tháng năm 2025, cột phí lấy từ dữ liệu gốc có kiểu số thực. Khi bước 04 đọc toàn bộ các tệp bằng `read_parquet` với mẫu đường dẫn, DuckDB mặc

định lấy lược đồ của tệp đầu tiên theo thứ tự tên (HVFHV tháng 01/2024) và ép mọi tệp sau về lược đồ đó. Tổng phí của taxi vàng, vốn là bội số của 0,75 USD, bị làm tròn về một chữ số thập phân: 2,25 thành 2,3, 3,75 thành 3,8. HVFHV không bị ảnh hưởng vì phí 1,50 USD cho tổng là bội của 0,5, luôn biểu diễn đúng với một chữ số thập phân.

Cách sửa là thêm tùy chọn `union_by_name=true` khi đọc, để DuckDB hợp nhất lược đồ theo tên cột và nâng kiểu lên kiểu rộng nhất. Sau khi chạy lại bước 04 và các bước phân tích 06 đến 14, đối chứng lần hai cho chênh lệch tương đối lớn nhất của mọi chỉ tiêu dưới $1e-9$ và tổng phí CBD của taxi vàng hai bên khớp nhau (24.026.395,50 và 24.026.395,50 USD). Mọi con số trong báo cáo này đều dùng dữ liệu sau khi sửa.

Về độ lớn, lỗi nhỏ: tổng phí taxi vàng trong năm 2025 bị ghi cao hơn 0,0074%, và các ước lượng DiD về phí trên mỗi chuyến của taxi vàng chỉ đổi ở chữ số thập phân thứ năm. Nhưng loại lỗi này đáng chú ý vì ba lý do. Nó im lặng: không có cảnh báo, không có lỗi thực thi. Nó phụ thuộc thứ tự tệp: nếu tệp đầu tiên thuộc năm 2025, lỗi sẽ không xảy ra. Và nó không thể phát hiện bằng cách xem kết quả phân tích, vì mọi con số đều hợp lý. Chỉ một phép tính độc lập mới lộ ra nó. Đây là lập luận thực nghiệm mạnh nhất của chương cho việc có hai bộ máy trong một pipeline dữ liệu lớn: bộ máy thứ hai đóng vai trò kiểm toán viên.

Bảng 5.5. Đối chứng Spark – DuckDB, lần 2 (sau khi sửa lỗi)

Chỉ tiêu	HVFHV: lệch tuyệt đối / tương đối lớn nhất	Taxi vàng: lệch tuyệt đối / tương đối lớn nhất
n	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
fare	7,0e-09 / 1,2e-14	1,2e-09 / 6,2e-15
pay	3,7e-09 / 1,4e-14	(cột rỗng)
miles	2,2e-09 / 1,2e-14	5,2e-10 / 6,2e-15
time_s	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
tips	6,3e-10 / 8,4e-15	1,0e-09 / 1,9e-14
cbd	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
rider_cost	6,1e-08 / 4,8e-14	2,7e-09 / 1,3e-14
cong_sur	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
tolls	9,0e-09 / 1,6e-13	7,8e-10 / 4,4e-14
wait_sum	9,0e-10 / 9,4e-15	(cột rỗng)
wait_n	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
shared_req	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
n_cbd	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
n_to_crz	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)
n_uber	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)

Chi tiêu	HVFHV: lệch tuyệt đối / tương đối lớn nhất	Taxi vàng: lệch tuyệt đối / tương đối lớn nhất
n_lyft	0 (khớp tuyệt đối)	0 (khớp tuyệt đối)

Nguồn: t61_spark_validation.csv.


5.3. So sánh bộ máy và khả năng mở rộng

5.3.1. Cùng truy vấn trên một tháng

Bảng 5.6. DuckDB và Spark trên cùng truy vấn, 19.564.232 dòng HVFHV tháng 03/2025

Bộ máy	Ba lần chạy (s)	Lần 1 (s)	Trung vị (s)	Triệu dòng/giây	Bộ nhớ đỉnh (MB)
DuckDB	3,46 / 3,12 / 3,03	3,46	3,12	6,26	135 (tiền trình)
Spark DataFrame	11,58 / 6,86 / 6,17	11,58	6,86	2,85	760 (JVM) + 54
Spark SQL	11,22 / 7,23 / 6,26	11,22	7,23	2,71	770 (JVM) + 54

Nguồn: t62_spark_engine.csv.



Hình 5.1. Thời gian truy vấn của DuckDB và Spark: một tháng (trái) và theo khối lượng dữ liệu (phải)

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Ba bộ máy cho cùng 7.981 nhóm. DuckDB nhanh nhất ở cả lần đầu (3,46 giây) lẫn trung vị (3,12 giây). Spark chậm hơn 2,2 lần theo trung vị và 3,3 lần ở lần đầu. Khoảng cách lớn hơn ở lần đầu phản ánh chi phí khởi động riêng của Spark: biên dịch mã sinh ra từ kế hoạch truy vấn, nạp lớp Java và khởi tạo bộ quản lý bộ nhớ. Về bộ nhớ, JVM của Spark chiếm khoảng 760 MB, gấp 5,6 lần tiến trình DuckDB.

Spark DataFrame và Spark SQL cho thời gian gần như trùng nhau (6,86 và 7,23 giây). Đây là điều lý thuyết dự đoán: cả hai cách viết đều được Catalyst dịch về cùng một cây kế hoạch logic, tối ưu bằng cùng bộ quy tắc và sinh cùng một kế hoạch vật lý. Lựa chọn giữa SQL và DataFrame vì vậy là lựa chọn về khả năng bảo trì mã, không phải về hiệu năng.

5.3.2. Mở rộng theo khối lượng dữ liệu

Bảng 5.7. Thời gian truy vấn theo số tháng HVFHV năm 2025

Bộ máy	Số tháng	Triệu dòng	Lần 1 (s)	Trung vị (s)	Triệu dòng/giây	Bộ nhớ đỉnh (MB)
DuckDB	1	19,6	3,09	2,46	7,94	127
DuckDB	2	38,1	5,06	5,61	6,79	141
DuckDB	3	57,7	9,54	9,29	6,20	170
DuckDB	4	76,5	11,82	11,82	6,48	185
DuckDB	6	115,6	18,33	18,33	6,31	226
Spark DataFrame	1	19,6	13,34	7,67	2,55	786
Spark DataFrame	2	38,1	16,35	11,04	3,45	939
Spark DataFrame	3	57,7	27,47	17,07	3,38	799
Spark DataFrame	4	76,5	29,95	23,37	3,27	832
Spark DataFrame	6	115,6	46,89	42,51	2,72	918

Nguồn: *t64_spark_scale.csv*. Bộ nhớ của Spark là JVM, của DuckDB là tiến trình.

Khi khối lượng tăng từ 1 lên 6 tháng (từ 19,6 lên 115,6 triệu dòng), thời gian của cả hai bộ máy tăng gần tuyến tính. Hồi quy tuyến tính thời gian trung vị theo số triệu dòng cho hệ số góc 0,164 giây trên một triệu dòng với DuckDB và 0,367 giây với Spark. Nói cách khác, chi phí biên của Spark cao hơn khoảng 2,2 lần. Ở mức 6 tháng, DuckDB cần 18,3 giây và Spark cần 42,5 giây.

Bộ nhớ cho thấy khác biệt về thiết kế. Bộ nhớ của DuckDB tăng dần theo khối lượng (từ 127 lên 226 MB), trong khi bộ nhớ JVM của Spark gần như không đổi quanh 855 MB. Spark cấp phát một vùng nhớ cố định theo cấu hình ngay từ đầu và xử lý dữ liệu theo từng phân vùng tệp, nên bộ nhớ phụ thuộc vào cấu hình hơn là vào khối lượng. DuckDB cấp phát theo nhu cầu, nhỏ hơn nhiều ở khối lượng nhỏ nhưng vẫn tăng theo số nhóm trong bảng băm.


Trên một nút, Spark không có lợi thế nào về tốc độ. Lợi thế của nó chỉ xuất hiện khi thêm nút: vì thời gian tăng tuyến tính theo dữ liệu và công việc được chia thành các tác vụ độc lập theo tệp, về nguyên tắc có thể giảm thời gian gần tỷ lệ với số nút, trong khi DuckDB bị giới hạn ở tài nguyên của một máy. Đồ án không có cụm để kiểm chứng điều này, nên chỉ nêu như một dự đoán dựa trên cấu trúc tác vụ.

5.4. Xáo trộn dữ liệu và thực thi truy vấn thích nghi

Bảng 5.8. Thời gian truy vấn theo số phân vùng xáo trộn, có và không có AQE

Số phân vùng xáo trộn	Tắt AQE: trung vị (s)	Tắt AQE: lần 1 (s)	Bật AQE: trung vị (s)	Bật AQE: lần 1 (s)
1	7,76	10,50	7,59	11,32
2	6,63	11,14	6,66	11,04
4	7,25	10,64	7,38	10,64
8	7,60	11,13	7,63	10,61
16	7,32	11,66	6,27	11,25
32	6,56	11,26	6,41	11,05
64	7,84	12,26	7,26	10,71
200	8,41	13,51	6,60	11,09
1.000	14,33	21,99	7,54	11,25

Nguồn: t63_spark_shuffle.csv.



Hình 5.2. Ảnh hưởng của số phân vùng xáo trộn đến thời gian truy vấn khi bật và tắt AQE

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Truy vấn tổng hợp trong Spark được thực hiện qua hai giai đoạn. Giai đoạn một tổng hợp cục bộ trong từng tác vụ đọc tệp. Giai đoạn hai chia kết quả trung gian theo giá trị băm của khóa nhóm thành một số phân vùng xáo trộn, ghi xuống đĩa, rồi các tác vụ của giai đoạn sau đọc lại và tổng hợp lần cuối. Số phân vùng xáo trộn là một tham số mà người dùng phải chọn. Quá ít phân vùng làm mỗi tác vụ quá lớn; quá nhiều phân vùng tạo ra hàng nghìn tác vụ nhỏ, mỗi tác vụ tốn chi phí lập lịch và mở tệp cố định.

Khi tắt AQE, thời gian thấp nhất đạt ở 32 phân vùng (6,56 giây). Từ 64 phân vùng trở lên, thời gian tăng rõ: ở 200 phân vùng, giá trị mặc định của Spark, trung vị là 8,41 giây, và ở 1.000 phân vùng, thời gian lên 14,33 giây, gấp 2,2 lần mức tốt nhất.

Kết quả trung gian của truy vấn này rất nhỏ (vài nghìn nhóm), nên gần như toàn bộ chi phí thêm là chi phí quản lý tác vụ.


Khi bật AQE, đường thời gian gần như phẳng: từ 1 đến 1.000 phân vùng, trung vị nằm trong khoảng 6,27 đến 7,63 giây. Cơ chế nằm ở toán tử AQEShuffleRead trong kế hoạch vật lý (mục 5.6): sau khi giai đoạn một kết thúc, Spark đọc thống kê kích thước thật của từng phân vùng xáo trộn và gộp các phân vùng nhỏ lại trước khi chạy giai đoạn hai. Tham số do người dùng đặt trở thành giới hạn trên thay vì số tác vụ thật. Với người phân tích, hàm ý thực tiễn là khi dùng Spark 3 trở lên thì nên bật AQE và không cần tinh chỉnh số phân vùng xáo trộn cho từng truy vấn.

5.5. Lưu đệm trong bộ nhớ và phá hệ của phép biến đổi

Bảng 5.9. Thời gian ba truy vấn trước và sau khi lưu đệm DataFrame một tháng HVFHV (trung vị 2 lần)

Truy vấn	Đọc lại từ Parquet (s)	Từ bộ đệm (s)	Chênh lệch (s)
vùng×ngày	3,18	1,71	1,46
nhóm×giờ	1,48	2,34	-0,86
OD	2,41	2,04	0,37

Nguồn: *t65_spark_cache.csv*.



Hình 5.3. Thời gian truy vấn khi đọc lại từ Parquet và khi đọc từ bộ đệm trong bộ nhớ

Nguồn: *kết quả tính toán của tác giả từ dữ liệu NYC TLC*.

Nguyên lý tính toán trong bộ nhớ ở mục 3.1 của bài giảng gợi ý rằng giữ dữ liệu trong RAM sẽ làm các truy vấn lặp lại nhanh hơn nhiều. Thực nghiệm lưu đệm (persist với mức MEMORY_AND_DISK) mười cột của tháng 03/2025 cho kết quả khác kỳ vọng. Việc vật chất hóa bộ đệm mất 22,3 giây và chiếm 380,4 MB trong bộ nhớ, không tràn xuống đĩa. Sau đó, ba truy vấn chỉ nhanh hơn tổng cộng 0,98 giây, và truy

vấn nhóm × giờ còn chậm hơn khi đọc từ bộ đệm. JVM đạt đỉnh 1.602 MB, cao gấp đôi so với khi không lưu đệm.

Lý do là điểm xuất phát đã rất nhanh. Parquet ZSTD là định dạng cột nén tốt, bộ đọc vector hóa của Spark giải nén theo lô, và sau lần đọc đầu các tệp đã nằm trong bộ đệm trang của hệ điều hành. Bộ đệm của Spark lưu dữ liệu ở dạng cột trong bộ nhớ với nén nhẹ, nên việc quét nó không rẻ hơn bao nhiêu so với giải nén Parquet từ bộ đệm trang, trong khi áp lực bộ nhớ lên JVM tăng. Lưu đệm có lợi rõ khi phép tính tạo ra DataFrame tốn kém (nhiều phép nối, hàm do người dùng định nghĩa) hoặc khi cùng dữ liệu được quét hàng chục lần, như trong các thuật toán học máy lặp. Với các truy vấn quét đơn giản trên Parquet, như phần lớn công việc của đồ án, nó không đáng chi phí.

Thực nghiệm này cũng cho phép quan sát trực tiếp khái niệm phả hệ (lineage) của Spark. Mỗi DataFrame giữ chuỗi phép biến đổi từ tệp nguồn. Khi một phân vùng bộ đệm bị mất, Spark không cần bản sao mà tính lại phân vùng đó theo chuỗi này. Đoạn trích dưới đây là phả hệ RDD của truy vấn vùng × ngày, do chính Spark in ra: tác vụ đọc tệp (FileScanRDD) ở đáy, các phép chiếu và tổng hợp cục bộ, ranh giới xáo trộn (ShuffledRowRDD, đánh dấu bằng thực thể) và tổng hợp cuối.

```
(1) MapPartitionsRDD[150] at javaToPython at NativeMethodAccessorImpl.java:0 []
| MapPartitionsRDD[149] at javaToPython at NativeMethodAccessorImpl.java:0 []
| SQLExecutionRDD[148] at javaToPython at NativeMethodAccessorImpl.java:0 []
| MapPartitionsRDD[147] at javaToPython at NativeMethodAccessorImpl.java:0 []
| ShuffledRowRDD[146] at javaToPython at NativeMethodAccessorImpl.java:0 []
+- (5) MapPartitionsRDD[145] at javaToPython at NativeMethodAccessorImpl.java:0 []
| MapPartitionsRDD[144] at javaToPython at NativeMethodAccessorImpl.java:0 []
| MapPartitionsRDD[143] at javaToPython at NativeMethodAccessorImpl.java:0 []
| MapPartitionsRDD[142] at javaToPython at NativeMethodAccessorImpl.java:0 []
| MapPartitionsRDD[141] at javaToPython at NativeMethodAccessorImpl.java:0 []
| * (1) Project [d#23, hr#24, pu#5, dl#6, pu_grp#28, do_grp#29, fare#9, miles#7, time_s#8,
wait_min#26]
+- * (1) ColumnarToRow
+ FileScan parquet
[pu#5,dl#6,miles#7,time_s#8,fare#9,d#23,hr#24,wait_min#26,pu_grp#28,do_grp#29,service#0
MapPartitionsRDD[66] at count at NativeMethodAccessorImpl.java:0 []
| CachedPartitions: 5; MemorySize: 380.4 MiB; DiskSize: 0.0 B
| MapPartitionsRDD[65] at count at NativeMethodAccessorImpl.java:0 []
```

5.6. Cắt tỉa phân vùng, đẩy điều kiện lọc và kế hoạch thực thi

Bảng 5.10. Tác động của cắt tỉa phân vùng kiểu Hive và đẩy điều kiện lọc trong Spark

Điều kiện lọc	Tệp quét	Phân vùng	Dung lượng tệp (MB)	Dòng đọc ra	Thời gian (s)
toàn bộ Silver (không lọc)	120	48	16.019,1	544.311.785	39,18
service='hvfhv'	96	24	14.146,3	461.438.058	30,13
service='hvfhv' AND year=2025	48	12	7.131,3	232.106.815	15,29
service='hvfhv' AND year=2025 AND month=3	4	1	601,6	19.564.232	1,40
lọc theo cột d (không phải khóa phân vùng)	120	48	16.019,1	23.353.605	7,40

Nguồn: t66_spark_pruning.csv; số tệp và số dòng đọc từ số liệu của toán tử quét trong kế hoạch vật lý đã thực thi.

Lớp Silver được tổ chức theo thư mục service=/year=/month=. Spark tự nhận các cấp thư mục này thành cột phân vùng khi đọc. Khi điều kiện lọc chỉ dùng cột phân vùng, Spark loại các thư mục không phù hợp ngay ở bước lập danh sách tệp, trước khi mở bất kỳ tệp nào. Kết quả đo khớp chính xác với cấu trúc thư mục: lọc theo dịch vụ còn 96 tệp, thêm năm còn 48 tệp, thêm tháng còn 4 tệp của một phân vùng. Thời gian giảm từ 39,2 giây xuống 1,40 giây.

Dòng cuối của bảng cho thấy một cơ chế khác. Điều kiện lọc trên cột ngày d không phải là cột phân vùng, nên Spark vẫn phải xét cả 120 tệp. Tuy vậy, số dòng thật sự được đọc ra chỉ là 23.353.605, đúng bằng số chuyển trong tháng 03/2025 của hai dịch vụ, và thời gian chỉ 7,4 giây. Nguyên nhân là đẩy điều kiện lọc xuống bộ đọc Parquet: bộ đọc so điều kiện với thống kê min/max của cột d trong chân mỗi nhóm dòng và bỏ qua các nhóm dòng không thể chứa ngày tháng 3. Vì mỗi tệp Silver chỉ chứa chuyển của đúng một tháng, mọi nhóm dòng của các tháng khác đều bị bỏ qua, nên số dòng đọc ra trùng khớp với số chuyển của tháng 03/2025. Cột dung lượng trong bảng là kích thước danh nghĩa của các tệp được xét, không phải số byte thật sự đọc. Đây là cùng cơ chế đã quan sát với DuckDB ở mục 4.1.3, và cho thấy cách tổ chức dữ liệu khi ghi quyết định hiệu quả của truy vấn khi đọc.

Kế hoạch vật lý dạng rút gọn của truy vấn có lọc theo tháng được trình bày dưới đây. Có thể đọc thấy toàn bộ những gì chương này đã đo: điều kiện phân vùng được đẩy vào bước quét (PartitionFilters), chỉ hai cột cần dùng được đọc (ReadSchema), tổng hợp được chia thành tổng hợp cục bộ và tổng hợp cuối quanh bước xáo trộn (Exchange), và AQE thay kế hoạch ban đầu bằng kế hoạch cuối có bước gộp phân vùng (AQEShuffleRead: coalesced). Các toán tử có dấu sao được gộp vào một hàm Java sinh tự động (whole-stage code generation) thay vì gọi từng toán tử qua giao diện lập.

```
== Physical Plan ==
AdaptiveSparkPlan (13)
+- == Final Plan ==
   * HashAggregate (8)
   +- AQEShuffleRead (7)
      +- ShuffleQueryStage (6), Statistics(sizeInBytes=40.5 KiB, rowCount=1.30E+3)
         +- Exchange (5)
            +- * HashAggregate (4)
               +- * Project (3)
                  +- * ColumnarToRow (2)
                     +- Scan parquet (1)
+- == Initial Plan ==
   HashAggregate (12)
```

```

+- Exchange (11)
  +- HashAggregate (10)
    +- Project (9)
      +- Scan parquet (1)

(1) Scan parquet
Batched: true
PartitionFilters: [isnotnull(service#0), isnotnull(year#32), isnotnull(month#33), (service#0 = hvfhv), (year#32 = 2025), (month#33 = 3)]
ReadSchema: struct<pu:int,fare:double>
(7) AQEShuffleRead
Arguments: coalesced

```

5.7. Trao đổi dữ liệu giữa Spark và Python qua Apache Arrow

Bảng 5.11. Thời gian chuyển một DataFrame Spark sang pandas

Cấu hình	Số dòng × cột	Trung vị (s)	Nhanh nhất – chậm nhất (s)
Không dùng Arrow (tuần tự hóa từng dòng)	2.004.221 × 8	23,48	22,11 – 40,46
Dùng Arrow (truyền theo lô cột)	2.004.221 × 8	3,10	1,50 – 4,46

Nguồn: *t66b_spark_arrow.csv*.

Khi phân tích bằng PySpark, kết quả thường phải được chuyển từ JVM sang Python để vẽ hình hoặc ước lượng mô hình. Mục 3.4 của bài giảng giới thiệu Apache Arrow như định dạng cột chuẩn trong bộ nhớ để làm việc này. Không có Arrow, Spark tuần tự hóa từng dòng bằng pickle, gửi qua socket và Python dựng lại từng đối tượng. Có Arrow, dữ liệu được gửi theo lô cột nhị phân mà pandas đọc trực tiếp. Với 2.004.221 dòng tám cột, thời gian giảm từ 23,5 giây xuống 3,1 giây, nhanh hơn 7,6 lần.

Đây là khác biệt lớn nhất trong mọi thực nghiệm của chương, và nó không nằm ở bộ máy tính toán mà ở ranh giới giữa hai môi trường chạy. Trong thực tế, nhiều pipeline PySpark chậm không phải vì Spark chậm mà vì chuyển dữ liệu qua ranh giới JVM – Python không có Arrow, hoặc vì dùng hàm do người dùng định nghĩa bằng Python chạy từng dòng.

5.8. Xử lý luồng có cấu trúc để giám sát chính sách

5.8.1. Thiết kế

Mục 2.4.7 đã nêu rằng nếu cơ quan quản lý muốn giám sát chính sách hằng ngày, kiến trúc cần một nhánh xử lý luồng. Thực nghiệm này dựng nhánh đó bằng Spark Structured Streaming. Hai tuần dữ liệu HVFHV từ 29/12/2024 đến 11/01/2025, bao quanh ngày bắt đầu thu phí, được tách thành 14 tệp theo ngày và đặt vào một thư mục hạ cánh. Luồng đọc thư mục này với `maxFilesPerTrigger = 1`, nên mỗi tệp là một lô vi mô, mô phỏng tình huống mỗi ngày nền tảng gửi lên một tệp.


Phép tính trên luồng là tổng hợp theo cửa sổ một giờ của thời điểm đón (thời gian sự kiện, không phải thời gian xử lý) và theo hãng: số chuyến, số chuyến chạm CRZ, số chuyến có phí CBD, tổng phí, quãng đường và thời lượng. Mốc nước (watermark) được đặt hai giờ: một cửa sổ chỉ được phát ra khi thời gian sự kiện lớn nhất đã đi qua điểm kết thúc cửa sổ hơn hai giờ, và dữ liệu đến muộn hơn mức này bị bỏ. Kết quả được ghi ở chế độ append ra Parquet, trạng thái và vị trí đọc được ghi vào thư mục checkpoint, nên luồng có thể dừng và chạy tiếp mà không tính trùng.

5.8.2. Kết quả

Bảng 5.12. Số liệu của từng lô vi mô trong Structured Streaming

Lô	Dòng vào	Thời gian lô (ms)	Trong đó addBatch (ms)	Dòng/giây	Mốc nước sau lô	Dòng trạng thái
0	518.769	5.140	3.828	100.889	chưa có	48
1	500.609	2.519	2.254	198.733	2024-12-29 21:59	54
2	674.345	2.529	2.275	266.645	2024-12-30 21:59	54
3	631.016	1.012	817	623.534	2024-12-31 21:59	54
4	508.544	953	733	533.624	2025-01-01 21:59	54
5	590.301	911	728	647.970	2025-01-02 21:59	54
6	646.880	923	779	700.845	2025-01-03 21:59	54
7	562.005	851	658	660.405	2025-01-04 21:59	54
8	542.445	761	609	712.806	2025-01-05 21:59	54
9	585.665	811	647	722.152	2025-01-06 21:59	54
10	616.238	741	608	831.630	2025-01-07 21:59	54
11	660.239	722	580	914.458	2025-01-08 21:59	54
12	687.860	758	613	907.467	2025-01-09 21:59	54
13	725.720	667	559	1.088.036	2025-01-10 21:59	54


Nguồn: t67_stream_batches.csv (từ StreamingQueryProgress của Spark).



Hình 5.4. Thời gian xử lý và số dòng của từng lô vi mô

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Luồng xử lý 8.450.636 dòng trong 14 lô, tổng thời gian thực 20,3 giây. Lô đầu mất 5,14 giây vì phải biên dịch kế hoạch và khởi tạo kho trạng thái; từ lô thứ tư trở đi, mỗi lô khoảng 614.265 dòng chỉ mất trung bình 0,83 giây, thông lượng tăng dần đến 1.088.036 dòng mỗi giây ở lô cuối nhờ JVM đã tối ưu mã nóng. Kho trạng thái chỉ giữ 54 dòng, tức các cửa sổ giờ chưa đóng của ba hãng, và dùng dưới 0,03 MB. Mốc nước tăng đều mỗi lô đúng một ngày, trễ hai giờ so với thời điểm đón muộn nhất của ngày trước đó.



Hình 5.5. Các cửa sổ 1 giờ do Structured Streaming phát ra quanh ngày bắt đầu thu phí
Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Hình 5.5 là đầu ra của luồng, không phải của một phép tính theo lô sau đó. Trước 23:00 ngày 04/01/2025, tỷ lệ chuyển có phí CBD gần như bằng 0 ở mọi giờ (tối đa 0,003%); riêng cửa sổ 23:00–24:00 ngày 04/01 có 2,5%, là các chuyển đón trước nửa đêm nhưng đi vào vùng sau thời điểm bắt đầu thu phí. Ngay trong cửa sổ đầu tiên sau nửa đêm ngày 05/01, tỷ lệ này nhảy lên 38,4% và dao động trong khoảng 24,5% đến 44,5% trong những ngày sau. Một hệ thống giám sát đọc luồng này sẽ ghi nhận việc chính sách bắt đầu có hiệu lực trong vòng một chu kỳ lô.

Trong triển khai thật, thư mục hạ cánh sẽ được thay bằng một hàng đợi thông điệp như Kafka, và lô vi mô có thể ngắn đến vài giây. Logic phép tính không đổi. Điểm quan trọng về kiến trúc là các chỉ tiêu tính trên luồng đều là đại lượng cộng được, cùng dạng với các bảng Gold, nên kết quả luồng có thể ghi thẳng vào lớp Gold

và được ước lượng nhân quả định kỳ trên cùng một định nghĩa. Đây là cách hợp nhất xử lý lô và luồng mà mục 3.3 của bài giảng mô tả với Flink; Structured Streaming đạt được cùng mục tiêu bằng cách coi luồng là một bảng tăng dần.

5.9. Thảo luận: chọn công cụ theo quy mô

Tổng hợp các thực nghiệm, trên một máy 2 lõi, 3 GB RAM và khoảng nửa tỷ dòng, DuckDB nhanh hơn Spark khoảng 2,2 lần về chi phí biên, dùng ít bộ nhớ hơn nhiều ở khối lượng nhỏ, và không có chi phí khởi động JVM. Đây là kết quả đúng với lý thuyết: Spark được thiết kế để chia việc trên nhiều nút và chịu lỗi khi một nút hỏng, và cái giá của thiết kế đó là chi phí cố định cho mỗi tác vụ, cho mỗi lần xáo trộn và cho việc chạy trên JVM. Trên một nút, cái giá này không được bù lại.

Tuy vậy, kết luận "không cần Spark" là quá vội. Chương này cho thấy ba vai trò mà Spark đảm nhận tốt ngay cả ở quy mô này. Vai trò thứ nhất là kiểm toán: bản tái lập độc lập phát hiện một lỗi ép kiểu mà không phép kiểm tra nào khác phát hiện. Vai trò thứ hai là đường nâng cấp: cùng mã SQL chạy được trên cụm khi dữ liệu mở rộng sang toàn bộ lịch sử TLC hoặc khi cần xử lý đồng thời cho nhiều người dùng, với hành vi đã được kiểm chứng trên dữ liệu nhỏ. Vai trò thứ ba là xử lý luồng có trạng thái với bảo đảm chạy tiếp sau sự cố, điều DuckDB không được thiết kế để làm.

Mục 3.5 của bài giảng còn nêu Ray và Dask như các lựa chọn phân tán gần với Python hơn. Đồ án không đo hai công cụ này, nhưng các kết quả trên cho phép dự đoán vị trí của chúng: vì chi phí trong bài toán này chủ yếu nằm ở quét và tổng hợp dữ liệu dạng bảng, một bộ máy có tối ưu truy vấn và đọc Parquet vector hóa sẽ có lợi thế; lợi thế của Ray nằm ở các tác vụ tính toán không đồng dạng như huấn luyện nhiều mô hình song song, chẳng hạn bước cross-fitting của DML ở Chương 4.

Hàm ý cho thực hành trong doanh nghiệp là quy tắc chọn công cụ dựa trên ba ngưỡng đo được, không dựa trên thói quen: dữ liệu cần xử lý trong một lần có vượt khả năng của một máy (kể cả khi đã tận dụng tràn đĩa) hay không; có yêu cầu chịu lỗi và chạy liên tục hay không; và có nhiều người dùng đồng thời hay không. Với bài toán của đồ án, chỉ ngưỡng thứ hai được đáp ứng, và chỉ cho nhánh luồng.

5.10. Tiểu kết Chương 5

Chương 5 đã đưa Apache Spark vào pipeline như bộ máy thứ hai. Spark tái lập toàn bộ bảng `zone_day_pu` từ 544.311.785 dòng Silver trong vài phút; phép đối chứng từng ô phát hiện và giúp sửa một lỗi ép kiểu im lặng ở bước hợp nhất Gold. Trên cùng phần cứng một nút, Spark chậm hơn DuckDB và tốn bộ nhớ hơn, nhưng các cơ chế của nó hoạt động đúng như lý thuyết: Catalyst cho cùng kế hoạch với SQL và DataFrame, AQE loại bỏ gần hết tác động của việc chọn sai số phân vùng xáo trộn, cắt tĩa phân vùng giảm số tệp quét từ 120 xuống 4, Arrow rút ngắn việc chuyển dữ liệu sang pandas 7,6 lần, và Structured Streaming phát hiện thời điểm chính sách có hiệu lực ngay trong lô đầu sau đó. Lưu đệm là ngoại lệ: với Parquet nén trên đĩa cục bộ, nó không đáng chi phí.

CHƯƠNG 6. QUẢN TRỊ DỮ LIỆU, QUYỀN RIÊNG TƯ VÀ QUẢN TRỊ RỦI RO

Một pipeline cho kết quả đúng hôm nay chưa đủ để được tin dùng lâu dài. Người dùng kết quả cần biết dữ liệu nào nằm ở đâu, được tạo ra từ đâu, có bị thay đổi không, chất lượng có ổn định không, và việc công bố nó có gây hại cho ai không. Chương 2 và Chương 7 của bài giảng gọi chung các câu hỏi này là quản trị dữ liệu và quản trị rủi ro. Chương này trả lời chúng trên chính tài sản dữ liệu của đồ án, bằng các phép đo có thể chạy lại, thay vì chỉ mô tả khung lý thuyết.

Câu hỏi nghiên cứu tương ứng là RQ7: tài sản dữ liệu của đồ án có những rủi ro nào về tính toàn vẹn, chất lượng và quyền riêng tư, và có thể công bố dữ liệu tổng hợp theo cách bảo vệ quyền riêng tư mà vẫn giữ được kết luận chính sách hay không. Bảng 6.1 đối chiếu từng chủ đề của bài giảng với phần triển khai trong chương.

Bảng 6.1. Đối chiếu chủ đề quản trị dữ liệu và rủi ro của bài giảng với phần triển khai

Chủ đề bài giảng	Triển khai trong đồ án	Mục	Kết quả
2.6 Metadata và Data Catalog	Danh mục dữ liệu tự động cho ba lớp, dấu vân tay lược đồ	6.1	t68
2.6 Metadata (phả hệ)	Phả hệ trích tự động từ mã nguồn: bước nào đọc, ghi bảng nào	6.2	t69, hình phả hệ
7.5 Bảo vệ chuỗi cung ứng số	Băm SHA-256 mọi tệp nguồn; kiểm tra lại ngẫu nhiên	6.3	t70
2.7 Kiểm soát chất lượng	Đối soát số dòng giữa các lớp; biểu đồ kiểm soát tỷ lệ loại	6.4	t71, t72d
7.2 Phát hiện bất thường tự động	Ngày bất thường theo z-score bền vững	6.5	t72
7.1 Phát hiện gian lận	Chuyển bất thường: Isolation Forest và quy tắc nghiệp vụ	6.6	t73
2.8 Quyền riêng tư và tuân thủ	Đo rủi ro tái nhận dạng bằng k-ẩn danh	6.7	t74
2.8 Quyền riêng tư (công nghệ)	Quyền riêng tư vi phân cho bảng công bố, đo ảnh hưởng tới DiD	6.8	t75
7.4, 7.7 Zero Trust và phục hồi	Thời gian dựng lại từng lớp (RTO) đo từ nhật ký	6.9	t76
7.8 Khung quản trị rủi ro	Số đăng ký rủi ro dựa trên bảng chứng của chương	6.10	Số đăng ký rủi ro

Nguồn: tác giả tổng hợp.

6.1. Danh mục dữ liệu và siêu dữ liệu

Bảng 6.2. Danh mục dữ liệu của đồ án, tạo tự động từ siêu dữ liệu Parquet

Lớp	Tập dữ liệu	Tệp	Số dòng	Cột	Nhóm dòng	MB	Vân tay lược đồ
Bronze	fhvhv_tripdata_2024-*	12	239.470.448	24	236	5.508,5	cc5218a0b9
Silver	service=hvhv/year=2024	48	229.331.243	32	270	7.015,0	9f87dd8d01

Lớp	Tập dữ liệu	Tệp	Số dòng	Cột	Nhóm dòng	MB	Vân tay lược đồ
Bronze	fhvhv_tripdata_2025-*	12	243.589.684	25	238	5.683,2	fefb24f298
Silver	service=hvhv/year=2025	48	232.106.815	32	264	7.131,3	a0d5ac3dc9
Bronze	yellow_tripdata_2024-*	12	41.169.720	19	44	660,9	c15873e78e
Silver	service=yellow/year=2024	12	39.183.528	32	47	873,9	eed64b69bd
Bronze	yellow_tripdata_2025-*	12	48.722.602	20	53	791,5	483751328d
Silver	service=yellow/year=2025	12	43.690.199	32	52	998,9	2e6c46de6d
Gold	company_grp_day	1	54.825	19	1	2,6	07ec6f751e
Gold	dim_zone	1	265	17	1	0,0	23a0dae5a2
Gold	dml_od_dataset	1	9.280	36	1	1,5	200e385a2c
Gold	grp_hour_day	1	859.415	19	7	29,4	dbf4b340d5
Gold	od_month	1	2.230.151	18	19	64,7	17135dbd66
Gold	trip_sample	1	1.974.894	34	17	62,3	8d0689e210
Gold	zone_day_do	1	370.868	18	4	14,4	6375ac9537
Gold	zone_day_pu	1	358.148	20	3	14,3	3c100d0bfc
Gold	zone_hour_month	1	281.102	18	3	9,9	d9a3099448
Gold	zone_polygons	1	49.189	5	1	0,8	b71cabf3ad


Nguồn: *t68_data_catalog.csv*.

Danh mục được dựng bằng cách đọc chân tệp Parquet, không mở dữ liệu, nên chạy trong vài giây cho cả 28,2 GB. Mỗi dòng ghi số tệp, số dòng, số cột, số nhóm dòng, dung lượng và một dấu vân tay lược đồ, là mã băm của danh sách tên và kiểu cột. Ba lớp có quy mô rất khác nhau: Bronze 572.952.454 dòng, Silver 544.311.785 dòng sau khi loại bản ghi lỗi, Gold chỉ 6.188.137 dòng. Lớp Gold chiếm 1,6% dung lượng của Bronze nhưng chứa mọi thông tin mà các phân tích nhân quả cần.

Dấu vân tay lược đồ cho phép phát hiện lệch lược đồ tự động. Ở lớp Bronze, mỗi nguồn có đúng hai lược đồ, tách chính xác tại ranh giới 2024/2025 do cột *cbd_congestion_fee* được thêm vào. Ở lớp Silver, mọi phân vùng có cùng số cột nhưng dấu vân tay vẫn khác nhau giữa các năm. Chính khác biệt này, cụ thể là kiểu của cột phí (DECIMAL ở năm 2024, số thực ở năm 2025), là gốc của lỗi ép kiểu phát hiện ở mục 5.2. Nói cách khác, danh mục đã chứa sẵn tín hiệu cảnh báo; điều còn thiếu là một quy tắc tự động buộc các phân vùng của cùng một bảng phải có cùng dấu vân tay. Đây là một ví dụ cụ thể cho luận điểm của mục 2.6 bài giảng rằng danh mục dữ liệu chỉ có giá trị khi được gắn với kiểm tra tự động.

6.2. Phả hệ dữ liệu

Phả hệ dữ liệu trích tự động từ mã nguồn



Hình 6.1. Phả hệ dữ liệu của đồ án: từ Bronze, Silver, các bảng Gold đến từng bước phân tích và sản phẩm

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Phả hệ được trích tự động từ mã nguồn của 17 bước: với mỗi tệp mã, chương trình tìm tên các bảng Gold được nhắc đến (trực tiếp hoặc qua mô-đun panels.py), các tệp bảng kết quả được ghi (tiền tố tNN) và các hình được lưu (tiền tố fNN). Tổng cộng các bước tạo ra 104 tệp bảng và 47 hình. Cách trích này không hoàn hảo, vì nó dựa trên tên chứ không dựa trên thực thi, nhưng có ưu điểm là luôn cập nhật theo mã mà không cần người khai báo.

Giá trị thực tiễn của phả hệ thể hiện khi có sự cố. Khi lỗi ép kiểu ở bước 04 được phát hiện, câu hỏi đầu tiên là những kết quả nào bị ảnh hưởng. Theo phả hệ, bảng zone_day_pu được 10 bước đọc (03, 06, 07, 08, 09, 10, 11, 14, 15, 16), và các bảng Gold khác chứa cột phí cũng được hợp nhất ở cùng bước. Vì vậy toàn bộ các bước từ

06 đến 14 được chạy lại, rồi bước 15b so từng tệp bảng kết quả với bản chụp trước khi sửa: trong 66 tệp được so, chỉ 5 tệp thay đổi (a01_zone_detail, a02_month_group_detail, t16_cbd_revenue_by_month, t27_desc_by_group_year_yellow, t30_did_main), và các cột thay đổi đều là chỉ tiêu phí CBD hoặc các đại lượng suy ra từ nó (trong t30 là các dòng phí CBD mỗi chuyến của taxi vàng). Không có phả hệ và phép so sánh này, cách an toàn duy nhất là chạy lại mọi thứ mà không biết chắc thay đổi nằm ở đâu.

6.3. Tính toàn vẹn và chuỗi cung ứng dữ liệu

Dữ liệu nguồn của đồ án đến từ một bên thứ ba qua mạng phân phối nội dung. Mục 7.5 của bài giảng xếp loại rủi ro này vào chuỗi cung ứng số: tệp có thể bị hỏng khi tải, bị thay thế bởi phiên bản khác khi nguồn công bố lại, hoặc bị sửa trên máy lưu trữ. Mọi phân tích phía sau đều thừa hưởng rủi ro đó. Biện pháp cơ bản là ghi lại dấu băm mật mã của từng tệp ngay khi nhận và kiểm tra lại trước mỗi lần xử lý.

Đồ án tính SHA-256 cho 50 tệp của lớp Bronze, tổng 12,35 GB, trong 167,7 giây, tức khoảng 75,4 MB mỗi giây, giới hạn bởi tốc độ đọc của ổ đĩa qua lớp chia sẻ thư mục của máy ảo. Việc băm được làm tăng dần, lưu kết quả sau mỗi tệp, nên có thể dừng và chạy tiếp. Ba tệp chọn ngẫu nhiên được băm lại để kiểm tra: yellow_tripdata_2025-07.parquet, fhvhv_tripdata_2025-04.parquet, fhvhv_tripdata_2024-05.parquet; cả ba đều khớp. Danh sách đầy đủ nằm ở Phụ lục H.

Trong một hệ thống vận hành, bản kê dấu băm này đóng vai trò hợp đồng giữa lớp Bronze và các lớp sau: nhật ký của mỗi phân vùng Silver nên ghi dấu băm của tệp nguồn đã dùng, để khi nguồn thay đổi thì biết chính xác phân vùng nào cần xử lý lại. Đây cũng là cách các định dạng bảng giao dịch như Delta Lake và Iceberg ghi nhận phiên bản dữ liệu, chỉ khác ở mức chi tiết.


6.4. Đối soát giữa các lớp và giám sát chất lượng

6.4.1. Đối soát số dòng

Với mỗi trong 48 phân vùng tháng-dịch vụ, đồ án kiểm tra ba đẳng thức: số dòng trong siêu dữ liệu tệp Bronze bằng số dòng mà bước 03 đã đọc; số dòng đã đọc bằng số dòng bị loại cộng số dòng vào Silver; và số dòng Silver ghi trong nhật ký bằng số dòng trong siêu dữ liệu các tệp Silver. Kết quả: 48/48, 48/48 và 48/48 phân vùng đạt.

Không có bản ghi nào bị mất hoặc bị đếm hai lần giữa các lớp, kể cả khi mỗi tháng HVFHV được xử lý thành bốn khúc riêng.


6.4.2. Biểu đồ kiểm soát tỷ lệ loại bỏ



01/2025, trùng với thời điểm có phí. Đồ án không xác định được nguyên nhân từ dữ liệu, nhưng hàm ý đối với phân tích nhân quả là rõ: nếu bản ghi bị loại khác nhau giữa vùng xử lý và vùng đối chứng, mẫu Silver của taxi vàng năm 2025 có thể bị chọn lọc theo cách tương quan với chính sách. Đây là một lý do nữa, bên cạnh những lý do đã nêu ở mục 4.13, để coi kết quả của taxi vàng là kém chắc chắn hơn HVFHV.

6.5. Phát hiện ngày bất thường

Giám sát chất lượng ở mức bản ghi không phát hiện được các vấn đề ở mức tổng hợp, chẳng hạn một ngày thiếu dữ liệu vì lỗi truyền tệp, hoặc một ngày có lưu lượng bất thường vì sự kiện bên ngoài. Mục 7.2 của bài giảng đề xuất phát hiện bất thường tự động cho mục đích này. Đồ án dùng một phương pháp đơn giản, minh bạch và bền vững ngoại lai: với mỗi ngày và mỗi nhóm vùng, giá trị kỳ vọng của log số chuyển là trung vị của các ngày cùng thứ trong cửa sổ ± 28 ngày (không gồm chính ngày đó), thang đo là độ lệch tuyệt đối trung vị (MAD) nhân 1,4826, và ngày có $|z| > 3,5$ được đánh dấu.



Hình 6.3. Số chuyển HVFHV đón trong CRZ theo ngày, giá trị kỳ vọng và các ngày bất thường

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Bảng 6.3. Số ngày bất thường theo dịch vụ và nhóm vùng, 2024–2025

Dịch vụ	Nhóm vùng	Số ngày	Bất thường	Thấp bất thường	Cao bất thường
HVFHV	Sân bay	731	52	21	31
HVFHV	CRZ	731	61	49	12
HVFHV	Manhattan phía bắc	731	51	31	20
HVFHV	Quận ngoài	731	54	28	26
Taxi vàng	Sân bay	731	49	23	26
Taxi vàng	CRZ	731	56	51	5
Taxi vàng	Manhattan phía bắc	731	55	46	9
Taxi vàng	Quận ngoài	731	48	27	21

Nguồn: *t72c_anomaly_summary.csv*.

Bảng 6.4. Hai mươi ngày bất thường nhất của số chuyến HVFHV đón trong CRZ

Ngày	Thứ	Số chuyến	Lệch so với kỳ vọng	z bền vững	Ngày lễ liên bang gần nhất
28/05/2024	Thứ Ba	124.234	-19,8%	-19,8	Ngày Tưởng niệm (± 1 ngày)
04/07/2024	Thứ Năm	111.964	-33,6%	-18,4	Ngày Độc lập (04/07)
02/01/2024	Thứ Ba	100.373	-35,6%	-16,1	Năm mới (± 1 ngày)
05/01/2024	Thứ Sáu	152.358	-19,0%	-12,6	
26/11/2025	Thứ Tư	121.309	-25,4%	-11,6	Lễ Tạ ơn (± 1 ngày)
04/07/2025	Thứ Sáu	99.227	-37,2%	-10,5	Ngày Độc lập (04/07)
22/08/2024	Thứ Năm	137.974	-17,6%	-10,3	
14/05/2025	Thứ Tư	188.031	+21,9%	10,2	
05/07/2025	Thứ Bảy	112.256	-33,5%	-9,5	Ngày Độc lập (04/07) (± 1 ngày)
02/07/2024	Thứ Ba	123.464	-19,5%	-9,1	
28/11/2025	Thứ Sáu	113.467	-39,6%	-8,9	Lễ Tạ ơn (± 1 ngày)
27/11/2025	Thứ Năm	96.398	-46,8%	-8,9	Lễ Tạ ơn
27/05/2024	Thứ Hai	116.545	-15,0%	-8,5	Ngày Tưởng niệm
02/01/2025	Thứ Năm	105.010	-39,6%	-8,5	Năm mới (± 1 ngày)
26/12/2025	Thứ Sáu	92.452	-53,6%	-8,2	Giáng sinh (± 1 ngày)
07/07/2024	Chủ nhật	133.235	-13,3%	-7,5	
30/12/2025	Thứ Ba	113.011	-32,7%	-7,1	Kỳ nghỉ cuối năm
05/07/2024	Thứ Sáu	132.121	-25,3%	-6,6	Ngày Độc lập (04/07) (± 1 ngày)
06/07/2024	Thứ Bảy	144.923	-23,0%	-6,5	
04/01/2024	Thứ Năm	133.539	-23,6%	-6,3	

Nguồn: *t72b_anomaly_days_crz.csv*; ngày lễ theo lịch liên bang Hoa Kỳ của pandas.

Trong 731 ngày, phương pháp đánh dấu 61 ngày bất thường với CRZ, phần lớn là thấp bất thường (49 ngày). Trong 20 ngày bất thường nhất, 13 ngày trùng hoặc liền kề ngày lễ liên bang hay kỳ nghỉ cuối năm, như Ngày Độc lập 04/07, Lễ Tạ ơn, Giáng sinh và Ngày Tưởng niệm. Đây là kiểm tra thực tế cho phương pháp: nó tìm lại được các sự kiện đã biết mà không cần được cho biết trước. Ngày 05/01/2025 cũng nằm trong danh sách bất thường thấp.

Tỷ lệ ngày bị đánh dấu khá cao (khoảng 7–8%) vì cửa sổ so sánh chỉ gồm tám ngày cùng thứ, nên MAD ước lượng nhỏ và nhạy, và vì ở đầu năm 2024 cửa sổ bị cắt một phía. Trong vận hành thật, ngưỡng nên được chọn theo chi phí của cảnh báo sai so với cảnh báo bỏ sót, và lịch ngày lễ nên được đưa vào mô hình kỳ vọng. Với phân tích nhân quả, danh sách này có công dụng trực tiếp: nó cho biết các tuần nào có thể làm nhiều panel vùng $\times$ tuần. Vì các ngày lễ rơi vào cùng tuần trong năm ở cả hai năm, đặc tả DDD khử mùa vụ ở Chương 4 đã tự động kiểm soát phần lớn ảnh hưởng này.

6.6. Phát hiện chuyển đi bất thường

Mục 7.1 của bài giảng trình bày phát hiện gian lận trong giao dịch. Với dữ liệu chuyển đi, gian lận có thể là ghi quỹ đường hoặc giá cước sai, chuyển ảo để nhận thưởng, hoặc lỗi thiết bị. Đồ án không có nhãn gian lận, nên bài toán là phát hiện bất thường không giám sát. Isolation Forest (Liu, Ting và Zhou, 2008) được huấn luyện trên 1.145.311 chuyển HVFHV của mẫu 0,25% với tám đặc trưng: log quỹ đường, log thời lượng, log giá cước, log thu nhập tài xế, tốc độ, log giá mỗi dặm, tỷ lệ thu nhập tài xế trên giá và tỷ lệ tip trên giá. Thuật toán cô lập mỗi điểm bằng các phép chia ngẫu nhiên; điểm bất thường là điểm bị cô lập sau ít phép chia. Ngưỡng được đặt để đánh dấu 0,5% chuyển. Việc huấn luyện và chấm điểm mất 26,2 giây.

Bảng 6.5. Quy tắc nghiệp vụ và mức trùng với Isolation Forest


Quy tắc	Số chuyển	% mẫu	% cũng bị Isolation Forest đánh dấu
Thu nhập tài xế > giá cước + tip	132.643	11,581	0,9
Giá cước / dặm > 30 USD	8.748	0,764	10,9
Tip > giá cước	339	0,030	24,5
Tốc độ < 2 dặm/giờ và thời gian > 30 phút	186	0,016	23,7
Cùng vùng đón/trả và quỹ đường > 10 dặm	397	0,035	17,9
Isolation Forest (ngưỡng 0,5%)	5.727	0,500	100,0

Nguồn: *t73_trip_anomaly_rules.csv*.

Bảng 6.6. Trung vị các đặc trưng của chuyến bình thường và bất thường

Đặc trưng	Bình thường	Bất thường
Quãng đường (dặm)	2,84	10,26
Thời lượng (giây)	946,00	2.055,00
Giá cước (USD)	18,87	40,63
Thu nhập tài xế (USD)	14,76	51,25
Tốc độ (dặm/giờ)	11,24	12,73
Giá / dặm (USD)	6,46	8,18
Thu nhập tài xế / giá	0,75	0,75
Tip / giá	0,00	0,19
Thời gian chờ (phút)	4,00	4,33

Nguồn: *t73b_trip_anomaly_profile.csv*.

**Hình 6.4.** Quãng đường và giá cước của chuyến bình thường và chuyến bị Isolation Forest đánh dấu

Nguồn: *kết quả tính toán của tác giả từ dữ liệu NYC TLC*.

Chuyến bị đánh dấu có trung vị quãng đường 10,3 dặm so với 2,8 dặm của chuyến bình thường, giá cước 40,6 so với 18,9 USD, và đặc biệt là tỷ lệ tip 0,19 so với 0,00. Nói cách khác, phần lớn chuyến bất thường là chuyến dài có tip cao, tức nằm ở đuôi của phân phối nhiều chiều, không nhất thiết là gian lận. Các quy tắc nghiệp vụ cụ thể (tip lớn hơn giá, tốc độ gần bằng 0 trong chuyến dài, cùng vùng đón trả nhưng đi xa) trùng với Isolation Forest ở mức 18–25%, cho thấy hai cách tiếp cận bổ sung cho nhau.

Quy tắc đầu tiên trong bảng là một bài học về hiệu nghiệp vụ. Nếu coi "thu nhập tài xế lớn hơn giá cước cộng tip" là dấu hiệu bất thường, 11,6% chuyến sẽ bị đánh dấu, và chỉ 0,9% trong số đó bị Isolation Forest coi là bất thường. Ở New York, thu nhập

tài xế HVFHV được tính theo công thức tối thiểu của TLC dựa trên thời gian và quãng đường, độc lập với giá mà nền tảng thu của khách (mục 2.3.3), nên nền tảng có thể trả tài xế nhiều hơn giá thu ở chuyển ngắn hoặc chuyển có khuyến mãi. Đây là hiện tượng thường xuyên, không phải bất thường. Một hệ thống phát hiện gian lận dựa trên quy tắc viết mà không có kiến thức này sẽ tạo ra hàng chục triệu cảnh báo sai mỗi năm trên toàn bộ dữ liệu.

Tỷ lệ chuyển bất thường tăng sau chính sách ở cả chuyển chạm CRZ (từ 0,55% lên 0,65%) và chuyển không chạm CRZ (từ 0,40% lên 0,50%), với mức tăng gần như bằng nhau. Như vậy, phí không làm thay đổi đáng kể tỷ lệ chuyển bất thường của riêng vùng chịu phí; mức tăng chung phản ánh thay đổi của phân phối chuyển đi giữa hai năm, mà Isolation Forest huấn luyện trên dữ liệu gộp hai năm diễn giải như bất thường.

6.7. Rủi ro tái nhận dạng trong dữ liệu công bố


TLC không công bố định danh hành khách, tài xế hay biển số, và chỉ công bố vị trí ở mức vùng taxi. Câu hỏi là mức ẩn danh này đủ đến đâu. Khung k-ẩn danh (Sweeney, 2002) trả lời bằng cách xét các thuộc tính định danh gián tiếp (quasi-identifier): những thuộc tính mà một người ngoài có thể biết về một chuyến cụ thể, chẳng hạn nơi và lúc một người được đón. Một bản ghi là k-ẩn danh nếu có ít nhất $k-1$ bản ghi khác trùng với nó trên mọi thuộc tính định danh gián tiếp. Nếu $k = 1$, người biết các thuộc tính đó xác định được duy nhất chuyến đi và đọc được mọi thuộc tính còn lại, như giá cước, tip và điểm trả.

Đồ án đo k cho 19.564.232 chuyến HVFHV tháng 03/2025 với mười tổ hợp thuộc tính, từ thô nhất (quận đón, quận trả trong tháng) đến đúng mức chi tiết của bản công bố (vùng đón, vùng trả và thời điểm đón đến giây). Với mỗi tổ hợp, đồ án đếm kích thước từng lớp tương đương bằng một phép GROUP BY trên DuckDB và tính tỷ lệ chuyển nằm trong lớp có $k = 1$, $k < 5$ và $k < 10$.

Bảng 6.7. Tỷ lệ chuyển nằm trong lớp tương đương nhỏ theo mức chi tiết của thuộc tính định danh gián tiếp

Thuộc tính định danh gián tiếp	Số lớp	k = 1 (%)	k < 5 (%)	k < 10 (%)	k trung vị
Quận đón, quận trả, tháng	31	0,00	0,00	0,00	87.337
Quận đón, quận trả, ngày	931	0,00	0,00	0,00	2.790
Quận đón, quận trả, ngày, giờ	21.192	0,01	0,03	0,10	125
Vùng đón, vùng trả	59.282	0,02	0,11	0,32	35
Vùng đón, vùng trả, thứ, giờ	3.053.872	6,00	18,99	33,66	2
Vùng đón, vùng trả, ngày	1.119.136	1,55	5,96	11,35	4
Vùng đón, vùng trả, ngày, giờ	7.003.620	19,11	48,83	72,24	1
Vùng đón, vùng trả, ngày, giờ, hãng	9.090.207	28,34	63,79	84,12	1
Vùng đón, vùng trả, phút đón	18.412.080	88,98	99,83	100,00	1
Vùng đón, vùng trả, giây đón (như bản công bố)	19.541.252	99,77	100,00	100,00	1

Nguồn: *t74_privacy_kanonymity.csv*.



Hình 6.5. Rủi ro tái nhận dạng theo mức chi tiết của thuộc tính định danh gián tiếp

Nguồn: *kết quả tính toán của tác giả từ dữ liệu NYC TLC*.

Kết quả cho thấy tổng quát hóa không gian ở mức vùng không bảo vệ được quyền riêng tư khi thời gian được công bố chính xác. Ở đúng mức chi tiết của bản công bố, 99,77% chuyển là duy nhất. Nếu người ngoài chỉ biết thời điểm đón đến phút, tỷ lệ này vẫn là 89,0%. Giả sử một người được chụp ảnh lên xe ở một góc phố vào một phút xác định và người ngoài biết người đó về khu nào: với xác suất gần như chắc chắn, người ngoài tìm được đúng chuyến đi và biết người đó đã trả bao nhiêu, tip bao nhiêu. Đây chính là loại tấn công liên kết đã được nêu trong tài liệu về dữ liệu taxi New York (Douriez và cộng sự, 2016) và trong nghiên cứu về tính duy nhất của dữ liệu di chuyển (de Montjoye và cộng sự, 2013).

Rủi ro giảm rất nhanh khi thời gian được làm thô. Ở mức vùng $\times$ ngày $\times$ giờ, còn 19,1% chuyển duy nhất và 48,8% chuyển có $k < 5$. Ở mức vùng $\times$ ngày, chỉ 1,55% chuyển là duy nhất. Nếu vùng được gộp thành quận, ngay cả ở mức ngày $\times$ giờ, tỷ lệ chuyển duy nhất chỉ còn 0,005%. Hàm ý là quyết định công bố nên cân nhắc cả hai chiều không gian và thời gian cùng lúc: bản công bố hiện tại đã thô về không gian nhưng rất chi tiết về thời gian, và chiều thời gian là chiều mang rủi ro.

Đối với đồ án, kết quả này có hai hàm ý. Thứ nhất, mọi phân tích của đồ án đều ở mức tổng hợp tối thiểu là vùng $\times$ ngày, và các bảng Gold không chứa thời điểm đón chi tiết, nên việc công bố các bảng Gold không tạo thêm rủi ro. Riêng bảng mẫu chuyển đi giữ nguyên thời điểm và chỉ nên dùng nội bộ. Thứ hai, trong khung của Nghị định 13/2023/NĐ-CP và GDPR, dữ liệu mà 99% bản ghi có thể được liên kết với một người cụ thể khi có thêm thông tin bên ngoài khó có thể được coi là dữ liệu ẩn danh hoàn toàn; một doanh nghiệp Việt Nam công bố dữ liệu tương tự cần đánh giá rủi ro này trước.

6.8. Quyền riêng tư vi phân cho bảng công bố


Nếu dữ liệu vi mô có rủi ro, một lựa chọn là chỉ công bố bảng tổng hợp. Nhưng bảng tổng hợp cũng có thể rò rỉ thông tin khi các ô nhỏ hoặc khi nhiều bảng được đối chiếu với nhau. Quyền riêng tư vi phân (Dwork và cộng sự, 2006; Dwork và Roth, 2014) cho một bảo đảm có thể chứng minh: kết quả công bố gần như không đổi dù có hay không có một bản ghi bất kỳ trong dữ liệu. Cơ chế Laplace đạt ϵ -quyền riêng tư vi phân cho một phép đếm bằng cách cộng nhiễu Laplace với thang đo $1/\epsilon$, vì thêm hoặc bớt một chuyển làm phép đếm đổi tối đa 1. ϵ nhỏ nghĩa là riêng tư hơn và nhiều hơn.

Câu hỏi thực nghiệm là: nếu TLC chỉ công bố bảng số chuyển theo vùng $\times$ ngày có nhiễu Laplace, người đánh giá chính sách còn rút ra được kết luận của Chương 4 không? Đồ án cộng nhiễu độc lập vào từng ô vùng $\times$ ngày của bảng `zone_day_pu`, dựng lại panel vùng $\times$ tuần với đúng tập vùng như bản gốc, và ước lượng lại TWFE log số chuyển. Mỗi mức ϵ được lặp 40 lần với hạt giống cố định.

Bảng 6.8. Ước lượng TWFE log số chuyển khi bảng vùng × ngày được cộng nhiễu Laplace (40 lần lặp mỗi ϵ ; bản gốc: -9,27%)

ϵ	Độ lệch chuẩn nhiễu mỗi ô	Nhiều / ô nhỏ (P5) (%)	Tác động TB (%)	Độ chênh ($\times 100$)	Độ lệch chuẩn giữa lần lặp ($\times 100$)	RMSE ($\times 100$)
0,001	1.414,2	541,8	-7,98	1,413	0,800	1,624
0,005	282,8	108,4	-9,11	0,173	0,293	0,340
0,010	141,4	54,2	-9,21	0,060	0,139	0,152
0,050	28,3	10,8	-9,26	0,004	0,027	0,028
0,100	14,1	5,4	-9,27	-0,001	0,018	0,018
1,000	1,4	0,5	-9,27	-0,000	0,001	0,001

Nguồn: *t75b_dp_summary.csv*, *t75_dp_replications.csv*.



Hình 6.6. Đánh đổi giữa ngân sách riêng tư ϵ và ước lượng tác động lên số chuyển

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Với ϵ từ 0,05 trở lên, ước lượng gần như không đổi: tác động trung bình là -9,26% so với -9,27% của bản gốc, và độ lệch chuẩn giữa các lần lặp nhỏ hơn sai số chuẩn thống kê của ước lượng gốc (0,622) hàng chục lần. Ở $\epsilon = 0,01$, một mức riêng tư rất chặt theo tiêu chuẩn thực hành, RMSE vẫn chỉ 0,152 điểm log. Chỉ khi $\epsilon = 0,001$, nhiễu mỗi ô có độ lệch chuẩn 1.414 chuyển, lớn gấp 5,4 lần ô nhỏ ở phân vị 5, ước lượng mới bị kéo về 0 (còn -7,98%). Hiện tượng kéo về 0 này là chệch do sai số đo lường ở biến phụ thuộc dạng log khi phải cắt số đếm âm về 1, chứ không phải do nhiễu trung bình khác 0.

Kết quả rộng hơn là đánh đổi riêng tư – hữu dụng phụ thuộc rất mạnh vào mức tổng hợp mà câu hỏi phân tích cần. Câu hỏi của đồ án được trả lời trên panel vùng × tuần với 237 vùng, mỗi ô tuần gộp bảy ô ngày có hàng trăm đến hàng nghìn chuyển, nên nhiễu bảo vệ từng chuyển gần như biến mất khi tổng hợp. Cục Điều tra Dân số

Hoa Kỳ đã áp dụng quyền riêng tư vi phân cho kết quả điều tra dân số 2020 dựa trên cùng lập luận (Abowd, 2018). Đối với TLC, điều này gợi ý một mô hình công bố hai tầng: bảng tổng hợp có nhiều ở mức chi tiết khá cao cho công chúng, và dữ liệu vi mô chỉ cho nhà nghiên cứu qua thỏa thuận sử dụng.

Cần nói rõ giới hạn của bảo đảm này. Thực nghiệm dùng quyền riêng tư vi phân ở mức chuyển: nó bảo vệ việc một chuyến cụ thể có mặt hay không, không bảo vệ một hành khách đi nhiều chuyến. Bảo vệ ở mức người dùng cần biết định danh người dùng để giới hạn số chuyến mỗi người đóng góp, thông tin mà dữ liệu công bố không có. Ngoài ra, mỗi bảng công bố thêm tiêu tốn thêm ngân sách riêng tư, nên tổng ϵ của một chương trình công bố nhiều bảng phải được quản lý như một ngân sách thật.

6.9. Bảo mật, Zero Trust và phục hồi sau sự cố

6.9.1. Phân loại tài sản và nguyên tắc Zero Trust

Bảng 6.9. Phân loại tài sản dữ liệu và biện pháp kiểm soát

Tài sản	Mức nhạy cảm	Biện pháp kiểm soát	Phục hồi
Bronze (tập gốc TLC)	Công khai	Toàn vẹn: dấu băm SHA-256; chỉ đọc sau khi nhận	Tải lại từ nguồn
Silver (chuyến đã làm sạch)	Nội bộ, rủi ro tái nhận dạng cao	Quyền đọc theo vai trò; không xuất ra ngoài	Dừng lại từ Bronze
Gold: bảng tổng hợp	Có thể công bố	Kiểm tra kích thước ô nhỏ; có thể cộng nhiều (mục 6.8)	Dừng lại từ Silver
Gold: mẫu chuyến đi	Nội bộ, rủi ro như Silver	Chỉ dùng cho mô tả; không công bố	Dừng lại từ Silver
Mã nguồn và cấu hình	Nội bộ hoặc công khai	Quản lý phiên bản; rà soát khi thay đổi	Kho mã
Bảng kết quả và báo cáo	Công bố sau kiểm duyệt	Sinh tự động từ Gold; không có số gõ tay	Chạy lại bước 06–17 và 13

Nguồn: tác giả đề xuất dựa trên kết quả mục 6.7 và 6.8.

Kiến trúc Zero Trust (Rose và cộng sự, 2020), được trình bày ở mục 7.4 của bài giảng, bỏ giả định rằng mọi thứ bên trong mạng nội bộ là đáng tin. Mỗi yêu cầu truy cập được xác thực và cấp quyền riêng, theo nguyên tắc quyền tối thiểu. Áp dụng vào pipeline của đồ án, điều quan trọng không phải là công nghệ mà là phân loại tài sản đúng. Kết quả mục 6.7 cho thấy dữ liệu ở mức chuyển, dù ở Bronze hay Silver, có rủi ro tái nhận dạng cao; Silver còn được làm sạch và dễ truy vấn hơn nên cần kiểm soát truy cập chặt nhất. Ngược lại, lớp Gold chiếm chưa tới hai phần trăm dung lượng nhưng chứa toàn bộ thông tin cần cho phân tích và có thể công bố. Việc tách bạch này cho phép cấp cho phần lớn người dùng phân tích quyền đọc Gold mà không bao giờ chạm vào dữ liệu vi mô.

6.9.2. Mục tiêu thời gian phục hồi

Bảng 6.10. Thời gian phục hồi (RTO) đo từ nhật ký thực thi của pipeline

Tình huống	Cách dựng lại	Thời gian (phút)
Mất lớp Gold (còn Silver)	Chạy lại phần Gold của bước 03 + bước 04	13,8
Mất lớp Silver và Gold (còn Bronze)	Chạy lại bước 03 toàn bộ + bước 04	84,9
Mất một phân vùng tháng HVFHV	Chạy lại 4 khúc của tháng đó	2,8
Mất toàn bộ kết quả phân tích (còn Gold)	Chạy lại các bước 06–11, 14	3,4

Nguồn: *t76_recovery_rto.csv*.

Mục 7.7 của bài giảng về phục hồi sau sự cố dùng hai chỉ tiêu: thời gian phục hồi mục tiêu (RTO) và điểm phục hồi mục tiêu (RPO). Vì mỗi lớp của pipeline được dựng lại hoàn toàn từ lớp trước bằng mã có tính lũy đẳng, RTO có thể đo trực tiếp từ nhật ký thay vì ước đoán. Mất toàn bộ Silver và Gold tốn khoảng 85 phút để dựng lại; mất riêng Gold tốn khoảng 14 phút; mất một tháng HVFHV chỉ tốn khoảng 2,8 phút nhờ phân vùng. RPO bằng 0 đối với dữ liệu, vì Bronze là bản sao của nguồn công khai và các lớp sau là hàm tất định của Bronze. Chỉ mã nguồn và cấu hình là không tái tạo được và cần sao lưu theo quy tắc 3-2-1.

Đây là một lợi thế ít được nhắc đến của kiến trúc medallion có tính lũy đẳng: chiến lược sao lưu có thể chỉ tập trung vào lớp Bronze và mã nguồn, còn Silver và Gold được coi là bộ đệm có thể tính lại. Cái giá phải trả là thời gian tính lại, và bảng trên cho biết chính xác cái giá đó.

6.10. Số đăng ký rủi ro

Bảng 6.11. Số đăng ký rủi ro của pipeline và của các kết luận

Rủi ro	Khả năng / bằng chứng	Mức ảnh hưởng	Biện pháp kiểm soát
Ép kiểu im lặng khi hợp nhất lược đồ	Đã xảy ra (mục 5.2)	Thấp (đã sửa)	Đối chứng Spark; vân tay lược đồ; union_by_name
Nguồn công bố lại tệp đã tải	Có thể	Trung bình	Dấu băm SHA-256; ghi dấu băm vào nhật ký phân vùng
Thay đổi chất lượng khác nhau giữa nhóm xử lý và đối chứng	Đã quan sát ở taxi vàng (mục 6.4.2)	Cao với kết quả taxi vàng	Biểu đồ p'; phân tích riêng theo quy tắc loại bỏ
Nhóm đối chứng bị ảnh hưởng lan tỏa	Đã quan sát (mục 4.12)	Cao với độ lớn ước lượng	Loại vùng lân cận; báo cáo nhiều nhóm đối chứng
Tái nhận dạng hành khách từ dữ liệu vi mô	Rất cao ở mức chi tiết gốc (mục 6.7)	Cao (pháp lý, uy tín)	Chỉ công bố Gold; làm thô thời gian; quyền riêng tư vi phân
Cảnh báo sai do quy tắc thiếu hiệu nghiệp vụ	Đã quan sát (mục 6.6)	Trung bình (chi phí vận hành)	Kết hợp mô hình không giám sát với quy tắc có kiểm chứng
Mất dữ liệu trung gian	Có thể	Thấp	Dừng lại từ Bronze (thời gian ở mục 6.9.2)
Hiệu sai kết quả có tiền xu hướng	Đã quan sát với giá cược (mục 4.14)	Cao với khuyến nghị chính sách	Giả được cho từng chỉ tiêu; không kết luận khi thất bại

Nguồn: tác giả tổng hợp từ các kết quả của Chương 4, 5 và 6.

Khung quản trị rủi ro ở mục 7.8 của bài giảng đề xuất nhận diện, đánh giá, xử lý và giám sát rủi ro một cách có hệ thống. Số đăng ký trên khác các danh sách rủi ro thường gặp ở một điểm: mỗi rủi ro được gắn với bằng chứng cụ thể trong đồ án, và phần lớn không phải là giả định mà đã xảy ra hoặc đã được đo. Bốn trong tám rủi ro liên quan đến tính đúng của kết luận phân tích chứ không phải đến an ninh hạ tầng. Điều này phản ánh đặc điểm của các dự án phân tích dữ liệu lớn: rủi ro lớn nhất thường không phải bị tấn công, mà là đưa ra quyết định dựa trên một con số sai mà không ai biết là sai.

6.11. Tiểu kết Chương 6

Chương 6 đã áp dụng các công cụ quản trị dữ liệu và rủi ro lên chính tài sản dữ liệu của đồ án. Danh mục và phả hệ tự động cho biết dữ liệu nằm ở đâu và kết quả nào phụ thuộc vào bảng nào; dấu băm và đối soát xác nhận toàn bộ 48 phân vùng không mất hay trùng bản ghi. Biểu đồ kiểm soát p' cho thấy chất lượng dữ liệu HVFHV ổn định, còn taxi vàng có thay đổi rõ từ 01/2025, một rủi ro cho các kết luận về taxi vàng. Về quyền riêng tư, 99,8% chuyển là duy nhất ở mức chi tiết của bản công bố, nhưng bảng tổng hợp vùng $\times$ ngày có thể được bảo vệ bằng quyền riêng tư vi phân ở mức $\epsilon = 0,01$ mà không làm thay đổi kết luận chính sách về số chuyển.

CHƯƠNG 7. GIÁ TRỊ KINH DOANH VÀ CHIẾN LƯỢC DỮ LIỆU

Các chương trước đo tác động của chính sách từ góc nhìn của người đánh giá chính sách. Chương này đổi góc nhìn sang doanh nghiệp: một nền tảng gọi xe, một cơ quan vận tải hoặc một đơn vị cung cấp dữ liệu sẽ dùng cùng tài sản dữ liệu này để ra quyết định gì, và giá trị của tài sản đó được đo thế nào. Nội dung bám theo ba chương ứng dụng của bài giảng: dự báo nhu cầu và quản trị vận hành (Chương 4), phân tích khách hàng và thử nghiệm quy mô lớn (Chương 5), định giá và thương mại hóa dữ liệu (Chương 6).

Câu hỏi nghiên cứu tương ứng là RQ8: kết quả của đồ án tạo ra những thông tin gì cho quyết định kinh doanh, và phương pháp phân tích nào đáng tin cho từng loại quyết định? Mục 7.1 phân tích tác động theo hãng. Mục 7.2 so sánh dự báo nhu cầu với suy luận nhân quả. Mục 7.3 tính quy mô dữ liệu cần cho một thử nghiệm chính sách. Mục 7.4 xem xét định giá động. Mục 7.5 tổng hợp phân khúc chuyển đi. Mục 7.6 và 7.7 bàn về giá trị của tài sản dữ liệu và lộ trình chiến lược.

7.1. Tác động theo hãng và cạnh tranh trong vùng thu phí

Bảng 7.1. Tác động của phí CRZ lên số chuyến theo hãng và thị phần của Uber (panel vùng × tuần)

Biến kết quả	Đặc tả	Hệ số	SE	KTC 95%	Tác động
log số chuyến Uber	TWFE	-0,1150***	0,0074	[-0,1297; -0,1004]	-10,87%
log số chuyến Uber	DDD mùa vụ	-0,1205***	0,0073	[-0,1349; -0,1062]	-11,36%
log số chuyến Lyft	TWFE	-0,0516***	0,0089	[-0,0691; -0,0342]	-5,03%
log số chuyến Lyft	DDD mùa vụ	-0,0521***	0,0089	[-0,0696; -0,0347]	-5,08%
Thị phần Uber trong HVFHV (%)	TWFE	-1,2558***	0,1883	[-1,6267; -0,8848]	-1,26 điểm %
Thị phần Uber trong HVFHV (%)	DDD mùa vụ	-1,3462***	0,1905	[-1,7215; -0,9710]	-1,35 điểm %

Nguồn: *t77_company_did.csv*. *, **, *** tương ứng $p < 0,1$; $0,05$; $0,01$; sai số chuẩn phân cụm theo vùng.

Số chuyến Uber đón trong CRZ giảm 10,9% so với phản thực tế, trong khi số chuyến Lyft giảm 5,0%. Hồi quy xếp chồng hai hãng với hiệu ứng cố định vùng × hãng và tuần × hãng cho chênh lệch giữa hai hệ số là -0,0634 (sai số chuẩn 0,0097, $p < 0,001$), nên khác biệt này không phải ngẫu nhiên. Hệ quả trực tiếp là thị phần của Uber trong HVFHV tại CRZ giảm 1,26 điểm phần trăm, trên nền 74,9% năm 2024. Kết quả gần như không đổi khi thêm hiệu ứng cố định nhóm × tuần trong năm.

Đồ án không có dữ liệu giá theo hãng ở mức đủ chi tiết để giải thích khác biệt này, nên chỉ có thể nêu các giả thuyết có thể kiểm định. Một là khác biệt về cơ cấu khách hàng: nếu Uber có tỷ trọng chuyển ngắn nội vùng cao hơn, và đây là loại chuyển nhảy nhất với phí (mục 4.8), Uber sẽ mất nhiều hơn. Hai là khác biệt về chiến lược chuyển phí: một hãng có thể hấp thụ một phần phí qua khuyến mãi trong khi hãng kia chuyển toàn bộ. Ba là khác biệt về phía cung: nếu tài xế đa nền tảng ưu tiên nhận chuyển của hãng trả tốt hơn trong vùng có phí, số chuyển hoàn thành của từng hãng sẽ phản ánh cả cạnh tranh trên thị trường tài xế. Với một nền tảng, đây là loại thông tin cạnh tranh có giá trị cao mà dữ liệu công khai cung cấp miễn phí cho cả đối thủ.

7.2. Dự báo nhu cầu và giới hạn của dự báo làm phản thực tế

7.2.1. Thiết kế

Mục 4.4 của bài giảng trình bày dự báo nhu cầu bằng dữ liệu lớn như một ứng dụng vận hành cốt lõi. Một cách dùng dự báo cho đánh giá chính sách, phổ biến trong doanh nghiệp, là huấn luyện mô hình dự báo trên giai đoạn trước sự kiện rồi coi dự báo cho giai đoạn sau là phản thực tế; chênh lệch giữa thực tế và dự báo được diễn giải là tác động. Brodersen và cộng sự (2015) chính thức hóa cách tiếp cận này trong CausalImpact bằng mô hình chuỗi thời gian cấu trúc Bayes có dùng các chuỗi đối chứng làm biến giải thích.


Đồ án áp dụng cách tiếp cận này cho log số chuyển HVFHV đón trong CRZ theo ngày, với năm mô hình: Ridge chỉ dùng lịch (thứ trong tuần, ngày lễ liên bang và ngày liền kề, kỳ nghỉ cuối năm, sóng điều hòa theo năm) có xu hướng tuyến tính; Ridge thêm hai chuỗi đối chứng là log số chuyển của Manhattan phía bắc và quận ngoại, có và không có xu hướng; Ridge chỉ thêm chuỗi quận ngoại; và LightGBM với lịch và hai chuỗi đối chứng. Mô hình được huấn luyện trên dữ liệu đến 31/10/2024 và đánh giá trên giai đoạn giữ lại từ 01/11/2024 đến 04/01/2025, gồm cả kỳ nghỉ cuối năm, một thử thách khó. Quy tắc chọn được định trước: mô hình có sai số phần trăm tuyệt đối trung bình (MAPE) thấp nhất trên giai đoạn giữ lại được dùng làm phản thực tế chính.

7.2.2. Kết quả

Bảng 7.2. Độ chính xác dự báo trên giai đoạn giữ lại và chênh lệch thực tế – dự báo sau chính sách

Mô hình	MAPE giữ lại (%)	RMSE (chuyển/ngày)	Chênh (%)	Chênh lệch sau chính sách (%)
Ridge: lịch + MN phía bắc + quận ngoài + xu hướng	8,92	19.088	-4,00	+3,06
Ridge: lịch + quận ngoài	9,49	18.867	-4,86	-8,59
Ridge: lịch + MN phía bắc + quận ngoài	9,49	19.854	-5,62	-2,24
LightGBM: lịch + MN phía bắc + quận ngoài	11,46	21.340	-5,96	-3,12
Ridge: chỉ lịch + xu hướng	14,82	27.088	-7,01	-8,98
Naive theo tuần (t-7)	20,06	38.421	-6,82	–

Nguồn: *t78_forecast_accuracy.csv*. Mô hình naive không dùng được để dự báo xa nên không có chênh lệch sau chính sách.



Hình 7.1. Số chuyển thực tế và dự báo phản thực tế của mô hình được chọn (trên) và chênh lệch theo tháng (dưới)

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Mô hình có MAPE thấp nhất là "Ridge: lịch + MN phía bắc + quận ngoài + xu hướng" (8,92%). Phản thực tế của nó cho chênh lệch trung bình sau chính sách là +3,06%, tức số chuyển thực tế còn cao hơn dự báo. Kết quả này trái chiều với mọi thiết kế nhân quả ở Chương 4, vốn cho mức giảm khoảng 9,3%. Năm mô hình cho chênh lệch từ -9,0% đến +3,1%, một khoảng rộng hơn cả độ lớn của tác động cần đo.

Trong khi đó, MAPE của bốn mô hình tốt nhất chỉ khác nhau khoảng 2,5 điểm phần trăm.

Nguyên nhân có thể đọc từ hệ số của mô hình được chọn. Hệ số của log số chuyển Manhattan phía bắc là 1,111, nghĩa là dự báo cho CRZ gần như bám theo chuỗi này. Nhưng mục 4.12 đã cho thấy Manhattan phía bắc bị lan tỏa: số chuyển ở đây cũng giảm sau chính sách. Khi chuỗi đối chứng bị ảnh hưởng, phản thực tế bị kéo xuống theo, và tác động bị triệt tiêu hoặc đảo dấu. Thêm vào đó, xu hướng tuyến tính ước lượng từ mười tháng được ngoại suy ra mười hai tháng. Mô hình chỉ dùng chuỗi quận ngoài, ít bị lan tỏa hơn, cho -8,6%, gần với kết quả DiD, dù MAPE của nó chỉ đứng thứ 2 trong bảng.

Dữ liệu 2022–2025 ở mục 4.14.4 cho thêm một cách đọc. Số chuyển CRZ đã giảm tương đối khoảng 0,85 điểm phần trăm mỗi tháng từ trước chính sách, và sau khi trừ xu hướng này, tác động gần bằng không. Mô hình có xu hướng tuyến tính riêng vì thế không hẳn sai: nó ngoại suy một xu hướng có thật, và chênh lệch gần bằng không của nó phù hợp với ước lượng điều chỉnh xu hướng hơn là với các thiết kế chỉ dùng một năm trước chính sách. Điều đó không làm mô hình này trở thành ước lượng nhân quả đáng tin, vì chuỗi giải thích vẫn bị lan tỏa, nhưng nó cho thấy khoảng cách giữa dự báo và DiD một phần do cách hai phương pháp xử lý xu hướng.

Đây là một kết quả phương pháp quan trọng, không chỉ cho đồ án. Độ chính xác dự báo trên giai đoạn giữ lại đo khả năng mô hình tái hiện quan hệ giữa các chuỗi khi không có can thiệp. Nó không đo được việc quan hệ đó có còn đúng sau can thiệp hay không, vì chính can thiệp có thể làm thay đổi các chuỗi giải thích. Chọn mô hình phản thực tế theo sai số dự báo vì vậy có thể chọn đúng mô hình tệ nhất về mặt nhân quả. Brodersen và cộng sự (2015) nêu rõ giả định rằng các chuỗi đối chứng không bị can thiệp ảnh hưởng; dữ liệu của đồ án cho thấy giả định này bị vi phạm theo cách có thể đo được. Trong doanh nghiệp, nơi các đánh giá kiểu "thực tế so với dự báo" rất phổ biến, bài học là mọi chuỗi đối chứng phải được kiểm tra độc lập về khả năng bị ảnh hưởng, chứ không chỉ về độ tương quan.

Dù vậy, mô hình dự báo vẫn có giá trị vận hành. Sai số dự báo ngày khoảng 9% trên giai đoạn khó nhất trong năm là đủ tốt để lập kế hoạch cung xe, và phần dư dự báo

là đầu vào tự nhiên cho hệ thống phát hiện bất thường ở mục 6.5. Điều cần tránh là dùng cùng mô hình đó để trả lời câu hỏi nhân quả.


7.3. Quy mô dữ liệu cần cho một thử nghiệm chính sách

Mục 5.7 của bài giảng trình bày thử nghiệm A/B ở quy mô dữ liệu lớn. Một câu hỏi thiết kế trung tâm của mọi thử nghiệm là cần bao nhiêu dữ liệu để phát hiện một tác động có độ lớn cho trước. Với chính sách công, câu hỏi tương ứng là: sau bao lâu thì có thể đánh giá được chính sách? Đồ án trả lời bằng cách cắt giai đoạn sau chính sách còn 4, 8, 13, 26, 39 và 52 tuần, giữ nguyên toàn bộ giai đoạn trước, và ước lượng lại TWFE cho ba biến kết quả. Tác động nhỏ nhất phát hiện được (MDE) với công suất 80% và mức ý nghĩa 5% được tính bằng 2,8 lần sai số chuẩn (Bloom, 1995).

Bảng 7.3. Ước lượng và tác động nhỏ nhất phát hiện được theo độ dài giai đoạn sau chính sách

Tuần sau	Số chuyển: ước lượng	Số chuyển: MDE	Tốc độ: ước lượng	Tốc độ: MDE	Chờ: ước lượng	Chờ: MDE
4	-2,67%***	2,92%	0,673***	0,144	-0,371***	0,077
8	-3,03%***	2,54%	0,626***	0,128	-0,302***	0,070
13	-4,78%***	2,24%	0,702***	0,106	-0,312***	0,063
26	-8,09%***	1,61%	0,595***	0,060	-0,303***	0,053
39	-8,85%***	1,74%	0,480***	0,054	-0,348***	0,055
52	-9,27%***	1,76%	0,406***	0,056	-0,377***	0,051

Nguồn: *t80_power_mde.csv*. Tốc độ theo dặm/giờ, thời gian chờ theo phút.



Hình 7.2. Giá trị tuyệt đối của ước lượng và MDE theo số tuần sau chính sách

Nguồn: kết quả tính toán của tác giả từ dữ liệu NYC TLC.

Hai quy luật hiện ra. Thứ nhất, MDE giảm khi có thêm dữ liệu nhưng giảm chậm: với số chuyển, từ 2,92% sau 4 tuần xuống 1,76% sau 52 tuần. Mức giảm chậm vì sai số chuẩn phân cụm theo vùng bị chi phối bởi số vùng, vốn cố định, hơn là bởi số

tuần. Nói cách khác, sau vài tháng, dữ liệu mới chủ yếu làm tăng độ tin cậy về động thái chứ không cải thiện nhiều độ chính xác của tác động trung bình.

Thứ hai, và quan trọng hơn cho quyết định, bản thân tác động thay đổi theo thời gian. Mức giảm số chuyến sau 4 tuần chỉ là 2,7%, sau 13 tuần là 4,8% và sau 52 tuần là 9,3%. Ngược lại, mức tăng tốc độ lớn nhất ở giai đoạn đầu (0,67 dặm/giờ sau 4 tuần) và giảm dần về 0,41 dặm/giờ khi tính cả năm. Hai xu hướng ngược chiều gợi ý rằng hành khách điều chỉnh chậm (thói quen thay đổi dần), còn hệ thống giao thông điều chỉnh nhanh rồi một phần lưu lượng quay lại khi đường thông thoáng hơn, đúng hiện tượng nhu cầu cảm ứng mà lý thuyết giao thông dự báo. Tất cả các ước lượng này đều có ý nghĩa thống kê ngay từ tuần thứ tư, nên vấn đề không phải là công suất mà là tác động đo sớm không đại diện cho tác động dài hạn.

Với doanh nghiệp chạy thử nghiệm, hàm ý tương tự đã được ghi nhận trong tài liệu thử nghiệm trực tuyến dưới tên hiệu ứng mới lạ và hiệu ứng thích nghi (Kohavi, Tang và Xu, 2020): quyết định dựa trên vài tuần đầu có thể đánh giá sai tác động dài hạn theo cả hai chiều. Dữ liệu lớn giải quyết được bài toán công suất, nhưng không giải quyết được bài toán thời gian.

7.4. Định giá động: giá có phản ứng với nhu cầu trong ngày không?

Bảng 7.4. Độ co giãn của giá cước mỗi dặm theo số chuyến và tốc độ giữa các giờ trong ngày

Nhóm vùng	Năm	Hệ số log số chuyến	SE	Hệ số log tốc độ	SE	Số quan sát	R ² trong
CRZ	2.024	0,008	0,009	-0,629***	0,020	10.707	0,897
CRZ	2.025	0,020	0,012	-0,594***	0,026	10.705	0,851
Manhattan phía bắc	2.024	0,026	0,016	-0,534***	0,028	5.644	0,846
Manhattan phía bắc	2.025	0,059***	0,017	-0,464***	0,035	5.706	0,783
Quận ngoài	2.024	-0,005	0,005	-0,531***	0,011	49.161	0,889
Quận ngoài	2.025	0,004	0,005	-0,521***	0,012	49.366	0,834

Nguồn: *t81_price_demand_elasticity.csv*. Hiệu ứng cố định vùng $\times$ tháng; biến thiên chỉ giữa các giờ; cụm theo vùng.

Mục 6.4 của bài giảng trình bày định giá linh hoạt (dynamic pricing), mà giá tăng đột biến theo cầu của các nền tảng gọi xe là ví dụ điển hình (Castillo, Knoepfle và Weyl, 2017). Dữ liệu TLC không có hệ số tăng giá, nhưng cho phép một kiểm tra gián tiếp: trong cùng một vùng và cùng một tháng, giữa các giờ có nhiều chuyến và ít chuyến, giá cước mỗi dặm có khác nhau không? Hồi quy log giá mỗi dặm theo log số chuyến và log tốc độ, với hiệu ứng cố định vùng $\times$ tháng, trả lời câu hỏi này.

Kết quả là giá mỗi dặm gần như không phản ứng với số chuyển ở mức giờ trung bình tháng: hệ số của log số chuyển trong CRZ là 0,008 năm 2024 và 0,020 năm 2025, đều không có ý nghĩa ở mức 5%. Trong khi đó, hệ số của log tốc độ là -0,629 và -0,594, rất có ý nghĩa: khi tốc độ thấp hơn 10%, giá mỗi dặm cao hơn khoảng 6,3%. Hệ số của tốc độ âm và có ý nghĩa ở cả ba nhóm vùng và hai năm; hệ số của số chuyển đều nhỏ, chỉ có ý nghĩa ở mức 5% trong Manhattan phía bắc năm 2025 (0,059). Mẫu hình này cho thấy phần biến thiên giá giữa các giờ chủ yếu đến từ cấu trúc giá theo thời gian và quãng đường (chuyển chậm tốn nhiều phút hơn trên mỗi dặm), không phải từ tăng giá theo khối lượng cầu.

Cần thận trọng với cách đọc này. Giá tăng đột biến phản ứng với mất cân bằng cung cầu tức thời trong vài phút và vài trăm mét, trong khi dữ liệu ở đây đã được trung bình theo vùng, giờ và tháng. Một giờ có nhiều chuyển cũng thường là giờ có nhiều tài xế, nên tỷ lệ cung cầu có thể không đổi. Kết quả vì vậy không bác bỏ việc có định giá động, mà cho thấy ở mức tổng hợp mà cơ quan quản lý quan sát được, định giá động không phải là yếu tố chính của biến thiên giá giữa các giờ, và phí CRZ không làm thay đổi điều đó.

7.5. Phân khúc chuyển đi và hàm ý cá nhân hóa

Bảng 7.5. Tác động trung bình theo nhóm (GATES) của số chuyển và tốc độ

Nhóm GATES (ngũ phân vị CATE của chính biến kết quả)	Số chuyển	Tốc độ (dặm/giờ)
Nhóm 1	-13,04%	0,157
Nhóm 2	-7,85%	0,275
Nhóm 3	-9,08%	0,368
Nhóm 4	-6,79%	0,418
Nhóm 5	-5,10%	0,475

Nguồn: *t43_dml_gates.csv* (Chương 4). Mỗi biến kết quả được chia nhóm theo CATE ước lượng của riêng nó.

Bảng 7.6. Tác động có điều kiện trung bình theo loại luồng

Loại luồng	CATE trung bình: số chuyển	CATE trung bình: tốc độ (dặm/giờ)	Số cặp OD
CRZ → CRZ	-8,36%	0,216	924
CRZ → ngoài	-6,64%	0,440	994
không chạm CRZ	-9,61%	0,337	1.908
ngoài → CRZ	-7,64%	0,360	804

Nguồn: *t47_cate_by_flowtype.csv* (Chương 4).

Chương 5 của bài giảng đặt cá nhân hóa và dự báo giá trị vòng đời khách hàng ở trung tâm của phân tích khách hàng. Dữ liệu TLC không có định danh khách hàng, nên

không thể tính giá trị vòng đời hay xác suất rời bỏ ở mức cá nhân. Đơn vị gần nhất với "khách hàng" mà dữ liệu cho phép là cặp điểm đón – điểm trả, và kết quả CATE ở Chương 4 chính là một phân khúc hóa theo độ nhạy với chi phí. Nhóm GATES nhạy nhất giảm 13,0% số chuyển, nhóm ít nhạy nhất giảm 5,1%, và phân tích CLAN cho thấy nhóm nhạy nhất có quãng đường trung bình 4,82 dặm so với 5,43 dặm của nhóm ít nhạy nhất. Về tốc độ, mọi nhóm đều được lợi, từ 0,16 đến 0,47 dặm/giờ.

Với một nền tảng, khác biệt về độ nhạy này định hình chiến lược phân khúc. Phân khúc nhạy giá (chuyển ngắn, thời lượng ngắn) là nơi cần khuyến mãi có mục tiêu nếu muốn giữ khối lượng. Phân khúc ít nhạy nhưng được lợi về tốc độ là nơi có thể nhấn mạnh thời gian di chuyển ngắn hơn như một giá trị. Chuyển sân bay là trường hợp đặc biệt: số chuyển từ CRZ ra sân bay mỗi ngày thay đổi +3,5% và từ sân bay vào CRZ thay đổi +0,7% giữa hai năm, gần như không bị ảnh hưởng. Đây là phân khúc có giá trị cao, ít phương án thay thế và ít nhạy với phí.

Khi doanh nghiệp có định danh khách hàng, cùng phương pháp DR-learner có thể ước lượng độ nhạy ở mức cá nhân, tức là mô hình uplift. Điều kiện chống lẩn mà Chương 4 phân tích sẽ trở thành điều kiện thiết kế: cần có khách hàng ở mọi phân khúc được và không được can thiệp, điều mà một thử nghiệm ngẫu nhiên bảo đảm nhưng một chính sách theo vùng thì không.

7.6. Giá trị và chi phí của tài sản dữ liệu

7.6.1. Hạch toán tài nguyên

Bảng 7.7. Hạch toán tài nguyên của pipeline, đo từ nhật ký và siêu dữ liệu

Hạng mục	Giá trị	Đơn vị	Ghi chú
Dung lượng lớp Bronze	12,35	GB	572,952,454 dòng; 48 tệp
Dung lượng lớp Silver	15,64	GB	544,311,785 dòng; 120 tệp
Dung lượng lớp Gold	0,20	GB	6,188,137 dòng; 10 tệp
Thời gian lớp Silver + Gold (bước 03)	83,68	phút	2 luồng, giới hạn bộ nhớ DuckDB 1,8 GB
Thời gian hợp nhất Gold (bước 04)	1,26	phút	
Thời gian các bước phân tích 06–11, 14	3,36	phút	11 nhật ký
Tài nguyên xử lý Silver+Gold trên mỗi triệu dòng Bronze	17,53	lỗi·giây	= thời gian × 2 lỗi / triệu dòng
Tái lập zone_day_pu bằng Spark trên mỗi triệu dòng Silver	0,82	lỗi·giây	local[2]
Tỷ lệ Gold / Bronze theo dung lượng	1,58	%	mức cô đặc thông tin cho phân tích

Nguồn: *t82_resource_accounting.csv*.

Mục 6.5 của bài giảng đặt ra bài toán đo ROI và TCO của dự án dữ liệu lớn. Phần chi phí có thể đo chính xác từ nhật ký, và bảng trên tổng hợp các con số đó bằng đơn vị vật lý (GB, phút, lỗi·giây) thay vì tiền. Lựa chọn không quy ra tiền là có chủ đích: đơn giá lưu trữ và tính toán thay đổi theo nhà cung cấp, vùng và thời điểm, còn đơn vị vật lý thì không. Người đọc có thể nhân với đơn giá hiện hành của mình.

Hai con số đáng chú ý. Thứ nhất, lớp Gold chỉ chiếm 1,58% dung lượng của Bronze. Chi phí lưu trữ lâu dài cho mục đích phân tích vì vậy gần như không đáng kể nếu chỉ giữ Gold, và Bronze có thể tái lại từ nguồn khi cần. Thứ hai, chi phí xử lý của bước làm sạch và tổng hợp là khoảng 17,5 lỗi·giây cho mỗi triệu dòng, còn tái lập một bảng Gold bằng Spark chỉ khoảng 0,82 lỗi·giây cho mỗi triệu dòng. Phần lớn chi phí nằm ở bước ghi lớp Silver đầy đủ, không phải ở tổng hợp. Nếu chỉ cần Gold, một kiến trúc bỏ qua việc ghi Silver sẽ rẻ hơn nhiều, đổi lại mất khả năng truy vấn linh hoạt ở mức chuyển.

7.6.2. Định giá tài sản dữ liệu

Phía giá trị khó đo hơn. Moody và Walsh (1999) đề xuất ba cách tiếp cận định giá thông tin tương tự định giá tài sản: theo chi phí tạo ra, theo giá thị trường và theo giá trị sử dụng. Với tài sản của đồ án, cách thứ nhất cho con số thấp, vì dữ liệu nguồn miễn phí và chi phí xử lý nhỏ như bảng trên. Cách thứ hai không áp dụng được vì không có thị trường cho dữ liệu này. Cách thứ ba là cách có ý nghĩa: giá trị nằm ở các quyết định mà thông tin làm thay đổi. Để có hình dung về quy mô, dữ liệu ghi nhận 141,2 triệu USD phí CBD trong năm 2025 chỉ từ hai dịch vụ; một quyết định điều chỉnh mức phí hay cơ cấu phí theo giờ, dựa trên các ước lượng như của đồ án, tác động trực tiếp đến khoản thu này và đến thời gian di chuyển của hàng trăm nghìn chuyển mỗi ngày.

Laney (2017) lập luận rằng doanh nghiệp nên quản lý thông tin như một tài sản với các chỉ tiêu giá trị riêng, dù chuẩn mực kế toán chưa cho phép ghi nhận nó trên bảng cân đối. Một đặc điểm mà đồ án minh họa rõ là giá trị của dữ liệu không nằm ở dữ liệu thô mà ở lớp tổng hợp đã được kiểm chứng: cùng tệp nguồn công khai, nhưng chỉ sau khi có pipeline có kiểm soát chất lượng, đối chứng chéo và các thiết kế nhận dạng đáng tin thì nó mới đủ độ tin cậy để dùng cho quyết định.

7.6.3. Các sản phẩm dữ liệu có thể thương mại hóa

Bảng 7.8. Các sản phẩm dữ liệu có thể xây dựng từ tài sản của đồ án

Sản phẩm	Người dùng	Thành phần từ đồ án	Hình thức giá trị
Chỉ số ùn tắc theo vùng và giờ	Cơ quan quản lý, doanh nghiệp logistics	Bảng Gold grp_hour_day, zone_hour_month; nhánh luồng mục 5.8	Gián tiếp (cải thiện quyết định) hoặc thuê bao
Bảng tổng hợp có quyền riêng tư vi phân	Nhà nghiên cứu, công chúng	zone_day_pu cộng nhiều (mục 6.8)	Công bố mở
Dịch vụ đánh giá chính sách theo yêu cầu	Chính quyền, hiệp hội ngành	Toàn bộ pipeline và thiết kế nhân quả	Dịch vụ tư vấn
Cảnh báo bất thường ngày	Nhà vận hành nền tảng	Mục 6.5 và mô hình dự báo mục 7.2	Gián tiếp (vận hành)
Phân khúc độ nhạy theo cấp OD	Bộ phận giá và marketing của nền tảng	CATE, GATES (Chương 4, mục 7.5)	Gián tiếp (giá, khuyến mãi)

Nguồn: tác giả đề xuất.

Mục 6.2 và 6.3 của bài giảng phân biệt thương mại hóa trực tiếp (bán dữ liệu) và gián tiếp (dùng dữ liệu để tạo giá trị gia tăng). Với dữ liệu gốc là tài sản công, thương mại hóa trực tiếp không phù hợp. Các sản phẩm trong bảng đều thuộc loại gián tiếp hoặc dịch vụ, nơi giá trị nằm ở năng lực xử lý và phân tích chứ không ở quyền sở hữu dữ liệu. Kết quả mục 6.7 còn đặt ra một giới hạn: mọi sản phẩm công bố ra ngoài phải ở mức tổng hợp đủ thô hoặc có nhiễu, không phải dữ liệu vi mô.

7.7. Lộ trình chiến lược dữ liệu

Bảng 7.9. Lộ trình chiến lược dữ liệu đề xuất cho một cơ quan quản lý vận tải

Giai đoạn	Nội dung	Chỉ tiêu theo dõi
1. Nền tảng (đã làm trong đồ án)	Lakehouse ba lớp; kiểm soát chất lượng; danh mục, phá hệ, đấu bầm; đối chứng hai bộ máy	Đối soát 100% phân vùng; lỗi được phát hiện trước khi công bố
2. Phân tích định kỳ	Chạy lại theo tháng khi TLC công bố dữ liệu mới; báo cáo tự động sinh từ Gold	Thời gian từ khi có dữ liệu đến báo cáo
3. Giám sát gần thời gian thực	Nhánh luồng (mục 5.8) nối với hàng đợi thông điệp; cảnh báo bất thường ngày	Độ trễ phát hiện sự kiện
4. Công bố có kiểm soát	Bảng tổng hợp có quyền riêng tư vi phân; quản lý ngân sách ϵ	Tổng ϵ đã dùng; số yêu cầu dữ liệu vi mô
5. Mở rộng và tổ chức	Chuyển sang cụm khi dữ liệu vượt một máy; trung tâm xuất sắc dữ liệu; văn hóa kiểm chứng	Tỷ lệ quyết định có đánh giá nhân quả đi kèm

Nguồn: tác giả đề xuất.

Mục 6.6 đến 6.8 của bài giảng bàn về văn hóa ra quyết định dựa trên dữ liệu, trung tâm xuất sắc và lộ trình chiến lược. Lộ trình trên được sắp theo thứ tự phụ thuộc: không thể giám sát theo thời gian thực nếu chưa có định nghĩa chỉ tiêu ổn định ở lớp Gold, và không thể công bố có kiểm soát nếu chưa đo được rủi ro tái nhận dạng. Giai đoạn cuối cố ý đặt việc chuyển sang cụm tính toán phân tán sau cùng, vì Chương 5 cho thấy ở quy mô hiện tại nó chưa đem lại lợi ích tốc độ.

Về văn hóa, bài học rõ nhất từ đồ án là giá trị của thói quen kiểm chứng. Ba phát hiện quan trọng của đồ án đến từ việc thử bác bỏ kết quả của chính mình: tác động lên giá cước không vượt qua giả được (Chương 4), bảng Gold có lỗi ép kiểu (Chương 5), và mô hình dự báo tốt nhất cho phản thực tế sai (mục 7.2). Một tổ chức muốn ra quyết định dựa trên dữ liệu cần thường cho việc tìm ra những điều này, chứ không chỉ cho việc đưa ra con số.

7.8. Tiểu kết Chương 7

Chương 7 đã chuyển kết quả sang góc nhìn kinh doanh. Phí CRZ ảnh hưởng không đều giữa các hãng: Uber giảm 10,9% số chuyển trong vùng, Lyft giảm 5,0%, và thị phần Uber giảm 1,26 điểm phần trăm. Dự báo nhu cầu có độ chính xác đủ cho vận hành, nhưng dùng làm phản thực tế thì cho kết quả phụ thuộc mạnh vào chuỗi đối chứng, và mô hình dự báo tốt nhất lại cho kết quả sai chiều vì chuỗi đối chứng bị lan tỏa. Tác động lên số chuyển lớn dần theo thời gian còn tác động lên tốc độ nhỏ dần, nên đánh giá sớm không đại diện cho dài hạn. Ở mức tổng hợp, giá mỗi dặm phản ứng với tốc độ chứ không với khối lượng chuyển. Chi phí tài nguyên của toàn bộ tài sản dữ liệu nhỏ so với giá trị quyết định mà nó hỗ trợ.

CHƯƠNG 8. THẢO LUẬN KẾT QUẢ, HÀM Ý QUẢN TRỊ VÀ HẠN CHẾ

Các chương 4 đến 7 đã trình bày các con số. Chương này đặt chúng vào bối cảnh: các kết quả nói gì về cơ chế của chính sách, chúng khớp hay lệch với lý thuyết và các nghiên cứu khác ở đâu, doanh nghiệp và cơ quan quản lý có thể rút ra điều gì, và giới hạn của bằng chứng nằm ở đâu.

8.1. Về kỹ thuật dữ liệu lớn

8.1.1. Quy mô vừa phải và lựa chọn công cụ

Một kết luận thực tiễn của đồ án là quy mô dữ liệu của bài toán, khoảng 573 triệu bản ghi và 12,3 GB Parquet nén, nằm ở vùng mà nhiều người mặc định phải dùng cụm Spark, nhưng thực tế xử lý được trên một máy ảo 2 lõi, 3 GB RAM trong 84 phút. Điều kiện để làm được là ba lựa chọn đi cùng nhau: định dạng cột nén, bộ máy thực thi vector hóa có giới hạn bộ nhớ và cơ chế tràn đĩa, và chia việc thành các phân vùng lũy đẳng. Thiếu một trong ba, bài toán sẽ vượt tài nguyên.

Chương 5 đã kiểm chứng trực tiếp nhận định này thay vì chỉ lập luận: trên cùng phần cứng, chi phí biên của Spark là 0,367 giây cho mỗi triệu dòng so với 0,164 giây của DuckDB, và JVM cần bộ nhớ cố định lớn hơn nhiều. Nhưng Chương 5 cũng cho thấy Spark có ba vai trò mà DuckDB không thay thế được ngay cả ở quy mô này: kiểm toán độc lập (phát hiện lỗi ép kiểu), đường nâng cấp khi dữ liệu vượt một máy, và xử lý luồng có trạng thái. Quan điểm của mục 3.8 trong bài giảng về tối ưu chi phí tính toán vì vậy cần được hiểu đúng: chọn công cụ theo quy mô và tần suất thực tế, nhưng một bộ máy thứ hai với chi phí thấp có thể đáng giá vì lý do kiểm soát chất lượng, không phải vì tốc độ.

8.1.2. Chất lượng dữ liệu ảnh hưởng đến kết luận nhân quả

Quy tắc chất lượng loại nhiều dữ liệu nhất là vùng không xác định (4,37% bản ghi HVFHV). Nếu tỷ lệ này thay đổi khác nhau giữa CRZ và vùng đối chứng quanh thời điểm chính sách, chẳng hạn do ứng dụng thay đổi cách ghi vị trí, kết quả nhân quả sẽ bị ảnh hưởng. Phụ lục F cho thấy tỷ lệ loại ổn định qua 24 tháng, nhưng đây là một điểm cần được theo dõi thường xuyên nếu pipeline được dùng để giám sát chính sách lâu dài.

Cách xác định vùng xử lý từ dữ liệu thu phí cũng là một bài học về chất lượng dữ liệu. Nếu gán tay theo ranh giới đường 60, sáu vùng vắt ranh giới sẽ bị xếp nhầm vào nhóm này hay nhóm kia. Với các chính sách khác mà ranh giới không trùng với đơn vị thống kê, cách làm tương tự có thể áp dụng miễn là có một biến trong dữ liệu phản ánh trực tiếp việc chịu chính sách.

8.1.3. Chi phí tính toán như một chỉ tiêu quản trị

Nhật ký phân vùng cho phép tính chính xác chi phí tính toán của pipeline: 1,39 giờ thời gian chạy trên máy 2 lõi cho 120 phân vùng, bộ nhớ DuckDB không vượt 1,8 GB, dung lượng lưu trữ tổng của ba lớp khoảng 28,0 GB cộng khoảng nửa gigabyte cho Gold. Các con số này đủ nhỏ để quy trình giám sát chính sách có thể chạy định kỳ mỗi tháng trên hạ tầng rất khiêm tốn, hoặc trên một máy ảo đám mây cỡ nhỏ trong vài giờ.

Trong khung ROI và TCO của Chương 6 bài giảng, điểm đáng chú ý là phần lớn chi phí của một dự án như thế này không nằm ở hạ tầng mà ở công sức thiết kế: xác định vùng xử lý, lựa chọn đối chứng, xây dựng các phép thử giả được. Một khi pipeline đã được xây dựng và kiểm chứng, chi phí biên của việc đánh giá thêm một chỉ tiêu hay thêm một tháng dữ liệu gần như bằng 0.

8.2. Về tác động lên số chuyển

8.2.1. Độ lớn so với lý thuyết

Mức giảm số chuyển trong khoảng 6,5% đến 9,3% cần được so với mức tăng chi phí. Tổng chi phí hành khách trung bình của chuyển đón trong CRZ năm 2024 là 36,00 USD, nên riêng khoản phí 1,50 USD làm chi phí tăng khoảng 4,2%. Nếu mọi mức giảm số chuyển đều do phí, độ co giãn ngụ ý theo công thức ở mục 2.1.2 sẽ vào khoảng -1,6 đến -2,2, tức cầu rất co giãn. Con số này cao hơn đáng kể so với độ co giãn thường được báo cáo cho dịch vụ gọi xe.

Có ba cách giải thích không loại trừ nhau. Thứ nhất, chi phí thực tế tăng nhiều hơn mức phí danh nghĩa nếu giá cước cơ sở cũng tăng; đồ án không xác định được phần này nhưng phân phối chi phí hành khách cho thấy nó có thể không nhỏ. Thứ hai, cầu của chuyển ngắn trong khu trung tâm rất co giãn vì có nhiều phương án thay thế gần như miễn phí về tiền (đi bộ, xe đạp) hoặc rẻ (tàu điện ngầm, taxi với phí thấp hơn).

Thứ ba, một phần mức giảm có thể là xu hướng có sẵn chưa được kiểm soát hết, như phép thử giả được về số chuyển gợi ý. Vì vậy, đề án coi phạm vi 6–10% là tác động tổng hợp của phí cùng mọi phản ứng đi kèm trong năm đầu, không phải độ co giãn thuần theo giá.

8.2.2. So sánh với nghiên cứu khác

Pandey, Guler và Gayah (2026) báo cáo mức giảm 5,95% tổng số chuyển của các công ty gọi xe. Con số này nằm ở cận dưới của phạm vi mà đề án tìm thấy và gần với kết quả kiểm soát tổng hợp. Sự chênh lệch có thể đến từ định nghĩa nhóm xử lý và đối chứng: đề án dùng vùng xác định từ dữ liệu thu phí, loại vùng vắt ranh giới và vùng nhỏ, và tách riêng Manhattan phía bắc. Kết quả lan tỏa cho thấy nếu nhóm đối chứng chứa nhiều vùng gần CRZ, ước lượng sẽ nhỏ hơn. Ngược lại, TWFE không trọng số đại diện cho vùng nên nhạy với các vùng CRZ nhỏ, có thể làm ước lượng lớn hơn. Hai kết quả vì vậy nhất quán về chiều và tương thích về độ lớn khi xét đến khác biệt thiết kế.

Về chuyển đi chung, cả hai nghiên cứu đều thấy mức giảm tương đối lớn hơn nhiều so với tổng số chuyển. Đề án đo tỷ lệ chuyển có yêu cầu đi chung giảm khoảng 16% so với mức nền, cùng chiều với phát hiện của Pandey và cộng sự. Kết quả này đặt ra một câu hỏi thiết kế chính sách: phí tính theo chuyển làm tăng chi phí trên mỗi hành khách của chuyển đi chung nhiều hơn chuyển đi riêng, trái với mục tiêu giảm số xe trên đường.

8.2.3. Luồng nào nhạy nhất

Luồng nội vùng CRZ → CRZ giảm mạnh nhất (11,1%). Đây là các chuyển ngắn, thường dưới vài dặm, trong khu vực có mật độ tàu điện ngầm dày đặc. Về chính sách, nhóm này cũng là nhóm mà việc giảm chuyển ít gây thiệt hại phúc lợi nhất, vì phương án thay thế sẵn có. Chuyển ra sân bay, ngược lại, gần như không đổi về tỷ trọng, phù hợp với độ co giãn thấp của chuyển đi có giá trị cao và ít phương án thay thế.

8.3. Về tác động lên ùn tắc

8.3.1. Tốc độ và thời gian chờ như bằng chứng trực tiếp

Mục tiêu tuyên bố của chính sách là giảm ùn tắc. Dữ liệu gọi xe cho phép đo điều này gián tiếp qua tốc độ của chính các chuyến đi. Mức tăng 0,41 dặm/giờ trên nền 13,0

dặm/giờ nghe có vẻ khiêm tốn, nhưng cần đặt trong bối cảnh: tốc độ khu trung tâm vào giờ cao điểm buổi chiều chỉ khoảng 7 dặm/giờ, và mức tăng tập trung đúng vào các giờ đó. Kết quả tốc độ còn là bằng chứng vững nhất trong đồ án: nó có bước nhảy rõ tại mốc chính sách, vượt qua giả được theo thời gian (giả được ngược dấu), không nhảy với xu hướng nhóm và được xác nhận bởi cả DML.

Thời gian chờ giảm 0,38 phút là lợi ích trực tiếp cho hành khách còn lại trong hệ thống. Nó cũng cho thấy phí có tác động qua hai kênh: đường thông thoáng hơn và nguồn cung xe tương đối dồi dào hơn so với cầu. Về mặt phúc lợi, những hành khách vẫn đi xe gọi công nghệ trả thêm phí nhưng nhận lại thời gian di chuyển và chờ đợi ngắn hơn.

So với Cook và cộng sự (2025), những người dùng dữ liệu tốc độ Google Maps và báo cáo tốc độ trung bình trong vùng tăng từ 8,2 lên 9,7 dặm/giờ (khoảng 15%) trong hai tháng đầu, mức tăng của đồ án nhỏ hơn: 3,1% tính trung bình cả năm và 5,2% trong 4 tuần đầu. Ba lý do làm hai con số khác nhau về định nghĩa chứ không mâu thuẫn. Thứ nhất, tốc độ của đồ án là tốc độ trung bình của cả chuyến, gồm cả đoạn nằm ngoài vùng. Thứ hai, mức tăng giảm dần theo thời gian (giả thuyết H6, mục 4.15), nên trung bình cả năm nhỏ hơn hai tháng đầu. Thứ ba, nhóm đối chứng của đồ án là các vùng trong cùng thành phố, vốn cũng được lợi một phần (mục 4.15.3), trong khi Cook và cộng sự dùng các thành phố khác làm đối chứng.

8.3.2. Giới hạn của thước đo tốc độ

Tốc độ chuyến gọi xe không phải tốc độ của mọi phương tiện. Chuyến gọi xe có thể chọn tuyến khác, và thành phần chuyến thay đổi khi chuyến ngắn giảm mạnh hơn chuyến dài. Đồ án giảm thiểu vấn đề thành phần bằng cách đo tốc độ trên panel cặp OD với hiệu ứng cố định cặp, nơi tuyến đường về cơ bản không đổi, và kết quả vẫn dương. Tuy nhiên, để khẳng định tác động lên toàn bộ giao thông, cần dữ liệu cảm biến giao thông hoặc dữ liệu GPS của xe buýt, nằm ngoài phạm vi của đồ án.

8.3.3. Không đồng nhất theo giờ và theo ngày

Tốc độ tăng mạnh nhất vào chiều tối ngày thường và gần như không tăng vào giờ cao điểm buổi sáng hay cuối tuần. Mẫu hình này phù hợp với lý thuyết đường cong tốc độ – lưu lượng: khi lưu lượng gần mức bão hòa, giảm một ít xe tạo ra cải thiện lớn về

tốc độ. Nó cũng gợi ý rằng một cơ cấu phí phân biệt theo giờ chi tiết hơn có thể đạt hiệu quả cao hơn cùng mức thu. Đây chính là khuyến nghị của Vickrey (1969) về phí thay đổi theo thời gian.

8.4. Về giá cước, chi phí hành khách và thu nhập tài xế

8.4.1. Vì sao không kết luận

Kết quả DiD thô cho thấy chi phí hành khách của chuyến đón trong CRZ tăng 3,65 USD, gấp 2,7 lần phí CBD. Đây là loại con số dễ trở thành tiêu đề báo chí. Đồ án chủ động không dùng nó làm kết luận vì ba bằng chứng: xu hướng giá của CRZ đã tách khỏi vùng đối chứng trong suốt năm 2024; phép thử giả được tháng 07/2024 tạo ra "tác động" có ý nghĩa với cùng độ lớn; và đặc tả có xu hướng nhóm đảo dấu kết quả. Khi ba phép thử cùng thất bại, hệ số DiD không còn diễn giải được như tác động nhân quả.

Điều duy nhất có thể nói chắc chắn là khoản phí 1,50 USD được chuyển toàn bộ sang hóa đơn hành khách, vì nó được ghi riêng trên hóa đơn. Việc nền tảng có điều chỉnh giá cơ sở hay không, và phần điều chỉnh đó được chia thế nào giữa nền tảng và tài xế, cần một thiết kế khác: dữ liệu dài hơn trước chính sách để mô hình hóa xu hướng giá, hoặc dữ liệu từ bên trong nền tảng về thuật toán định giá.

8.4.2. Ý nghĩa đối với phương pháp

Trường hợp này minh họa một điểm phương pháp quan trọng: giả định xu hướng song song có thể đúng với một biến kết quả và sai với biến khác trong cùng một thiết kế. Số chuyến, tốc độ, thời gian chờ và giá cước đều được đo trên cùng vùng, cùng tuần, nhưng chỉ một số biến có động thái trước chính sách đủ ổn định. Việc chạy phép thử giả được riêng cho từng biến, thay vì chỉ cho biến chính, là cần thiết. Đây cũng là tinh thần của Roth và cộng sự (2023) và Rambachan và Roth (2023) về việc đánh giá tính đáng tin của giả định xu hướng song song một cách minh bạch.

8.5. Về hiệu ứng lan tỏa

Mức giảm lan ra các vùng lân cận và nhỏ dần theo khoảng cách. Có hai cách đọc. Cách thứ nhất là lan tỏa qua mạng lưới chuyển đi: nhiều chuyến từ các vùng lân cận có đích trong CRZ, nên chịu phí và giảm theo. Cách thứ hai là lan tỏa hành vi: hành khách và tài xế thay đổi thói quen ở cả khu vực xung quanh. Dữ liệu cho thấy cách thứ

nhiều nhất chiếm phần lớn, vì phía điểm trả, số chuyển của khách đến từ ngoài CRZ trả ở dải lân cận giảm ít hơn nhiều so với CRZ, trong khi số chuyển từ CRZ trả ở ngay ngoài ranh giới lại tăng.

Về phương pháp, kết quả lan tỏa là cảnh báo quan trọng cho mọi đánh giá dùng các vùng lân cận làm đối chứng. Với CRZ, dùng Manhattan phía bắc làm đối chứng cho mức giảm chỉ khoảng một nửa so với dùng quận ngoài. Một nghiên cứu chỉ dùng Manhattan phía bắc với lập luận "đó là các vùng tương đồng nhất" sẽ đánh giá thấp tác động một cách có hệ thống.

8.6. Về học máy nhân quả

8.6.1. Chồng lấn là vấn đề trung tâm

Ứng dụng DML trong đồ án cho thấy vấn đề lớn nhất khi áp dụng học máy nhân quả cho chính sách không gian không phải là chọn thuật toán mà là chồng lấn. Với bộ biến đầy đủ, AUC của mô hình xu hướng là 0,996; mô hình "biết" gần như chắc chắn cặp nào chạm CRZ. Trong tình huống đó, mọi ước lượng dựa trên trọng số xu hướng chỉ đại diện cho một tập con rất nhỏ và đặc biệt. Báo cáo ước lượng mà không báo cáo chồng lấn sẽ gây hiểu nhầm.

Lựa chọn của đồ án là dùng bộ biến rút gọn chỉ gồm đặc trưng chuyển đi. Lựa chọn này có cái giá: nếu có yếu tố gắn với vị trí vừa ảnh hưởng đến xu hướng số chuyển vừa tương quan với việc chạm CRZ, ước lượng sẽ chệch. Việc kết quả DML (8,4%) nằm trong khoảng của các thiết kế DiD và SCM là một kiểm tra chéo hữu ích, nhưng không thay thế được giả định.

8.6.2. Giá trị của CATE

Kiểm định BLP xác nhận có không đồng nhất thật. GATES cho thấy mọi nhóm đều giảm số chuyển và tăng tốc độ, chỉ khác độ lớn. Đặc trưng giải thích sự khác biệt là quãng đường, thời lượng, tỷ trọng chuyển đêm và mức tip. Với doanh nghiệp nền tảng, thông tin này có giá trị trực tiếp: nó cho biết phân khúc chuyển nào mất khách nhiều nhất khi chi phí tăng, và vì vậy cần chính sách giá hoặc khuyến mãi bù đắp. Đây là dạng phân tích uplift được đề cập ở Chương 5 của bài giảng, áp dụng cho một cú sốc chi phí thay vì một chiến dịch marketing.

8.7. Hàm ý quản trị và chính sách

8.7.1. Đối với cơ quan quản lý

- Phí đặt được mục tiêu giảm ùn tắc ở mức đo được qua tốc độ và thời gian chờ, và tạo nguồn thu đáng kể: riêng hai dịch vụ HVFHV và taxi vàng ghi nhận 141,2 triệu USD phí trong dữ liệu năm 2025.
- Cơ cấu phí theo chuyến đang bất lợi cho chuyến đi chung. Có thể xem xét giảm phí cho chuyến đi chung được ghép thành công, để phí phản ánh đúng số xe trên đường thay vì số giao dịch.
- Tốc độ tăng không đều theo giờ. Một cơ cấu phí phân biệt theo giờ chi tiết hơn cho xe gọi công nghệ có thể tạo cải thiện lớn hơn với cùng mức thu.
- Cần giám sát các vùng ngay ngoài ranh giới, nơi có dấu hiệu tăng chuyến trả khách từ CRZ, để phát hiện sớm ùn tắc dịch chuyển.
- Dữ liệu chuyến đi công khai của TLC, cùng một pipeline như đồ án, đủ để giám sát chính sách gần như theo thời gian thực với chi phí rất thấp.

8.7.2. Đối với doanh nghiệp nền tảng

- Chuyển ngắn nội vùng và chuyển đêm là phân khúc nhạy nhất; đây là nơi mất thị phần sang taxi, tàu điện ngầm hoặc đi bộ.
- Thời gian chờ giảm trong CRZ có nghĩa là xe dư thừa tương đối; điều phối xe sang vùng lân cận hoặc giờ khác có thể cải thiện thu nhập theo giờ của tài xế.
- Taxi vàng, với phí bằng một nửa, là đối thủ được lợi. Chiến lược giá cho chuyển ngắn trong CRZ cần tính đến chênh lệch phí này.
- Tác động không đều giữa các hãng (mục 7.1): hãng mất nhiều chuyến hơn cần xem lại cơ cấu khách hàng và chính sách chuyển phí.
- Đánh giá kiểu "thực tế so với dự báo" dễ sai khi chuỗi đối chứng bị ảnh hưởng (mục 7.2); cần thiết kế nhân quả cho các quyết định lớn.

8.7.3. Đối với phân tích dữ liệu trong doanh nghiệp

Ngoài nội dung chính sách, đồ án minh họa một quy trình mà các doanh nghiệp có dữ liệu giao dịch quy mô lớn có thể áp dụng để đánh giá bất kỳ thay đổi nào có ranh

giới rõ về không gian hoặc thời gian: một khoản thuế mới, một thay đổi giá theo vùng, một đối thủ mới vào thị trường. Các thành phần gồm pipeline Lakehouse có kiểm soát chất lượng, xác định nhóm chịu tác động từ chính dữ liệu, nhiều thiết kế nhận dạng đối chiếu nhau và phép thử giả được cho từng chỉ tiêu. Trong thuật ngữ của Chương 6 của bài giảng, đây là một cách biến dữ liệu thành giá trị ra quyết định có thể đo lường được.

8.8. Hạn chế của nghiên cứu

Bảng 8.1. Tổng hợp các hạn chế, ảnh hưởng và hướng khắc phục

Hạn chế	Ảnh hưởng đến kết luận	Hướng khắc phục
Năm gốc 2022 còn chịu ảnh hưởng COVID-19	Xu hướng trước chính sách có thể là phục hồi sau đại dịch, không kéo dài tuyến tính	Dữ liệu 2019 làm mốc thứ hai; xu hướng phi tuyến
Tác động lên số chuyển phụ thuộc giả định xu hướng	Không tách chắc chắn tác động khỏi xu hướng có sẵn; điểm gãy RR gần bằng 0	Thêm vùng đối chứng tương đồng; dữ liệu lưu lượng xe con
Silver 2022–2023 không lưu bền cho phần lớn tháng	Không kiểm toán lại được từng chuyển mở rộng sau khi chạy	Lưu Silver trên máy có RAM lớn hơn hoặc lưu trữ đám mây
Không có dữ liệu xe con cá nhân	Không đo trực tiếp lưu lượng giao thông vào vùng	Kết hợp dữ liệu cảm biến giao thông, dữ liệu thu phí của MTA
Tốc độ đo trên chuyến gọi xe	Có thể khác tốc độ của toàn bộ phương tiện	Dùng dữ liệu GPS xe buýt MTA
Giá cước chịu xu hướng có sẵn	Không kết luận được về phân bố gánh nặng	Dữ liệu dài hơn; phương pháp của Rambachan và Roth (2023)
Chồng lấn thấp trong DML	Ước lượng chỉ đại diện cho vùng chồng lấn	Thiết kế ở cấp chuyển với đặc trưng thời gian chi tiết
Không quan sát hành khách cá nhân	Không đo được phương thức thay thế cụ thể	Kết hợp dữ liệu lượt quét thẻ tàu điện ngầm
Phí ghi nhận khác phí thực thu	Doanh thu phí chỉ là ước lượng từ hóa đơn	Đối chiếu với báo cáo tài chính của MTA
Taxi vàng có biến động riêng ở quận ngoại	Kết quả taxi vàng kém ổn định	Phân tích riêng theo nhà cung cấp và loại chuyển
Tỷ lệ loại bỏ của taxi vàng tăng từ 01/2025	Mẫu Silver taxi vàng năm 2025 có thể bị chọn lọc	Phân tích độ nhạy với quy tắc giá cước (mục 6.4.2)
Spark chỉ chạy trên một nút	Chưa đo được khả năng mở rộng theo số nút	Chạy lại bước 15 trên cụm đám mây
Quyền riêng tư vì phân ở mức chuyển	Không bảo vệ hành khách đi nhiều chuyển	Cần định danh người dùng để giới hạn đóng góp
Dự báo phản thực tế phụ thuộc chuỗi đối chứng	Không dùng được làm ước lượng nhân quả chính	Chọn chuỗi đối chứng theo kiểm tra lan tỏa

Nguồn: tác giả tổng hợp.

Hạn chế quan trọng nhất là cách xử lý xu hướng trước chính sách. Dữ liệu 2022–2023 đã được bổ sung và cho thấy số chuyển CRZ giảm tương đối từ trước, nhưng năm gốc 2022 còn chịu ảnh hưởng của làn sóng Omicron và quá trình phục hồi sau đại dịch. Nếu xu hướng đó là phục hồi đang chậm lại thì trừ đi xu hướng tuyến tính sẽ làm tác động bị ước lượng thấp; nếu nó là dịch chuyển lâu dài của hoạt động ra khỏi khu

trung tâm thì các ước lượng một năm sẽ bị phóng đại. Dữ liệu TLC không phân biệt được hai khả năng này, nên đề án báo cáo khoảng 0–2% là ước lượng thận trọng và 6–10% là cận trên.

Các hạn chế còn lại chủ yếu liên quan đến phạm vi dữ liệu TLC. Chúng không làm thay đổi các kết luận chính về chiều của tác động lên tốc độ và thời gian chờ, nhưng giới hạn khả năng mở rộng kết luận sang toàn bộ hệ thống giao thông.

8.9. Tiểu kết Chương 5

Chương 8 đã thảo luận ý nghĩa của các kết quả. Về kỹ thuật, bài toán quy mô hàng trăm triệu bản ghi có thể xử lý trên máy cá nhân khi kết hợp đúng các lựa chọn kiến trúc. Về chính sách, phí CRZ cải thiện tốc độ và thời gian chờ; mức giảm số chuyến gọi xe trùng phần lớn với xu hướng có sẵn từ 2022, nên độ lớn của nó chưa kết luận chắc chắn. Về phương pháp, việc kiểm tra giả được cho từng chỉ tiêu và kiểm tra chồng lẩn trong học máy nhân quả là cần thiết để phân biệt kết quả đáng tin với kết quả chỉ phản ánh xu hướng có sẵn.

CHƯƠNG 9. KẾT LUẬN VÀ KIẾN NGHỊ

9.1. Kết luận tổng quát

Đồ án đã đánh giá tác động của phí vùng giảm ùn tắc Manhattan, có hiệu lực từ 05/01/2025, lên thị trường gọi xe công nghệ và taxi vàng bằng tổng bộ 572.952.454 bản ghi chuyển đi của NYC TLC trong 24 tháng 2024–2025, cùng 522.872.427 bản ghi của 24 tháng 2022–2023 dùng cho giai đoạn trước chính sách mở rộng. Công việc gồm hai phần gắn chặt với nhau: xây dựng một pipeline Lakehouse có kiểm soát chất lượng để biến dữ liệu thô thành các bảng phân tích đáng tin, và áp dụng nhiều thiết kế suy luận nhân quả, từ sai khác kép đến kiểm soát tổng hợp và học máy nhân quả, để ước lượng tác động và kiểm tra độ tin cậy của chúng.

Bên cạnh đó, đồ án tái lập bảng phân tích chính bằng Apache Spark để kiểm toán kết quả và đo chi phí của xử lý phân tán, đánh giá rủi ro quản trị và quyền riêng tư của chính tài sản dữ liệu, và chuyển kết quả thành thông tin cho quyết định kinh doanh. Về chính sách, kết quả có thể tóm gọn thành ba mệnh đề. Phí cải thiện điều kiện di chuyển đo được qua tốc độ và thời gian chờ, tập trung vào các giờ đông nhất. Số chuyến gọi xe chạm vùng giảm 6–10% so với năm trước, nhưng dữ liệu 2022–2025 cho thấy phần lớn mức giảm này trùng với xu hướng giảm tương đối đã có từ 2022; phần vượt xu hướng chỉ khoảng 0–2%. Ngược lại, dữ liệu hiện có không cho phép kết luận về tác động lên giá cước cơ sở và thu nhập tài xế.

Về lý thuyết, mô hình bốn khối ở mục 2.11 cho tám giả thuyết; ba được dữ liệu ủng hộ rõ (tốc độ tăng, lợi ích tốc độ giảm dần theo thời gian, lan tỏa theo mức phơi nhiễm về chiều), bốn được ủng hộ một phần (số chuyến giảm, liều – đáp ứng theo tỷ trọng phí, độ lỗi của quan hệ tốc độ – lưu lượng, chuyển đi chung giảm mạnh hơn), và một chưa kiểm định được (thu nhập tài xế). Hai điểm lệch có hệ thống so với mô hình, tác động gần như không đổi theo tỷ trọng phí và lan tỏa mạnh ở vùng sát ranh giới, gợi ý rằng hành khách phản ứng với việc đi vào vùng thu phí như một sự kiện theo địa điểm, hơn là với mức tăng giá của từng chuyến.

9.2. Trả lời các câu hỏi nghiên cứu

9.2.1. RQ1: kiến trúc và chi phí xử lý

Pipeline Bronze–Silver–Gold trên DuckDB và Parquet xử lý toàn bộ dữ liệu trong 83,7 phút trên máy 2 lõi, khoảng 3 GB RAM. Parquet ZSTD nhỏ hơn CSV 6,6 lần và cho truy vấn tổng hợp nhanh hơn 12,7 lần. DuckDB dùng 164 MB bộ nhớ cho truy vấn một tháng, so với 1.382 MB của pandas. Cắt tia cột và đẩy điều kiện lọc theo thời gian cho lợi ích lớn nhờ dữ liệu được lưu theo thứ tự thời gian.

9.2.2. RQ2: tác động lên số chuyến

Số chuyến HVFHV đón trong CRZ giảm 9,3% theo TWFE, 9,7% theo DDD khứ mùa vụ, 6,5% theo kiểm soát tổng hợp và 8,4% theo AIPW trên cặp OD thuộc vùng chồng lấn. Kết quả vượt qua suy luận hoán vị và vững qua hầu hết các đặc tả thay thế. Luồng nội vùng CRZ → CRZ giảm mạnh nhất (11,1%). Tuy vậy, với dữ liệu 2022–2025, giả được 2024 so với 2023 đã cho -7,8%, và sau khi trừ xu hướng tuyến tính, tác động còn +0,06% (sai số chuẩn 0,80 điểm %). Mức tăng tốc của đà giảm so với năm trước là -2,0%. Đánh giá thận trọng là phí làm số chuyến giảm thêm khoảng 0–2% ngoài xu hướng có sẵn; phạm vi 6–10% chỉ là cận trên, đúng khi xu hướng 2022–2024 không kéo dài sang 2025.

9.2.3. RQ3: tác động lên ùn tắc

Tốc độ trung bình của chuyến đón trong CRZ tăng 0,41 dặm/giờ và thời gian chờ giảm 0,38 phút. Hai kết quả có bước nhảy rõ tại mốc chính sách, vượt qua giả được theo thời gian. Với dữ liệu 2022–2025, sau điều chỉnh xu hướng, tốc độ vẫn tăng 0,15 dặm/giờ (sai số chuẩn 0,029) và thời gian chờ giảm 0,25 phút; độ lớn nhỏ hơn nhưng chiều không đổi. Đây là bằng chứng vững nhất của đồ án về việc chính sách đạt mục tiêu giảm ùn tắc.

9.2.4. RQ4: không đồng nhất và lan tỏa

Số chuyến giảm mạnh hơn vào đêm và tối, ít hơn vào giờ đi làm buổi sáng; tốc độ tăng mạnh nhất vào chiều tối ngày thường. Kiểm định BLP xác nhận có không đồng nhất thật theo đặc trưng chuyến đi, với chuyến ngắn nhạy hơn. Về không gian, mức giảm lan tới các vùng cách CRZ vài km; dùng Manhattan phía bắc làm đối chứng

cho mức giảm 4,0%, so với 9,9% khi dùng quận ngoài. Số chuyển từ CRZ trả khách ở dải 0–1 km ngoài ranh giới tăng 5,7%.

9.2.5. RQ5: phân bổ gánh nặng

Phí 1,50 USD được chuyển toàn bộ sang hóa đơn hành khách. Các ước lượng DiD về giá cước cơ sở và thu nhập tài xế không vượt qua phép thử giả được và đối dấu khi có xu hướng nhóm, nên đồ án không kết luận về việc nền tảng có điều chỉnh giá cơ sở hay phân chia lại với tài xế hay không.

9.2.6. RQ6: xử lý phân tán với Spark

Spark tái lập toàn bộ bảng Gold zone_day_pu từ 544.311.785 dòng Silver trong 3,7 phút, khớp với bản DuckDB trên cả 358.148 dòng sau khi sửa một lỗi ép kiểu ở bước hợp nhất mà chính phép đối chứng này phát hiện. Trên cùng máy một nút, Spark chậm hơn DuckDB khoảng 2,2 lần cho một tháng dữ liệu. AQE làm cho hiệu năng gần như không phụ thuộc vào số phân vùng xáo trộn, cắt tĩa phân vùng và đẩy điều kiện lọc hoạt động như lý thuyết, Arrow rút ngắn việc chuyển dữ liệu sang pandas 7,6 lần, còn lưu đệm không đem lại lợi ích với truy vấn quét trên Parquet. Structured Streaming phát hiện thời điểm chính sách có hiệu lực ngay trong lô vi mô đầu tiên sau đó.

9.2.7. RQ7: quản trị dữ liệu, quyền riêng tư và rủi ro

Toàn bộ 48 phân vùng vượt qua ba phép đối soát số dòng giữa các lớp, và 50 tệp nguồn có dấu băm SHA-256 để kiểm tra tính toàn vẹn. Chất lượng dữ liệu HVFHV ổn định theo biểu đồ kiểm soát p' (2 tháng vượt giới hạn), còn taxi vàng có tỷ lệ loại bỏ tăng rõ từ 01/2025, làm giảm độ tin cậy của kết quả taxi vàng. Ở mức chi tiết của bản công bố, 99,8% chuyển là duy nhất, nên dữ liệu vi mô có rủi ro tái nhận dạng cao; rủi ro giảm mạnh khi thời gian được làm thô. Bảng vùng $\times$ ngày có quyền riêng tư vi phân với $\epsilon = 0,01$ vẫn cho tác động lên số chuyển là -9,21%, gần như trùng với bản gốc.

9.2.8. RQ8: giá trị kinh doanh

Phí ảnh hưởng không đều giữa các hãng (Uber -10,9%, Lyft -5,0%). Dự báo nhu cầu đạt sai số khoảng 9% trên giai đoạn giữ lại, đủ cho vận hành, nhưng dùng làm phản thực tế thì cho kết quả từ -9,0% đến +3,1% tùy chuỗi đối chứng; mô hình dự báo tốt nhất lại sai chiều vì chuỗi đối chứng bị lan tỏa. Tác động lên số chuyển lớn dần và

tác động lên tốc độ nhỏ dần theo thời gian, nên đánh giá sau vài tuần không đại diện cho dài hạn. Chi phí tài nguyên của tài sản dữ liệu nhỏ, còn giá trị nằm ở các quyết định về một khoản thu phí hàng trăm triệu USD mỗi năm.

9.3. Kiến nghị

9.3.1. Kiến nghị chính sách

- Duy trì chính sách vì có bằng chứng về cải thiện tốc độ và thời gian chờ, đồng thời tạo nguồn thu đáng kể.
- Xem xét ưu đãi phí cho chuyển đi chung được ghép thành công để không làm giảm hình thức đi lại tiết kiệm không gian đường.
- Nghiên cứu cơ cấu phí phân biệt theo giờ cho xe gọi công nghệ, vì lợi ích về tốc độ tập trung ở chiều tối.
- Giám sát các vùng ngay ngoài ranh giới để phát hiện ùn tắc dịch chuyển.
- Công bố định kỳ các chỉ số giám sát (số chuyển, tốc độ, thời gian chờ theo vùng) tính từ dữ liệu TLC, vì chi phí tính toán rất thấp.

9.3.2. Kiến nghị về phương pháp và dữ liệu

- Bổ sung dữ liệu 2019 để có một năm gốc không chịu ảnh hưởng đại dịch, và thử các dạng xu hướng phi tuyến thay cho xu hướng tuyến tính 2022–2024.
- Áp dụng bản đầy đủ của phương pháp Rambachan và Roth (2023), với khoảng tin cậy điều chỉnh, thay cho phiên bản đơn giản ở mục 4.14.5.
- Kết hợp dữ liệu thu phí của MTA, cảm biến giao thông và lượt quét thẻ tàu điện ngầm để đo tác động lên toàn hệ thống.
- Xây dựng CATE ở cấp chuyển với đặc trưng thời gian chi tiết để cải thiện chồng lấn trong học máy nhân quả.
- Đưa đối chứng bằng một bộ máy thứ hai (như Spark ở Chương 5) và kiểm tra vãn tay lược đồ thành bước bắt buộc trước khi công bố bảng Gold.
- Khi công bố dữ liệu vi mô, làm thô thời điểm đón trả (ví dụ theo giờ) hoặc thay bằng bảng tổng hợp có quyền riêng tư vi phân.

- Không dùng dự báo "thực tế so với kỳ vọng" làm ước lượng tác động nếu chưa kiểm tra chuỗi đối chứng có bị chính sách ảnh hưởng hay không.

9.4. Hướng nghiên cứu tiếp theo

Hướng thứ nhất là theo dõi tác động dài hạn. Các nghiên cứu về Stockholm và London cho thấy tác động lên lưu lượng thường được duy trì, còn tác động lên tốc độ có thể mờ dần. Dữ liệu TLC năm 2026 đã được công bố và có thể đưa trực tiếp vào pipeline hiện tại để kiểm tra xu hướng này.

Hướng thứ hai là mô hình hóa phía cung: phân tích thu nhập theo giờ của tài xế và mức độ sử dụng xe, cần dữ liệu ở cấp tài xế mà TLC không công bố công khai. Hướng thứ ba là đánh giá tác động phân phối: hành khách ở các khu vực thu nhập khác nhau chịu ảnh hưởng thế nào, bằng cách ghép dữ liệu điều tra dân số theo vùng.

Về kỹ thuật, bước 15 có thể được chạy lại trên một cụm Spark nhiều nút để đo khả năng mở rộng theo số nút, điều mà đồ án chỉ dự đoán được từ cấu trúc tác vụ. Về quyền riêng tư, nếu có định danh người dùng, có thể thử quyền riêng tư vi phân ở mức người dùng thay vì mức chuyến. Pipeline cũng có thể chuyển sang chế độ tăng dần theo tháng với định dạng bảng giao dịch như Delta Lake hoặc Apache Iceberg, để hỗ trợ cập nhật và truy vấn theo phiên bản (time travel) như mục 2.4 của bài giảng đã trình bày.

9.5. Kết luận cuối

Với 141,2 triệu USD phí ghi nhận trong một năm từ riêng hai dịch vụ, tốc độ tăng và thời gian chờ giảm, phí CRZ là một can thiệp có tác động đo được lên thị trường gọi xe New York. Đồ án cho thấy dữ liệu chuyển đi công khai, xử lý bằng một pipeline Lakehouse gọn nhẹ, được kiểm toán bằng một bộ máy phân tán độc lập, quản trị bằng danh mục, phá hệ và đo lường rủi ro quyền riêng tư, và phân tích bằng các phương pháp nhân quả được kiểm tra chéo, đủ để đưa ra những kết luận có căn cứ, đồng thời chỉ rõ những câu hỏi mà dữ liệu chưa trả lời được.

TÀI LIỆU THAM KHẢO

- [1] Abadie, A. (2021). Using synthetic controls: Feasibility, data requirements, and methodological aspects. *Journal of Economic Literature*, 59(2), 391–425.
- [2] Abadie, A., Diamond, A., & Hainmueller, J. (2010). Synthetic control methods for comparative case studies: Estimating the effect of California's tobacco control program. *Journal of the American Statistical Association*, 105(490), 493–505.
- [3] Abowd, J. M. (2018). The U.S. Census Bureau adopts differential privacy. *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2867.
- [4] Anderson, M. L. (2014). Subways, strikes, and slowdowns: The impacts of public transit on traffic congestion. *American Economic Review*, 104(9), 2763–2796.
- [5] Angrist, J. D., & Pischke, J.-S. (2009). *Mostly harmless econometrics: An empiricist's companion*. Princeton University Press.
- [6] Armbrust, M., Das, T., Torres, J., Yavuz, B., Zhu, S., Xin, R., Ghodsi, A., Stoica, I., & Zaharia, M. (2018). Structured Streaming: A declarative API for real-time applications in Apache Spark. *Proceedings of the 2018 International Conference on Management of Data (SIGMOD)*, 601–613.
- [7] Armbrust, M., Ghodsi, A., Xin, R., & Zaharia, M. (2021). Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics. *Proceedings of the Conference on Innovative Data Systems Research (CIDR)*.
- [8] Armbrust, M., Xin, R. S., Lian, C., Huai, Y., Liu, D., Bradley, J. K., Meng, X., Kaftan, T., Franklin, M. J., Ghodsi, A., & Zaharia, M. (2015). Spark SQL: Relational data processing in Spark. *Proceedings of the 2015 ACM SIGMOD International Conference on Management of Data*, 1383–1394.
- [9] Athey, S., & Imbens, G. W. (2017). The state of applied econometrics: Causality and policy evaluation. *Journal of Economic Perspectives*, 31(2), 3–32.
- [10] Beojone, C. V., & Geroliminis, N. (2021). On the inefficiency of ride-sourcing services towards urban congestion. *Transportation Research Part C: Emerging Technologies*, 124, 102890.
- [11] Bertrand, M., Duflo, E., & Mullainathan, S. (2004). How much should we trust differences-in-differences estimates? *Quarterly Journal of Economics*, 119(1), 249–275.
- [12] Bloom, H. S. (1995). Minimum detectable effects: A simple way to report the statistical power of experimental designs. *Evaluation Review*, 19(5), 547–556.
- [13] Börjesson, M., Eliasson, J., Hugosson, M. B., & Brundell-Freij, K. (2012). The Stockholm congestion charges—5 years on. Effects, acceptability and lessons learnt. *Transport Policy*, 20, 1–12.

- [14] Brodersen, K. H., Gallusser, F., Koehler, J., Remy, N., & Scott, S. L. (2015). Inferring causal impact using Bayesian structural time-series models. *Annals of Applied Statistics*, 9(1), 247–274.
- [15] Bureau of Public Roads (1964). Traffic assignment manual. U.S. Department of Commerce, Urban Planning Division.
- [16] Callaway, B., & Sant'Anna, P. H. C. (2021). Difference-in-differences with multiple time periods. *Journal of Econometrics*, 225(2), 200–230.
- [17] Cameron, A. C., & Miller, D. L. (2015). A practitioner's guide to cluster-robust inference. *Journal of Human Resources*, 50(2), 317–372.
- [18] Castillo, J. C., Knoepfle, D., & Weyl, G. (2017). Surge pricing solves the wild goose chase. *Proceedings of the 2017 ACM Conference on Economics and Computation (EC '17)*, 241–242.
- [19] Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.
- [20] Chernozhukov, V., Demirer, M., Duflo, E., & Fernández-Val, I. (2018). Generic machine learning inference on heterogeneous treatment effects in randomized experiments. NBER Working Paper No. 24678.
- [21] Cohen, P., Hahn, R., Hall, J., Levitt, S., & Metcalfe, R. (2016). Using big data to estimate consumer surplus: The case of Uber. NBER Working Paper No. 22627.
- [22] Cook, C., Kreidieh, A., Vasserman, S., Allcott, H., Arora, N., van Sambeek, F., Tomkins, A., & Turkel, E. (2025). The short-run effects of congestion pricing in New York City (bản sửa: The network-wide effects of congestion pricing: Evidence from New York City). NBER Working Paper No. 33584.
- [23] Correia, S. (2016). Linear models with high-dimensional fixed effects: An efficient and feasible estimator. Working paper, Duke University.
- [24] Cramer, J., & Krueger, A. B. (2016). Disruptive change in the taxi business: The case of Uber. *American Economic Review*, 106(5), 177–182.
- [25] de Montjoye, Y.-A., Hidalgo, C. A., Verleysen, M., & Blondel, V. D. (2013). Unique in the crowd: The privacy bounds of human mobility. *Scientific Reports*, 3, 1376.
- [26] Dean, J., & Ghemawat, S. (2008). MapReduce: Simplified data processing on large clusters. *Communications of the ACM*, 51(1), 107–113.
- [27] Douriez, M., Doraiswamy, H., Freire, J., & Silva, C. T. (2016). Anonymizing NYC taxi data: Does it matter? *Proceedings of the 2016 IEEE International Conference on Data Science and Advanced Analytics (DSAA)*, 140–148.
- [28] Duranton, G., & Turner, M. A. (2011). The fundamental law of road congestion: Evidence from US cities. *American Economic Review*, 101(6), 2616–2652.

- [29] Dwork, C., & Roth, A. (2014). The algorithmic foundations of differential privacy. *Foundations and Trends in Theoretical Computer Science*, 9(3–4), 211–407.
- [30] Dwork, C., McSherry, F., Nissim, K., & Smith, A. (2006). Calibrating noise to sensitivity in private data analysis. *Theory of Cryptography Conference (TCC 2006)*, Lecture Notes in Computer Science 3876, 265–284.
- [31] Eliasson, J. (2009). A cost–benefit analysis of the Stockholm congestion charging system. *Transportation Research Part A: Policy and Practice*, 43(4), 468–480.
- [32] Erhardt, G. D., Roy, S., Cooper, D., Sana, B., Chen, M., & Castiglione, J. (2019). Do transportation network companies decrease or increase congestion? *Science Advances*, 5(5), eaau2670.
- [33] Ferman, B., & Pinto, C. (2021). Synthetic controls with imperfect pretreatment fit. *Quantitative Economics*, 12(4), 1197–1221.
- [34] Gibson, M., & Carnovale, M. (2015). The effects of road pricing on driver behavior and air pollution. *Journal of Urban Economics*, 89, 62–73.
- [35] Goodman-Bacon, A. (2021). Difference-in-differences with variation in treatment timing. *Journal of Econometrics*, 225(2), 254–277.
- [36] Green, C. P., Heywood, J. S., & Navarro Paniagua, M. (2020). Did the London congestion charge reduce pollution? *Regional Science and Urban Economics*, 84, 103573.
- [37] Guimarães, P., & Portugal, P. (2010). A simple feasible procedure to fit models with high-dimensional fixed effects. *The Stata Journal*, 10(4), 628–649.
- [38] Hanna, R., Kreindler, G., & Olken, B. A. (2017). Citywide effects of high-occupancy vehicle restrictions: Evidence from "three-in-one" in Jakarta. *Science*, 357(6346), 89–93.
- [39] Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.). OTexts.
- [40] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30.
- [41] Kennedy, E. H. (2023). Towards optimal doubly robust estimation of heterogeneous causal effects. *Electronic Journal of Statistics*, 17(2), 3008–3049.
- [42] Kohavi, R., Tang, D., & Xu, Y. (2020). *Trustworthy online controlled experiments: A practical guide to A/B testing*. Cambridge University Press.
- [43] Kreindler, G. (2024). Peak-hour road congestion pricing: Experimental evidence and equilibrium implications. *Econometrica*, 92(4), 1233–1268.
- [44] Laney, D. B. (2002). Improved control charts for attributes. *Quality Engineering*, 14(4), 531–537.

- [45] Laney, D. B. (2017). *Infonomics: How to monetize, manage, and measure information as an asset for competitive advantage*. Bibliomotion (Routledge).
- [46] Leape, J. (2006). The London congestion charge. *Journal of Economic Perspectives*, 20(4), 157–176.
- [47] Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. *Proceedings of the 2008 Eighth IEEE International Conference on Data Mining (ICDM)*, 413–422.
- [48] Melnik, S., Gubarev, A., Long, J. J., Romer, G., Shivakumar, S., Tolton, M., & Vassilakis, T. (2010). Dremel: Interactive analysis of web-scale datasets. *Proceedings of the VLDB Endowment*, 3(1–2), 330–339.
- [49] Metropolitan Transportation Authority (2025). Congestion Relief Zone tolls: Taxis and for-hire vehicles. <https://www.mta.info/fares-tolls/tolls/congestion-relief-zone/taxi-fhv-tolls> (truy cập 09/2026).
- [50] Montgomery, D. C. (2019). *Introduction to statistical quality control* (8th ed.). Wiley.
- [51] Moody, D., & Walsh, P. (1999). Measuring the value of information: An asset valuation approach. *Proceedings of the Seventh European Conference on Information Systems (ECIS)*.
- [52] New York City Taxi and Limousine Commission (2025). Data dictionary – High Volume FHV trip records. https://www.nyc.gov/assets/tlc/downloads/pdf/data_dictionary_trip_records_hvfhs.pdf.
- [53] New York City Taxi and Limousine Commission (2026). TLC Trip Record Data. <https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page> (truy cập 09/2026).
- [54] Nguyễn Thôn Dã (2026). Bài giảng Nghiên cứu Dữ liệu lớn trong kinh doanh, Chương 1–7. Trường Đại học Kinh tế – Luật, ĐHQG TP.HCM.
- [55] Olszewski, P., & Xie, L. (2005). Modelling the effects of road pricing on traffic in Singapore. *Transportation Research Part A: Policy and Practice*, 39(7–9), 755–772.
- [56] Pandey, A., Guler, I., & Gayah, V. (2026). The effect of the New York City congestion toll on trips served by transportation network companies. Findings. <https://doi.org/10.32866/001c.155761>.
- [57] Percoco, M. (2013). Is road pricing effective in abating pollution? Evidence from Milan. *Transportation Research Part D: Transport and Environment*, 25, 112–118.
- [58] Pigou, A. C. (1920). *The economics of welfare*. Macmillan.
- [59] Raasveldt, M., & Mühleisen, H. (2019). DuckDB: An embeddable analytical database. *Proceedings of the 2019 International Conference on Management of Data (SIGMOD)*, 1981–1984.
- [60] Rambachan, A., & Roth, J. (2023). A more credible approach to parallel trends. *Review of Economic Studies*, 90(5), 2555–2591.
- [61] Rochet, J.-C., & Tirole, J. (2003). Platform competition in two-sided markets. *Journal of the European Economic Association*, 1(4), 990–1029.

- [62] Rose, S., Borchert, O., Mitchell, S., & Connelly, S. (2020). Zero trust architecture (NIST Special Publication 800-207). National Institute of Standards and Technology.
- [63] Roth, J., Sant'Anna, P. H. C., Bilinski, A., & Poe, J. (2023). What's trending in difference-in-differences? A synthesis of the recent econometrics literature. *Journal of Econometrics*, 235(2), 2218–2244.
- [64] Santos, G., & Shaffer, B. (2004). Preliminary results of the London congestion charging scheme. *Public Works Management & Policy*, 9(2), 164–181.
- [65] Schaller, B. (2021). Can sharing a ride make for less traffic? Evidence from Uber and Lyft and implications for cities. *Transport Policy*, 102, 1–10.
- [66] Simeonova, E., Currie, J., Nilsson, P., & Walker, R. (2021). Congestion pricing, air pollution, and children's health. *Journal of Human Resources*, 56(4), 971–996.
- [67] Small, K. A., & Verhoef, E. T. (2007). *The economics of urban transportation*. Routledge.
- [68] Small, K. A., Winston, C., & Yan, J. (2005). Uncovering the distribution of motorists' preferences for travel time and reliability. *Econometrica*, 73(4), 1367–1382.
- [69] Sweeney, L. (2002). k-anonymity: A model for protecting privacy. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 10(5), 557–570.
- [70] Tirachini, A. (2020). Ride-hailing, travel behaviour and sustainable mobility: An international review. *Transportation*, 47, 2011–2047.
- [71] Vickrey, W. S. (1969). Congestion theory and transport investment. *American Economic Review*, 59(2), 251–260.
- [72] Walters, A. A. (1961). The theory and measurement of private and social cost of highway congestion. *Econometrica*, 29(4), 676–699.
- [73] Wang, R. Y., & Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12(4), 5–33.
- [74] Weyl, E. G., & Fabinger, M. (2013). Pass-through as an economic tool: Principles of incidence under imperfect competition. *Journal of Political Economy*, 121(3), 528–583.
- [75] Zaharia, M., Chowdhury, M., Das, T., Dave, A., Ma, J., McCauley, M., Franklin, M. J., Shenker, S., & Stoica, I. (2012). Resilient distributed datasets: A fault-tolerant abstraction for in-memory cluster computing. *Proceedings of the 9th USENIX Symposium on Networked Systems Design and Implementation (NSDI)*, 15–28.
- [76] Zaharia, M., Xin, R. S., Wendell, P., Das, T., Armbrust, M., Dave, A., Meng, X., Rosen, J., Venkataraman, S., Franklin, M. J., Ghodsi, A., Gonzalez, J., Shenker, S., & Stoica, I. (2016). Apache Spark: A unified engine for big data processing. *Communications of the ACM*, 59(11), 56–65.

PHỤ LỤC A. HỒ SƠ CHI TIẾT THEO VÙNG

Phụ lục này trình bày hồ sơ của từng vùng taxi thuộc Manhattan (CRZ, vắt ranh giới và Manhattan phía bắc) và của 60 vùng quận ngoài có lưu lượng HVFHV lớn nhất năm 2024, là các vùng đóng góp nhiều nhất vào nhóm đối chứng. Mỗi hồ sơ so sánh cùng cửa sổ lịch 05/01 – 31/12 của hai năm 2024 và 2025. Số chuyến được tính bình quân mỗi ngày; các chỉ tiêu khác là trung bình theo chuyến đón tại vùng. Nhận xét dưới mỗi bảng được sinh tự động từ chính các con số trong bảng.

Để danh mục bảng và mục lục gọn, các hồ sơ vùng trong phụ lục này không được liệt kê riêng trong danh mục; mục lục chỉ liệt kê đến cấp nhóm vùng.

A.1. Nhóm CRZ (38 vùng)

A.1.1. Vùng 4 – Alphabet City

Bảng A.1. Hồ sơ vùng 4 – Alphabet City (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.011	1.804	-207	-10,3
Chuyến HVFHV trả/ngày	1.737	1.562	-175	-10,1
Giá cước cơ sở/chuyến (USD)	23,57	24,90	+1,33	+5,6
Thu nhập tài xế/chuyến (USD)	18,27	19,14	+0,87	+4,7
Tốc độ trung bình (dặm/giờ)	13,35	13,68	+0,33	+2,5
Thời gian chờ (phút)	5,05	4,97	-0,07	-1,4
Phí CBD/chuyến (USD)	0,000	1,482	+1,482	–
% chuyến đón có đích trong CRZ	62,0	60,3	-1,7	-2,8
Chuyến taxi vàng đón/ngày	183	355	+172	+94,1

So với cùng kỳ: Số chuyến đón giảm 10,3%, tốc độ tăng 0,33 dặm/giờ, thời gian chờ giảm 0,07 phút.

A.1.2. Vùng 12 – Battery Park

Bảng A.2. Hồ sơ vùng 12 – Battery Park (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	71	66	-6	-7,9
Chuyến HVFHV trả/ngày	125	117	-7	-5,7
Giá cước cơ sở/chuyến (USD)	31,91	33,36	+1,45	+4,5
Thu nhập tài xế/chuyến (USD)	22,87	23,47	+0,61	+2,6
Tốc độ trung bình (dặm/giờ)	12,84	13,23	+0,39	+3,0
Thời gian chờ (phút)	4,45	4,64	+0,19	+4,3
Phí CBD/chuyến (USD)	0,000	1,493	+1,493	–
% chuyến đón có đích trong CRZ	70,8	70,0	-0,8	-1,1
Chuyến taxi vàng đón/ngày	44	41	-3	-7,2

So với cùng kỳ: Số chuyến đón giảm 7,9%, tốc độ tăng 0,39 dặm/giờ, thời gian chờ tăng 0,19 phút.

A.1.3. Vùng 13 – Battery Park City

Bảng A.3. Hồ sơ vùng 13 – Battery Park City (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.782	2.724	-57	-2,1
Chuyến HVFHV trả/ngày	2.660	2.537	-123	-4,6
Giá cước cơ sở/chuyến (USD)	32,77	35,42	+2,65	+8,1
Thu nhập tài xế/chuyến (USD)	22,46	23,61	+1,15	+5,1
Tốc độ trung bình (dặm/giờ)	15,26	15,54	+0,28	+1,8
Thời gian chờ (phút)	4,52	4,49	-0,04	-0,9
Phí CBD/chuyến (USD)	0,000	1,440	+1,440	–
% chuyến đón có đích trong CRZ	69,0	68,2	-0,8	-1,2
Chuyến taxi vàng đón/ngày	669	753	+85	+12,7

So với cùng kỳ: Số chuyến đón giảm 2,1%, tốc độ tăng 0,28 dặm/giờ, thời gian chờ giảm 0,04 phút.

A.1.4. Vùng 45 – Chinatown

Bảng A.4. Hồ sơ vùng 45 – Chinatown (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	1.614	1.586	-28	-1,8
Chuyến HVFHV trả/ngày	1.458	1.421	-37	-2,5
Giá cước cơ sở/chuyến (USD)	25,88	26,92	+1,04	+4,0
Thu nhập tài xế/chuyến (USD)	19,57	20,15	+0,58	+2,9
Tốc độ trung bình (dặm/giờ)	13,54	13,69	+0,15	+1,1
Thời gian chờ (phút)	4,94	4,83	-0,11	-2,2
Phí CBD/chuyến (USD)	0,000	1,492	+1,492	–
% chuyến đón có đích trong CRZ	56,0	54,8	-1,2	-2,1
Chuyến taxi vàng đón/ngày	167	248	+81	+48,3

So với cùng kỳ: Số chuyến đón giảm 1,8%, tốc độ tăng 0,15 dặm/giờ, thời gian chờ giảm 0,11 phút.

A.1.5. Vùng 48 – Clinton East

Bảng A.5. Hồ sơ vùng 48 – Clinton East (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	6.008	5.713	-295	-4,9
Chuyến HVFHV trả/ngày	5.286	4.933	-352	-6,7
Giá cước cơ sở/chuyến (USD)	28,91	30,62	+1,70	+5,9
Thu nhập tài xế/chuyến (USD)	21,44	22,38	+0,95	+4,4
Tốc độ trung bình (dặm/giờ)	13,60	13,84	+0,24	+1,8
Thời gian chờ (phút)	4,42	4,27	-0,15	-3,4
Phí CBD/chuyến (USD)	0,000	1,494	+1,494	–
% chuyến đón có đích trong CRZ	52,5	52,6	+0,1	+0,2
Chuyến taxi vàng đón/ngày	2.722	2.851	+129	+4,7

So với cùng kỳ: Số chuyến đón giảm 4,9%, tốc độ tăng 0,24 dặm/giờ, thời gian chờ giảm 0,15 phút.

A.1.6. Vùng 50 – Clinton West

Bảng A.6. Hồ sơ vùng 50 – Clinton West (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.598	3.309	-289	-8,0
Chuyến HVFHV trả/ngày	3.120	2.852	-268	-8,6
Giá cước cơ sở/chuyến (USD)	25,83	27,26	+1,43	+5,6
Thu nhập tài xế/chuyến (USD)	19,20	19,95	+0,75	+3,9
Tốc độ trung bình (dặm/giờ)	13,20	13,44	+0,23	+1,8
Thời gian chờ (phút)	4,50	4,43	-0,07	-1,5
Phí CBD/chuyến (USD)	0,000	1,472	+1,472	–
% chuyến đón có đích trong CRZ	59,2	59,2	+0,0	+0,1
Chuyến taxi vàng đón/ngày	655	787	+132	+20,2

So với cùng kỳ: Số chuyến đón giảm 8,0%, tốc độ tăng 0,23 dặm/giờ, thời gian chờ giảm 0,07 phút.

A.1.7. Vùng 68 – East Chelsea

Bảng A.7. Hồ sơ vùng 68 – East Chelsea (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	6.859	6.399	-461	-6,7
Chuyến HVFHV trả/ngày	7.104	6.805	-299	-4,2
Giá cước cơ sở/chuyến (USD)	30,38	32,64	+2,27	+7,5
Thu nhập tài xế/chuyến (USD)	21,69	22,67	+0,98	+4,5
Tốc độ trung bình (dặm/giờ)	12,01	12,25	+0,25	+2,1
Thời gian chờ (phút)	4,29	4,17	-0,12	-2,7
Phí CBD/chuyến (USD)	0,000	1,493	+1,493	–
% chuyến đón có đích trong CRZ	63,0	62,4	-0,6	-0,9
Chuyến taxi vàng đón/ngày	2.932	3.122	+190	+6,5

So với cùng kỳ: Số chuyến đón giảm 6,7%, tốc độ tăng 0,25 dặm/giờ, thời gian chờ giảm 0,12 phút.

A.1.8. Vùng 79 – East Village

Bảng A.8. Hồ sơ vùng 79 – East Village (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	8.373	7.570	-803	-9,6
Chuyến HVFHV trả/ngày	7.113	6.462	-652	-9,2
Giá cước cơ sở/chuyến (USD)	24,68	26,47	+1,79	+7,3
Thu nhập tài xế/chuyến (USD)	18,16	19,15	+0,99	+5,4
Tốc độ trung bình (dặm/giờ)	12,79	13,11	+0,31	+2,4
Thời gian chờ (phút)	4,32	4,20	-0,12	-2,8
Phí CBD/chuyến (USD)	0,000	1,493	+1,493	–
% chuyến đón có đích trong CRZ	61,4	59,9	-1,6	-2,5
Chuyến taxi vàng đón/ngày	2.500	2.998	+498	+19,9

So với cùng kỳ: Số chuyến đón giảm 9,6%, tốc độ tăng 0,31 dặm/giờ, thời gian chờ giảm 0,12 phút.

A.1.9. Vùng 87 – Financial District North

Bảng A.9. Hồ sơ vùng 87 – Financial District North (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.879	3.844	-35	-0,9
Chuyến HVFHV trả/ngày	3.795	3.699	-95	-2,5
Giá cước cơ sở/chuyến (USD)	32,83	35,04	+2,21	+6,7
Thu nhập tài xế/chuyến (USD)	23,76	24,88	+1,12	+4,7
Tốc độ trung bình (dặm/giờ)	15,46	15,59	+0,13	+0,9
Thời gian chờ (phút)	4,44	4,47	+0,03	+0,6
Phí CBD/chuyến (USD)	0,000	1,486	+1,486	–
% chuyến đón có đích trong CRZ	58,7	57,4	-1,3	-2,2
Chuyến taxi vàng đón/ngày	612	818	+207	+33,8

So với cùng kỳ: Số chuyến đón giảm 0,9%, tốc độ tăng 0,13 dặm/giờ, thời gian chờ tăng 0,03 phút.

A.1.10. Vùng 88 – Financial District South

Bảng A.10. Hồ sơ vùng 88 – Financial District South (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	1.601	1.580	-21	-1,3
Chuyến HVFHV trả/ngày	1.671	1.667	-4	-0,2
Giá cước cơ sở/chuyến (USD)	34,32	36,62	+2,30	+6,7
Thu nhập tài xế/chuyến (USD)	24,42	25,56	+1,14	+4,7
Tốc độ trung bình (dặm/giờ)	15,52	15,80	+0,28	+1,8
Thời gian chờ (phút)	4,63	4,63	+0,00	+0,0
Phí CBD/chuyến (USD)	0,000	1,446	+1,446	–
% chuyến đón có đích trong CRZ	58,9	57,8	-1,1	-1,8
Chuyến taxi vàng đón/ngày	327	409	+82	+25,2

So với cùng kỳ: Số chuyến đón giảm 1,3%, tốc độ tăng 0,28 dặm/giờ, thời gian chờ tăng 0,00 phút.

A.1.11. Vùng 90 – Flatiron

Bảng A.11. Hồ sơ vùng 90 – Flatiron (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.277	4.050	-227	-5,3
Chuyến HVFHV trả/ngày	3.775	3.557	-218	-5,8
Giá cước cơ sở/chuyến (USD)	27,49	29,52	+2,02	+7,4
Thu nhập tài xế/chuyến (USD)	19,65	20,45	+0,81	+4,1
Tốc độ trung bình (dặm/giờ)	12,24	12,47	+0,22	+1,8
Thời gian chờ (phút)	3,95	3,88	-0,07	-1,7
Phí CBD/chuyến (USD)	0,000	1,491	+1,491	–
% chuyến đón có đích trong CRZ	66,0	65,6	-0,4	-0,7
Chuyến taxi vàng đón/ngày	1.723	1.842	+119	+6,9

So với cùng kỳ: Số chuyến đón giảm 5,3%, tốc độ tăng 0,22 dặm/giờ, thời gian chờ giảm 0,07 phút.

A.1.12. Vùng 100 – Garment District

Bảng A.12. Hồ sơ vùng 100 – Garment District (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.376	3.160	-216	-6,4
Chuyến HVFHV trả/ngày	3.058	2.888	-169	-5,5
Giá cước cơ sở/chuyến (USD)	32,45	35,13	+2,68	+8,2
Thu nhập tài xế/chuyến (USD)	23,26	24,51	+1,25	+5,4
Tốc độ trung bình (dặm/giờ)	12,95	13,23	+0,28	+2,2
Thời gian chờ (phút)	4,84	4,73	-0,11	-2,3
Phí CBD/chuyến (USD)	0,000	1,494	+1,494	–
% chuyến đón có đích trong CRZ	54,4	54,0	-0,4	-0,7
Chuyến taxi vàng đón/ngày	1.642	1.687	+46	+2,8

So với cùng kỳ: Số chuyến đón giảm 6,4%, tốc độ tăng 0,28 dặm/giờ, thời gian chờ giảm 0,11 phút.

A.1.13. Vùng 107 – Gramercy

Bảng A.13. Hồ sơ vùng 107 – Gramercy (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.996	4.555	-440	-8,8
Chuyến HVFHV trả/ngày	4.519	4.138	-381	-8,4
Giá cước cơ sở/chuyến (USD)	25,19	27,36	+2,17	+8,6
Thu nhập tài xế/chuyến (USD)	18,33	19,43	+1,11	+6,0
Tốc độ trung bình (dặm/giờ)	12,56	12,78	+0,22	+1,8
Thời gian chờ (phút)	4,15	4,09	-0,06	-1,4
Phí CBD/chuyến (USD)	0,000	1,492	+1,492	–
% chuyến đón có đích trong CRZ	63,7	62,4	-1,3	-2,0
Chuyến taxi vàng đón/ngày	2.173	2.305	+133	+6,1

So với cùng kỳ: Số chuyến đón giảm 8,8%, tốc độ tăng 0,22 dặm/giờ, thời gian chờ giảm 0,06 phút.

A.1.14. Vùng 113 – Greenwich Village North

Bảng A.14. Hồ sơ vùng 113 – Greenwich Village North (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.894	3.586	-308	-7,9
Chuyến HVFHV trả/ngày	3.415	3.156	-259	-7,6
Giá cước cơ sở/chuyến (USD)	26,78	28,86	+2,08	+7,8
Thu nhập tài xế/chuyến (USD)	18,94	19,78	+0,84	+4,4
Tốc độ trung bình (dặm/giờ)	11,41	11,72	+0,31	+2,7
Thời gian chờ (phút)	4,18	4,06	-0,11	-2,7
Phí CBD/chuyến (USD)	0,000	1,493	+1,493	–
% chuyến đón có đích trong CRZ	66,4	65,5	-0,9	-1,4
Chuyến taxi vàng đón/ngày	1.543	1.697	+154	+10,0

So với cùng kỳ: Số chuyến đón giảm 7,9%, tốc độ tăng 0,31 dặm/giờ, thời gian chờ giảm 0,11 phút.

A.1.15. Vùng 114 – Greenwich Village South

Bảng A.15. Hồ sơ vùng 114 – Greenwich Village South (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.023	3.674	-349	-8,7
Chuyến HVFHV trả/ngày	3.707	3.389	-319	-8,6
Giá cước cơ sở/chuyến (USD)	25,91	28,02	+2,11	+8,1
Thu nhập tài xế/chuyến (USD)	18,30	19,30	+1,00	+5,5
Tốc độ trung bình (dặm/giờ)	11,51	11,87	+0,36	+3,1
Thời gian chờ (phút)	4,42	4,23	-0,20	-4,4
Phí CBD/chuyến (USD)	0,000	1,493	+1,493	–
% chuyến đón có đích trong CRZ	66,4	64,9	-1,6	-2,4
Chuyến taxi vàng đón/ngày	1.580	1.773	+193	+12,2

So với cùng kỳ: Số chuyến đón giảm 8,7%, tốc độ tăng 0,36 dặm/giờ, thời gian chờ giảm 0,20 phút.

A.1.16. Vùng 125 – Hudson Sq

Bảng A.16. Hồ sơ vùng 125 – Hudson Sq (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.209	2.213	+4	+0,2
Chuyến HVFHV trả/ngày	1.988	2.023	+35	+1,8
Giá cước cơ sở/chuyến (USD)	30,03	32,89	+2,86	+9,5
Thu nhập tài xế/chuyến (USD)	20,62	21,92	+1,30	+6,3
Tốc độ trung bình (dặm/giờ)	12,51	12,84	+0,33	+2,6
Thời gian chờ (phút)	4,28	4,16	-0,12	-2,8
Phí CBD/chuyến (USD)	0,000	1,493	+1,493	–
% chuyến đón có đích trong CRZ	67,3	65,6	-1,6	-2,4
Chuyến taxi vàng đón/ngày	550	602	+53	+9,6

So với cùng kỳ: Số chuyến đón tăng 0,2%, tốc độ tăng 0,33 dặm/giờ, thời gian chờ giảm 0,12 phút.

A.1.17. Vùng 137 – Kips Bay

Bảng A.17. Hồ sơ vùng 137 – Kips Bay (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.510	3.253	-257	-7,3
Chuyến HVFHV trả/ngày	3.590	3.348	-242	-6,7
Giá cước cơ sở/chuyến (USD)	23,62	25,05	+1,44	+6,1
Thu nhập tài xế/chuyến (USD)	18,41	19,45	+1,04	+5,6
Tốc độ trung bình (dặm/giờ)	13,79	14,17	+0,38	+2,7
Thời gian chờ (phút)	4,56	4,48	-0,09	-1,9
Phí CBD/chuyến (USD)	0,000	1,488	+1,488	–
% chuyến đón có đích trong CRZ	57,2	55,1	-2,0	-3,6
Chuyến taxi vàng đón/ngày	1.147	1.297	+150	+13,1

So với cùng kỳ: Số chuyến đón giảm 7,3%, tốc độ tăng 0,38 dặm/giờ, thời gian chờ giảm 0,09 phút.

A.1.18. Vùng 144 – Little Italy/NoLiTa

Bảng A.18. Hồ sơ vùng 144 – Little Italy/NoLiTa (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.595	4.288	-307	-6,7
Chuyến HVFHV trả/ngày	3.966	3.709	-256	-6,5
Giá cước cơ sở/chuyến (USD)	27,32	29,34	+2,02	+7,4
Thu nhập tài xế/chuyến (USD)	19,06	19,95	+0,89	+4,7
Tốc độ trung bình (dặm/giờ)	11,68	12,04	+0,36	+3,1
Thời gian chờ (phút)	4,55	4,41	-0,14	-3,1
Phí CBD/chuyến (USD)	0,000	1,493	+1,493	–
% chuyến đón có đích trong CRZ	64,2	62,9	-1,4	-2,1
Chuyến taxi vàng đón/ngày	1.116	1.339	+223	+19,9

So với cùng kỳ: Số chuyến đón giảm 6,7%, tốc độ tăng 0,36 dặm/giờ, thời gian chờ giảm 0,14 phút.

A.1.19. Vùng 148 – Lower East Side

Bảng A.19. Hồ sơ vùng 148 – Lower East Side (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	6.575	6.300	-276	-4,2
Chuyến HVFHV trả/ngày	5.287	5.020	-268	-5,1
Giá cước cơ sở/chuyến (USD)	26,52	28,12	+1,60	+6,0
Thu nhập tài xế/chuyến (USD)	19,19	20,06	+0,86	+4,5
Tốc độ trung bình (dặm/giờ)	13,56	13,90	+0,34	+2,5
Thời gian chờ (phút)	4,78	4,57	-0,21	-4,4
Phí CBD/chuyến (USD)	0,000	1,494	+1,494	–
% chuyến đón có đích trong CRZ	54,3	53,0	-1,4	-2,6
Chuyến taxi vàng đón/ngày	1.181	1.467	+287	+24,3

So với cùng kỳ: Số chuyến đón giảm 4,2%, tốc độ tăng 0,34 dặm/giờ, thời gian chờ giảm 0,21 phút.

A.1.20. Vùng 158 – Meatpacking/West Village West

Bảng A.20. Hồ sơ vùng 158 – Meatpacking/West Village West (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.766	3.547	-219	-5,8
Chuyến HVFHV trả/ngày	3.497	3.321	-176	-5,0
Giá cước cơ sở/chuyến (USD)	28,21	30,99	+2,78	+9,8
Thu nhập tài xế/chuyến (USD)	19,39	20,45	+1,06	+5,5
Tốc độ trung bình (dặm/giờ)	11,39	11,57	+0,18	+1,6
Thời gian chờ (phút)	4,20	4,07	-0,13	-3,0
Phí CBD/chuyến (USD)	0,000	1,486	+1,486	–
% chuyến đón có đích trong CRZ	72,8	72,4	-0,4	-0,5
Chuyến taxi vàng đón/ngày	1.098	1.223	+126	+11,4

So với cùng kỳ: Số chuyến đón giảm 5,8%, tốc độ tăng 0,18 dặm/giờ, thời gian chờ giảm 0,13 phút.

A.1.21. Vùng 161 – Midtown Center

Bảng A.21. Hồ sơ vùng 161 – Midtown Center (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	7.076	7.070	-6	-0,1
Chuyến HVFHV trả/ngày	6.873	6.813	-60	-0,9
Giá cước cơ sở/chuyến (USD)	33,04	36,44	+3,40	+10,3
Thu nhập tài xế/chuyến (USD)	21,96	23,37	+1,40	+6,4
Tốc độ trung bình (dặm/giờ)	11,60	11,62	+0,02	+0,2
Thời gian chờ (phút)	4,84	4,63	-0,22	-4,5
Phí CBD/chuyến (USD)	0,000	1,494	+1,494	–
% chuyến đón có đích trong CRZ	56,5	56,5	-0,0	-0,0
Chuyến taxi vàng đón/ngày	5.067	5.319	+251	+5,0

So với cùng kỳ: Số chuyến đón giảm 0,1%, tốc độ tăng 0,02 dặm/giờ, thời gian chờ giảm 0,22 phút.

A.1.22. Vùng 162 – Midtown East

Bảng A.22. Hồ sơ vùng 162 – Midtown East (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.843	4.834	-9	-0,2
Chuyến HVFHV trả/ngày	5.398	5.285	-113	-2,1
Giá cước cơ sở/chuyến (USD)	31,19	34,12	+2,92	+9,4
Thu nhập tài xế/chuyến (USD)	21,26	22,48	+1,22	+5,7
Tốc độ trung bình (dặm/giờ)	12,47	12,66	+0,19	+1,5
Thời gian chờ (phút)	4,22	4,04	-0,17	-4,1
Phí CBD/chuyến (USD)	0,000	1,493	+1,493	–
% chuyến đón có đích trong CRZ	51,9	50,8	-1,1	-2,1
Chuyến taxi vàng đón/ngày	3.761	3.863	+102	+2,7

So với cùng kỳ: Số chuyến đón giảm 0,2%, tốc độ tăng 0,19 dặm/giờ, thời gian chờ giảm 0,17 phút.

A.1.23. Vùng 163 – Midtown North

Bảng A.23. Hồ sơ vùng 163 – Midtown North (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	5.068	5.014	-54	-1,1
Chuyến HVFHV trả/ngày	4.586	4.519	-67	-1,5
Giá cước cơ sở/chuyến (USD)	34,05	37,17	+3,13	+9,2
Thu nhập tài xế/chuyến (USD)	22,92	24,21	+1,28	+5,6
Tốc độ trung bình (dặm/giờ)	12,06	12,06	-0,01	-0,1
Thời gian chờ (phút)	4,27	4,10	-0,17	-4,0
Phí CBD/chuyến (USD)	0,000	1,494	+1,494	–
% chuyến đón có đích trong CRZ	53,5	53,4	-0,1	-0,2
Chuyến taxi vàng đón/ngày	3.094	3.150	+56	+1,8

So với cùng kỳ: Số chuyến đón giảm 1,1%, tốc độ giảm 0,01 dặm/giờ, thời gian chờ giảm 0,17 phút.

A.1.24. Vùng 164 – Midtown South

Bảng A.24. Hồ sơ vùng 164 – Midtown South (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	6.454	6.143	-310	-4,8
Chuyến HVFHV trả/ngày	5.829	5.493	-336	-5,8
Giá cước cơ sở/chuyến (USD)	30,14	32,78	+2,64	+8,8
Thu nhập tài xế/chuyến (USD)	21,06	22,28	+1,22	+5,8
Tốc độ trung bình (dặm/giờ)	13,08	13,37	+0,29	+2,2
Thời gian chờ (phút)	4,46	4,39	-0,07	-1,6
Phí CBD/chuyến (USD)	0,000	1,494	+1,494	–
% chuyến đón có đích trong CRZ	58,6	57,7	-0,9	-1,5
Chuyến taxi vàng đón/ngày	2.465	2.571	+107	+4,3

So với cùng kỳ: Số chuyến đón giảm 4,8%, tốc độ tăng 0,29 dặm/giờ, thời gian chờ giảm 0,07 phút.

A.1.25. Vùng 170 – Murray Hill

Bảng A.25. Hồ sơ vùng 170 – Murray Hill (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	5.674	5.430	-244	-4,3
Chuyến HVFHV trả/ngày	5.968	5.627	-341	-5,7
Giá cước cơ sở/chuyến (USD)	26,96	28,79	+1,83	+6,8
Thu nhập tài xế/chuyến (USD)	19,28	20,17	+0,89	+4,6
Tốc độ trung bình (dặm/giờ)	12,88	13,20	+0,32	+2,5
Thời gian chờ (phút)	4,39	4,29	-0,10	-2,3
Phí CBD/chuyến (USD)	0,000	1,493	+1,493	–
% chuyến đón có đích trong CRZ	59,8	58,8	-1,0	-1,6
Chuyến taxi vàng đón/ngày	3.103	3.242	+139	+4,5

So với cùng kỳ: Số chuyến đón giảm 4,3%, tốc độ tăng 0,32 dặm/giờ, thời gian chờ giảm 0,10 phút.

A.1.26. Vùng 186 – Penn Station/Madison Sq West

Bảng A.26. Hồ sơ vùng 186 – Penn Station/Madison Sq West (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.843	3.718	-125	-3,2
Chuyến HVFHV trả/ngày	5.405	4.913	-493	-9,1
Giá cước cơ sở/chuyến (USD)	29,51	31,19	+1,67	+5,7
Thu nhập tài xế/chuyến (USD)	21,49	22,16	+0,66	+3,1
Tốc độ trung bình (dặm/giờ)	12,09	12,34	+0,25	+2,0
Thời gian chờ (phút)	4,38	4,24	-0,14	-3,2
Phí CBD/chuyến (USD)	0,000	1,494	+1,494	–
% chuyến đón có đích trong CRZ	60,5	60,6	+0,1	+0,2
Chuyến taxi vàng đón/ngày	3.595	3.936	+341	+9,5

So với cùng kỳ: Số chuyến đón giảm 3,2%, tốc độ tăng 0,25 dặm/giờ, thời gian chờ giảm 0,14 phút.

A.1.27. Vùng 209 – Seaport

Bảng A.27. Hồ sơ vùng 209 – Seaport (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	1.460	1.369	-91	-6,2
Chuyến HVFHV trả/ngày	1.372	1.269	-103	-7,5
Giá cước cơ sở/chuyến (USD)	30,76	32,65	+1,90	+6,2
Thu nhập tài xế/chuyến (USD)	22,28	23,33	+1,05	+4,7
Tốc độ trung bình (dặm/giờ)	15,09	15,21	+0,12	+0,8
Thời gian chờ (phút)	4,69	4,82	+0,13	+2,8
Phí CBD/chuyến (USD)	0,000	1,485	+1,485	–
% chuyến đón có đích trong CRZ	57,0	55,8	-1,2	-2,2
Chuyến taxi vàng đón/ngày	227	267	+41	+18,0

So với cùng kỳ: Số chuyến đón giảm 6,2%, tốc độ tăng 0,12 dặm/giờ, thời gian chờ tăng 0,13 phút.

A.1.28. Vùng 211 – SoHo

Bảng A.28. Hồ sơ vùng 211 – SoHo (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.603	3.472	-131	-3,6
Chuyến HVFHV trả/ngày	3.418	3.273	-145	-4,2
Giá cước cơ sở/chuyến (USD)	28,66	31,09	+2,43	+8,5
Thu nhập tài xế/chuyến (USD)	19,58	20,59	+1,02	+5,2
Tốc độ trung bình (dặm/giờ)	10,86	11,11	+0,26	+2,4
Thời gian chờ (phút)	4,21	4,03	-0,17	-4,1
Phí CBD/chuyến (USD)	0,000	1,494	+1,494	–
% chuyến đón có đích trong CRZ	69,3	68,4	-0,9	-1,3
Chuyến taxi vàng đón/ngày	899	1.029	+131	+14,6

So với cùng kỳ: Số chuyến đón giảm 3,6%, tốc độ tăng 0,26 dặm/giờ, thời gian chờ giảm 0,17 phút.

A.1.29. Vùng 224 – Stuy Town/Peter Cooper Village

Bảng A.29. Hồ sơ vùng 224 – Stuy Town/Peter Cooper Village (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	1.422	1.276	-146	-10,2
Chuyến HVFHV trả/ngày	1.194	1.067	-127	-10,7
Giá cước cơ sở/chuyến (USD)	24,38	26,04	+1,66	+6,8
Thu nhập tài xế/chuyến (USD)	18,50	19,48	+0,98	+5,3
Tốc độ trung bình (dặm/giờ)	13,60	14,02	+0,41	+3,0
Thời gian chờ (phút)	5,18	5,19	+0,01	+0,3
Phí CBD/chuyến (USD)	0,000	1,491	+1,491	–
% chuyến đón có đích trong CRZ	65,8	64,5	-1,3	-2,0
Chuyến taxi vàng đón/ngày	160	234	+73	+45,8

So với cùng kỳ: Số chuyến đón giảm 10,2%, tốc độ tăng 0,41 dặm/giờ, thời gian chờ tăng 0,01 phút.

A.1.30. Vùng 229 – Sutton Place/Turtle Bay North

Bảng A.30. Hồ sơ vùng 229 – Sutton Place/Turtle Bay North (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.733	3.500	-232	-6,2
Chuyến HVFHV trả/ngày	3.073	2.833	-239	-7,8
Giá cước cơ sở/chuyến (USD)	26,26	28,04	+1,78	+6,8
Thu nhập tài xế/chuyến (USD)	19,04	19,99	+0,96	+5,0
Tốc độ trung bình (dặm/giờ)	12,53	12,60	+0,06	+0,5
Thời gian chờ (phút)	3,97	3,85	-0,12	-3,0
Phí CBD/chuyến (USD)	0,000	1,493	+1,493	–
% chuyến đón có đích trong CRZ	49,9	48,8	-1,0	-2,1
Chuyến taxi vàng đón/ngày	1.892	1.913	+21	+1,1

So với cùng kỳ: Số chuyến đón giảm 6,2%, tốc độ tăng 0,06 dặm/giờ, thời gian chờ giảm 0,12 phút.

A.1.31. Vùng 230 – Times Sq/Theatre District

Bảng A.31. Hồ sơ vùng 230 – Times Sq/Theatre District (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	7.326	7.139	-187	-2,5
Chuyến HVFHV trả/ngày	6.947	6.641	-306	-4,4
Giá cước cơ sở/chuyến (USD)	35,20	38,51	+3,31	+9,4
Thu nhập tài xế/chuyến (USD)	24,04	25,53	+1,48	+6,2
Tốc độ trung bình (dặm/giờ)	13,44	13,54	+0,10	+0,8
Thời gian chờ (phút)	5,07	4,88	-0,20	-3,9
Phí CBD/chuyến (USD)	0,000	1,495	+1,495	–
% chuyến đón có đích trong CRZ	53,2	53,1	-0,1	-0,2
Chuyến taxi vàng đón/ngày	3.631	3.788	+158	+4,3

So với cùng kỳ: Số chuyến đón giảm 2,5%, tốc độ tăng 0,10 dặm/giờ, thời gian chờ giảm 0,20 phút.

A.1.32. Vùng 231 – TriBeCa/Civic Center

Bảng A.32. Hồ sơ vùng 231 – TriBeCa/Civic Center (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	7.084	6.876	-208	-2,9
Chuyến HVFHV trả/ngày	6.259	6.072	-186	-3,0
Giá cước cơ sở/chuyến (USD)	29,98	32,18	+2,20	+7,3
Thu nhập tài xế/chuyến (USD)	20,78	21,83	+1,04	+5,0
Tốc độ trung bình (dặm/giờ)	13,15	13,33	+0,18	+1,4
Thời gian chờ (phút)	4,15	4,03	-0,12	-2,9
Phí CBD/chuyến (USD)	0,000	1,488	+1,488	–
% chuyến đón có đích trong CRZ	66,4	65,9	-0,5	-0,8
Chuyến taxi vàng đón/ngày	1.473	1.667	+194	+13,2

So với cùng kỳ: Số chuyến đón giảm 2,9%, tốc độ tăng 0,18 dặm/giờ, thời gian chờ giảm 0,12 phút.

A.1.33. Vùng 232 – Two Bridges/Seward Park

Bảng A.33. Hồ sơ vùng 232 – Two Bridges/Seward Park (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.883	2.689	-194	-6,7
Chuyến HVFHV trả/ngày	2.551	2.343	-208	-8,2
Giá cước cơ sở/chuyến (USD)	25,04	26,00	+0,96	+3,8
Thu nhập tài xế/chuyến (USD)	19,22	19,87	+0,66	+3,4
Tốc độ trung bình (dặm/giờ)	13,89	14,25	+0,36	+2,6
Thời gian chờ (phút)	5,44	5,38	-0,07	-1,2
Phí CBD/chuyến (USD)	0,000	1,485	+1,485	–
% chuyến đón có đích trong CRZ	57,9	56,0	-1,9	-3,2
Chuyến taxi vàng đón/ngày	161	293	+132	+81,5

So với cùng kỳ: Số chuyến đón giảm 6,7%, tốc độ tăng 0,36 dặm/giờ, thời gian chờ giảm 0,07 phút.

A.1.34. Vùng 233 – UN/Turtle Bay South

Bảng A.34. Hồ sơ vùng 233 – UN/Turtle Bay South (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.573	3.367	-206	-5,8
Chuyến HVFHV trả/ngày	3.364	3.094	-270	-8,0
Giá cước cơ sở/chuyến (USD)	26,48	28,02	+1,54	+5,8
Thu nhập tài xế/chuyến (USD)	18,99	19,66	+0,68	+3,6
Tốc độ trung bình (dặm/giờ)	12,89	13,27	+0,38	+3,0
Thời gian chờ (phút)	4,31	4,27	-0,04	-1,0
Phí CBD/chuyến (USD)	0,000	1,488	+1,488	–
% chuyến đón có đích trong CRZ	59,9	59,1	-0,8	-1,3
Chuyến taxi vàng đón/ngày	1.253	1.289	+36	+2,9

So với cùng kỳ: Số chuyến đón giảm 5,8%, tốc độ tăng 0,38 dặm/giờ, thời gian chờ giảm 0,04 phút.

A.1.35. Vùng 234 – Union Sq

Bảng A.35. Hồ sơ vùng 234 – Union Sq (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	6.497	6.488	-9	-0,1
Chuyến HVFHV trả/ngày	6.014	6.024	+10	+0,2
Giá cước cơ sở/chuyến (USD)	27,46	29,94	+2,48	+9,0
Thu nhập tài xế/chuyến (USD)	19,19	20,21	+1,03	+5,4
Tốc độ trung bình (dặm/giờ)	11,42	11,59	+0,17	+1,5
Thời gian chờ (phút)	4,24	4,16	-0,08	-1,9
Phí CBD/chuyến (USD)	0,000	1,493	+1,493	–
% chuyến đón có đích trong CRZ	66,1	65,2	-0,8	-1,3
Chuyến taxi vàng đón/ngày	2.934	3.252	+318	+10,8

So với cùng kỳ: Số chuyến đón giảm 0,1%, tốc độ tăng 0,17 dặm/giờ, thời gian chờ giảm 0,08 phút.

A.1.36. Vùng 246 – West Chelsea/Hudson Yards

Bảng A.36. Hồ sơ vùng 246 – West Chelsea/Hudson Yards (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	6.625	6.405	-220	-3,3
Chuyến HVFHV trả/ngày	6.721	6.425	-295	-4,4
Giá cước cơ sở/chuyến (USD)	28,86	31,22	+2,37	+8,2
Thu nhập tài xế/chuyến (USD)	20,11	21,00	+0,89	+4,4
Tốc độ trung bình (dặm/giờ)	11,16	11,40	+0,24	+2,2
Thời gian chờ (phút)	4,60	4,53	-0,07	-1,5
Phí CBD/chuyến (USD)	0,000	1,475	+1,475	–
% chuyến đón có đích trong CRZ	68,4	68,4	-0,0	-0,0
Chuyến taxi vàng đón/ngày	1.900	2.171	+271	+14,3

So với cùng kỳ: Số chuyến đón giảm 3,3%, tốc độ tăng 0,24 dặm/giờ, thời gian chờ giảm 0,07 phút.

A.1.37. Vùng 249 – West Village

Bảng A.37. Hồ sơ vùng 249 – West Village (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	5.846	5.379	-467	-8,0
Chuyến HVFHV trả/ngày	5.222	4.878	-344	-6,6
Giá cước cơ sở/chuyến (USD)	26,13	28,17	+2,04	+7,8
Thu nhập tài xế/chuyến (USD)	18,51	19,39	+0,88	+4,8
Tốc độ trung bình (dặm/giờ)	11,50	11,69	+0,18	+1,6
Thời gian chờ (phút)	4,35	4,17	-0,18	-4,1
Phí CBD/chuyến (USD)	0,000	1,493	+1,493	–
% chuyến đón có đích trong CRZ	69,0	68,4	-0,6	-0,8
Chuyến taxi vàng đón/ngày	2.512	2.669	+157	+6,3

So với cùng kỳ: Số chuyến đón giảm 8,0%, tốc độ tăng 0,18 dặm/giờ, thời gian chờ giảm 0,18 phút.

A.1.38. Vùng 261 – World Trade Center

Bảng A.38. Hồ sơ vùng 261 – World Trade Center (CRZ, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.304	2.287	-16	-0,7
Chuyến HVFHV trả/ngày	2.395	2.343	-51	-2,1
Giá cước cơ sở/chuyến (USD)	35,30	38,59	+3,29	+9,3
Thu nhập tài xế/chuyến (USD)	24,89	26,38	+1,49	+6,0
Tốc độ trung bình (dặm/giờ)	14,97	15,19	+0,23	+1,5
Thời gian chờ (phút)	4,71	4,78	+0,08	+1,6
Phí CBD/chuyến (USD)	0,000	1,458	+1,458	–
% chuyến đón có đích trong CRZ	59,6	58,0	-1,6	-2,6
Chuyến taxi vàng đón/ngày	567	607	+41	+7,2

So với cùng kỳ: Số chuyến đón giảm 0,7%, tốc độ tăng 0,23 dặm/giờ, thời gian chờ tăng 0,08 phút.

A.2. Nhóm Vắt ranh giới (6 vùng)

A.2.1. Vùng 43 – Central Park

Bảng A.39. Hồ sơ vùng 43 – Central Park (Vắt ranh giới, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	952	943	-9	-1,0
Chuyến HVFHV trả/ngày	1.375	1.363	-12	-0,9
Giá cước cơ sở/chuyến (USD)	28,56	30,16	+1,60	+5,6
Thu nhập tài xế/chuyến (USD)	19,87	20,76	+0,89	+4,5
Tốc độ trung bình (dặm/giờ)	11,55	11,66	+0,11	+0,9
Thời gian chờ (phút)	4,26	4,31	+0,05	+1,2
Phí CBD/chuyến (USD)	0,000	0,983	+0,983	–
% chuyến đón có đích trong CRZ	50,7	48,0	-2,7	-5,3
Chuyến taxi vàng đón/ngày	1.724	1.631	-94	-5,4

So với cùng kỳ: Số chuyến đón giảm 1,0%, tốc độ tăng 0,11 dặm/giờ, thời gian chờ tăng 0,05 phút.

A.2.2. Vùng 140 – Lenox Hill East

Bảng A.40. Hồ sơ vùng 140 – Lenox Hill East (Vắt ranh giới, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.703	3.546	-157	-4,2
Chuyến HVFHV trả/ngày	3.926	3.856	-70	-1,8
Giá cước cơ sở/chuyến (USD)	26,46	27,49	+1,03	+3,9
Thu nhập tài xế/chuyến (USD)	20,35	21,43	+1,08	+5,3
Tốc độ trung bình (dặm/giờ)	14,18	14,14	-0,04	-0,3
Thời gian chờ (phút)	4,50	4,50	+0,00	+0,1
Phí CBD/chuyến (USD)	0,000	0,823	+0,823	–
% chuyến đón có đích trong CRZ	39,6	36,9	-2,7	-6,8
Chuyến taxi vàng đón/ngày	2.126	2.290	+164	+7,7

So với cùng kỳ: Số chuyến đón giảm 4,2%, tốc độ giảm 0,04 dặm/giờ, thời gian chờ tăng 0,00 phút.

A.2.3. Vùng 141 – Lenox Hill West

Bảng A.41. Hồ sơ vùng 141 – Lenox Hill West (Vắt ranh giới, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.122	4.000	-123	-3,0
Chuyến HVFHV trả/ngày	3.621	3.507	-114	-3,1
Giá cước cơ sở/chuyến (USD)	26,08	27,14	+1,06	+4,1
Thu nhập tài xế/chuyến (USD)	19,13	19,92	+0,80	+4,2
Tốc độ trung bình (dặm/giờ)	13,29	13,29	+0,01	+0,1
Thời gian chờ (phút)	4,16	4,12	-0,04	-1,0
Phí CBD/chuyến (USD)	0,000	0,899	+0,899	–
% chuyến đón có đích trong CRZ	43,1	40,5	-2,6	-6,0
Chuyến taxi vàng đón/ngày	2.460	2.593	+133	+5,4

So với cùng kỳ: Số chuyến đón giảm 3,0%, tốc độ tăng 0,01 dặm/giờ, thời gian chờ giảm 0,04 phút.

A.2.4. Vùng 142 – Lincoln Square East

Bảng A.42. Hồ sơ vùng 142 – Lincoln Square East (Vắt ranh giới, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.317	4.043	-275	-6,4
Chuyến HVFHV trả/ngày	4.214	3.977	-236	-5,6
Giá cước cơ sở/chuyến (USD)	28,85	30,69	+1,84	+6,4
Thu nhập tài xế/chuyến (USD)	20,58	21,54	+0,97	+4,7
Tốc độ trung bình (dặm/giờ)	13,22	13,29	+0,08	+0,6
Thời gian chờ (phút)	4,27	4,18	-0,09	-2,2
Phí CBD/chuyến (USD)	0,000	1,046	+1,046	–
% chuyến đón có đích trong CRZ	44,2	42,6	-1,6	-3,6
Chuyến taxi vàng đón/ngày	3.488	3.514	+25	+0,7

So với cùng kỳ: Số chuyến đón giảm 6,4%, tốc độ tăng 0,08 dặm/giờ, thời gian chờ giảm 0,09 phút.

A.2.5. Vùng 143 – Lincoln Square West

Bảng A.43. Hồ sơ vùng 143 – Lincoln Square West (Vắt ranh giới, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.202	3.058	-144	-4,5
Chuyến HVFHV trả/ngày	2.513	2.422	-91	-3,6
Giá cước cơ sở/chuyến (USD)	26,27	27,67	+1,40	+5,3
Thu nhập tài xế/chuyến (USD)	19,00	19,82	+0,82	+4,3
Tốc độ trung bình (dặm/giờ)	13,65	13,74	+0,09	+0,7
Thời gian chờ (phút)	4,41	4,31	-0,10	-2,3
Phí CBD/chuyến (USD)	0,000	0,977	+0,977	–
% chuyến đón có đích trong CRZ	46,1	45,0	-1,1	-2,4
Chuyến taxi vàng đón/ngày	1.209	1.322	+113	+9,3

So với cùng kỳ: Số chuyến đón giảm 4,5%, tốc độ tăng 0,09 dặm/giờ, thời gian chờ giảm 0,10 phút.

A.2.6. Vùng 237 – Upper East Side South

Bảng A.44. Hồ sơ vùng 237 – Upper East Side South (Vắt ranh giới, cách CRZ 0,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	5.058	5.166	+109	+2,1
Chuyến HVFHV trả/ngày	5.012	5.157	+145	+2,9
Giá cước cơ sở/chuyến (USD)	28,73	30,59	+1,86	+6,5
Thu nhập tài xế/chuyến (USD)	19,64	20,57	+0,93	+4,7
Tốc độ trung bình (dặm/giờ)	11,62	11,67	+0,05	+0,4
Thời gian chờ (phút)	3,92	3,84	-0,09	-2,2
Phí CBD/chuyến (USD)	0,000	0,990	+0,990	–
% chuyến đón có đích trong CRZ	44,8	43,6	-1,3	-2,8
Chuyến taxi vàng đón/ngày	5.106	5.473	+367	+7,2

So với cùng kỳ: Số chuyến đón tăng 2,1%, tốc độ tăng 0,05 dặm/giờ, thời gian chờ giảm 0,09 phút.

A.3. Nhóm Manhattan phía bắc (24 vùng)

A.3.1. Vùng 24 – Bloomingdale

Bảng A.45. Hồ sơ vùng 24 – Bloomingdale (Manhattan phía bắc, cách CRZ 3,81 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	906	857	-49	-5,4
Chuyến HVFHV trả/ngày	852	811	-41	-4,8
Giá cước cơ sở/chuyến (USD)	23,96	24,34	+0,38	+1,6
Thu nhập tài xế/chuyến (USD)	18,85	19,20	+0,35	+1,9
Tốc độ trung bình (dặm/giờ)	14,41	14,34	-0,07	-0,5
Thời gian chờ (phút)	4,36	4,44	+0,08	+1,8
Phí CBD/chuyến (USD)	0,000	0,323	+0,323	–
% chuyến đón có đích trong CRZ	20,9	17,7	-3,1	-15,0
Chuyến taxi vàng đón/ngày	277	320	+43	+15,4

So với cùng kỳ: Số chuyến đón giảm 5,4%, tốc độ giảm 0,07 dặm/giờ, thời gian chờ tăng 0,08 phút.

A.3.2. Vùng 41 – Central Harlem

Bảng A.46. Hồ sơ vùng 41 – Central Harlem (Manhattan phía bắc, cách CRZ 4,13 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.215	4.227	+12	+0,3
Chuyến HVFHV trả/ngày	3.899	3.887	-12	-0,3
Giá cước cơ sở/chuyến (USD)	21,42	21,08	-0,34	-1,6
Thu nhập tài xế/chuyến (USD)	16,86	16,97	+0,11	+0,6
Tốc độ trung bình (dặm/giờ)	14,07	13,82	-0,25	-1,8
Thời gian chờ (phút)	4,68	4,97	+0,29	+6,2
Phí CBD/chuyến (USD)	0,000	0,178	+0,178	–
% chuyến đón có đích trong CRZ	12,4	10,3	-2,1	-16,8
Chuyến taxi vàng đón/ngày	303	484	+181	+59,6

So với cùng kỳ: Số chuyến đón tăng 0,3%, tốc độ giảm 0,25 dặm/giờ, thời gian chờ tăng 0,29 phút.

A.3.3. Vùng 42 – Central Harlem North

Bảng A.47. Hồ sơ vùng 42 – Central Harlem North (Manhattan phía bắc, cách CRZ 5,43 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	5.785	5.760	-25	-0,4
Chuyến HVFHV trả/ngày	5.372	5.288	-84	-1,6
Giá cước cơ sở/chuyến (USD)	19,99	19,80	-0,19	-1,0
Thu nhập tài xế/chuyến (USD)	16,27	16,41	+0,14	+0,8
Tốc độ trung bình (dặm/giờ)	15,03	14,90	-0,13	-0,8
Thời gian chờ (phút)	4,92	5,22	+0,31	+6,2
Phí CBD/chuyến (USD)	0,000	0,150	+0,150	–
% chuyến đón có đích trong CRZ	10,3	8,9	-1,4	-13,6
Chuyến taxi vàng đón/ngày	148	332	+184	+124,3

So với cùng kỳ: Số chuyến đón giảm 0,4%, tốc độ giảm 0,13 dặm/giờ, thời gian chờ tăng 0,31 phút.

A.3.4. Vùng 74 – East Harlem North

Bảng A.48. Hồ sơ vùng 74 – East Harlem North (Manhattan phía bắc, cách CRZ 4,06 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.546	4.512	-34	-0,8
Chuyến HVFHV trả/ngày	4.439	4.394	-45	-1,0
Giá cước cơ sở/chuyến (USD)	19,77	19,70	-0,07	-0,4
Thu nhập tài xế/chuyến (USD)	16,31	16,72	+0,42	+2,6
Tốc độ trung bình (dặm/giờ)	14,83	14,55	-0,28	-1,9
Thời gian chờ (phút)	4,96	5,20	+0,24	+4,8
Phí CBD/chuyến (USD)	0,000	0,168	+0,168	–
% chuyến đón có đích trong CRZ	11,6	9,8	-1,8	-15,4
Chuyến taxi vàng đón/ngày	271	437	+166	+61,1

So với cùng kỳ: Số chuyến đón giảm 0,8%, tốc độ giảm 0,28 dặm/giờ, thời gian chờ tăng 0,24 phút.

A.3.5. Vùng 75 – East Harlem South

Bảng A.49. Hồ sơ vùng 75 – East Harlem South (Manhattan phía bắc, cách CRZ 3,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.153	3.981	-171	-4,1
Chuyến HVFHV trả/ngày	4.315	4.146	-169	-3,9
Giá cước cơ sở/chuyến (USD)	22,64	22,97	+0,34	+1,5
Thu nhập tài xế/chuyến (USD)	18,25	18,87	+0,61	+3,4
Tốc độ trung bình (dặm/giờ)	14,90	14,57	-0,33	-2,2
Thời gian chờ (phút)	4,75	4,90	+0,15	+3,2
Phí CBD/chuyến (USD)	0,000	0,294	+0,294	–
% chuyến đón có đích trong CRZ	17,5	15,4	-2,1	-12,0
Chuyến taxi vàng đón/ngày	682	854	+173	+25,3

So với cùng kỳ: Số chuyến đón giảm 4,1%, tốc độ giảm 0,33 dặm/giờ, thời gian chờ tăng 0,15 phút.

A.3.6. Vùng 104 – Governor's Island/Ellis Island/Liberty Island

Bảng A.50. Hồ sơ vùng 104 – Governor's Island/Ellis Island/Liberty Island (Manhattan phía bắc, cách CRZ 1,70 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	–	–	–	–
Chuyến HVFHV trả/ngày	0	0	-0	-33,1
Giá cước cơ sở/chuyến (USD)	–	–	–	–
Thu nhập tài xế/chuyến (USD)	–	–	–	–
Tốc độ trung bình (dặm/giờ)	–	–	–	–
Thời gian chờ (phút)	–	–	–	–
Phí CBD/chuyến (USD)	–	–	–	–
% chuyến đón có đích trong CRZ	–	–	–	–

A.3.7. Vùng 105 – Governor's Island/Ellis Island/Liberty Island

Bảng A.51. Hồ sơ vùng 105 – Governor's Island/Ellis Island/Liberty Island (Manhattan phía bắc, cách CRZ 0,74 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	0	0	-0	-5,0
Chuyến HVFHV trả/ngày	0	0	-0	-14,0
Giá cước cơ sở/chuyến (USD)	37,82	39,87	+2,05	+5,4
Thu nhập tài xế/chuyến (USD)	27,45	27,46	+0,01	+0,0
Tốc độ trung bình (dặm/giờ)	15,82	21,02	+5,20	+32,9
Thời gian chờ (phút)	8,92	9,64	+0,73	+8,2
Phí CBD/chuyến (USD)	0,000	0,958	+0,958	–
% chuyến đón có đích trong CRZ	68,4	50,0	-18,4	-26,9
Chuyến taxi vàng đón/ngày	0	0	+0	+75,5

So với cùng kỳ: Số chuyến đón giảm 5,0%, tốc độ tăng 5,20 dặm/giờ, thời gian chờ tăng 0,73 phút.

A.3.8. Vùng 116 – Hamilton Heights

Bảng A.52. Hồ sơ vùng 116 – Hamilton Heights (Manhattan phía bắc, cách CRZ 6,33 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.894	2.907	+13	+0,5
Chuyến HVFHV trả/ngày	2.822	2.778	-44	-1,6
Giá cước cơ sở/chuyến (USD)	21,25	21,09	-0,15	-0,7
Thu nhập tài xế/chuyến (USD)	17,43	17,52	+0,09	+0,5
Tốc độ trung bình (dặm/giờ)	15,57	15,44	-0,13	-0,8
Thời gian chờ (phút)	4,61	4,92	+0,31	+6,7
Phí CBD/chuyến (USD)	0,000	0,186	+0,186	–
% chuyến đón có đích trong CRZ	12,9	11,1	-1,8	-13,8
Chuyến taxi vàng đón/ngày	98	207	+108	+110,7

So với cùng kỳ: Số chuyến đón tăng 0,5%, tốc độ giảm 0,13 dặm/giờ, thời gian chờ tăng 0,31 phút.

A.3.9. Vùng 120 – Highbridge Park

Bảng A.53. Hồ sơ vùng 120 – Highbridge Park (Manhattan phía bắc, cách CRZ 7,77 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	65	59	-5	-7,9
Chuyến HVFHV trả/ngày	97	86	-11	-11,3
Giá cước cơ sở/chuyến (USD)	20,64	20,78	+0,14	+0,7
Thu nhập tài xế/chuyến (USD)	17,35	17,68	+0,33	+1,9
Tốc độ trung bình (dặm/giờ)	16,47	16,38	-0,09	-0,6
Thời gian chờ (phút)	4,65	5,02	+0,37	+8,0
Phí CBD/chuyến (USD)	0,000	0,139	+0,139	–
% chuyến đón có đích trong CRZ	9,4	8,6	-0,8	-8,4
Chuyến taxi vàng đón/ngày	1	2	+2	+255,2

So với cùng kỳ: Số chuyến đón giảm 7,9%, tốc độ giảm 0,09 dặm/giờ, thời gian chờ tăng 0,37 phút.

A.3.10. Vùng 127 – Inwood

Bảng A.54. Hồ sơ vùng 127 – Inwood (Manhattan phía bắc, cách CRZ 10,95 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.205	2.317	+112	+5,1
Chuyến HVFHV trả/ngày	2.299	2.349	+49	+2,2
Giá cước cơ sở/chuyến (USD)	20,60	20,71	+0,11	+0,5
Thu nhập tài xế/chuyến (USD)	17,11	17,44	+0,33	+1,9
Tốc độ trung bình (dặm/giờ)	16,58	16,52	-0,06	-0,4
Thời gian chờ (phút)	4,21	4,42	+0,21	+5,1
Phí CBD/chuyến (USD)	0,000	0,126	+0,126	–
% chuyến đón có đích trong CRZ	8,0	7,6	-0,4	-5,1
Chuyến taxi vàng đón/ngày	11	45	+34	+302,5

So với cùng kỳ: Số chuyến đón tăng 5,1%, tốc độ giảm 0,06 dặm/giờ, thời gian chờ tăng 0,21 phút.

A.3.11. Vùng 128 – Inwood Hill Park

Bảng A.55. Hồ sơ vùng 128 – Inwood Hill Park (Manhattan phía bắc, cách CRZ 11,78 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	175	187	+13	+7,4
Chuyến HVFHV trả/ngày	221	232	+11	+4,8
Giá cước cơ sở/chuyến (USD)	22,55	22,48	-0,07	-0,3
Thu nhập tài xế/chuyến (USD)	18,15	18,35	+0,20	+1,1
Tốc độ trung bình (dặm/giờ)	16,45	16,04	-0,41	-2,5
Thời gian chờ (phút)	4,15	4,31	+0,16	+3,9
Phí CBD/chuyến (USD)	0,000	0,148	+0,148	–
% chuyến đón có đích trong CRZ	8,8	8,7	-0,0	-0,1
Chuyến taxi vàng đón/ngày	1	3	+2	+246,9

So với cùng kỳ: Số chuyến đón tăng 7,4%, tốc độ giảm 0,41 dặm/giờ, thời gian chờ tăng 0,16 phút.

A.3.12. Vùng 151 – Manhattan Valley

Bảng A.56. Hồ sơ vùng 151 – Manhattan Valley (Manhattan phía bắc, cách CRZ 3,09 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	1.910	1.778	-132	-6,9
Chuyến HVFHV trả/ngày	1.740	1.652	-88	-5,1
Giá cước cơ sở/chuyến (USD)	24,72	25,39	+0,66	+2,7
Thu nhập tài xế/chuyến (USD)	19,11	19,72	+0,61	+3,2
Tốc độ trung bình (dặm/giờ)	14,88	14,83	-0,05	-0,3
Thời gian chờ (phút)	4,44	4,48	+0,04	+0,9
Phí CBD/chuyến (USD)	0,000	0,359	+0,359	–
% chuyến đón có đích trong CRZ	21,4	19,3	-2,1	-9,9
Chuyến taxi vàng đón/ngày	858	919	+62	+7,2

So với cùng kỳ: Số chuyến đón giảm 6,9%, tốc độ giảm 0,05 dặm/giờ, thời gian chờ tăng 0,04 phút.

A.3.13. Vùng 152 – Manhattanville

Bảng A.57. Hồ sơ vùng 152 – Manhattanville (Manhattan phía bắc, cách CRZ 5,44 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	1.441	1.404	-37	-2,5
Chuyến HVFHV trả/ngày	1.520	1.491	-28	-1,9
Giá cước cơ sở/chuyến (USD)	21,39	21,38	-0,01	-0,0
Thu nhập tài xế/chuyến (USD)	17,54	17,75	+0,22	+1,2
Tốc độ trung bình (dặm/giờ)	15,19	15,04	-0,15	-1,0
Thời gian chờ (phút)	4,67	4,93	+0,25	+5,4
Phí CBD/chuyến (USD)	0,000	0,224	+0,224	–
% chuyến đón có đích trong CRZ	14,4	12,9	-1,5	-10,6
Chuyến taxi vàng đón/ngày	79	137	+58	+73,7

So với cùng kỳ: Số chuyến đón giảm 2,5%, tốc độ giảm 0,15 dặm/giờ, thời gian chờ tăng 0,25 phút.

A.3.14. Vùng 153 – Marble Hill

Bảng A.58. Hồ sơ vùng 153 – Marble Hill (Manhattan phía bắc, cách CRZ 13,10 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	592	602	+10	+1,7
Chuyến HVFHV trả/ngày	499	512	+13	+2,6
Giá cước cơ sở/chuyến (USD)	16,98	17,15	+0,16	+1,0
Thu nhập tài xế/chuyến (USD)	14,03	14,32	+0,28	+2,0
Tốc độ trung bình (dặm/giờ)	14,58	14,46	-0,12	-0,8
Thời gian chờ (phút)	4,47	4,86	+0,39	+8,7
Phí CBD/chuyến (USD)	0,000	0,046	+0,046	–
% chuyến đón có đích trong CRZ	3,0	2,9	-0,1	-1,8
Chuyến taxi vàng đón/ngày	2	5	+4	+196,2

So với cùng kỳ: Số chuyến đón tăng 1,7%, tốc độ giảm 0,12 dặm/giờ, thời gian chờ tăng 0,39 phút.

A.3.15. Vùng 166 – Morningside Heights

Bảng A.59. Hồ sơ vùng 166 – Morningside Heights (Manhattan phía bắc, cách CRZ 4,12 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.750	2.648	-103	-3,7
Chuyến HVFHV trả/ngày	2.963	2.946	-18	-0,6
Giá cước cơ sở/chuyến (USD)	24,42	24,85	+0,42	+1,7
Thu nhập tài xế/chuyến (USD)	19,16	19,48	+0,32	+1,7
Tốc độ trung bình (dặm/giờ)	14,49	14,43	-0,06	-0,4
Thời gian chờ (phút)	4,23	4,32	+0,09	+2,2
Phí CBD/chuyến (USD)	0,000	0,310	+0,310	–
% chuyến đón có đích trong CRZ	19,5	16,9	-2,6	-13,4
Chuyến taxi vàng đón/ngày	521	655	+134	+25,8

So với cùng kỳ: Số chuyến đón giảm 3,7%, tốc độ giảm 0,06 dặm/giờ, thời gian chờ tăng 0,09 phút.

A.3.16. Vùng 194 – Randalls Island

Bảng A.60. Hồ sơ vùng 194 – Randalls Island (Manhattan phía bắc, cách CRZ 3,40 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	110	139	+29	+26,3
Chuyến HVFHV trả/ngày	256	285	+28	+11,0
Giá cước cơ sở/chuyến (USD)	32,50	33,35	+0,85	+2,6
Thu nhập tài xế/chuyến (USD)	38,51	39,28	+0,77	+2,0
Tốc độ trung bình (dặm/giờ)	16,93	16,76	-0,17	-1,0
Thời gian chờ (phút)	7,62	7,57	-0,05	-0,7
Phí CBD/chuyến (USD)	0,000	0,362	+0,362	–
% chuyến đón có đích trong CRZ	21,4	22,1	+0,7	+3,4
Chuyến taxi vàng đón/ngày	5	5	+1	+19,7

So với cùng kỳ: Số chuyến đón tăng 26,3%, tốc độ giảm 0,17 dặm/giờ, thời gian chờ giảm 0,05 phút.

A.3.17. Vùng 202 – Roosevelt Island

Bảng A.61. Hồ sơ vùng 202 – Roosevelt Island (Manhattan phía bắc, cách CRZ 0,28 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	445	439	-6	-1,4
Chuyến HVFHV trả/ngày	524	496	-29	-5,5
Giá cước cơ sở/chuyến (USD)	29,63	30,56	+0,93	+3,1
Thu nhập tài xế/chuyến (USD)	24,51	25,00	+0,49	+2,0
Tốc độ trung bình (dặm/giờ)	14,05	14,13	+0,08	+0,6
Thời gian chờ (phút)	5,85	6,27	+0,42	+7,1
Phí CBD/chuyến (USD)	0,000	0,337	+0,337	–
% chuyến đón có đích trong CRZ	19,7	18,6	-1,1	-5,7
Chuyến taxi vàng đón/ngày	5	14	+9	+164,8

So với cùng kỳ: Số chuyến đón giảm 1,4%, tốc độ tăng 0,08 dặm/giờ, thời gian chờ tăng 0,42 phút.

A.3.18. Vùng 236 – Upper East Side North

Bảng A.62. Hồ sơ vùng 236 – Upper East Side North (Manhattan phía bắc, cách CRZ 1,45 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.570	4.379	-192	-4,2
Chuyến HVFHV trả/ngày	4.575	4.392	-182	-4,0
Giá cước cơ sở/chuyến (USD)	28,20	29,57	+1,38	+4,9
Thu nhập tài xế/chuyến (USD)	19,78	20,69	+0,91	+4,6
Tốc độ trung bình (dặm/giờ)	13,26	13,19	-0,07	-0,6
Thời gian chờ (phút)	4,17	4,15	-0,01	-0,3
Phí CBD/chuyến (USD)	0,000	0,634	+0,634	–
% chuyến đón có đích trong CRZ	36,0	33,9	-2,1	-5,8
Chuyến taxi vàng đón/ngày	4.611	4.780	+168	+3,7

So với cùng kỳ: Số chuyến đón giảm 4,2%, tốc độ giảm 0,07 dặm/giờ, thời gian chờ giảm 0,01 phút.

A.3.19. Vùng 238 – Upper West Side North

Bảng A.63. Hồ sơ vùng 238 – Upper West Side North (Manhattan phía bắc, cách CRZ 2,19 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.267	3.088	-180	-5,5
Chuyến HVFHV trả/ngày	3.038	2.904	-134	-4,4
Giá cước cơ sở/chuyến (USD)	26,40	27,46	+1,06	+4,0
Thu nhập tài xế/chuyến (USD)	19,65	20,55	+0,90	+4,6
Tốc độ trung bình (dặm/giờ)	14,94	15,06	+0,12	+0,8
Thời gian chờ (phút)	4,31	4,29	-0,02	-0,4
Phí CBD/chuyến (USD)	0,000	0,452	+0,452	–
% chuyến đón có đích trong CRZ	26,0	24,1	-1,9	-7,2
Chuyến taxi vàng đón/ngày	2.095	2.153	+58	+2,8

So với cùng kỳ: Số chuyến đón giảm 5,5%, tốc độ tăng 0,12 dặm/giờ, thời gian chờ giảm 0,02 phút.

A.3.20. Vùng 239 – Upper West Side South

Bảng A.64. Hồ sơ vùng 239 – Upper West Side South (Manhattan phía bắc, cách CRZ 1,05 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.014	3.740	-274	-6,8
Chuyến HVFHV trả/ngày	3.744	3.551	-192	-5,1
Giá cước cơ sở/chuyến (USD)	27,86	29,49	+1,64	+5,9
Thu nhập tài xế/chuyến (USD)	20,18	21,24	+1,06	+5,3
Tốc độ trung bình (dặm/giờ)	14,18	14,40	+0,22	+1,5
Thời gian chờ (phút)	4,20	4,12	-0,08	-2,0
Phí CBD/chuyến (USD)	0,000	0,650	+0,650	–
% chuyến đón có đích trong CRZ	35,8	33,6	-2,2	-6,2
Chuyến taxi vàng đón/ngày	3.027	3.043	+16	+0,5

So với cùng kỳ: Số chuyến đón giảm 6,8%, tốc độ tăng 0,22 dặm/giờ, thời gian chờ giảm 0,08 phút.

A.3.21. Vùng 243 – Washington Heights North

Bảng A.65. Hồ sơ vùng 243 – Washington Heights North (Manhattan phía bắc, cách CRZ 9,48 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.323	3.417	+94	+2,8
Chuyến HVFHV trả/ngày	3.195	3.160	-35	-1,1
Giá cước cơ sở/chuyến (USD)	21,82	21,98	+0,16	+0,7
Thu nhập tài xế/chuyến (USD)	18,16	18,35	+0,20	+1,1
Tốc độ trung bình (dặm/giờ)	16,57	16,54	-0,02	-0,1
Thời gian chờ (phút)	4,40	4,70	+0,30	+6,8
Phí CBD/chuyến (USD)	0,000	0,178	+0,178	–
% chuyến đón có đích trong CRZ	11,6	10,8	-0,8	-6,9
Chuyến taxi vàng đón/ngày	26	98	+72	+277,8

So với cùng kỳ: Số chuyến đón tăng 2,8%, tốc độ giảm 0,02 dặm/giờ, thời gian chờ tăng 0,30 phút.

A.3.22. Vùng 244 – Washington Heights South

Bảng A.66. Hồ sơ vùng 244 – Washington Heights South (Manhattan phía bắc, cách CRZ 7,76 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.712	4.748	+36	+0,8
Chuyến HVFHV trả/ngày	4.974	4.874	-100	-2,0
Giá cước cơ sở/chuyến (USD)	22,02	22,10	+0,08	+0,4
Thu nhập tài xế/chuyến (USD)	18,27	18,58	+0,31	+1,7
Tốc độ trung bình (dặm/giờ)	16,76	16,63	-0,13	-0,8
Thời gian chờ (phút)	4,35	4,66	+0,31	+7,1
Phí CBD/chuyến (USD)	0,000	0,181	+0,181	–
% chuyến đón có đích trong CRZ	11,7	10,6	-1,1	-9,0
Chuyến taxi vàng đón/ngày	85	225	+140	+164,3

So với cùng kỳ: Số chuyến đón tăng 0,8%, tốc độ giảm 0,13 dặm/giờ, thời gian chờ tăng 0,31 phút.

A.3.23. Vùng 262 – Yorkville East

Bảng A.67. Hồ sơ vùng 262 – Yorkville East (Manhattan phía bắc, cách CRZ 1,62 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.330	2.185	-145	-6,2
Chuyến HVFHV trả/ngày	2.003	1.902	-102	-5,1
Giá cước cơ sở/chuyến (USD)	26,12	26,85	+0,73	+2,8
Thu nhập tài xế/chuyến (USD)	19,37	20,18	+0,81	+4,2
Tốc độ trung bình (dặm/giờ)	15,34	15,20	-0,14	-0,9
Thời gian chờ (phút)	4,75	4,73	-0,02	-0,4
Phí CBD/chuyến (USD)	0,000	0,644	+0,644	–
% chuyến đón có đích trong CRZ	38,0	34,9	-3,1	-8,2
Chuyến taxi vàng đón/ngày	1.484	1.573	+90	+6,1

So với cùng kỳ: Số chuyến đón giảm 6,2%, tốc độ giảm 0,14 dặm/giờ, thời gian chờ giảm 0,02 phút.

A.3.24. Vùng 263 – Yorkville West

Bảng A.68. Hồ sơ vùng 263 – Yorkville West (Manhattan phía bắc, cách CRZ 1,62 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.436	3.313	-123	-3,6
Chuyến HVFHV trả/ngày	3.218	3.120	-98	-3,1
Giá cước cơ sở/chuyến (USD)	26,06	26,87	+0,81	+3,1
Thu nhập tài xế/chuyến (USD)	19,59	20,43	+0,84	+4,3
Tốc độ trung bình (dặm/giờ)	15,48	15,25	-0,23	-1,5
Thời gian chờ (phút)	4,34	4,35	+0,01	+0,2
Phí CBD/chuyến (USD)	0,000	0,611	+0,611	–
% chuyến đón có đích trong CRZ	33,3	30,9	-2,3	-7,0
Chuyến taxi vàng đón/ngày	2.026	2.133	+107	+5,3

So với cùng kỳ: Số chuyến đón giảm 3,6%, tốc độ giảm 0,23 dặm/giờ, thời gian chờ tăng 0,01 phút.

A.4. Quận ngoài: 60 vùng có lưu lượng lớn nhất

A.4.1. Vùng 18 – Bedford Park

Bảng A.69. Hồ sơ vùng 18 – Bedford Park (Bronx, cách CRZ 12,27 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.842	3.042	+201	+7,1
Chuyến HVFHV trả/ngày	2.815	2.998	+184	+6,5
Giá cước cơ sở/chuyến (USD)	17,78	17,85	+0,07	+0,4
Thu nhập tài xế/chuyến (USD)	15,03	15,26	+0,24	+1,6
Tốc độ trung bình (dặm/giờ)	13,85	13,80	-0,05	-0,4
Thời gian chờ (phút)	4,55	4,82	+0,26	+5,7
Phí CBD/chuyến (USD)	0,000	0,039	+0,039	–
% chuyến đón có đích trong CRZ	2,8	2,5	-0,3	-12,2
Chuyến taxi vàng đón/ngày	7	26	+19	+276,7

So với cùng kỳ: Số chuyến đón tăng 7,1%, tốc độ giảm 0,05 dặm/giờ, thời gian chờ tăng 0,26 phút.

A.4.2. Vùng 51 – Co-Op City

Bảng A.70. Hồ sơ vùng 51 – Co-Op City (Bronx, cách CRZ 15,78 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.251	2.360	+109	+4,9
Chuyến HVFHV trả/ngày	2.341	2.451	+109	+4,7
Giá cước cơ sở/chuyến (USD)	20,70	20,82	+0,13	+0,6
Thu nhập tài xế/chuyến (USD)	18,06	18,27	+0,21	+1,2
Tốc độ trung bình (dặm/giờ)	16,81	16,82	+0,01	+0,0
Thời gian chờ (phút)	5,09	5,40	+0,31	+6,0
Phí CBD/chuyến (USD)	0,000	0,030	+0,030	–
% chuyến đón có đích trong CRZ	2,2	2,0	-0,2	-7,9
Chuyến taxi vàng đón/ngày	14	35	+21	+143,0

So với cùng kỳ: Số chuyến đón tăng 4,9%, tốc độ tăng 0,01 dặm/giờ, thời gian chờ tăng 0,31 phút.

A.4.3. Vùng 69 – East Concourse/Concourse Village

Bảng A.71. Hồ sơ vùng 69 – East Concourse/Concourse Village (Bronx, cách CRZ 7,14 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.173	3.340	+167	+5,3
Chuyến HVFHV trả/ngày	3.215	3.390	+175	+5,4
Giá cước cơ sở/chuyến (USD)	18,59	18,77	+0,18	+1,0
Thu nhập tài xế/chuyến (USD)	15,66	16,01	+0,35	+2,2
Tốc độ trung bình (dặm/giờ)	13,21	13,03	-0,18	-1,4
Thời gian chờ (phút)	4,87	5,09	+0,22	+4,5
Phí CBD/chuyến (USD)	0,000	0,066	+0,066	–
% chuyến đón có đích trong CRZ	4,6	4,1	-0,4	-9,8
Chuyến taxi vàng đón/ngày	17	45	+29	+174,5

So với cùng kỳ: Số chuyến đón tăng 5,3%, tốc độ giảm 0,18 dặm/giờ, thời gian chờ tăng 0,22 phút.

A.4.4. Vùng 78 – East Tremont

Bảng A.72. Hồ sơ vùng 78 – East Tremont (Bronx, cách CRZ 10,75 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.739	2.875	+136	+5,0
Chuyến HVFHV trả/ngày	2.680	2.807	+127	+4,7
Giá cước cơ sở/chuyến (USD)	17,85	17,93	+0,08	+0,4
Thu nhập tài xế/chuyến (USD)	15,17	15,36	+0,20	+1,3
Tốc độ trung bình (dặm/giờ)	13,77	13,68	-0,09	-0,6
Thời gian chờ (phút)	4,70	4,94	+0,25	+5,3
Phí CBD/chuyến (USD)	0,000	0,047	+0,047	–
% chuyến đón có đích trong CRZ	3,2	2,9	-0,3	-9,6
Chuyến taxi vàng đón/ngày	9	28	+20	+227,0

So với cùng kỳ: Số chuyến đón tăng 5,0%, tốc độ giảm 0,09 dặm/giờ, thời gian chờ tăng 0,25 phút.

A.4.5. Vùng 159 – Melrose South

Bảng A.73. Hồ sơ vùng 159 – Melrose South (Bronx, cách CRZ 6,93 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.839	2.978	+138	+4,9
Chuyến HVFHV trả/ngày	2.969	3.110	+142	+4,8
Giá cước cơ sở/chuyến (USD)	18,17	18,33	+0,17	+0,9
Thu nhập tài xế/chuyến (USD)	15,45	15,84	+0,39	+2,5
Tốc độ trung bình (dặm/giờ)	12,53	12,36	-0,17	-1,3
Thời gian chờ (phút)	4,67	4,83	+0,17	+3,5
Phí CBD/chuyến (USD)	0,000	0,063	+0,063	–
% chuyến đón có đích trong CRZ	4,4	4,0	-0,4	-9,9
Chuyến taxi vàng đón/ngày	15	41	+26	+178,5

So với cùng kỳ: Số chuyến đón tăng 4,9%, tốc độ giảm 0,17 dặm/giờ, thời gian chờ tăng 0,17 phút.

A.4.6. Vùng 167 – Morrisania/Melrose

Bảng A.74. Hồ sơ vùng 167 – Morrisania/Melrose (Bronx, cách CRZ 8,07 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.341	2.445	+104	+4,5
Chuyến HVFHV trả/ngày	2.259	2.386	+128	+5,6
Giá cước cơ sở/chuyến (USD)	17,95	18,15	+0,20	+1,1
Thu nhập tài xế/chuyến (USD)	15,30	15,68	+0,38	+2,5
Tốc độ trung bình (dặm/giờ)	12,47	12,32	-0,15	-1,2
Thời gian chờ (phút)	4,67	4,84	+0,17	+3,6
Phí CBD/chuyến (USD)	0,000	0,058	+0,058	–
% chuyến đón có đích trong CRZ	3,9	3,6	-0,3	-8,7
Chuyến taxi vàng đón/ngày	10	32	+21	+206,7

So với cùng kỳ: Số chuyến đón tăng 4,5%, tốc độ giảm 0,15 dặm/giờ, thời gian chờ tăng 0,17 phút.

A.4.7. Vùng 168 – Mott Haven/Port Morris

Bảng A.75. Hồ sơ vùng 168 – Mott Haven/Port Morris (Bronx, cách CRZ 5,59 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.894	4.249	+354	+9,1
Chuyến HVFHV trả/ngày	3.965	4.344	+378	+9,5
Giá cước cơ sở/chuyến (USD)	19,37	19,51	+0,14	+0,7
Thu nhập tài xế/chuyến (USD)	16,34	16,76	+0,42	+2,6
Tốc độ trung bình (dặm/giờ)	14,85	14,72	-0,13	-0,9
Thời gian chờ (phút)	4,85	5,08	+0,22	+4,6
Phí CBD/chuyến (USD)	0,000	0,102	+0,102	–
% chuyến đón có đích trong CRZ	6,6	6,3	-0,3	-4,8
Chuyến taxi vàng đón/ngày	29	80	+51	+178,0

So với cùng kỳ: Số chuyến đón tăng 9,1%, tốc độ giảm 0,13 dặm/giờ, thời gian chờ tăng 0,22 phút.

A.4.8. Vùng 169 – Mount Hope

Bảng A.76. Hồ sơ vùng 169 – Mount Hope (Bronx, cách CRZ 10,14 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.933	3.033	+100	+3,4
Chuyến HVFHV trả/ngày	2.850	2.924	+75	+2,6
Giá cước cơ sở/chuyến (USD)	17,38	17,58	+0,20	+1,2
Thu nhập tài xế/chuyến (USD)	14,67	15,03	+0,36	+2,5
Tốc độ trung bình (dặm/giờ)	13,65	13,54	-0,11	-0,8
Thời gian chờ (phút)	4,66	4,93	+0,27	+5,8
Phí CBD/chuyến (USD)	0,000	0,050	+0,050	–
% chuyến đón có đích trong CRZ	3,4	3,1	-0,3	-7,9
Chuyến taxi vàng đón/ngày	9	31	+22	+236,9

So với cùng kỳ: Số chuyến đón tăng 3,4%, tốc độ giảm 0,11 dặm/giờ, thời gian chờ tăng 0,27 phút.

A.4.9. Vùng 174 – Norwood

Bảng A.77. Hồ sơ vùng 174 – Norwood (Bronx, cách CRZ 13,62 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.460	2.612	+153	+6,2
Chuyến HVFHV trả/ngày	2.644	2.794	+150	+5,7
Giá cước cơ sở/chuyến (USD)	18,87	19,00	+0,12	+0,7
Thu nhập tài xế/chuyến (USD)	16,10	16,39	+0,28	+1,8
Tốc độ trung bình (dặm/giờ)	15,54	15,42	-0,11	-0,7
Thời gian chờ (phút)	4,26	4,47	+0,21	+5,0
Phí CBD/chuyến (USD)	0,000	0,040	+0,040	–
% chuyến đón có đích trong CRZ	2,7	2,5	-0,2	-5,8
Chuyến taxi vàng đón/ngày	6	20	+14	+255,8

So với cùng kỳ: Số chuyến đón tăng 6,2%, tốc độ giảm 0,11 dặm/giờ, thời gian chờ tăng 0,21 phút.

A.4.10. Vùng 213 – Soundview/Castle Hill

Bảng A.78. Hồ sơ vùng 213 – Soundview/Castle Hill (Bronx, cách CRZ 9,35 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.980	3.182	+202	+6,8
Chuyến HVFHV trả/ngày	2.995	3.178	+183	+6,1
Giá cước cơ sở/chuyến (USD)	18,69	18,40	-0,30	-1,6
Thu nhập tài xế/chuyến (USD)	15,98	15,90	-0,08	-0,5
Tốc độ trung bình (dặm/giờ)	15,88	16,03	+0,15	+0,9
Thời gian chờ (phút)	5,03	5,29	+0,25	+5,0
Phí CBD/chuyến (USD)	0,000	0,043	+0,043	–
% chuyến đón có đích trong CRZ	2,9	2,8	-0,2	-5,2
Chuyến taxi vàng đón/ngày	14	39	+25	+183,0

So với cùng kỳ: Số chuyến đón tăng 6,8%, tốc độ tăng 0,15 dặm/giờ, thời gian chờ tăng 0,25 phút.

A.4.11. Vùng 235 – University Heights/Morris Heights

Bảng A.79. Hồ sơ vùng 235 – University Heights/Morris Heights (Bronx, cách CRZ 9,72 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.604	2.728	+124	+4,8
Chuyến HVFHV trả/ngày	2.567	2.686	+119	+4,6
Giá cước cơ sở/chuyến (USD)	18,09	18,22	+0,13	+0,7
Thu nhập tài xế/chuyến (USD)	15,31	15,71	+0,39	+2,6
Tốc độ trung bình (dặm/giờ)	14,21	14,15	-0,06	-0,4
Thời gian chờ (phút)	5,05	5,34	+0,29	+5,7
Phí CBD/chuyến (USD)	0,000	0,069	+0,069	–
% chuyến đón có đích trong CRZ	4,5	4,3	-0,2	-4,6
Chuyến taxi vàng đón/ngày	11	32	+21	+201,3

So với cùng kỳ: Số chuyến đón tăng 4,8%, tốc độ giảm 0,06 dặm/giờ, thời gian chờ tăng 0,29 phút.

A.4.12. Vùng 241 – Van Cortlandt Village

Bảng A.80. Hồ sơ vùng 241 – Van Cortlandt Village (Bronx, cách CRZ 13,03 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.264	2.372	+108	+4,8
Chuyến HVFHV trả/ngày	2.311	2.427	+116	+5,0
Giá cước cơ sở/chuyến (USD)	18,73	18,98	+0,24	+1,3
Thu nhập tài xế/chuyến (USD)	15,91	16,25	+0,34	+2,2
Tốc độ trung bình (dặm/giờ)	15,00	14,90	-0,10	-0,7
Thời gian chờ (phút)	4,47	4,78	+0,31	+6,9
Phí CBD/chuyến (USD)	0,000	0,061	+0,061	–
% chuyến đón có đích trong CRZ	4,1	3,9	-0,3	-6,2
Chuyến taxi vàng đón/ngày	7	22	+15	+202,6

So với cùng kỳ: Số chuyến đón tăng 4,8%, tốc độ giảm 0,10 dặm/giờ, thời gian chờ tăng 0,31 phút.

A.4.13. Vùng 242 – Van Nest/Morris Park

Bảng A.81. Hồ sơ vùng 242 – Van Nest/Morris Park (Bronx, cách CRZ 11,56 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.416	2.552	+136	+5,7
Chuyến HVFHV trả/ngày	2.529	2.668	+139	+5,5
Giá cước cơ sở/chuyến (USD)	18,32	18,87	+0,54	+3,0
Thu nhập tài xế/chuyến (USD)	15,40	16,06	+0,66	+4,3
Tốc độ trung bình (dặm/giờ)	13,88	13,83	-0,05	-0,4
Thời gian chờ (phút)	4,54	4,75	+0,21	+4,7
Phí CBD/chuyến (USD)	0,000	0,031	+0,031	–
% chuyến đón có đích trong CRZ	2,1	2,0	-0,0	-1,8
Chuyến taxi vàng đón/ngày	7	21	+14	+189,5

So với cùng kỳ: Số chuyến đón tăng 5,7%, tốc độ giảm 0,05 dặm/giờ, thời gian chờ tăng 0,21 phút.

A.4.14. Vùng 247 – West Concourse

Bảng A.82. Hồ sơ vùng 247 – West Concourse (Bronx, cách CRZ 6,50 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.152	3.347	+195	+6,2
Chuyến HVFHV trả/ngày	3.075	3.283	+207	+6,7
Giá cước cơ sở/chuyến (USD)	18,93	19,02	+0,09	+0,5
Thu nhập tài xế/chuyến (USD)	15,61	15,91	+0,30	+1,9
Tốc độ trung bình (dặm/giờ)	14,30	14,16	-0,14	-1,0
Thời gian chờ (phút)	5,23	5,34	+0,11	+2,2
Phí CBD/chuyến (USD)	0,000	0,079	+0,079	–
% chuyến đón có đích trong CRZ	5,6	4,9	-0,7	-12,1
Chuyến taxi vàng đón/ngày	20	51	+31	+158,6

So với cùng kỳ: Số chuyến đón tăng 6,2%, tốc độ giảm 0,14 dặm/giờ, thời gian chờ tăng 0,11 phút.

A.4.15. Vùng 254 – Williamsbridge/Olinville

Bảng A.83. Hồ sơ vùng 254 – Williamsbridge/Olinville (Bronx, cách CRZ 14,61 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.781	2.962	+181	+6,5
Chuyến HVFHV trả/ngày	2.679	2.863	+184	+6,9
Giá cước cơ sở/chuyến (USD)	18,41	18,22	-0,18	-1,0
Thu nhập tài xế/chuyến (USD)	15,93	15,94	+0,01	+0,0
Tốc độ trung bình (dặm/giờ)	15,78	15,60	-0,18	-1,1
Thời gian chờ (phút)	4,85	5,27	+0,41	+8,5
Phí CBD/chuyến (USD)	0,000	0,032	+0,032	–
% chuyến đón có đích trong CRZ	2,4	2,1	-0,3	-13,6
Chuyến taxi vàng đón/ngày	10	35	+25	+247,3

So với cùng kỳ: Số chuyến đón tăng 6,5%, tốc độ giảm 0,18 dặm/giờ, thời gian chờ tăng 0,41 phút.

A.4.16. Vùng 14 – Bay Ridge

Bảng A.84. Hồ sơ vùng 14 – Bay Ridge (Brooklyn, cách CRZ 6,41 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.419	3.646	+227	+6,6
Chuyến HVFHV trả/ngày	3.566	3.786	+220	+6,2
Giá cước cơ sở/chuyến (USD)	21,93	21,91	-0,02	-0,1
Thu nhập tài xế/chuyến (USD)	18,12	18,14	+0,02	+0,1
Tốc độ trung bình (dặm/giờ)	16,92	16,76	-0,16	-1,0
Thời gian chờ (phút)	3,97	4,23	+0,26	+6,5
Phí CBD/chuyến (USD)	0,000	0,108	+0,108	–
% chuyến đón có đích trong CRZ	7,0	6,7	-0,3	-4,3
Chuyến taxi vàng đón/ngày	16	48	+32	+198,0

So với cùng kỳ: Số chuyến đón tăng 6,6%, tốc độ giảm 0,16 dặm/giờ, thời gian chờ tăng 0,26 phút.

A.4.17. Vùng 17 – Bedford

Bảng A.85. Hồ sơ vùng 17 – Bedford (Brooklyn, cách CRZ 1,97 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	5.384	5.346	-38	-0,7
Chuyến HVFHV trả/ngày	5.543	5.524	-19	-0,3
Giá cước cơ sở/chuyến (USD)	20,43	20,76	+0,33	+1,6
Thu nhập tài xế/chuyến (USD)	16,40	16,91	+0,51	+3,1
Tốc độ trung bình (dặm/giờ)	11,62	11,46	-0,16	-1,4
Thời gian chờ (phút)	4,90	5,13	+0,23	+4,6
Phí CBD/chuyến (USD)	0,000	0,140	+0,140	–
% chuyến đón có đích trong CRZ	8,8	8,5	-0,3	-3,5
Chuyến taxi vàng đón/ngày	34	110	+76	+224,8

So với cùng kỳ: Số chuyến đón giảm 0,7%, tốc độ giảm 0,16 dặm/giờ, thời gian chờ tăng 0,23 phút.

A.4.18. Vùng 25 – Boerum Hill

Bảng A.86. Hồ sơ vùng 25 – Boerum Hill (Brooklyn, cách CRZ 1,76 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.796	3.846	+49	+1,3
Chuyến HVFHV trả/ngày	3.435	3.482	+47	+1,4
Giá cước cơ sở/chuyến (USD)	26,16	26,57	+0,41	+1,6
Thu nhập tài xế/chuyến (USD)	20,05	20,64	+0,59	+2,9
Tốc độ trung bình (dặm/giờ)	13,23	13,16	-0,08	-0,6
Thời gian chờ (phút)	4,65	4,76	+0,11	+2,4
Phí CBD/chuyến (USD)	0,000	0,253	+0,253	–
% chuyến đón có đích trong CRZ	15,5	15,5	-0,0	-0,1
Chuyến taxi vàng đón/ngày	60	128	+68	+114,2

So với cùng kỳ: Số chuyến đón tăng 1,3%, tốc độ giảm 0,08 dặm/giờ, thời gian chờ tăng 0,11 phút.

A.4.19. Vùng 26 – Borough Park

Bảng A.87. Hồ sơ vùng 26 – Borough Park (Brooklyn, cách CRZ 6,45 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.179	3.330	+152	+4,8
Chuyến HVFHV trả/ngày	3.316	3.456	+140	+4,2
Giá cước cơ sở/chuyến (USD)	17,70	17,78	+0,07	+0,4
Thu nhập tài xế/chuyến (USD)	14,43	14,56	+0,14	+0,9
Tốc độ trung bình (dặm/giờ)	10,71	10,70	-0,01	-0,1
Thời gian chờ (phút)	4,85	5,15	+0,30	+6,2
Phí CBD/chuyến (USD)	0,000	0,037	+0,037	–
% chuyến đón có đích trong CRZ	2,2	2,1	-0,1	-3,8
Chuyến taxi vàng đón/ngày	11	30	+19	+176,6

So với cùng kỳ: Số chuyến đón tăng 4,8%, tốc độ giảm 0,01 dặm/giờ, thời gian chờ tăng 0,30 phút.

A.4.20. Vùng 33 – Brooklyn Heights

Bảng A.88. Hồ sơ vùng 33 – Brooklyn Heights (Brooklyn, cách CRZ 0,43 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.089	3.122	+33	+1,1
Chuyến HVFHV trả/ngày	3.018	3.105	+87	+2,9
Giá cước cơ sở/chuyến (USD)	28,93	29,55	+0,63	+2,2
Thu nhập tài xế/chuyến (USD)	21,27	21,89	+0,62	+2,9
Tốc độ trung bình (dặm/giờ)	14,37	14,29	-0,08	-0,6
Thời gian chờ (phút)	4,54	4,63	+0,09	+2,0
Phí CBD/chuyến (USD)	0,000	0,411	+0,411	–
% chuyến đón có đích trong CRZ	26,1	25,7	-0,4	-1,5
Chuyến taxi vàng đón/ngày	77	140	+64	+83,3

So với cùng kỳ: Số chuyến đón tăng 1,1%, tốc độ giảm 0,08 dặm/giờ, thời gian chờ tăng 0,09 phút.

A.4.21. Vùng 35 – Brownsville

Bảng A.89. Hồ sơ vùng 35 – Brownsville (Brooklyn, cách CRZ 6,64 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.886	3.972	+87	+2,2
Chuyến HVFHV trả/ngày	3.650	3.785	+135	+3,7
Giá cước cơ sở/chuyến (USD)	17,99	18,25	+0,27	+1,5
Thu nhập tài xế/chuyến (USD)	15,24	15,61	+0,37	+2,4
Tốc độ trung bình (dặm/giờ)	12,18	12,01	-0,17	-1,4
Thời gian chờ (phút)	5,30	5,53	+0,23	+4,4
Phí CBD/chuyến (USD)	0,000	0,027	+0,027	–
% chuyến đón có đích trong CRZ	1,9	1,7	-0,1	-6,6
Chuyến taxi vàng đón/ngày	30	80	+51	+171,1

So với cùng kỳ: Số chuyến đón tăng 2,2%, tốc độ giảm 0,17 dặm/giờ, thời gian chờ tăng 0,23 phút.

A.4.22. Vùng 36 – Bushwick North

Bảng A.90. Hồ sơ vùng 36 – Bushwick North (Brooklyn, cách CRZ 3,56 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	5.186	5.283	+97	+1,9
Chuyến HVFHV trả/ngày	5.083	5.158	+75	+1,5
Giá cước cơ sở/chuyến (USD)	21,32	21,55	+0,23	+1,1
Thu nhập tài xế/chuyến (USD)	17,05	17,60	+0,54	+3,2
Tốc độ trung bình (dặm/giờ)	12,48	12,30	-0,19	-1,5
Thời gian chờ (phút)	4,53	4,85	+0,33	+7,2
Phí CBD/chuyến (USD)	0,000	0,129	+0,129	–
% chuyến đón có đích trong CRZ	8,3	7,8	-0,4	-5,1
Chuyến taxi vàng đón/ngày	22	98	+76	+343,9

So với cùng kỳ: Số chuyến đón tăng 1,9%, tốc độ giảm 0,19 dặm/giờ, thời gian chờ tăng 0,33 phút.

A.4.23. Vùng 37 – Bushwick South

Bảng A.91. Hồ sơ vùng 37 – Bushwick South (Brooklyn, cách CRZ 2,65 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	6.999	7.269	+270	+3,9
Chuyến HVFHV trả/ngày	7.194	7.430	+236	+3,3
Giá cước cơ sở/chuyến (USD)	21,46	22,00	+0,53	+2,5
Thu nhập tài xế/chuyến (USD)	17,43	18,08	+0,65	+3,7
Tốc độ trung bình (dặm/giờ)	12,12	12,00	-0,12	-1,0
Thời gian chờ (phút)	4,60	4,88	+0,28	+6,0
Phí CBD/chuyến (USD)	0,000	0,149	+0,149	–
% chuyến đón có đích trong CRZ	9,4	9,0	-0,4	-4,0
Chuyến taxi vàng đón/ngày	35	156	+122	+350,6

So với cùng kỳ: Số chuyến đón tăng 3,9%, tốc độ giảm 0,12 dặm/giờ, thời gian chờ tăng 0,28 phút.

A.4.24. Vùng 39 – Canarsie

Bảng A.92. Hồ sơ vùng 39 – Canarsie (Brooklyn, cách CRZ 8,75 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.711	4.933	+222	+4,7
Chuyến HVFHV trả/ngày	4.558	4.768	+210	+4,6
Giá cước cơ sở/chuyến (USD)	18,38	18,21	-0,17	-0,9
Thu nhập tài xế/chuyến (USD)	15,30	15,18	-0,12	-0,8
Tốc độ trung bình (dặm/giờ)	13,84	13,55	-0,28	-2,1
Thời gian chờ (phút)	5,12	5,34	+0,22	+4,2
Phí CBD/chuyến (USD)	0,000	0,019	+0,019	–
% chuyến đón có đích trong CRZ	1,4	1,2	-0,2	-11,3
Chuyến taxi vàng đón/ngày	39	96	+57	+143,6

So với cùng kỳ: Số chuyến đón tăng 4,7%, tốc độ giảm 0,28 dặm/giờ, thời gian chờ tăng 0,22 phút.

A.4.25. Vùng 49 – Clinton Hill

Bảng A.93. Hồ sơ vùng 49 – Clinton Hill (Brooklyn, cách CRZ 1,76 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.965	3.994	+29	+0,7
Chuyến HVFHV trả/ngày	4.022	4.032	+10	+0,3
Giá cước cơ sở/chuyến (USD)	22,87	23,29	+0,42	+1,8
Thu nhập tài xế/chuyến (USD)	17,71	18,25	+0,55	+3,1
Tốc độ trung bình (dặm/giờ)	12,19	12,08	-0,11	-0,9
Thời gian chờ (phút)	4,52	4,66	+0,14	+3,1
Phí CBD/chuyến (USD)	0,000	0,228	+0,228	–
% chuyến đón có đích trong CRZ	14,7	14,2	-0,5	-3,4
Chuyến taxi vàng đón/ngày	34	94	+60	+177,1

So với cùng kỳ: Số chuyến đón tăng 0,7%, tốc độ giảm 0,11 dặm/giờ, thời gian chờ tăng 0,14 phút.

A.4.26. Vùng 61 – Crown Heights North

Bảng A.94. Hồ sơ vùng 61 – Crown Heights North (Brooklyn, cách CRZ 3,63 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	8.511	8.585	+73	+0,9
Chuyến HVFHV trả/ngày	8.958	9.159	+201	+2,2
Giá cước cơ sở/chuyến (USD)	20,40	20,81	+0,41	+2,0
Thu nhập tài xế/chuyến (USD)	16,62	17,19	+0,57	+3,4
Tốc độ trung bình (dặm/giờ)	11,76	11,62	-0,14	-1,2
Thời gian chờ (phút)	4,97	5,16	+0,19	+3,8
Phí CBD/chuyến (USD)	0,000	0,090	+0,090	–
% chuyến đón có đích trong CRZ	5,8	5,6	-0,2	-4,0
Chuyến taxi vàng đón/ngày	68	198	+130	+193,1

So với cùng kỳ: Số chuyến đón tăng 0,9%, tốc độ giảm 0,14 dặm/giờ, thời gian chờ tăng 0,19 phút.

A.4.27. Vùng 62 – Crown Heights South

Bảng A.95. Hồ sơ vùng 62 – Crown Heights South (Brooklyn, cách CRZ 4,51 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.348	2.425	+77	+3,3
Chuyến HVFHV trả/ngày	2.335	2.437	+102	+4,4
Giá cước cơ sở/chuyến (USD)	20,68	21,26	+0,59	+2,8
Thu nhập tài xế/chuyến (USD)	16,92	17,61	+0,69	+4,1
Tốc độ trung bình (dặm/giờ)	11,65	11,52	-0,13	-1,1
Thời gian chờ (phút)	5,03	5,27	+0,24	+4,7
Phí CBD/chuyến (USD)	0,000	0,082	+0,082	–
% chuyến đón có đích trong CRZ	5,2	5,0	-0,2	-2,9
Chuyến taxi vàng đón/ngày	22	57	+35	+159,9

So với cùng kỳ: Số chuyến đón tăng 3,3%, tốc độ giảm 0,13 dặm/giờ, thời gian chờ tăng 0,24 phút.

A.4.28. Vùng 65 – Downtown Brooklyn/MetroTech

Bảng A.96. Hồ sơ vùng 65 – Downtown Brooklyn/MetroTech (Brooklyn, cách CRZ 0,94 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.133	3.094	-39	-1,3
Chuyến HVFHV trả/ngày	2.842	2.853	+12	+0,4
Giá cước cơ sở/chuyến (USD)	26,24	26,76	+0,52	+2,0
Thu nhập tài xế/chuyến (USD)	20,21	21,01	+0,79	+3,9
Tốc độ trung bình (dặm/giờ)	13,94	13,94	-0,00	-0,0
Thời gian chờ (phút)	5,02	5,14	+0,12	+2,3
Phí CBD/chuyến (USD)	0,000	0,329	+0,329	–
% chuyến đón có đích trong CRZ	20,9	20,3	-0,6	-3,0
Chuyến taxi vàng đón/ngày	83	143	+61	+73,6

So với cùng kỳ: Số chuyến đón giảm 1,3%, tốc độ giảm 0,00 dặm/giờ, thời gian chờ tăng 0,12 phút.

A.4.29. Vùng 66 – DUMBO/Vinegar Hill

Bảng A.97. Hồ sơ vùng 66 – DUMBO/Vinegar Hill (Brooklyn, cách CRZ 0,43 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.394	2.483	+88	+3,7
Chuyến HVFHV trả/ngày	2.164	2.277	+112	+5,2
Giá cước cơ sở/chuyến (USD)	28,19	28,49	+0,31	+1,1
Thu nhập tài xế/chuyến (USD)	20,51	21,08	+0,57	+2,8
Tốc độ trung bình (dặm/giờ)	13,88	13,86	-0,02	-0,2
Thời gian chờ (phút)	4,73	4,80	+0,06	+1,3
Phí CBD/chuyến (USD)	0,000	0,529	+0,529	–
% chuyến đón có đích trong CRZ	34,3	33,8	-0,5	-1,6
Chuyến taxi vàng đón/ngày	54	137	+83	+154,7

So với cùng kỳ: Số chuyến đón tăng 3,7%, tốc độ giảm 0,02 dặm/giờ, thời gian chờ tăng 0,06 phút.

A.4.30. Vùng 71 – East Flatbush/Farragut

Bảng A.98. Hồ sơ vùng 71 – East Flatbush/Farragut (Brooklyn, cách CRZ 6,64 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.813	2.838	+25	+0,9
Chuyến HVFHV trả/ngày	2.804	2.826	+22	+0,8
Giá cước cơ sở/chuyến (USD)	19,05	19,17	+0,13	+0,7
Thu nhập tài xế/chuyến (USD)	15,85	16,08	+0,23	+1,4
Tốc độ trung bình (dặm/giờ)	11,85	11,69	-0,16	-1,4
Thời gian chờ (phút)	4,98	5,23	+0,25	+5,0
Phí CBD/chuyến (USD)	0,000	0,041	+0,041	–
% chuyến đón có đích trong CRZ	2,7	2,5	-0,2	-6,9
Chuyến taxi vàng đón/ngày	24	66	+42	+176,7

So với cùng kỳ: Số chuyến đón tăng 0,9%, tốc độ giảm 0,16 dặm/giờ, thời gian chờ tăng 0,25 phút.

A.4.31. Vùng 72 – East Flatbush/Remsen Village

Bảng A.99. Hồ sơ vùng 72 – East Flatbush/Remsen Village (Brooklyn, cách CRZ 6,57 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.260	3.300	+41	+1,2
Chuyến HVFHV trả/ngày	3.150	3.219	+69	+2,2
Giá cước cơ sở/chuyến (USD)	18,15	18,32	+0,17	+0,9
Thu nhập tài xế/chuyến (USD)	15,04	15,30	+0,26	+1,7
Tốc độ trung bình (dặm/giờ)	11,83	11,66	-0,17	-1,4
Thời gian chờ (phút)	5,38	5,61	+0,23	+4,3
Phí CBD/chuyến (USD)	0,000	0,027	+0,027	–
% chuyến đón có đích trong CRZ	2,0	1,7	-0,3	-14,0
Chuyến taxi vàng đón/ngày	28	76	+48	+169,1

So với cùng kỳ: Số chuyến đón tăng 1,2%, tốc độ giảm 0,17 dặm/giờ, thời gian chờ tăng 0,23 phút.

A.4.32. Vùng 76 – East New York

Bảng A.100. Hồ sơ vùng 76 – East New York (Brooklyn, cách CRZ 7,54 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	6.943	7.366	+422	+6,1
Chuyến HVFHV trả/ngày	7.017	7.372	+354	+5,1
Giá cước cơ sở/chuyến (USD)	18,08	18,03	-0,05	-0,3
Thu nhập tài xế/chuyến (USD)	15,24	15,39	+0,15	+1,0
Tốc độ trung bình (dặm/giờ)	13,75	13,43	-0,32	-2,4
Thời gian chờ (phút)	4,75	4,95	+0,20	+4,3
Phí CBD/chuyến (USD)	0,000	0,019	+0,019	–
% chuyến đón có đích trong CRZ	1,3	1,2	-0,1	-10,1
Chuyến taxi vàng đón/ngày	50	145	+95	+191,1

So với cùng kỳ: Số chuyến đón tăng 6,1%, tốc độ giảm 0,32 dặm/giờ, thời gian chờ tăng 0,20 phút.

A.4.33. Vùng 80 – East Williamsburg

Bảng A.101. Hồ sơ vùng 80 – East Williamsburg (Brooklyn, cách CRZ 1,77 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	5.196	5.138	-58	-1,1
Chuyến HVFHV trả/ngày	5.077	5.027	-50	-1,0
Giá cước cơ sở/chuyến (USD)	22,97	22,86	-0,11	-0,5
Thu nhập tài xế/chuyến (USD)	17,75	18,11	+0,36	+2,0
Tốc độ trung bình (dặm/giờ)	13,32	12,96	-0,36	-2,7
Thời gian chờ (phút)	4,56	4,71	+0,15	+3,3
Phí CBD/chuyến (USD)	0,000	0,239	+0,239	–
% chuyến đón có đích trong CRZ	15,7	14,4	-1,2	-7,9
Chuyến taxi vàng đón/ngày	50	141	+91	+180,3

So với cùng kỳ: Số chuyến đón giảm 1,1%, tốc độ giảm 0,36 dặm/giờ, thời gian chờ tăng 0,15 phút.

A.4.34. Vùng 89 – Flatbush/Ditmas Park

Bảng A.102. Hồ sơ vùng 89 – Flatbush/Ditmas Park (Brooklyn, cách CRZ 6,28 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	5.103	5.293	+191	+3,7
Chuyến HVFHV trả/ngày	5.297	5.460	+162	+3,1
Giá cước cơ sở/chuyến (USD)	21,32	21,20	-0,11	-0,5
Thu nhập tài xế/chuyến (USD)	17,89	18,06	+0,17	+0,9
Tốc độ trung bình (dặm/giờ)	12,70	12,55	-0,15	-1,2
Thời gian chờ (phút)	4,51	4,70	+0,20	+4,4
Phí CBD/chuyến (USD)	0,000	0,085	+0,085	–
% chuyến đón có đích trong CRZ	5,6	5,1	-0,4	-7,7
Chuyến taxi vàng đón/ngày	36	113	+77	+211,0

So với cùng kỳ: Số chuyến đón tăng 3,7%, tốc độ giảm 0,15 dặm/giờ, thời gian chờ tăng 0,20 phút.

A.4.35. Vùng 91 – Flatlands

Bảng A.103. Hồ sơ vùng 91 – Flatlands (Brooklyn, cách CRZ 8,78 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.162	3.255	+93	+3,0
Chuyến HVFHV trả/ngày	2.968	3.056	+88	+3,0
Giá cước cơ sở/chuyến (USD)	19,57	19,51	-0,07	-0,3
Thu nhập tài xế/chuyến (USD)	16,25	16,36	+0,11	+0,7
Tốc độ trung bình (dặm/giờ)	12,87	12,63	-0,24	-1,8
Thời gian chờ (phút)	4,86	5,14	+0,28	+5,8
Phí CBD/chuyến (USD)	0,000	0,030	+0,030	–
% chuyến đón có đích trong CRZ	2,0	1,8	-0,2	-8,5
Chuyến taxi vàng đón/ngày	25	66	+41	+161,5

So với cùng kỳ: Số chuyến đón tăng 3,0%, tốc độ giảm 0,24 dặm/giờ, thời gian chờ tăng 0,28 phút.

A.4.36. Vùng 97 – Fort Greene

Bảng A.104. Hồ sơ vùng 97 – Fort Greene (Brooklyn, cách CRZ 1,28 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.255	4.368	+114	+2,7
Chuyến HVFHV trả/ngày	4.080	4.102	+22	+0,5
Giá cước cơ sở/chuyến (USD)	23,51	23,87	+0,35	+1,5
Thu nhập tài xế/chuyến (USD)	18,27	18,91	+0,64	+3,5
Tốc độ trung bình (dặm/giờ)	12,52	12,50	-0,02	-0,2
Thời gian chờ (phút)	4,81	4,89	+0,08	+1,7
Phí CBD/chuyến (USD)	0,000	0,249	+0,249	–
% chuyến đón có đích trong CRZ	15,3	15,5	+0,2	+1,0
Chuyến taxi vàng đón/ngày	66	145	+80	+121,7

So với cùng kỳ: Số chuyến đón tăng 2,7%, tốc độ giảm 0,02 dặm/giờ, thời gian chờ tăng 0,08 phút.

A.4.37. Vùng 112 – Greenpoint

Bảng A.105. Hồ sơ vùng 112 – Greenpoint (Brooklyn, cách CRZ 0,73 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	6.175	6.493	+317	+5,1
Chuyến HVFHV trả/ngày	6.134	6.447	+313	+5,1
Giá cước cơ sở/chuyến (USD)	23,29	23,95	+0,65	+2,8
Thu nhập tài xế/chuyến (USD)	17,87	18,63	+0,76	+4,2
Tốc độ trung bình (dặm/giờ)	12,94	12,78	-0,16	-1,2
Thời gian chờ (phút)	4,20	4,41	+0,21	+5,0
Phí CBD/chuyến (USD)	0,000	0,330	+0,330	–
% chuyến đón có đích trong CRZ	20,2	20,3	+0,2	+1,0
Chuyến taxi vàng đón/ngày	42	148	+106	+253,3

So với cùng kỳ: Số chuyến đón tăng 5,1%, tốc độ giảm 0,16 dặm/giờ, thời gian chờ tăng 0,21 phút.

A.4.38. Vùng 177 – Ocean Hill

Bảng A.106. Hồ sơ vùng 177 – Ocean Hill (Brooklyn, cách CRZ 5,64 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.748	2.794	+47	+1,7
Chuyến HVFHV trả/ngày	2.724	2.770	+46	+1,7
Giá cước cơ sở/chuyến (USD)	19,15	19,35	+0,20	+1,0
Thu nhập tài xế/chuyến (USD)	16,17	16,54	+0,38	+2,3
Tốc độ trung bình (dặm/giờ)	12,30	12,06	-0,24	-1,9
Thời gian chờ (phút)	5,10	5,34	+0,24	+4,7
Phí CBD/chuyến (USD)	0,000	0,049	+0,049	–
% chuyến đón có đích trong CRZ	3,3	3,0	-0,3	-9,7
Chuyến taxi vàng đón/ngày	22	74	+52	+230,9

So với cùng kỳ: Số chuyến đón tăng 1,7%, tốc độ giảm 0,24 dặm/giờ, thời gian chờ tăng 0,24 phút.

A.4.39. Vùng 181 – Park Slope

Bảng A.107. Hồ sơ vùng 181 – Park Slope (Brooklyn, cách CRZ 2,78 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	6.241	6.365	+124	+2,0
Chuyến HVFHV trả/ngày	6.299	6.508	+209	+3,3
Giá cước cơ sở/chuyến (USD)	24,31	24,35	+0,04	+0,2
Thu nhập tài xế/chuyến (USD)	18,95	19,23	+0,28	+1,5
Tốc độ trung bình (dặm/giờ)	12,89	12,76	-0,13	-1,0
Thời gian chờ (phút)	3,98	4,11	+0,12	+3,1
Phí CBD/chuyến (USD)	0,000	0,177	+0,177	–
% chuyến đón có đích trong CRZ	11,1	10,9	-0,2	-1,5
Chuyến taxi vàng đón/ngày	54	126	+72	+132,6

So với cùng kỳ: Số chuyến đón tăng 2,0%, tốc độ giảm 0,13 dặm/giờ, thời gian chờ tăng 0,12 phút.

A.4.40. Vùng 188 – Prospect-Lefferts Gardens

Bảng A.108. Hồ sơ vùng 188 – Prospect-Lefferts Gardens (Brooklyn, cách CRZ 5,37 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.878	5.024	+146	+3,0
Chuyến HVFHV trả/ngày	5.096	5.258	+162	+3,2
Giá cước cơ sở/chuyến (USD)	20,69	20,81	+0,12	+0,6
Thu nhập tài xế/chuyến (USD)	17,12	17,52	+0,40	+2,3
Tốc độ trung bình (dặm/giờ)	11,63	11,49	-0,14	-1,2
Thời gian chờ (phút)	4,88	5,12	+0,24	+4,9
Phí CBD/chuyến (USD)	0,000	0,076	+0,076	–
% chuyến đón có đích trong CRZ	5,1	4,7	-0,4	-8,0
Chuyến taxi vàng đón/ngày	42	120	+78	+186,0

So với cùng kỳ: Số chuyến đón tăng 3,0%, tốc độ giảm 0,14 dặm/giờ, thời gian chờ tăng 0,24 phút.

A.4.41. Vùng 189 – Prospect Heights

Bảng A.109. Hồ sơ vùng 189 – Prospect Heights (Brooklyn, cách CRZ 3,04 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.375	2.418	+42	+1,8
Chuyến HVFHV trả/ngày	2.384	2.437	+53	+2,2
Giá cước cơ sở/chuyến (USD)	23,99	24,27	+0,28	+1,2
Thu nhập tài xế/chuyến (USD)	18,59	19,10	+0,51	+2,7
Tốc độ trung bình (dặm/giờ)	12,26	12,18	-0,08	-0,6
Thời gian chờ (phút)	4,42	4,58	+0,16	+3,7
Phí CBD/chuyến (USD)	0,000	0,182	+0,182	–
% chuyến đón có đích trong CRZ	11,3	11,1	-0,2	-2,0
Chuyến taxi vàng đón/ngày	20	49	+30	+152,4

So với cùng kỳ: Số chuyến đón tăng 1,8%, tốc độ giảm 0,08 dặm/giờ, thời gian chờ tăng 0,16 phút.

A.4.42. Vùng 225 – Stuyvesant Heights

Bảng A.110. Hồ sơ vùng 225 – Stuyvesant Heights (Brooklyn, cách CRZ 3,14 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	5.188	5.241	+53	+1,0
Chuyến HVFHV trả/ngày	5.494	5.540	+46	+0,8
Giá cước cơ sở/chuyến (USD)	21,32	21,89	+0,57	+2,7
Thu nhập tài xế/chuyến (USD)	17,35	17,97	+0,62	+3,6
Tốc độ trung bình (dặm/giờ)	11,59	11,42	-0,16	-1,4
Thời gian chờ (phút)	4,88	5,12	+0,25	+5,1
Phí CBD/chuyến (USD)	0,000	0,128	+0,128	–
% chuyến đón có đích trong CRZ	7,9	7,8	-0,2	-2,4
Chuyến taxi vàng đón/ngày	35	120	+85	+246,6

So với cùng kỳ: Số chuyến đón tăng 1,0%, tốc độ giảm 0,16 dặm/giờ, thời gian chờ tăng 0,25 phút.

A.4.43. Vùng 228 – Sunset Park West

Bảng A.111. Hồ sơ vùng 228 – Sunset Park West (Brooklyn, cách CRZ 3,30 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.128	3.385	+257	+8,2
Chuyến HVFHV trả/ngày	3.303	3.530	+227	+6,9
Giá cước cơ sở/chuyến (USD)	22,94	23,00	+0,06	+0,2
Thu nhập tài xế/chuyến (USD)	18,93	19,16	+0,23	+1,2
Tốc độ trung bình (dặm/giờ)	14,34	14,29	-0,05	-0,3
Thời gian chờ (phút)	4,50	4,83	+0,34	+7,5
Phí CBD/chuyến (USD)	0,000	0,127	+0,127	–
% chuyến đón có đích trong CRZ	8,2	7,9	-0,3	-3,9
Chuyến taxi vàng đón/ngày	14	56	+41	+287,7

So với cùng kỳ: Số chuyến đón tăng 8,2%, tốc độ giảm 0,05 dặm/giờ, thời gian chờ tăng 0,34 phút.

A.4.44. Vùng 255 – Williamsburg (North Side)

Bảng A.112. Hồ sơ vùng 255 – Williamsburg (North Side) (Brooklyn, cách CRZ 0,52 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	6.568	6.570	+3	+0,0
Chuyến HVFHV trả/ngày	6.061	6.094	+32	+0,5
Giá cước cơ sở/chuyến (USD)	25,74	26,44	+0,69	+2,7
Thu nhập tài xế/chuyến (USD)	19,32	19,93	+0,61	+3,2
Tốc độ trung bình (dặm/giờ)	12,48	12,48	-0,00	-0,0
Thời gian chờ (phút)	4,31	4,44	+0,14	+3,2
Phí CBD/chuyến (USD)	0,000	0,334	+0,334	–
% chuyến đón có đích trong CRZ	20,8	20,3	-0,6	-2,8
Chuyến taxi vàng đón/ngày	85	228	+142	+166,8

So với cùng kỳ: Số chuyến đón tăng 0,0%, tốc độ giảm 0,00 dặm/giờ, thời gian chờ tăng 0,14 phút.

A.4.45. Vùng 256 – Williamsburg (South Side)

Bảng A.113. Hồ sơ vùng 256 – Williamsburg (South Side) (Brooklyn, cách CRZ 0,55 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	5.410	5.493	+84	+1,5
Chuyến HVFHV trả/ngày	5.161	5.278	+117	+2,3
Giá cước cơ sở/chuyến (USD)	24,37	24,89	+0,52	+2,1
Thu nhập tài xế/chuyến (USD)	18,61	19,19	+0,58	+3,1
Tốc độ trung bình (dặm/giờ)	12,40	12,46	+0,05	+0,4
Thời gian chờ (phút)	4,41	4,58	+0,16	+3,7
Phí CBD/chuyến (USD)	0,000	0,367	+0,367	–
% chuyến đón có đích trong CRZ	21,6	21,4	-0,2	-1,0
Chuyến taxi vàng đón/ngày	59	170	+111	+187,3

So với cùng kỳ: Số chuyến đón tăng 1,5%, tốc độ tăng 0,05 dặm/giờ, thời gian chờ tăng 0,16 phút.

A.4.46. Vùng 7 – Astoria

Bảng A.114. Hồ sơ vùng 7 – Astoria (Queens, cách CRZ 1,87 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	6.192	6.277	+84	+1,4
Chuyến HVFHV trả/ngày	6.165	6.265	+101	+1,6
Giá cước cơ sở/chuyến (USD)	19,90	19,88	-0,03	-0,1
Thu nhập tài xế/chuyến (USD)	16,33	16,52	+0,19	+1,1
Tốc độ trung bình (dặm/giờ)	14,59	14,47	-0,12	-0,9
Thời gian chờ (phút)	3,72	3,90	+0,18	+4,8
Phí CBD/chuyến (USD)	0,000	0,193	+0,193	–
% chuyến đón có đích trong CRZ	10,0	9,3	-0,7	-6,8
Chuyến taxi vàng đón/ngày	69	212	+143	+207,4

So với cùng kỳ: Số chuyến đón tăng 1,4%, tốc độ giảm 0,12 dặm/giờ, thời gian chờ tăng 0,18 phút.

A.4.47. Vùng 82 – Elmhurst

Bảng A.115. Hồ sơ vùng 82 – Elmhurst (Queens, cách CRZ 5,80 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.473	4.887	+414	+9,3
Chuyến HVFHV trả/ngày	4.380	4.755	+375	+8,6
Giá cước cơ sở/chuyến (USD)	18,40	18,14	-0,25	-1,4
Thu nhập tài xế/chuyến (USD)	15,45	15,54	+0,09	+0,6
Tốc độ trung bình (dặm/giờ)	13,37	13,25	-0,12	-0,9
Thời gian chờ (phút)	4,47	4,68	+0,21	+4,8
Phí CBD/chuyến (USD)	0,000	0,067	+0,067	–
% chuyến đón có đích trong CRZ	4,0	3,8	-0,2	-4,6
Chuyến taxi vàng đón/ngày	25	81	+56	+224,3

So với cùng kỳ: Số chuyến đón tăng 9,3%, tốc độ giảm 0,12 dặm/giờ, thời gian chờ tăng 0,21 phút.

A.4.48. Vùng 92 – Flushing

Bảng A.116. Hồ sơ vùng 92 – Flushing (Queens, cách CRZ 10,11 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.232	3.555	+323	+10,0
Chuyến HVFHV trả/ngày	3.289	3.553	+264	+8,0
Giá cước cơ sở/chuyến (USD)	21,54	21,57	+0,04	+0,2
Thu nhập tài xế/chuyến (USD)	18,17	18,52	+0,36	+2,0
Tốc độ trung bình (dặm/giờ)	16,38	16,24	-0,14	-0,9
Thời gian chờ (phút)	4,66	5,25	+0,59	+12,7
Phí CBD/chuyến (USD)	0,000	0,085	+0,085	–
% chuyến đón có đích trong CRZ	5,8	5,3	-0,5	-9,3
Chuyến taxi vàng đón/ngày	10	36	+26	+248,9

So với cùng kỳ: Số chuyến đón tăng 10,0%, tốc độ giảm 0,14 dặm/giờ, thời gian chờ tăng 0,59 phút.

A.4.49. Vùng 95 – Forest Hills

Bảng A.117. Hồ sơ vùng 95 – Forest Hills (Queens, cách CRZ 8,81 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.255	4.601	+346	+8,1
Chuyến HVFHV trả/ngày	4.487	4.812	+325	+7,2
Giá cước cơ sở/chuyến (USD)	21,10	21,00	-0,10	-0,5
Thu nhập tài xế/chuyến (USD)	17,11	17,19	+0,09	+0,5
Tốc độ trung bình (dặm/giờ)	15,37	15,21	-0,16	-1,0
Thời gian chờ (phút)	4,65	4,84	+0,19	+4,1
Phí CBD/chuyến (USD)	0,000	0,088	+0,088	–
% chuyến đón có đích trong CRZ	5,4	5,1	-0,3	-6,1
Chuyến taxi vàng đón/ngày	26	70	+44	+173,2

So với cùng kỳ: Số chuyến đón tăng 8,1%, tốc độ giảm 0,16 dặm/giờ, thời gian chờ tăng 0,19 phút.

A.4.50. Vùng 129 – Jackson Heights

Bảng A.118. Hồ sơ vùng 129 – Jackson Heights (Queens, cách CRZ 4,98 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.955	5.159	+204	+4,1
Chuyến HVFHV trả/ngày	4.578	4.780	+202	+4,4
Giá cước cơ sở/chuyến (USD)	18,93	18,75	-0,17	-0,9
Thu nhập tài xế/chuyến (USD)	15,65	15,79	+0,14	+0,9
Tốc độ trung bình (dặm/giờ)	13,87	13,77	-0,10	-0,7
Thời gian chờ (phút)	4,42	4,60	+0,18	+4,0
Phí CBD/chuyến (USD)	0,000	0,083	+0,083	–
% chuyến đón có đích trong CRZ	5,0	4,6	-0,4	-7,8
Chuyến taxi vàng đón/ngày	38	120	+81	+212,1

So với cùng kỳ: Số chuyến đón tăng 4,1%, tốc độ giảm 0,10 dặm/giờ, thời gian chờ tăng 0,18 phút.

A.4.51. Vùng 130 – Jamaica

Bảng A.119. Hồ sơ vùng 130 – Jamaica (Queens, cách CRZ 13,38 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.667	5.137	+470	+10,1
Chuyến HVFHV trả/ngày	4.989	5.366	+377	+7,6
Giá cước cơ sở/chuyến (USD)	19,26	19,49	+0,23	+1,2
Thu nhập tài xế/chuyến (USD)	16,33	16,83	+0,50	+3,1
Tốc độ trung bình (dặm/giờ)	15,55	15,19	-0,36	-2,3
Thời gian chờ (phút)	4,61	4,88	+0,26	+5,7
Phí CBD/chuyến (USD)	0,000	0,028	+0,028	–
% chuyến đón có đích trong CRZ	1,7	1,7	+0,0	+0,4
Chuyến taxi vàng đón/ngày	33	126	+94	+287,7

So với cùng kỳ: Số chuyến đón tăng 10,1%, tốc độ giảm 0,36 dặm/giờ, thời gian chờ tăng 0,26 phút.

A.4.52. Vùng 145 – Long Island City/Hunters Point

Bảng A.120. Hồ sơ vùng 145 – Long Island City/Hunters Point (Queens, cách CRZ 0,41 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	5.297	5.660	+363	+6,9
Chuyến HVFHV trả/ngày	5.284	5.637	+353	+6,7
Giá cước cơ sở/chuyến (USD)	22,92	22,86	-0,06	-0,2
Thu nhập tài xế/chuyến (USD)	18,44	18,56	+0,12	+0,6
Tốc độ trung bình (dặm/giờ)	14,11	14,06	-0,04	-0,3
Thời gian chờ (phút)	4,05	4,24	+0,19	+4,6
Phí CBD/chuyến (USD)	0,000	0,344	+0,344	–
% chuyến đón có đích trong CRZ	19,4	19,2	-0,2	-1,0
Chuyến taxi vàng đón/ngày	70	200	+130	+185,3

So với cùng kỳ: Số chuyến đón tăng 6,9%, tốc độ giảm 0,04 dặm/giờ, thời gian chờ tăng 0,19 phút.

A.4.53. Vùng 179 – Old Astoria

Bảng A.121. Hồ sơ vùng 179 – Old Astoria (Queens, cách CRZ 2,18 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.241	2.357	+115	+5,2
Chuyến HVFHV trả/ngày	2.382	2.492	+111	+4,7
Giá cước cơ sở/chuyến (USD)	20,97	20,88	-0,09	-0,4
Thu nhập tài xế/chuyến (USD)	17,47	17,61	+0,14	+0,8
Tốc độ trung bình (dặm/giờ)	14,30	14,15	-0,15	-1,1
Thời gian chờ (phút)	4,03	4,20	+0,18	+4,4
Phí CBD/chuyến (USD)	0,000	0,184	+0,184	–
% chuyến đón có đích trong CRZ	10,8	9,9	-0,9	-8,0
Chuyến taxi vàng đón/ngày	26	80	+54	+212,0

So với cùng kỳ: Số chuyến đón tăng 5,2%, tốc độ giảm 0,15 dặm/giờ, thời gian chờ tăng 0,18 phút.

A.4.54. Vùng 197 – Richmond Hill

Bảng A.122. Hồ sơ vùng 197 – Richmond Hill (Queens, cách CRZ 10,73 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.753	2.885	+132	+4,8
Chuyến HVFHV trả/ngày	2.578	2.742	+164	+6,4
Giá cước cơ sở/chuyến (USD)	18,57	18,52	-0,05	-0,3
Thu nhập tài xế/chuyến (USD)	15,24	15,38	+0,13	+0,9
Tốc độ trung bình (dặm/giờ)	15,27	14,67	-0,60	-3,9
Thời gian chờ (phút)	4,48	4,71	+0,23	+5,1
Phí CBD/chuyến (USD)	0,000	0,030	+0,030	–
% chuyến đón có đích trong CRZ	2,0	1,8	-0,2	-8,4
Chuyến taxi vàng đón/ngày	23	78	+55	+234,8

So với cùng kỳ: Số chuyến đón tăng 4,8%, tốc độ giảm 0,60 dặm/giờ, thời gian chờ tăng 0,23 phút.

A.4.55. Vùng 198 – Ridgewood

Bảng A.123. Hồ sơ vùng 198 – Ridgewood (Queens, cách CRZ 4,20 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.969	4.232	+264	+6,6
Chuyến HVFHV trả/ngày	4.149	4.373	+224	+5,4
Giá cước cơ sở/chuyến (USD)	20,71	21,11	+0,40	+1,9
Thu nhập tài xế/chuyến (USD)	16,99	17,54	+0,55	+3,2
Tốc độ trung bình (dặm/giờ)	12,70	12,54	-0,16	-1,3
Thời gian chờ (phút)	4,52	4,83	+0,31	+6,9
Phí CBD/chuyến (USD)	0,000	0,109	+0,109	–
% chuyến đón có đích trong CRZ	6,7	6,5	-0,1	-2,1
Chuyến taxi vàng đón/ngày	12	54	+43	+366,7

So với cùng kỳ: Số chuyến đón tăng 6,6%, tốc độ giảm 0,16 dặm/giờ, thời gian chờ tăng 0,31 phút.

A.4.56. Vùng 205 – Saint Albans

Bảng A.124. Hồ sơ vùng 205 – Saint Albans (Queens, cách CRZ 16,39 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.463	2.629	+167	+6,8
Chuyến HVFHV trả/ngày	2.309	2.470	+161	+7,0
Giá cước cơ sở/chuyến (USD)	19,10	18,99	-0,11	-0,6
Thu nhập tài xế/chuyến (USD)	15,86	15,91	+0,06	+0,4
Tốc độ trung bình (dặm/giờ)	15,67	15,31	-0,36	-2,3
Thời gian chờ (phút)	5,10	5,42	+0,32	+6,2
Phí CBD/chuyến (USD)	0,000	0,017	+0,017	–
% chuyến đón có đích trong CRZ	1,2	1,0	-0,1	-11,3
Chuyến taxi vàng đón/ngày	14	40	+26	+192,3

So với cùng kỳ: Số chuyến đón tăng 6,8%, tốc độ giảm 0,36 dặm/giờ, thời gian chờ tăng 0,32 phút.

A.4.57. Vùng 216 – South Ozone Park

Bảng A.125. Hồ sơ vùng 216 – South Ozone Park (Queens, cách CRZ 12,00 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	4.120	4.327	+207	+5,0
Chuyến HVFHV trả/ngày	3.504	3.733	+228	+6,5
Giá cước cơ sở/chuyến (USD)	17,58	17,57	-0,01	-0,0
Thu nhập tài xế/chuyến (USD)	14,29	14,24	-0,05	-0,3
Tốc độ trung bình (dặm/giờ)	15,82	15,14	-0,68	-4,3
Thời gian chờ (phút)	3,98	4,11	+0,13	+3,2
Phí CBD/chuyến (USD)	0,000	0,022	+0,022	–
% chuyến đón có đích trong CRZ	1,5	1,4	-0,1	-9,3
Chuyến taxi vàng đón/ngày	30	82	+52	+176,5

So với cùng kỳ: Số chuyến đón tăng 5,0%, tốc độ giảm 0,68 dặm/giờ, thời gian chờ tăng 0,13 phút.

A.4.58. Vùng 223 – Steinway

Bảng A.126. Hồ sơ vùng 223 – Steinway (Queens, cách CRZ 3,45 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.111	3.253	+142	+4,6
Chuyến HVFHV trả/ngày	3.307	3.435	+128	+3,9
Giá cước cơ sở/chuyến (USD)	20,49	20,50	+0,01	+0,0
Thu nhập tài xế/chuyến (USD)	16,68	16,80	+0,13	+0,8
Tốc độ trung bình (dặm/giờ)	15,90	15,54	-0,36	-2,3
Thời gian chờ (phút)	3,79	3,94	+0,15	+3,9
Phí CBD/chuyến (USD)	0,000	0,126	+0,126	–
% chuyến đón có đích trong CRZ	8,2	7,5	-0,6	-7,7
Chuyến taxi vàng đón/ngày	25	68	+43	+167,1

So với cùng kỳ: Số chuyến đón tăng 4,6%, tốc độ giảm 0,36 dặm/giờ, thời gian chờ tăng 0,15 phút.

A.4.59. Vùng 226 – Sunnyside

Bảng A.127. Hồ sơ vùng 226 – Sunnyside (Queens, cách CRZ 1,74 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	3.866	4.092	+226	+5,8
Chuyến HVFHV trả/ngày	3.969	4.216	+247	+6,2
Giá cước cơ sở/chuyến (USD)	20,21	20,09	-0,12	-0,6
Thu nhập tài xế/chuyến (USD)	16,56	16,78	+0,22	+1,3
Tốc độ trung bình (dặm/giờ)	13,19	13,18	-0,00	-0,0
Thời gian chờ (phút)	4,22	4,44	+0,22	+5,3
Phí CBD/chuyến (USD)	0,000	0,218	+0,218	–
% chuyến đón có đích trong CRZ	11,3	10,9	-0,4	-3,6
Chuyến taxi vàng đón/ngày	87	192	+106	+122,0

So với cùng kỳ: Số chuyến đón tăng 5,8%, tốc độ giảm 0,00 dặm/giờ, thời gian chờ tăng 0,22 phút.

A.4.60. Vùng 260 – Woodside

Bảng A.128. Hồ sơ vùng 260 – Woodside (Queens, cách CRZ 4,10 km)

Chỉ tiêu	2024	2025	Chênh lệch	%
Chuyến HVFHV đón/ngày	2.793	3.009	+216	+7,7
Chuyến HVFHV trả/ngày	2.886	3.036	+150	+5,2
Giá cước cơ sở/chuyến (USD)	18,05	17,88	-0,17	-0,9
Thu nhập tài xế/chuyến (USD)	14,78	14,90	+0,11	+0,8
Tốc độ trung bình (dặm/giờ)	14,39	14,21	-0,19	-1,3
Thời gian chờ (phút)	3,95	4,12	+0,17	+4,3
Phí CBD/chuyến (USD)	0,000	0,121	+0,121	–
% chuyến đón có đích trong CRZ	6,3	6,3	-0,1	-1,0
Chuyến taxi vàng đón/ngày	29	79	+50	+172,3

So với cùng kỳ: Số chuyến đón tăng 7,7%, tốc độ giảm 0,19 dặm/giờ, thời gian chờ tăng 0,17 phút.

PHỤ LỤC B. BẢNG TỔNG HỢP 263 VÙNG TAXI

Bảng dưới đây liệt kê mọi vùng có chuyển HVFHV trong dữ liệu, sắp theo quận và mã vùng, với số chuyển đón bình quân mỗi ngày, tốc độ và thời gian chờ trong cửa sổ 05/01 – 31/12 của hai năm.

Bảng B.1. Chỉ tiêu HVFHV theo vùng – Manhattan

Mã	Tên vùng	Nhóm	Đón/ ngày 2024	Đón/ ngày 2025	Thay đổi %	Dặm/ giờ 2024	Dặm/ giờ 2025	Chờ 2024	Chờ 2025
4	Alphabet City	CRZ	2.011	1.804	-10,3	13,3	13,7	5,0	5,0
12	Battery Park	CRZ	71	66	-7,9	12,8	13,2	4,4	4,6
13	Battery Park City	CRZ	2.782	2.724	-2,1	15,3	15,5	4,5	4,5
24	Bloomingdale	Manhattan phía bắc	906	857	-5,4	14,4	14,3	4,4	4,4
41	Central Harlem	Manhattan phía bắc	4.215	4.227	0,3	14,1	13,8	4,7	5,0
42	Central Harlem North	Manhattan phía bắc	5.785	5.760	-0,4	15,0	14,9	4,9	5,2
43	Central Park	Vắt ranh giới	952	943	-1,0	11,6	11,7	4,3	4,3
45	Chinatown	CRZ	1.614	1.586	-1,8	13,5	13,7	4,9	4,8
48	Clinton East	CRZ	6.008	5.713	-4,9	13,6	13,8	4,4	4,3
50	Clinton West	CRZ	3.598	3.309	-8,0	13,2	13,4	4,5	4,4
68	East Chelsea	CRZ	6.859	6.399	-6,7	12,0	12,3	4,3	4,2
74	East Harlem North	Manhattan phía bắc	4.546	4.512	-0,8	14,8	14,5	5,0	5,2
75	East Harlem South	Manhattan phía bắc	4.153	3.981	-4,1	14,9	14,6	4,7	4,9
79	East Village	CRZ	8.373	7.570	-9,6	12,8	13,1	4,3	4,2
87	Financial District North	CRZ	3.879	3.844	-0,9	15,5	15,6	4,4	4,5
88	Financial District South	CRZ	1.601	1.580	-1,3	15,5	15,8	4,6	4,6
90	Flatiron	CRZ	4.277	4.050	-5,3	12,2	12,5	3,9	3,9
100	Garment District	CRZ	3.376	3.160	-6,4	13,0	13,2	4,8	4,7
104	Governor's Island/Ellis Island/Liberty Island	Manhattan phía bắc	–	–	–	–	–	–	–
105	Governor's Island/Ellis Island/Liberty Island	Manhattan phía bắc	0	0	-5,0	15,8	21,0	8,9	9,6
107	Gramercy	CRZ	4.996	4.555	-8,8	12,6	12,8	4,1	4,1
113	Greenwich Village North	CRZ	3.894	3.586	-7,9	11,4	11,7	4,2	4,1
114	Greenwich Village South	CRZ	4.023	3.674	-8,7	11,5	11,9	4,4	4,2
116	Hamilton Heights	Manhattan phía bắc	2.894	2.907	0,5	15,6	15,4	4,6	4,9
120	Highbridge Park	Manhattan phía bắc	65	59	-7,9	16,5	16,4	4,6	5,0
125	Hudson Sq	CRZ	2.209	2.213	0,2	12,5	12,8	4,3	4,2
127	Inwood	Manhattan phía bắc	2.205	2.317	5,1	16,6	16,5	4,2	4,4
128	Inwood Hill Park	Manhattan phía bắc	175	187	7,4	16,4	16,0	4,1	4,3
137	Kips Bay	CRZ	3.510	3.253	-7,3	13,8	14,2	4,6	4,5
140	Lenox Hill East	Vắt ranh giới	3.703	3.546	-4,2	14,2	14,1	4,5	4,5
141	Lenox Hill West	Vắt ranh giới	4.122	4.000	-3,0	13,3	13,3	4,2	4,1
142	Lincoln Square East	Vắt ranh giới	4.317	4.043	-6,4	13,2	13,3	4,3	4,2
143	Lincoln Square West	Vắt ranh giới	3.202	3.058	-4,5	13,7	13,7	4,4	4,3
144	Little Italy/NoLiTa	CRZ	4.595	4.288	-6,7	11,7	12,0	4,6	4,4
148	Lower East Side	CRZ	6.575	6.300	-4,2	13,6	13,9	4,8	4,6
151	Manhattan Valley	Manhattan phía bắc	1.910	1.778	-6,9	14,9	14,8	4,4	4,5

Mã	Tên vùng	Nhóm	Đón/ ngày 2024	Đón/ ngày 2025	Thay đổi %	Dặm/ giờ 2024	Dặm/ giờ 2025	Chờ 2024	Chờ 2025
152	Manhattanville	Manhattan phía bắc	1.441	1.404	-2,5	15,2	15,0	4,7	4,9
153	Marble Hill	Manhattan phía bắc	592	602	1,7	14,6	14,5	4,5	4,9
158	Meatpacking/West Village West	CRZ	3.766	3.547	-5,8	11,4	11,6	4,2	4,1
161	Midtown Center	CRZ	7.076	7.070	-0,1	11,6	11,6	4,8	4,6
162	Midtown East	CRZ	4.843	4.834	-0,2	12,5	12,7	4,2	4,0
163	Midtown North	CRZ	5.068	5.014	-1,1	12,1	12,1	4,3	4,1
164	Midtown South	CRZ	6.454	6.143	-4,8	13,1	13,4	4,5	4,4
166	Morningside Heights	Manhattan phía bắc	2.750	2.648	-3,7	14,5	14,4	4,2	4,3
170	Murray Hill	CRZ	5.674	5.430	-4,3	12,9	13,2	4,4	4,3
186	Penn Station/Madison Sq West	CRZ	3.843	3.718	-3,2	12,1	12,3	4,4	4,2
194	Randalls Island	Manhattan phía bắc	110	139	26,3	16,9	16,8	7,6	7,6
202	Roosevelt Island	Manhattan phía bắc	445	439	-1,4	14,1	14,1	5,9	6,3
209	Seaport	CRZ	1.460	1.369	-6,2	15,1	15,2	4,7	4,8
211	SoHo	CRZ	3.603	3.472	-3,6	10,9	11,1	4,2	4,0
224	Stuy Town/Peter Cooper Village	CRZ	1.422	1.276	-10,2	13,6	14,0	5,2	5,2
229	Sutton Place/Turtle Bay North	CRZ	3.733	3.500	-6,2	12,5	12,6	4,0	3,9
230	Times Sq/Theatre District	CRZ	7.326	7.139	-2,5	13,4	13,5	5,1	4,9
231	TriBeCa/Civic Center	CRZ	7.084	6.876	-2,9	13,1	13,3	4,2	4,0
232	Two Bridges/Seward Park	CRZ	2.883	2.689	-6,7	13,9	14,2	5,4	5,4
233	UN/Turtle Bay South	CRZ	3.573	3.367	-5,8	12,9	13,3	4,3	4,3
234	Union Sq	CRZ	6.497	6.488	-0,1	11,4	11,6	4,2	4,2
236	Upper East Side North	Manhattan phía bắc	4.570	4.379	-4,2	13,3	13,2	4,2	4,2
237	Upper East Side South	Vắt ranh giới	5.058	5.166	2,1	11,6	11,7	3,9	3,8
238	Upper West Side North	Manhattan phía bắc	3.267	3.088	-5,5	14,9	15,1	4,3	4,3
239	Upper West Side South	Manhattan phía bắc	4.014	3.740	-6,8	14,2	14,4	4,2	4,1
243	Washington Heights North	Manhattan phía bắc	3.323	3.417	2,8	16,6	16,5	4,4	4,7
244	Washington Heights South	Manhattan phía bắc	4.712	4.748	0,8	16,8	16,6	4,4	4,7
246	West Chelsea/Hudson Yards	CRZ	6.625	6.405	-3,3	11,2	11,4	4,6	4,5
249	West Village	CRZ	5.846	5.379	-8,0	11,5	11,7	4,3	4,2
261	World Trade Center	CRZ	2.304	2.287	-0,7	15,0	15,2	4,7	4,8
262	Yorkville East	Manhattan phía bắc	2.330	2.185	-6,2	15,3	15,2	4,7	4,7
263	Yorkville West	Manhattan phía bắc	3.436	3.313	-3,6	15,5	15,2	4,3	4,4

Nguồn: a01_zone_detail.csv.

Bảng B.2. Chỉ tiêu HVFHV theo vùng – Brooklyn

Mã	Tên vùng	Nhóm	Đón/ ngày 2024	Đón/ ngày 2025	Thay đổi %	Dặm/ giờ 2024	Dặm/ giờ 2025	Chờ 2024	Chờ 2025
11	Bath Beach	Quận ngoài	698	763	9,3	16,6	16,4	4,2	4,4
14	Bay Ridge	Quận ngoài	3.419	3.646	6,6	16,9	16,8	4,0	4,2
17	Bedford	Quận ngoài	5.384	5.346	-0,7	11,6	11,5	4,9	5,1
21	Bensonhurst East	Quận ngoài	1.607	1.774	10,4	14,2	13,9	4,3	4,5
22	Bensonhurst West	Quận ngoài	2.126	2.355	10,8	14,2	14,1	4,3	4,6
25	Boerum Hill	Quận ngoài	3.796	3.846	1,3	13,2	13,2	4,6	4,8
26	Borough Park	Quận ngoài	3.179	3.330	4,8	10,7	10,7	4,8	5,1

Mã	Tên vùng	Nhóm	Đón/ ngày 2024	Đón/ ngày 2025	Thay đổi %	Dặm/ giờ 2024	Dặm/ giờ 2025	Chờ 2024	Chờ 2025
29	Brighton Beach	Quận ngoài	1.203	1.366	13,5	15,7	15,5	4,3	4,5
33	Brooklyn Heights	Quận ngoài	3.089	3.122	1,1	14,4	14,3	4,5	4,6
34	Brooklyn Navy Yard	Quận ngoài	610	564	-7,5	13,3	13,1	5,7	6,0
35	Brownsville	Quận ngoài	3.886	3.972	2,2	12,2	12,0	5,3	5,5
36	Bushwick North	Quận ngoài	5.186	5.283	1,9	12,5	12,3	4,5	4,9
37	Bushwick South	Quận ngoài	6.999	7.269	3,9	12,1	12,0	4,6	4,9
39	Canarsie	Quận ngoài	4.711	4.933	4,7	13,8	13,6	5,1	5,3
40	Carroll Gardens	Quận ngoài	1.509	1.582	4,9	14,3	14,3	4,1	4,2
49	Clinton Hill	Quận ngoài	3.965	3.994	0,7	12,2	12,1	4,5	4,7
52	Cobble Hill	Quận ngoài	1.012	1.019	0,7	14,0	14,0	4,1	4,1
54	Columbia Street	Quận ngoài	372	390	4,8	15,1	15,1	4,4	4,4
55	Coney Island	Quận ngoài	1.704	1.846	8,4	17,5	17,3	4,8	5,1
61	Crown Heights North	Quận ngoài	8.511	8.585	0,9	11,8	11,6	5,0	5,2
62	Crown Heights South	Quận ngoài	2.348	2.425	3,3	11,6	11,5	5,0	5,3
63	Cypress Hills	Quận ngoài	2.020	2.104	4,1	14,2	13,9	4,4	4,7
65	Downtown Brooklyn/MetroTech	Quận ngoài	3.133	3.094	-1,3	13,9	13,9	5,0	5,1
66	DUMBO/Vinegar Hill	Quận ngoài	2.394	2.483	3,7	13,9	13,9	4,7	4,8
67	Dyker Heights	Quận ngoài	1.140	1.228	7,7	15,1	14,9	4,3	4,5
71	East Flatbush/Farragut	Quận ngoài	2.813	2.838	0,9	11,8	11,7	5,0	5,2
72	East Flatbush/Remsen Village	Quận ngoài	3.260	3.300	1,2	11,8	11,7	5,4	5,6
76	East New York	Quận ngoài	6.943	7.366	6,1	13,8	13,4	4,8	5,0
77	East New York/Pennsylvania Avenue	Quận ngoài	1.886	1.922	1,9	13,1	12,9	4,9	5,1
80	East Williamsburg	Quận ngoài	5.196	5.138	-1,1	13,3	13,0	4,6	4,7
85	Erasmus	Quận ngoài	2.030	2.100	3,4	12,1	11,9	4,9	5,1
89	Flatbush/Ditmas Park	Quận ngoài	5.103	5.293	3,7	12,7	12,6	4,5	4,7
91	Flatlands	Quận ngoài	3.162	3.255	3,0	12,9	12,6	4,9	5,1
97	Fort Greene	Quận ngoài	4.255	4.368	2,7	12,5	12,5	4,8	4,9
106	Gowanus	Quận ngoài	1.300	1.450	11,5	13,1	13,1	4,1	4,4
108	Gravesend	Quận ngoài	880	971	10,3	16,4	16,2	4,3	4,5
111	Green-Wood Cemetery	Quận ngoài	24	25	1,1	13,3	13,7	4,0	4,2
112	Greenpoint	Quận ngoài	6.175	6.493	5,1	12,9	12,8	4,2	4,4
123	Homecrest	Quận ngoài	1.780	1.962	10,2	13,2	12,9	4,2	4,4
133	Kensington	Quận ngoài	1.226	1.252	2,1	13,7	13,6	4,2	4,4
149	Madison	Quận ngoài	1.497	1.624	8,5	12,9	12,7	4,1	4,3
150	Manhattan Beach	Quận ngoài	673	709	5,4	16,7	16,4	4,5	4,6
154	Marine Park/Floyd Bennett Field	Quận ngoài	69	59	-13,7	18,4	17,4	6,6	6,2
155	Marine Park/Mill Basin	Quận ngoài	1.781	1.837	3,1	14,0	13,8	5,0	5,3
165	Midwood	Quận ngoài	1.884	2.004	6,4	12,4	12,1	4,2	4,4
177	Ocean Hill	Quận ngoài	2.748	2.794	1,7	12,3	12,1	5,1	5,3
178	Ocean Parkway South	Quận ngoài	631	659	4,4	12,5	12,4	4,3	4,5
181	Park Slope	Quận ngoài	6.241	6.365	2,0	12,9	12,8	4,0	4,1
188	Prospect-Lefferts Gardens	Quận ngoài	4.878	5.024	3,0	11,6	11,5	4,9	5,1
189	Prospect Heights	Quận ngoài	2.375	2.418	1,8	12,3	12,2	4,4	4,6
190	Prospect Park	Quận ngoài	395	397	0,4	11,8	11,8	4,7	4,9
195	Red Hook	Quận ngoài	1.207	1.320	9,4	14,6	14,7	5,1	5,3
210	Sheepshead Bay	Quận ngoài	1.967	2.136	8,6	15,3	15,0	4,3	4,5
217	South Williamsburg	Quận ngoài	1.069	1.141	6,7	10,5	10,3	5,4	5,7
222	Starrett City	Quận ngoài	777	830	6,8	14,8	14,5	5,3	5,5
225	Stuyvesant Heights	Quận ngoài	5.188	5.241	1,0	11,6	11,4	4,9	5,1
227	Sunset Park East	Quận ngoài	1.528	1.665	9,0	13,4	13,3	4,5	4,8
228	Sunset Park West	Quận ngoài	3.128	3.385	8,2	14,3	14,3	4,5	4,8
255	Williamsburg (North Side)	Quận ngoài	6.568	6.570	0,0	12,5	12,5	4,3	4,4
256	Williamsburg (South Side)	Quận ngoài	5.410	5.493	1,5	12,4	12,5	4,4	4,6

Mã	Tên vùng	Nhóm	Đón/ ngày 2024	Đón/ ngày 2025	Thay đổi %	Dặm/ giờ 2024	Dặm/ giờ 2025	Chờ 2024	Chờ 2025
257	Windsor Terrace	Quận ngoài	949	1.016	7,1	15,0	15,0	4,1	4,3

Nguồn: a01_zone_detail.csv.

Bảng B.3. Chỉ tiêu HVFHV theo vùng – Queens

Mã	Tên vùng	Nhóm	Đón/ ngày 2024	Đón/ ngày 2025	Thay đổi %	Dặm/ giờ 2024	Dặm/ giờ 2025	Chờ 2024	Chờ 2025
2	Jamaica Bay	Quận ngoài	1	2	28,6	18,1	18,1	8,2	8,5
7	Astoria	Quận ngoài	6.192	6.277	1,4	14,6	14,5	3,7	3,9
8	Astoria Park	Quận ngoài	27	27	1,3	14,2	14,0	4,2	4,3
9	Auburndale	Quận ngoài	541	585	8,0	17,9	17,8	4,4	4,7
10	Baisley Park	Quận ngoài	2.011	2.121	5,5	15,7	15,4	4,4	4,6
15	Bay Terrace/Fort Totten	Quận ngoài	431	464	7,4	20,7	20,5	5,5	5,9
16	Bayside	Quận ngoài	1.163	1.267	9,0	19,6	19,4	4,5	4,8
19	Bellerose	Quận ngoài	442	474	7,3	21,8	21,3	4,9	5,4
27	Breezy Point/Fort Tilden/Riis Beach	Quận ngoài	50	50	0,9	20,8	21,2	9,7	10,2
28	Briarwood/Jamaica Hills	Quận ngoài	1.536	1.641	6,8	16,2	15,9	4,4	4,7
30	Broad Channel	Quận ngoài	38	38	0,3	19,7	19,5	8,4	8,7
38	Cambria Heights	Quận ngoài	642	708	10,3	19,1	18,7	4,8	5,2
53	College Point	Quận ngoài	929	1.009	8,6	17,5	17,4	5,1	5,6
56	Corona	Quận ngoài	1.882	2.059	9,4	14,7	14,6	4,6	4,9
57	Corona	Quận ngoài	136	160	17,7	17,1	16,9	5,1	5,5
64	Douglaston	Quận ngoài	347	376	8,5	21,8	21,6	5,8	6,4
70	East Elmhurst	Quận ngoài	1.518	1.598	5,3	16,0	16,1	4,1	4,4
73	East Flushing	Quận ngoài	640	686	7,2	15,0	14,9	4,3	4,7
82	Elmhurst	Quận ngoài	4.473	4.887	9,3	13,4	13,2	4,5	4,7
83	Elmhurst/Maspeth	Quận ngoài	1.426	1.615	13,3	14,3	14,2	4,4	4,6
86	Far Rockaway	Quận ngoài	1.084	1.203	11,0	17,1	16,7	6,5	7,3
92	Flushing	Quận ngoài	3.232	3.555	10,0	16,4	16,2	4,7	5,3
93	Flushing Meadows-Corona Park	Quận ngoài	486	494	1,7	18,4	18,4	8,1	8,1
95	Forest Hills	Quận ngoài	4.255	4.601	8,1	15,4	15,2	4,6	4,8
96	Forest Park/Highland Park	Quận ngoài	96	100	4,6	15,1	15,0	5,0	5,2
98	Fresh Meadows	Quận ngoài	553	603	9,1	17,7	17,7	4,7	5,1
101	Glen Oaks	Quận ngoài	383	428	11,8	22,7	22,3	5,2	5,7
102	Glendale	Quận ngoài	1.524	1.607	5,5	13,5	13,3	4,7	5,0
117	Hammels/Arverne	Quận ngoài	934	1.014	8,6	17,6	17,1	6,8	7,6
121	Hillcrest/Pomonok	Quận ngoài	1.370	1.463	6,8	16,1	16,0	4,5	4,9
122	Hollis	Quận ngoài	692	767	10,7	16,9	16,5	4,8	5,1
124	Howard Beach	Quận ngoài	942	995	5,7	17,4	16,8	5,3	5,4
129	Jackson Heights	Quận ngoài	4.955	5.159	4,1	13,9	13,8	4,4	4,6
130	Jamaica	Quận ngoài	4.667	5.137	10,1	15,5	15,2	4,6	4,9
131	Jamaica Estates	Quận ngoài	932	1.002	7,5	17,8	17,6	4,5	4,7
132	JFK Airport	Sân bay	9.525	8.861	-7,0	21,3	20,6	6,7	6,4
134	Kew Gardens	Quận ngoài	1.398	1.529	9,4	17,0	16,6	4,3	4,5
135	Kew Gardens Hills	Quận ngoài	1.097	1.158	5,6	16,2	16,1	4,4	4,7
138	LaGuardia Airport	Sân bay	11.319	11.642	2,9	17,4	17,4	6,2	6,4
139	Laurelton	Quận ngoài	1.047	1.150	9,8	17,5	17,1	4,9	5,2
145	Long Island City/Hunters Point	Quận ngoài	5.297	5.660	6,9	14,1	14,1	4,0	4,2
146	Long Island City/Queens Plaza	Quận ngoài	1.604	1.679	4,7	13,5	13,5	3,9	4,0
157	Maspeth	Quận ngoài	2.055	2.203	7,2	14,2	14,1	5,0	5,2
160	Middle Village	Quận ngoài	1.391	1.496	7,6	14,1	14,0	4,6	4,9
171	Murray Hill-Queens	Quận ngoài	1.202	1.316	9,4	16,3	16,1	4,2	4,6
173	North Corona	Quận ngoài	1.515	1.688	11,4	14,3	14,3	5,0	5,2

Mã	Tên vùng	Nhóm	Đón/ ngày 2024	Đón/ ngày 2025	Thay đổi %	Đắm/ giờ 2024	Đắm/ giờ 2025	Chờ 2024	Chờ 2025
175	Oakland Gardens	Quận ngoài	459	483	5,3	20,6	20,5	4,8	5,2
179	Old Astoria	Quận ngoài	2.241	2.357	5,2	14,3	14,2	4,0	4,2
180	Ozone Park	Quận ngoài	1.067	1.135	6,4	15,3	14,8	4,4	4,5
191	Queens Village	Quận ngoài	1.579	1.709	8,2	18,8	18,4	4,7	5,0
192	Queensboro Hill	Quận ngoài	813	874	7,5	16,7	16,8	4,2	4,5
193	Queensbridge/Ravenswood	Quận ngoài	941	1.121	19,1	13,3	13,5	4,3	4,5
196	Rego Park	Quận ngoài	1.599	1.754	9,6	14,6	14,4	4,6	4,8
197	Richmond Hill	Quận ngoài	2.753	2.885	4,8	15,3	14,7	4,5	4,7
198	Ridgewood	Quận ngoài	3.969	4.232	6,6	12,7	12,5	4,5	4,8
201	Rockaway Park	Quận ngoài	433	463	6,9	19,8	19,6	6,5	7,3
203	Rosedale	Quận ngoài	929	987	6,3	18,1	17,8	5,6	6,2
205	Saint Albans	Quận ngoài	2.463	2.629	6,8	15,7	15,3	5,1	5,4
207	Saint Michaels Cemetery/Woodside	Quận ngoài	118	118	0,1	15,8	15,6	4,6	4,3
215	South Jamaica	Quận ngoài	1.951	2.030	4,0	14,9	14,2	4,8	5,1
216	South Ozone Park	Quận ngoài	4.120	4.327	5,0	15,8	15,1	4,0	4,1
218	Springfield Gardens North	Quận ngoài	1.275	1.311	2,8	16,1	15,7	4,7	5,1
219	Springfield Gardens South	Quận ngoài	1.056	1.108	5,0	17,1	16,7	5,0	5,3
223	Steinway	Quận ngoài	3.111	3.253	4,6	15,9	15,5	3,8	3,9
226	Sunnyside	Quận ngoài	3.866	4.092	5,8	13,2	13,2	4,2	4,4
252	Whitestone	Quận ngoài	780	859	10,2	19,1	19,0	5,1	5,6
253	Willets Point	Quận ngoài	23	24	0,8	18,4	17,8	7,0	7,1
258	Woodhaven	Quận ngoài	2.054	2.133	3,9	15,0	14,7	4,6	4,8
260	Woodside	Quận ngoài	2.793	3.009	7,7	14,4	14,2	3,9	4,1

Nguồn: a01_zone_detail.csv.

Bảng B.4. Chỉ tiêu HVFHV theo vùng – Bronx

Mã	Tên vùng	Nhóm	Đón/ ngày 2024	Đón/ ngày 2025	Thay đổi %	Đắm/ giờ 2024	Đắm/ giờ 2025	Chờ 2024	Chờ 2025
3	Allerton/Pelham Gardens	Quận ngoài	1.333	1.414	6,1	15,5	15,6	4,5	4,7
18	Bedford Park	Quận ngoài	2.842	3.042	7,1	13,9	13,8	4,6	4,8
20	Belmont	Quận ngoài	1.819	1.912	5,1	14,1	14,1	4,5	4,7
31	Bronx Park	Quận ngoài	266	274	3,0	16,0	16,2	5,0	5,4
32	Bronxdale	Quận ngoài	1.483	1.558	5,0	15,2	15,1	4,5	4,8
46	City Island	Quận ngoài	110	121	10,3	21,4	21,6	8,3	8,6
47	Claremont/Bathgate	Quận ngoài	2.080	2.172	4,4	13,2	13,1	4,6	4,9
51	Co-Op City	Quận ngoài	2.251	2.360	4,9	16,8	16,8	5,1	5,4
58	Country Club	Quận ngoài	201	211	5,2	17,8	17,9	5,6	5,9
59	Crotona Park	Quận ngoài	72	79	10,4	13,8	13,7	4,9	5,1
60	Crotona Park East	Quận ngoài	1.403	1.494	6,5	13,8	13,9	5,0	5,2
69	East Concourse/Concourse Village	Quận ngoài	3.173	3.340	5,3	13,2	13,0	4,9	5,1
78	East Tremont	Quận ngoài	2.739	2.875	5,0	13,8	13,7	4,7	4,9
81	Eastchester	Quận ngoài	1.537	1.644	7,0	16,6	16,6	4,9	5,3
94	Fordham South	Quận ngoài	1.305	1.348	3,3	13,0	13,0	4,6	4,9
119	Highbridge	Quận ngoài	2.086	2.166	3,8	14,7	14,6	4,9	5,1
126	Hunts Point	Quận ngoài	1.955	2.033	4,0	14,4	14,3	5,3	5,3
136	Kingsbridge Heights	Quận ngoài	1.592	1.678	5,4	14,2	14,2	4,5	4,8
147	Longwood	Quận ngoài	1.311	1.372	4,7	13,4	13,3	4,6	4,7
159	Melrose South	Quận ngoài	2.839	2.978	4,9	12,5	12,4	4,7	4,8
167	Morrisania/Melrose	Quận ngoài	2.341	2.445	4,5	12,5	12,3	4,7	4,8
168	Mott Haven/Port Morris	Quận ngoài	3.894	4.249	9,1	14,8	14,7	4,9	5,1
169	Mount Hope	Quận ngoài	2.933	3.033	3,4	13,6	13,5	4,7	4,9
174	Norwood	Quận ngoài	2.460	2.612	6,2	15,5	15,4	4,3	4,5
182	Parkchester	Quận ngoài	1.622	1.720	6,1	14,8	14,8	4,4	4,7

Mã	Tên vùng	Nhóm	Đón/ ngày 2024	Đón/ ngày 2025	Thay đổi %	Dặm/ giờ 2024	Dặm/ giờ 2025	Chờ 2024	Chờ 2025
183	Pelham Bay	Quận ngoài	780	824	5,7	18,0	18,4	4,6	4,8
184	Pelham Bay Park	Quận ngoài	143	158	10,3	18,9	19,2	5,6	5,9
185	Pelham Parkway	Quận ngoài	1.927	2.027	5,2	15,2	15,3	4,6	4,8
199	Rikers Island	Quận ngoài	0	0	28,9	18,4	20,3	10,9	12,2
200	Riverdale/North Riverdale/Fieldston	Quận ngoài	1.135	1.226	8,0	20,4	20,4	4,9	5,2
208	Schuylerville/Edgewater Park	Quận ngoài	1.987	2.093	5,3	18,0	18,3	4,9	5,1
212	Soundview/Bruckner	Quận ngoài	1.638	1.764	7,7	15,9	16,1	4,6	4,9
213	Soundview/Castle Hill	Quận ngoài	2.980	3.182	6,8	15,9	16,0	5,0	5,3
220	Spuyten Duyvil/Kingsbridge	Quận ngoài	2.049	2.231	8,9	17,1	16,9	4,4	4,7
235	University Heights/Morris Heights	Quận ngoài	2.604	2.728	4,8	14,2	14,1	5,1	5,3
240	Van Cortlandt Park	Quận ngoài	313	334	6,5	17,3	17,2	5,0	5,4
241	Van Cortlandt Village	Quận ngoài	2.264	2.372	4,8	15,0	14,9	4,5	4,8
242	Van Nest/Morris Park	Quận ngoài	2.416	2.552	5,7	13,9	13,8	4,5	4,7
247	West Concourse	Quận ngoài	3.152	3.347	6,2	14,3	14,2	5,2	5,3
248	West Farms/Bronx River	Quận ngoài	1.506	1.601	6,3	15,9	15,9	4,6	4,9
250	Westchester Village/Unionport	Quận ngoài	1.480	1.601	8,2	15,0	15,3	4,4	4,6
254	Williamsbridge/Olinville	Quận ngoài	2.781	2.962	6,5	15,8	15,6	4,9	5,3
259	Woodlawn/Wakefield	Quận ngoài	1.593	1.734	8,9	18,0	17,7	5,1	5,6

Nguồn: a01_zone_detail.csv.

Bảng B.5. Chỉ tiêu HVFHV theo vùng – Staten Island

Mã	Tên vùng	Nhóm	Đón/ ngày 2024	Đón/ ngày 2025	Thay đổi %	Dặm/ giờ 2024	Dặm/ giờ 2025	Chờ 2024	Chờ 2025
5	Arden Heights	Quận ngoài	188	188	0,0	22,5	22,6	6,2	6,9
6	Arrochar/Fort Wadsworth	Quận ngoài	357	388	8,7	19,3	19,3	5,1	5,8
23	Bloomfield/Emerson Hill	Quận ngoài	956	1.028	7,5	20,8	20,8	5,7	6,3
44	Charleston/Tottenville	Quận ngoài	250	285	14,0	25,6	25,3	6,8	7,4
84	Eltingville/Annadale/Prince's Bay	Quận ngoài	285	312	9,2	22,0	21,7	6,3	6,7
99	Freshkills Park	Quận ngoài	14	16	18,3	22,1	22,4	6,4	6,8
109	Great Kills	Quận ngoài	425	470	10,6	18,9	18,6	6,2	6,8
110	Great Kills Park	Quận ngoài	1	1	2,4	18,6	19,3	7,7	8,7
115	Grymes Hill/Clifton	Quận ngoài	523	563	7,7	18,0	17,7	5,8	6,6
118	Heartland Village/Todt Hill	Quận ngoài	649	680	4,8	18,6	18,6	5,8	6,6
156	Mariners Harbor	Quận ngoài	846	927	9,5	19,4	19,3	5,2	5,8
172	New Dorp/Midland Beach	Quận ngoài	387	434	12,1	17,3	17,1	5,8	6,5
176	Oakwood	Quận ngoài	213	235	10,0	17,9	17,8	6,1	6,7
187	Port Richmond	Quận ngoài	455	500	9,8	18,8	18,7	5,4	6,1
204	Rossville/Woodrow	Quận ngoài	160	174	8,6	25,0	24,9	6,0	6,6
206	Saint George/New Brighton	Quận ngoài	1.318	1.394	5,8	16,9	16,6	5,2	5,9
214	South Beach/Dongan Hills	Quận ngoài	525	570	8,5	17,9	17,8	5,1	5,8
221	Stapleton	Quận ngoài	892	964	8,0	17,9	17,6	5,3	6,1
245	West Brighton	Quận ngoài	495	530	7,1	17,4	17,2	5,7	6,3
251	Westerleigh	Quận ngoài	491	537	9,4	18,6	18,6	5,2	5,8

Nguồn: a01_zone_detail.csv.

Bảng B.6. Chỉ tiêu HVFHV theo vùng – EWR

Mã	Tên vùng	Nhóm	Đón/ ngày 2024	Đón/ ngày 2025	Thay đổi %	Dặm/ giờ 2024	Dặm/ giờ 2025	Chờ 2024	Chờ 2025
1	Newark Airport	Sân bay	0	0	-42,7	6,6	10,7	35,9	42,6

Nguồn: a01_zone_detail.csv.

PHỤ LỤC C. CHỈ TIÊU THEO THÁNG VÀ NHÓM VÙNG

Bảng C.1. Chỉ tiêu theo tháng – HVFHV, nhóm vùng đón CRZ

Tháng	Chuyến/ ngày	Giá/chuyến	Dặm/giờ	Phí CBD/chuyến	% chuyến bị tính phí	TN tài xế/chuyến	Chờ (phút)
2024-01	162.681	25,35	13,20	0,000	0,0	17,88	3,87
2024-02	171.931	25,92	12,98	0,000	0,0	18,81	4,13
2024-03	171.199	27,54	12,84	0,000	0,0	19,51	4,46
2024-04	165.326	27,91	12,70	0,000	0,0	19,79	4,46
2024-05	166.866	29,72	12,43	0,000	0,0	21,08	4,39
2024-06	165.127	29,39	12,70	0,000	0,0	20,74	4,68
2024-07	153.292	27,34	13,03	0,000	0,0	19,34	4,17
2024-08	148.855	27,82	13,18	0,000	0,0	19,54	4,23
2024-09	160.730	30,30	12,27	0,000	0,0	21,62	4,86
2024-10	162.722	30,42	12,43	0,000	0,0	21,51	4,50
2024-11	165.214	30,23	12,61	0,000	0,0	21,37	4,42
2024-12	161.083	33,47	12,31	0,000	0,0	23,66	5,32
2025-01	158.331	26,98	13,85	1,325	88,4	18,29	4,10
2025-02	168.527	27,88	13,52	1,489	99,3	19,04	4,38
2025-03	154.767	31,25	13,70	1,489	99,3	20,64	4,40
2025-04	157.682	29,42	13,12	1,490	99,3	20,21	4,07
2025-05	157.663	32,72	12,60	1,488	99,2	22,50	4,78
2025-06	150.219	32,63	12,96	1,487	99,1	22,33	4,72
2025-07	144.388	30,34	13,01	1,488	99,2	20,87	4,10
2025-08	135.876	29,63	13,57	1,490	99,4	20,92	3,84
2025-09	157.110	32,74	12,37	1,487	99,2	23,04	4,52
2025-10	165.483	31,67	12,36	1,490	99,4	22,67	4,37
2025-11	161.668	32,00	12,55	1,489	99,3	22,62	4,12
2025-12	155.117	35,47	12,12	1,491	99,4	24,32	4,70

Nguồn: a02_month_group_detail.csv.

Bảng C.2. Chỉ tiêu theo tháng – HVFHV, nhóm vùng đón Vắt ranh giới

Tháng	Chuyến/ ngày	Giá/chuyến	Dặm/giờ	Phí CBD/chuyến	% chuyến bị tính phí	TN tài xế/chuyến	Chờ (phút)
2024-01	22.280	24,41	13,34	0,000	0,0	17,46	3,78
2024-02	22.332	25,30	13,33	0,000	0,0	18,51	3,88
2024-03	22.157	26,65	13,33	0,000	0,0	19,02	4,10
2024-04	22.328	26,65	13,13	0,000	0,0	19,06	4,19
2024-05	22.562	28,21	12,63	0,000	0,0	20,26	4,24
2024-06	21.012	27,86	13,13	0,000	0,0	19,93	4,36
2024-07	18.910	26,27	13,57	0,000	0,0	18,83	3,97
2024-08	17.980	27,01	13,71	0,000	0,0	19,17	4,03
2024-09	20.322	28,75	12,62	0,000	0,0	21,00	4,56
2024-10	21.482	28,56	12,62	0,000	0,0	20,76	4,14
2024-11	22.189	28,63	12,77	0,000	0,0	20,62	4,34
2024-12	22.172	30,99	12,55	0,000	0,0	22,32	5,04
2025-01	22.007	25,50	13,74	0,824	55,0	17,90	3,95
2025-02	22.370	26,48	13,62	0,940	62,7	18,72	4,10
2025-03	20.224	29,49	13,93	0,951	63,4	20,19	4,08
2025-04	21.603	27,84	13,30	0,950	63,3	19,75	3,89
2025-05	21.705	30,28	12,66	0,963	64,2	21,43	4,58
2025-06	19.648	30,04	13,14	0,969	64,6	21,19	4,53

Tháng	Chuyển/ ngày	Giá/chuyển	Dặm/giờ	Phí CBD/chuyển	% chuyển bị tính phí	TN tài xế/chuyển	Chờ (phút)
2025-07	17.966	28,47	13,23	0,995	66,3	20,30	3,94
2025-08	16.622	28,18	13,97	0,987	65,8	20,49	3,73
2025-09	20.356	30,21	12,55	0,957	63,8	22,02	4,26
2025-10	22.199	29,51	12,30	0,952	63,5	21,85	4,21
2025-11	22.092	29,57	12,46	0,939	62,6	21,59	4,02
2025-12	22.088	31,48	12,36	0,918	61,2	22,42	4,51

Nguồn: a02_month_group_detail.csv.

Bảng C.3. Chỉ tiêu theo tháng – HVFHV, nhóm vùng đón Manhattan phía bắc

Tháng	Chuyển/ ngày	Giá/chuyển	Dặm/giờ	Phí CBD/chuyển	% chuyển bị tính phí	TN tài xế/chuyển	Chờ (phút)
2024-01	57.906	21,59	15,25	0,000	0,0	16,65	4,04
2024-02	61.042	21,99	15,16	0,000	0,0	17,52	4,19
2024-03	60.654	23,12	15,08	0,000	0,0	17,88	4,48
2024-04	59.598	23,01	15,01	0,000	0,0	17,86	4,55
2024-05	59.387	24,25	14,60	0,000	0,0	18,86	4,59
2024-06	57.343	23,85	15,09	0,000	0,0	18,62	4,71
2024-07	53.119	22,66	15,77	0,000	0,0	17,78	4,34
2024-08	53.085	23,24	15,62	0,000	0,0	18,01	4,43
2024-09	55.040	23,86	14,65	0,000	0,0	18,89	4,74
2024-10	56.814	23,50	14,71	0,000	0,0	18,67	4,44
2024-11	59.522	23,78	14,83	0,000	0,0	18,80	4,63
2024-12	59.669	24,91	14,86	0,000	0,0	19,60	5,19
2025-01	59.005	21,79	15,50	0,290	19,3	17,01	4,32
2025-02	60.675	22,60	15,31	0,329	22,0	17,51	4,52
2025-03	57.272	24,82	15,57	0,323	21,6	18,65	4,65
2025-04	58.111	23,25	15,03	0,331	22,1	18,25	4,42
2025-05	57.462	24,90	14,46	0,320	21,3	19,64	5,07
2025-06	53.588	24,79	14,94	0,324	21,6	19,58	5,14
2025-07	51.160	23,20	15,21	0,323	21,6	18,71	4,62
2025-08	50.512	23,09	15,58	0,318	21,2	18,66	4,43
2025-09	54.342	24,30	14,52	0,328	21,9	19,31	4,69
2025-10	58.524	23,35	14,27	0,326	21,7	19,25	4,75
2025-11	59.671	23,34	14,65	0,313	20,9	18,94	4,57
2025-12	60.126	24,20	14,61	0,290	19,3	19,25	5,15

Nguồn: a02_month_group_detail.csv.

Bảng C.4. Chỉ tiêu theo tháng – HVFHV, nhóm vùng đón Quận ngoài

Tháng	Chuyển/ ngày	Giá/chuyển	Dặm/giờ	Phí CBD/chuyển	% chuyển bị tính phí	TN tài xế/chuyển	Chờ (phút)
2024-01	347.487	19,42	14,61	0,000	0,0	15,65	4,37
2024-02	367.000	19,70	14,48	0,000	0,0	16,45	4,41
2024-03	384.714	20,51	14,04	0,000	0,0	16,58	4,60
2024-04	362.414	20,57	14,27	0,000	0,0	16,68	4,53
2024-05	368.187	21,22	13,66	0,000	0,0	17,23	4,54
2024-06	376.292	21,22	13,99	0,000	0,0	17,27	4,83
2024-07	346.507	20,52	14,75	0,000	0,0	16,74	4,52
2024-08	349.703	21,04	14,65	0,000	0,0	16,99	4,58
2024-09	354.103	21,40	13,73	0,000	0,0	17,54	4,80
2024-10	354.123	20,88	14,07	0,000	0,0	17,21	4,57
2024-11	371.156	20,42	14,07	0,000	0,0	17,08	4,76

Tháng	Chuyển/ ngày	Giá/chuyển	Dặm/giờ	Phí CBD/chuyển	% chuyển bị tính phí	TN tài xế/chuyển	Chờ (phút)
2024-12	384.785	20,74	14,07	0,000	0,0	17,13	5,21
2025-01	372.220	19,29	14,62	0,093	6,2	15,90	4,69
2025-02	390.771	20,02	14,36	0,113	7,5	16,17	4,79
2025-03	378.217	21,77	14,28	0,109	7,3	16,87	4,90
2025-04	370.518	20,55	14,17	0,112	7,5	16,94	4,64
2025-05	389.697	21,09	13,64	0,111	7,4	17,62	5,05
2025-06	385.631	21,26	13,94	0,110	7,3	17,71	5,25
2025-07	369.890	20,41	14,43	0,110	7,3	17,20	4,82
2025-08	363.109	21,10	14,57	0,110	7,4	17,38	4,66
2025-09	362.833	21,90	13,73	0,119	8,0	17,85	4,81
2025-10	386.800	20,60	13,72	0,117	7,8	17,62	4,89
2025-11	398.686	20,54	13,97	0,110	7,3	17,38	4,79
2025-12	422.783	20,23	13,66	0,097	6,5	17,06	5,36

Nguồn: a02_month_group_detail.csv.

Bảng C.5. Chỉ tiêu theo tháng – HVFHV, nhóm vùng đón Sân bay

Tháng	Chuyển/ ngày	Giá/chuyển	Dặm/giờ	Phí CBD/chuyển	% chuyển bị tính phí	TN tài xế/chuyển	Chờ (phút)
2024-01	19.656	48,93	22,46	0,000	0,0	37,36	6,59
2024-02	18.807	49,41	21,30	0,000	0,0	37,83	6,09
2024-03	20.689	53,47	20,37	0,000	0,0	40,24	6,33
2024-04	21.081	52,95	20,39	0,000	0,0	39,45	6,45
2024-05	22.582	54,95	18,60	0,000	0,0	41,62	6,73
2024-06	22.032	54,88	18,74	0,000	0,0	41,43	6,58
2024-07	20.760	50,34	20,22	0,000	0,0	38,28	6,21
2024-08	21.136	51,33	20,01	0,000	0,0	38,74	6,28
2024-09	21.671	55,26	17,81	0,000	0,0	41,90	6,48
2024-10	21.316	54,38	18,84	0,000	0,0	40,14	6,23
2024-11	19.614	53,33	18,57	0,000	0,0	40,75	6,11
2024-12	20.753	58,40	17,81	0,000	0,0	42,55	6,95
2025-01	19.716	51,33	22,26	0,534	35,6	38,89	6,77
2025-02	19.412	49,83	21,24	0,594	39,6	39,63	6,61
2025-03	20.624	57,19	20,30	0,607	40,5	42,19	6,44
2025-04	20.779	56,32	19,72	0,580	38,7	42,00	6,30
2025-05	22.246	58,36	17,86	0,614	40,9	44,14	6,78
2025-06	21.608	57,96	18,30	0,610	40,7	43,03	6,44
2025-07	20.112	54,48	19,44	0,581	38,8	40,63	6,13
2025-08	19.971	55,04	19,40	0,566	37,7	40,63	5,96
2025-09	21.296	58,92	17,59	0,642	42,8	43,64	6,05
2025-10	21.317	59,08	17,72	0,650	43,3	43,53	6,30
2025-11	19.343	58,33	18,54	0,637	42,5	42,40	6,32
2025-12	19.450	60,09	17,48	0,605	40,3	43,29	6,84

Nguồn: a02_month_group_detail.csv.

Bảng C.6. Chỉ tiêu theo tháng – taxi vàng, nhóm vùng đón CRZ

Tháng	Chuyển/ngày	Giá/chuyển	Dặm/giờ	Phí CBD/chuyển	% chuyển bị tính phí
2024-01	52.797	15,52	10,57	0,000	0,0
2024-02	58.903	15,78	10,25	0,000	0,0
2024-03	65.695	16,30	10,21	0,000	0,0
2024-04	65.675	16,67	10,08	0,000	0,0

Tháng	Chuyến/ngày	Giá/chuyến	Dặm/giờ	Phí CBD/chuyến	% chuyến bị tính phí
2024-05	66.540	17,24	9,70	0,000	0,0
2024-06	67.266	16,96	9,94	0,000	0,0
2024-07	57.164	16,48	10,14	0,000	0,0
2024-08	54.896	16,41	10,31	0,000	0,0
2024-09	67.506	17,36	9,41	0,000	0,0
2024-10	68.214	17,30	9,40	0,000	0,0
2024-11	67.165	16,93	9,45	0,000	0,0
2024-12	65.137	17,80	8,87	0,000	0,0
2025-01	60.705	15,15	10,66	0,664	88,6
2025-02	69.074	15,42	10,30	0,746	99,4
2025-03	71.760	16,11	10,51	0,746	99,4
2025-04	69.683	16,35	10,15	0,746	99,4
2025-05	73.435	17,14	9,81	0,746	99,4
2025-06	72.742	17,32	10,21	0,745	99,4
2025-07	64.753	16,77	10,21	0,745	99,3
2025-08	58.404	16,18	10,75	0,743	99,1
2025-09	72.757	17,59	9,57	0,743	99,1
2025-10	71.466	17,09	9,36	0,742	99,0
2025-11	67.835	16,61	9,35	0,742	98,9
2025-12	71.740	20,13	9,09	0,742	98,9

Nguồn: a02_month_group_detail.csv.

Bảng C.7. Chỉ tiêu theo tháng – taxi vàng, nhóm vùng đón Vất ranh giới

Tháng	Chuyến/ngày	Giá/chuyến	Dặm/giờ	Phí CBD/chuyến	% chuyến bị tính phí
2024-01	14.756	13,35	10,15	0,000	0,0
2024-02	15.157	13,56	10,06	0,000	0,0
2024-03	16.134	13,93	10,13	0,000	0,0
2024-04	17.136	14,05	9,93	0,000	0,0
2024-05	17.769	14,61	9,40	0,000	0,0
2024-06	16.309	14,27	9,79	0,000	0,0
2024-07	13.212	13,93	10,10	0,000	0,0
2024-08	12.419	14,01	10,20	0,000	0,0
2024-09	16.526	14,73	9,09	0,000	0,0
2024-10	17.973	14,65	9,02	0,000	0,0
2024-11	17.950	14,42	9,09	0,000	0,0
2024-12	17.597	14,66	8,64	0,000	0,0
2025-01	15.910	13,19	10,08	0,340	45,3
2025-02	16.696	13,52	9,92	0,389	51,9
2025-03	16.632	14,01	10,17	0,409	54,6
2025-04	17.567	13,99	9,79	0,408	54,5
2025-05	18.698	14,66	9,40	0,412	55,0
2025-06	17.044	14,57	9,95	0,420	56,0
2025-07	14.255	14,33	9,99	0,436	58,1
2025-08	12.444	13,99	10,65	0,440	58,7
2025-09	17.316	14,95	9,28	0,408	54,4
2025-10	18.461	14,63	8,96	0,406	54,1
2025-11	17.665	14,31	8,95	0,407	54,3
2025-12	18.650	16,03	8,94	0,402	53,6

Nguồn: a02_month_group_detail.csv.

Bảng C.8. Chỉ tiêu theo tháng – taxi vàng, nhóm vùng đón Manhattan phía bắc

Tháng	Chuyến/ngày	Giá/chuyến	Dặm/giờ	Phí CBD/chuyến	% chuyến bị tính phí
2024-01	14.913	13,80	11,11	0,000	0,0
2024-02	15.881	14,07	11,06	0,000	0,0
2024-03	16.973	14,64	11,27	0,000	0,0
2024-04	18.222	14,84	11,12	0,000	0,0
2024-05	18.677	15,38	10,62	0,000	0,0
2024-06	17.114	15,06	11,07	0,000	0,0
2024-07	13.010	14,71	11,62	0,000	0,0
2024-08	12.499	14,83	11,62	0,000	0,0
2024-09	17.397	15,21	10,45	0,000	0,0
2024-10	18.183	14,96	10,39	0,000	0,0
2024-11	18.399	14,98	10,35	0,000	0,0
2024-12	17.696	14,88	10,04	0,000	0,0
2025-01	16.601	13,86	10,98	0,186	24,8
2025-02	18.500	14,44	11,07	0,216	28,8
2025-03	18.333	15,15	11,56	0,231	30,7
2025-04	18.951	15,13	11,32	0,235	31,4
2025-05	20.409	15,92	11,03	0,239	31,9
2025-06	18.959	16,44	11,74	0,251	33,5
2025-07	15.499	16,27	12,10	0,265	35,3
2025-08	13.857	15,62	12,61	0,263	35,0
2025-09	19.101	16,40	11,12	0,247	32,9
2025-10	19.515	15,58	10,63	0,240	32,1
2025-11	19.051	15,00	10,64	0,236	31,5
2025-12	21.613	17,72	11,00	0,237	31,7

Nguồn: a02_month_group_detail.csv.

Bảng C.9. Chỉ tiêu theo tháng – taxi vàng, nhóm vùng đón Quận ngoài

Tháng	Chuyến/ngày	Giá/chuyến	Dặm/giờ	Phí CBD/chuyến	% chuyến bị tính phí
2024-01	1.874	33,16	14,32	0,000	0,0
2024-02	2.044	32,93	13,80	0,000	0,0
2024-03	2.866	31,76	13,33	0,000	0,0
2024-04	3.072	32,13	13,49	0,000	0,0
2024-05	3.426	32,50	12,89	0,000	0,0
2024-06	3.577	31,99	13,20	0,000	0,0
2024-07	2.839	32,36	13,76	0,000	0,0
2024-08	3.032	33,17	14,09	0,000	0,0
2024-09	4.163	32,37	13,54	0,000	0,0
2024-10	3.558	31,82	13,41	0,000	0,0
2024-11	3.980	30,98	13,35	0,000	0,0
2024-12	3.466	32,03	12,87	0,000	0,0
2025-01	3.684	29,25	14,10	0,133	17,7
2025-02	5.886	27,77	14,01	0,136	18,1
2025-03	7.683	28,53	14,31	0,127	17,0
2025-04	6.953	28,29	14,11	0,136	18,1
2025-05	8.915	27,84	13,74	0,147	19,6
2025-06	9.949	29,32	14,06	0,151	20,1
2025-07	8.914	28,14	14,28	0,142	18,9
2025-08	8.540	26,99	14,21	0,140	18,7
2025-09	8.664	30,17	13,07	0,169	22,5

Tháng	Chuyến/ngày	Giá/chuyến	Dặm/giờ	Phí CBD/chuyến	% chuyến bị tính phí
2025-10	7.390	28,59	12,62	0,159	21,2
2025-11	7.436	26,26	12,76	0,137	18,3
2025-12	9.278	31,99	12,57	0,163	21,7

Nguồn: a02_month_group_detail.csv.

Bảng C.10. Chỉ tiêu theo tháng – taxi vàng, nhóm vùng đón Sân bay

Tháng	Chuyến/ngày	Giá/chuyến	Dặm/giờ	Phí CBD/chuyến	% chuyến bị tính phí
2024-01	6.995	53,29	23,95	0,000	0,0
2024-02	6.838	53,18	22,61	0,000	0,0
2024-03	7.908	54,06	21,53	0,000	0,0
2024-04	8.254	53,71	21,32	0,000	0,0
2024-05	8.731	54,27	19,12	0,000	0,0
2024-06	8.463	54,19	19,36	0,000	0,0
2024-07	8.307	54,12	21,58	0,000	0,0
2024-08	8.299	53,89	21,26	0,000	0,0
2024-09	9.068	55,74	18,86	0,000	0,0
2024-10	9.179	55,27	20,16	0,000	0,0
2024-11	8.087	55,19	19,82	0,000	0,0
2024-12	8.163	55,25	18,43	0,000	0,0
2025-01	6.854	53,14	23,47	0,300	40,0
2025-02	6.765	52,74	22,57	0,348	46,4
2025-03	7.830	53,67	21,32	0,363	48,3
2025-04	7.977	53,86	20,36	0,369	49,2
2025-05	9.126	54,96	18,75	0,370	49,4
2025-06	8.877	54,56	19,41	0,360	48,0
2025-07	8.035	53,66	20,76	0,333	44,3
2025-08	8.078	53,50	20,67	0,318	42,4
2025-09	8.704	55,09	19,03	0,355	47,4
2025-10	8.978	54,92	19,06	0,367	48,9
2025-11	8.120	54,28	19,81	0,355	47,4
2025-12	7.940	54,70	18,60	0,351	46,8

Nguồn: a02_month_group_detail.csv.

PHỤ LỤC D. LUỒNG CHUYỂN THEO GIỜ

Mỗi bảng trình bày một luồng giữa hai nhóm vùng: số chuyển bình quân mỗi ngày, tốc độ và giá cước/chuyển theo giờ đón, trong cửa sổ 05/01 – 31/12 của hai năm.

Bảng D.1. Luồng CRZ → CRZ theo giờ đón (HVFHV)

Giờ	Chuyển/ngày 2024	Chuyển/ngày 2025	Thay đổi %	Dặm/giờ 2024	Dặm/giờ 2025	Giá/chuyển 2024	Giá/chuyển 2025
0	3.710	3.279	-11,6	10,17	10,21	19,23	21,46
1	2.730	2.419	-11,4	10,83	10,76	17,85	19,81
2	1.866	1.657	-11,2	11,38	11,28	16,93	18,81
3	1.189	1.040	-12,5	11,97	11,86	16,34	18,18
4	733	652	-11,2	12,52	12,48	16,85	19,15
5	708	704	-0,6	12,99	12,90	15,26	16,70
6	1.553	1.506	-3,0	12,14	12,02	15,74	17,16
7	2.706	2.681	-0,9	10,37	10,32	17,75	19,34
8	4.308	4.244	-1,5	8,66	8,66	20,19	22,22
9	4.423	4.389	-0,8	8,15	8,11	19,62	21,46
10	4.075	4.005	-1,7	8,08	8,05	20,26	22,16
11	4.297	4.183	-2,6	7,74	7,72	21,33	23,34
12	4.359	4.187	-3,9	7,52	7,57	21,51	23,46
13	4.409	4.242	-3,8	7,48	7,54	21,77	23,70
14	4.394	4.182	-4,8	7,40	7,52	21,94	23,70
15	4.541	4.335	-4,5	7,28	7,42	22,09	23,81
16	4.993	4.835	-3,2	7,20	7,36	22,54	24,12
17	6.149	5.871	-4,5	7,21	7,35	23,37	25,27
18	7.094	6.628	-6,6	7,50	7,62	22,56	24,38
19	7.104	6.564	-7,6	7,99	8,12	20,51	21,91
20	6.676	6.226	-6,7	8,53	8,70	19,83	21,45
21	6.422	5.895	-8,2	8,94	9,04	20,60	22,60
22	6.001	5.382	-10,3	9,13	9,19	21,05	22,97
23	4.983	4.362	-12,5	9,50	9,61	20,10	21,87

Nguồn: a03_flow_hour_detail.csv.

Bảng D.2. Luồng CRZ → Quận ngoài theo giờ đón (HVFHV)

Giờ	Chuyển/ngày 2024	Chuyển/ngày 2025	Thay đổi %	Dặm/giờ 2024	Dặm/giờ 2025	Giá/chuyển 2024	Giá/chuyển 2025
0	2.321	2.209	-4,8	17,24	17,24	34,25	35,55
1	1.801	1.715	-4,8	18,66	18,48	32,09	33,37
2	1.374	1.306	-4,9	19,47	19,30	31,50	32,64
3	974	920	-5,5	20,00	19,89	31,91	32,94
4	638	584	-8,6	20,65	20,51	33,35	35,62
5	323	311	-3,9	21,09	21,07	31,64	33,70
6	328	323	-1,4	20,25	20,24	32,24	33,91
7	460	452	-1,7	18,04	18,04	34,43	36,05
8	526	524	-0,5	16,36	16,33	37,01	38,97
9	589	599	1,7	15,86	15,71	36,01	37,68
10	649	659	1,5	15,13	15,36	37,14	38,70
11	747	744	-0,5	14,83	15,14	37,70	38,96
12	798	800	0,3	14,45	14,76	37,67	38,93
13	834	836	0,3	13,77	14,08	37,75	38,99
14	896	910	1,6	12,68	13,10	38,79	39,72

Giờ	Chuyến/ngày 2024	Chuyến/ngày 2025	Thay đổi %	Dặm/giờ 2024	Dặm/giờ 2025	Giá/chuyến 2024	Giá/chuyến 2025
15	980	1.011	3,2	11,53	12,05	40,19	41,00
16	1.095	1.153	5,3	11,02	11,56	41,27	41,90
17	1.330	1.392	4,7	11,44	11,93	41,28	41,91
18	1.594	1.639	2,8	12,76	13,22	38,49	39,25
19	1.848	1.880	1,8	14,13	14,55	36,01	36,76
20	2.173	2.223	2,3	15,10	15,54	36,01	37,06
21	2.484	2.520	1,5	15,75	16,10	37,00	38,45
22	2.748	2.712	-1,3	15,72	15,96	37,52	38,65
23	2.683	2.566	-4,4	15,91	16,18	36,04	36,92

Nguồn: a03_flow_hour_detail.csv.

Bảng D.3. Luồng Quận ngoài → CRZ theo giờ đón (HVFHV)

Giờ	Chuyến/ngày 2024	Chuyến/ngày 2025	Thay đổi %	Dặm/giờ 2024	Dặm/giờ 2025	Giá/chuyến 2024	Giá/chuyến 2025
0	838	772	-7,9	16,61	16,66	30,57	31,77
1	622	572	-7,9	17,18	17,14	29,48	30,44
2	458	431	-5,8	17,99	18,04	30,50	31,55
3	431	408	-5,2	19,63	19,75	33,12	33,89
4	542	536	-1,1	21,63	21,75	34,37	35,72
5	836	846	1,2	21,23	21,60	33,72	34,86
6	1.279	1.302	1,7	18,15	18,76	34,96	36,01
7	1.352	1.385	2,4	14,81	15,41	38,00	39,88
8	1.582	1.638	3,5	12,93	13,22	38,87	41,43
9	1.477	1.558	5,5	13,18	13,45	37,09	38,73
10	1.247	1.286	3,1	13,43	13,78	36,84	38,02
11	1.151	1.183	2,8	13,28	13,70	37,40	38,46
12	1.071	1.088	1,6	13,12	13,70	37,65	38,89
13	1.003	1.017	1,4	12,94	13,49	38,00	39,09
14	951	967	1,7	12,38	12,95	38,46	39,60
15	911	933	2,4	11,95	12,57	38,98	39,97
16	974	997	2,4	11,57	12,22	39,03	40,14
17	1.172	1.181	0,8	11,59	12,18	38,16	39,34
18	1.300	1.311	0,8	12,34	12,93	35,84	37,09
19	1.251	1.240	-0,9	13,94	14,38	33,85	34,70
20	1.161	1.143	-1,5	15,09	15,43	32,37	33,38
21	1.232	1.189	-3,5	15,65	15,81	32,20	33,60
22	1.338	1.276	-4,7	15,94	16,13	32,63	34,38
23	1.136	1.047	-7,9	16,14	16,40	32,01	33,72

Nguồn: a03_flow_hour_detail.csv.

Bảng D.4. Luồng CRZ → Manhattan phía bắc theo giờ đón (HVFHV)

Giờ	Chuyến/ngày 2024	Chuyến/ngày 2025	Thay đổi %	Dặm/giờ 2024	Dặm/giờ 2025	Giá/chuyến 2024	Giá/chuyến 2025
0	723	588	-18,7	17,51	17,19	29,27	30,89
1	577	465	-19,4	18,62	18,31	28,03	29,58
2	436	347	-20,4	19,29	18,84	27,65	29,01
3	302	237	-21,6	19,85	19,43	27,75	29,01
4	185	141	-23,9	20,70	20,37	28,50	31,00
5	114	97	-15,7	21,08	20,72	25,76	27,39
6	200	172	-14,2	19,29	18,78	25,68	26,47
7	281	252	-10,6	14,19	14,12	29,34	30,74

Giờ	Chuyến/ngày 2024	Chuyến/ngày 2025	Thay đổi %	Dặm/giờ 2024	Dặm/giờ 2025	Giá/chuyến 2024	Giá/chuyến 2025
8	298	268	-10,1	13,57	13,59	31,05	32,91
9	331	306	-7,5	12,85	12,97	30,76	32,39
10	364	333	-8,6	12,31	12,36	31,24	32,99
11	370	339	-8,3	12,13	12,27	32,21	34,03
12	385	352	-8,6	11,74	11,99	32,55	34,30
13	394	360	-8,6	11,42	11,63	33,18	34,80
14	418	382	-8,6	10,72	10,95	33,97	35,46
15	437	404	-7,7	10,25	10,56	34,73	36,17
16	475	442	-6,9	10,21	10,65	34,40	35,61
17	581	535	-7,8	10,66	11,01	34,00	35,38
18	665	597	-10,2	11,86	12,21	32,21	33,84
19	690	618	-10,4	13,48	13,72	29,95	31,39
20	773	694	-10,2	14,48	14,59	29,99	31,88
21	882	771	-12,6	14,96	14,96	31,65	33,92
22	935	787	-15,8	15,23	15,03	32,39	34,23
23	856	695	-18,8	16,00	15,81	30,77	32,21

Nguồn: a03_flow_hour_detail.csv.

Bảng D.5. Luồng Manhattan phía bắc → CRZ theo giờ đón (HVFHV)

Giờ	Chuyến/ngày 2024	Chuyến/ngày 2025	Thay đổi %	Dặm/giờ 2024	Dặm/giờ 2025	Giá/chuyến 2024	Giá/chuyến 2025
0	244	190	-22,1	17,59	17,28	25,46	26,62
1	143	118	-17,6	18,71	18,36	24,88	25,45
2	84	74	-11,8	19,80	19,64	24,65	24,82
3	79	70	-11,5	20,88	20,95	24,73	25,51
4	133	122	-8,1	21,85	21,70	25,89	27,12
5	227	199	-12,4	20,89	21,00	25,49	26,96
6	437	393	-10,1	18,53	18,82	25,76	26,96
7	621	565	-9,0	15,47	15,76	28,69	30,55
8	830	771	-7,2	12,87	13,11	30,93	33,10
9	774	731	-5,5	13,18	13,29	30,14	31,88
10	645	590	-8,4	13,39	13,51	30,12	31,61
11	592	542	-8,4	12,75	12,92	31,40	32,85
12	561	505	-10,1	12,67	12,95	32,01	33,48
13	535	478	-10,5	12,55	12,81	32,10	33,61
14	510	449	-12,0	12,20	12,45	32,36	33,98
15	511	448	-12,5	11,71	11,90	32,83	34,71
16	535	470	-12,1	11,27	11,49	33,16	34,86
17	636	550	-13,5	11,18	11,36	33,61	35,50
18	700	594	-15,2	11,86	12,00	32,81	34,75
19	619	518	-16,3	13,20	13,35	30,73	32,44
20	524	441	-15,7	14,54	14,69	28,79	30,41
21	503	423	-15,9	15,13	15,09	27,90	29,52
22	486	393	-19,1	15,61	15,40	27,45	29,42
23	384	293	-23,7	16,53	16,44	26,78	28,53

Nguồn: a03_flow_hour_detail.csv.

Bảng D.6. Luồng Manhattan phía bắc → Manhattan phía bắc theo giờ đón (HVFHV)

Giờ	Chuyến/ngày 2024	Chuyến/ngày 2025	Thay đổi %	Dặm/giờ 2024	Dặm/giờ 2025	Giá/chuyến 2024	Giá/chuyến 2025
0	748	712	-4,9	13,64	13,39	12,78	12,39

Giờ	Chuyến/ngày 2024	Chuyến/ngày 2025	Thay đổi %	Dặm/giờ 2024	Dặm/giờ 2025	Giá/chuyến 2024	Giá/chuyến 2025
1	513	495	-3,6	13,81	13,56	12,54	12,00
2	347	342	-1,5	14,11	13,87	12,55	11,93
3	246	246	-0,1	14,38	14,18	12,66	12,18
4	224	224	0,1	15,09	15,01	13,50	13,51
5	278	278	-0,0	15,69	15,40	13,71	13,64
6	556	580	4,4	14,32	14,09	14,26	14,32
7	1.125	1.137	1,1	11,26	11,21	15,36	15,82
8	1.435	1.470	2,5	10,57	10,44	14,68	15,03
9	1.279	1.339	4,7	11,11	10,88	13,78	13,83
10	1.146	1.214	5,9	11,02	10,72	13,79	13,64
11	1.089	1.141	4,7	10,78	10,50	14,08	13,85
12	1.131	1.168	3,2	10,68	10,42	14,25	14,07
13	1.151	1.177	2,2	10,50	10,25	14,38	14,20
14	1.257	1.286	2,3	9,95	9,70	14,70	14,50
15	1.327	1.344	1,3	9,60	9,42	14,96	14,84
16	1.337	1.353	1,2	9,67	9,51	14,82	14,55
17	1.458	1.450	-0,6	9,89	9,71	14,86	14,62
18	1.472	1.467	-0,4	10,58	10,38	14,44	14,10
19	1.368	1.366	-0,2	11,39	11,21	13,86	13,46
20	1.226	1.208	-1,5	12,06	11,81	13,53	13,12
21	1.166	1.138	-2,4	12,52	12,29	13,34	12,97
22	1.119	1.056	-5,6	12,94	12,67	13,39	12,96
23	1.004	949	-5,5	13,33	13,08	13,13	12,76

Nguồn: a03_flow_hour_detail.csv.

Bảng D.7. Luồng Quận ngoài → Quận ngoài theo giờ đón (HVFHV)

Giờ	Chuyến/ngày 2024	Chuyến/ngày 2025	Thay đổi %	Dặm/giờ 2024	Dặm/giờ 2025	Giá/chuyến 2024	Giá/chuyến 2025
0	11.034	11.344	2,8	16,28	15,87	17,71	17,55
1	7.617	7.851	3,1	16,95	16,54	17,60	17,38
2	5.428	5.568	2,6	17,48	17,13	17,98	17,80
3	4.172	4.309	3,3	18,07	17,72	18,61	18,47
4	4.107	4.309	4,9	18,63	18,25	18,76	18,77
5	4.852	5.183	6,8	18,36	18,20	17,78	17,72
6	8.365	8.844	5,7	15,97	15,91	18,48	18,47
7	14.121	14.722	4,3	12,82	12,85	18,48	19,11
8	17.040	18.206	6,8	12,37	12,29	17,60	18,05
9	14.813	16.127	8,9	13,18	13,06	17,11	17,32
10	13.307	14.475	8,8	13,23	13,07	17,15	17,25
11	12.800	13.892	8,5	13,02	12,87	17,52	17,50
12	13.140	14.161	7,8	12,67	12,56	17,67	17,64
13	13.873	14.926	7,6	12,31	12,19	17,83	17,80
14	15.567	16.761	7,7	11,42	11,31	18,01	17,97
15	15.980	17.108	7,1	11,05	10,98	18,25	18,22
16	16.370	17.554	7,2	10,95	10,89	18,16	18,04
17	17.931	19.044	6,2	11,09	11,00	18,01	17,92
18	18.000	18.997	5,5	11,98	11,88	17,60	17,56
19	17.071	18.066	5,8	13,00	12,86	17,29	17,13
20	15.803	16.605	5,1	13,94	13,79	17,21	17,03
21	15.123	15.719	3,9	14,71	14,53	17,42	17,26
22	15.205	15.709	3,3	15,25	14,96	17,96	17,85

Giờ	Chuyến/ngày 2024	Chuyến/ngày 2025	Thay đổi %	Dặm/giờ 2024	Dặm/giờ 2025	Giá/chuyến 2024	Giá/chuyến 2025
23	14.212	14.481	1,9	15,70	15,38	18,01	17,92

Nguồn: a03_flow_hour_detail.csv.

Bảng D.8. Luồng CRZ → Sân bay theo giờ đón (HVFHV)

Giờ	Chuyến/ngày 2024	Chuyến/ngày 2025	Thay đổi %	Dặm/giờ 2024	Dặm/giờ 2025	Giá/chuyến 2024	Giá/chuyến 2025
0	10	9	-7,7	26,27	26,35	62,41	61,39
1	11	10	-5,5	29,11	29,36	55,44	57,71
2	38	38	-0,2	30,77	30,74	58,23	60,58
3	238	253	6,6	30,71	30,70	59,68	62,60
4	731	767	4,9	30,62	30,06	62,88	68,19
5	968	991	2,4	28,47	28,04	64,36	69,89
6	916	929	1,4	26,68	26,45	65,81	69,58
7	803	833	3,7	24,42	24,07	66,26	70,27
8	726	784	8,0	23,29	22,77	69,02	73,22
9	689	708	2,8	23,06	22,53	67,17	70,89
10	666	676	1,4	22,22	22,18	68,03	71,67
11	740	782	5,6	21,70	21,60	69,45	73,38
12	848	914	7,7	20,33	20,29	72,98	76,95
13	949	1.011	6,5	19,17	19,28	77,21	81,27
14	1.036	1.062	2,5	17,48	17,57	81,76	86,44
15	996	998	0,2	15,74	15,99	85,52	89,59
16	873	872	-0,1	14,82	15,23	86,95	91,25
17	684	694	1,5	15,71	16,05	86,01	90,79
18	456	475	4,2	18,84	19,23	81,12	84,57
19	272	285	5,1	22,12	22,43	74,79	75,92
20	146	151	3,7	24,02	24,25	73,49	74,19
21	84	89	5,3	24,63	24,84	74,49	75,93
22	53	55	3,9	23,85	23,80	76,27	78,38
23	24	24	-3,3	23,68	23,57	73,17	74,29

Nguồn: a03_flow_hour_detail.csv.

PHỤ LỤC E. HỆ SỐ ĐẦY ĐỦ CỦA CÁC NGHIÊN CỨU SỰ KIỆN

Bảng E.1. Hệ số nghiên cứu sự kiện theo tuần, log số chuyển đón – HVFHV (TWFE, chuẩn hóa theo trung bình kỳ trước)

k (tuần)	Tuần bắt đầu	Hệ số chuẩn hóa $\times 100$	SE $\times 100$	KTC 95%
-52	07/01/2024	1,96	0,99	[-0,00; 3,92]
-51	14/01/2024	12,18	1,26	[9,69; 14,67]
-50	21/01/2024	9,86	1,11	[7,68; 12,05]
-49	28/01/2024	8,40	1,07	[6,28; 10,51]
-48	04/02/2024	8,52	0,97	[6,61; 10,44]
-47	11/02/2024	5,35	1,04	[3,29; 7,41]
-46	18/02/2024	6,93	1,06	[4,85; 9,02]
-45	25/02/2024	1,83	0,96	[-0,06; 3,71]
-44	03/03/2024	3,02	0,91	[1,23; 4,82]
-43	10/03/2024	0,03	0,71	[-1,36; 1,43]
-42	17/03/2024	1,96	0,71	[0,57; 3,36]
-41	24/03/2024	-1,75	0,79	[-3,31; -0,19]
-40	31/03/2024	0,77	0,77	[-0,75; 2,28]
-39	07/04/2024	-1,35	0,68	[-2,69; -0,01]
-38	14/04/2024	0,19	0,70	[-1,18; 1,57]
-37	21/04/2024	7,15	0,86	[5,46; 8,84]
-36	28/04/2024	6,26	0,89	[4,51; 8,01]
-35	05/05/2024	3,72	0,60	[2,54; 4,91]
-34	12/05/2024	5,88	0,73	[4,45; 7,31]
-33	19/05/2024	-4,08	0,76	[-5,58; -2,58]
-32	26/05/2024	-7,03	0,81	[-8,64; -5,43]
-31	02/06/2024	0,69	0,93	[-1,14; 2,51]
-30	09/06/2024	0,19	0,94	[-1,66; 2,04]
-29	16/06/2024	-5,02	0,85	[-6,69; -3,34]
-28	23/06/2024	-2,08	1,03	[-4,11; -0,05]
-27	30/06/2024	-15,93	1,75	[-19,37; -12,49]
-26	07/07/2024	3,30	0,98	[1,37; 5,23]
-25	14/07/2024	2,28	0,87	[0,57; 3,99]
-24	21/07/2024	2,21	0,95	[0,34; 4,09]
-23	28/07/2024	2,31	0,79	[0,75; 3,87]
-22	04/08/2024	3,57	0,81	[1,98; 5,16]
-21	11/08/2024	-7,54	1,03	[-9,58; -5,50]
-20	18/08/2024	-7,37	1,10	[-9,54; -5,20]
-19	25/08/2024	-9,46	1,43	[-12,27; -6,64]
-18	01/09/2024	2,10	1,28	[-0,42; 4,62]
-17	08/09/2024	2,74	1,06	[0,64; 4,83]
-16	15/09/2024	0,31	0,76	[-1,18; 1,80]
-15	22/09/2024	0,51	1,29	[-2,03; 3,04]
-14	29/09/2024	2,33	0,55	[1,24; 3,43]
-13	06/10/2024	1,25	0,63	[0,01; 2,49]
-12	13/10/2024	3,53	0,78	[1,99; 5,07]
-11	20/10/2024	4,79	0,77	[3,28; 6,30]
-10	27/10/2024	0,52	0,77	[-1,00; 2,04]
-9	03/11/2024	2,74	0,60	[1,55; 3,93]
-8	10/11/2024	7,09	0,78	[5,55; 8,62]
-7	17/11/2024	3,49	0,78	[1,95; 5,03]
-6	24/11/2024	-21,38	1,41	[-24,15; -18,61]

k (tuần)	Tuần bắt đầu	Hệ số chuẩn hóa ×100	SE ×100	KTC 95%
-5	01/12/2024	6,09	1,02	[4,08; 8,10]
-4	08/12/2024	8,96	0,97	[7,05; 10,88]
-3	15/12/2024	-4,89	1,01	[-6,87; -2,91]
-2	22/12/2024	-35,17	2,23	[-39,56; -30,77]
0	05/01/2025	-8,93	1,20	[-11,30; -6,56]
1	12/01/2025	-0,81	1,23	[-3,24; 1,62]
2	19/01/2025	0,20	1,10	[-1,97; 2,36]
3	26/01/2025	-1,30	1,04	[-3,35; 0,75]
4	02/02/2025	2,46	1,05	[0,39; 4,53]
5	09/02/2025	-4,43	0,94	[-6,28; -2,58]
6	16/02/2025	-0,03	0,92	[-1,85; 1,78]
7	23/02/2025	-11,77	0,87	[-13,49; -10,04]
8	02/03/2025	-8,72	1,08	[-10,84; -6,59]
9	09/03/2025	-9,10	0,84	[-10,76; -7,44]
10	16/03/2025	-8,39	0,89	[-10,15; -6,63]
11	23/03/2025	-8,33	0,96	[-10,23; -6,43]
12	30/03/2025	-4,59	0,87	[-6,30; -2,88]
13	06/04/2025	-2,55	0,89	[-4,29; -0,80]
14	13/04/2025	-5,23	0,96	[-7,13; -3,34]
15	20/04/2025	-8,81	0,78	[-10,34; -7,28]
16	27/04/2025	-9,39	0,91	[-11,19; -7,59]
17	04/05/2025	-7,10	0,97	[-9,00; -5,20]
18	11/05/2025	-8,56	0,96	[-10,45; -6,67]
19	18/05/2025	-13,94	1,08	[-16,06; -11,82]
20	25/05/2025	-14,81	0,84	[-16,46; -13,15]
21	01/06/2025	-11,27	1,22	[-13,67; -8,86]
22	08/06/2025	-13,04	1,27	[-15,53; -10,54]
23	15/06/2025	-19,04	0,97	[-20,94; -17,13]
24	22/06/2025	-12,23	1,35	[-14,89; -9,56]
25	29/06/2025	-29,53	1,75	[-32,98; -26,08]
26	06/07/2025	-14,36	1,33	[-16,97; -11,74]
27	13/07/2025	-9,92	1,38	[-12,64; -7,20]
28	20/07/2025	-12,04	1,36	[-14,73; -9,35]
29	27/07/2025	-12,12	1,27	[-14,61; -9,62]
30	03/08/2025	-15,76	1,29	[-18,31; -13,22]
31	10/08/2025	-17,61	1,27	[-20,11; -15,11]
32	17/08/2025	-15,26	1,19	[-17,61; -12,91]
33	24/08/2025	-19,39	1,59	[-22,53; -16,25]
34	31/08/2025	-9,27	1,35	[-11,92; -6,61]
35	07/09/2025	0,45	1,52	[-2,53; 3,44]
36	14/09/2025	-2,98	1,33	[-5,61; -0,36]
37	21/09/2025	-5,31	1,49	[-8,26; -2,37]
38	28/09/2025	-8,69	0,91	[-10,48; -6,91]
39	05/10/2025	-3,24	1,31	[-5,82; -0,66]
40	12/10/2025	-1,18	1,13	[-3,41; 1,05]
41	19/10/2025	-6,11	1,05	[-8,18; -4,04]
42	26/10/2025	-5,52	1,02	[-7,52; -3,51]
43	02/11/2025	-1,24	1,08	[-3,37; 0,90]
44	09/11/2025	-1,33	1,13	[-3,55; 0,89]
45	16/11/2025	-6,92	1,03	[-8,95; -4,90]
46	23/11/2025	-34,83	1,29	[-37,38; -32,28]
47	30/11/2025	-6,70	1,24	[-9,15; -4,25]
48	07/12/2025	-1,63	1,38	[-4,35; 1,08]
49	14/12/2025	-15,32	1,21	[-17,71; -12,93]
50	21/12/2025	-50,47	2,46	[-55,32; -45,62]

Nguồn: t31_event_study_weekly_ln_n.csv.

Bảng E.2. Hệ số DDD theo tuần sau chính sách, log số chuyển đón – HVFHV

k (tuần)	Tuần bắt đầu	Hệ số ×100	SE ×100	p
0	05/01/2025	-10,89	0,73	< 0,001
1	12/01/2025	-12,98	1,04	< 0,001
2	19/01/2025	-9,67	0,70	< 0,001
3	26/01/2025	-9,70	0,75	< 0,001
4	02/02/2025	-6,06	0,77	< 0,001
5	09/02/2025	-9,78	0,81	< 0,001
6	16/02/2025	-6,96	0,86	< 0,001
7	23/02/2025	-13,59	0,88	< 0,001
8	02/03/2025	-11,74	0,85	< 0,001
9	09/03/2025	-9,13	0,84	< 0,001
10	16/03/2025	-10,35	0,86	< 0,001
11	23/03/2025	-6,58	1,35	< 0,001
12	30/03/2025	-5,36	0,89	< 0,001
13	06/04/2025	-1,19	0,78	0,130
14	13/04/2025	-5,43	1,10	< 0,001
15	20/04/2025	-15,96	1,02	< 0,001
16	27/04/2025	-15,65	1,00	< 0,001
17	04/05/2025	-10,82	0,88	< 0,001
18	11/05/2025	-14,44	0,89	< 0,001
19	18/05/2025	-9,86	0,92	< 0,001
20	25/05/2025	-7,77	0,87	< 0,001
21	01/06/2025	-11,96	0,80	< 0,001
22	08/06/2025	-13,22	0,95	< 0,001
23	15/06/2025	-14,02	0,88	< 0,001
24	22/06/2025	-10,15	0,99	< 0,001
25	29/06/2025	-13,60	1,14	< 0,001
26	06/07/2025	-17,65	0,76	< 0,001
27	13/07/2025	-12,20	0,85	< 0,001
28	20/07/2025	-14,25	0,88	< 0,001
29	27/07/2025	-14,43	0,95	< 0,001
30	03/08/2025	-19,33	0,97	< 0,001
31	10/08/2025	-10,07	0,83	< 0,001
32	17/08/2025	-7,89	0,92	< 0,001
33	24/08/2025	-9,94	0,78	< 0,001
34	31/08/2025	-11,37	0,87	< 0,001
35	07/09/2025	-2,28	0,85	0,008
36	14/09/2025	-3,29	0,96	< 0,001
37	21/09/2025	-5,82	1,06	< 0,001
38	28/09/2025	-11,03	0,85	< 0,001
39	05/10/2025	-4,49	1,01	< 0,001
40	12/10/2025	-4,71	0,91	< 0,001
41	19/10/2025	-10,90	0,93	< 0,001
42	26/10/2025	-6,04	1,11	< 0,001
43	02/11/2025	-3,98	1,06	< 0,001
44	09/11/2025	-8,42	0,80	< 0,001
45	16/11/2025	-10,41	0,81	< 0,001
46	23/11/2025	-13,45	0,90	< 0,001
47	30/11/2025	-12,79	0,81	< 0,001
48	07/12/2025	-10,60	0,91	< 0,001
49	14/12/2025	-10,43	1,03	< 0,001
50	21/12/2025	-15,30	0,99	< 0,001

Nguồn: *t31_event_study_weekly_ln_n.csv*.

Bảng E.3. Hệ số nghiên cứu sự kiện theo tuần, log số chuyến đón – taxi vàng (TWFE, chuẩn hóa theo trung bình kỳ trước)

k (tuần)	Tuần bắt đầu	Hệ số chuẩn hóa ×100	SE ×100	KTC 95%
-52	07/01/2024	-0,82	5,61	[-12,08; 10,44]
-51	14/01/2024	7,91	6,75	[-5,63; 21,45]
-50	21/01/2024	6,93	6,95	[-7,01; 20,87]
-49	28/01/2024	7,35	7,35	[-7,40; 22,10]
-48	04/02/2024	9,99	5,94	[-1,93; 21,91]
-47	11/02/2024	-3,87	2,68	[-9,25; 1,50]
-46	18/02/2024	11,08	4,30	[2,45; 19,70]
-45	25/02/2024	-8,29	2,55	[-13,41; -3,17]
-44	03/03/2024	-8,90	2,12	[-13,17; -4,64]
-43	10/03/2024	-0,15	1,82	[-3,81; 3,51]
-42	17/03/2024	0,98	2,57	[-4,17; 6,13]
-41	24/03/2024	-1,48	3,39	[-8,27; 5,32]
-40	31/03/2024	-16,09	4,51	[-25,14; -7,04]
-39	07/04/2024	-13,70	3,60	[-20,91; -6,49]
-38	14/04/2024	-10,06	2,21	[-14,50; -5,63]
-37	21/04/2024	-2,66	3,38	[-9,45; 4,12]
-36	28/04/2024	-2,52	2,27	[-7,07; 2,03]
-35	05/05/2024	-10,84	1,79	[-14,44; -7,24]
-34	12/05/2024	-14,81	3,57	[-21,97; -7,64]
-33	19/05/2024	-14,34	2,96	[-20,28; -8,41]
-32	26/05/2024	-16,69	3,54	[-23,78; -9,59]
-31	02/06/2024	-13,02	3,26	[-19,56; -6,49]
-30	09/06/2024	2,53	1,82	[-1,13; 6,19]
-29	16/06/2024	8,04	1,95	[4,14; 11,95]
-28	23/06/2024	12,40	1,52	[9,36; 15,44]
-27	30/06/2024	5,41	4,58	[-3,78; 14,61]
-26	07/07/2024	16,48	2,87	[10,72; 22,23]
-25	14/07/2024	9,54	3,10	[3,32; 15,76]
-24	21/07/2024	15,18	2,67	[9,83; 20,54]
-23	28/07/2024	8,73	2,92	[2,88; 14,58]
-22	04/08/2024	15,23	2,52	[10,17; 20,29]
-21	11/08/2024	13,71	3,02	[7,64; 19,77]
-20	18/08/2024	14,44	2,91	[8,60; 20,27]
-19	25/08/2024	8,23	2,90	[2,40; 14,05]
-18	01/09/2024	6,11	3,06	[-0,04; 12,25]
-17	08/09/2024	-4,27	4,10	[-12,49; 3,96]
-16	15/09/2024	-6,94	4,03	[-15,03; 1,15]
-15	22/09/2024	-0,27	2,43	[-5,15; 4,60]
-14	29/09/2024	5,98	3,14	[-0,32; 12,29]
-13	06/10/2024	-0,37	1,55	[-3,49; 2,74]
-12	13/10/2024	1,96	1,46	[-0,96; 4,88]
-11	20/10/2024	-3,19	1,94	[-7,08; 0,71]
-10	27/10/2024	-9,60	2,72	[-15,06; -4,14]
-9	03/11/2024	-4,28	2,52	[-9,33; 0,77]
-8	10/11/2024	-9,56	3,05	[-15,68; -3,44]
-7	17/11/2024	-11,68	3,30	[-18,29; -5,06]
-6	24/11/2024	-11,85	2,67	[-17,22; -6,49]
-5	01/12/2024	8,40	3,72	[0,95; 15,85]
-4	08/12/2024	5,69	3,24	[-0,81; 12,19]
-3	15/12/2024	-5,12	2,63	[-10,40; 0,17]

k (tuần)	Tuần bắt đầu	Hệ số chuẩn hóa ×100	SE ×100	KTC 95%
-2	22/12/2024	-5,57	3,67	[-12,92; 1,79]
0	05/01/2025	-5,37	3,72	[-12,83; 2,10]
1	12/01/2025	-6,81	3,31	[-13,46; -0,16]
2	19/01/2025	-12,24	4,93	[-22,12; -2,36]
3	26/01/2025	-8,52	4,27	[-17,07; 0,04]
4	02/02/2025	-12,36	5,21	[-22,82; -1,91]
5	09/02/2025	-26,44	8,55	[-43,58; -9,29]
6	16/02/2025	-11,74	6,17	[-24,12; 0,64]
7	23/02/2025	-28,20	8,85	[-45,96; -10,45]
8	02/03/2025	-26,35	8,22	[-42,84; -9,86]
9	09/03/2025	-23,35	8,57	[-40,54; -6,15]
10	16/03/2025	-14,35	9,45	[-33,30; 4,60]
11	23/03/2025	-16,78	8,75	[-34,34; 0,77]
12	30/03/2025	-26,73	8,76	[-44,30; -9,17]
13	06/04/2025	-26,45	7,63	[-41,76; -11,14]
14	13/04/2025	-15,66	8,09	[-31,88; 0,57]
15	20/04/2025	-23,55	8,99	[-41,58; -5,52]
16	27/04/2025	-27,65	10,14	[-47,99; -7,31]
17	04/05/2025	-30,13	11,30	[-52,79; -7,48]
18	11/05/2025	-32,28	12,57	[-57,49; -7,07]
19	18/05/2025	-29,53	9,78	[-49,16; -9,91]
20	25/05/2025	-33,52	12,64	[-58,88; -8,15]
21	01/06/2025	-31,35	12,47	[-56,36; -6,34]
22	08/06/2025	-25,84	11,89	[-49,68; -2,00]
23	15/06/2025	-25,37	13,43	[-52,31; 1,56]
24	22/06/2025	-25,53	14,17	[-53,95; 2,90]
25	29/06/2025	-30,68	14,89	[-60,54; -0,82]
26	06/07/2025	-24,44	13,29	[-51,10; 2,23]
27	13/07/2025	-20,85	13,35	[-47,63; 5,93]
28	20/07/2025	-16,09	13,51	[-43,20; 11,01]
29	27/07/2025	-24,07	13,57	[-51,29; 3,15]
30	03/08/2025	-19,17	12,91	[-45,06; 6,72]
31	10/08/2025	-20,97	13,14	[-47,32; 5,38]
32	17/08/2025	-16,71	12,07	[-40,93; 7,51]
33	24/08/2025	-24,01	13,73	[-51,55; 3,53]
34	31/08/2025	-22,44	13,01	[-48,54; 3,65]
35	07/09/2025	-21,54	12,46	[-46,53; 3,44]
36	14/09/2025	-23,13	11,76	[-46,72; 0,45]
37	21/09/2025	-28,41	12,46	[-53,39; -3,43]
38	28/09/2025	-31,61	11,12	[-53,92; -9,30]
39	05/10/2025	-23,91	11,59	[-47,17; -0,65]
40	12/10/2025	-23,15	10,98	[-45,16; -1,13]
41	19/10/2025	-21,45	9,09	[-39,68; -3,21]
42	26/10/2025	-29,13	10,17	[-49,53; -8,74]
43	02/11/2025	-26,42	10,00	[-46,47; -6,36]
44	09/11/2025	-23,44	8,39	[-40,26; -6,61]
45	16/11/2025	-33,48	11,94	[-57,42; -9,54]
46	23/11/2025	-42,54	11,32	[-65,24; -19,84]
47	30/11/2025	-36,48	11,85	[-60,24; -12,72]
48	07/12/2025	-36,50	13,39	[-63,37; -9,64]
49	14/12/2025	-45,82	14,12	[-74,15; -17,49]
50	21/12/2025	-60,18	16,42	[-93,11; -27,24]

Nguồn: t31_event_study_weekly_ln_n.csv.

Bảng E.4. Hệ số DDD theo tuần sau chính sách, log số chuyển đón – taxi vàng

k (tuần)	Tuần bắt đầu	Hệ số ×100	SE ×100	p
0	05/01/2025	-4,55	4,20	0,284
1	12/01/2025	-14,72	8,06	0,073
2	19/01/2025	-19,17	10,56	0,075
3	26/01/2025	-15,86	9,61	0,105
4	02/02/2025	-22,35	9,87	0,028
5	09/02/2025	-22,56	10,07	0,029
6	16/02/2025	-22,81	9,85	0,024
7	23/02/2025	-19,91	9,50	0,041
8	02/03/2025	-17,45	8,29	0,040
9	09/03/2025	-23,20	8,15	0,006
10	16/03/2025	-15,33	7,82	0,055
11	23/03/2025	-15,31	5,81	0,011
12	30/03/2025	-10,64	4,83	0,032
13	06/04/2025	-12,75	4,52	0,007
14	13/04/2025	-5,59	7,98	0,486
15	20/04/2025	-20,88	11,65	0,079
16	27/04/2025	-25,13	11,73	0,037
17	04/05/2025	-19,29	9,85	0,055
18	11/05/2025	-17,48	9,68	0,077
19	18/05/2025	-15,19	7,61	0,051
20	25/05/2025	-16,83	10,54	0,116
21	01/06/2025	-18,32	9,71	0,065
22	08/06/2025	-28,36	11,94	0,021
23	15/06/2025	-33,41	12,96	0,013
24	22/06/2025	-37,93	13,76	0,008
25	29/06/2025	-36,09	13,02	0,008
26	06/07/2025	-40,91	14,85	0,008
27	13/07/2025	-30,40	11,02	0,008
28	20/07/2025	-31,28	12,21	0,013
29	27/07/2025	-32,80	11,80	0,007
30	03/08/2025	-34,40	12,89	0,010
31	10/08/2025	-34,68	13,48	0,013
32	17/08/2025	-31,15	12,68	0,017
33	24/08/2025	-32,24	12,95	0,016
34	31/08/2025	-28,55	11,63	0,017
35	07/09/2025	-17,28	8,83	0,056
36	14/09/2025	-16,20	7,97	0,047
37	21/09/2025	-28,14	12,65	0,030
38	28/09/2025	-37,59	13,93	0,009
39	05/10/2025	-23,53	12,26	0,060
40	12/10/2025	-25,11	10,33	0,018
41	19/10/2025	-18,26	7,84	0,024
42	26/10/2025	-19,53	7,86	0,016
43	02/11/2025	-22,14	11,11	0,052
44	09/11/2025	-13,88	5,97	0,024
45	16/11/2025	-21,80	9,57	0,027
46	23/11/2025	-30,69	10,81	0,006
47	30/11/2025	-44,88	15,04	0,004
48	07/12/2025	-42,19	15,54	0,009
49	14/12/2025	-40,70	15,51	0,011
50	21/12/2025	-54,61	15,52	< 0,001

Nguồn: *t31_event_study_weekly_ln_n.csv*.

Bảng E.5. Hệ số nghiên cứu sự kiện theo tháng cho sáu chỉ tiêu (HVFHV; hệ số chuẩn hóa, sai số chuẩn trong ngoặc)

k (tháng)	Giá cược/dặm	TN tài xế/dặm	Chi phí hành khách/chuyến	Tốc độ	Thời gian chờ	Dặm/chuyến
-12	-0,173 (0,021)	-0,093 (0,011)	-2,240 (0,146)	-0,049 (0,043)	-0,235 (0,024)	-0,154 (0,014)
-11	-0,207 (0,020)	-0,103 (0,010)	-1,945 (0,128)	-0,156 (0,034)	-0,057 (0,022)	-0,124 (0,012)
-10	-0,165 (0,009)	-0,087 (0,006)	-0,885 (0,069)	0,169 (0,021)	0,204 (0,017)	0,020 (0,007)
-9	-0,145 (0,009)	-0,062 (0,006)	-0,806 (0,055)	-0,132 (0,025)	0,046 (0,016)	-0,016 (0,009)
-8	-0,093 (0,010)	-0,045 (0,007)	0,387 (0,061)	0,384 (0,033)	0,061 (0,016)	0,118 (0,009)
-7	-0,104 (0,012)	-0,080 (0,008)	-0,146 (0,077)	0,168 (0,027)	-0,006 (0,021)	0,035 (0,013)
-6	-0,063 (0,018)	-0,037 (0,010)	-1,326 (0,079)	-0,386 (0,028)	-0,032 (0,017)	-0,156 (0,015)
-5	-0,216 (0,017)	-0,158 (0,011)	-1,318 (0,101)	0,054 (0,031)	-0,234 (0,023)	-0,056 (0,013)
-4	0,092 (0,013)	0,083 (0,009)	0,816 (0,098)	-0,034 (0,031)	0,239 (0,021)	0,039 (0,013)
-3	0,232 (0,020)	0,119 (0,010)	1,728 (0,121)	-0,120 (0,024)	0,161 (0,013)	0,072 (0,016)
-2	0,256 (0,018)	0,091 (0,009)	1,965 (0,090)	0,199 (0,024)	-0,195 (0,017)	0,101 (0,009)
0	0,057 (0,013)	-0,178 (0,010)	0,881 (0,092)	0,677 (0,051)	-0,361 (0,027)	-0,040 (0,015)
1	0,020 (0,027)	-0,110 (0,012)	1,314 (0,123)	0,583 (0,042)	-0,224 (0,024)	0,024 (0,014)
2	0,049 (0,018)	-0,122 (0,008)	2,761 (0,101)	0,826 (0,033)	-0,318 (0,021)	0,191 (0,013)
3	0,108 (0,014)	-0,086 (0,007)	2,231 (0,093)	0,406 (0,025)	-0,342 (0,023)	0,080 (0,011)
4	0,495 (0,036)	0,094 (0,014)	5,317 (0,162)	0,530 (0,041)	-0,099 (0,025)	0,228 (0,015)
5	0,385 (0,029)	0,021 (0,012)	4,493 (0,129)	0,532 (0,043)	-0,387 (0,031)	0,174 (0,016)
6	0,384 (0,030)	0,045 (0,014)	3,085 (0,100)	0,130 (0,039)	-0,518 (0,026)	-0,005 (0,017)
7	-0,028 (0,022)	-0,060 (0,010)	2,012 (0,141)	0,477 (0,032)	-0,630 (0,032)	0,108 (0,016)
8	0,357 (0,036)	0,214 (0,017)	4,545 (0,214)	0,101 (0,027)	-0,087 (0,029)	0,195 (0,014)
9	0,456 (0,038)	0,225 (0,018)	4,695 (0,212)	0,091 (0,034)	-0,322 (0,024)	0,169 (0,013)
10	0,552 (0,051)	0,214 (0,021)	5,476 (0,265)	0,107 (0,036)	-0,500 (0,024)	0,232 (0,014)
11	0,975 (0,080)	0,406 (0,038)	9,239 (0,401)	0,368 (0,063)	-0,582 (0,049)	0,454 (0,027)

Nguồn: *t32_event_study_monthly_hvfhv.csv*.

Bảng E.6. Hệ số DiD riêng của từng vùng CRZ (sai số chuẩn trong ngoặc)

Mã	Vùng	log số chuyển	% thay đổi	Tốc độ	Thời gian chờ	Chuyển/ ngày 2024	Độ sâu (km)
4	Alphabet City	-0,1588 (0,0030)	-14,69	0,479 (0,012)	-0,348 (0,013)	2.009	0,39
13	Battery Park City	-0,0650 (0,0030)	-6,29	0,434 (0,012)	-0,317 (0,013)	2.773	0,05
45	Chinatown	-0,0688 (0,0030)	-6,65	0,311 (0,012)	-0,387 (0,013)	1.612	0,42
48	Clinton East	-0,1004 (0,0030)	-9,55	0,407 (0,012)	-0,439 (0,013)	6.000	0,80
50	Clinton West	-0,1311 (0,0030)	-12,29	0,400 (0,012)	-0,352 (0,013)	3.590	0,19
68	East Chelsea	-0,1198 (0,0030)	-11,29	0,425 (0,012)	-0,399 (0,013)	6.847	0,76
79	East Village	-0,1490 (0,0030)	-13,85	0,472 (0,012)	-0,398 (0,013)	8.354	1,13
87	Financial District North	-0,0565 (0,0030)	-5,49	0,295 (0,012)	-0,252 (0,013)	3.871	0,32
88	Financial District South	-0,0655 (0,0030)	-6,34	0,480 (0,012)	-0,278 (0,013)	1.599	0,21
90	Flatiron	-0,1021 (0,0030)	-9,70	0,376 (0,012)	-0,348 (0,013)	4.266	1,02
100	Garment District	-0,1125 (0,0030)	-10,64	0,456 (0,012)	-0,404 (0,013)	3.366	1,43
107	Gramercy	-0,1404 (0,0030)	-13,10	0,370 (0,012)	-0,333 (0,013)	4.984	0,81
113	Greenwich Village North	-0,1290 (0,0030)	-12,10	0,463 (0,012)	-0,394 (0,013)	3.882	1,39
114	Greenwich Village South	-0,1385 (0,0030)	-12,94	0,516 (0,012)	-0,471 (0,013)	4.012	1,15
125	Hudson Sq	-0,0438 (0,0030)	-4,29	0,482 (0,012)	-0,394 (0,013)	2.203	0,34
137	Kips Bay	-0,1249 (0,0030)	-11,74	0,511 (0,012)	-0,366 (0,013)	3.502	0,34
144	Little Italy/NoLiTa	-0,1182 (0,0030)	-11,15	0,534 (0,012)	-0,420 (0,013)	4.584	1,28
148	Lower East Side	-0,0929 (0,0030)	-8,87	0,503 (0,012)	-0,487 (0,013)	6.567	1,01
158	Meatpacking/West Village West	-0,1062 (0,0030)	-10,07	0,354 (0,012)	-0,408 (0,013)	3.755	0,15
161	Midtown Center	-0,0452 (0,0030)	-4,42	0,196 (0,012)	-0,516 (0,013)	7.058	0,78
162	Midtown East	-0,0454 (0,0030)	-4,43	0,364 (0,012)	-0,449 (0,013)	4.830	0,64
163	Midtown North	-0,0581 (0,0030)	-5,64	0,162 (0,012)	-0,455 (0,013)	5.059	0,17

Mã	Vùng	log số chuyển	% thay đổi	Tốc độ	Thời gian chờ	Chuyển/ ngày 2024	Độ sâu (km)
164	Midtown South	-0,0977 (0,0030)	-9,31	0,456 (0,012)	-0,349 (0,013)	6.442	1,28
170	Murray Hill	-0,0918 (0,0030)	-8,77	0,477 (0,012)	-0,380 (0,013)	5.662	0,73
186	Penn Station/Madison Sq West	-0,0833 (0,0030)	-7,99	0,418 (0,012)	-0,413 (0,013)	3.837	1,41
209	Seaport	-0,1130 (0,0030)	-10,69	0,298 (0,012)	-0,143 (0,013)	1.456	0,32
211	SoHo	-0,0860 (0,0030)	-8,24	0,425 (0,012)	-0,451 (0,013)	3.595	0,84
224	Stuy Town/Peter Cooper Village	-0,1562 (0,0030)	-14,46	0,560 (0,012)	-0,263 (0,013)	1.419	0,25
229	Sutton Place/Turtle Bay North	-0,1126 (0,0030)	-10,65	0,221 (0,012)	-0,396 (0,013)	3.724	0,34
230	Times Sq/Theatre District	-0,0708 (0,0030)	-6,83	0,262 (0,012)	-0,501 (0,013)	7.312	0,85
231	TriBeCa/Civic Center	-0,0748 (0,0030)	-7,21	0,337 (0,012)	-0,399 (0,013)	7.059	0,40
232	Two Bridges/Seward Park	-0,1183 (0,0030)	-11,16	0,502 (0,012)	-0,350 (0,013)	2.877	0,52
233	UN/Turtle Bay South	-0,1069 (0,0030)	-10,14	0,541 (0,012)	-0,319 (0,013)	3.565	0,29
234	Union Sq	-0,0477 (0,0030)	-4,65	0,334 (0,012)	-0,358 (0,013)	6.480	1,42
246	West Chelsea/Hudson Yards	-0,0797 (0,0030)	-7,66	0,429 (0,012)	-0,348 (0,013)	6.606	0,31
249	West Village	-0,1293 (0,0030)	-12,13	0,346 (0,012)	-0,454 (0,013)	5.824	0,66
261	World Trade Center	-0,0581 (0,0030)	-5,65	0,411 (0,012)	-0,200 (0,013)	2.301	0,45

Nguồn: t54_zone_specific_effects.csv.

Bảng E.7. Hệ số nghiên cứu sự kiện theo tháng trên panel cặp OD (log số chuyển)

k (tháng)	Hệ số ×100	SE ×100	KTC 95%
-12	3,62	0,58	[2,48; 4,77]
-11	4,36	0,55	[3,28; 5,45]
-10	-0,40	0,44	[-1,27; 0,47]
-9	2,18	0,44	[1,31; 3,05]
-8	0,72	0,36	[0,01; 1,42]
-7	-0,35	0,52	[-1,37; 0,67]
-6	-0,36	0,67	[-1,67; 0,95]
-5	-3,62	0,61	[-4,82; -2,41]
-4	1,90	0,57	[0,78; 3,03]
-3	2,22	0,43	[1,37; 3,08]
-2	-1,88	0,35	[-2,58; -1,19]
0	-6,52	0,56	[-7,63; -5,42]
1	-4,10	0,59	[-5,26; -2,94]
2	-9,26	0,64	[-10,52; -8,00]
3	-5,12	0,59	[-6,28; -3,95]
4	-10,86	0,60	[-12,04; -9,68]
5	-14,31	0,80	[-15,88; -12,73]
6	-14,54	1,05	[-16,61; -12,47]
7	-17,36	0,88	[-19,08; -15,63]
8	-4,15	0,88	[-5,90; -2,41]
9	-5,94	0,81	[-7,54; -4,34]
10	-11,60	0,69	[-12,96; -10,24]
11	-22,27	0,96	[-24,16; -20,38]

Nguồn: t37_event_od_ln_n.csv.

PHỤ LỤC F. KIỂM SOÁT TỔNG HỢP, HOÁN VỊ VÀ CHẤT LƯỢNG DỮ LIỆU

F.1. Kết quả giả được không gian của kiểm soát tổng hợp

Bảng F.1. Kết quả SCM cho 60 vùng giả được, sắp theo tỷ số RMSPE

Mã	Vùng	Quận	RMSPE trước	RMSPE sau	Tỷ số	Khoảng cách TB sau
130	Jamaica	Queens	0,0086	0,0504	5,83	0,0360
168	Mott Haven/Port Morris	Bronx	0,0092	0,0492	5,36	0,0407
76	East New York	Brooklyn	0,0072	0,0343	4,74	0,0188
74	East Harlem North	Manhattan	0,0120	0,0487	4,05	-0,0387
71	East Flatbush/Farragut	Brooklyn	0,0096	0,0364	3,80	-0,0303
216	South Ozone Park	Queens	0,0130	0,0461	3,56	-0,0088
75	East Harlem South	Manhattan	0,0171	0,0543	3,17	-0,0452
89	Flatbush/Ditmas Park	Brooklyn	0,0123	0,0386	3,15	-0,0245
18	Bedford Park	Bronx	0,0069	0,0218	3,15	0,0128
243	Washington Heights North	Manhattan	0,0097	0,0295	3,03	-0,0164
129	Jackson Heights	Queens	0,0107	0,0314	2,95	-0,0288
42	Central Harlem North	Manhattan	0,0101	0,0292	2,90	-0,0236
260	Woodside	Queens	0,0097	0,0276	2,85	-0,0215
35	Brownsville	Brooklyn	0,0173	0,0479	2,77	-0,0368
239	Upper West Side South	Manhattan	0,0222	0,0609	2,74	-0,0551
188	Prospect-Lefferts Gardens	Brooklyn	0,0064	0,0173	2,72	0,0050
69	East Concourse/Concourse Village	Bronx	0,0099	0,0266	2,69	0,0210
91	Flatlands	Brooklyn	0,0071	0,0191	2,69	-0,0154
65	Downtown Brooklyn/MetroTech	Brooklyn	0,0221	0,0588	2,66	-0,0481
7	Astoria	Queens	0,0155	0,0385	2,48	-0,0344
254	Williamsbridge/Olinville	Bronx	0,0069	0,0165	2,40	0,0118
213	Soundview/Castle Hill	Bronx	0,0068	0,0162	2,39	0,0058
17	Bedford	Brooklyn	0,0137	0,0324	2,37	-0,0204
33	Brooklyn Heights	Brooklyn	0,0192	0,0451	2,35	-0,0280
225	Stuyvesant Heights	Brooklyn	0,0102	0,0238	2,34	-0,0142
145	Long Island City/Hunters Point	Queens	0,0173	0,0404	2,34	0,0234
181	Park Slope	Brooklyn	0,0130	0,0294	2,26	-0,0115
39	Canarsie	Brooklyn	0,0072	0,0161	2,23	0,0077
78	East Tremont	Bronx	0,0079	0,0171	2,16	0,0027
37	Bushwick South	Brooklyn	0,0178	0,0385	2,16	0,0285
169	Mount Hope	Bronx	0,0096	0,0207	2,15	-0,0095
61	Crown Heights North	Brooklyn	0,0090	0,0185	2,06	-0,0109
198	Ridgewood	Queens	0,0146	0,0292	2,00	0,0184
36	Bushwick North	Brooklyn	0,0173	0,0346	2,00	-0,0211
112	Greenpoint	Brooklyn	0,0335	0,0663	1,98	0,0561
228	Sunset Park West	Brooklyn	0,0341	0,0671	1,97	0,0267
92	Flushing	Queens	0,0220	0,0428	1,95	0,0200
25	Boerum Hill	Brooklyn	0,0135	0,0253	1,87	0,0107
14	Bay Ridge	Brooklyn	0,0140	0,0258	1,84	-0,0096
177	Ocean Hill	Brooklyn	0,0142	0,0255	1,80	-0,0075
244	Washington Heights South	Manhattan	0,0097	0,0174	1,79	-0,0079
97	Fort Greene	Brooklyn	0,0181	0,0319	1,76	0,0170
41	Central Harlem	Manhattan	0,0125	0,0219	1,75	-0,0123
95	Forest Hills	Queens	0,0260	0,0454	1,74	-0,0004

Mã	Vùng	Quận	RMSPE trước	RMSPE sau	Tỷ số	Khoảng cách TB sau
223	Steinway	Queens	0,0117	0,0202	1,72	0,0127
197	Richmond Hill	Queens	0,0093	0,0160	1,72	-0,0095
247	West Concourse	Bronx	0,0234	0,0402	1,72	0,0285
226	Sunnyside	Queens	0,0227	0,0382	1,68	0,0204
80	East Williamsburg	Brooklyn	0,0414	0,0643	1,55	-0,0486
72	East Flatbush/Remsen Village	Brooklyn	0,0117	0,0181	1,55	-0,0120
238	Upper West Side North	Manhattan	0,0164	0,0254	1,55	-0,0143
82	Elmhurst	Queens	0,0169	0,0244	1,44	-0,0087
116	Hamilton Heights	Manhattan	0,0199	0,0252	1,27	-0,0140
159	Melrose South	Bronx	0,0174	0,0214	1,23	-0,0056
256	Williamsburg (South Side)	Brooklyn	0,0145	0,0177	1,22	-0,0030
49	Clinton Hill	Brooklyn	0,0207	0,0250	1,21	-0,0099
255	Williamsburg (North Side)	Brooklyn	0,0295	0,0355	1,20	-0,0254
263	Yorkville West	Manhattan	0,0182	0,0200	1,10	-0,0041
26	Borough Park	Brooklyn	0,0437	0,0469	1,07	-0,0105
236	Upper East Side North	Manhattan	0,0500	0,0526	1,05	0,0135

Nguồn: *t40_scm_placebo.csv*.

Bảng F.2. Chuỗi chỉ số tuần của CRZ thực tế và CRZ tổng hợp

Tuần	CRZ thực tế	CRZ tổng hợp	Khoảng cách ×100
07/01/2024	0,9470	0,9441	0,29
14/01/2024	1,1307	1,0977	3,30
21/01/2024	1,0606	1,0321	2,85
28/01/2024	1,0618	1,0438	1,79
04/02/2024	1,0531	1,0133	3,98
11/02/2024	1,0775	1,0578	1,96
18/02/2024	1,0393	1,0052	3,40
25/02/2024	1,0706	1,0747	-0,41
03/03/2024	1,0973	1,0881	0,92
10/03/2024	1,0099	0,9873	2,25
17/03/2024	1,0429	1,0177	2,53
24/03/2024	0,9971	0,9877	0,94
31/03/2024	1,0648	1,0720	-0,73
07/04/2024	0,9996	1,0065	-0,69
14/04/2024	1,0322	1,0449	-1,28
21/04/2024	0,9906	1,0021	-1,15
28/04/2024	1,0454	1,0532	-0,78
05/05/2024	1,0597	1,0970	-3,73
12/05/2024	1,1026	1,0977	0,49
19/05/2024	0,9653	0,9789	-1,35
26/05/2024	0,9232	0,9677	-4,45
02/06/2024	1,0332	1,0376	-0,43
09/06/2024	1,0223	1,0173	0,49
16/06/2024	0,9775	0,9832	-0,57
23/06/2024	1,0057	0,9901	1,56
30/06/2024	0,7965	0,8415	-4,50
07/07/2024	0,9840	0,9347	4,92
14/07/2024	1,0236	1,0031	2,05
21/07/2024	0,9746	0,9389	3,56
28/07/2024	0,9956	0,9691	2,65
04/08/2024	0,9999	0,9721	2,78
11/08/2024	0,8623	0,8607	0,16
18/08/2024	0,8491	0,8625	-1,35

Tuần	CRZ thực tế	CRZ tổng hợp	Khoảng cách ×100
25/08/2024	0,8581	0,8803	-2,22
01/09/2024	0,9761	0,9327	4,34
08/09/2024	1,0058	0,9709	3,48
15/09/2024	0,9825	0,9886	-0,61
22/09/2024	0,9966	1,0266	-2,99
29/09/2024	0,9676	1,0014	-3,38
06/10/2024	0,9857	1,0061	-2,04
13/10/2024	1,0180	1,0266	-0,86
20/10/2024	1,0387	1,0353	0,34
27/10/2024	1,0438	1,0609	-1,70
03/11/2024	0,9936	0,9894	0,43
10/11/2024	1,0670	1,0460	2,10
17/11/2024	1,0896	1,1041	-1,45
24/11/2024	0,8304	0,8859	-5,56
01/12/2024	1,1151	1,0920	2,31
08/12/2024	1,1999	1,2018	-0,19
15/12/2024	1,0584	1,1202	-6,18
22/12/2024	0,6937	0,7155	-2,18
29/12/2024	0,7841	0,8351	-5,10
05/01/2025	0,9353	1,0020	-6,67
12/01/2025	1,0162	1,0096	0,66
19/01/2025	1,0457	1,1025	-5,68
26/01/2025	1,0116	1,0654	-5,38
02/02/2025	1,0675	1,0661	0,14
09/02/2025	1,0532	1,0990	-4,58
16/02/2025	1,0541	1,0984	-4,43
23/02/2025	0,9486	1,0072	-5,85
02/03/2025	0,9906	1,0452	-5,45
09/03/2025	0,9510	0,9856	-3,46
16/03/2025	0,9421	0,9329	0,92
23/03/2025	0,9352	0,9539	-1,87
30/03/2025	0,9722	1,0193	-4,71
06/04/2025	1,0395	1,0901	-5,06
13/04/2025	0,9244	0,9686	-4,42
20/04/2025	0,9412	1,0113	-7,00
27/04/2025	0,9588	1,0526	-9,38
04/05/2025	1,0055	1,0912	-8,57
11/05/2025	0,9977	1,0910	-9,32
18/05/2025	0,9273	1,0606	-13,33
25/05/2025	0,8882	0,9882	-10,00
01/06/2025	0,9240	1,0004	-7,64
08/06/2025	0,9387	1,0438	-10,50
15/06/2025	0,8842	0,9905	-10,63
22/06/2025	0,9720	1,0006	-2,86
29/06/2025	0,7578	0,8434	-8,56
06/07/2025	0,8682	0,8972	-2,90
13/07/2025	0,9497	0,9521	-0,24
20/07/2025	0,9110	0,9344	-2,34
27/07/2025	0,9286	0,9831	-5,45
03/08/2025	0,8504	0,8971	-4,67
10/08/2025	0,8446	0,9012	-5,65
17/08/2025	0,8164	0,8630	-4,66
24/08/2025	0,8030	0,8689	-6,60
31/08/2025	0,9112	0,9807	-6,95
07/09/2025	1,0228	1,0063	1,65

Tuần	CRZ thực tế	CRZ tổng hợp	Khoảng cách ×100
14/09/2025	1,0116	1,0521	-4,05
21/09/2025	0,9386	1,0464	-10,78
28/09/2025	0,9281	1,0333	-10,52
05/10/2025	1,0123	1,0872	-7,49
12/10/2025	1,0407	1,1220	-8,12
19/10/2025	1,0079	1,1143	-10,64
26/10/2025	1,0807	1,1849	-10,42
02/11/2025	1,0427	1,0867	-4,40
09/11/2025	1,0687	1,1517	-8,30
16/11/2025	1,0457	1,1290	-8,33
23/11/2025	0,7721	0,9211	-14,91
30/11/2025	1,0638	1,1647	-10,09
07/12/2025	1,1774	1,2874	-11,00
14/12/2025	1,0523	1,2512	-19,89
21/12/2025	0,6424	0,7587	-11,63

Nguồn: t39_scm_series.csv.

F.2. Phân phối hoán vị

Bảng F.3. Các phân vị của phân phối hoán vị (500 lần)

Phân vị	Hệ số ×100
1,0%	-1,787
2,5%	-1,491
5,0%	-1,257
25,0%	-0,449
50,0%	0,048
75,0%	0,537
95,0%	1,221
97,5%	1,503
99,0%	1,816

Nguồn: t50_permutation.csv.

F.3. Chất lượng dữ liệu theo tháng

Bảng F.4. Kết quả kiểm soát chất lượng theo tháng – HVFHV

Tháng	Bản ghi thô	Vùng lỗi	Dậm lỗi	Thời lượng lỗi	Giá lỗi	Tốc độ lỗi	Tỷ lệ loại %	Silver
2024-01	19.663.930	741.680	4.946	1.943	7.355	27	3,83	18.910.349
2024-02	19.359.148	754.016	4.366	1.809	8.595	29	3,96	18.592.234
2024-03	21.280.788	833.493	4.358	1.613	1.190	22	3,94	20.441.826
2024-04	19.733.038	806.036	3.950	1.629	781	26	4,11	18.922.395
2024-05	20.704.538	873.271	4.241	1.662	414	21	4,24	19.827.114
2024-06	20.123.226	864.872	4.830	1.598	380	16	4,32	19.254.178
2024-07	19.182.934	808.370	4.927	1.658	651	20	4,24	18.370.233
2024-08	19.128.392	810.656	5.300	1.565	445	35	4,26	18.313.557
2024-09	19.209.788	848.027	4.523	1.455	1.678	23	4,44	18.356.014
2024-10	20.028.282	897.433	4.526	1.427	17.236	9	4,58	19.110.153
2024-11	19.987.533	850.335	4.355	1.428	2.374	2	4,29	19.130.848
2024-12	21.068.851	929.174	4.886	1.756	33.908	8	4,59	20.102.342
2025-01	20.405.666	815.783	4.086	1.514	17.214	5	4,10	19.569.642
2025-02	19.339.461	804.916	3.748	1.431	1.720	7	4,19	18.529.144
2025-03	20.536.879	908.216	3.716	1.673	64.226	16	4,74	19.564.232
2025-04	19.753.983	876.720	3.764	1.717	14.241	9	4,52	18.860.817

Tháng	Bản ghi thô	Vùng lỗi	Dậm lỗi	Thời lượng lỗi	Giá lỗi	Tốc độ lỗi	Tỷ lệ loại %	Silver
2025-05	21.091.193	974.167	4.585	2.500	486	12	4,64	20.111.990
2025-06	19.868.009	930.945	4.716	2.197	12.918	10	4,77	18.920.843
2025-07	19.653.012	928.527	4.762	1.937	12.627	13	4,80	18.708.970
2025-08	19.271.461	921.860	4.810	1.707	186.236	13	5,72	18.168.810
2025-09	19.434.641	950.220	4.070	1.816	3.013	10	4,92	18.478.071
2025-10	21.308.701	990.687	4.222	1.865	32.974	11	4,81	20.284.044
2025-11	20.818.240	966.851	3.925	1.695	4.496	19	4,68	19.843.783
2025-12	22.108.438	1.005.799	4.121	1.931	35.260	11	4,71	21.066.469

Nguồn: t06_quality_by_month.csv.

Bảng F.5. Kết quả kiểm soát chất lượng theo tháng – taxi vàng

Tháng	Bản ghi thô	Vùng lỗi	Dậm lỗi	Thời lượng lỗi	Giá lỗi	Tốc độ lỗi	Tỷ lệ loại %	Silver
2024-01	2.964.624	31.527	60.430	36.999	38.348	1.107	4,49	2.831.392
2024-02	3.007.526	28.974	68.296	35.546	41.500	953	4,71	2.865.861
2024-03	3.582.628	35.374	87.290	42.690	59.756	1.241	5,19	3.396.863
2024-04	3.514.289	35.759	45.963	42.330	58.877	1.141	4,08	3.370.762
2024-05	3.723.833	38.725	49.945	45.583	62.568	1.158	4,15	3.569.455
2024-06	3.539.193	38.513	53.123	44.400	63.046	1.115	4,45	3.381.865
2024-07	3.076.903	36.087	48.204	43.265	59.737	1.091	4,76	2.930.477
2024-08	2.979.183	34.435	57.569	43.938	59.390	1.047	5,16	2.825.522
2024-09	3.633.030	35.378	81.288	47.019	74.778	1.199	5,32	3.439.773
2024-10	3.833.771	42.609	81.768	47.668	76.878	1.107	5,31	3.630.327
2024-11	3.646.369	32.984	68.463	45.998	72.939	1.023	4,91	3.467.427
2024-12	3.668.371	35.295	75.579	49.508	80.503	1.063	5,30	3.473.804
2025-01	3.475.226	28.357	91.055	41.389	145.519	982	7,45	3.216.376
2025-02	3.577.543	25.008	99.943	41.452	184.102	841	8,49	3.273.795
2025-03	4.145.257	28.415	103.936	66.969	210.383	1.050	8,59	3.789.373
2025-04	3.970.553	29.100	91.745	80.342	188.174	1.095	8,48	3.633.932
2025-05	4.591.845	34.771	141.491	115.402	327.378	1.268	11,84	4.048.068
2025-06	4.322.960	33.016	135.160	117.933	277.533	1.522	11,47	3.827.160
2025-07	3.898.963	31.914	124.048	103.343	248.464	1.043	11,38	3.455.160
2025-08	3.574.091	32.089	105.429	96.125	262.641	1.070	12,12	3.140.994
2025-09	4.251.015	32.074	124.697	109.349	254.427	1.216	10,70	3.796.245
2025-10	4.428.699	33.545	125.828	120.072	323.385	1.292	11,94	3.900.104
2025-11	4.181.444	31.090	109.643	108.529	397.563	1.171	13,83	3.603.168
2025-12	4.305.006	32.278	152.853	107.109	50.720	1.150	6,95	4.005.824

Nguồn: t06_quality_by_month.csv.

F.4. Danh mục tập Bronze

Bảng F.6. Danh mục 48 tập chuyển đi ở lớp Bronze

Tập	MB	Số dòng	Row group	Số cột	Lược đồ
fhhvh_tripdata_2024-01.parquet	450,9	19.663.930	19	24	fa01fc19a9
fhhvh_tripdata_2024-02.parquet	441,1	19.359.148	19	24	fa01fc19a9
fhhvh_tripdata_2024-03.parquet	484,4	21.280.788	21	24	fa01fc19a9
fhhvh_tripdata_2024-04.parquet	454,1	19.733.038	19	24	fa01fc19a9
fhhvh_tripdata_2024-05.parquet	475,5	20.704.538	20	24	fa01fc19a9
fhhvh_tripdata_2024-06.parquet	462,0	20.123.226	20	24	fa01fc19a9
fhhvh_tripdata_2024-07.parquet	446,7	19.182.934	19	24	fa01fc19a9
fhhvh_tripdata_2024-08.parquet	444,4	19.128.392	19	24	fa01fc19a9
fhhvh_tripdata_2024-09.parquet	444,9	19.209.788	19	24	fa01fc19a9
fhhvh_tripdata_2024-10.parquet	462,6	20.028.282	20	24	fa01fc19a9
fhhvh_tripdata_2024-11.parquet	458,0	19.987.533	20	24	fa01fc19a9
fhhvh_tripdata_2024-12.parquet	484,0	21.068.851	21	24	fa01fc19a9

Tệp	MB	Số dòng	Row group	Số cột	Lược đồ
fhvhv_tripdata_2025-01.parquet	468,3	20.405.666	20	25	b47916b42d
fhvhv_tripdata_2025-02.parquet	440,2	19.339.461	19	25	b47916b42d
fhvhv_tripdata_2025-03.parquet	478,5	20.536.879	20	25	b47916b42d
fhvhv_tripdata_2025-04.parquet	464,6	19.753.983	19	25	b47916b42d
fhvhv_tripdata_2025-05.parquet	493,4	21.091.193	21	25	b47916b42d
fhvhv_tripdata_2025-06.parquet	468,1	19.868.009	19	25	b47916b42d
fhvhv_tripdata_2025-07.parquet	464,7	19.653.012	19	25	b47916b42d
fhvhv_tripdata_2025-08.parquet	457,4	19.271.461	19	25	b47916b42d
fhvhv_tripdata_2025-09.parquet	458,6	19.434.641	19	25	b47916b42d
fhvhv_tripdata_2025-10.parquet	494,5	21.308.701	21	25	b47916b42d
fhvhv_tripdata_2025-11.parquet	484,0	20.818.240	20	25	b47916b42d
fhvhv_tripdata_2025-12.parquet	510,9	22.108.438	22	25	b47916b42d
yellow_tripdata_2024-01.parquet	47,6	2.964.624	3	19	6a4b8a3f68
yellow_tripdata_2024-02.parquet	48,0	3.007.526	3	19	6a4b8a3f68
yellow_tripdata_2024-03.parquet	57,3	3.582.628	4	19	6a4b8a3f68
yellow_tripdata_2024-04.parquet	56,4	3.514.289	4	19	6a4b8a3f68
yellow_tripdata_2024-05.parquet	59,7	3.723.833	4	19	6a4b8a3f68
yellow_tripdata_2024-06.parquet	57,1	3.539.193	4	19	6a4b8a3f68
yellow_tripdata_2024-07.parquet	49,9	3.076.903	3	19	6a4b8a3f68
yellow_tripdata_2024-08.parquet	48,7	2.979.183	3	19	6a4b8a3f68
yellow_tripdata_2024-09.parquet	58,3	3.633.030	4	19	6a4b8a3f68
yellow_tripdata_2024-10.parquet	61,4	3.833.771	4	19	6a4b8a3f68
yellow_tripdata_2024-11.parquet	57,8	3.646.369	4	19	6a4b8a3f68
yellow_tripdata_2024-12.parquet	58,7	3.668.371	4	19	6a4b8a3f68
yellow_tripdata_2025-01.parquet	56,4	3.475.226	4	20	9ffcb98921
yellow_tripdata_2025-02.parquet	57,5	3.577.543	4	20	9ffcb98921
yellow_tripdata_2025-03.parquet	66,7	4.145.257	4	20	9ffcb98921
yellow_tripdata_2025-04.parquet	64,2	3.970.553	4	20	9ffcb98921
yellow_tripdata_2025-05.parquet	74,2	4.591.845	5	20	9ffcb98921
yellow_tripdata_2025-06.parquet	70,1	4.322.960	5	20	9ffcb98921
yellow_tripdata_2025-07.parquet	63,8	3.898.963	4	20	9ffcb98921
yellow_tripdata_2025-08.parquet	59,4	3.574.091	4	20	9ffcb98921
yellow_tripdata_2025-09.parquet	69,1	4.251.015	5	20	9ffcb98921
yellow_tripdata_2025-10.parquet	71,8	4.428.699	5	20	9ffcb98921
yellow_tripdata_2025-11.parquet	67,8	4.181.444	4	20	9ffcb98921
yellow_tripdata_2025-12.parquet	70,3	4.305.006	5	20	9ffcb98921

Nguồn: *t01_bronze_manifest.csv*.

F.5. Nhật ký thời gian theo phân vùng

Bảng F.7. Thời gian xử lý của từng phân vùng

Dịch vụ	Tháng	Khúc	Dòng vào	Dòng Silver	Chất lượng (s)	Silver (s)	Gold (s)	Tổng (s)	MB
hvfhv	2024-01	0	4.615.667	4.439.844	7,4	57,8	8,1	73,2	135,8
hvfhv	2024-01	1	5.095.800	4.900.130	3,7	61,5	8,4	73,6	148,8
hvfhv	2024-01	2	5.386.070	5.184.771	2,0	55,5	9,3	66,8	156,7
hvfhv	2024-01	3	4.566.393	4.385.604	4,8	53,7	8,5	67,0	132,8
hvfhv	2024-02	0	5.227.320	5.019.006	1,8	56,5	10,2	68,5	152,4
hvfhv	2024-02	1	5.510.903	5.301.487	5,1	65,6	9,3	80,0	160,3
hvfhv	2024-02	2	5.368.065	5.155.427	2,2	53,5	10,1	65,7	155,8
hvfhv	2024-02	3	3.252.860	3.116.314	4,5	33,5	5,4	43,4	94,7
hvfhv	2024-03	0	5.663.015	5.448.094	2,1	43,1	8,2	53,5	165,2
hvfhv	2024-03	1	5.544.000	5.326.251	7,4	54,3	9,0	70,7	162,3
hvfhv	2024-03	2	5.432.646	5.218.004	2,4	54,9	10,2	67,5	158,6
hvfhv	2024-03	3	4.641.127	4.449.477	4,3	47,2	6,8	58,3	135,5

Dịch vụ	Tháng	Khúc	Dòng vào	Dòng Silver	Chất lượng (s)	Silver (s)	Gold (s)	Tổng (s)	MB
hvfhv	2024-04	0	5.408.865	5.196.436	1,7	50,8	9,5	61,9	158,5
hvfhv	2024-04	1	5.264.279	5.045.649	4,1	56,4	8,2	68,7	154,6
hvfhv	2024-04	2	5.186.410	4.970.009	1,9	47,2	7,2	56,4	152,4
hvfhv	2024-04	3	3.873.484	3.710.301	4,1	40,4	7,2	51,7	113,9
hvfhv	2024-05	0	5.360.450	5.133.920	1,7	51,3	7,9	60,9	157,1
hvfhv	2024-05	1	5.549.454	5.314.480	4,6	56,9	8,8	70,3	162,5
hvfhv	2024-05	2	5.413.183	5.179.346	2,2	52,2	8,1	62,6	158,6
hvfhv	2024-05	3	4.381.451	4.199.368	4,1	47,3	7,4	58,9	128,9
hvfhv	2024-06	0	5.494.511	5.255.534	1,7	53,7	7,8	63,2	160,7
hvfhv	2024-06	1	5.316.892	5.086.710	4,5	64,2	8,3	77,0	155,6
hvfhv	2024-06	2	5.271.558	5.049.717	1,7	46,9	7,8	56,4	154,3
hvfhv	2024-06	3	4.040.265	3.862.217	3,9	28,2	5,5	37,6	118,5
hvfhv	2024-07	0	4.565.136	4.379.621	1,0	30,5	6,0	37,5	134,8
hvfhv	2024-07	1	5.162.540	4.943.683	1,1	34,9	6,4	42,4	151,2
hvfhv	2024-07	2	5.072.290	4.849.242	3,6	39,1	7,0	49,8	148,7
hvfhv	2024-07	3	4.382.968	4.197.687	1,5	36,8	5,9	44,2	129,0
hvfhv	2024-08	0	5.220.531	5.005.395	3,3	39,2	7,1	49,5	153,2
hvfhv	2024-08	1	4.852.391	4.647.043	1,2	34,7	6,3	42,3	143,2
hvfhv	2024-08	2	4.842.228	4.629.422	2,8	37,3	6,7	46,9	142,6
hvfhv	2024-08	3	4.213.242	4.031.697	1,3	27,8	5,4	34,5	124,2
hvfhv	2024-09	0	5.055.750	4.840.537	1,0	32,0	7,1	40,1	148,7
hvfhv	2024-09	1	5.039.504	4.813.642	3,4	35,8	6,6	45,8	148,5
hvfhv	2024-09	2	5.068.103	4.834.515	1,1	32,9	6,5	40,5	148,9
hvfhv	2024-09	3	4.046.431	3.867.320	1,0	24,0	5,1	30,2	118,5
hvfhv	2024-10	0	4.922.546	4.689.080	2,5	32,3	6,4	41,2	144,1
hvfhv	2024-10	1	5.145.138	4.908.665	1,2	29,3	5,9	36,5	151,0
hvfhv	2024-10	2	5.166.962	4.930.606	1,0	30,1	6,1	37,2	151,7
hvfhv	2024-10	3	4.793.636	4.581.802	2,7	30,8	6,1	39,6	139,8
hvfhv	2024-11	0	5.253.623	5.030.742	1,1	32,0	5,7	38,8	153,8
hvfhv	2024-11	1	5.451.168	5.212.434	1,0	36,7	6,3	44,0	159,5
hvfhv	2024-11	2	5.551.624	5.314.150	2,9	37,6	6,6	47,1	162,3
hvfhv	2024-11	3	3.731.118	3.573.522	1,1	22,7	5,1	28,8	109,8
hvfhv	2024-12	0	5.660.458	5.407.119	0,9	34,7	7,0	42,7	165,2
hvfhv	2024-12	1	5.897.180	5.616.666	3,5	43,1	7,6	54,2	172,2
hvfhv	2024-12	2	5.565.429	5.317.420	1,3	33,1	7,0	41,3	163,0
hvfhv	2024-12	3	3.945.784	3.761.137	2,8	31,9	5,6	40,3	116,4
hvfhv	2025-01	0	4.876.224	4.683.094	1,0	34,8	6,3	42,1	143,5
hvfhv	2025-01	1	5.322.361	5.109.206	0,9	29,8	7,1	37,8	156,1
hvfhv	2025-01	2	5.514.949	5.280.920	3,5	32,9	6,9	43,3	161,1
hvfhv	2025-01	3	4.692.132	4.496.422	1,4	26,4	6,0	33,8	137,1
hvfhv	2025-02	0	5.586.430	5.360.326	1,1	32,2	7,5	40,8	163,4
hvfhv	2025-02	1	5.657.470	5.426.910	3,1	43,0	7,9	54,0	165,4
hvfhv	2025-02	2	5.404.391	5.173.877	1,4	38,8	7,1	47,2	158,1
hvfhv	2025-02	3	2.691.170	2.568.031	2,8	20,3	4,0	27,1	78,5
hvfhv	2025-03	0	5.579.356	5.338.563	1,1	36,7	7,4	45,2	163,2
hvfhv	2025-03	1	5.285.801	5.033.968	1,2	29,9	5,8	36,9	155,0
hvfhv	2025-03	2	5.240.483	4.973.950	3,6	39,1	6,7	49,3	152,9
hvfhv	2025-03	3	4.431.239	4.217.751	1,2	27,1	5,6	33,8	130,6
hvfhv	2025-04	0	5.322.374	5.091.474	1,1	49,1	9,1	59,3	156,3
hvfhv	2025-04	1	5.304.383	5.073.750	2,9	41,9	7,3	52,1	155,9
hvfhv	2025-04	2	5.112.906	4.863.214	1,2	32,4	6,3	39,8	150,2
hvfhv	2025-04	3	4.014.320	3.832.379	3,0	29,8	4,9	37,6	118,0
hvfhv	2025-05	0	5.499.054	5.244.046	1,3	33,8	7,0	42,2	161,5
hvfhv	2025-05	1	5.604.531	5.344.072	1,1	34,1	6,8	41,9	164,7
hvfhv	2025-05	2	5.466.539	5.207.318	3,8	39,2	7,2	50,2	161,3
hvfhv	2025-05	3	4.521.069	4.316.554	1,5	26,9	5,4	33,9	133,1

Dịch vụ	Tháng	Khúc	Dòng vào	Dòng Silver	Chất lượng (s)	Silver (s)	Gold (s)	Tổng (s)	MB
hvfhv	2025-06	0	5.226.964	4.959.685	0,8	29,4	5,9	36,1	153,5
hvfhv	2025-06	1	5.235.782	4.991.720	3,0	34,8	6,8	44,6	154,3
hvfhv	2025-06	2	5.374.863	5.126.492	1,2	34,8	7,1	43,1	157,9
hvfhv	2025-06	3	4.030.400	3.842.946	1,1	27,5	4,9	33,5	118,8
hvfhv	2025-07	0	4.690.868	4.475.733	2,8	31,8	5,6	40,2	137,6
hvfhv	2025-07	1	5.163.317	4.903.570	0,8	36,9	6,5	44,2	151,0
hvfhv	2025-07	2	5.138.876	4.888.083	1,2	31,4	6,9	39,5	150,5
hvfhv	2025-07	3	4.659.951	4.441.584	3,3	34,1	6,5	43,9	136,0
hvfhv	2025-08	0	5.001.065	4.763.929	0,9	31,9	6,6	39,3	146,5
hvfhv	2025-08	1	5.085.047	4.822.917	1,3	31,1	6,4	38,8	148,7
hvfhv	2025-08	2	4.939.046	4.546.079	3,4	34,2	6,0	43,6	140,6
hvfhv	2025-08	3	4.246.303	4.035.885	1,3	28,3	5,5	35,1	124,8
hvfhv	2025-09	0	5.012.630	4.777.619	1,0	33,4	6,3	40,6	147,9
hvfhv	2025-09	1	5.294.492	5.035.167	3,5	38,0	7,1	48,5	156,1
hvfhv	2025-09	2	5.127.705	4.868.608	1,3	30,3	6,9	38,4	151,1
hvfhv	2025-09	3	3.999.814	3.796.677	1,2	21,8	5,1	28,0	117,1
hvfhv	2025-10	0	5.186.218	4.936.591	2,6	32,5	6,8	41,9	152,1
hvfhv	2025-10	1	5.514.284	5.256.858	1,2	29,0	6,5	36,7	161,4
hvfhv	2025-10	2	5.559.556	5.267.511	1,2	30,7	6,6	38,5	161,6
hvfhv	2025-10	3	5.048.643	4.823.084	2,8	36,3	6,4	45,6	147,6
hvfhv	2025-11	0	5.722.455	5.448.493	1,2	33,5	9,0	43,7	166,4
hvfhv	2025-11	1	5.652.054	5.386.129	0,9	32,5	6,1	39,5	164,4
hvfhv	2025-11	2	5.580.291	5.322.635	3,3	38,7	7,3	49,3	162,9
hvfhv	2025-11	3	3.863.440	3.686.526	1,2	22,6	4,5	28,3	113,0
hvfhv	2025-12	0	5.957.820	5.669.643	1,1	33,5	7,0	41,6	172,9
hvfhv	2025-12	1	6.279.707	5.965.028	3,5	41,9	7,8	53,2	181,5
hvfhv	2025-12	2	5.746.309	5.478.703	1,2	34,9	6,6	42,6	168,0
hvfhv	2025-12	3	4.124.602	3.953.095	2,9	27,4	5,6	36,0	121,1
yellow	2024-01	0	2.964.624	2.831.392	0,6	13,9	2,9	17,4	62,3
yellow	2024-02	0	3.007.526	2.865.861	0,6	13,6	2,9	17,1	63,1
yellow	2024-03	0	3.582.628	3.396.863	0,8	14,0	3,7	18,4	75,1
yellow	2024-04	0	3.514.289	3.370.762	0,7	15,2	3,4	19,4	74,9
yellow	2024-05	0	3.723.833	3.569.455	0,7	14,8	3,7	19,1	79,7
yellow	2024-06	0	3.539.193	3.381.865	0,7	13,6	3,4	17,7	75,6
yellow	2024-07	0	3.076.903	2.930.477	4,3	20,7	3,2	28,2	66,0
yellow	2024-08	0	2.979.183	2.825.522	0,6	14,0	3,0	17,6	63,9
yellow	2024-09	0	3.633.030	3.439.773	0,7	18,7	3,7	23,1	77,4
yellow	2024-10	0	3.833.771	3.630.327	0,7	15,0	3,4	19,1	81,2
yellow	2024-11	0	3.646.369	3.467.427	0,8	18,1	3,7	22,6	76,9
yellow	2024-12	0	3.668.371	3.473.804	0,8	17,5	4,1	22,4	77,8
yellow	2025-01	0	3.475.226	3.216.376	0,7	12,6	3,5	16,7	72,0
yellow	2025-02	0	3.577.543	3.273.795	3,7	19,0	3,8	26,5	73,3
yellow	2025-03	0	4.145.257	3.789.373	0,7	17,7	3,8	22,2	85,4
yellow	2025-04	0	3.970.553	3.633.932	0,7	17,6	3,7	22,0	82,5
yellow	2025-05	0	4.591.845	4.048.068	0,8	21,2	4,7	26,7	92,7
yellow	2025-06	0	4.322.960	3.827.160	0,9	18,5	3,8	23,2	87,8
yellow	2025-07	0	3.898.963	3.455.160	0,7	16,3	4,0	20,9	79,7
yellow	2025-08	0	3.574.091	3.140.994	3,5	18,1	4,0	25,7	72,6
yellow	2025-09	0	4.251.015	3.796.245	0,7	20,0	3,9	24,6	87,4
yellow	2025-10	0	4.428.699	3.900.104	0,8	20,8	4,3	25,9	89,6
yellow	2025-11	0	4.181.444	3.603.168	0,8	18,6	4,3	23,7	82,7
yellow	2025-12	0	4.305.006	4.005.824	0,8	23,4	4,5	28,8	93,0

Nguồn: t08_partition_runtime.csv.

PHỤ LỤC G. DANH MỤC TẬP KẾT QUẢ

Bảng G.1. Danh mục các tập bảng kết quả

Tập bảng kết quả	Số dòng	Số cột
outputs/tables/a01_zone_detail.csv	523	25
outputs/tables/a02_month_group_detail.csv	240	22
outputs/tables/a03_flow_hour_detail.csv	2.400	13
outputs/tables/t01_bronze_manifest.csv	48	12
outputs/tables/t01x_bronze_manifest_ext.csv	48	12
outputs/tables/t02_schema_drift.csv	24	5
outputs/tables/t02x_schema_drift_ext.csv	22	5
outputs/tables/t03_bronze_summary.csv	2	4
outputs/tables/t03x_bronze_summary_ext.csv	2	4
outputs/tables/t04_dim_zone.csv	265	17
outputs/tables/t05_zone_groups.csv	10	3
outputs/tables/t06_quality_by_month.csv	48	19
outputs/tables/t06x_quality_by_month.csv	48	19
outputs/tables/t07_quality_summary.csv	2	18
outputs/tables/t07x_quality_summary.csv	2	18
outputs/tables/t08_partition_runtime.csv	120	18
outputs/tables/t08x_partition_runtime.csv	154	19
outputs/tables/t09_bench_format.csv	4	8
outputs/tables/t10_bench_engine.csv	3	8
outputs/tables/t11_bench_pruning.csv	4	6
outputs/tables/t12_rowgroup_stats.csv	21	4
outputs/tables/t13_reject_rate_by_rule.csv	7	3
outputs/tables/t14_daily_trips_by_group_hvfhv.csv	731	6
outputs/tables/t15_weekly_yoy_pct_by_group_hvfhv.csv	50	5
outputs/tables/t16_cbd_revenue_by_month.csv	24	7
outputs/tables/t17_flow_matrix_by_year_hvfhv.csv	10	7
outputs/tables/t18_flow_share_change_hvfhv.csv	25	5
outputs/tables/t19_hour_profile_crz_touch.csv	24	4
outputs/tables/t20_speed_intra_crz_by_hour.csv	24	4
outputs/tables/t21_speed_by_month_flow.csv	24	4
outputs/tables/t22_price_pay_by_month.csv	26	19
outputs/tables/t23_company_share_by_month.csv	24	3
outputs/tables/t24_company_share_crz_by_month.csv	24	3
outputs/tables/t25_zone_yoy_pickups.csv	256	7
outputs/tables/t26_desc_by_group_year_hvfhv.csv	10	21
outputs/tables/t27_desc_by_group_year_yellow.csv	10	11
outputs/tables/t27b_yellow_vendor_by_year_group.csv	45	4
outputs/tables/t28_weekly_index_crz_by_service.csv	105	4
outputs/tables/t29_rider_cost_quantiles_sample.csv	4	7
outputs/tables/t30_did_main.csv	88	15
outputs/tables/t31_event_study_weekly_ln_n.csv	306	17
outputs/tables/t32_event_study_monthly_hvfhv.csv	138	15
outputs/tables/t33_heterogeneity_hour.csv	20	9
outputs/tables/t34_heterogeneity_weekend.csv	8	9
outputs/tables/t35_did_od_pairs.csv	44	12
outputs/tables/t36_pass_through.csv	4	6
outputs/tables/t37_event_od_ln_n.csv	23	13
outputs/tables/t38_scm_weights_demeaned.csv	200	5

Tập bảng kết quả	Số dòng	Số cột
outputs/tables/t38_scm_weights_standard.csv	200	5
outputs/tables/t39_scm_series.csv	103	4
outputs/tables/t40_scm_placebo.csv	60	8
outputs/tables/t41_dml_ate.csv	3	10
outputs/tables/t41b_dml_sensitivity_xsets.csv	6	11
outputs/tables/t42_dml_blp.csv	3	6
outputs/tables/t43_dml_gates.csv	15	6
outputs/tables/t44_dml_clan.csv	24	4
outputs/tables/t45_dml_cate_importance.csv	21	3
outputs/tables/t46_cate_by_distance.csv	8	4
outputs/tables/t47_cate_by_flowtype.csv	4	5
outputs/tables/t48_spillover_bands.csv	24	11
outputs/tables/t49_placebo_time.csv	9	13
outputs/tables/t49b_placebo_time_od.csv	7	13
outputs/tables/t50_permutation.csv	500	1
outputs/tables/t51_robustness_ln_n.csv	17	11
outputs/tables/t52_pipeline_totals.csv	2	8
outputs/tables/t53_storage_by_layer.csv	2	3
outputs/tables/t54_zone_specific_effects.csv	37	14
outputs/tables/t55_zone_effect_meta_regression.csv	10	7
outputs/tables/t56_spillover_by_borough.csv	4	7
outputs/tables/t57_speed_did_hour_daytype.csv	48	7
outputs/tables/t58_airport_flows.csv	9	5
outputs/tables/t59_distance_composition.csv	4	8
outputs/tables/t60_spark_repro_partitions.csv	48	7
outputs/tables/t60b_spark_repro_totals.csv	2	8
outputs/tables/t61_spark_validation.csv	34	9
outputs/tables/t61a_spark_validation_truoc_sua.csv	34	9
outputs/tables/t61c_rerun_changes.csv	66	5
outputs/tables/t62_spark_engine.csv	3	11
outputs/tables/t63_spark_shuffle.csv	18	6
outputs/tables/t64_spark_scale.csv	10	8
outputs/tables/t65_spark_cache.csv	13	4
outputs/tables/t66_spark_pruning.csv	5	7
outputs/tables/t66b_spark_arrow.csv	2	6
outputs/tables/t67_stream_batches.csv	14	8
outputs/tables/t67b_stream_hourly.csv	333	6
outputs/tables/t68_data_catalog.csv	18	9
outputs/tables/t68b_schema_fingerprints.csv	2	4
outputs/tables/t69_lineage.csv	17	10
outputs/tables/t70_sha256_manifest.csv	50	5
outputs/tables/t71_reconciliation.csv	48	10
outputs/tables/t72_daily_anomaly_scores.csv	5,848	10
outputs/tables/t72b_anomaly_days_crz.csv	61	4
outputs/tables/t72c_anomaly_summary.csv	8	6
outputs/tables/t72d_pchart_reject.csv	2	9
outputs/tables/t73_trip_anomaly_rules.csv	6	4
outputs/tables/t73b_trip_anomaly_profile.csv	9	3
outputs/tables/t73c_trip_anomaly_by_company.csv	2	3
outputs/tables/t73d_trip_anomaly_by_crz_period.csv	4	3
outputs/tables/t74_privacy_kanonymity.csv	10	9
outputs/tables/t75_dp_replications.csv	241	4

Tập bảng kết quả	Số dòng	Số cột
outputs/tables/t75b_dp_summary.csv	6	11
outputs/tables/t76_recovery_rto.csv	4	4
outputs/tables/t77_company_did.csv	6	12
outputs/tables/t77b_company_diff.csv	1	7
outputs/tables/t78_forecast_accuracy.csv	6	6
outputs/tables/t79_forecast_counterfactual_monthly.csv	12	6
outputs/tables/t79b_forecast_daily.csv	731	5
outputs/tables/t80_power_mde.csv	18	9
outputs/tables/t81_price_demand_elasticity.csv	12	9
outputs/tables/t82_resource_accounting.csv	9	4
outputs/tables/t83_dose_response_fee_share.csv	5	12
outputs/tables/t84_speed_gain_vs_flow.csv	48	10
outputs/tables/t84b_speed_gain_vs_flow_models.csv	5	8
outputs/tables/t85_spillover_dose_response.csv	6	11
outputs/tables/t85b_spillover_by_exposure_bin.csv	4	9
outputs/tables/t86_driver_pay_mechanical.csv	1	10
outputs/tables/t89_long_event_study.csv	288	5
outputs/tables/t89b_long_index.csv	48	3
outputs/tables/t90_long_placebo_trend.csv	8	27
outputs/tables/t91_rr_relative_magnitudes.csv	56	8
outputs/tables/t91b_rr_smoothness.csv	48	8

Bảng G.2. Danh mục các tập hình

Tập hình
outputs/figures/f00_architecture.png
outputs/figures/f01_rows_by_month.png
outputs/figures/f02_reject_by_rule.png
outputs/figures/f03_zone_group_map.png
outputs/figures/f04_manhattan_map.png
outputs/figures/f05_daily_trips_by_group.png
outputs/figures/f06_weekly_yoy_by_group.png
outputs/figures/f07_cbd_revenue.png
outputs/figures/f08_hour_profile_crz.png
outputs/figures/f09_speed_intra_crz_hour.png
outputs/figures/f10_speed_by_month.png
outputs/figures/f11_fare_per_mile.png
outputs/figures/f12_pay_per_mile.png
outputs/figures/f13_wait_time.png
outputs/figures/f14_pay_share.png
outputs/figures/f15_company_share.png
outputs/figures/f16_zone_yoy_map.png
outputs/figures/f17_weekly_index_crz_services.png
outputs/figures/f18_rider_cost_hist.png
outputs/figures/f19_event_study_hvfhv.png
outputs/figures/f20_event_study_yellow.png
outputs/figures/f21_event_ddd_weekly.png
outputs/figures/f22_event_monthly_grid.png
outputs/figures/f23_heterogeneity_hour.png
outputs/figures/f24_event_od.png
outputs/figures/f25_scm_fit_gap.png

Tệp hình
outputs/figures/f26_scm_placebo.png
outputs/figures/f27_scm_rmspe_ratio.png
outputs/figures/f28_dml_overlap.png
outputs/figures/f29_dml_gates.png
outputs/figures/f30_cate_by_distance.png
outputs/figures/f31_cate_importance.png
outputs/figures/f32_spillover_bands.png
outputs/figures/f33_permutation.png
outputs/figures/f34_robustness_forest.png
outputs/figures/f35_bench_format.png
outputs/figures/f36_bench_engine.png
outputs/figures/f37_partition_runtime.png
outputs/figures/f38_zone_effects_map.png
outputs/figures/f39_zone_effects_scatter.png
outputs/figures/f40_speed_did_heatmap.png
outputs/figures/f41_distance_composition.png
outputs/figures/f42_spark_engine_scale.png
outputs/figures/f43_spark_shuffle.png
outputs/figures/f44_spark_cache.png
outputs/figures/f45_stream_hourly.png
outputs/figures/f46_stream_batches.png
outputs/figures/f47_lineage.png
outputs/figures/f48_anomaly_days.png
outputs/figures/f49_pchart_reject.png
outputs/figures/f50_trip_anomaly.png
outputs/figures/f51_privacy_kanonymity.png
outputs/figures/f52_dp_tradeoff.png
outputs/figures/f53_forecast_counterfactual.png
outputs/figures/f54_power_mde.png
outputs/figures/f56_theory_tests.png
outputs/figures/f57_long_event_study.png
outputs/figures/f58_rr_long.png

PHỤ LỤC H. NHẬT KÝ XỬ LÝ PHÂN TÁN VÀ QUẢN TRỊ DỮ LIỆU

Phụ lục này trình bày các bảng chi tiết của Chương 5 và Chương 6: thời gian tái lập từng phân vùng bằng Spark, kết quả đối chứng đầy đủ, bản kê dấu băm SHA-256 của lớp Bronze, kết quả đối soát số dòng, phả hệ chi tiết và kế hoạch logic của Spark.

H.1. Tái lập bảng zone_day_pu bằng Spark theo phân vùng

Bảng H.1. Thời gian tái lập của 48 phân vùng tháng-dịch vụ

Dịch vụ	Tháng	Dòng Silver	Thời gian (s)	Dòng/giây	JVM đỉnh (MB)
hvfhv	2024-01	18.910.349	18,10	1.044.805	923
hvfhv	2024-02	18.592.234	6,78	2.742.579	934
hvfhv	2024-03	20.441.826	8,02	2.549.038	951
hvfhv	2024-04	18.922.395	6,84	2.767.810	959
hvfhv	2024-05	19.827.114	7,47	2.655.914	976
hvfhv	2024-06	19.254.178	7,21	2.669.526	983
hvfhv	2024-07	18.370.233	6,19	2.967.235	988
hvfhv	2024-08	18.313.557	6,50	2.819.151	1.006
hvfhv	2024-09	18.356.014	6,29	2.916.474	1.009
hvfhv	2024-10	19.110.153	6,73	2.838.937	1.012
hvfhv	2024-11	19.130.848	6,70	2.855.715	1.027
hvfhv	2024-12	20.102.342	7,32	2.748.018	1.047
hvfhv	2025-01	19.569.642	8,29	2.359.327	1.049
hvfhv	2025-02	18.529.144	6,29	2.946.084	1.053
hvfhv	2025-03	19.564.232	7,00	2.793.314	1.064
hvfhv	2025-04	18.860.817	6,23	3.025.702	1.065
hvfhv	2025-05	20.111.990	6,88	2.923.907	1.071
hvfhv	2025-06	18.920.843	18,57	1.018.789	844
hvfhv	2025-07	18.708.970	6,73	2.780.590	866
hvfhv	2025-08	18.168.810	7,13	2.548.683	877
hvfhv	2025-09	18.478.071	6,74	2.741.497	882
hvfhv	2025-10	20.284.044	7,60	2.669.577	887
hvfhv	2025-11	19.843.783	6,95	2.856.838	894
hvfhv	2025-12	21.066.469	7,29	2.889.647	899
yellow	2024-01	2.831.392	1,91	1.485.984	904
yellow	2024-02	2.865.861	1,39	2.055.651	907
yellow	2024-03	3.396.863	1,16	2.923.525	912
yellow	2024-04	3.370.762	1,38	2.449.374	916
yellow	2024-05	3.569.455	1,41	2.539.296	922
yellow	2024-06	3.381.865	1,42	2.380.465	923
yellow	2024-07	2.930.477	1,33	2.200.402	923
yellow	2024-08	2.825.522	1,33	2.118.709	923
yellow	2024-09	3.439.773	1,24	2.782.356	923
yellow	2024-10	3.630.327	1,28	2.836.648	923
yellow	2024-11	3.467.427	1,23	2.811.203	923
yellow	2024-12	3.473.804	1,21	2.877.640	924
yellow	2025-01	3.216.376	2,12	1.517.194	926
yellow	2025-02	3.273.795	1,75	1.875.546	926
yellow	2025-03	3.789.373	1,70	2.231.583	927
yellow	2025-04	3.633.932	1,39	2.612.874	928
yellow	2025-05	4.048.068	1,32	3.060.386	929

Dịch vụ	Tháng	Dòng Silver	Thời gian (s)	Dòng/giây	JVM đỉnh (MB)
yellow	2025-06	3.827.160	1,41	2.705.703	930
yellow	2025-07	3.455.160	1,24	2.780.146	931
yellow	2025-08	3.140.994	1,30	2.421.616	935
yellow	2025-09	3.796.245	1,36	2.796.940	935
yellow	2025-10	3.900.104	1,36	2.859.966	936
yellow	2025-11	3.603.168	1,27	2.829.446	936
yellow	2025-12	4.005.824	1,38	2.912.326	936

Nguồn: `t60_spark_repro_partitions.csv`.

H.2. Đối chứng chi tiết Spark – DuckDB

Bảng H.2. Đối chứng từng chỉ tiêu, trước khi sửa lỗi

Dịch vụ	Chỉ tiêu	Số ô	Lệch rỗng	Lệch tuyệt đối max	Lệch tương đối max	Tổng Spark	Tổng DuckDB
hvfhv	n	188.377	0	0	0	461.438.058,00	461.438.058,00
yellow	n	169.771	0	0	0	82.873.727,00	82.873.727,00
hvfhv	fare	188.377	0	6,98e-09	1,24e-14	11.364.983.908,50	11.364.983.908,50
yellow	fare	169.771	0	1,22e-09	6,2e-15	1.618.840.690,41	1.618.840.690,41
hvfhv	pay	188.377	0	3,73e-09	1,38e-14	8.781.008.283,57	8.781.008.283,57
yellow	pay	169.771	0	–	–	–	–
hvfhv	miles	188.377	0	2,21e-09	1,22e-14	2.082.604.078,22	2.082.604.078,22
yellow	miles	169.771	0	5,24e-10	6,2e-15	281.852.457,65	281.852.457,65
hvfhv	time_s	188.377	0	0	0	530.600.043.782,00	530.600.043.782,00
yellow	time_s	169.771	0	0	0	84.669.456.383,00	84.669.456.383,00
hvfhv	tips	188.377	0	6,26e-10	8,42e-15	492.814.106,28	492.814.106,28
yellow	tips	169.771	0	1,03e-09	1,93e-14	262.516.211,83	262.516.211,83
hvfhv	cbd	188.377	0	0	0	117.129.055,50	117.129.055,50
yellow	cbd	169.771	0	0,05	0,0625	24.026.395,50	24.028.170,60
hvfhv	rider_cost	188.377	0	6,15e-08	4,76e-14	13.719.124.046,26	13.719.124.046,26
yellow	rider_cost	169.771	0	2,68e-09	1,27e-14	1.901.354.933,73	1.901.354.933,73
hvfhv	cong_sur	188.377	0	0	0	483.795.261,25	483.795.261,25
yellow	cong_sur	169.771	0	0	0	162.896.886,52	162.896.886,52
hvfhv	tolls	188.377	0	9e-09	1,58e-13	345.014.956,74	345.014.956,74
yellow	tolls	169.771	0	7,82e-10	4,43e-14	43.896.573,86	43.896.573,86
hvfhv	wait_sum	188.377	0	9,02e-10	9,43e-15	2.146.839.146,38	2.146.839.146,38
yellow	wait_sum	169.771	0	–	–	–	–
hvfhv	wait_n	188.377	0	0	0	456.689.884,00	456.689.884,00
yellow	wait_n	169.771	0	0	–	0,00	0,00
hvfhv	shared_req	188.377	0	0	0	15.551.969,00	15.551.969,00
yellow	shared_req	169.771	0	0	–	0,00	0,00
hvfhv	n_cbd	188.377	0	0	0	78.085.912,00	78.085.912,00
yellow	n_cbd	169.771	0	0	0	32.035.086,00	32.035.086,00
hvfhv	n_to_crz	188.377	0	0	0	109.058.701,00	109.058.701,00
yellow	n_to_crz	169.771	0	0	0	46.595.042,00	46.595.042,00
hvfhv	n_uber	188.377	0	0	0	339.364.306,00	339.364.306,00
yellow	n_uber	169.771	0	0	–	0,00	0,00
hvfhv	n_lyft	188.377	0	0	0	122.073.752,00	122.073.752,00
yellow	n_lyft	169.771	0	0	–	0,00	0,00

Nguồn: `t61a`.

Bảng H.3. Đối chứng từng chỉ tiêu, sau khi sửa lỗi

Dịch vụ	Chỉ tiêu	Số ô	Lệch rỗng	Lệch tuyệt đối max	Lệch tương đối max	Tổng Spark	Tổng DuckDB
hvfhv	n	188.377	0	0	0	461.438.058,00	461.438.058,00
yellow	n	169.771	0	0	0	82.873.727,00	82.873.727,00
hvfhv	fare	188.377	0	6,98e-09	1,24e-14	11.364.983.908,50	11.364.983.908,50
yellow	fare	169.771	0	1,22e-09	6,2e-15	1.618.840.690,41	1.618.840.690,41
hvfhv	pay	188.377	0	3,73e-09	1,38e-14	8.781.008.283,57	8.781.008.283,57

Dịch vụ	Chỉ tiêu	Số ô	Lệch rỗng	Lệch tuyệt đối max	Lệch tương đối max	Tổng Spark	Tổng DuckDB
yellow	pay	169.771	0	–	–	–	–
hvfhv	miles	188.377	0	2,21e-09	1,22e-14	2.082.604.078,22	2.082.604.078,22
yellow	miles	169.771	0	5,24e-10	6,22e-15	281.852.457,65	281.852.457,65
hvfhv	time_s	188.377	0	0	0	530.600.043.782,00	530.600.043.782,00
yellow	time_s	169.771	0	0	0	84.669.456.383,00	84.669.456.383,00
hvfhv	tips	188.377	0	6,26e-10	8,42e-15	492.814.106,28	492.814.106,28
yellow	tips	169.771	0	1,03e-09	1,93e-14	262.516.211,83	262.516.211,83
hvfhv	cbd	188.377	0	0	0	117.129.055,50	117.129.055,50
yellow	cbd	169.771	0	0	0	24.026.395,50	24.026.395,50
hvfhv	rider_cost	188.377	0	6,15e-08	4,76e-14	13.719.124.046,26	13.719.124.046,26
yellow	rider_cost	169.771	0	2,68e-09	1,27e-14	1.901.354.933,73	1.901.354.933,73
hvfhv	cong_sur	188.377	0	0	0	483.795.261,25	483.795.261,25
yellow	cong_sur	169.771	0	0	0	162.896.886,52	162.896.886,52
hvfhv	tolls	188.377	0	9e-09	1,58e-13	345.014.956,74	345.014.956,74
yellow	tolls	169.771	0	7,82e-10	4,43e-14	43.896.573,86	43.896.573,86
hvfhv	wait_sum	188.377	0	9,02e-10	9,43e-15	2.146.839.146,38	2.146.839.146,38
yellow	wait_sum	169.771	0	–	–	–	–
hvfhv	wait_n	188.377	0	0	0	456.689.884,00	456.689.884,00
yellow	wait_n	169.771	0	0	–	0,00	0,00
hvfhv	shared_req	188.377	0	0	0	15.551.969,00	15.551.969,00
yellow	shared_req	169.771	0	0	–	0,00	0,00
hvfhv	n_cbd	188.377	0	0	0	78.085.912,00	78.085.912,00
yellow	n_cbd	169.771	0	0	0	32.035.086,00	32.035.086,00
hvfhv	n_to_crz	188.377	0	0	0	109.058.701,00	109.058.701,00
yellow	n_to_crz	169.771	0	0	0	46.595.042,00	46.595.042,00
hvfhv	n_uber	188.377	0	0	0	339.364.306,00	339.364.306,00
yellow	n_uber	169.771	0	0	–	0,00	0,00
hvfhv	n_lyft	188.377	0	0	0	122.073.752,00	122.073.752,00
yellow	n_lyft	169.771	0	0	–	0,00	0,00

Nguồn: *t61_spark*.

H.3. Bản kê dấu băm SHA-256 của lớp Bronze

Bảng H.4. Dấu băm SHA-256 của 50 tệp nguồn

Tệp	Byte	SHA-256	MB/s
fhvhv_tripdata_2024-01.parquet	472.757.547	9897de352aa52cea36b70348cc6721b8d4494327ce39c85f0dba83d86ecaa098	89
fhvhv_tripdata_2024-02.parquet	462.475.428	54bafa7bcf3f06e7833fcbccf7ef158eb793a72ee1c4bb8b0f080e56ae71a15d6	82
fhvhv_tripdata_2024-03.parquet	507.940.560	ff25b93f890f889637963b749d0839ec5a15f075d23ea5297b3312ed9a10d6d9	79
fhvhv_tripdata_2024-04.parquet	476.115.643	1493f3edd0486bffc3f949cb5a66ec49e9d04f7ad6e94f85626f16aa6fec7260	87
fhvhv_tripdata_2024-05.parquet	498.575.918	152db11cbc95a796fea0b9cb26184b3c4cfad181fa9d7488d4c61f06c521b4b5	41
fhvhv_tripdata_2024-06.parquet	484.417.715	4772ee1ab01e639a5db74169b49049f74f0f46a0c925fd3b67f9f068221f6373	62
fhvhv_tripdata_2024-07.parquet	468.437.522	3a511a8df72441d72b32f6ce9829e29f5d61666e37f1b40b8d352cc5830c81e1	85
fhvhv_tripdata_2024-08.parquet	465.991.646	99fd2913d2c8935e4c1d166f229290a90971b6564c490a8ba2a257de9e08fae2	77
fhvhv_tripdata_2024-09.parquet	466.470.118	d2d26d608a77555128a2b435d375f5d25d3d8125b688c57fc60d5a0fb5a1d3b	83
fhvhv_tripdata_2024-10.parquet	485.102.359	8ee625798a6543148c3a3e33df5e2cf44acb17af904dbfff925d1cd4f077afb5	43
fhvhv_tripdata_2024-11.parquet	480.228.052	cc3547280a9ff6edb4eaa467a3aa0ea2a372fca746e3e733d1ea3152d56daed3	72
fhvhv_tripdata_2024-12.parquet	507.534.115	dcf0885722bc76ab7b5f22a23b784513caf7e7c2b23381ed854610c436c48887	85
fhvhv_tripdata_2025-01.parquet	491.076.642	fcdef276f4e9887f2beab30590165cdea74caef50a1313d71fa01ff6afacca3a	85
fhvhv_tripdata_2025-02.parquet	461.632.254	2077477d4d841b8ec40a3839b629f08f45f6802ca016adc1e01d6d8cffd2cf23	80
fhvhv_tripdata_2025-03.parquet	501.783.767	671399467732b00653307525421bfc6004e6a45be1fadd5e4b8fa3d11da22043	82
fhvhv_tripdata_2025-04.parquet	487.219.586	d1edcd63ba37e87e0c6fda58fcfc12352c0aa9ad9ad88dd2992094bcecd1e3b1	78
fhvhv_tripdata_2025-05.parquet	517.386.544	424be0dcc1248f8d3db2f35805f2d475e19196ad64dc2e1d2e9c7b771851585a	87
fhvhv_tripdata_2025-06.parquet	490.819.474	f26bbe980f037a15f47f40da4ad7102b7aaebe0c9a8f3c1fd058c6652007c88	92
fhvhv_tripdata_2025-07.parquet	487.222.980	cae4e3d120f9af1a7369dad915dfe9beadda914b08a38ee8c045a4d09f085712	88
fhvhv_tripdata_2025-08.parquet	479.574.607	e2fc965d31bd10f23224f5e007b463d037c45fbdaa6ded23c5deab01ec8d3b7	88
fhvhv_tripdata_2025-09.parquet	480.851.341	1744115e019e2f6e1e41214afb33f087a303620834c42021c642c5afca042d6f	92
fhvhv_tripdata_2025-10.parquet	518.486.063	5610c7bcbe2aadd14761858eb7b94d3b01a2ee03d299c05f3575f72357f5b81a	91
fhvhv_tripdata_2025-11.parquet	507.485.661	a17ebafe3b6b1927f9b1b4cfc9062a328867b79a871ce762bfb16a841024f1e0	90
fhvhv_tripdata_2025-12.parquet	535.754.793	897e541b2a998df118dc5cc2b4182b74d14f6d0f2a950ef2bac3a8924ce6e95f	77
taxi_zone_lookup.csv	12.331	1a99e105092230f8620f301edcca7f80d3080642ff404d28ed957d3fa222c8ed	0
taxi_zones.zip	1.022.574	f6d711917bb4340f8f644d5366c51665489eb2d426dd1a4a55677721ae5adf17	11

Tệp	Byte	SHA-256	MB/s
yellow_tripdata_2024-01.parquet	49.961.641	c4d59da7bbc8abaeceb1727947ee93d9891a71acb42854bd80db1571b2030510	34
yellow_tripdata_2024-02.parquet	50.349.284	c76c43c18c6c6664080dd920baab4928988d5786a6b65980792ca7cd796f9f20	51
yellow_tripdata_2024-03.parquet	60.078.280	2d4cdc8fb96726cdd3803b13b02d2e61e71d45720aff0ebc693a8bdd1f249823	50
yellow_tripdata_2024-04.parquet	59.133.625	ce37f736c7cf9e92164c850ef2b502a8f7bb590fc1804b6edcb80293da01b89	70
yellow_tripdata_2024-05.parquet	62.553.128	1974230be2b5a3ea92e47b5eb77f32dbf1de896d81ad8df4ab6faba52749ad23	53
yellow_tripdata_2024-06.parquet	59.859.922	677cf14c8347f745b583f012fbdab072334c6c4efa17bfd6a64369f2ba30329c	60
yellow_tripdata_2024-07.parquet	52.299.432	af12d6b04daeb78550799ae99933d495b27d715b6dbb0fad9bb750a4537d3070	64
yellow_tripdata_2024-08.parquet	51.067.350	7315643dd16bafc03e27d9903edbfd35404c2550a695d0da0a3e73852d940cfb	62
yellow_tripdata_2024-09.parquet	61.170.186	2f42e4a383a6635de803001462848d0aee2b47f6ce899126805d2d05361fb843	73
yellow_tripdata_2024-10.parquet	64.346.071	d19fe05aa0b259af24eb47051735293287f1e6dc263ba04030ec1ab4c6ec2650	75
yellow_tripdata_2024-11.parquet	60.658.709	5ef321876de5007a7c147a347389133fc94fd7ac28f82eb1d57d8f2cf05cfd3b	73
yellow_tripdata_2024-12.parquet	61.524.085	41ebf7db80bebe60c58e5143c14cdf38ad04a0f3e3ff44215b3e240d55f6c78	75
yellow_tripdata_2025-01.parquet	59.158.238	9af277e4c0d3f9deb30644da822981e1e7df6af58313170df3aa8a474485488a	61
yellow_tripdata_2025-02.parquet	60.343.086	037cba555a73663f3a51a2c27816e40e3feb364769942bdf122b9da31e377bd3	73
yellow_tripdata_2025-03.parquet	69.964.745	20c4b77cce457b7cfdae77c5069ca7dc91c167f876a41467f4502ab69487a186	87
yellow_tripdata_2025-04.parquet	67.352.824	6f98938de9380a3f85600533816f0dc0e6d9b5b210e485d623952bac599bbe28	80
yellow_tripdata_2025-05.parquet	77.837.865	7ef46bcd0fcee7f8c0bb38a532be05bceefabb512d4bb0b32a7727dd862b15c	83
yellow_tripdata_2025-06.parquet	73.542.954	1beaf75b09c744414451fa7fef09fbc5a393ffb1621c859be6ba0df23a14e1b6	83
yellow_tripdata_2025-07.parquet	66.943.728	1efa6a0458dc60341f7f81dcb5015af731f42d1a109f4e0d594dd46970fd4ef	87
yellow_tripdata_2025-08.parquet	62.293.743	b982ace703e3564d92e94edae5ec93515f4f1fb07a5b95e7404c32464c1a6a89	87
yellow_tripdata_2025-09.parquet	72.432.945	cd39b9901f01d1df752d45cbaec91ee5f68c4dddf9e261e938c1dbab404644c7	82
yellow_tripdata_2025-10.parquet	75.267.589	e1f63caf331bc6230d9c6f757cb88e55fdc2bddde185fb414d2c947abd773c3	89
yellow_tripdata_2025-11.parquet	71.134.255	2cf2f3127f96d4d5dea30f8afe05119cf8e4ba57bd9e60b789d3f296fc8459ab	62
yellow_tripdata_2025-12.parquet	73.701.327	eaba7ff61ebb6453fc6f673fda43d621380307f869b768b124992e8486c785e1	87

Nguồn: `t70_sha256_manifest.csv`.

H.4. Đối soát số dòng giữa các lớp

Bảng H.5. Kết quả ba phép đối soát cho 48 phân vùng

Dịch vụ	Tháng	Bronze	Bị loại	Silver	Bronze = đã đọc	Cân đối	Silver khớp
hvfhv	2024-01	19.663.930	753.581	18.910.349	Đạt	Đạt	Đạt
hvfhv	2024-02	19.359.148	766.914	18.592.234	Đạt	Đạt	Đạt
hvfhv	2024-03	21.280.788	838.962	20.441.826	Đạt	Đạt	Đạt
hvfhv	2024-04	19.733.038	810.643	18.922.395	Đạt	Đạt	Đạt
hvfhv	2024-05	20.704.538	877.424	19.827.114	Đạt	Đạt	Đạt
hvfhv	2024-06	20.123.226	869.048	19.254.178	Đạt	Đạt	Đạt
hvfhv	2024-07	19.182.934	812.701	18.370.233	Đạt	Đạt	Đạt
hvfhv	2024-08	19.128.392	814.835	18.313.557	Đạt	Đạt	Đạt
hvfhv	2024-09	19.209.788	853.774	18.356.014	Đạt	Đạt	Đạt
hvfhv	2024-10	20.028.282	918.129	19.110.153	Đạt	Đạt	Đạt
hvfhv	2024-11	19.987.533	856.685	19.130.848	Đạt	Đạt	Đạt
hvfhv	2024-12	21.068.851	966.509	20.102.342	Đạt	Đạt	Đạt
hvfhv	2025-01	20.405.666	836.024	19.569.642	Đạt	Đạt	Đạt
hvfhv	2025-02	19.339.461	810.317	18.529.144	Đạt	Đạt	Đạt
hvfhv	2025-03	20.536.879	972.647	19.564.232	Đạt	Đạt	Đạt
hvfhv	2025-04	19.753.983	893.166	18.860.817	Đạt	Đạt	Đạt
hvfhv	2025-05	21.091.193	979.203	20.111.990	Đạt	Đạt	Đạt
hvfhv	2025-06	19.868.009	947.166	18.920.843	Đạt	Đạt	Đạt
hvfhv	2025-07	19.653.012	944.042	18.708.970	Đạt	Đạt	Đạt
hvfhv	2025-08	19.271.461	1.102.651	18.168.810	Đạt	Đạt	Đạt
hvfhv	2025-09	19.434.641	956.570	18.478.071	Đạt	Đạt	Đạt
hvfhv	2025-10	21.308.701	1.024.657	20.284.044	Đạt	Đạt	Đạt
hvfhv	2025-11	20.818.240	974.457	19.843.783	Đạt	Đạt	Đạt
hvfhv	2025-12	22.108.438	1.041.969	21.066.469	Đạt	Đạt	Đạt
yellow	2024-01	2.964.624	133.232	2.831.392	Đạt	Đạt	Đạt
yellow	2024-02	3.007.526	141.665	2.865.861	Đạt	Đạt	Đạt
yellow	2024-03	3.582.628	185.765	3.396.863	Đạt	Đạt	Đạt
yellow	2024-04	3.514.289	143.527	3.370.762	Đạt	Đạt	Đạt
yellow	2024-05	3.723.833	154.378	3.569.455	Đạt	Đạt	Đạt

Dịch vụ	Tháng	Bronze	Bị loại	Silver	Bronze = đã đọc	Cân đối	Silver khớp
yellow	2024-06	3.539.193	157.328	3.381.865	Đạt	Đạt	Đạt
yellow	2024-07	3.076.903	146.426	2.930.477	Đạt	Đạt	Đạt
yellow	2024-08	2.979.183	153.661	2.825.522	Đạt	Đạt	Đạt
yellow	2024-09	3.633.030	193.257	3.439.773	Đạt	Đạt	Đạt
yellow	2024-10	3.833.771	203.444	3.630.327	Đạt	Đạt	Đạt
yellow	2024-11	3.646.369	178.942	3.467.427	Đạt	Đạt	Đạt
yellow	2024-12	3.668.371	194.567	3.473.804	Đạt	Đạt	Đạt
yellow	2025-01	3.475.226	258.850	3.216.376	Đạt	Đạt	Đạt
yellow	2025-02	3.577.543	303.748	3.273.795	Đạt	Đạt	Đạt
yellow	2025-03	4.145.257	355.884	3.789.373	Đạt	Đạt	Đạt
yellow	2025-04	3.970.553	336.621	3.633.932	Đạt	Đạt	Đạt
yellow	2025-05	4.591.845	543.777	4.048.068	Đạt	Đạt	Đạt
yellow	2025-06	4.322.960	495.800	3.827.160	Đạt	Đạt	Đạt
yellow	2025-07	3.898.963	443.803	3.455.160	Đạt	Đạt	Đạt
yellow	2025-08	3.574.091	433.097	3.140.994	Đạt	Đạt	Đạt
yellow	2025-09	4.251.015	454.770	3.796.245	Đạt	Đạt	Đạt
yellow	2025-10	4.428.699	528.595	3.900.104	Đạt	Đạt	Đạt
yellow	2025-11	4.181.444	578.276	3.603.168	Đạt	Đạt	Đạt
yellow	2025-12	4.305.006	299.182	4.005.824	Đạt	Đạt	Đạt

Nguồn: *t71_reconciliation.csv*.

H.5. Phả hệ chi tiết theo bước

Bảng H.6. Các bảng Gold mà mỗi bước đọc, ghi và số sản phẩm tạo ra

Bước	Đọc Gold	Ghi Gold	Bảng	Hình
00_download_data			0	0
01_bronze_catalog			3	0
02_zone_dimension		dim_zone, zone_adjacency, zone_polygons	2	0
03_silver_gold_month	company_grp_day, dim_zone, grp_hour_day, od_month, trip_sample, zone_day_do, zone_day_pu, zone_hour_month		0	0
04_gold Consolidate		company_grp_day, grp_hour_day, od_month, trip_sample, zone_day_do, zone_day_pu, zone_hour_month	3	0
05_benchmark			4	0
06_eda	company_grp_day, dim_zone, grp_hour_day, trip_sample, zone_day_pu, zone_polygons		20	14
07_did_main	dim_zone, od_month, zone_day_pu, zone_hour_month		8	4
08_synthetic_control	dim_zone, od_month, zone_day_pu, zone_hour_month		3	3
09_dml_heterogeneity	dim_zone, od_month, trip_sample, zone_day_pu, zone_hour_month	dml_od_dataset	8	4
10_spillover_robustness	dim_zone, od_month, zone_day_do, zone_day_pu, zone_hour_month		5	3
11_appendix_tables	dim_zone, grp_hour_day, od_month, zone_day_do, zone_day_pu, zone_hour_month		3	0
12_pipeline_figures	dim_zone		8	4
13_build_report			0	0
14_extra_analysis	dim_zone, grp_hour_day, od_month, trip_sample, zone_day_pu, zone_hour_month, zone_polygons		6	4
15_spark_pipeline	zone_day_pu		11	5
16_governance_risk	dim_zone, dml_od_dataset, grp_hour_day, od_month, trip_sample, zone_adjacency, zone_day_pu, zone_hour_month, zone_polygons		20	6

Nguồn: t69_lineage.csv.

H.6. Kế hoạch logic của truy vấn có cắt tỉa phân vùng

```
== Parsed Logical Plan ==
'Aggregate [pu], [pu, count(1) AS n#139L, sum(fare) AS fare#141]
+- Filter (((service#0 = hvfhv) AND (year#32 = 2025)) AND (month#33 = 3))
  +- Project [service#0, year#32, month#33, pu#5, d#23, fare#9]
    +- Relation
      [service#0,company_code#1,request_ts#2,pickup_ts#3,dropoff_ts#4,pu#5,dl#6,miles#7,time_s#8,fare#9,toll

== Analyzed Logical Plan ==
pu: int, n: bigint, fare: double
Aggregate [pu#5], [pu#5, count(1) AS n#139L, sum(fare#9) AS fare#141]
+- Filter (((service#0 = hvfhv) AND (year#32 = 2025)) AND (month#33 = 3))
  +- Project [service#0, year#32, month#33, pu#5, d#23, fare#9]
    +- Relation
      [service#0,company_code#1,request_ts#2,pickup_ts#3,dropoff_ts#4,pu#5,dl#6,miles#7,time_s#8,fare#9,toll

== Optimized Logical Plan ==
Aggregate [pu#5], [pu#5, count(1) AS n#139L, sum(fare#9) AS fare#141]
+- Project [pu#5, fare#9]
  +- Filter (((isnotnull(service#0) AND isnotnull(year#32)) AND isnotnull(month#33)) AND (((service#0 = hvfhv) AND (year#32 = 2025)) AND (month#33 = 3)))
    +- Relation
      [service#0,company_code#1,request_ts#2,pickup_ts#3,dropoff_ts#4,pu#5,dl#6,miles#7,time_s#8,fare#9,toll

== Physical Plan ==
AdaptiveSparkPlan isFinalPlan=true
+- == Final Plan ==
  *(2) HashAggregate(keys=[pu#5], functions=[count(1), sum(fare#9)], output=[pu#5, n#139L, fare#141])
    +- AQEShuffleRead coalesced
      +- ShuffleQueryStage 0
        +- Exchange hashpartitioning(pu#5, 8), ENSURE_REQUIREMENTS, [plan_id=178]
          +- *(1) HashAggregate(keys=[pu#5], functions=[partial_count(1), partial_sum(fare#9)], output=[pu#5, count#14])
            +- *(1) Project [pu#5, fare#9]
              +- *(1) ColumnarToRow
                +- FileScan parquet [pu#5,fare#9,service#0,year#32,month#33] Batched: true,
DataFilters: [], Format
+- == Initial Plan ==
  HashAggregate(keys=[pu#5], functions=[count(1), sum(fare#9)], output=[pu#5, n#139L, fare#141])
    +- Exchange hashpartitioning(pu#5, 8), ENSURE_REQUIREMENTS, [plan_id=160]
      +- HashAggregate(keys=[pu#5], functions=[partial_count(1), partial_sum(fare#9)], output=[pu#5, count#147L, sum#148])
        +- Project [pu#5, fare#9]
          +- FileScan parquet [pu#5,fare#9,service#0,year#32,month#33] Batched: true, DataFilters: [],
Format: Parquet
```

H.7. Kết quả cửa sổ giờ của Structured Streaming

Bảng H.7. Các cửa sổ 1 giờ do luồng phát ra (tổng ba hãng)

Giờ bắt đầu	Chuyến	Chạm CRZ	Có phí CBD	Phí (USD)
29/12 00:00	27.637	8.431	0	0,00
29/12 01:00	21.441	6.697	0	0,00
29/12 02:00	16.561	5.041	0	0,00
29/12 03:00	13.522	3.960	0	0,00
29/12 04:00	12.318	3.073	0	0,00
29/12 05:00	10.536	2.484	0	0,00
29/12 06:00	11.749	2.973	0	0,00
29/12 07:00	13.897	3.292	0	0,00
29/12 08:00	15.260	4.061	0	0,00
29/12 09:00	18.941	5.247	0	0,00
29/12 10:00	22.699	6.678	0	0,00
29/12 11:00	23.686	7.400	0	0,00
29/12 12:00	24.028	7.758	0	0,00
29/12 13:00	24.564	7.826	0	0,00
29/12 14:00	25.914	7.853	0	0,00
29/12 15:00	26.169	7.630	0	0,00
29/12 16:00	26.834	8.290	0	0,00
29/12 17:00	28.730	8.643	0	0,00
29/12 18:00	28.795	9.078	0	0,00
29/12 19:00	27.440	8.370	0	0,00

Giờ bắt đầu	Chuyến	Chạm CRZ	Có phí CBD	Phí (USD)
29/12 20:00	26.056	7.692	0	0,00
29/12 21:00	24.693	7.708	0	0,00
29/12 22:00	24.742	7.284	0	0,00
29/12 23:00	22.557	6.329	0	0,00
30/12 00:00	17.960	5.013	0	0,00
30/12 01:00	12.558	3.738	0	0,00
30/12 02:00	8.890	2.471	0	0,00
30/12 03:00	7.747	2.032	0	0,00
30/12 04:00	8.491	2.191	0	0,00
30/12 05:00	10.050	2.504	0	0,00
30/12 06:00	14.197	3.571	0	0,00
30/12 07:00	18.369	4.241	0	0,00
30/12 08:00	24.561	5.275	0	0,00
30/12 09:00	24.157	5.865	0	0,00
30/12 10:00	22.748	6.152	0	0,00
30/12 11:00	22.874	6.870	0	0,00
30/12 12:00	23.035	6.827	0	0,00
30/12 13:00	24.294	7.143	0	0,00
30/12 14:00	25.737	7.263	0	0,00
30/12 15:00	26.611	7.670	0	0,00
30/12 16:00	27.838	7.936	0	0,00
30/12 17:00	29.487	8.337	0	0,00
30/12 18:00	29.347	8.696	0	0,00
30/12 19:00	27.645	8.404	0	0,00
30/12 20:00	25.423	7.701	0	0,00
30/12 21:00	23.480	7.490	0	0,00
30/12 22:00	23.051	7.356	0	0,00
30/12 23:00	22.059	6.928	0	0,00
31/12 00:00	17.223	5.397	0	0,00
31/12 01:00	11.248	3.715	0	0,00
31/12 02:00	7.971	2.566	0	0,00
31/12 03:00	6.391	1.864	0	0,00
31/12 04:00	7.166	1.833	0	0,00
31/12 05:00	8.453	1.916	0	0,00
31/12 06:00	12.971	3.070	0	0,00
31/12 07:00	16.548	3.431	0	0,00
31/12 08:00	21.862	4.421	0	0,00
31/12 09:00	22.019	4.896	0	0,00
31/12 10:00	21.377	5.414	0	0,00
31/12 11:00	21.969	5.821	0	0,00
31/12 12:00	23.080	5.984	0	0,00
31/12 13:00	24.794	6.450	0	0,00
31/12 14:00	26.675	6.610	0	0,00
31/12 15:00	28.374	6.943	0	0,00
31/12 16:00	30.391	7.662	0	0,00
31/12 17:00	34.833	8.997	0	0,00
31/12 18:00	41.963	11.704	0	0,00
31/12 19:00	50.986	14.820	0	0,00
31/12 20:00	62.447	20.117	0	0,00
31/12 21:00	65.802	21.476	0	0,00
31/12 22:00	65.463	20.023	0	0,00
31/12 23:00	44.339	10.846	0	0,00
01/01 00:00	54.342	17.927	0	0,00
01/01 01:00	57.883	17.013	0	0,00
01/01 02:00	54.187	15.963	0	0,00
01/01 03:00	44.742	12.583	0	0,00
01/01 04:00	31.064	7.986	0	0,00

Giờ bắt đầu	Chuyến	Chạm CRZ	Có phí CBD	Phí (USD)
01/01 05:00	20.781	4.691	0	0,00
01/01 06:00	16.649	3.822	0	0,00
01/01 07:00	15.345	3.394	0	0,00
01/01 08:00	13.401	3.152	0	0,00
01/01 09:00	13.123	3.615	0	0,00
01/01 10:00	14.715	4.800	0	0,00
01/01 11:00	17.013	5.819	0	0,00
01/01 12:00	18.895	6.681	0	0,00
01/01 13:00	21.304	6.996	0	0,00
01/01 14:00	24.040	7.604	0	0,00
01/01 15:00	25.749	7.811	0	0,00
01/01 16:00	24.821	7.651	0	0,00
01/01 17:00	26.375	7.975	0	0,00
01/01 18:00	26.435	8.122	0	0,00
01/01 19:00	25.090	7.336	0	0,00
01/01 20:00	23.710	6.662	0	0,00
01/01 21:00	22.328	6.495	0	0,00
01/01 22:00	20.836	5.943	0	0,00
01/01 23:00	18.188	4.529	0	0,00
02/01 00:00	12.817	3.125	0	0,00
02/01 01:00	7.580	1.889	0	0,00
02/01 02:00	5.440	1.336	0	0,00
02/01 03:00	5.171	1.341	0	0,00
02/01 04:00	6.877	1.773	0	0,00
02/01 05:00	9.649	2.371	0	0,00
02/01 06:00	16.669	4.264	0	0,00
02/01 07:00	26.647	5.211	0	0,00
02/01 08:00	31.443	6.611	0	0,00
02/01 09:00	26.103	6.970	0	0,00
02/01 10:00	23.430	6.876	0	0,00
02/01 11:00	22.605	7.027	0	0,00
02/01 12:00	22.990	7.271	0	0,00
02/01 13:00	24.667	7.376	0	0,00
02/01 14:00	27.214	7.336	0	0,00
02/01 15:00	27.782	7.553	0	0,00
02/01 16:00	28.620	8.192	0	0,00
02/01 17:00	31.964	8.978	0	0,00
02/01 18:00	31.221	9.638	0	0,00
02/01 19:00	28.197	8.945	0	0,00
02/01 20:00	24.961	8.064	0	0,00
02/01 21:00	23.802	8.033	0	0,00
02/01 22:00	22.768	7.827	0	0,00
02/01 23:00	19.927	6.091	0	0,00
03/01 00:00	15.106	4.747	0	0,00
03/01 01:00	9.562	3.045	0	0,00
03/01 02:00	6.702	2.090	0	0,00
03/01 03:00	5.901	1.695	0	0,00
03/01 04:00	7.261	2.007	0	0,00
03/01 05:00	9.976	2.424	0	0,00
03/01 06:00	17.226	4.388	0	0,00
03/01 07:00	27.504	5.095	0	0,00
03/01 08:00	32.652	6.448	0	0,00
03/01 09:00	27.411	6.801	0	0,00
03/01 10:00	24.526	7.016	0	0,00
03/01 11:00	24.208	7.397	0	0,00
03/01 12:00	25.011	7.695	0	0,00
03/01 13:00	26.771	7.794	0	0,00

Giờ bắt đầu	Chuyến	Chạm CRZ	Có phí CBD	Phí (USD)
03/01 14:00	29.832	8.145	0	0,00
03/01 15:00	30.406	8.412	0	0,00
03/01 16:00	31.843	9.016	0	0,00
03/01 17:00	36.221	10.513	0	0,00
03/01 18:00	37.374	12.190	0	0,00
03/01 19:00	37.236	13.368	0	0,00
03/01 20:00	32.277	10.909	0	0,00
03/01 21:00	31.340	10.898	0	0,00
03/01 22:00	32.321	11.922	0	0,00
03/01 23:00	31.634	11.574	0	0,00
04/01 00:00	26.542	9.723	0	0,00
04/01 01:00	19.471	7.641	0	0,00
04/01 02:00	14.037	5.298	0	0,00
04/01 03:00	11.257	3.901	0	0,00
04/01 04:00	9.511	2.565	0	0,00
04/01 05:00	8.858	2.159	0	0,00
04/01 06:00	11.925	3.113	0	0,00
04/01 07:00	14.957	3.594	0	0,00
04/01 08:00	18.874	4.668	0	0,00
04/01 09:00	22.648	6.387	0	0,00
04/01 10:00	25.564	8.182	0	0,00
04/01 11:00	27.673	9.256	0	0,00
04/01 12:00	29.120	10.008	0	0,00
04/01 13:00	30.770	10.602	0	0,00
04/01 14:00	31.630	10.238	0	0,00
04/01 15:00	33.566	10.844	0	0,00
04/01 16:00	34.848	11.794	0	0,00
04/01 17:00	38.438	13.460	0	0,00
04/01 18:00	41.256	14.782	0	0,00
04/01 19:00	41.665	15.702	0	0,00
04/01 20:00	38.257	13.965	0	0,00
04/01 21:00	38.057	13.928	0	0,00
04/01 22:00	38.780	15.015	1	1,50
04/01 23:00	39.176	15.116	992	1.488,00
05/01 00:00	32.184	12.237	12.374	18.561,00
05/01 01:00	23.471	9.213	9.527	14.290,50
05/01 02:00	17.228	6.764	6.977	10.465,50
05/01 03:00	13.096	4.548	4.755	7.132,50
05/01 04:00	10.706	3.084	3.350	5.025,00
05/01 05:00	9.186	2.440	2.671	4.006,50
05/01 06:00	11.478	3.129	3.428	5.142,00
05/01 07:00	14.399	3.613	3.923	5.884,50
05/01 08:00	16.662	4.383	4.685	7.027,50
05/01 09:00	21.771	6.086	6.448	9.672,00
05/01 10:00	26.235	7.908	8.307	12.460,50
05/01 11:00	27.662	9.097	9.507	14.260,50
05/01 12:00	28.630	9.717	10.138	15.207,00
05/01 13:00	29.072	9.786	10.204	15.306,00
05/01 14:00	29.426	9.101	9.583	14.374,50
05/01 15:00	29.675	8.878	9.347	14.020,50
05/01 16:00	30.135	9.693	10.129	15.193,50
05/01 17:00	31.922	10.211	10.667	16.000,50
05/01 18:00	31.848	10.049	10.293	15.439,50
05/01 19:00	30.283	9.371	9.489	14.233,50
05/01 20:00	27.068	8.419	8.780	13.170,00
05/01 21:00	25.723	8.038	8.378	12.567,00
05/01 22:00	23.492	7.049	7.348	11.022,00

Giờ bắt đầu	Chuyến	Chạm CRZ	Có phí CBD	Phí (USD)
05/01 23:00	20.653	5.751	6.055	9.082,50
06/01 00:00	13.751	3.650	3.800	5.700,00
06/01 01:00	7.604	1.943	2.038	3.057,00
06/01 02:00	5.188	1.293	1.354	2.031,00
06/01 03:00	4.869	1.184	1.258	1.887,00
06/01 04:00	7.046	1.758	1.930	2.895,00
06/01 05:00	10.888	2.839	3.146	4.719,00
06/01 06:00	19.592	5.471	5.921	8.881,50
06/01 07:00	31.784	7.613	8.075	12.112,50
06/01 08:00	39.594	10.028	10.428	15.642,00
06/01 09:00	30.750	8.676	9.025	13.537,50
06/01 10:00	25.996	7.358	7.711	11.566,50
06/01 11:00	24.176	7.192	7.520	11.280,00
06/01 12:00	24.917	7.403	7.731	11.596,50
06/01 13:00	26.202	7.318	7.643	11.464,50
06/01 14:00	28.470	7.094	7.491	11.236,50
06/01 15:00	28.346	7.107	7.533	11.299,50
06/01 16:00	29.192	7.605	7.993	11.989,50
06/01 17:00	33.635	9.487	9.919	14.878,50
06/01 18:00	32.368	10.224	10.506	15.759,00
06/01 19:00	28.122	9.053	9.118	13.677,00
06/01 20:00	25.616	9.135	9.447	14.170,50
06/01 21:00	23.966	8.955	9.257	13.885,50
06/01 22:00	22.087	7.483	7.751	11.626,50
06/01 23:00	18.286	5.418	5.630	8.445,00
07/01 00:00	12.872	3.694	3.863	5.794,50
07/01 01:00	7.203	2.029	2.113	3.169,50
07/01 02:00	4.691	1.282	1.349	2.023,50
07/01 03:00	4.210	998	1.071	1.606,50
07/01 04:00	6.563	1.771	1.911	2.866,50
07/01 05:00	10.466	2.816	3.081	4.621,50
07/01 06:00	19.697	5.601	6.004	9.006,00
07/01 07:00	33.840	8.360	8.774	13.161,00
07/01 08:00	42.530	11.561	11.901	17.851,50
07/01 09:00	33.557	10.255	10.615	15.922,50
07/01 10:00	27.228	8.069	8.425	12.637,50
07/01 11:00	24.947	7.773	8.090	12.135,00
07/01 12:00	24.819	7.433	7.786	11.679,00
07/01 13:00	25.792	7.454	7.756	11.634,00
07/01 14:00	29.985	7.655	8.053	12.079,50
07/01 15:00	31.210	8.237	8.675	13.012,50
07/01 16:00	32.027	8.950	9.330	13.995,00
07/01 17:00	38.896	11.745	12.187	18.280,50
07/01 18:00	37.771	12.563	12.815	19.222,50
07/01 19:00	33.248	11.296	11.189	16.783,50
07/01 20:00	30.340	11.597	11.978	17.967,00
07/01 21:00	28.288	11.363	11.689	17.533,50
07/01 22:00	25.401	9.660	9.965	14.947,50
07/01 23:00	20.084	6.697	6.988	10.482,00
08/01 00:00	13.162	4.248	4.404	6.606,00
08/01 01:00	7.495	2.448	2.529	3.793,50
08/01 02:00	4.747	1.434	1.486	2.229,00
08/01 03:00	4.473	1.135	1.215	1.822,50
08/01 04:00	6.332	1.679	1.815	2.722,50
08/01 05:00	10.621	2.888	3.149	4.723,50
08/01 06:00	20.369	5.797	6.222	9.333,00
08/01 07:00	34.931	8.620	9.077	13.615,50

Giờ bắt đầu	Chuyến	Chạm CRZ	Có phí CBD	Phí (USD)
08/01 08:00	43.881	12.151	12.519	18.778,50
08/01 09:00	34.282	10.883	11.263	16.894,50
08/01 10:00	27.302	8.463	8.797	13.195,50
08/01 11:00	25.276	8.218	8.524	12.786,00
08/01 12:00	25.183	7.752	8.120	12.180,00
08/01 13:00	26.620	7.792	8.154	12.231,00
08/01 14:00	30.694	7.957	8.360	12.540,00
08/01 15:00	30.968	8.320	8.753	13.129,50
08/01 16:00	33.542	9.520	9.973	14.959,50
08/01 17:00	41.119	12.665	13.205	19.807,50
08/01 18:00	41.704	14.123	14.400	21.600,00
08/01 19:00	37.010	13.222	13.096	19.644,00
08/01 20:00	33.426	13.212	13.629	20.443,50
08/01 21:00	31.324	12.720	13.096	19.644,00
08/01 22:00	28.631	11.113	11.486	17.229,00
08/01 23:00	23.146	8.179	8.413	12.619,50
09/01 00:00	15.373	5.370	5.554	8.331,00
09/01 01:00	8.485	2.924	3.023	4.534,50
09/01 02:00	5.549	1.901	1.976	2.964,00
09/01 03:00	5.150	1.490	1.577	2.365,50
09/01 04:00	7.120	2.117	2.284	3.426,00
09/01 05:00	11.396	3.071	3.359	5.038,50
09/01 06:00	21.017	5.821	6.235	9.352,50
09/01 07:00	35.789	8.452	8.931	13.396,50
09/01 08:00	45.290	12.307	12.725	19.087,50
09/01 09:00	36.000	11.459	11.814	17.721,00
09/01 10:00	29.365	9.316	9.651	14.476,50
09/01 11:00	27.395	8.799	9.139	13.708,50
09/01 12:00	27.079	8.725	9.064	13.596,00
09/01 13:00	28.421	8.678	9.043	13.564,50
09/01 14:00	32.902	9.039	9.458	14.187,00
09/01 15:00	33.849	9.657	10.192	15.288,00
09/01 16:00	35.762	10.460	10.939	16.408,50
09/01 17:00	43.271	13.525	14.109	21.163,50
09/01 18:00	43.861	15.593	15.889	23.833,50
09/01 19:00	39.702	14.866	14.816	22.224,00
09/01 20:00	35.644	14.151	14.688	22.032,00
09/01 21:00	33.580	14.024	14.496	21.744,00
09/01 22:00	31.099	12.584	13.047	19.570,50
09/01 23:00	27.140	10.658	11.165	16.747,50
10/01 00:00	18.846	7.249	7.535	11.302,50
10/01 01:00	11.130	4.562	4.696	7.044,00
10/01 02:00	7.320	2.876	2.984	4.476,00
10/01 03:00	6.233	2.106	2.194	3.291,00
10/01 04:00	8.221	2.505	2.670	4.005,00
10/01 05:00	11.657	3.343	3.629	5.443,50
10/01 06:00	20.530	5.673	6.100	9.150,00
10/01 07:00	34.234	7.880	8.383	12.574,50
10/01 08:00	41.581	10.059	10.472	15.708,00
10/01 09:00	32.608	9.389	9.750	14.625,00
10/01 10:00	27.702	8.456	8.802	13.203,00
10/01 11:00	26.347	8.271	8.604	12.906,00
10/01 12:00	27.386	8.533	8.880	13.320,00
10/01 13:00	28.506	8.362	8.757	13.135,50
10/01 14:00	32.154	8.849	9.260	13.890,00
10/01 15:00	33.188	9.418	9.886	14.829,00
10/01 16:00	34.735	10.119	10.587	15.880,50

Giờ bắt đầu	Chuyến	Chạm CRZ	Có phí CBD	Phí (USD)
10/01 17:00	41.031	12.990	13.593	20.389,50
10/01 18:00	44.742	16.281	16.607	24.910,50
10/01 19:00	44.453	17.175	17.222	25.833,00
10/01 20:00	38.833	15.190	15.659	23.488,50
10/01 21:00	37.518	14.967	15.434	23.151,00
10/01 22:00	39.213	16.070	16.675	25.012,50
10/01 23:00	39.692	16.148	16.750	25.125,00
11/01 00:00	32.236	13.097	13.578	20.367,00
11/01 01:00	24.219	10.449	10.780	16.170,00
11/01 02:00	18.090	7.641	7.931	11.896,50
11/01 03:00	13.807	5.454	5.677	8.515,50
11/01 04:00	11.322	3.342	3.571	5.356,50
11/01 05:00	10.052	2.670	2.960	4.440,00
11/01 06:00	13.022	3.469	3.782	5.673,00
11/01 07:00	17.212	4.427	4.822	7.233,00
11/01 08:00	21.035	5.533	5.874	8.811,00
11/01 09:00	25.571	7.327	7.759	11.638,50
11/01 10:00	27.826	9.282	9.688	14.532,00
11/01 11:00	30.057	10.621	11.041	16.561,50
11/01 12:00	31.731	11.700	12.202	18.303,00
11/01 13:00	32.734	11.905	12.379	18.568,50
11/01 14:00	33.218	11.381	11.877	17.815,50
11/01 15:00	34.961	12.238	12.747	19.120,50
11/01 16:00	37.444	14.245	14.811	22.216,50
11/01 17:00	41.144	15.921	16.510	24.765,00
11/01 18:00	45.252	17.813	18.273	27.409,50
11/01 19:00	47.464	19.456	19.529	29.293,50
11/01 20:00	44.128	17.684	18.213	27.319,50

Nguồn: t67b_stream_hourly.csv.

PHỤ LỤC I. MÃ NGUỒN

Phụ lục này in toàn bộ mã nguồn của pipeline và phân tích (không gồm mã dựng báo cáo). Mã nguồn đồng thời được nộp dưới dạng tệp trong thư mục code/.

I.1. config.py

```
"""Cấu hình chung cho toàn bộ pipeline đồ án.

Mọi đường dẫn đều tính tương đối so với thư mục gốc của đồ án
(thư mục cha của thư mục code/), vì vậy có thể chép nguyên thư mục
CongestionPricing_CaseStudy sang máy khác và chạy lại.
"""

from pathlib import Path
import datetime as dt

ROOT = Path(__file__).resolve().parent.parent
RAW = ROOT / "data" / "raw"
BRONZE = ROOT / "data" / "bronze"
SILVER = ROOT / "data" / "silver"
GOLD = ROOT / "data" / "gold"
OUT = ROOT / "outputs"
FIG = OUT / "figures"
TAB = OUT / "tables"
LOG = OUT / "logs"
for p in (BRONZE, SILVER, GOLD, FIG, TAB, LOG):
    p.mkdir(parents=True, exist_ok=True)

# Giai đoạn nghiên cứu: 24 tháng, 12 tháng trước và 12 tháng sau chính sách
MONTHS = [f"{y}-{m:02d}" for y in (2024, 2025) for m in range(1, 13)]
# Giai đoạn trước chính sách mở rộng (bước 03 ext, 04 ext, 19): chỉ dùng cho các phân tích dài hạn,
# không làm thay đổi các bảng Gold chính của giai đoạn 2024-2025.
MONTHS_EXT = [f"{y}-{m:02d}" for y in (2022, 2023) for m in range(1, 13)]

def is_ext(ym: str) -> bool:
    return ym[:4] in ("2022", "2023")
SERVICES = ("hvfhv", "yellow")

# Ngày bắt đầu thu phí vùng giảm ùn tắc (Congestion Relief Zone toll)
POLICY_DATE = dt.date(2025, 1, 5)
POLICY_TS = "2025-01-05 00:00:00"

# Mã giấy phép của các hãng gọi xe (High Volume For-Hire Services)
HVFHS_COMPANY = {"HV0002": "Juno", "HV0003": "Uber", "HV0004": "Vía", "HV0005": "Lyft"}

# Ngưỡng làm sạch dữ liệu (áp dụng ở lớp Silver)
CLEAN = dict(
    min_miles=0.0,          # quãng đường phải > 0
    max_miles=100.0,        # loại chuyển > 100 dặm
    min_time_s=60,          # loại chuyển < 1 phút
    max_time_s=4 * 3600,    # loại chuyển > 4 giờ
    max_speed_mph=80.0,     # loại chuyển có tốc độ trung bình > 80 mph
    min_fare=0.0,           # giá cước phải > 0
    max_fare=1000.0,        # loại giá cước > 1000 USD
    max_wait_min=120.0,     # thời gian chờ hợp lệ 0..120 phút
)

# Ngưỡng phân loại vùng theo tỷ lệ chuyển nội vùng bị thu phí CBD
CRZ_FULL_SHARE = 0.90      # >= 90%: vùng nằm trọn trong vùng thu phí
CRZ_PARTIAL_SHARE = 0.10   # 10%..90%: vùng nằm vắt qua ranh giới
AIRPORT_ZONES = (1, 132, 138) # EWR, JFK, LaGuardia

DUCKDB_SETTINGS = {"memory_limit": "1800MB", "threads": 2,
                   "preserve_insertion_order": False}
SEED = 20250105

def duck():
    """Tạo kết nối DuckDB với cấu hình giới hạn bộ nhớ (chạy được trên máy RAM thấp)."""
    import duckdb
    con = duckdb.connect()
    for k, v in DUCKDB_SETTINGS.items():
        con.execute(f"SET {k}='{v}'" if isinstance(v, str) else f"SET {k}={v}")
    import os
    # Thư mục trên đĩa của DuckDB; có thể trở ra ổ cục bộ bằng DUCKDB_TMP nếu thư mục dự án không
    # cho xóa tệp.
    tmp = Path(os.environ.get("DUCKDB_TMP", ROOT / "data" / "_duckdb_tmp"))
    tmp.mkdir(exist_ok=True)
```



```

con.execute(f"SET temp_directory='{tmp.as_posix()}'")
return con

def raw_file(service: str, ym: str) -> Path:
    name = "fhvhv" if service == "hvfhv" else "yellow"
    return RAW / f"{name}_tripdata_{ym}.parquet"

def silver_file(service: str, ym: str) -> Path:
    y, m = ym.split("-")
    p = SILVER / f"service={service}" / f"year={y}" / f"month={m}"
    p.mkdir(parents=True, exist_ok=True)
    return p / "part-0.parquet"

def gold_part(table: str, service: str, ym: str) -> Path:
    p = GOLD / ("_parts_ext" if is_ext(ym) else "_parts") / table
    p.mkdir(parents=True, exist_ok=True)
    return p / f"{service}_{ym}.parquet"

```

I.2. 00_download_data.py

"""Bước 0 - Tải dữ liệu thô từ NYC TLC về data/raw (bỏ qua tệp đã có).

Nguồn: <https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>
Tệp: fhvhv_tripdata_YYYY-MM.parquet và yellow_tripdata_YYYY-MM.parquet
cho 01/2024-12/2025, cùng taxi_zone_lookup.csv và taxi_zones.zip.
Tổng dung lượng khoảng 12,6 GB.

Chạy: python code/00_download_data.py

```

"""
import urllib.request

from config import MONTHS, RAW

BASE = "https://d37ci6vzurychx.cloudfront.net"
urls = [f"{BASE}/misc/taxi_zone_lookup.csv", f"{BASE}/misc/taxi_zones.zip"]
for ym in MONTHS:
    urls += [f"{BASE}/trip-data/fhvhv_tripdata_{ym}.parquet",
f"{BASE}/trip-data/yellow_tripdata_{ym}.parquet"]

RAW.mkdir(parents=True, exist_ok=True)
for u in urls:
    dst = RAW / u.rsplit("/", 1)[-1]
    if dst.exists() and dst.stat().st_size > 0:
        continue
    print("Tải", u, flush=True)
    tmp = dst.with_suffix(dst.suffix + ".part")
    urllib.request.urlretrieve(u, tmp)
    tmp.rename(dst)
print("Đủ", len(list(RAW.glob('*.*parquet'))), "tệp parquet")

```

I.3. 01_bronze_catalog.py

"""Bước 1 - Lớp Bronze: lập danh mục (catalog) cho dữ liệu thô.

Dữ liệu thô là các tệp Parquet gốc của NYC TLC, giữ nguyên, không sửa (nguyên tắc bất biến của lớp Bronze). Bước này đọc metadata của từng tệp (không đọc toàn bộ dữ liệu) để ghi lại: kích thước, số dòng, số row group, lược đồ cột, dấu vân tay lược đồ và khoảng thời gian thực tế trong tệp. Kết quả dùng để phát hiện lệch lược đồ (schema drift) giữa các tháng.

Chạy: python code/01_bronze_catalog.py (giai đoạn chính 2024-2025)
python code/01_bronze_catalog.py ext (giai đoạn mở rộng 2022-2023, ghi t01x-t03x)

```

"""
import sys
import hashlib
import json
import time

import pandas as pd
import pyarrow.parquet as pq

from config import MONTHS, MONTHS_EXT, SERVICES, raw_file, BRONZE, TAB, LOG, duck

EXT = len(sys.argv) > 1 and sys.argv[1] == "ext"
if EXT:
    MONTHS = MONTHS_EXT
SFX = "x" if EXT else ""

```

```

t0 = time.time()
con = duck()
rows = []
schemas = {}
for svc in SERVICES:
    ts_col = "pickup_datetime" if svc == "hvhfv" else "tpep_pickup_datetime"
    for ym in MONTHS:
        f = raw_file(svc, ym)
        meta = pq.ParquetFile(f).metadata
        sch = pq.read_schema(f)
        cols = [(n, str(t)) for n, t in zip(sch.names, sch.types)]
        fp = hashlib.md5(json.dumps(cols).encode()).hexdigest()[:10]
        schemas.setdefault(svc, {})[ym] = cols
        mn, mx = con.execute(f"SELECT min({ts_col}), max({ts_col}) FROM
'f.as_posix()}'").fetchone()
        comp = meta.row_group(0).column(0).compression if meta.num_row_groups else ""
        rows.append(dict(service=svc, month=ym, file=f.name,
                        size_mb=round(f.stat().st_size / 2**20, 1),
                        n_rows=meta.num_rows, n_row_groups=meta.num_row_groups,
                        n_columns=meta.num_columns, compression=comp,
                        schema_fingerprint=fp, min_pickup=str(mn), max_pickup=str(mx),
                        created_by=meta.created_by))
    print(svc, ym, meta.num_rows, flush=True)

man = pd.DataFrame(rows)
man.to_csv(TAB / f"t01{SFX}_bronze_manifest{'_ext' if EXT else ''}.csv", index=False)
man.to_parquet(BRONZE / f"bronze_manifest{'_ext' if EXT else ''}.parquet", index=False)

# Phát hiện lệch lược đồ: so cột của từng tháng với tháng đầu tiên
drift = []
for svc, d in schemas.items():
    base = dict(d[MONTHS[0]])
    for ym, cols in d.items():
        cur = dict(cols)
        added = sorted(set(cur) - set(base))
        removed = sorted(set(base) - set(cur))
        changed = sorted(c for c in set(cur) & set(base) if cur[c] != base[c])
        if added or removed or changed:
            drift.append(dict(service=svc, month=ym, added=";".join(added),
                            removed=";".join(removed), type_changed=";".join(changed)))
pd.DataFrame(drift).to_csv(TAB / f"t02{SFX}_schema_drift{'_ext' if EXT else ''}.csv", index=False)

summary = man.groupby("service").agg(files=("file", "count"), total_rows=("n_rows", "sum"),
                                     total_size_mb=("size_mb", "sum")).reset_index()
summary.to_csv(TAB / f"t03{SFX}_bronze_summary{'_ext' if EXT else ''}.csv", index=False)
(LOG / f"t01_bronze_catalog{'_ext' if EXT else ''}.json").write_text(json.dumps(
    dict(seconds=round(time.time() - t0, 1), files=len(man),
         total_rows=int(man.n_rows.sum()), total_mb=float(man.size_mb.sum()), indent=2))
print(summary)
print("drift rows:", len(drift), "time", round(time.time() - t0, 1))

```

I.4. 02_zone_dimension.py

""""Bước 2 - Bảng chiều vùng (zone dimension) và xác định vùng xử lý.

Không gán tay danh sách vùng thu phí. Vùng được phân loại bằng dữ liệu: với các chuyến có điểm đón và điểm trả cùng một vùng (chuyến nội vùng) trong quý I/2025, nếu phần lớn chuyến bị thu `cbd.congestion_fee` thì vùng đó nằm trong Congestion Relief Zone (CRZ). Cách làm này tránh sai sót khi ranh giới đường 60 cắt ngang một số vùng taxi.

Ngoài ra, bước này đọc shapefile `taxi_zones` để tính diện tích, tâm vùng, quan hệ kề nhau và khoảng cách tới ranh giới CRZ (phục vụ phân tích lan tỏa).

```

Chạy: python code/02_zone_dimension.py
"""
import io
import json
import time
import zipfile

import numpy as np
import pandas as pd
import shapefile  # pyshp
from shapely.geometry import shape
from shapely.ops import unary_union

from config import (RAW, GOLD, TAB, LOG, AIRPORT_ZONES, CRZ_FULL_SHARE,
                   CRZ_PARTIAL_SHARE, raw_file, duck)

t0 = time.time()
con = duck()

```

```

lk = pd.read_csv(RAW / "taxi_zone_lookup.csv")

share = {}
for svc in ("hvfhv", "yellow"):
    files = ", ".join(f"'{raw_file}(svc, m).as_posix()'" for m in ("2025-01", "2025-02", "2025-03"))
    ts = "pickup_datetime" if svc == "hvfhv" else "tpep_pickup_datetime"
    q = f"""SELECT PULocationID AS LocationID, count(*) AS n_intra,
        avg(CASE WHEN coalesce(cbd_congestion_fee,0) > 0 THEN 1 ELSE 0 END) AS fee_share
    FROM read_parquet([{files}])
    WHERE PULocationID = DOLocationID AND {ts} >= TIMESTAMP '2025-01-05'
    GROUP BY 1"""
    share[svc] = con.execute(q).df().rename(columns={"n_intra": f"n_intra_{svc}",
                                                    "fee_share": f"fee_share_{svc}"})

z = lk.merge(share["hvfhv"], on="LocationID", how="left").merge(share["yellow"], on="LocationID",
how="left")

def classify(r):
    if r.LocationID in (264, 265) or pd.isna(r.Borough) or r.Borough in ("Unknown", "N/A"):
        return "UNKNOWN"
    if r.LocationID in AIRPORT_ZONES:
        return "AIRPORT"
    s = r.fee_share_hvfhv if not pd.isna(r.fee_share_hvfhv) else 0.0
    if s >= CRZ_FULL_SHARE:
        return "CRZ"
    if s >= CRZ_PARTIAL_SHARE:
        return "CRZ_PARTIAL"
    if r.Borough == "Manhattan":
        return "MN_NORTH"
    return "OUTER"

z["grp"] = z.apply(classify, axis=1)

# --- Hình học vùng từ shapefile (hệ tọa độ NY State Plane, đơn vị feet) ---
zf = zipfile.ZipFile(RAW / "taxi_zones.zip")
names = zf.namelist()

def member(ext):
    return [n for n in names if n.lower().endswith(ext)][0]

rdr = shapefile.Reader(shp=io.BytesIO(zf.read(member(".shp"))),
                        shx=io.BytesIO(zf.read(member(".shx"))),
                        dbf=io.BytesIO(zf.read(member(".dbf"))))
fields = [f[0] for f in rdr.fields[1:]]
geoms = {}
for sr in rdr.shapeRecords():
    rec = dict(zip(fields, sr.record))
    lid = int(rec.get("LocationID") or rec.get("OBJECTID"))
    g = shape(sr.shape.__geo_interface__).buffer(0)
    geoms[lid] = unary_union([geoms[lid], g]) if lid in geoms else g
FT2KM = 0.0003048
crz_union = unary_union([geoms[i] for i in z.loc[z.grp == "CRZ", "LocationID"] if i in geoms])

geo = []
for lid, g in geoms.items():
    c = g.centroid
    geo.append(dict(LocationID=lid, area_km2=g.area * FT2KM ** 2, cx_ft=c.x, cy_ft=c.y,
                    dist_to_crz_km=g.distance(crz_union) * FT2KM,
                    centroid_dist_crz_km=c.distance(crz_union) * FT2KM))
geo = pd.DataFrame(geo)
z = z.merge(geo, on="LocationID", how="left")

# Quan hệ kề: hai vùng chạm nhau hoặc cách nhau < 200 feet (qua đường/phố)
ids = sorted(geoms)
adj = []
for i, a in enumerate(ids):
    ga = geoms[a]
    for b in ids[i + 1:]:
        if ga.distance(geoms[b]) < 200:
            adj.append((a, b))
adj_df = pd.DataFrame(adj, columns=["a", "b"])
adj_df = pd.concat([adj_df, adj_df.rename(columns={"a": "b", "b": "a"})], ignore_index=True)
adj_df.to_csv(GOLD / "zone_adjacency.csv", index=False)
z["n_neighbors"] = z.LocationID.map(adj_df.groupby("a").size()).fillna(0).astype(int)

# Vành đai theo số bước kề tính từ CRZ (0 = trong CRZ)
ring = {int(i): 0 for i in z.loc[z.grp == "CRZ", "LocationID"]}
frontier = set(ring)
nb = adj_df.groupby("a")["b"].apply(set).to_dict()
for k in range(1, 6):
    new = set()

```

```

        for u in frontier:
            for v in nb.get(u, ()):
                if v not in ring:
                    ring[v] = k
                    new.add(v)
        frontier = new
z["ring"] = z.LocationID.map(ring)
z["crz_flag"] = (z.grp == "CRZ").astype(int)
z.to_parquet(GOLD / "dim_zone.parquet", index=False)
z.to_csv(TAB / "t04_dim_zone.csv", index=False)

# Lưu hình học dạng tọa độ để vẽ bản đồ (không cần geopandas)
poly = []
for lid, g in geoms.items():
    parts = g.geoms if g.geom_type == "MultiPolygon" else [g]
    for k, p in enumerate(parts):
        xs, ys = p.exterior.coords.xy
        poly += [dict(LocationID=lid, part=k, order=j, x=x, y=y)
                  for j, (x, y) in enumerate(zip(xs[::2], ys[::2]))]
pd.DataFrame(poly).to_parquet(GOLD / "zone_polygons.parquet", index=False)

cnt = z.groupby(["grp", "Borough"]).size().reset_index(name="n_zones")
cnt.to_csv(TAB / "t05_zone_groups.csv", index=False)
(LOG / "02_zone_dimension.json").write_text(json.dumps(dict(
    seconds=round(time.time() - t0, 1), n_zones=len(z),
    groups=z.grp.value_counts().to_dict(), n_adjacent_pairs=len(adj)), indent=2))
print(z.grp.value_counts())
print(z[z.grp.isin(["CRZ_PARTIAL"])]["LocationID", "Zone", "fee_share_hvfhv", "fee_share_yellow"])
print("time", round(time.time() - t0, 1))

```

I.5. 03_silver_gold_month.py

""""Bước 3 - Lọc Silver và các phân vùng Gold theo tháng (xử lý tăng dần).

Mỗi lần chạy xử lý một cặp (dịch vụ, tháng):

1. Đọc tệp Bronze, chuẩn hóa lược đồ chung cho HVFHV và Yellow Taxi.
2. Gắn cờ chất lượng cho từng chuyến và đếm số chuyến vi phạm từng quy tắc.
3. Ghi các chuyến hợp lệ ra Silver (Parquet ZSTD, phân vùng service=/year=/month=).
4. Từ Silver, tính các bảng tổng hợp Gold của tháng đó.

Thiết kế theo tháng giúp pipeline chạy lại được từng phần (idempotent) và chạy được trên máy chỉ có khoảng 3 GB RAM.

Chạy: python code/03_silver_gold_month.py hvfhv 2024-01 0 (khúc 0 của tháng)
python code/03_silver_gold_month.py all (chạy hết mọi phân vùng còn thiếu)
python code/03_silver_gold_month.py ext (giai đoạn mở rộng 2022-2023)

```

import json
import os
import sys
import time

```

```

from config import (CLEAN, GOLD, LOG, MONTHS, MONTHS_EXT, SERVICES, SEED, duck,
                    gold_part, is_ext, raw_file, silver_file)

```

```

def month_bounds(ym):
    y, m = map(int, ym.split("-"))
    ny, nm = (y + 1, 1) if m == 12 else (y, m + 1)
    return f"{y}-{m:02d}-01", f"{ny}-{nm:02d}-01"

```

```

def std_select(svc, f, ym):
    """Chuẩn hóa về lược đồ chung. Cột không có ở một nguồn được gán NULL/0."""
    has_cbd = ym >= "2025-01"
    # 0.0::DOUBLE (không phải hằng số DECIMAL) để mọi phân vùng có cùng kiểu cột phí (xem mục 5.2 của báo cáo)
    cbd = "coalesce(cbd_congestion_fee,0)" if has_cbd else "0.0::DOUBLE"
    if svc == "hvfhv":
        return f"""
        SELECT 'hvfhv' AS service, hvfhs_license_num AS company_code,
        request_datetime AS request_ts, pickup_datetime AS pickup_ts,
        dropoff_datetime AS dropoff_ts, PULocationID::INTEGER AS pu, DOLocationID::INTEGER AS
dl,
        trip_miles AS miles, trip_time::DOUBLE AS time_s,
        base_passenger_fare AS fare, coalesce(tolls,0) AS tolls,
        coalesce(bcf,0) AS bcf, coalesce(sales_tax,0) AS tax,
        coalesce(congestion_surcharge,0) AS cong_sur,
        coalesce(airport_fee,0) AS airport_fee, {cbd} AS cbd_fee,
        coalesce(tips,0) AS tips, driver_pay,
        (shared_request_flag = 'Y')::INT AS shared_req,
        (shared_match_flag = 'Y')::INT AS shared_match,
        (wav_request_flag = 'Y')::INT AS wav_req,

```

```

        NULL::DOUBLE AS total_amount, NULL::INT AS payment_type
    FROM read_parquet('{f}')"""
    return f"""
    SELECT 'yellow' AS service, 'YELLOW' AS company_code,
        NULL::TIMESTAMP AS request_ts, tpep_pickup_datetime AS pickup_ts,
        tpep_dropoff_datetime AS dropoff_ts, PULocationID::INTEGER AS pu,
DOLocationID::INTEGER AS dl,
        trip_distance AS miles,
        date_diff('second', tpep_pickup_datetime, tpep_dropoff_datetime)::DOUBLE AS time_s,
        fare_amount AS fare, coalesce(tolls_amount,0) AS tolls, 0.0 AS bcf,
        coalesce(mta_tax,0) AS tax, coalesce(congestion_surcharge,0) AS cong_sur,
        coalesce(Airport_fee,0) AS airport_fee, {cbd} AS cbd_fee,
        coalesce(tip_amount,0) AS tips, NULL::DOUBLE AS driver_pay,
        0 AS shared_req, 0 AS shared_match, 0 AS wav_req,
        total_amount, payment_type::INT AS payment_type
    FROM read_parquet('{f}')"""

def chunk_filter(ym, k, n):
    """Chia một tháng thành n khúc theo ngày đón khách để mỗi lần xử lý vừa bộ nhớ.
    Khúc cuối nhận thêm các dòng có thời điểm ngoài tháng/NULL để chúng vẫn được gán cò."""
    lo, hi = month_bounds(ym)
    if n == 1:
        return "TRUE"
    y, m = map(int, ym.split("-"))
    step = {4: 8, 6: 5}.get(n, 28 // n) # 4 khúc: ngày 1, 9, 17, 25; 6 khúc: ngày 1, 6, 11, 16,
21, 26
    cuts = [f"{y}-{m:02d}-{1 + step * i:02d}" for i in range(n)] + [hi]
    a, b = cuts[k], cuts[k + 1]
    if k < n - 1:
        return f"pickup_ts >= TIMESTAMP '{a}' AND pickup_ts < TIMESTAMP '{b}'"
    return f"(pickup_ts IS NULL OR pickup_ts >= TIMESTAMP '{a}' OR pickup_ts < TIMESTAMP '{lo}')"

N_CHUNKS = {"hvfhv": 4, "yellow": 1}

def n_chunks_for(svc, ym):
    """Số khúc mỗi tháng. Từ HVFHV 08/2022 của giai đoạn mở rộng dùng 6 khúc để mỗi khúc chắc chắn
    xong trong giới hạn thời gian của môi trường chạy (máy đồng thời đang tải dữ liệu)."""
    if svc == "hvfhv" and is_ext(ym) and ym >= "2022-08":
        return 6
    return N_CHUNKS[svc]

def run(svc, ym, k=0):
    t0 = time.time()
    n_chunks = n_chunks_for(svc, ym)
    tag = f"{svc}_{ym}_c{k}"
    con = duck()
    lo, hi = month_bounds(ym)
    f = raw_file(svc, ym).as_posix()
    dim = (GOLD / "dim_zone.parquet").as_posix()
    c = CLEAN
    con.execute(f"CREATE TEMP TABLE z AS SELECT LocationID, grp FROM '{dim}'")
    con.execute(f"CREATE TEMP VIEW std AS SELECT * FROM ({std_select(svc, f, ym)}) "
        f"WHERE {chunk_filter(ym, k, n_chunks)}")
    # Cờ chất lượng: mỗi quy tắc một cột 0/1
    con.execute(f"""
    CREATE TEMP VIEW flagged AS
    SELECT *,
        (pickup_ts < TIMESTAMP '{lo}' OR pickup_ts >= TIMESTAMP '{hi}' OR pickup_ts IS NULL)::INT AS
q_out_of_month,
        (pu IS NULL OR dl IS NULL OR pu NOT BETWEEN 1 AND 263 OR dl NOT BETWEEN 1 AND 263)::INT AS
q_bad_zone,
        (miles IS NULL OR miles <= {c['min_miles']} OR miles > {c['max_miles']})::INT AS q_bad_miles,
        (time_s IS NULL OR time_s < {c['min_time_s']} OR time_s > {c['max_time_s']})::INT AS
q_bad_time,
        (fare IS NULL OR fare <= {c['min_fare']} OR fare > {c['max_fare']})::INT AS q_bad_fare,
        (CASE WHEN time_s > 0 AND miles / (time_s/3600.0) > {c['max_speed_mph']} THEN 1 ELSE 0 END) AS
q_bad_speed,
        (CASE WHEN service='hvfhv' AND (driver_pay IS NULL OR driver_pay < 0) THEN 1 ELSE 0 END) AS
q_bad_pay
    FROM std""")
    q = con.execute("""
    SELECT count(*) n_raw, sum(q_out_of_month) q_out_of_month, sum(q_bad_zone) q_bad_zone,
        sum(q_bad_miles) q_bad_miles, sum(q_bad_time) q_bad_time, sum(q_bad_fare) q_bad_fare,
        sum(q_bad_speed) q_bad_speed, sum(q_bad_pay) q_bad_pay,
        sum(CASE WHEN
q_out_of_month+q_bad_zone+q_bad_miles+q_bad_time+q_bad_fare+q_bad_speed+q_bad_pay>0
        THEN 1 ELSE 0 END) n_rejected
    FROM flagged""").df().iloc[0].to_dict()
    q = {k: int(v) for k, v in q.items()}
    t_quality = time.time() - t0

```

```

# Giai đoạn mở rộng từ HVFHV 08/2022: không ghi lớp Silver xuống đĩa (Bronze vẫn giữ nguyên nên
dùng lại
# được bất cứ lúc nào); bảng chuyển đã làm sạch chỉ nằm trong bộ nhớ DuckDB để tính các phân
vùng Gold.
persist = not (is_ext(ym) and (svc == "yellow" or ym >= "2022-08"))
silver_sql = f"""
    SELECT f.service, f.company_code, f.request_ts, f.pickup_ts, f.dropoff_ts, f.pu, f.dl,
        f.miles, f.time_s, f.fare, f.tolls, f.bcf, f.tax, f.cong_sur, f.airport_fee, f.cbd_fee,
        f.tips, f.driver_pay, f.shared_req, f.shared_match, f.wav_req, f.total_amount,
f.payment_type,
        CAST(f.pickup_ts AS DATE) AS d, hour(f.pickup_ts)::TINYINT AS hr,
        isodow(f.pickup_ts)::TINYINT AS dow,
        CASE WHEN f.request_ts IS NOT NULL
            AND date_diff('second', f.request_ts, f.pickup_ts) BETWEEN 0 AND
{c['max_wait_min']*60}
            THEN date_diff('second', f.request_ts, f.pickup_ts)/60.0 END AS wait_min,
        f.miles / (f.time_s/3600.0) AS mph,
        zp.grp AS pu_grp, zd.grp AS do_grp,
        (zp.grp='CRZ' OR zd.grp='CRZ')::INT AS touch_crz,
        f.fare + f.tolls + f.bcf + f.tax + f.cong_sur + f.airport_fee + f.cbd_fee AS rider_cost
    FROM flagged f
    LEFT JOIN z zp ON f.pu = zp.LocationID
    LEFT JOIN z zd ON f.dl = zd.LocationID
    WHERE q_out_of_month+q_bad_zone+q_bad_miles+q_bad_time+q_bad_fare+q_bad_speed+q_bad_pay = 0
"""

if persist:
    sf = silver_file(svc, ym).with_name(f"part-{k}.parquet").as_posix()
    con.execute(f"COPY ({silver_sql}) TO '{sf}' (FORMAT PARQUET, COMPRESSION ZSTD,
ROW_GROUP_SIZE 1000000)")
    t_silver = time.time() - t0
    con.execute(f"CREATE TEMP VIEW s AS SELECT * FROM read_parquet('{sf}')"
else:
    sf = None
    con.execute(f"CREATE TEMP TABLE s AS {silver_sql}")
    t_silver = time.time() - t0
    sums = f"""count(*) AS n, sum(fare) AS fare, sum(driver_pay) AS pay, sum(miles) AS miles,
        sum(time_s) AS time_s, sum(tips) AS tips, sum(cbd_fee) AS cbd, sum(rider_cost) AS
rider_cost,
        sum(cong_sur) AS cong_sur, sum(tolls) AS tolls, sum(wait_min) AS wait_sum,
        count(wait_min) AS wait_n, sum(shared_req) AS shared_req, sum((cbd_fee>0)::INT) AS
n_cbd"""
    gold = {
        "zone_day_pu": f"""SELECT service, d, pu AS zone, {sums},
            sum((do_grp='CRZ')::INT) AS n_to_crz,
            sum((company_code='HV0003')::INT) AS n_uber, sum((company_code='HV0005')::INT) AS
n_lyft
        FROM s GROUP BY ALL""",
        "zone_day_do": f"""SELECT service, d, dl AS zone, {sums},
            sum((pu_grp='CRZ')::INT) AS n_from_crz FROM s GROUP BY ALL""",
        "grp_hour_day": f"""SELECT service, d, hr, pu_grp, do_grp, {sums} FROM s GROUP BY ALL""",
        "company_grp_day": f"""SELECT service, company_code, d, pu_grp, do_grp, {sums} FROM s GROUP
BY ALL""",
        "zone_hour_month": f"""SELECT service, '{ym}' AS ym, pu AS zone, hr, {sums} FROM s GROUP BY
ALL""",
        "od_month": f"""SELECT service, '{ym}' AS ym, pu, dl, {sums} FROM s GROUP BY ALL""",
        "trip_sample": f"""SELECT * FROM s USING SAMPLE {0.25 if svc == 'hvfhv' else 1.0}%
(bernoulli, {SEED})""",
    }
    for name, sql in gold.items():
        gp = gold_part(name, svc, ym + "_c" + str(k)).as_posix()
        con.execute(f"COPY ({sql}) TO '{gp}' (FORMAT PARQUET, COMPRESSION ZSTD)")
        t_gold = time.time() - t0
        n_silver = con.execute("SELECT count(*) FROM s").fetchone()[0]
        rec = dict(service=svc, month=ym, chunk=k, **q, n_silver=int(n_silver),
            sec_quality=round(t_quality, 1), sec_silver=round(t_silver - t_quality, 1),
            sec_gold=round(t_gold - t_silver, 1), sec_total=round(t_gold, 1),
            silver_mb=round(os.path.getsize(sf) / 2**20, 1) if sf else 0.0,
silver_persisted=bool(sf))
        plog = LOG / ("partitions_ext" if is_ext(ym) else "partitions")
        plog.mkdir(exist_ok=True)
        (plog / f"{tag}.json").write_text(json.dumps(rec, indent=2))
        print(json.dumps(rec), flush=True)

if __name__ == "__main__":
    if sys.argv[1] in ("all", "ext"):
        months = MONTHS_EXT if sys.argv[1] == "ext" else MONTHS
        plog = LOG / ("partitions_ext" if sys.argv[1] == "ext" else "partitions")
        # Tùy chọn: giới hạn thời gian mỗi lần gọi (giây), dừng khi môi trường giới hạn thời gian
lệnh
        budget = float(sys.argv[2]) if len(sys.argv) > 2 else float("inf")
        start = time.time()
        for s in SERVICES:
            for m in months:
                rf = raw_file(s, m)

```

```

# Bỏ qua tệp chưa tải hoặc đang được tải (sửa đổi trong 2 phút gần nhất)
if not rf.exists() or time.time() - rf.stat().st_mtime < 120:
    continue
for k in range(n_chunks_for(s, m)):
    if not (plog / f"{s}_{m}_c{k}.json").exists():
        est = (80 if n_chunks_for(s, m) == 4 else 45) if s == "hvfhv" else 30
        if time.time() - start + est > budget:
            sys.exit(0)
        run(s, m, k)
else:
    run(sys.argv[1], sys.argv[2], int(sys.argv[3]) if len(sys.argv) > 3 else 0)

```

I.6. 04_gold Consolidate.py

""""Bước 4 - Hợp nhất các phân vùng Gold theo tháng thành bảng Gold cuối.

Các bảng tổng hợp ở bước 3 được ghi theo từng khúc (chunk) của từng tháng. Vì mọi chỉ tiêu đều là tổng (count, sum), việc hợp nhất chỉ là cộng dồn, không làm mất thông tin. Bước này cũng tổng hợp nhật ký chất lượng dữ liệu.

Chạy: python code/04_gold Consolidate.py (bảng Gold chính 2024-2025)
python code/04_gold Consolidate.py ext (bảng Gold dài 2022-2025 trong data/gold/long/, không dùng bảng chính)

```

"""
import sys
import json
import time

import pandas as pd

from config import GOLD, LOG, TAB, duck

t0 = time.time()
con = duck()
EXT = len(sys.argv) > 1 and sys.argv[1] == "ext"
parts = GOLD / "_parts"
OUTDIR = GOLD / "long" if EXT else GOLD
OUTDIR.mkdir(exist_ok=True)
SFX = "x" if EXT else ""
SUM_COLS = ("n, fare, pay, miles, time_s, tips, cbd, rider_cost, cong_sur, tolls, "
            "wait_sum, wait_n, shared_req, n_cbd")

def sums(extra=""):
    cols = [c.strip() for c in (SUM_COLS + ("," + extra if extra else "")).split(",")]
    return ", ".join(f"sum({c}):DOUBLE AS {c}" for c in cols)

specs = {
    "zone_day_pu": ("service, d, zone", sums("n_to_crz, n_uber, n_lyft")),
    "zone_day_do": ("service, d, zone", sums("n_from_crz")),
    "grp_hour_day": ("service, d, hr, pu_grp, do_grp", sums()),
    "company_grp_day": ("service, company_code, d, pu_grp, do_grp", sums()),
    "zone_hour_month": ("service, ym, zone, hr", sums()),
    "od_month": ("service, ym, pu, dl", sums()),
}
info = {}
# Tùy chọn: chỉ hợp nhất một số bảng (python 04_gold Consolidate.py ext
od_month, trip_sample, quality)
ONLY = set(sys.argv[2].split(",")) if len(sys.argv) > 2 else None
for name, (keys, agg) in specs.items():
    if ONLY and name not in ONLY:
        continue
    src = (parts / name / f"*_c*.parquet").as_posix()
    if EXT:
        src = [src, (GOLD / "_parts_ext" / name / f"*_c*.parquet").as_posix()]
        dst = (OUTDIR / f"{name}.parquet").as_posix()
        # union_by_name=true: hợp nhất lược đồ theo tên cột và nâng kiểu lên kiểu rộng nhất.
        # Không có tùy chọn này DuckDB lấy lược đồ của tệp đầu tiên (HVFHV 01/2024, cột cbd kiểu
        # DECIMAL(38,1)) và ép các tệp sau về kiểu đó, làm tròn tổng phí 0,75 USD của taxi vàng.
        # Lỗi này được phát hiện khi đối chứng chéo với bản tải lập bằng Spark (bước 15).
        srcx = f'"{src}"' if isinstance(src, str) else "[" + ", ".join(f'"{x}"' for x in src) + "]"
        con.execute(f"COPY (SELECT {keys}, {agg} FROM read_parquet({srcx}, union_by_name=true) GROUP BY
ALL ORDER BY ALL) "
                    f"TO '{dst}' (FORMAT PARQUET, COMPRESSION ZSTD)")
        info[name] = con.execute(f"SELECT count(*) FROM '{dst}'").fetchone()[0]
        print(name, info[name], flush=True)

if ONLY and "trip_sample" not in ONLY:
    src = None
else:
    src = (parts / "trip_sample" / f"*_c*.parquet").as_posix()
if EXT and src:

```

```

src = (GOLD / "_parts_ext" / "trip_sample" / "*_c*.parquet").as_posix()
if src:
    con.execute(f"COPY (SELECT * FROM read_parquet('{src}', union_by_name=true)) TO '{{OUTDIR /
'trip_sample.parquet'}}.as_posix()}' "
                "(FORMAT PARQUET, COMPRESSION ZSTD)")
    info["trip_sample"] = con.execute(f"SELECT count(*) FROM '{{OUTDIR /
'trip_sample.parquet'}}.as_posix()}'").fetchone()[0]

# Nhật ký chất lượng dữ liệu theo tháng
recs = [json.loads(p.read_text()) for p in sorted((LOG / ("partitions_ext" if EXT else
"partitions")).glob("*_c*.json"))]
q = pd.DataFrame(recs)
qm = q.groupby(["service", "month"]).agg(
    n_raw=("n_raw", "sum"), q_out_of_month=("q_out_of_month", "sum"), q_bad_zone=("q_bad_zone",
"sum"),
    q_bad_miles=("q_bad_miles", "sum"), q_bad_time=("q_bad_time", "sum"), q_bad_fare=("q_bad_fare",
"sum"),
    q_bad_speed=("q_bad_speed", "sum"), q_bad_pay=("q_bad_pay", "sum"), n_rejected=("n_rejected",
"sum"),
    n_silver=("n_silver", "sum"), silver_mb=("silver_mb", "sum"), sec_quality=("sec_quality",
"sum"),
    sec_silver=("sec_silver", "sum"), sec_gold=("sec_gold", "sum"), sec_total=("sec_total", "sum"),
    chunks=("chunk", "count")).reset_index()
qm["reject_pct"] = 100 * qm.n_rejected / qm.n_raw
qm.to_csv(TAB / f"t06{SFX}_quality_by_month.csv", index=False)
qs = qm.groupby("service").sum(numeric_only=True).reset_index()
qs["reject_pct"] = 100 * qs.n_rejected / qs.n_raw
qs.to_csv(TAB / f"t07{SFX}_quality_summary.csv", index=False)
q.to_csv(TAB / f"t08{SFX}_partition_runtime.csv", index=False)
(LOG / f"04_gold consolidate{'_ext' if EXT else ''}.json").write_text(json.dumps(dict(
seconds=round(time.time() - t0, 1), rows=info), indent=2, default=int))
print(qs.T)
print("time", round(time.time() - t0, 1))

```

I.7. 05_benchmark.py

"""Bước 5 - Thực nghiệm hiệu năng lưu trữ và xử lý.

Đo trên chính dữ liệu của đồ án (không dùng số liệu tham khảo bên ngoài):

- (a) Định dạng lưu trữ: CSV, CSV nén gzip, Parquet Snappy, Parquet ZSTD cho cùng một lát cắt dữ liệu HVFHV (kích thước tệp, thời gian ghi, đọc).
- (b) Bộ máy xử lý: DuckDB, Pandas, PyArrow cho cùng một truy vấn tổng hợp (doanh thu và số chuyến theo vùng đón) trên một tháng dữ liệu đầy đủ.
- (c) Cắt tỉa cột (column pruning) và đẩy điều kiện lọc xuống (predicate pushdown) trong DuckDB.

Mỗi phép đo chạy trong tiến trình con riêng để đo bộ nhớ đỉnh (max RSS).

Chạy: python code/05_benchmark.py [part] với part ∈ {format, engine, pruning}

```

"""
import json
import subprocess
import sys
import textwrap

import pandas as pd

from config import ROOT, TAB, LOG, raw_file

BENCH = ROOT / "data" / "_bench"
BENCH.mkdir(exist_ok=True)
MONTH = "2024-03"
SRC = raw_file("hvfhv", MONTH).as_posix()
SLICE_ROWS = 2_000_000
REPEAT = 3

def child(code):
    """Chạy đoạn mã trong tiến trình con; trả về dict kết quả và max RSS (MB)."""
    wrapper = textwrap.dedent(f"""
import json, resource, time
t0 = time.perf_counter()
{textwrap.dedent(code)}
el = time.perf_counter() - t0
rss = resource.getrusage(resource.RUSAGE_SELF).ru_maxrss / 1024
print(json.dumps(dict(seconds=el, max_rss_mb=rss, **({extra if 'extra' in dir() else {}}))))
""")
    out = subprocess.run([sys.executable, "-c", wrapper], capture_output=True, text=True,
cwd=str(ROOT / "code"))
    if out.returncode != 0:
        raise RuntimeError(out.stderr[-2000:])
    return json.loads(out.stdout.strip().splitlines()[-1])

```



```

def part_format():
    base = (BENCH / "slice").as_posix()
    rows = []
    prep = f"""
import duckdb
con = duckdb.connect(); con.execute("SET threads=2")
con.execute("CREATE TABLE t AS SELECT * FROM '{SRC}' LIMIT {SLICE_ROWS}")
"""
    writes = {
        "CSV": f"COPY t TO '{base}.csv' (HEADER)",
        "CSV.gz": f"COPY t TO '{base}.csv.gz' (HEADER, COMPRESSION gzip)",
        "Parquet Snappy": f"COPY t TO '{base}_snappy.parquet' (FORMAT PARQUET, COMPRESSION SNAPPY)",
        "Parquet ZSTD": f"COPY t TO '{base}_zstd.parquet' (FORMAT PARQUET, COMPRESSION ZSTD)",
    }
    files = {"CSV": f"{base}.csv", "CSV.gz": f"{base}.csv.gz",
            "Parquet Snappy": f"{base}_snappy.parquet", "Parquet ZSTD": f"{base}_zstd.parquet"}
    for fmt, sql in writes.items():
        r = child(prepare + f"""
t1 = time.perf_counter(); con.execute("{sql}"); w = time.perf_counter() - t1
import os; extra = dict(write_s=w, size_mb=os.path.getsize('{files[fmt]}')/2**20)
""")
        reader = (f"read_csv('{files[fmt]}', header=true)" if fmt.startswith("CSV") else
f"'{files[fmt]}'"")
        reads = []
        for _ in range(REPEAT):
            rr = child(f"""
import duckdb
con = duckdb.connect(); con.execute("SET threads=2")
res = con.execute("SELECT PULocationID, count(*), sum(base_passenger_fare) FROM {reader} GROUP BY
1").fetchall()
extra = dict(groups=len(res))
""")
            reads.append(rr["seconds"])
            rows.append(dict(format=fmt, rows=SLICE_ROWS, size_mb=r["size_mb"], write_s=r["write_s"],
                            agg_query_s_median=sorted(reads)[1], agg_query_s_min=min(reads),
                            agg_query_s_max=max(reads)))
            print(rows[-1], flush=True)
        df = pd.DataFrame(rows)
        df["size_ratio_vs_csv"] = df.size_mb / df.loc[df.format == "CSV", "size_mb"].iloc[0]
        df.to_csv(TAB / "t09_bench_format.csv", index=False)

```

QUERY_DESC = "Số chuyển, tổng giá cước, tổng thu nhập tài xế theo vùng đón (1 tháng HVFHV đầy đủ)"

```

def part_engine():
    codes = {
        "DuckDB (SQL)": f"""
import duckdb
con = duckdb.connect(); con.execute("SET threads=2")
res = con.execute("SELECT PULocationID, count(*), sum(base_passenger_fare), sum(driver_pay) FROM
'{SRC}' GROUP BY 1").df()
extra = dict(groups=len(res))
""",
        "Pandas (read_parquet 3 cột + groupby)": f"""
import pandas as pd
df = pd.read_parquet('{SRC}', columns=['PULocationID', 'base_passenger_fare', 'driver_pay'])
res = df.groupby('PULocationID').agg(n=('base_passenger_fare', 'size'),
fare=('base_passenger_fare', 'sum'), pay=('driver_pay', 'sum'))
extra = dict(groups=len(res))
""",
        "PyArrow (dataset + groupby)": f"""
import pyarrow.parquet as pq
t = pq.read_table('{SRC}', columns=['PULocationID', 'base_passenger_fare', 'driver_pay'])
res = t.group_by('PULocationID').aggregate([( 'base_passenger_fare', 'count'),
('base_passenger_fare', 'sum'), ('driver_pay', 'sum')])
extra = dict(groups=res.num_rows)
""",
    }
    rows = []
    for eng, code in codes.items():
        rs = [child(code) for _ in range(REPEAT)]
        secs = sorted(r["seconds"] for r in rs)
        rows.append(dict(engine=eng, query=QUERY_DESC, month=MONTH, seconds_median=secs[1],
                        seconds_min=secs[0], seconds_max=secs[-1],
                        max_rss_mb=max(r["max_rss_mb"] for r in rs), groups=rs[0]["groups"]))
        print(rows[-1], flush=True)
    pd.DataFrame(rows).to_csv(TAB / "t10_bench_engine.csv", index=False)

```

```

def part_pruning():
    tests = {
        "Đọc 2 cột, không lọc": f"SELECT count(*), sum(base_passenger_fare), sum(trip_miles) FROM
'{SRC}'",
        "Đọc toàn bộ 24 cột (max từng cột)": f"SELECT max(COLUMNS(*)) FROM '{SRC}'",
    }

```

```

        "2 cột + lọc 1 ngày (pushdown theo min/max row group)": f"SELECT count(*),
sum(base_passenger_fare) FROM '{SRC}' WHERE pickup_datetime >= TIMESTAMP '{MONTH}-15' AND
pickup_datetime < TIMESTAMP '{MONTH}-16'",
        "2 cột + lọc theo vùng (không sắp xếp theo vùng)": f"SELECT count(*),
sum(base_passenger_fare) FROM '{SRC}' WHERE PULocationID = 161",
    }
    rows = []
    for name, sql in tests.items():
        rs = []
        for _ in range(REPEAT):
            rs.append(child(f""
import duckdb
con = duckdb.connect(); con.execute("SET threads=2"); con.execute("PRAGMA
enable_profiling='no_output'")
res = con.execute("\\"{sql}\\").fetchall()
extra = dict(result=str(res[0][0]))
"""))
        secs = sorted(r["seconds"] for r in rs)
        rows.append(dict(test=name, seconds_median=secs[1], seconds_min=secs[0], seconds_max=secs[-
1],
                        max_rss_mb=max(r["max_rss_mb"] for r in rs), first_value=rs[0]["result"]))
    print(rows[-1], flush=True)
    import pyarrow.parquet as pq
    md = pq.ParquetFile(SRC).metadata
    rg = []
    for i in range(md.num_row_groups):
        st = md.row_group(i).column(5).statistics
        rg.append(dict(row_group=i, rows=md.row_group(i).num_rows,
                        min_pickup=str(st.min) if st else None, max_pickup=str(st.max) if st else
None))
    pd.DataFrame(rg).to_csv(TAB / "t12_rowgroup_stats.csv", index=False)
    pd.DataFrame(rows).to_csv(TAB / "t11_bench_pruning.csv", index=False)

if __name__ == "__main__":
    part = sys.argv[1] if len(sys.argv) > 1 else "all"
    for p, fn in (("format", part_format), ("engine", part_engine), ("pruning", part_pruning)):
        if part in (p, "all"):
            fn()
    (LOG / f"05_benchmark_{part}.json").write_text(json.dumps(dict(done=part)))

```

I.8. panels.py

"""Dùng các bảng dữ liệu bảng (panel) dùng cho phân tích nhân quả.

Tuần được định nghĩa từ Chủ nhật đến thứ Bảy, để tuần 0 bắt đầu đúng ngày 05/01/2025 (Chủ nhật), ngày đầu tiên thu phí. Nhờ vậy không có tuần nào bị trộn lẫn ngày trước và sau chính sách.

```

"""
import numpy as np
import pandas as pd

from config import GOLD, POLICY_DATE

P = pd.Timestamp(POLICY_DATE)
W0 = pd.Timestamp("2024-01-07") # Chủ nhật đầu tiên của năm 2024
W_END = pd.Timestamp("2025-12-27") # thứ Bảy cuối cùng có đủ tuần trong dữ liệu
MIN_DAILY = {"hvfhv": 100, "yellow": 20}

def dim():
    return pd.read_parquet(GOLD / "dim_zone.parquet")

def add_ratios(g):
    g["ln_n"] = np.log(g["n"])
    g["fare_pm"] = g.fare / g.miles
    g["pay_pm"] = g.pay / g.miles
    g["fare_pt"] = g.fare / g.n
    g["pay_pt"] = g.pay / g.n
    g["mph"] = g.miles / (g.time_s / 3600)
    g["min_pt"] = g.time_s / g.n / 60
    g["miles_pt"] = g.miles / g.n
    g["wait"] = g.wait_sum / g.wait_n.replace(0, np.nan)
    g["rider_pt"] = g.rider_cost / g.n
    g["cbd_pt"] = g.cbd / g.n
    g["tips_pt"] = g.tips / g.n
    g["pay_share"] = 100 * g.pay / g.fare
    g["cbd_share"] = 100 * g.n_cbd / g.n
    g["shared_pct"] = 100 * g.shared_req / g.n
    return g

```

```

SUMS = ["n", "fare", "pay", "miles", "time_s", "tips", "cbd", "rider_cost", "cong_sur",
        "tolls", "wait_sum", "wait_n", "shared_req", "n_cbd"]

def zone_week(service="hvfhv", table="zone_day_pu", groups=("CRZ", "MN_NORTH", "OUTER"),
              min_daily=None, extra=()):
    """Panel vùng x tuần, cân bằng, chỉ giữ vùng đủ lớn trong năm 2024."""
    z = pd.read_parquet(GOLD / f"{table}.parquet")
    z = z[z.service == service].copy()
    z["d"] = pd.to_datetime(z["d"])
    z = z[(z.d >= W0) & (z.d <= W_END)]
    z["wk"] = z.d - pd.to_timedelta((z.d.dt.dayofweek + 1) % 7, unit="D")
    cols = SUMS + list(extra)
    g = z.groupby(["zone", "wk"])[cols].sum().reset_index()
    dm = dim()[["LocationID", "grp", "Borough", "Zone", "dist_to_crz_km", "ring", "area_km2"]]
    g = g.merge(dm, left_on="zone", right_on="LocationID", how="left")
    g = g[g.grp.isin(groups)]
    md = MIN_DAILY[service] if min_daily is None else min_daily
    pre = g[g.wk < P].groupby("zone")["n"].sum() / ((P - W0).days)
    keep = pre[pre >= md].index
    nweeks = g.wk.nunique()
    full = g.groupby("zone").wk.nunique()
    keep = [k for k in keep if full.get(k, 0) == nweeks]
    g = g[g.zone.isin(keep)].copy()
    g["treat"] = (g.grp == "CRZ").astype(int)
    g["post"] = (g.wk >= P).astype(int)
    g["p"] = g.treat * g.post
    g["k"] = ((g.wk - P).dt.days // 7).astype(int)
    g["woy"] = ((g.wk - pd.Timestamp("2024-01-07")).dt.days // 7) % 52
    g["w_pre"] = g.zone.map(pre)
    g["month"] = g.wk.dt.to_period("M").astype(str)
    return add_ratios(g)

def zone_day(service="hvfhv", groups=("CRZ", "MN_NORTH", "OUTER"), min_daily=None):
    z = pd.read_parquet(GOLD / "zone_day_pu.parquet")
    z = z[z.service == service].copy()
    z["d"] = pd.to_datetime(z["d"])
    dm = dim()[["LocationID", "grp"]]
    z = z.merge(dm, left_on="zone", right_on="LocationID")
    z = z[z.grp.isin(groups)]
    md = MIN_DAILY[service] if min_daily is None else min_daily
    pre = z[z.d < P].groupby("zone")["n"].sum() / 366
    z = z[z.zone.isin(pre[pre >= md].index)].copy()
    # cân bằng: điền 0 không cần vì vùng lớn luôn có chuyến; bỏ ngày thiếu
    z["treat"] = (z.grp == "CRZ").astype(int)
    z["post"] = (z.d >= P).astype(int)
    z["p"] = z.treat * z.post
    z["weekend"] = (z.d.dt.dayofweek >= 5).astype(int)
    return add_ratios(z)

def od_month(service="hvfhv", min_monthly=300):
    """Panel cặp vùng (điểm đón, điểm trả) x tháng, cân bằng 24 tháng."""
    o = pd.read_parquet(GOLD / "od_month.parquet")
    o = o[o.service == service].copy()
    dm = dim().set_index("LocationID")["grp"]
    o["pu_grp"] = o.pu.map(dm)
    o["do_grp"] = o.dl.map(dm)
    ok = ["CRZ", "MN_NORTH", "OUTER"]
    o = o[o.pu_grp.isin(ok) & o.do_grp.isin(ok)]
    o["pair"] = o.pu.astype(str) + "_" + o.dl.astype(str)
    pre = o[o.ym < "2025-01"].groupby("pair")["n"].mean()
    cnt = o.groupby("pair").ym.nunique()
    keep = pre[pre >= min_monthly].index.intersection(cnt[cnt == 24].index)
    o = o[o.pair.isin(keep)].copy()
    o["touch"] = ((o.pu_grp == "CRZ") | (o.do_grp == "CRZ")).astype(int)
    o["ftype"] = np.select([(o.pu_grp == "CRZ") & (o.do_grp == "CRZ"), o.pu_grp == "CRZ", o.do_grp == "CRZ"],
                           ["CRZ-CRZ", "CRZ-ngoài", "ngoài-CRZ"], "không chạm CRZ")
    o["post"] = (o.ym >= "2025-01").astype(int)
    o["p"] = o.touch * o.post
    o["w_pre"] = o.pair.map(pre)
    o["k"] = o.ym.map({m: i - 12 for i, m in enumerate(sorted(o.ym.unique()))})
    return add_ratios(o)

def zone_hour_month(service="hvfhv", groups=("CRZ", "MN_NORTH", "OUTER"), min_daily=None):
    h = pd.read_parquet(GOLD / "zone_hour_month.parquet")
    h = h[h.service == service].copy()
    dm = dim()[["LocationID", "grp"]]
    h = h.merge(dm, left_on="zone", right_on="LocationID")
    h = h[h.grp.isin(groups)]
    md = MIN_DAILY[service] if min_daily is None else min_daily
    pre = h[h.ym < "2025-01"].groupby("zone")["n"].sum() / 366

```

```

h = h[h.zone.isin(pre[pre >= md].index)].copy()
bins = [(0, 5, "00-05"), (6, 9, "06-09"), (10, 15, "10-15"), (16, 19, "16-19"), (20, 23, "20-23")]
h["hbin"] = pd.cut(h.hr, [-1] + [b[1] for b in bins], labels=[b[2] for b in bins]).astype(str)
g = h.groupby(["zone", "grp", "ym", "hbin"])[SUMS].sum().reset_index()
g["treat"] = (g.grp == "CRZ").astype(int)
g["post"] = (g.ym >= "2025-01").astype(int)
g["D"] = g.treat * g.post
return add_ratios(g)

```

I.9. causal.py

"""Thư viện ước lượng nhân quả dùng chung (tự cài đặt, minh bạch từng bước).

- `demean_fe`: khử nhiễu hiệu ứng cố định bằng phép chiếu luân phiên (alternating projections, còn gọi là thuật toán Guimarães-Portugal / "within" nhiều chiều), có hỗ trợ trọng số.
- `fe_ols`: hồi quy OLS sau khi khử nhiễu hiệu ứng cố định, sai số chuẩn phân cụm (CR1, hiệu chỉnh bậc tự do kiểu Stata).
- `event_study`: hệ số động theo thời gian tương đối so với mốc chính sách.

```

import numpy as np
import pandas as pd

```

```

def demean_fe(df, cols, fes, w=None, tol=1e-10, max_iter=500):
    """Khử trung bình theo nhiều nhóm hiệu ứng cố định cho các cột `cols`."""
    X = df[cols].to_numpy(dtype=float).copy()
    ww = np.ones(len(df)) if w is None else np.asarray(w, dtype=float)
    codes = [pd.factorize(df[f])[0] for f in fes]
    sizes = [c.max() + 1 for c in codes]
    wsum = [np.bincount(c, weights=ww, minlength=s) for c, s in zip(codes, sizes)]
    for it in range(max_iter):
        X_old = X.copy()
        for c, s, ws in zip(codes, sizes, wsum):
            for j in range(X.shape[1]):
                m = np.bincount(c, weights=ww * X[:, j], minlength=s) / np.where(ws > 0, ws, 1)
                X[:, j] -= m[c]
        if np.max(np.abs(X - X_old)) < tol:
            break
    return X, it + 1

```

```

def fe_ols(df, y, xs, fes, cluster, w=None):
    """OLS với hiệu ứng cố định `fes`, sai số chuẩn phân cụm theo `cluster`.

    Trả về DataFrame hệ số (coef, se, t, p, ci_low, ci_high) và thông tin mô hình.
    """
    from scipy import stats
    d = df.dropna(subset=[y] + xs).reset_index(drop=True)
    ww = None if w is None else d[w].to_numpy(dtype=float)
    Z, n_iter = demean_fe(d, [y] + xs, fes, ww)
    yt, Xt = Z[:, 0], Z[:, 1:]
    sw = np.ones(len(d)) if ww is None else np.sqrt(ww)
    Xs, ys = Xt * sw[:, None], yt * sw
    XtX = Xs.T @ Xs
    XtX_inv = np.linalg.pinv(XtX)
    b = XtX_inv @ (Xs.T @ ys)
    e = ys - Xs @ b
    g = pd.factorize(d[cluster])[0]
    G = g.max() + 1
    scores = np.zeros((G, Xs.shape[1]))
    np.add.at(scores, g, Xs * e[:, None])
    meat = scores.T @ scores
    n, k = Xs.shape
    k_fe = sum(d[f].nunique() for f in fes) - (len(fes) - 1)
    adj = G / (G - 1) * (n - 1) / max(n - k - k_fe, 1)
    V = adj * XtX_inv @ meat @ XtX_inv
    se = np.sqrt(np.clip(np.diag(V), 0, None))
    tval = b / np.where(se > 0, se, np.nan)
    p = 2 * stats.t.sf(np.abs(tval), df=G - 1)
    crit = stats.t.ppf(0.975, df=G - 1)
    res = pd.DataFrame(dict(term=xs, coef=b, se=se, t=tval, p=p,
                           ci_low=b - crit * se, ci_high=b + crit * se))
    ss_res = float(e @ e)
    ss_tot = float(ys @ ys)
    info = dict(n_obs=int(n), n_clusters=int(G), n_fe_levels=int(k_fe),
                within_r2=1 - ss_res / ss_tot if ss_tot > 0 else np.nan, demean_iter=int(n_iter))
    return res, info, V

```

```

def event_study(df, y, treat, rel, fes, cluster, ref=-1, lo=None, hi=None, w=None):
    """Hệ số động: y = FE + sum_k beta_k * treat * 1[rel == k] (bỏ mốc ref).

```

```

Các kỳ ngoài [lo, hi] được gộp vào hai đầu mút (binning)."""
d = df.copy()
r = d[rel].clip(lower=lo, upper=hi) if lo is not None else d[rel]
ks = sorted(k for k in r.unique() if k != ref)
names = []
for k in ks:
    nm = f"ev_{'m' if k < 0 else 'p'}{abs(int(k))}"
    d[nm] = ((r == k) & (d[treat] == 1)).astype(float)
    names.append(nm)
res, info, V = fe_ols(d, y, names, fes, cluster, w)
res["k"] = ks
# Chuẩn hóa lại mốc so sánh: trừ trung bình của TOÀN BỘ các kỳ trước chính sách
# (kể cả kỳ ref có hệ số 0). Phép biến đổi tuyến tính L áp dụng cho cả hệ số và
# ma trận hiệp phương sai, nên sai số chuẩn được tính lại đúng.
kk = np.array(ks)
n_pre = int((kk < 0).sum()) + (1 if ref < 0 else 0)
a = np.where(kk < 0, 1.0 / n_pre, 0.0)
L = np.eye(len(ks)) - np.ones((len(ks), 1)) @ a[None, :]
bc = L @ res.coef.to_numpy()
Vc = L @ V @ L.T
sc = np.sqrt(np.clip(np.diag(Vc), 0, None))
from scipy import stats
crit = stats.t.ppf(0.975, df=info["n_clusters"] - 1)
res["coef_c"], res["se_c"] = bc, sc
res["ci_low_c"], res["ci_high_c"] = bc - crit * sc, bc + crit * sc
return res, info, V

def _center_matrix(ks, ref=-1):
    kk = np.array(ks)
    n_pre = int((kk < 0).sum()) + (1 if ref < 0 else 0)
    a = np.where(kk < 0, 1.0 / n_pre, 0.0)
    return np.eye(len(ks)) - np.ones((len(ks), 1)) @ a[None, :]

def pretrend_wald_centered(res, V, ref=-1):
    """Kiểm định Wald: mọi hệ số trước chính sách (đã chuẩn hóa theo trung bình kỳ trước) bằng nhau,
    tức là không có biến động có hệ thống trước chính sách quanh mức trung bình."""
    from scipy import stats
    L = _center_matrix(list(res.k), ref)
    Vc = L @ V @ L.T
    idx = np.where(res.k.to_numpy() < 0)[0]
    b = res.coef_c.to_numpy()[idx]
    Vs = Vc[np.ix_(idx, idx)]
    wald = float(b @ np.linalg.pinv(Vs) @ b)
    dof = int(np.linalg.matrix_rank(Vs))
    return dict(wald=wald, dof=dof, p=float(stats.chi2.sf(wald, dof)))

def pretrend_wald(res, V, upto=-2):
    """Kiểm định Wald chung: mọi hệ số trước chính sách (k <= upto) bằng 0."""
    from scipy import stats
    idx = np.where(res.k.to_numpy() <= upto)[0]
    if len(idx) == 0:
        return dict(wald=np.nan, dof=0, p=np.nan)
    b = res.coef.to_numpy()[idx]
    Vs = V[np.ix_(idx, idx)]
    wald = float(b @ np.linalg.pinv(Vs) @ b)
    return dict(wald=wald, dof=int(len(idx)), p=float(stats.chi2.sf(wald, len(idx))))

```

I.10. viz.py

```

"""Quy ước trình bày hình dùng chung cho mọi hình trong báo cáo.

Bảng màu phân loại dùng thứ tự cố định (không xoay vòng), đã kiểm tra độ
phân biệt với người mù màu. Nhóm xử lý (CRZ) luôn mang màu 1, nhóm đối chứng
luôn mang màu 2, để người đọc nhận diện nhất quán giữa các hình.
"""
import matplotlib

matplotlib.use("Agg")
import matplotlib.pyplot as plt
from matplotlib import font_manager # noqa: F401

from config import FIG

C = dict(s1="#2a78d6", s2="#eb6834", s3="#1baf7a", s4="#eda100", s5="#e87ba4",
        s6="#008300", s7="#4a3aa7", s8="#e34948",
        text="#0b0b0b", text2="#52514e", muted="#8a8984", grid="#e4e3df",
        surface="ffffff", neutral="#c9c8c2", neutral_dark="#8f8e88",
        div_neg="#2a78d6", div_mid="#f0efec", div_pos="#e34948")
SEQ = ["#cde2fb", "#9ec5f4", "#6da7ec", "#3987e5", "#256abf", "#184f95", "#0d366b"]

```

```

GROUP_COLOR = {"CRZ": C["s1"], "CRZ_PARTIAL": C["s2"], "MN_NORTH": C["s3"],
               "OUTER": C["neutral"], "AIRPORT": C["neutral_dark"], "UNKNOWN": "#ffffff"}
GROUP_LABEL = {"CRZ": "Trong vùng thu phí (CRZ)", "CRZ_PARTIAL": "Vượt qua ranh giới",
               "MN_NORTH": "Manhattan phía bắc", "OUTER": "Các quận ngoài",
               "AIRPORT": "Sân bay", "UNKNOWN": "Không xác định"}

plt.rcParams.update({
    "font.family": "DejaVu Sans", "font.size": 9.5, "axes.titlesize": 10.5,
    "axes.labelsize": 9.5, "axes.edgecolor": C["grid"], "axes.labelcolor": C["text2"],
    "axes.titleweight": "bold", "axes.titlecolor": C["text"], "axes.titlelocation": "left",
    "axes.grid": True, "grid.color": C["grid"], "grid.linewidth": 0.6,
    "axes.spines.top": False, "axes.spines.right": False,
    "xtick.color": C["text2"], "ytick.color": C["text2"],
    "xtick.labelsize": 8.5, "ytick.labelsize": 8.5,
    "legend.frameon": False, "legend.fontsize": 8.5, "lines.linewidth": 2.0,
    "figure.dpi": 110, "savefig.dpi": 200, "savefig.bbox": "tight",
    "figure.facecolor": C["surface"], "axes.facecolor": C["surface"],
})

def fig(w=6.6, h=3.4, **kw):
    return plt.subplots(figsize=(w, h), **kw)

def policy_line(ax, x, label="05/01/2025: bắt đầu thu phí"):
    ax.axvline(x, color=C["text2"], lw=1.0, ls="--", zorder=1)
    ax.annotate(label, xy=(x, 1), xycoords="data", "axes fraction", xytext=(4, -4),
               textcoords="offset points", va="top", fontsize=8, color=C["text2"])

def save(f, name):
    f.savefig(FIG / f"{name}.png")
    plt.close(f)
    return FIG / f"{name}.png"

```

I.11. 06_eda.py

""""Bước 6 - Phân tích khám phá (EDA) trên các bảng Gold.

Sinh các bảng mô tả và hình ảnh phục vụ Chương 3-4 của báo cáo:
 quy mô dữ liệu, chất lượng dữ liệu, bản đồ nhóm vùng, chuỗi thời gian số
 chuyến theo nhóm, doanh thu phí CBD, cấu trúc theo giờ, tốc độ, thời gian chờ,
 giá cước và thị phần hãng.

```

Chạy: python code/06_eda.py
"""
import json
import time

import matplotlib.dates as mdates
import numpy as np
import pandas as pd
from matplotlib.collections import PolyCollection
from matplotlib.patches import Patch

from config import GOLD, LOG, TAB, POLICY_DATE
from viz import C, GROUP_COLOR, GROUP_LABEL, SEQ, fig, plt, policy_line, save

t0 = time.time()
P = pd.Timestamp(POLICY_DATE)
dim = pd.read_parquet(GOLD / "dim_zone.parquet")
zpu = pd.read_parquet(GOLD / "zone_day_pu.parquet")
zpu["d"] = pd.to_datetime(zpu["d"])
zpu = zpu.merge(dim[["LocationID", "grp", "Borough", "Zone"]], left_on="zone",
               right_on="LocationID", how="left")
ghd = pd.read_parquet(GOLD / "grp_hour_day.parquet")
ghd["d"] = pd.to_datetime(ghd["d"])
cgd = pd.read_parquet(GOLD / "company_grp_day.parquet")
cgd["d"] = pd.to_datetime(cgd["d"])
q = pd.read_csv(TAB / "t06_quality_by_month.csv")
man = pd.read_csv(TAB / "t01_bronze_manifest.csv")
out = {}

# ----- H1. Quy mô dữ liệu theo tháng -----
f, ax = fig(6.6, 3.2)
m = man.pivot(index="month", columns="service", values="n_rows") / 1e6
x = np.arange(len(m))
ax.bar(x - 0.2, m["hvfhv"], width=0.38, color=C["s1"], label="HVFHV (Uber, Lyft)")
ax.bar(x + 0.2, m["yellow"], width=0.38, color=C["s2"], label="Taxi vàng")
ax.set_xticks(x[::2], [s[2:] for s in m.index[::2]], rotation=0)
ax.set_ylabel("Triệu chuyến / tháng")
ax.set_title("Số bản ghi thô theo tháng và theo dịch vụ, 2024-2025")
ax.legend(loc="upper left", ncol=2)

```

```

save(f, "f01_rows_by_month")

# ----- H2. Tỷ lệ loại bỏ theo quy tắc -----
rules = ["q_bad_zone", "q_bad_miles", "q_bad_time", "q_bad_fare", "q_bad_speed", "q_bad_pay",
"q_out_of_month"]
lab = {"q_bad_zone": "Vùng không xác định (264/265)", "q_bad_miles": "Quãng đường ≤0 hoặc >100 dặm",
"q_bad_time": "Thời gian <1 phút hoặc >4 giờ", "q_bad_fare": "Giá cước ≤0 hoặc >1000 USD",
"q_bad_speed": "Tốc độ >80 mph", "q_bad_pay": "Thu nhập tài xế âm/thiếu",
"q_out_of_month": "Thời điểm ngoài tháng tệp"}
qs = q.groupby("service")[rules + ["n_raw"]].sum()
rate = qs[rules].div(qs["n_raw"], axis=0) * 100
rate.T.rename(index=lab).to_csv(TAB / "t13_reject_rate_by_rule.csv")
f, ax = fig(6.6, 3.4)
y = np.arange(len(rules))
ax.barh(y + 0.2, rate.loc["hvfhv", rules], height=0.38, color=C["s1"], label="HV FHV")
ax.barh(y - 0.2, rate.loc["yellow", rules], height=0.38, color=C["s2"], label="Taxi vàng")
ax.set_yticks(y, [lab[r] for r in rules])
ax.invert_yaxis()
ax.set_xlabel("% số bản ghi thô (một bản ghi có thể vi phạm nhiều quy tắc)")
ax.set_title("Tỷ lệ bản ghi vi phạm từng quy tắc chất lượng")
ax.legend(loc="lower right")
save(f, "f02_reject_by_rule")

# ----- H3. Bản đồ nhóm vùng -----
poly = pd.read_parquet(GOLD / "zone_polygons.parquet")
grp_of = dim.set_index("LocationID")["grp"].to_dict()

def draw_map(ax, values=None, cmap=None, norm=None, cats=None):
    verts, cols = [], []
    for (lid, part), g in poly.groupby(["LocationID", "part"]):
        verts.append(np.c_[g.x.values, g.y.values])
        if cats is not None:
            cols.append(cats.get(lid, "#ffffff"))
        else:
            v = values.get(lid, np.nan)
            cols.append("#f0efec" if pd.isna(v) else cmap(norm(v)))
    pc = PolyCollection(verts, facecolors=cols, edgecolors="#ffffff", linewidths=0.35)
    ax.add_collection(pc)
    ax.autoscale_view()
    ax.set_aspect("equal")
    ax.axis("off")

f, ax = fig(6.2, 6.2)
draw_map(ax, cats={k: GROUP_COLOR[v] for k, v in grp_of.items()})
hand = [Patch(facecolor=GROUP_COLOR[g], label=f"{GROUP_LABEL[g]} ({(dim.grp == g).sum()} vùng)")]
for g in ["CRZ", "CRZ_PARTIAL", "MN_NORTH", "OUTER", "AIRPORT"]
ax.legend(handles=hand, loc="upper left", fontsize=8.5)
ax.set_title("Phân nhóm 263 vùng taxi theo mức độ chịu phí CBD (xác định từ dữ liệu quý I/2025)")
save(f, "f03_zone_group_map")

f, ax = fig(4.6, 6.2)
mh = dim[dim.Borough == "Manhattan"].LocationID.tolist()
poly_m = poly[poly.LocationID.isin(mh)]
poly_bak = poly
poly = poly_m
draw_map(ax, cats={k: GROUP_COLOR[v] for k, v in grp_of.items()})
for _, r in dim[dim.Borough == "Manhattan"].iterrows():
    if r.grp in ("CRZ_PARTIAL",):
        ax.annotate(str(r.LocationID), (r.cx_ft, r.cy_ft), fontsize=6.5, ha="center",
color=C["text"])
ax.set_title("Manhattan: vùng CRZ và các vùng vắt qua ranh giới")
ax.legend(handles=hand[:3], loc="upper left", fontsize=8)
save(f, "f04_manhattan_map")
poly = poly_bak

# ----- H4. Chuỗi số chuyển theo ngày -----
hv = zpu[zpu.service == "hvfhv"]
daily = hv.groupby(["d", "grp"])["n"].sum().unstack()
daily.to_csv(TAB / "t14_daily_trips_by_group_hvfhv.csv")
f, ax = fig(6.8, 3.4)
for g in ["CRZ", "MN_NORTH", "OUTER"]:
    s = daily[g].rolling(7, center=True).mean() / 1e3
    ax.plot(s.index, s.values, color=GROUP_COLOR[g] if g != "OUTER" else C["s2"],
label=GROUP_LABEL[g])
policy_line(ax, P)
ax.set_ylabel("Nghìn chuyển / ngày (TB trượt 7 ngày)")
ax.set_title("Số chuyển HV FHV theo nhóm vùng đón khách")
ax.legend(loc="upper center", bbox_to_anchor=(0.5, -0.13), ncol=3)
ax.xaxis.set_major_formatter(mdates.DateFormatter("%m/%y"))
save(f, "f05_daily_trips_by_group")

# Chỉ số hóa so với cùng kỳ: tỷ lệ 2025/2024 theo tuần ISO
hv_w = hv.assign(y=hv.d.dt.isocalendar().year, w=hv.d.dt.isocalendar().week)

```

```

wk = hv_w.groupby(["y", "w", "grp"])[ "n"].sum().unstack().reset_index()
wk = wk[(wk.w >= 2) & (wk.w <= 51)]
yoy = wk.pivot(index="w", columns="y")
ratio = pd.DataFrame({g: 100 * (yoy[g, 2025]) / yoy[g, 2024]) - 1) for g in ["CRZ", "MN_NORTH",
"OUTER", "AIRPORT"]})
ratio.to_csv(TAB / "t15_weekly_yoy_pct_by_group_hvfhv.csv")
f, ax = fig(6.8, 3.4)
for g, col in (("CRZ", C["s1"]), ("MN_NORTH", C["s3"]), ("OUTER", C["s2"])):
    ax.plot(ratio.index, ratio[g], color=col, label=GROUP_LABEL[g], marker="o", ms=3)
ax.axhline(0, color=C["text2"], lw=0.8)
ax.set_xlabel("Tuần ISO (2025 so với cùng tuần 2024)")
ax.set_ylabel("% thay đổi số chuyển so với cùng kỳ")
ax.set_title("Tăng trưởng cùng kỳ số chuyển HVFHV theo tuần, 2025 so với 2024")
ax.legend(loc="upper center", bbox_to_anchor=(0.5, -0.2), ncol=3)
save(f, "f06_weekly_yoy_by_group")

# ----- H5. Doanh thu phí CBD -----
allz = zpu.assign(ym=zpu.d.dt.to_period("M").astype(str))
rev = allz[allz.d >= P].groupby(["ym", "service"]).agg(cbd=("cbd", "sum"), n=("n", "sum"),
n_cbd=("n_cbd", "sum")).reset_index()
rev["share_charged"] = 100 * rev.n_cbd / rev.n
rev["avg_fee_charged"] = rev.cbd / rev.n_cbd
rev.to_csv(TAB / "t16_cbd_revenue_by_month.csv", index=False)
out["cbd_total_2025_hvfhv_musd"] = float(rev[rev.service == "hvfhv"].cbd.sum() / 1e6)
out["cbd_total_2025_yellow_musd"] = float(rev[rev.service == "yellow"].cbd.sum() / 1e6)
rp = rev.pivot(index="ym", columns="service", values="cbd") / 1e6
f, ax = fig(6.6, 3.2)
x = np.arange(len(rp))
ax.bar(x - 0.2, rp["hvfhv"], width=0.38, color=C["s1"], label="HVFHV (1,50 USD/chuyến)")
ax.bar(x + 0.2, rp["yellow"], width=0.38, color=C["s2"], label="Taxi vàng (0,75 USD/chuyến)")
ax.set_xticks(x, [s[5:] + "/25" for s in rp.index])
ax.set_ylabel("Triệu USD")
ax.set_title("Tổng phí CBD ghi nhận trong dữ liệu chuyển đi theo tháng, 2025")
ax.legend(loc="upper center", bbox_to_anchor=(0.5, -0.13), ncol=2)
save(f, "f07_cbd_revenue")

# ----- H6. Cấu trúc luồng giữa các nhóm -----
hvg = ghd[ghd.service == "hvfhv"].copy()
hvg["post"] = hvg.d >= P
hvg["yr"] = hvg.d.dt.year
flow = hvg.groupby(["yr", "pu_grp", "do_grp"])[ "n"].sum().unstack("do_grp").fillna(0)
flow.to_csv(TAB / "t17_flow_matrix_by_year_hvfhv.csv")
share = hvg.groupby(["yr", "pu_grp", "do_grp"])[ "n"].sum()
share = (share / share.groupby("yr").transform("sum") * 100).unstack("yr")
share["change_pp"] = share[2025] - share[2024]
share.reset_index().to_csv(TAB / "t18_flow_share_change_hvfhv.csv", index=False)

# ----- H7. Hồ sơ theo giờ -----
crz_touch = hvg[(hvg.pu_grp == "CRZ") | (hvg.do_grp == "CRZ")]
hp = crz_touch.groupby(["yr", "hr"])[ "n"].sum().unstack("yr")
ndays = hvg.groupby("yr").d.nunique()
hp = hp / ndays
hp.to_csv(TAB / "t19_hour_profile_crz_touch.csv")
f, ax = fig(6.6, 3.2)
ax.plot(hp.index, hp[2024] / 1e3, color=C["s2"], label="2024", marker="o", ms=3)
ax.plot(hp.index, hp[2025] / 1e3, color=C["s1"], label="2025", marker="o", ms=3)
ax.set_xticks(range(0, 24, 2))
ax.set_xlabel("Giờ đón khách")
ax.set_ylabel("Nghìn chuyến / ngày")
ax.set_title("Chuyến HVFHV có điểm đầu hoặc cuối trong CRZ, trung bình theo giờ")
ax.legend()
save(f, "f08_hour_profile_crz")

# ----- H8. Tốc độ trong CRZ theo giờ -----
intra = hvg[(hvg.pu_grp == "CRZ") & (hvg.do_grp == "CRZ")]
sp = intra.groupby(["yr", "hr"])[ "miles", "time_s"].sum()
sp["mph"] = sp.miles / (sp.time_s / 3600)
spd = sp["mph"].unstack("yr")
spd.to_csv(TAB / "t20_speed_intra_crz_by_hour.csv")
f, ax = fig(6.6, 3.2)
ax.plot(spd.index, spd[2024], color=C["s2"], label="2024", marker="o", ms=3)
ax.plot(spd.index, spd[2025], color=C["s1"], label="2025", marker="o", ms=3)
ax.set_xticks(range(0, 24, 2))
ax.set_xlabel("Giờ đón khách")
ax.set_ylabel("Tốc độ trung bình (dặm/giờ)")
ax.set_title("Tốc độ trung bình của chuyến HVFHV nội vùng CRZ theo giờ")
ax.legend()
save(f, "f09_speed_intra_crz_hour")

# Tốc độ theo tháng cho 3 loại luồng
def mph_series(df):
    g = df.groupby(df.d.dt.to_period("M"))[ "miles", "time_s"].sum()
    return g.miles / (g.time_s / 3600)

```



```

sp_m = pd.DataFrame({
    "CRZ-CRZ": mph_series(hvg[(hvg.pu_grp == "CRZ") & (hvg.do_grp == "CRZ")]),
    "MN bắc-MN bắc": mph_series(hvg[(hvg.pu_grp == "MN_NORTH") & (hvg.do_grp == "MN_NORTH")]),
    "Quận ngoài-Quận ngoài": mph_series(hvg[(hvg.pu_grp == "OUTER") & (hvg.do_grp == "OUTER")]),
})
sp_m.index = sp_m.index.astype(str)
sp_m.to_csv(TAB / "t21_speed_by_month_flow.csv")
f, ax = fig(6.8, 3.3)
for (k, col) in zip(sp_m.columns, (C["s1"], C["s3"], C["s2"])):
    ax.plot(pd.to_datetime(sp_m.index), sp_m[k], color=col, label=k, marker="o", ms=3)
policy_line(ax, P)
ax.set_ylabel("Đậm/giờ")
ax.set_title("Tốc độ trung bình theo tháng của ba loại luồng chuyển HVFHV")
ax.legend(loc="upper center", bbox_to_anchor=(0.5, -0.13), ncol=3)
ax.xaxis.set_major_formatter(mdates.DateFormatter("%m/%y"))
save(f, "f10_speed_by_month")

# ----- H9. Giá cước, thu nhập tài xế theo tháng -----
def per_trip(df):
    g = df.groupby(df.d.dt.to_period("M"))[["n", "fare", "pay", "miles", "rider_cost", "tips",
"wait_sum", "wait_n", "cbd"]].sum()
    return pd.DataFrame({"fare_per_trip": g.fare / g.n, "pay_per_trip": g.pay / g.n,
"fare_per_mile": g.fare / g.miles, "pay_per_mile": g.pay / g.miles,
"rider_cost_per_trip": g.rider_cost / g.n, "tips_per_trip": g.tips / g.n,
"pay_share_of_fare": 100 * g.pay / g.fare, "wait_min": g.wait_sum /
g.wait_n,
"cbd_per_trip": g.cbd / g.n})

touch = hvg[(hvg.pu_grp == "CRZ") | (hvg.do_grp == "CRZ")]
notouch = hvg[(hvg.pu_grp != "CRZ") & (hvg.do_grp != "CRZ") & (hvg.pu_grp.isin(["MN_NORTH",
"OUTER"])) & (hvg.do_grp.isin(["MN_NORTH", "OUTER"]))]
pt = pd.concat({"touch_crz": per_trip(touch), "no_touch": per_trip(notouch)}, axis=1)
pt.index = pt.index.astype(str)
pt.to_csv(TAB / "t22_price_pay_by_month.csv")
for var, ttl, yl, nm in (("fare_per_mile", "Giá cước cơ sở trên mỗi dặm", "USD/dặm",
"f11_fare_per_mile"),
("pay_per_mile", "Thu nhập tài xế trên mỗi dặm", "USD/dặm",
"f12_pay_per_mile"),
("wait_min", "Thời gian chờ từ lúc gọi xe đến lúc đón", "Phút",
"f13_wait_time"),
("pay_share_of_fare", "Thu nhập tài xế so với giá cước cơ sở", "%",
"f14_pay_share")):
    f, ax = fig(6.6, 3.1)
    xx = pd.to_datetime(pt.index)
    ax.plot(xx, pt[("touch_crz", var)], color=C["s1"], label="Chuyến chạm CRZ", marker="o", ms=3)
    ax.plot(xx, pt[("no_touch", var)], color=C["s2"], label="Chuyến không chạm CRZ", marker="o",
ms=3)
    policy_line(ax, P)
    ax.set_ylabel(yl)
    ax.set_title(ttl + " (HVFHV, theo tháng)")
    ax.legend(loc="upper center", bbox_to_anchor=(0.5, -0.13), ncol=2)
    ax.xaxis.set_major_formatter(mdates.DateFormatter("%m/%y"))
    save(f, nm)

# ----- H10. Thị phần hãng -----
cg = cgd[cgd.service == "hvfhv"].copy()
cg["ym"] = cg.d.dt.to_period("M").astype(str)
cs = cg.groupby(["ym", "company_code"])["n"].sum().unstack().fillna(0)
cs = cs.div(cs.sum(axis=1), axis=0) * 100
cs.to_csv(TAB / "t23_company_share_by_month.csv")
cz = cg[(cg.pu_grp == "CRZ") | (cg.do_grp == "CRZ")].groupby(["ym", "company_code"])
["n"].sum().unstack().fillna(0)
cz = cz.div(cz.sum(axis=1), axis=0) * 100
cz.to_csv(TAB / "t24_company_share_crz_by_month.csv")
f, ax = fig(6.6, 3.1)
xx = pd.to_datetime(cs.index)
ax.plot(xx, cs["HV0003"], color=C["s1"], label="Uber, toàn thành phố", marker="o", ms=3)
ax.plot(xx, cz["HV0003"], color=C["s3"], label="Uber, chuyến chạm CRZ", marker="o", ms=3)
policy_line(ax, P)
ax.set_ylabel("% số chuyến HVFHV")
ax.set_title("Thị phần Uber theo tháng (phần còn lại chủ yếu là Lyft)")
ax.legend(loc="upper center", bbox_to_anchor=(0.5, -0.13), ncol=2)
ax.xaxis.set_major_formatter(mdates.DateFormatter("%m/%y"))
save(f, "f15_company_share")

# ----- H11. Bản đồ thay đổi cùng kỳ theo vùng -----
zy = hv.assign(yr=hv.d.dt.year).query("d.dt.dayofyear >= 5")
zz = zy.groupby(["zone", "yr"])["n"].sum().unstack()
zz = zz[zz[2024] >= 5000]
zz["yoy_pct"] = 100 * (zz[2025] / zz[2024] - 1)
zz = zz.join(dim.set_index("LocationID")["Zone", "Borough", "grp"])
zz.reset_index().to_csv(TAB / "t25_zone_yoy_pickups.csv", index=False)
from matplotlib.colors import LinearSegmentedColormap, TwoSlopeNorm
cmap = LinearSegmentedColormap.from_list("div", [C["div_neg"], C["div_mid"], C["div_pos"]])

```

```

lim = float(np.nanpercentile(np.abs(zs.yoy_pct), 95))
norm = TwoSlopeNorm(vmin=-lim, vcenter=0, vmax=lim)
f, ax = fig(6.2, 6.4)
draw_map(ax, values=zs["yoy_pct"].to_dict(), cmap=cmap, norm=norm)
sm = plt.cm.ScalarMappable(norm=norm, cmap=cmap)
cb = f.colorbar(sm, ax=ax, shrink=0.55, pad=0.01)
cb.set_label("% thay đổi số chuyến đón 2025 so với 2024")
ax.set_title("Thay đổi cùng kỳ số chuyến HVFHV theo vùng đón (từ 05/01)")
save(f, "f16_zone_yoy_map")

# ----- Bảng mô tả tổng hợp theo nhóm và năm -----
desc = hv.assign(yr=hv.d.dt.year).groupby(["grp", "yr"]).agg(
    trips=("n", "sum"), fare=("fare", "sum"), pay=("pay", "sum"), miles=("miles", "sum"),
    time_s=("time_s", "sum"), cbd=("cbd", "sum"), rider_cost=("rider_cost", "sum"),
    wait_sum=("wait_sum", "sum"), wait_n=("wait_n", "sum"), tips=("tips", "sum"))
desc["trips_per_day"] = desc.trips / desc.index.get_level_values("yr").map({2024: 366, 2025: 365})
desc["fare_per_trip"] = desc.fare / desc.trips
desc["pay_per_trip"] = desc.pay / desc.trips
desc["miles_per_trip"] = desc.miles / desc.trips
desc["min_per_trip"] = desc.time_s / desc.trips / 60
desc["mph"] = desc.miles / (desc.time_s / 3600)
desc["wait_min"] = desc.wait_sum / desc.wait_n
desc["cbd_per_trip"] = desc.cbd / desc.trips
desc["tips_per_trip"] = desc.tips / desc.trips
desc.reset_index().to_csv(TAB / "t26_desc_by_group_year_hvfhv.csv", index=False)

yl = zpu[zpu.service == "yellow"]
descy = yl.assign(yr=yl.d.dt.year).groupby(["grp", "yr"]).agg(trips=("n", "sum"), fare=("fare",
"sum"),
                                                                miles=("miles", "sum"),
                                                                cbd=("cbd", "sum"), tips=("tips",
"sum"))
descy["fare_per_trip"] = descy.fare / descy.trips
descy["mph"] = descy.miles / (descy.time_s / 3600)
descy["cbd_per_trip"] = descy.cbd / descy.trips
descy.reset_index().to_csv(TAB / "t27_desc_by_group_year_yellow.csv", index=False)

# Taxi vàng và HVFHV: số chuyến đón trong CRZ theo tuần (chỉ số)
both = zpu[zpu.grp == "CRZ"].groupby(["service", pd.Grouper(key="d", freq="W-SUN")])
["n"].sum().unstack("service")
base = both[(both.index >= "2024-01-08") & (both.index < "2024-12-30")].mean()
idx = both / base * 100
idx.to_csv(TAB / "t28_weekly_index_crz_by_service.csv")
f, ax = fig(6.8, 3.2)
ax.plot(idx.index, idx["hvfhv"], color=C["s1"], label="HVFHV")
ax.plot(idx.index, idx["yellow"], color=C["s2"], label="Taxi vàng")
policy_line(ax, P)
ax.set_ylabel("Chỉ số (TB tuần năm 2024 = 100)")
ax.set_title("Số chuyến đón trong CRZ theo tuần, HVFHV và taxi vàng")
ax.legend(loc="upper center", bbox_to_anchor=(0.5, -0.13), ncol=2)
ax.xaxis.set_major_formatter(mdates.DateFormatter("%m/%y"))
save(f, "f17_weekly_index_crz_services")

# Phân phối giá cước/chuyến từ mẫu chuyến (0,25% HVFHV)
smp = pd.read_parquet(GOLD / "trip_sample.parquet", columns=["service", "d", "fare", "rider_cost",
"miles", "touch_crz", "cbd_fee", "mph"])
smp = smp[smp.service == "hvfhv"]
smp["yr"] = pd.to_datetime(smp.d).dt.year
smp["fpm"] = smp.fare / smp.miles
qq = smp.groupby(["touch_crz", "yr"])["rider_cost"].quantile([0.1, 0.25, 0.5, 0.75, 0.9]).unstack()
qq.to_csv(TAB / "t29_rider_cost_quantiles_sample.csv")
f, axs = fig(6.8, 3.2, ncol=2, sharey=True)
bins = np.linspace(0, 80, 81)
for ax, tc, ttl in ((axs[0], 1, "Chuyến chậm CRZ"), (axs[1], 0, "Chuyến không chậm CRZ")):
    for yr, col in ((2024, C["s2"]), (2025, C["s1"])):
        v = smp[(smp.touch_crz == tc) & (smp.yr == yr)].rider_cost
        ax.hist(v.clip(upper=80), bins=bins, density=True, histtype="step", color=col, lw=1.6,
label=str(yr))
        ax.set_title(ttl)
        ax.set_xlabel("Tổng chi phí hành khách/chuyến (USD, chưa gồm tip)")
axs[0].set_ylabel("Mật độ")
axs[0].legend()
save(f, "f18_rider_cost_hist")
out["n_sample_hvfhv"] = int(len(smp))

# Taxi vàng: số chuyến theo nhà cung cấp (VendorID) × năm × nhóm vùng đón, đọc trực tiếp từ Bronze
from config import RAW, duck
con = duck()
con.execute(f"CREATE TEMP TABLE z AS SELECT LocationID, grp FROM '{(GOLD /
'dim_zone.parquet')}.as_posix()}'")
vend = con.execute(f"
SELECT year(tpickup_datetime) AS yr, VendorID AS vendor, coalesce(z.grp, 'UNKNOWN') AS
pu_grp, count(*) AS n
FROM read_parquet('{(RAW / 'yellow_tripdata_202*.parquet')}.as_posix()}' y

```

```

LEFT JOIN z ON y.PULocationID = z.LocationID
WHERE year(tpep_pickup_datetime) IN (2024, 2025)
GROUP BY ALL ORDER BY ALL"".df()
vend.to_csv(TAB / "t27b_yellow_vendor_by_year_group.csv", index=False)

(LOG / "06_eda.json").write_text(json.dumps(dict(seconds=round(time.time() - t0, 1), **out),
indent=2))
print(out, "time", round(time.time() - t0, 1))

```

I.12. 07_did_main.py

""""Bước 7 - Ước lượng tác động trung bình: DiD, DDD mùa vụ và nghiên cứu sự kiện.

Thiết kế chính: panel vùng đón x tuần (Chủ nhật-thứ Bảy), 01/2024-12/2025.

Nhóm xử lý : vùng nằm trọn trong CRZ.

Nhóm đối chứng: vùng Manhattan phía bắc và các quận ngoài (loại sân bay, vùng vắt ranh giới, vùng không xác định, vùng quá nhỏ).

Đặc tả:

(1) TWFE : $y_{zt} = a_z + g_t + b \cdot D_{zt} + e$

(2) DDD mùa vụ: thêm hiệu ứng cố định (nhóm xử lý x tuần-trong-năm), tức là so sánh chênh lệch xử lý-đối chứng của cùng tuần giữa 2025 và 2024.

(3) TWFE có trọng số theo số chuyến bình quân năm 2024.

Sai số chuẩn phân cụm theo vùng.

Chạy: python code/07_did_main.py

```

"""
import json
import time

import matplotlib.dates as mdates
import numpy as np
import pandas as pd

from causal import event_study, fe_ols, pretrend_wald, pretrend_wald_centered
from config import LOG, TAB
from panels import P, od_month, zone_day, zone_hour_month, zone_week
from viz import C, fig, plt, policy_line, save

t0 = time.time()
OUTCOMES_HV = {
    "ln_n": "log số chuyến đón",
    "fare_pm": "Giá cước cơ sở / dặm (USD)",
    "pay_pm": "Thu nhập tài xế / dặm (USD)",
    "fare_pt": "Giá cước cơ sở / chuyến (USD)",
    "pay_pt": "Thu nhập tài xế / chuyến (USD)",
    "rider_pt": "Tổng chi phí hành khách / chuyến (USD)",
    "cbd_pt": "Phí CBD / chuyến (USD)",
    "tips_pt": "Tiền tip / chuyến (USD)",
    "pay_share": "Thu nhập tài xế / giá cước (%)",
    "mph": "Tốc độ trung bình (dặm/giờ)",
    "miles_pt": "Quãng đường / chuyến (dặm)",
    "wait": "Thời gian chờ đón (phút)",
    "shared_pct": "Tỷ lệ chuyến có yêu cầu đi chung (%)",
}
OUTCOMES_YE = {k: v for k, v in OUTCOMES_HV.items() if k in ("ln_n", "fare_pm", "fare_pt",
"rider_pt", "cbd_pt", "tips_pt", "mph", "miles_pt")}
OUTCOMES_YE["rider_pt"] = "Tổng tiền thanh toán trừ tip / chuyến (USD)"

rows = []
meta = {}

def run_specs(panel, outcomes, service, label):
    for y, ylab in outcomes.items():
        if panel[y].notna().sum() == 0:
            continue
        specs = {
            "TWFE": dict(fes=["zone", "wk"], w=None, x=["D"]),
            "DDD mùa vụ": dict(fes=["zone", "wk", "tw"], w=None, x=["D"]),
            "TWFE có trọng số": dict(fes=["zone", "wk"], w="w_pre", x=["D"]),
            # Cho phép nhóm xử lý có xu hướng tuyến tính riêng (năm), tác động là độ dịch mức sau
            "TWFE + xu hướng nhóm": dict(fes=["zone", "wk"], w=None, x=["D", "trend_T"]),
            # Lưu ý: không kết hợp DDD với xu hướng nhóm vì khi đã có FE nhóm×tuần-trong-năm,
            # biến xu hướng tuyến tính và D gần như đa cộng tuyến hoàn toàn (không định danh được).
        }
        for sname, sp in specs.items():
            res, info, _ = fe_ols(panel, y, sp["x"], sp["fes"], "zone", sp["w"])
            r = res.iloc[0].to_dict()
            pre_mean = panel.loc[(panel.treat == 1) & (panel.post == 0), y].mean()
            rows.append(dict(service=service, sample=label, outcome=y, outcome_label=ylab,
spec=sname,

```

```

ci_high=r["ci_high"],
coef=r["coef"], se=r["se"], p=r["p"], ci_low=r["ci_low"],
pct_effect=(100 * (np.exp(r["coef"]) - 1)) if y == "ln_n" else 100 *
r["coef"] / pre_mean,
treated_pre_mean=pre_mean, n_obs=info["n_obs"],
n_clusters=info["n_clusters"],
within_r2=info["within_r2"]))

# ----- (A) HVFHV: panel vùng x tuần -----
zw = zone_week("hvfhv", extra=("n_to_crz",))
zw["tw"] = zw.treat.astype(str) + "_" + zw.woy.astype(str)
zw["trend_T"] = zw.treat * zw.k / 52.0
zw["ln_to_crz"] = np.log1p(zw.n_to_crz)
meta["hv_zone_week"] = dict(zones=int(zw.zone.nunique()), treated=int(zw[zw.treat ==
1].zone.nunique()),
control=int(zw[zw.treat == 0].zone.nunique()),
weeks=int(zw.wk.nunique()),
obs=int(len(zw)), trips=float(zw.n.sum()))
run_specs(zw, OUTCOMES_HV, "hvfhv", "vùngxtuần")

# ----- (B) Taxi vàng -----
# Taxi vàng: số chuyến taxi vàng ở các quận ngoài tăng hơn gấp đôi năm 2025 (xem bảng
# t27b theo VendorID), không liên quan đến CRZ, nên nhóm đối chứng chính chỉ gồm Manhattan phía bắc.
# Đặc tả gồm cả quận ngoài được báo cáo riêng như một phép thử độ nhạy.
yw_all = zone_week("yellow")
yw_all["tw"] = yw_all.treat.astype(str) + "_" + yw_all.woy.astype(str)
yw_all["trend_T"] = yw_all.treat * yw_all.k / 52.0
run_specs(yw_all, {"ln_n": "log số chuyến đón"}, "yellow", "vùngxtuần, đối chứng gồm quận ngoài")
yw = zone_week("yellow", groups=("CRZ", "MN_NORTH"))
yw["tw"] = yw.treat.astype(str) + "_" + yw.woy.astype(str)
yw["trend_T"] = yw.treat * yw.k / 52.0
meta["ye_zone_week"] = dict(zones=int(yw.zone.nunique()), treated=int(yw[yw.treat ==
1].zone.nunique()),
control=int(yw[yw.treat == 0].zone.nunique()),
weeks=int(yw.wk.nunique()),
obs=int(len(yw)), trips=float(yw.n.sum()))
run_specs(yw, OUTCOMES_YE, "yellow", "vùngxtuần")

main = pd.DataFrame(rows)
main.to_csv(TAB / "t30_did_main.csv", index=False)
print(main[main.spec == "TWFE"][["service", "outcome", "coef", "se", "p",
"pct_effect"]].to_string(), flush=True)

# ----- (C) Nghiên cứu sự kiện theo tuần: log số chuyến -----
ev_all = []
for svc, pan in (("hvfhv", zw), ("yellow", yw)):
    res, info, V = event_study(pan, "ln_n", "treat", "k", ["zone", "wk"], "zone", ref=-1, lo=-52,
hi=51)
    res["service"], res["spec"] = svc, "TWFE"
    pt = pretrend_wald_centered(res, V)
    res["pretrend_wald"], res["pretrend_p"] = pt["wald"], pt["p"]
    res["post_mean_c"] = res.loc[res.k >= 0, "coef_c"].mean()
    ev_all.append(res)
    # DDD: chỉ đưa biến giả cho các tuần sau chính sách; tuần 2024 cùng vị trí
    # trong năm đóng vai trò mốc so sánh thông qua hiệu ứng cố định nhómx tuần-trong-năm
    pp = pan.copy()
    ks = sorted(k for k in pp.k.unique() if k >= 0)
    names = []
    for k in ks:
        nm = f"post_{k}"
        pp[nm] = ((pp.k == k) & (pp.treat == 1)).astype(float)
        names.append(nm)
    r2, info2, _ = fe_ols(pp, "ln_n", names, ["zone", "wk", "tw"], "zone")
    r2["k"], r2["service"], r2["spec"] = ks, svc, "DDD mùa vụ"
    r2["pretrend_wald"], r2["pretrend_p"] = np.nan, np.nan
    ev_all.append(r2)
ev = pd.concat(ev_all)
ev.to_csv(TAB / "t31_event_study_weekly_ln_n.csv", index=False)

for svc, nm, ttl in (("hvfhv", "f19_event_study_hvfhv", "HVFHV"), ("yellow",
"f20_event_study_yellow", "Taxi vàng")):
    f, ax = fig(6.8, 3.4)
    e = ev[(ev.service == svc) & (ev.spec == "TWFE")].sort_values("k")
    x = P + pd.to_timedelta(e.k * 7, unit="D")
    ax.fill_between(x, 100 * e.ci_low_c, 100 * e.ci_high_c, color=C["s1"], alpha=0.18, lw=0)
    ax.plot(x, 100 * e.coef_c, color=C["s1"], lw=1.6, label=f"Hệ số tuần (x100, log điểm), KTC 95%")
    ax.axhline(0, color=C["text2"], lw=0.8)
    policy_line(ax, P)
    ax.set_ylabel("Chênh lệch CRZ - đối chứng (log điểm x100)")
    ax.set_title(f"Nghiên cứu sự kiện theo tuần, log số chuyến đón - {ttl} (mốc: TB 52 tuần trước)")
    ax.xaxis.set_major_formatter(mdates.DateFormatter("%m/%y"))
    ax.legend(loc="upper center", bbox_to_anchor=(0.5, -0.13), ncol=2)
    save(f, nm)

```

```

# DDD mùa vụ: chỉ các tuần sau chính sách có nghĩa
f, ax = fig(6.8, 3.2)
for svc, col, lab in (("hvfhv", C["s1"], "HVFHV"), ("yellow", C["s2"], "Taxi vàng")):
    e = ev[(ev.service == svc) & (ev.spec == "DDD mùa vụ") & (ev.k >= 0)].sort_values("k")
    ax.plot(e.k, 100 * e.coef, color=col, lw=1.6, label=lab)
    ax.fill_between(e.k, 100 * e.ci_low, 100 * e.ci_high, color=col, alpha=0.15, lw=0)
ax.axhline(0, color=C["text2"], lw=0.8)
ax.set_xlabel("Tuần kể từ 05/01/2025")
ax.set_ylabel("log điểm x100")
ax.set_title("Tác động theo tuần sau khi khử mùa vụ nhóm (DDD), log số chuyến đón")
ax.legend(loc="lower right")
save(f, "f21_event_ddd_weekly")

# ----- (D) Nghiên cứu sự kiện theo tháng cho các biến giá, thu nhập, tốc độ, thời gian chờ -----
zw["km"] = ((zw.wk.dt.year - 2025) * 12 + zw.wk.dt.month - 1).astype(int)
mo_rows = []
for y in ("fare_pm", "pay_pm", "rider_pt", "mph", "wait", "miles_pt"):
    res, info, V = event_study(zw, y, "treat", "km", ["zone", "wk"], "zone", ref=-1)
    res["outcome"] = y
    pt = pretrend_wald_centered(res, V)
    res["pretrend_p"] = pt["p"]
    # Kiểm tra gián đoạn: chênh lệch giữa TB 3 tháng đầu sau và TB 3 tháng cuối trước chính sách
    # Giá trị đã chuẩn hóa của kỳ mốc (k = -1, hệ số gốc bằng 0)
    n_pre = int((res.k < 0).sum()) + 1
    c_ref = -res.loc[res.k < 0, "coef"].sum() / n_pre
    pre3 = list(res.loc[res.k.isin([-3, -2]), "coef_c"]) + [c_ref]
    res["jump_3v3"] = res.loc[res.k.isin([0, 1, 2]), "coef_c"].mean() - np.mean(pre3)
    mo_rows.append(res)
evm = pd.concat(mo_rows)
evm.to_csv(TAB / "t32_event_study_monthly_hvfhv.csv", index=False)
f, axs = plt.subplots(3, 2, figsize=(6.8, 7.2), sharex=True)
for ax, y in zip(axs.ravel(), ("fare_pm", "pay_pm", "rider_pt", "mph", "wait", "miles_pt")):
    e = evm[evm.outcome == y].sort_values("k")
    ax.errorbar(e.k, e.coef_c, yerr=[e.coef_c - e.ci_low_c, e.ci_high_c - e.coef_c], fmt="o",
    ms=3.5,
    color=C["s1"], ecolor=C["s1"], elinewidth=1, capsize=0)
    ax.axhline(0, color=C["text2"], lw=0.8)
    ax.axvline(-0.5, color=C["text2"], lw=0.8, ls="--")
    ax.set_title(OUTCOMES_HV[y], fontsize=9)
for ax in axs[-1]:
    ax.set_xlabel("Tháng so với 01/2025")
f.suptitle("Nghiên cứu sự kiện theo tháng (HVFHV, vùng×tuần, mốc: TB 12 tháng 2024)", x=0.02,
ha="left",
    fontsize=10.5, fontweight="bold")
f.tight_layout()
save(f, "f22_event_monthly_grid")

# ----- (E) Không đồng nhất theo khung giờ -----
hm = zone_hour_month("hvfhv")
hrows = []
for hb, g in hm.groupby("hbin"):
    for y in ("ln_n", "mph", "wait", "fare_pm"):
        res, info, _ = fe_ols(g, y, ["D"], ["zone", "ym"], "zone")
        r = res.iloc[0]
        hrows.append(dict(hbin=hb, outcome=y, coef=r.coef, se=r.se, p=r.p, ci_low=r.ci_low,
ci_high=r.ci_high,
n_obs=info["n_obs"], pre_mean=g.loc[(g.treat == 1) & (g.post == 0),
y].mean()))
hh = pd.DataFrame(hrows)
hh.to_csv(TAB / "t33_heterogeneity_hour.csv", index=False)
f, axs = fig(6.8, 3.0, ncols=2)
for ax, y, ttl in ((axs[0], "ln_n", "log số chuyến đón (x100)"), (axs[1], "mph", "Tốc độ
(dặm/giờ)")):
    e = hh[hh.outcome == y].sort_values("hbin")
    sc = 100 if y == "ln_n" else 1
    xx = np.arange(len(e))
    ax.bar(xx, sc * e.coef, color=C["s1"], width=0.6)
    ax.errorbar(xx, sc * e.coef, yerr=[sc * (e.coef - e.ci_low), sc * (e.ci_high - e.coef)],
fmt="none",
    ecolor=C["text2"], elinewidth=1)
    ax.set_xticks(xx, e.hbin)
    ax.axhline(0, color=C["text2"], lw=0.8)
    ax.set_title(ttl, fontsize=9.5)
    ax.set_xlabel("Khung giờ đón")
f.suptitle("Tác động DiD theo khung giờ (HVFHV, vùng×khung giờ×tháng)", x=0.02, ha="left",
    fontsize=10.5, fontweight="bold")
f.tight_layout()
save(f, "f23_heterogeneity_hour")

# ----- (F) Ngày thường và cuối tuần -----
zd = zone_day("hvfhv")
zd["D_we"] = zd.D * zd.weekend
wres = []
for y in ("ln_n", "mph", "wait", "fare_pm"):

```

```

        res, info, _ = fe_ols(zd, y, ["D", "D_we"], ["zone", "d"], "zone")
        res["outcome"] = y
        res["n_obs"] = info["n_obs"]
        wres.append(res)
pd.concat(wres).to_csv(TAB / "t34_heterogeneity_weekend.csv", index=False)
meta["hv_zone_day"] = dict(zones=int(zd.zone.nunique()), obs=int(len(zd)))

# ----- (G) Panel cặp OD x tháng -----
od = od_month("hvfhv")
meta["hv_od_month"] = dict(pairs=int(od.pair.nunique()), obs=int(len(od)),
                           by_type=od.groupby("ftype").pair.nunique().to_dict(),
                           trips=float(od.n.sum()))
orow = []
for ft in ("Tất cả chuyến chạm CRZ", "CRZ-CRZ", "CRZ-ngoài", "ngoài-CRZ"):
    sub = od if ft.startswith("Tất cả") else od[(od.ftype == ft) | (od.touch == 0)]
    for y in ("ln_n", "fare_pm", "pay_pm", "rider_pt", "cbd_pt", "mph", "pay_share", "tips_pt",
              "fare_pt", "pay_pt", "shared_pct"):
        res, info, _ = fe_ols(sub, y, ["D"], ["pair", "ym"], "pu")
        r = res.iloc[0]
        pre_mean = sub.loc[(sub.touch == 1) & (sub.post == 0), y].mean()
        orow.append(dict(flow=ft, outcome=y, outcome_label=OUTCOMES_HV.get(y, y), coef=r.coef,
                        se=r.se, p=r.p,
                        ci_low=r.ci_low, ci_high=r.ci_high, pre_mean=pre_mean,
                        pct=(100 * (np.exp(r.coef) - 1)) if y == "ln_n" else 100 * r.coef /
                        pre_mean,
                        n_obs=info["n_obs"], n_clusters=info["n_clusters"])))
odr = pd.DataFrame(orow)
odr.to_csv(TAB / "t35_did_od_pairs.csv", index=False)
print(odr[odr.outcome.isin(["ln_n", "rider_pt", "cbd_pt", "fare_pt", "pay_pt"])].to_string(),
      flush=True)

# Tỷ lệ chuyển giá (pass-through) của phí CBD sang tổng chi phí hành khách
pt_rows = []
for ft in ("Tất cả chuyến chạm CRZ", "CRZ-CRZ", "CRZ-ngoài", "ngoài-CRZ"):
    a = odr[(odr.flow == ft) & (odr.outcome == "rider_pt")].iloc[0]
    b = odr[(odr.flow == ft) & (odr.outcome == "cbd_pt")].iloc[0]
    c = odr[(odr.flow == ft) & (odr.outcome == "fare_pt")].iloc[0]
    d = odr[(odr.flow == ft) & (odr.outcome == "pay_pt")].iloc[0]
    pt_rows.append(dict(flow=ft, d_rider_cost=a.coef, d_cbd=b.coef, d_base_fare=c.coef,
                        d_driver_pay=d.coef,
                        pass_through_ratio=a.coef / b.coef if b.coef else np.nan))
pd.DataFrame(pt_rows).to_csv(TAB / "t36_pass_through.csv", index=False)

# Nghiên cứu sự kiện theo tháng cho panel OD: log số chuyến
res, info, V = event_study(od, "ln_n", "touch", "k", ["pair", "ym"], "pu", ref=-1)
res["pretrend_p"] = pretrend_wald_centered(res, V)["p"]
res.to_csv(TAB / "t37_event_od_ln_n.csv", index=False)
f, ax = fig(6.6, 3.1)
ax.errorbar(res.k, 100 * res.coef_c, yerr=[100 * (res.coef_c - res.ci_low_c), 100 * (res.ci_high_c -
res.coef_c)],
            fmt="o", ms=4, color=C["s1"], elinewidth=1)
ax.axhline(0, color=C["text2"], lw=0.8)
ax.axvline(-0.5, color=C["text2"], lw=0.8, ls="--")
ax.set_xlabel("Tháng so với 01/2025")
ax.set_ylabel("log điểm x100")
ax.set_title("Nghiên cứu sự kiện theo tháng, cặp OD chạm CRZ so với không chạm (mốc: TB 2024)")
save(f, "f24_event_od")

(LOG / "07_did_main.json").write_text(json.dumps(dict(seconds=round(time.time() - t0, 1), **meta),
indent=2, default=float))
print(json.dumps(meta, indent=1, default=float), "time", round(time.time() - t0, 1))

```

I.13. 08_synthetic_control.py

""""Bước 8 - Kiểm soát tổng hợp (Synthetic Control) cho tổng số chuyến đón trong CRZ.

Chuỗi xử lý: tổng số chuyến HVFHV đón trong 38 vùng CRZ theo tuần, chuẩn hóa bằng trung bình năm 2024 (chỉ số = 1). Nguồn đối chứng (donor pool): các vùng đối chứng của panel chính, chuẩn hóa tương tự. Trọng số $w \geq 0$, tổng bằng 1, được chọn để khớp 52 tuần năm 2024. Hai biến thể: SCM chuẩn (Abadie và cộng sự) và SCM khử trung bình (cho phép chênh lệch mức cố định, Ferman & Pinto). Suy diễn: kiểm định giả được theo không gian (lần lượt coi từng vùng đối chứng là "vùng xử lý"), so sánh tỷ số RMSPE sau/trước.

Chạy: python code/08_synthetic_control.py

```

"""
import json
import time

import numpy as np
import pandas as pd
from scipy.optimize import minimize

```

```

from config import LOG, TAB
from panels import P, zone_week
from viz import C, fig, plt, policy_line, save

t0 = time.time()
zw = zone_week("hvfhv")
W = zw.pivot_table(index="wk", columns="zone", values="n", aggfunc="sum")
treated_z = sorted(zw[zw.treat == 1].zone.unique())
donors = sorted(zw[zw.treat == 0].zone.unique())
pre = W.index < P
yT = W[treated_z].sum(axis=1)
yT = yT / yT[pre].mean()
Y0 = W[donors] / W[donors][pre].mean()

def fit_w(y, X, demean=False):
    yp, Xp = y[pre].to_numpy(), X[pre].to_numpy()
    if demean:
        yp = yp - yp.mean()
        Xp = Xp - Xp.mean(axis=0)
    J = Xp.shape[1]
    obj = lambda w: np.sum((yp - Xp @ w) ** 2)
    jac = lambda w: -2 * Xp.T @ (yp - Xp @ w)
    cons = ({ "type": "eq", "fun": lambda w: w.sum() - 1, "jac": lambda w: np.ones(J)},)
    r = minimize(obj, np.full(J, 1 / J), jac=jac, bounds=[(0, 1)] * J, constraints=cons,
                method="SLSQP", options=dict(maxiter=500, ftol=1e-12))
    w = np.clip(r.x, 0, None)
    w = w / w.sum()
    synth = X.to_numpy() @ w
    if demean:
        synth = synth + (y[pre].mean() - (X[pre].to_numpy() @ w).mean())
    return w, pd.Series(synth, index=y.index)

out = {}
res = {}
for demean in (False, True):
    w, s = fit_w(yT, Y0, demean)
    gap = yT - s
    rm_pre = float(np.sqrt(np.mean(gap[pre] ** 2)))
    rm_post = float(np.sqrt(np.mean(gap[~pre] ** 2)))
    key = "demeaned" if demean else "standard"
    res[key] = (w, s, gap)
    out[key] = dict(rmspe_pre=rm_pre, rmspe_post=rm_post, ratio=rm_post / rm_pre,
                    avg_gap_post=float(gap[~pre].mean()),
                    avg_pct_effect_post=float(100 * (yT[~pre] / s[~pre] - 1).mean()),
                    n_donors_positive=int((w > 1e-3).sum()))
    wt = pd.DataFrame(dict(zone=donors, weight=w)).sort_values("weight", ascending=False)
    wt = wt.merge(zw[["zone", "Borough", "grp"]].drop_duplicates(), on="zone")
    wt.to_csv(TAB / f"t38_scm_weights_{key}.csv", index=False)

pd.DataFrame({"week": W.index, "treated_index": yT.values, "synth_standard": res["standard"]
[1].values,
              "synth_demeaned": res["demeaned"][1].values}).to_csv(TAB / "t39_scm_series.csv",
index=False)

f, axs = plt.subplots(2, 1, figsize=(6.8, 5.4), sharex=True)
axs[0].plot(yT.index, yT, color=C["s1"], label="CRZ thực tế")
axs[0].plot(yT.index, res["standard"][1], color=C["s2"], label="CRZ tổng hợp (SCM chuẩn)")
policy_line(axs[0], P)
axs[0].set_ylabel("Chỉ số (TB 2024 = 1)")
axs[0].set_title("Kiểm soát tổng hợp: số chuyển HVFHV đón trong CRZ theo tuần")
axs[0].legend(loc="lower left", fontsize=8)
axs[1].plot(yT.index, 100 * res["standard"][2], color=C["s2"], label="SCM chuẩn")
axs[1].axhline(0, color=C["text2"], lw=0.8)
policy_line(axs[1], P, "")
axs[1].set_ylabel("Khoảng cách x100")
axs[1].set_title("Khoảng cách giữa CRZ thực tế và CRZ tổng hợp")
axs[1].legend(loc="lower left", fontsize=8)
f.tight_layout()
save(f, "f25_scm_fit_gap")

# ----- Giả được theo không gian -----
vol = W[donors][pre].mean().sort_values(ascending=False)
plac_units = vol.index[:60]
pl_rows, gaps = [], {}
for u in plac_units:
    y = Y0[u]
    others = [d for d in donors if d != u]
    w, s = fit_w(y, Y0[others], demean=True)
    g = y - s
    rp, rq = np.sqrt(np.mean(g[pre] ** 2)), np.sqrt(np.mean(g[~pre] ** 2))
    pl_rows.append(dict(zone=u, rmspe_pre=rp, rmspe_post=rq, ratio=rq / rp,
                        avg_gap_post=g[~pre].mean()))

```

```

        gaps[u] = g
    pl = pd.DataFrame(pl_rows)
    tr_ratio = out["demeaned"]["ratio"]
    out["placebo_n"] = int(len(pl))
    out["placebo_rank_p"] = float((1 + (pl.ratio >= tr_ratio).sum()) / (1 + len(pl)))
    out["placebo_gap_p"] = float((1 + (pl.avg_gap_post.abs() >= abs(out["demeaned"]
    ["avg_gap_post"])).sum()) / (1 + len(pl)))
    pl = pl.merge(zw[["zone", "Zone", "Borough", "grp"]].drop_duplicates(), on="zone")
    pl.to_csv(TAB / "t40_scm_placebo.csv", index=False)

f, ax = fig(6.8, 3.4)
for u, g in gaps.items():
    ax.plot(g.index, 100 * g, color=C["neutral"], lw=0.7)
ax.plot(yT.index, 100 * res["demeaned"][2], color=C["s1"], lw=2.2, label="CRZ")
ax.plot([], [], color=C["neutral"], lw=0.7, label=f"{len(gaps)} vùng giả được")
ax.axhline(0, color=C["text2"], lw=0.8)
policy_line(ax, P)
ax.set_ylim(-60, 60)
ax.set_ylabel("Khoảng cách x100")
ax.set_title("Giả được theo không gian: khoảng cách SCM của CRZ và của các vùng đối chứng")
ax.legend(loc="upper center", bbox_to_anchor=(0.5, -0.13), ncol=2)
save(f, "f26_scm_placebo")

f, ax = fig(6.0, 3.0)
ax.hist(pl.ratio, bins=25, color=C["neutral"], edgecolor="white")
ax.axvline(tr_ratio, color=C["s1"], lw=2)
ax.annotate(f"CRZ: {tr_ratio:.2f}", (tr_ratio, ax.get_ylim()[1] * 0.9), xytext=(5, 0),
            textcoords="offset points", color=C["text"])
ax.set_xlabel("Tỷ số RMSPE sau / trước")
ax.set_ylabel("Số vùng")
ax.set_title("Phân phối tỷ số RMSPE của các vùng giả được")
save(f, "f27_scm_rmspe_ratio")

(LOG / "08_scm.json").write_text(json.dumps(dict(seconds=round(time.time() - t0, 1), **out),
indent=2, default=float))
print(json.dumps(out, indent=1, default=float))

```

I.14. 09_dml_heterogeneity.py

""""Bước 9 - Học máy nhân quả: Double/Debiased ML và tác động không đồng nhất.

Đơn vị: cặp vùng (điểm đón, điểm trả) có lưu lượng ổn định (panel OD bước 7).

Kết quả: thay đổi cùng kỳ $\Delta Y = Y(2025) - Y(2024)$ cho từng cặp OD

- dlog_n : chênh lệch log tổng số chuyến cả năm
- d_mph : chênh lệch tốc độ trung bình
- d_pay_pm : chênh lệch thu nhập tài xế/dặm

Xử lý: D = 1 nếu cặp OD chạm CRZ (điểm đón hoặc điểm trả trong CRZ).

Biến kiểm soát X: đặc trưng năm 2024 của cặp OD (quãng đường, thời lượng, tốc độ, giá/dặm, log lưu lượng, tỷ trọng Uber, tỷ trọng chuyển đêm...) và quận của điểm đón/điểm trả. Không đưa khoảng cách tới CRZ vào X vì biến này xác định gần như hoàn toàn D (vi phạm điều kiện chồng lấn).

Ước lượng:

- (1) PLR - mô hình tuyến tính từng phần (Chernozhukov và cộng sự, 2018), nuisance bằng LightGBM, cross-fitting 5 phần.
- (2) AIPW/DR - ước lượng bền vững kép, cắt xu hướng ở [0,05; 0,95].
- (3) CATE bằng DR-learner; kiểm định không đồng nhất bằng BLP và GATES (Chernozhukov, Demirer, Duflo, Fernández-Val).

Chạy: python code/09_dml_heterogeneity.py

```

"""
import json
import time

import lightgbm as lgb
import numpy as np
import pandas as pd
from sklearn.model_selection import KFold

from config import GOLD, LOG, SEED, TAB
from panels import dim
from viz import C, fig, plt, save

t0 = time.time()
rng = np.random.default_rng(SEED)
o = pd.read_parquet(GOLD / "od_month.parquet")
o = o[o.service == "hvfhv"].copy()
dm = dim().set_index("LocationID")
o["pu_grp"], o["do_grp"] = o.pu.map(dm.grp), o.dl.map(dm.grp)
ok = ["CRZ", "MN_NORTH", "OUTER"]
o = o[o.pu_grp.isin(ok) & o.do_grp.isin(ok)]
o["yr"] = o.ym.str[:4].astype(int)

```



```

agg = o.groupby(["pu", "dl", "yr"])[["n", "fare", "pay", "miles", "time_s", "tips",
"rider_cost"]].sum().unstack("yr")
agg = agg[(agg[("n", 2024)] >= 12 * 300) & (agg[("n", 2025)] > 0)]

# Đặc trưng 2024 bổ sung: tỷ trọng Uber và tỷ trọng giờ đêm từ mẫu chuyến
smp = pd.read_parquet(GOLD / "trip_sample.parquet", columns=["service", "d", "pu", "dl",
"company_code", "hr"])
smp = smp[(smp.service == "hvfhv") & (pd.to_datetime(smp.d).dt.year == 2024)]
sf = smp.groupby(["pu", "dl"]).agg(uber_share=("company_code", lambda s: (s == "HV0003").mean()),
night_share=("hr", lambda h: ((h <= 5) | (h >= 22)).mean()),
n_sample=("hr", "size"))

df = pd.DataFrame(index=agg.index)
for yr in (2024, 2025):
    df[f"ln_n_{yr}"] = np.log(agg[("n", yr)])
    df[f"mph_{yr}"] = agg[("miles", yr)] / (agg[("time_s", yr)] / 3600)
    df[f"pay_pm_{yr}"] = agg[("pay", yr)] / agg[("miles", yr)]
    df[f"fare_pm_{yr}"] = agg[("fare", yr)] / agg[("miles", yr)]
df["dlog_n"] = df.ln_n_2025 - df.ln_n_2024
df["d_mph"] = df.mph_2025 - df.mph_2024
df["d_pay_pm"] = df.pay_pm_2025 - df.pay_pm_2024
df["miles_pt"] = agg[("miles", 2024)] / agg[("n", 2024)]
df["min_pt"] = agg[("time_s", 2024)] / agg[("n", 2024)] / 60
df["tips_pt"] = agg[("tips", 2024)] / agg[("n", 2024)]
df = df.reset_index()
df = df.merge(sf.reset_index(), on=["pu", "dl"], how="left")
df["pu_boro"] = df.pu.map(dm.Borough)
df["do_boro"] = df.dl.map(dm.Borough)
df["same_zone"] = (df.pu == df.dl).astype(int)
df["d"] = ((df.pu.map(dm.grp) == "CRZ") | (df.dl.map(dm.grp) == "CRZ")).astype(int)
df["ftype"] = np.select([(df.pu.map(dm.grp) == "CRZ") & (df.dl.map(dm.grp) == "CRZ"),
df.pu.map(dm.grp) == "CRZ", df.dl.map(dm.grp) == "CRZ"],
["CRZ-CRZ", "CRZ-ngoài", "ngoài-CRZ"], "không chạm CRZ")
for b in ["Manhattan", "Brooklyn", "Queens", "Bronx", "Staten Island"]:
    df[f"pu_{b[:3]}"] = (df.pu_boro == b).astype(int)
    df[f"do_{b[:3]}"] = (df.do_boro == b).astype(int)
BORO = [c for c in df.columns if c[:3] in ("pu_", "do_") and c[3:6] in ("Man", "Bro", "Que", "Sta")]
X_SETS = {
    # Bộ chính: chỉ đặc trưng của chuyến đi, không mã hóa trực tiếp vị trí
    "rút gọn": ["ln_n_2024", "miles_pt", "min_pt", "tips_pt", "uber_share", "night_share",
"same_zone"],
    # Bộ đầy đủ: thêm tốc độ, giá/dặm, thu nhập/dặm và quận (vi phạm chồng lấn mạnh)
    "đầy đủ": ["ln_n_2024", "mph_2024", "fare_pm_2024", "pay_pm_2024", "miles_pt", "min_pt",
"tips_pt",
"uber_share", "night_share", "same_zone"] + BORO,
}
allx = sorted(set(sum(X_SETS.values(), [])))
df[allx] = df[allx].fillna(df[allx].median())
df.to_parquet(GOLD / "dml_od_dataset.parquet", index=False)
MAIN = "rút gọn"
X_COLS = X_SETS[MAIN]

X = df[X_COLS].to_numpy()
D = df.D.to_numpy()
K = 5
kf = KFold(K, shuffle=True, random_state=SEED)
params = dict(n_estimators=400, learning_rate=0.03, num_leaves=15, min_child_samples=40,
subsampling=0.8, subsampling_freq=1, colsample_bytree=0.8, reg_lambda=1.0,
random_state=SEED, verbose=-1, n_jobs=2)

# Xu hướng (propensity) - dùng chung cho mọi kết quả
e_hat = np.zeros(len(df))
for tr, te in kf.split(X):
    clf = lgb.LGBMClassifier(**params).fit(X[tr], D[tr])
    e_hat[te] = clf.predict_proba(X[te])[:, 1]
df["e_hat"] = e_hat
from sklearn.metrics import roc_auc_score
overlap = dict(auc_propensity=float(roc_auc_score(D, e_hat)),
share_trimmed=float(((e_hat < 0.05) | (e_hat > 0.95)).mean()),
n=int(len(df)), n_treated=int(D.sum()))

f, ax = fig(6.2, 3.0)
bins = np.linspace(0, 1, 41)
ax.hist(e_hat[D == 1], bins=bins, color=C["s1"], alpha=0.75, label="Cặp OD chạm CRZ")
ax.hist(e_hat[D == 0], bins=bins, color=C["s2"], alpha=0.6, label="Cặp OD không chạm CRZ")
for v in (0.05, 0.95):
    ax.axvline(v, color=C["text2"], lw=0.8, ls="--")
ax.set_xlabel("Xác suất ước lượng thuộc nhóm xử lý ê(X)")
ax.set_ylabel("Số cặp OD")
ax.set_title("Kiểm tra chồng lấn: phân phối điểm xu hướng (cross-fitted)")
ax.legend()
save(f, "f28_dml_overlap")

results, gates_all, blp_all, clan_all, imp_all, sens_rows = [], [], [], [], [], []
keep = (e_hat >= 0.05) & (e_hat <= 0.95)

```

```

for yname, ylab in (("dlog_n", "Δ log số chuyển"), ("d_mph", "Δ tốc độ (dặm/giờ)"), ("d_pay_pm", "Δ
thu nhập tài xế/dặm")):
    Y = df[ymame].to_numpy()
    g_hat = np.zeros(len(df))
    mu1 = np.zeros(len(df))
    mu0 = np.zeros(len(df))
    for tr, te in kf.split(X):
        g_hat[te] = lgb.LGBMRegressor(**params).fit(X[tr], Y[tr]).predict(X[te])
        t1, t0_ = tr[D[tr] == 1], tr[D[tr] == 0]
        mu1[te] = lgb.LGBMRegressor(**params).fit(X[t1], Y[t1]).predict(X[te])
        mu0[te] = lgb.LGBMRegressor(**params).fit(X[t0_], Y[t0_]).predict(X[te])
    # (1) PLR
    yr_, dr_ = Y - g_hat, D - e_hat
    theta = np.sum(dr_ * yr_) / np.sum(dr_ ** 2)
    psi = (yr_ - theta * dr_) * dr_
    se_plr = np.sqrt(np.mean(psi ** 2) / np.mean(dr_ ** 2) ** 2 / len(Y))
    # (2) AIPW trên vùng chồng lấn
    ec = np.clip(e_hat, 0.05, 0.95)
    phi = mu1 - mu0 + D * (Y - mu1) / ec - (1 - D) * (Y - mu0) / (1 - ec)
    ate = phi[keep].mean()
    se_ate = phi[keep].std(ddof=1) / np.sqrt(keep.sum())
    att_w = D[keep] / D[keep].mean()
    att = np.mean(att_w * (Y[keep] - mu0[keep]) - (1 - D[keep]) * ec[keep] / (1 - ec[keep]) *
(Y[keep] - mu0[keep]) / D[keep].mean())
    naive = Y[D == 1].mean() - Y[D == 0].mean()
    # (3) DR-learner cho CATE (cross-fit lần 2)
    tau = np.zeros(len(df))
    Xk, phik = X[keep], phi[keep]
    idx_keep = np.where(keep)[0]
    imp = np.zeros(len(X_COLS))
    for tr, te in KFold(K, shuffle=True, random_state=SEED + 1).split(Xk):
        mdl = lgb.LGBMRegressor(**{**params, "n_estimators": 300, "num_leaves": 7,
"min_child_samples": 80}).fit(Xk[tr], phik[tr])
        tau[idx_keep[te]] = mdl.predict(Xk[te])
        imp += mdl.booster_.feature_importance("gain")
    imp_all.append(pd.DataFrame(dict(outcome=ymame, feature=X_COLS, gain=imp / imp.sum())))
    tk = tau[keep]
    # BLP: phi = b1 + b2 (tau - mean tau)
    Z = np.c_[np.ones(keep.sum()), tk - tk.mean()]
    b = np.linalg.lstsq(Z, phik, rcond=None)[0]
    res_ = phik - Z @ b
    Vb = np.linalg.inv(Z.T @ Z) @ (Z.T * res_ ** 2) @ Z @ np.linalg.inv(Z.T @ Z)
    blp_all.append(dict(outcome=ymame, beta1=b[0], se1=np.sqrt(Vb[0, 0]), beta2=b[1],
se2=np.sqrt(Vb[1, 1]),
t2=b[1] / np.sqrt(Vb[1, 1])))
    # GATES theo ngũ phân vị của tau
    qg = pd.qcut(tk, 5, labels=False, duplicates="drop")
    for gidx in sorted(np.unique(qg)):
        sel = qg == gidx
        gates_all.append(dict(outcome=ymame, group=int(gidx) + 1, n=int(sel.sum()),
gate=phik[sel].mean(),
se=phik[sel].std(ddof=1) / np.sqrt(sel.sum()),
tau_mean=tk[sel].mean()))
    # CLAN: đặc trưng trung bình ở nhóm tác động thấp nhất và cao nhất
    lo_, hi_ = qg == qg.min(), qg == qg.max()
    dk = df.loc[keep].reset_index(drop=True)
    for c in ["miles_pt", "min_pt", "mph_2024", "fare_pm_2024", "ln_n_2024", "uber_share",
"night_share", "D"]:
        clan_all.append(dict(outcome=ymame, feature=c, low_group=dk.loc[lo_, c].mean(),
high_group=dk.loc[hi_, c].mean()))
    df[f"tau_{ymame}"] = tau
    df.loc[~keep, f"tau_{ymame}"] = np.nan
    results.append(dict(outcome=ymame, outcome_label=ylab, naive_diff=naive, plr_theta=theta,
plr_se=se_plr,
aipw_ate=ate, aipw_se=se_ate, aipw_att=att, n_used=int(keep.sum()),
r2_g=1 - np.mean((Y - g_hat) ** 2) / np.var(Y)))
    print(results[-1], flush=True)

# Độ nhạy: bộ biến đầy đủ (chỉ ước lượng ATE, kèm chẩn đoán chồng lấn)
for xs_name, xs in X_SETS.items():
    xs_ = df[xs].to_numpy()
    e2 = np.zeros(len(df))
    for tr, te in kf.split(xs_):
        e2[te] = lgb.LGBMClassifier(**params).fit(xs_[tr], D[tr]).predict_proba(xs_[te])[1, :]
    keep2 = (e2 >= 0.05) & (e2 <= 0.95)
    for yname in ("dlog_n", "d_mph", "d_pay_pm"):
        Y = df[ymame].to_numpy()
        g2, m1, m0 = np.zeros(len(df)), np.zeros(len(df)), np.zeros(len(df))
        for tr, te in kf.split(xs_):
            g2[te] = lgb.LGBMRegressor(**params).fit(xs_[tr], Y[tr]).predict(xs_[te])
            t1, t0_ = tr[D[tr] == 1], tr[D[tr] == 0]
            m1[te] = lgb.LGBMRegressor(**params).fit(xs_[t1], Y[t1]).predict(xs_[te])
            m0[te] = lgb.LGBMRegressor(**params).fit(xs_[t0_], Y[t0_]).predict(xs_[te])
        yr_, dr_ = Y - g2, D - e2
        th = np.sum(dr_ * yr_) / np.sum(dr_ ** 2)

```

```

ps = (yr_ - th * dr_) * dr_
se_ = np.sqrt(np.mean(ps ** 2) / np.mean(dr_ ** 2) ** 2 / len(Y))
ec2 = np.clip(e2, 0.05, 0.95)
ph = m1 - m0 + D * (Y - m1) / ec2 - (1 - D) * (Y - m0) / (1 - ec2)
sens_rows.append(dict(x_set=xs_name, n_features=len(xs), outcome=yname,
                      share_in_overlap=keep2.mean(), n_overlap=int(keep2.sum()),
                      n_treated_overlap=int(D[keep2].sum()), plr_theta=th, plr_se=se_,
                      aipw_ate=ph[keep2].mean(), aipw_se=ph[keep2].std(ddof=1) /
                      np.sqrt(keep2.sum()))))
pd.DataFrame(sens_rows).to_csv(TAB / "t41b_dml_sensitivity_xsets.csv", index=False)
pd.DataFrame(results).to_csv(TAB / "t41_dml_ate.csv", index=False)
pd.DataFrame(bl_p_all).to_csv(TAB / "t42_dml_blp.csv", index=False)
gates = pd.DataFrame(gates_all)
gates.to_csv(TAB / "t43_dml_gates.csv", index=False)
pd.DataFrame(clan_all).to_csv(TAB / "t44_dml_clan.csv", index=False)
pd.concat(imp_all).to_csv(TAB / "t45_dml_cate_importance.csv", index=False)
df.to_parquet(GOLD / "dml_od_dataset.parquet", index=False)

f, axs = fig(6.8, 3.0, ncol=3)
for ax, (y, ttl, sc) in zip(axs, (("dlog_n", "Δ log số chuyển ×100", 100), ("d_mph", "Δ tốc độ
(dặm/giờ)", 1),
                                ("d_pay_pm", "Δ thu nhập/dặm (USD)", 1))):
    g = gates[gates.outcome == y]
    ax.bar(g.group, sc * g.gate, color=C["s1"], width=0.6)
    ax.errorbar(g.group, sc * g.gate, yerr=sc * 1.96 * g.se, fmt="none", ecolor=C["text2"],
    elinewidth=1)
    ax.axhline(0, color=C["text2"], lw=0.8)
    ax.set_title(ttl, fontsize=9)
    ax.set_xlabel("Nhóm theo τ (1 thấp → 5 cao)")
f.suptitle("GATES: tác động trung bình theo nhóm ngũ phân vị của CATE ước lượng", x=0.02, ha="left",
          fontsize=10.5, fontweight="bold")
f.tight_layout()
save(f, "f29_dml_gates")

# CATE theo quãng đường chuyển và theo loại luồng
dk = df[keep].copy()
dk["dist_bin"] = pd.qcut(dk.miles_pt, 8)
cb = dk[dk.D == 1].groupby("dist_bin", observed=True).agg(tau=("tau_dlog_n", "mean"),
miles=("miles_pt", "mean"), n=("pu", "size"))
cb.to_csv(TAB / "t46_cate_by_distance.csv")
ft = dk.groupby("ftype").agg(tau_dlog_n=("tau_dlog_n", "mean"), tau_d_mph=("tau_d_mph", "mean"),
tau_d_pay_pm=("tau_d_pay_pm", "mean"), n=("pu", "size"))
ft.to_csv(TAB / "t47_cate_by_flowtype.csv")
f, ax = fig(6.2, 3.0)
ax.plot(cb.miles, 100 * cb.tau, color=C["s1"], marker="o")
ax.axhline(0, color=C["text2"], lw=0.8)
ax.set_xlabel("Quãng đường trung bình của cặp OD năm 2024 (dặm)")
ax.set_ylabel("τ log số chuyển ×100")
ax.set_title("CATE ước lượng theo quãng đường chuyển (cặp OD chạm CRZ)")
save(f, "f30_cate_by_distance")

imp = pd.concat(imp_all)
f, ax = fig(6.2, 3.4)
ii = imp[imp.outcome == "dlog_n"].sort_values("gain").tail(10)
ax.barh(ii.feature, ii.gain, color=C["s1"])
ax.set_xlabel("Tỷ trọng gain trong mô hình CATE")
ax.set_title("Đặc trưng giải thích sự khác biệt tác động (Δ log số chuyển)")
save(f, "f31_cate_importance")

(LOG / "09_dml.json").write_text(json.dumps(dict(seconds=round(time.time() - t0, 1),
overlap=overlap, x_sets=X_SETS, main=MAIN), indent=2, default=float))
print(overlap, "time", round(time.time() - t0, 1))

```

I.15. 10_spillover_robustness.py

""""Bước 10 - Hiệu ứng lan tỏa, kiểm định giả được và độ vững.

- Lan tỏa không gian: các vùng ngoài CRZ nằm sát ranh giới có thay đổi khác các vùng xa hay không (cả điểm đón và điểm trả), theo dải khoảng cách.
- Giả được theo thời gian: chỉ dùng dữ liệu 2024, giả định chính sách bắt đầu 07/07/2024.
- Suy diễn hoàn vi: gán ngẫu nhiên 38 vùng đối chứng làm "vùng xử lý", lặp 500 lần.
- Bảng độ vững cho log số chuyển đón với nhiều lựa chọn mẫu và đặc tả.

Chạy: python code/10_spillover_robustness.py

```

"""
import json
import sys
import time

import numpy as np
import pandas as pd

```

```

from causal import fe_ols
from config import LOG, SEED, TAB
from panels import P, zone_day, zone_week
from viz import C, fig, plt, save

t0 = time.time()
rng = np.random.default_rng(SEED)
meta = {}
PART = sys.argv[1] if len(sys.argv) > 1 else "all"

def want(p):
    return PART in (p, "all")

if want("spill"):
    # ----- (a) Lan tỏa -----
    groups = ("CRZ", "CRZ_PARTIAL", "MN_NORTH", "OUTER")
    pu = zone_week("hvfhv", "zone_day_pu", groups=groups)
    do = zone_week("hvfhv", "zone_day_do", groups=groups, extra=("n_from_crz",))
    do["n_nocrz"] = do.n - do.n_from_crz
    do["ln_nocrz"] = np.log(do.n_nocrz.clip(lower=1))
    do["ln_from_crz"] = np.log(do.n_from_crz.clip(lower=1))

    def band(r):
        if r.grp == "CRZ":
            return "CRZ"
        if r.grp == "CRZ_PARTIAL":
            return "Vất ranh giới"
        d = r.dist_to_crz_km
        if d <= 1.0:
            return "0-1 km"
        if d <= 2.5:
            return "1-2,5 km"
        if d <= 5:
            return "2,5-5 km"
        if d <= 10:
            return "5-10 km"
        return ">10 km"

    sp_rows = []
    for nm, pan, ys in (("điểm đón", pu, ["ln_n"]), ("điểm trả", do, ["ln_n", "ln_nocrz",
"ln_from_crz"])):
        pan = pan.copy()
        pan["band"] = pan.apply(band, axis=1)
        bands = ["CRZ", "Vất ranh giới", "0-1 km", "1-2,5 km", "2,5-5 km", "5-10 km"]
        for b in bands:
            pan[f"D_{b}"] = ((pan.band == b) & (pan.post == 1)).astype(float)
        for y in ys:
            res, info, _ = fe_ols(pan, y, [f"D_{b}" for b in bands], ["zone", "wk", "zone"])
            for (_, r), b in zip(res.iterrows(), bands):
                sp_rows.append(dict(side=nm, outcome=y, band=b, coef=r.coef, se=r.se, p=r.p,
ci_low=r.ci_low,
ci_high=r.ci_high, n_zones=int(pan[pan.band ==
b].zone.nunique()),
ref="> 10 km", n_obs=info["n_obs"])))

    sp = pd.DataFrame(sp_rows)
    sp.to_csv(TAB / "t48_spillover_bands.csv", index=False)
    f, axs = fig(6.8, 3.2, ncols=2, sharey=True)
    for ax, (side, y, ttl) in zip(axs, (("điểm đón", "ln_n", "Số chuyển đón"),
("điểm trả", "ln_nocrz", "Số chuyển trả (khách từ ngoài
CRZ)"))):
        e = sp[(sp.side == side) & (sp.outcome == y)]
        xx = np.arange(len(e))
        cols = [C["s1"] if b == "CRZ" else (C["s2"] if b == "Vất ranh giới" else C["s3"]) for b in
e.band]
        ax.bar(xx, 100 * e.coef, color=cols, width=0.65)
        ax.errorbar(xx, 100 * e.coef, yerr=[100 * (e.coef - e.ci_low), 100 * (e.ci_high - e.coef)],
fmt="none",
ecolor=C["text2"], elinewidth=1)
        ax.set_xticks(xx, e.band, rotation=35, ha="right")
        ax.axhline(0, color=C["text2"], lw=0.8)
        ax.set_title(ttl, fontsize=9.5)
        axs[0].set_ylabel("log điểm x100 (so với vùng > 10 km)")
        f.suptitle("Tác động theo dải khoảng cách tới ranh giới CRZ (HVFHV)", x=0.02, ha="left",
fontsize=10.5,
fontweight="bold")
        f.tight_layout()
        save(f, "f32_spillover_bands")

if want("placebo"):

```

```

# ----- (b) Giả được theo thời gian -----
zw = zone_week("hvfhv")
fake = pd.Timestamp("2024-07-07")
z24 = zw[zw.wk < P].copy()
z24["D_fake"] = ((z24.wk >= fake) & (z24.treat == 1)).astype(float)
pl_rows = []
z24["trend_T"] = z24.treat * z24.k / 52.0
zw["trend_T"] = zw.treat * zw.k / 52.0
for y in ("ln_n", "fare_pm", "pay_pm", "fare_pt", "pay_pt", "rider_pt", "mph", "wait",
"miles_pt"):
    res, info, _ = fe_ols(z24, y, ["D_fake"], ["zone", "wk", "zone"])
    rest, _, _ = fe_ols(z24, y, ["D_fake", "trend_T"], ["zone", "wk", "zone"])
    real, _, _ = fe_ols(zw, y, ["D"], ["zone", "wk", "zone"])
    realt, _, _ = fe_ols(zw, y, ["D", "trend_T"], ["zone", "wk", "zone"])
    pl_rows.append(dict(outcome=y, placebo_coef=res.coef[0], placebo_se=res.se[0],
placebo_p=res.p[0],
placebo_trend_coef=rest.coef[0], placebo_trend_se=rest.se[0],
placebo_trend_p=rest.p[0],
real_coef=real.coef[0], real_se=real.se[0], real_p=real.p[0],
real_trend_coef=realt.coef[0], real_trend_se=realt.se[0],
real_trend_p=realt.p[0]))
pd.DataFrame(pl_rows).to_csv(TAB / "t49_placebo_time.csv", index=False)

# Giả được theo thời gian cho panel cặp OD x tháng (07/2024) và đặc tả có xu hướng riêng
from panels import od_month
od = od_month("hvfhv")
od["trend_T"] = od.touch * od.k / 12.0
o24 = od[od.post == 0].copy()
o24["D_fake"] = ((o24.ym >= "2024-07") & (o24.touch == 1)).astype(float)
op = []
for y in ("ln_n", "fare_pt", "pay_pt", "rider_pt", "fare_pm", "pay_pm", "mph"):
    a = fe_ols(o24, y, ["D_fake"], ["pair", "ym"], "pu")[0].iloc[0]
    b = fe_ols(o24, y, ["D_fake", "trend_T"], ["pair", "ym"], "pu")[0].iloc[0]
    c = fe_ols(od, y, ["D"], ["pair", "ym"], "pu")[0].iloc[0]
    d = fe_ols(od, y, ["D", "trend_T"], ["pair", "ym"], "pu")[0].iloc[0]
    op.append(dict(outcome=y, placebo_coef=a.coef, placebo_se=a.se, placebo_p=a.p,
placebo_trend_coef=b.coef, placebo_trend_se=b.se, placebo_trend_p=b.p,
real_coef=c.coef, real_se=c.se, real_p=c.p,
real_trend_coef=d.coef, real_trend_se=d.se, real_trend_p=d.p))
pd.DataFrame(op).to_csv(TAB / "t49b_placebo_time_od.csv", index=False)

if want("perm"):
    zw = zone_week("hvfhv")
    # ----- (c) Hoán vị -----
    ctrl = zw[zw.treat == 0].zone.unique()
    n_t = zw[zw.treat == 1].zone.nunique()
    real = fe_ols(zw, "ln_n", ["D"], ["zone", "wk", "zone"])[0].coef[0]
    cz = zw[zw.treat == 0].copy()
    perm = []
    for i in range(500):
        fake_t = set(rng.choice(ctrl, size=n_t, replace=False))
        cz["Dp"] = (cz.zone.isin(fake_t) & (cz.post == 1)).astype(float)
        perm.append(fe_ols(cz, "ln_n", ["Dp"], ["zone", "wk", "zone"])[0].coef[0])
    perm = np.array(perm)
    meta["permutation"] = dict(real=float(real), n_perm=len(perm), p_two_sided=float((1 +
np.sum(np.abs(perm) >= abs(real))) / (1 + len(perm))),
perm_mean=float(perm.mean()), perm_sd=float(perm.std()),
perm_p2_5=float(np.percentile(perm, 2.5)),
perm_p97_5=float(np.percentile(perm, 97.5)))
    pd.DataFrame(dict(perm_coef=perm)).to_csv(TAB / "t50_permutation.csv", index=False)
    f, ax = fig(6.2, 3.0)
    ax.hist(100 * perm, bins=40, color=C["neutral"], edgecolor="white")
    ax.axvline(100 * real, color=C["s1"], lw=2)
    ax.annotate(f"Ước lượng thật: {100 * real:.1f}", (100 * real, ax.get_ylim()[1] * 0.9),
xytext=(5, 0),
textcoords="offset points")
    ax.set_xlabel("Hệ số DiD log số chuyển x100 khi gán xử lý ngẫu nhiên")
    ax.set_ylabel("Số lần lặp")
    ax.set_title("Phân phối hoán vị (500 lần) so với ước lượng thật")
    save(f, "f33_permutation")

if want("robust"):
    zw = zone_week("hvfhv")
    # ----- (d) Bảng độ vững -----
    rob = []

    def add(name, pan, y="ln_n", fes=("zone", "wk"), w=None, D="D", cl="zone"):
        res, info, _ = fe_ols(pan, y, [D], list(fes), cl, w)
        r = res.iloc[0]
        rob.append(dict(spec=name, coef=r.coef, se=r.se, p=r.p, ci_low=r.ci_low, ci_high=r.ci_high,
pct=100 * (np.exp(r.coef) - 1) if y.startswith("ln") else np.nan,
n_obs=info["n_obs"], n_zones=int(pan.zone.nunique()),

```

```

n_treated=int(pan[pan.treat == 1].zone.nunique()), outcome=y))

add("Cơ sở: CRZ vs MN bắc + quận ngoài, vùng ≥100 chuyển/ngày", zw)
add("Đối chứng chỉ Manhattan phía bắc", zw[(zw.treat == 1) | (zw.grp == "MN_NORTH")])
add("Đối chứng chỉ các quận ngoài", zw[(zw.treat == 1) | (zw.grp == "OUTER")])
add("Đối chứng chỉ Brooklyn và Queens", zw[(zw.treat == 1) | (zw.Borough.isin(["Brooklyn",
"Queens"])))])
add("Ngưỡng vùng ≥50 chuyển/ngày", zone_week("hvfhv", min_daily=50))
add("Ngưỡng vùng ≥300 chuyển/ngày", zone_week("hvfhv", min_daily=300))
zp = zone_week("hvfhv", groups=("CRZ", "CRZ_PARTIAL", "MN_NORTH", "OUTER"))
zp["treat"] = zp.grp.isin(["CRZ", "CRZ_PARTIAL"]).astype(int)
zp["D"] = zp.treat * zp.post
add("Gộp vùng vắt ranh giới vào nhóm xử lý", zp)
add("Bỏ tuần lễ cuối năm (20/12-05/01)", zw[~(((zw.wk.dt.month == 12) & (zw.wk.dt.day >= 20)) |
((zw.wk.dt.month == 1) & (zw.wk.dt.day <= 5))))])
add("Bỏ 4 tuần đầu sau chính sách", zw[(zw.k < 0) | (zw.k >= 4)])
add("Chỉ 01-06/2025 là giai đoạn sau", zw[zw.wk < "2025-07-01"])
add("Chỉ 07-12/2025 là giai đoạn sau", zw[(zw.wk < P) | (zw.wk >= "2025-07-01")])
add("Có trọng số theo lưu lượng 2024", zw, w="w_pre")
zt = zw.copy()
zt["trend_T"] = zt.treat * zt.k / 52.0
res_t, info_t, _ = fe_ols(zt, "ln_n", ["D", "trend_T"], ["zone", "wk"], "zone")
r = res_t.iloc[0]
rob.append(dict(spec="Thêm xu hướng tuyến tính riêng của nhóm xử lý", coef=r.coef, se=r.se,
p=r.p,
ci_low=r.ci_low, ci_high=r.ci_high, pct=100 * (np.exp(r.coef) - 1),
n_obs=info_t["n_obs"],
n_zones=int(zt.zone.nunique()), n_treated=int(zt[zt.treat == 1].zone.nunique()),
outcome="ln_n"))
zw2 = zw.copy()
zw2["tw"] = zw2.treat.astype(str) + "_" + zw2.woy.astype(str)
add("DDD: thêm FE nhóm × tuần-trong-năm", zw2, fes=("zone", "wk", "tw"))
zw3 = zw.copy()
zw3["bw"] = zw3.Borough + "_" + zw3.wk.astype(str)
add("FE quận × tuần (so sánh trong cùng quận)", zw3[zw3.Borough == "Manhattan"], fes=("zone",
"bw"))
add("Phân cụm theo quận thay vì vùng (5 cụm, chỉ tham khảo)", zw, cl="Borough")
zd = zone_day("hvfhv")
add("Panel vùng × ngày", zd.rename(columns={"d": "wk"}))
rb = pd.DataFrame(rob)
rb.to_csv(TAB / "t51_robustness_ln_n.csv", index=False)
print(rb[["spec", "coef", "se", "p", "pct"]].to_string(), flush=True)

f, ax = fig(6.8, 4.6)
yy = np.arange(len(rb))[:-1]
ax.errorbar(100 * rb.coef, yy, xerr=[100 * (rb.coef - rb.ci_low), 100 * (rb.ci_high - rb.coef)],
fmt="o",
color=C["s1"], ecolor=C["s1"], ms=4, elinewidth=1)
ax.axvline(0, color=C["text2"], lw=0.8)
ax.axvline(100 * rb.coef.iloc[0], color=C["s1"], lw=0.8, ls=":")
ax.set_yticks(yy, rb.spec, fontsize=7.5)
ax.set_xlabel("Hệ số DiD log số chuyển đến ×100 (KTC 95%)")
ax.set_title("Độ vững của ước lượng chính qua các đặc tả")
save(f, "f34_robustness_forest")

(LOG / f"10_spillover_robustness_{PART}.json").write_text(json.dumps(dict(seconds=round(time.time()
- t0, 1), **meta), indent=2, default=float))
print(meta, "time", round(time.time() - t0, 1))

```

I.16. 11_appendix_tables.py

"""Bước 11 - Bảng chi tiết cho phụ lục: theo vùng, theo tháng, theo luồng.

Mọi con số trong phụ lục được tính trực tiếp từ các bảng Gold.

Chạy: python code/11_appendix_tables.py

```

"""
import json
import time

import numpy as np
import pandas as pd

from config import GOLD, LOG, TAB
from panels import P

t0 = time.time()
dim = pd.read_parquet(GOLD / "dim_zone.parquet")
z = pd.read_parquet(GOLD / "zone_day_pu.parquet")
z["d"] = pd.to_datetime(z.d)
zd = pd.read_parquet(GOLD / "zone_day_do.parquet")
zd["d"] = pd.to_datetime(zd.d)

```

```

# Cùng cửa sổ lịch cho hai năm: 05/01-31/12
z = z[((z.d >= "2024-01-05") & (z.d <= "2024-12-31")) | (z.d >= P)]
zd = zd[((zd.d >= "2024-01-05") & (zd.d <= "2024-12-31")) | (zd.d >= P)]
z["yr"] = z.d.dt.year
zd["yr"] = zd.d.dt.year
S = ["n", "fare", "pay", "miles", "time_s", "tips", "cbd", "rider_cost", "wait_sum", "wait_n",
     "n_cbd"]
a = z.groupby(["service", "zone", "yr"])[S + ["n_to_crz"]].sum()
days = z.groupby("yr").d.nunique()
b = zd.groupby(["service", "zone", "yr"])[["n", "n_from_crz"]].sum().rename(columns={"n": "n_do"})
m = a.join(b, how="outer").reset_index()
m["days"] = m.yr.map(days)
m["pu_per_day"] = m.n / m.days
m["do_per_day"] = m.n_do / m.days
m["fare_pt"] = m.fare / m.n
m["pay_pt"] = m.pay / m.n
m["mph"] = m.miles / (m.time_s / 3600)
m["wait"] = m.wait_sum / m.wait_n.replace(0, np.nan)
m["cbd_pt"] = m.cbd / m.n
m["share_to_crz"] = 100 * m.n_to_crz / m.n
w = m.pivot_table(index=["service", "zone"], columns="yr",
                  values=["pu_per_day", "do_per_day", "fare_pt", "pay_pt", "mph", "wait", "cbd_pt",
                          "share_to_crz"])
w.columns = [f"{a}_{b}" for a, b in w.columns]
w = w.reset_index().merge(dim[["LocationID", "Zone", "Borough", "grp", "dist_to_crz_km"]],
                          left_on="zone", right_on="LocationID", how="left")
w["pu_yoy_pct"] = 100 * (w.pu_per_day_2025 / w.pu_per_day_2024 - 1)
w["do_yoy_pct"] = 100 * (w.do_per_day_2025 / w.do_per_day_2024 - 1)
w = w.sort_values(["service", "Borough", "zone"])
w.to_csv(TAB / "a01_zone_detail.csv", index=False)

# Theo tháng × nhóm
z2 = pd.read_parquet(GOLD / "zone_day_pu.parquet")
z2["d"] = pd.to_datetime(z2.d)
z2 = z2.merge(dim[["LocationID", "grp"]], left_on="zone", right_on="LocationID")
z2["ym"] = z2.d.dt.to_period("M").astype(str)
mg = z2.groupby(["service", "ym", "grp"])[S].sum().reset_index()
mg["days"] = mg.ym.map(z2.groupby("ym").d.nunique())
mg["trips_per_day"] = mg.n / mg.days
mg["fare_pt"] = mg.fare / mg.n
mg["pay_pt"] = mg.pay / mg.n
mg["mph"] = mg.miles / (mg.time_s / 3600)
mg["wait"] = mg.wait_sum / mg.wait_n.replace(0, np.nan)
mg["cbd_pt"] = mg.cbd / mg.n
mg["share_cbd"] = 100 * mg.n_cbd / mg.n
mg.to_csv(TAB / "a02_month_group_detail.csv", index=False)

# Luồng nhóm × giờ × năm
g = pd.read_parquet(GOLD / "grp_hour_day.parquet")
g["d"] = pd.to_datetime(g.d)
g = g[((g.d >= "2024-01-05") & (g.d <= "2024-12-31")) | (g.d >= P)]
g["yr"] = g.d.dt.year
fg = g.groupby(["service", "pu_grp", "do_grp", "hr", "yr"])[["n", "miles", "time_s", "fare",
    "pay"]].sum()
fg["mph"] = fg.miles / (fg.time_s / 3600)
fg["fare_pt"] = fg.fare / fg.n
fg = fg.reset_index()
fg["per_day"] = fg.n / fg.yr.map(days)
fg.to_csv(TAB / "a03_flow_hour_detail.csv", index=False)

(LOG / "11_appendix.json").write_text(json.dumps(dict(seconds=round(time.time() - t0, 1),
zones=int(w.zone.nunique()))))
print("done", round(time.time() - t0, 1))

```

I.17. 12_pipeline_figures.py

"""Bước 12 - Hình và bảng về hiệu năng pipeline (từ nhật ký chạy thực tế).

Chạy: python code/12_pipeline_figures.py

```

"""
import json

import numpy as np
import pandas as pd

from config import LOG, TAB
from viz import C, fig, plt, save

fmt = pd.read_csv(TAB / "t09_bench_format.csv")
eng = pd.read_csv(TAB / "t10_bench_engine.csv")
pru = pd.read_csv(TAB / "t11_bench_pruning.csv")
run = pd.read_csv(TAB / "t08_partition_runtime.csv")

```

```

qm = pd.read_csv(TAB / "t06_quality_by_month.csv")
man = pd.read_csv(TAB / "t01_bronze_manifest.csv")

f, axs = fig(6.8, 3.0, ncols=2)
axs[0].barh(fmt.format, fmt.size_mb, color=[C["s2"], C["s2"], C["s1"], C["s1"]])
axs[0].invert_yaxis()
axs[0].set_xlabel("MB (2 triệu dòng HVFHV)")
axs[0].set_title("Kích thước tệp", fontsize=9.5)
axs[1].barh(fmt.format, fmt.agg_query_s_median, color=[C["s2"], C["s2"], C["s1"], C["s1"]])
axs[1].invert_yaxis()
axs[1].set_yticklabels([])
axs[1].set_xlabel("Giây (trung vị 3 lần)")
axs[1].set_title("Thời gian truy vấn tổng hợp theo vùng", fontsize=9.5)
for ax, col in ((axs[0], "size_mb"), (axs[1], "agg_query_s_median")):
    for i, v in enumerate(fmt[col]):
        ax.annotate(f"{v:.2f}" if v < 10 else f"{v:.0f}", (v, i), xytext=(3, 0), textcoords="offset
points",
                    va="center", fontsize=8, color=C["text2"])
f.suptitle("So sánh định dạng lưu trữ trên cùng lát cắt dữ liệu", x=0.02, ha="left", fontsize=10.5,
           fontweight="bold")
f.tight_layout()
save(f, "f35_bench_format")

f, axs = fig(6.8, 2.8, ncols=2)
lab = [e.split(" ")[0] for e in eng.engine]
axs[0].bar(lab, eng.seconds_median, color=C["s1"], width=0.55)
axs[0].set_ylabel("Giây (trung vị)")
axs[0].set_title("Thời gian", fontsize=9.5)
axs[1].bar(lab, eng.max_rss_mb, color=C["s3"], width=0.55)
axs[1].set_ylabel("MB")
axs[1].set_title("Bộ nhớ đỉnh (max RSS)", fontsize=9.5)
f.suptitle("Ba bộ máy xử lý trên 1 tháng HVFHV đầy đủ (21,3 triệu dòng)", x=0.02, ha="left",
           fontsize=10.5, fontweight="bold")
f.tight_layout()
save(f, "f36_bench_engine")

r = run[run.service == "hvfhv"].copy()
r["rows_m"] = r.n_raw / 1e6
f, ax = fig(6.4, 3.0)
ax.scatter(r.rows_m, r.sec_total, s=18, color=C["s1"], label="HVFHV (khúc 1/4 tháng)")
ry = run[run.service == "yellow"]
ax.scatter(ry.n_raw / 1e6, ry.sec_total, s=18, color=C["s2"], label="Taxi vàng (cả tháng)")
ax.set_xlabel("Triệu dòng đầu vào")
ax.set_ylabel("Giây (Bronze - Silver - Gold)")
ax.set_title("Thời gian xử lý mỗi phân vùng theo số dòng")
ax.legend()
save(f, "f37_partition_runtime")

tot = run.groupby("service")[["sec_quality", "sec_silver", "sec_gold", "sec_total", "n_raw",
"silver_mb"]].sum()
tot["rows_per_sec"] = tot.n_raw / tot.sec_total
tot.to_csv(TAB / "t52_pipeline_totals.csv")
size = man.groupby("service").size_mb.sum().rename("bronze_mb").to_frame().join(tot.silver_mb)
size.to_csv(TAB / "t53_storage_by_layer.csv")
print(tot, size)

# ----- Sơ đồ kiến trúc pipeline (vẽ từ cấu hình thực tế) -----
from matplotlib.patches import FancyBboxPatch

gold_rows = json.loads((LOG / "04_gold Consolidate.json").read_text())["rows"]
f, ax = plt.subplots(figsize=(6.8, 4.4))
ax.set_xlim(0, 100)
ax.set_ylim(0, 64)
ax.axis("off")

def box(x, y, w, h, title, lines, col):
    ax.add_patch(FancyBboxPatch((x, y), w, h, boxstyle="round,pad=0.4,rounding_size=1.2",
                                facecolor=col, edgecolor=C["text2"], lw=0.8))
    ax.text(x + w / 2, y + h - 2.6, title, ha="center", va="top", fontsize=8.6, fontweight="bold",
            color=C["text"])
    for i, t in enumerate(lines):
        ax.text(x + w / 2, y + h - 7.2 - 3.6 * i, t, ha="center", va="top", fontsize=6.8,
                color=C["text"])

def arrow(x1, y1, x2, y2):
    ax.annotate("", xy=(x2, y2), xytext=(x1, y1), arrowprops=dict(arrowstyle="->", color=C["text2"],
                                                                    lw=1.1))

nb = int(man.n_rows.sum())
box(1, 38, 22, 24, "Nguồn", ["NYC TLC (CloudFront)", "48 tệp Parquet", "HVFHV + taxi vàng", "01/2024
- 12/2025", f"{nb/1e6:.1f} triệu dòng".replace(",", ".")], "X").replace(".", ", ").replace("X", ".")],
"#f0efec")

```



```

box(27, 38, 22, 24, "Bronze", ["Tập gốc, bất biến", "Danh mục metadata", "Phát hiện lệch lệch đồ",
f"{man.size_mb.sum()/1024:,.1f} GB".replace(".", ","), "t01-t03"], "#e4d6c3")
box(53, 38, 22, 24, "Silver", ["Lược đồ chung", "7 quy tắc chất lượng", "Parquet ZSTD",
"service/year/month", f"{int(qm.n_silver.sum())/1e6:,.1f} triệu dòng".replace(".", "X").replace(".",
",").replace("X", ".")], "#d9dde3")
box(77, 38, 22, 24, "Gold", ["7 bảng tổng hợp", "vùng×ngày, OD×tháng", "nhóm×giờ×ngày", "mẫu 0,25%
chuyển", "dim_zone, kề nhau"], "#f3e2a6")
arrow(23.5, 50, 26.5, 50)
arrow(49.5, 50, 52.5, 50)
arrow(75.5, 50, 76.5, 50)
box(1, 4, 30, 26, "Phân tích mô tả", ["EDA, bản đồ, chuỗi thời gian", "Doanh thu phí CBD", "Tốc độ,
thời gian chờ", "Hiệu năng định dạng/bộ máy"], "#eef3fb")
box(35, 4, 30, 26, "Suy luận nhân quả", ["DiD / TWFE / DDD mùa vụ", "Nghiên cứu sự kiện", "Kiểm soát
tổng hợp", "Giả được, hoán vị, độ vững"], "#eef3fb")
box(69, 4, 30, 26, "Học máy nhân quả", ["DML (PLR, AIPW)", "DR-learner cho CATE", "BLP, GATES,
CLAN", "LightGBM, cross-fitting"], "#eef3fb")
for x in (16, 50, 84):
    arrow(88, 37.5, x, 30.8)
ax.text(50, 63.5, "DuckDB (SQL, thực thi vector hóa, giới hạn bộ nhớ 1,8 GB) · Python · Pandas ·
statsmodels/SciPy · LightGBM",
        ha="center", va="bottom", fontsize=7, color=C["text2"])
save(f, "f00_architecture")

```

I.18. 14_extra_analysis.py

"""Bước 14 - Phân tích bổ sung.

- (a) Tác động riêng cho từng vùng CRZ: TWFE với tương tác D × vùng; quan hệ giữa tác động và đặc trưng vùng (lưu lượng, khoảng cách tới ranh giới bên trong CRZ, tỷ trọng chuyển nội vùng).
- (b) Lan tỏa theo dải khoảng cách, tách riêng theo quận.
- (c) Sai khác kép mô tả của tốc độ theo giờ × loại ngày: (CRZ-CRZ) so với (quận ngoài-quận ngoài).
- (d) Chuyển sân bay: số chuyển/ngày của các luồng sân bay, cùng kỳ 2025/2024.
- (e) Thành phần quảng đường: tỷ trọng chuyển ngắn trong mẫu chuyển, CRZ so với nơi khác.

Chạy: python code/14_extra_analysis.py

```

"""
import json
import time

import numpy as np
import pandas as pd
from matplotlib.collections import PolyCollection
from matplotlib.colors import LinearSegmentedColormap, TwoSlopeNorm
from shapely.geometry import Polygon
from shapely.ops import unary_union

from causal import fe_ols
from config import GOLD, LOG, TAB
from panels import P, zone_week
from viz import C, fig, plt, save

t0 = time.time()
meta = {}
dim = pd.read_parquet(GOLD / "dim_zone.parquet")

# ----- (a) Tác động theo từng vùng CRZ -----
zw = zone_week("hvfhv", extra=("n_to_crz",))
crz_zones = sorted(zw[zw.treat == 1].zone.unique())
names = []
for z in crz_zones:
    nm = f"D_{z}"
    zw[nm] = ((zw.zone == z) & (zw.post == 1)).astype(float)
    names.append(nm)
rows = []
for y in ("ln_n", "mph", "wait"):
    res, info, _ = fe_ols(zw, y, names, ["zone", "wk"], "zone")
    for (_, r), z in zip(res.iterrows(), crz_zones):
        rows.append(dict(zone=z, outcome=y, coef=r.coef, se=r.se, p=r.p, ci_low=r.ci_low,
ci_high=r.ci_high))
ze = pd.DataFrame(rows)
pre = zw[zw.post == 0].groupby("zone").agg(n=("n", "sum"), n_to_crz=("n_to_crz", "sum"),
miles=("miles", "sum"),
time_s=("time_s", "sum"), fare=("fare", "sum"))
pre["pre_per_day"] = pre.n / ((P - pd.Timestamp("2024-01-07")).days)
pre["share_to_crz"] = 100 * pre.n_to_crz / pre.n
pre["mph_pre"] = pre.miles / (pre.time_s / 3600)
pre["fare_pt_pre"] = pre.fare / pre.n

# Khoảng cách từ tâm vùng CRZ tới ranh giới ngoài của CRZ (độ "sâu" bên trong vùng)
poly = pd.read_parquet(GOLD / "zone_polygons.parquet")
geoms = {}
for (lid, part), g in poly.groupby(["LocationID", "part"]):

```

```

if len(g) >= 3:
    pg = Polygon(np.c_[g.x.values, g.y.values]).buffer(0)
    geoms[lid] = unary_union([geoms[lid], pg]) if lid in geoms else pg
crz_all = unary_union([geoms[z] for z in dim[dim.grp == "CRZ"].LocationID if z in geoms])
depth = {}
for z in crz_zones:
    if z in geoms:
        depth[z] = geoms[z].centroid.distance(crz_all.exterior if crz_all.geom_type == "Polygon"
                                                else unary_union([p.exterior for p in crz_all.geoms]))

* 0.0003048
zi = ze.pivot(index="zone", columns="outcome", values="coef").add_prefix("b_")
zs = ze.pivot(index="zone", columns="outcome", values="se").add_prefix("se_")
zt = zi.join(zs).join(pre[["pre_per_day", "share_to_crz", "mph_pre", "fare_pt_pre"]])
zt["depth_km"] = zt.index.map(depth)
zt = zt.join(dim.set_index("LocationID")[["Zone"]])
zt["pct_ln_n"] = 100 * (np.exp(zt.b_ln_n) - 1)
zt.reset_index().to_csv(TAB / "t54_zone_specific_effects.csv", index=False)

# Hồi quy tác động theo vùng lên đặc trưng vùng (trọng số nghịch đảo phương sai)
import statsmodels.api as sm
Xd = pd.DataFrame({"log_pre_per_day": np.log(zt.pre_per_day), "share_to_crz": zt.share_to_crz,
                  "depth_km": zt.depth_km, "fare_pt_pre": zt.fare_pt_pre}).dropna()

mr = []
for y in ("b_ln_n", "b_mph"):
    yy = zt.loc[Xd.index, y]
    w = 1 / zt.loc[Xd.index, y.replace("b_", "se_")] ** 2
    m = sm.WLS(yy, sm.add_constant(Xd), weights=w).fit(cov_type="HC1")
    for k in m.params.index:
        mr.append(dict(outcome=y, term=k, coef=m.params[k], se=m.bse[k], p=m.pvalues[k],
                      r2=m.rsquared, n=int(m.nobs)))
pd.DataFrame(mr).to_csv(TAB / "t55_zone_effect_meta_regression.csv", index=False)

# Bản đồ tác động theo vùng CRZ
cmap = LinearSegmentedColormap.from_list("div", [C["div_neg"], C["div_mid"], C["div_pos"]])
vals = zt.pct_ln_n.to_dict()
lim = float(np.nanmax(np.abs(zt.pct_ln_n)))
norm = TwoSlopeNorm(vmin=-lim, vcenter=0, vmax=lim)
mh = dim[dim.Borough == "Manhattan"].LocationID.tolist()
f, ax = fig(4.8, 6.4)
verts, cols = [], []
for (lid, part), g in poly[poly.LocationID.isin(mh)].groupby(["LocationID", "part"]):
    verts.append(np.c_[g.x.values, g.y.values])
    cols.append(cmap(norm(vals[lid])) if lid in vals else "#e4e3df")
ax.add_collection(PolyCollection(verts, facecolors=cols, edgecolors="#ffffff", linewidths=0.4))
ax.autoscale_view()
ax.set_aspect("equal")
ax.axis("off")
ax.set_ylim(ax.get_ylim()[0], ax.get_ylim()[0] + 0.55 * (ax.get_ylim()[1] - ax.get_ylim()[0]))
sm_ = plt.cm.ScalarMappable(norm=norm, cmap=cmap)
cb = f.colorbar(sm_, ax=ax, shrink=0.6, pad=0.01)
cb.set_label("% thay đổi số chuyển đón (DiD theo vùng)")
ax.set_title("Tác động DiD riêng của từng vùng CRZ")
save(f, "f38_zone_effects_map")

f, axs = fig(6.8, 3.0, ncols=2)
axs[0].scatter(np.log10(zt.pre_per_day), zt.pct_ln_n, s=22, color=C["s1"])
axs[0].axhline(0, color=C["text2"], lw=0.8)
axs[0].set_xlabel("log10 chuyển đón/ngày năm 2024")
axs[0].set_ylabel("% thay đổi số chuyển (DiD vùng)")
axs[0].set_title("Theo quy mô vùng", fontsize=9.5)
axs[1].scatter(zt.depth_km, zt.pct_ln_n, s=22, color=C["s1"])
axs[1].axhline(0, color=C["text2"], lw=0.8)
axs[1].set_xlabel("Khoảng cách từ tâm vùng tới ranh giới CRZ (km)")
axs[1].set_title("Theo độ sâu trong CRZ", fontsize=9.5)
f.suptitle("Tác động theo vùng CRZ và đặc trưng vùng", x=0.02, ha="left", fontsize=10.5,
fontweight="bold")
f.tight_layout()
save(f, "f39_zone_effects_scatter")
meta["zone_effects"] = dict(n=int(len(zt)), n_negative=int((zt.b_ln_n < 0).sum()),
                           n_sig_negative=int(((zt.b_ln_n + 1.96 * zt.se_ln_n) < 0).sum()),
                           n_mph_positive=int((zt.b_mph > 0).sum()))

# ----- (b) Lan tỏa theo quận -----
pu = zone_week("hvfhv", groups=("CRZ", "CRZ_PARTIAL", "MN_NORTH", "OUTER"))
pu = pu[pu.grp != "CRZ"].copy()
pu["near"] = (pu.dist_to_crz_km <= 5).astype(int)
rows = []
for b in ["Manhattan", "Brooklyn", "Queens", "Bronx"]:
    pu[f"D_{b}"] = ((pu.Borough == b) & (pu.near == 1) & (pu.post == 1)).astype(float)
res, info, _ = fe_ols(pu, "ln_n", [f"D_{b}" for b in ["Manhattan", "Brooklyn", "Queens", "Bronx"]],
["zone", "wk"], "zone")
for (_, r), b in zip(res.iterrows(), ["Manhattan", "Brooklyn", "Queens", "Bronx"]):
    rows.append(dict(borough=b, coef=r.coef, se=r.se, p=r.p, ci_low=r.ci_low, ci_high=r.ci_high,
                    n_near=int(pu[(pu.Borough == b) & (pu.near == 1)].zone.nunique()))
pd.DataFrame(rows).to_csv(TAB / "t56_spillover_by_borough.csv", index=False)

```

```

# ----- (c) Tốc độ theo giờ x loại ngày -----
g = pd.read_parquet(GOLD / "grp_hour_day.parquet")
g = g[g.service == "hvfhv"].copy()
g["d"] = pd.to_datetime(g.d)
g = g[((g.d >= "2024-01-05") & (g.d <= "2024-12-31")) | (g.d >= P)]
g["yr"] = g.d.dt.year
g["daytype"] = np.where(g.d.dt.dayofweek >= 5, "Cuối tuần", "Ngày thường")
g["flow"] = g.pu_grp + "_" + g.do_grp
sel = g[g.flow.isin(["CRZ-CRZ", "OUTER-OUTER", "MN_NORTH-MN_NORTH"])]
a = sel.groupby(["flow", "daytype", "hr", "yr"])[["miles", "time_s", "n"]].sum()
a["mph"] = a.miles / (a.time_s / 3600)
m = a["mph"].unstack("yr")
m["d"] = m[2025] - m[2024]
dd = m["d"].unstack("flow")
dd["did_vs_outer"] = dd["CRZ-CRZ"] - dd["OUTER-OUTER"]
dd["did_vs_mn"] = dd["CRZ-CRZ"] - dd["MN_NORTH-MN_NORTH"]
dd.reset_index().to_csv(TAB / "t57_speed_did_hour_daytype.csv", index=False)
f, axs = fig(6.8, 2.8, nrows=1)
hm = dd["did_vs_outer"].unstack("hr").loc[["Ngày thường", "Cuối tuần"]]
lim = float(np.nanmax(np.abs(hm.values)))
im = axs.imshow(hm.values, aspect="auto", cmap=cmap, norm=TwoSlopeNorm(vmin=-lim, vcenter=0,
vmax=lim))
axs.set_yticks([0, 1], hm.index)
axs.set_xticks(range(0, 24, 2), [str(h) for h in range(0, 24, 2)])
axs.set_xlabel("Giờ đón")
axs.grid(False)
cb = f.colorbar(im, ax=axs, pad=0.01)
cb.set_label("dặm/giờ")
axs.set_title("Chênh lệch thay đổi tốc độ cùng kỳ: CRZ-CRZ trừ quận ngoài-quận ngoài")
save(f, "f40_speed_did_heatmap")

# ----- (d) Chuyển sân bay -----
air = g[(g.pu_grp == "AIRPORT") | (g.do_grp == "AIRPORT")]
ag = air.groupby(["pu_grp", "do_grp", "yr"])[["n"]].sum().unstack("yr")
days = g.groupby("yr").d.nunique()
ag = ag.div(days, axis=1)
ag["chg_pct"] = 100 * (ag[2025] / ag[2024] - 1)
ag.reset_index().to_csv(TAB / "t58_airport_flows.csv", index=False)

# ----- (e) Thành phần quãng đường -----
s = pd.read_parquet(GOLD / "trip_sample.parquet", columns=["service", "d", "miles", "pu_grp",
"do_grp", "touch_crz"])
s = s[s.service == "hvfhv"].copy()
s["d"] = pd.to_datetime(s.d)
s = s[((s.d >= "2024-01-05") & (s.d <= "2024-12-31")) | (s.d >= P)]
s["yr"] = s.d.dt.year
bins = [0, 1, 2, 3, 5, 10, 1000]
labs = ["<1", "1-2", "2-3", "3-5", "5-10", ">10"]
s["mb"] = pd.cut(s.miles, bins, labels=labs, right=False)
comp = s.groupby(["touch_crz", "yr", "mb"], observed=True).size().unstack("mb")
comp = comp.div(comp.sum(axis=1), axis=0) * 100
comp.reset_index().to_csv(TAB / "t59_distance_composition.csv", index=False)
f, axs = fig(6.8, 3.0, ncols=2, sharey=True)
for ax, tc, ttl in ((axs[0], 1, "Chuyển chậm CRZ"), (axs[1], 0, "Chuyển không chậm CRZ")):
    xx = np.arange(len(labs))
    ax.bar(xx - 0.2, comp.loc[(tc, 2024)], width=0.38, color=C["s2"], label="2024")
    ax.bar(xx + 0.2, comp.loc[(tc, 2025)], width=0.38, color=C["s1"], label="2025")
    ax.set_xticks(xx, labs)
    ax.set_xlabel("Quãng đường (dặm)")
    ax.set_title(ttl, fontsize=9.5)
axs[0].set_ylabel("% số chuyển")
axs[0].legend()
f.suptitle("Phân bố quãng đường chuyển HVFHV (mẫu 0,25%), 05/01-31/12", x=0.02, ha="left",
fontsize=10.5,
fontweight="bold")
f.tight_layout()
save(f, "f41_distance_composition")

(LOG / "14_extra.json").write_text(json.dumps(dict(seconds=round(time.time() - t0, 1), **meta),
indent=2))
print(meta, round(time.time() - t0, 1))

```

I.19. 15_spark_pipeline.py

""Bước 15 - Xử lý phân tán bằng Apache Spark (PySpark) trên cùng lớp Silver.

Mục đích: đối chứng bộ máy nhúng một nút (DuckDB) với bộ máy phân tán trong bộ nhớ (Spark) trên chính dữ liệu của đồ án, và minh họa các cơ chế của Spark mà học phần đề cập: đồ thị thực thi (DAG) và phả hệ (lineage), bộ tối ưu Catalyst, cắt tia phân vùng, xáo trộn (shuffle), lưu đệm trong bộ nhớ, trao đổi dữ liệu qua Apache Arrow và xử lý luồng có cấu trúc (Structured Streaming).

Các phần (mỗi phần ghi nhật ký JSON riêng vào outputs/logs/spark/):

repro [giấy]	Tái lập bảng Gold zone_day_pu bằng Spark cho cả 48 tháng-dịch vụ (tăng dần, bỏ qua tháng đã làm, dừng khi hết ngân sách thời gian).
validate	So khớp từng ô giữa bản Spark và bản DuckDB của zone_day_pu.
engine <e>	Cùng một truy vấn trên một tháng HVFHV; e ∈ {duckdb, spark_df, spark_sql}.
shuffle <p> [noaqe]	Spark với spark.sql.shuffle.partitions = p (tùy chọn tắt AQE).
scale <e> <k>	Truy vấn trên k tháng HVFHV đầu tiên của năm 2025 với bộ máy e.
cache	Ba truy vấn lặp lại trước và sau khi lưu đệm DataFrame.
prune	Cắt tỉa phân vùng kiểu Hive trên toàn bộ lớp Silver; lưu kế hoạch vật lý.
arrow	Chuyển kết quả Spark sang pandas có và không có Apache Arrow.
stream_prep	Tách hai tuần quanh ngày 05/01/2025 thành các tệp theo ngày.
stream	Structured Streaming: mỗi tệp một lô vi mô, cửa sổ 1 giờ theo nhóm vùng.
report	Tổng hợp nhật ký thành bảng t60-t67 và hình f42-f46.

Chạy: python code/15_spark_pipeline.py <phần> [tham số]

Yêu cầu: Java 11+, pyspark 3.5.

```

"""
import json
import os
import resource
import shutil
import sys
import time

from config import GOLD, LOG, MONTHS, ROOT, SERVICES, SILVER, TAB, duck

os.environ.setdefault("SPARK_LOCAL_HOSTNAME", "localhost")
os.environ.setdefault("SPARK_LOCAL_IP", "127.0.0.1")
os.environ.setdefault("PYSPARK_PYTHON", sys.executable)

SLOG = LOG / "spark"
SLOG.mkdir(parents=True, exist_ok=True)
# Thư mục làm việc của Spark (bằng tái lập, tệp tạm, luồng, checkpoint). Spark cần quyền
# xóa tệp trong thư mục này (thư mục _temporary khi ghi, checkpoint khi xử lý luồng), nên có
# thể trở sang ổ đĩa cục bộ bằng biến môi trường SPARK_WORK.
from pathlib import Path # noqa: E402
WORK = Path(os.environ.get("SPARK_WORK", ROOT / "data" / "_spark"))
SPARK_GOLD = WORK / "gold" / "zone_day_pu"
SPARK_TMP = WORK / "tmp"
STREAM = WORK / "stream"
BENCH_MONTH = "2025-03"
DRIVER_MEM = "1200m"
REPEAT = 3

SUMS_SQL = """count(*) AS n, sum(fare) AS fare, sum(driver_pay) AS pay, sum(miles) AS miles,
sum(time_s) AS time_s, sum(tips) AS tips, sum(CAST(cbd_fee AS DOUBLE)) AS cbd,
sum(rider_cost) AS rider_cost, sum(cong_sur) AS cong_sur, sum(tolls) AS tolls,
sum(wait_min) AS wait_sum, count(wait_min) AS wait_n, sum(shared_req) AS shared_req,
sum(CAST(cbd_fee > 0 AS INT)) AS n_cbd,
sum(CAST(do_grp = 'CRZ' AS INT)) AS n_to_crz,
sum(CAST(company_code = 'HV0003' AS INT)) AS n_uber,
sum(CAST(company_code = 'HV0005' AS INT)) AS n_lyft"""
QUERY = f"SELECT service, d, pu AS zone, {SUMS_SQL} FROM s GROUP BY service, d, pu"
METRICS = ["n", "fare", "pay", "miles", "time_s", "tips", "cbd", "rider_cost", "cong_sur", "tolls",
"wait_sum", "wait_n", "shared_req", "n_cbd", "n_to_crz", "n_uber", "n_lyft"]

def month_dir(svc, ym):
    y, m = ym.split("-")
    return SILVER / f"service={svc}" / f"year={y}" / f"month={m}"

def months_2025(k):
    return [m for m in MONTHS if m.startswith("2025")][k:]

def spark_session(shuffle=8, extra=None):
    from pyspark.sql import SparkSession
    SPARK_TMP.mkdir(parents=True, exist_ok=True)
    b = (SparkSession.builder.master("local[2]").appName("crz-lakehouse")
        .config("spark.driver.memory", DRIVER_MEM)
        .config("spark.ui.enabled", "false")
        .config("spark.ui.showConsoleProgress", "false")
        .config("spark.sql.shuffle.partitions", str(shuffle))
        .config("spark.sql.session.timeZone", "UTC")
        .config("spark.local.dir", SPARK_TMP.as_posix())
        .config("spark.sql.adaptive.enabled", "true")
        .config("spark.driver.extraJavaOptions", "-Dlog4j2.level=ERROR"))
    for k, v in (extra or {}).items():
        b = b.config(k, v)
    s = b.getOrCreate()
    s.sparkContext.setLogLevel("ERROR")
    return s

```

```

def jvm_peak_mb(spark):
    """Bộ nhớ đỉnh (VmHWM) của tiến trình JVM chạy Spark driver/executor (chế độ local)."""
    try:
        pid = spark.sparkContext._gateway.proc.pid
        for line in open(f"/proc/{pid}/status"):
            if line.startswith("VmHWM"):
                return int(line.split()[1]) / 1024
    except Exception:
        return None

def py_peak_mb():
    return resource.getrusage(resource.RUSAGE_SELF).ru_maxrss / 1024

def write_log(name, rec):
    (SLOG / f"{name}.json").write_text(json.dumps(rec, indent=2, ensure_ascii=False, default=str))
    print(json.dumps(rec, ensure_ascii=False, default=str)[:600], flush=True)

def load_months(spark, svc, months, cols=None):
    paths = [month_dir(svc, m).as_posix() for m in months]
    df = spark.read.option("basePath", SILVER.as_posix()).parquet(*paths)
    if cols:
        df = df.select(*cols)
    return df

# ----- repro
def part_repro(budget):
    t_start = time.time()
    todo = [(s, m) for s in SERVICES for m in MONTHS
             if not (SLOG / "repro" / f"{s}_{m}.json").exists()]
    if not todo:
        print("repro: đã xong toàn bộ")
        return
    (SLOG / "repro").mkdir(exist_ok=True)
    t0 = time.time()
    spark = spark_session()
    t_boot = time.time() - t0
    for svc, ym in todo:
        if time.time() - t_start > budget:
            break
        t1 = time.time()
        df = load_months(spark, svc, [ym])
        df.createOrReplaceTempView("s")
        out = spark.sql(QUERY)
        dst = SPARK_GOLD / f"service={svc}" / f"ym={ym}"
        out.coalesce(1).write.mode("overwrite").parquet(dst.as_posix())
        el = time.time() - t1
        n_in = sum(json.loads(p.read_text())["n_silver"]
                   for p in (LOG / "partitions").glob(f"{svc}_{ym}_c*.json"))
        rec = dict(service=svc, month=ym, seconds=round(el, 2), n_silver=n_in,
                  rows_per_sec=round(n_in / el), boot_s=round(t_boot, 2),
                  jvm_peak_mb=jvm_peak_mb(spark))
        (SLOG / "repro" / f"{svc}_{ym}.json").write_text(json.dumps(rec, indent=2))
        print(json.dumps(rec), flush=True)
    spark.stop()
    left = sum(1 for s in SERVICES for m in MONTHS if not (SLOG / "repro" /
f"{s}_{m}.json").exists())
    print("repro: còn lại", left)

# ----- validate
def part_validate():
    con = duck()
    sp = (SPARK_GOLD / "****" / "*.parquet").as_posix()
    con.execute(f"CREATE VIEW sp AS SELECT * FROM read_parquet('{sp}', hive_partitioning=true)")
    con.execute(f"CREATE VIEW dk AS SELECT * FROM '{(GOLD / 'zone_day_pu.parquet').as_posix()}'")
    rows = []
    cnt = con.execute("""SELECT (SELECT count(*) FROM sp), (SELECT count(*) FROM dk),
(SELECT count(*) FROM sp FULL JOIN dk USING (service, d, zone) WHERE sp.n IS NULL OR dk.n IS
NULL)
""").fetchone()
    for m in METRICS:
        r = con.execute(f"""SELECT sp.service,
count(*) AS cells,
sum(CASE WHEN (sp.{m} IS NULL) <> (dk.{m} IS NULL) THEN 1 ELSE 0 END) AS
null_mismatch,
max(abs(sp.{m}::DOUBLE - dk.{m}::DOUBLE)) AS max_abs_diff,
max(abs(sp.{m}::DOUBLE - dk.{m}::DOUBLE) / nullif(abs(dk.{m}::DOUBLE), 0)) AS
max_rel_diff,
sum(sp.{m}::DOUBLE) AS total_spark, sum(dk.{m}::DOUBLE) AS total_duckdb
FROM sp JOIN dk USING (service, d, zone) GROUP BY 1 ORDER BY 1""").df()
        r.insert(1, "metric", m)

```

```

        rows.append(r)
import pandas as pd
t = pd.concat(rows, ignore_index=True)
t["exact_match"] = (t.max_abs_diff.fillna(0) == 0) & (t.null_mismatch == 0)
t.to_csv(TAB / "t61_spark_validation.csv", index=False)
write_log("validate", dict(rows_spark=cnt[0], rows_duckdb=cnt[1], unmatched_keys=cnt[2],
                           metrics=len(METRICS), all_within_1e9=bool((t.max_rel_diff.fillna(0) <
1e-9).all()),
                           exact_cells_share=float(t.exact_match.mean()))))

# ----- engine
def run_duckdb(months):
    con = duck()
    paths = ", ".join(f'{{month_dir('hvfhv', m) / '*.parquet'}}.as_posix()' for m in months)
    con.execute(f"CREATE VIEW s AS SELECT * FROM read_parquet([{{paths}}])")
    times = []
    for _ in range(REPEAT):
        t = time.perf_counter()
        res = con.execute(QUERY).fetchall()
        times.append(time.perf_counter() - t)
    return times, len(res), None

def run_spark(months, api="df", shuffle=8, extra=None):
    from pyspark.sql import functions as F
    t0 = time.perf_counter()
    spark = spark_session(shuffle, extra)
    boot = time.perf_counter() - t0
    df = load_months(spark, "hvfhv", months)
    df.createOrReplaceTempView("s")
    times = []
    for _ in range(REPEAT):
        t = time.perf_counter()
        if api == "sql":
            res = spark.sql(QUERY).collect()
        else:
            res = (df.groupBy("service", "d", F.col("pu").alias("zone"))
                    .agg(F.count(F.lit(1)).alias("n"), F.sum("fare").alias("fare"),
                        F.sum("driver_pay").alias("pay"), F.sum("miles").alias("miles"),
                        F.sum("time_s").alias("time_s"), F.sum("tips").alias("tips"),
                        F.sum(F.col("cbd_fee").cast("double")).alias("cbd"),
                        F.sum("rider_cost").alias("rider_cost"),
                        F.sum("cong_sur").alias("cong_sur"),
                        F.sum("tolls").alias("tolls"), F.sum("wait_min").alias("wait_sum"),
                        F.count("wait_min").alias("wait_n"),
                        F.sum("shared_req").alias("shared_req"),
                        F.sum((F.col("cbd_fee") > 0).cast("int")).alias("n_cbd"),
                        F.sum((F.col("do_grp") == "CRZ").cast("int")).alias("n_to_crz"),
                        F.sum((F.col("company_code") == "HV0003").cast("int")).alias("n_uber"),
                        F.sum((F.col("company_code") == "HV0005").cast("int")).alias("n_lyft"))
                    .collect())
            times.append(time.perf_counter() - t)
        peak = jvm_peak_mb(spark)
        spark.stop()
    return times, len(res), dict(boot_s=boot, jvm_peak_mb=peak)

def n_rows(months, svc="hvfhv"):
    return sum(json.loads(p.read_text())[n_silver] for m in months
                for p in (LOG / "partitions").glob(f'{{svc}}_{{m}}_c*.json'))

def part_engine(engine, months=None, tag=None, shuffle=8, aqe=True):
    months = months or [BENCH_MONTH]
    if engine == "duckdb":
        times, groups, extra = run_duckdb(months)
    else:
        times, groups, extra = run_spark(months, "sql" if engine == "spark_sql" else "df", shuffle,
                                         None if aqe else {"spark.sql.adaptive.enabled": "false"})
    rec = dict(engine=engine, months=months, n_rows=n_rows(months), groups=groups, shuffle=shuffle,
               aqe=aqe,
               times=[round(x, 3) for x in times], first_s=round(times[0], 3),
               median_s=round(sorted(times)[len(times) // 2], 3),
               py_peak_mb=round(py_peak_mb(), 1), **(extra or {}))
    write_log(tag or f"engine_{engine}", rec)

# ----- cache
def part_cache():
    from pyspark import StorageLevel
    from pyspark.sql import functions as F
    spark = spark_session()
    df = load_months(spark, "hvfhv", [BENCH_MONTH],

```

```

        ["d", "hr", "pu", "dl", "pu_grp", "do_grp", "fare", "miles", "time_s",
"wait_min"])
    qs = {
        "q1_vùngxngày": lambda x: x.groupBy("pu", "d").agg(F.count(F.lit(1)),
F.sum("fare").count()),
        "q2_nhómgiờ": lambda x: x.groupBy("pu_grp", "hr").agg(F.avg("wait_min"),
F.sum("miles").count()),
        "q3_OD": lambda x: x.groupBy("pu", "dl").agg(F.sum("time_s").count()),
    }
    out = []
    for phase in ("không lưu đệm", "lưu đệm"):
        x = df
        mat = None
        if phase == "lưu đệm":
            x = df.persist(StorageLevel.MEMORY_AND_DISK)
            t = time.perf_counter()
            x.count()
            mat = time.perf_counter() - t
            for qn, q in qs.items():
                for rep in range(2):
                    t = time.perf_counter()
                    q(x)
                    out.append(dict(phase=phase, query=qn, rep=rep + 1,
seconds=round(time.perf_counter() - t, 3)))
            if mat is not None:
                out.append(dict(phase=phase, query="vật chất hóa bộ đệm", rep=1, seconds=round(mat, 3)))
# Dung lượng bộ đệm theo trình quản lý lưu trữ của Spark
st = spark.sparkContext._jsc.sc().getRDDStorageInfo()
mem = sum(i.memSize() for i in st) / 2**20
disk = sum(i.diskSize() for i in st) / 2**20
lineage = df.groupBy("pu", "d").agg(F.count(F.lit(1))).rdd.toDebugString().decode()
(SLOG / "lineage_q1.txt").write_text(lineage)
write_log("cache", dict(month=BENCH_MONTH, n_rows=n_rows[BENCH_MONTH], runs=out,
cache_mem_mb=round(mem, 1), cache_disk_mb=round(disk, 1),
jvm_peak_mb=jvm_peak_mb(spark)))

spark.stop()

# ----- prune
def scan_metrics(df):
    """Đọc số liệu của toán tử quét tệp (FileSourceScanExec) trong kế hoạch vật lý đã thực thi."""
    def walk(n):
        name = n.getClass().getSimpleName()
        if name.endswith("QueryStageExec"):
            return walk(n.plan())
        if name == "AdaptiveSparkPlanExec":
            return walk(n.executedPlan())
        if "FileSourceScanExec" in name:
            return [n]
        out, ch = [], n.children()
        for i in range(ch.size()):
            out += walk(ch.apply(i))
        return out
    res = {}
    for node in walk(df._jdf.queryExecution().executedPlan()):
        m = node.metrics()
        for k in ("numFiles", "numPartitions", "filesSize", "numOutputRows"):
            o = m.get(k)
            if o.isDefined():
                res[k] = res.get(k, 0) + int(o.get().value())
    return res

def part_prune():
    from pyspark.sql import functions as F
    spark = spark_session()
    cols = ["service", "year", "month", "pu", "d", "fare"]
    base = spark.read.parquet((SILVER).as_posix()).select(*cols)
    runs = []
    cases = {
        "toàn bộ Silver (không lọc)": base,
        "service='hvfhv'": base.where(F.col("service") == "hvfhv"),
        "service='hvfhv' AND year=2025": base.where((F.col("service") == "hvfhv") & (F.col("year")
== 2025)),
        "service='hvfhv' AND year=2025 AND month=3": base.where(
            (F.col("service") == "hvfhv") & (F.col("year") == 2025) & (F.col("month") == 3)),
        "lọc theo cột d (không phải khóa phân vùng)": base.where(
            (F.col("d") >= "2025-03-01") & (F.col("d") < "2025-04-01")),
    }
    for name, q in cases.items():
        agg = q.groupBy("pu").agg(F.count(F.lit(1)).alias("n"), F.sum("fare").alias("fare"))
        t = time.perf_counter()
        rows = agg.collect()
        el = time.perf_counter() - t
        sm = scan_metrics(agg)

```

```

        runs.append(dict(case=name, files=sm.get("numFiles"), partitions=sm.get("numPartitions"),
                        scanned_mb=round(sm.get("filesSize", 0) / 2**20, 1),
                        rows_scanned=sm.get("numOutputRows"), rows=int(sum(x["n"] for x in rows)),
                        seconds=round(el, 3)))
    if "month=3" in name:
        (SLOG / "plan_pruned.txt").write_text(agg._jdf.queryExecution().explainString(
            spark._jvm.org.apache.spark.sql.execution.ExplainMode.fromString("formatted")))
        (SLOG / "plan_logical.txt").write_text(agg._jdf.queryExecution().toString())
    print(runs[-1], flush=True)
    write_log("prune", dict(runs=runs, jvm_peak_mb=jvm_peak_mb(spark)))
    spark.stop()

# ----- arrow
def part_arrow():
    from pyspark.sql import functions as F
    out = []
    for arrow in ("false", "true"):
        spark = spark_session(extra={"spark.sql.execution.arrow.pyspark.enabled": arrow})
        df = load_months(spark, "hvfhv", [BENCH_MONTH], ["pu", "dl", "d", "hr", "fare", "miles",
            "time_s", "mph"])
        sub = df.where(F.col("d") < "2025-03-04").cache()
        n = sub.count()
        for rep in range(REPEAT):
            t = time.perf_counter()
            pdf = sub.toPandas()
            out.append(dict(arrow=arrow == "true", rep=rep + 1, rows=n, cols=pdf.shape[1],
                seconds=round(time.perf_counter() - t, 3)))
            del pdf
        spark.stop()
    write_log("arrow", dict(runs=out))

# ----- stream
def part_stream_prep():
    inp = STREAM / "in_all"
    if inp.exists():
        shutil.rmtree(inp)
    inp.mkdir(parents=True)
    con = duck()
    paths = ", ".join(f'"{(month_dir("hvfhv", m) / "*.parquet").as_posix()}"' for m in ("2024-12",
        "2025-01"))
    days = con.execute(f"SELECT DISTINCT d FROM read_parquet({paths})
        WHERE d BETWEEN '2024-12-29' AND '2025-01-11' ORDER BY d").fetchall()
    for (d,) in days:
        con.execute(f"COPY (SELECT pickup_ts, company_code, pu, dl, pu_grp, do_grp,
            CAST(cbd_fee AS DOUBLE) AS cbd_fee, fare, miles, time_s
            FROM read_parquet({paths}) WHERE d = DATE '{d}' ORDER BY pickup_ts)
            TO '{(inp / f"trips_{d}.parquet").as_posix()}' (FORMAT PARQUET, COMPRESSION
        ZSTD)")
    print("stream_prep:", len(days), "tệp")

def part_stream():
    from pyspark.sql import functions as F
    src = STREAM / "in_all"
    land = STREAM / "landing"
    ck = STREAM / "checkpoint"
    sink = STREAM / "sink"
    for p in (land, ck, sink):
        if p.exists():
            shutil.rmtree(p)
    land.mkdir(parents=True)
    # Mô phỏng nguồn phát sinh: chép toàn bộ tệp ngày vào thư mục hạ cánh;
    # maxFilesPerTrigger=1 buộc Spark xử lý mỗi tệp (một ngày) là một lô vi mô.
    for f in sorted(src.glob("*.parquet")):
        shutil.copy(f, land / f.name)
    spark = spark_session(shuffle=4)
    schema = spark.read.parquet(next(land.glob("*.parquet")).as_posix()).schema
    stream = (spark.readStream.schema(schema).option("maxFilesPerTrigger", 1)
        .parquet(land.as_posix()))
    # Parquet do DuckDB ghi có kiểu TIMESTAMP không múi giờ (timestamp_ntz); cơ chế watermark
    # của Spark yêu cầu kiểu timestamp, nên ép kiểu (phiên đặt múi giờ UTC nên không lệch giờ).
    agg = (stream.withColumn("pickup_ts", F.col("pickup_ts").cast("timestamp"))
        .withWatermark("pickup_ts", "2 hours")
        .withColumn("vao_crz", ((F.col("pu_grp") == "CRZ") | (F.col("do_grp") ==
            "CRZ")).cast("int")))
        .groupBy(F.window("pickup_ts", "1 hour"), "company_code")
        .agg(F.count(F.lit(1)).alias("n"), F.sum("vao_crz").alias("n_crz"),
            F.sum((F.col("cbd_fee") > 0).cast("int")).alias("n_cbd"),
            F.sum("cbd_fee").alias("cbd"), F.sum("miles").alias("miles"),
            F.sum("time_s").alias("time_s")))
    t0 = time.perf_counter()
    q = (agg.writeStream.outputMode("append").format("parquet")
        .option("path", sink.as_posix()).option("checkpointLocation", ck.as_posix()))

```



```

        .trigger(availableNow=True).start()
q.awaitTermination()
wall = time.perf_counter() - t0
prog = [json.loads(p.json) for p in q.recentProgress] if hasattr(q.recentProgress[0], "json") \
    else q.recentProgress
batches = [dict(batch=p["batchId"], rows=p["numInputRows"],
                trigger_ms=p["durationMs"].get("triggerExecution"),
                add_batch_ms=p["durationMs"].get("addBatch"),
                rows_per_s=p.get("processedRowsPerSecond"),
                watermark=p.get("eventTime", {}).get("watermark"),
                state_rows=(p.get("stateOperators") or [{}])[0].get("numRowsTotal"),
                state_mem_mb=round((p.get("stateOperators") or [{}])[0].get("memoryUsedBytes",
0) / 2**20, 2))
        for p in prog]
res = spark.read.parquet(sink.as_posix()).toPandas()
res["hour"] = res["window"].apply(lambda w: w["start"])
res.drop(columns="window").to_parquet(STREAM / "stream_hourly.parquet")
write_log("stream", dict(files=len(list(land.glob("*.parquet"))), wall_s=round(wall, 2),
                        batches=batches, output_rows=len(res), jvm_peak_mb=jvm_peak_mb(spark)))
spark.stop()

# ----- report
def part_report():
    import pandas as pd
    import matplotlib.dates as mdates
    from viz import C, fig, save, policy_line

    # t60: tái lập zone_day_pu bằng Spark
    rp = pd.DataFrame([json.loads(p.read_text()) for p in sorted((SLOG / "repro").glob("*.json"))])
    rp.to_csv(TAB / "t60_spark_repro_partitions.csv", index=False)
    tot = rp.groupby("service").agg(months=("month", "count"), n_silver=("n_silver", "sum"),
                                   seconds=("seconds", "sum"), sec_median=("seconds", "median"),
                                   jvm_peak_mb=("jvm_peak_mb", "max"))
    tot["rows_per_sec"] = tot.n_silver / tot.seconds
    # Thời gian DuckDB cho riêng bước Gold (cùng dữ liệu) từ nhật ký bước 03
    parts = pd.DataFrame([json.loads(p.read_text()) for p in (LOG / "partitions").glob("*.json")])
    tot = tot.join(parts.groupby("service").sec_gold.sum().rename("duckdb_gold_all7_s"))
    tot.to_csv(TAB / "t60b_spark_repro_totals.csv")

    # t62: bộ máy
    eng = []
    for e in ("duckdb", "spark_df", "spark_sql"):
        p = SLOG / f"engine_{e}.json"
        if p.exists():
            eng.append(json.loads(p.read_text()))
    eng = pd.DataFrame(eng)
    eng["rows_per_s_median"] = eng.n_rows / eng.median_s
    eng.drop(columns=["months"]).to_csv(TAB / "t62_spark_engine.csv", index=False)

    # t63: shuffle
    sh = pd.DataFrame([json.loads(p.read_text()) for p in sorted(SLOG.glob("shuffle_*.json"))])
    sh["aqe"] = sh.get("aqe", True)
    sh["aqe"] = sh.aqe.fillna(True).astype(bool)
    sh = sh.sort_values(["aqe", "shuffle"])
    sh[["aqe", "shuffle", "first_s", "median_s", "times", "jvm_peak_mb"]].to_csv(TAB /
    "t63_spark_shuffle.csv", index=False)

    # t64: mở rộng theo khối lượng
    sc = pd.DataFrame([json.loads(p.read_text()) for p in sorted(SLOG.glob("scale_*.json"))])
    sc["k_months"] = sc.months.apply(len)
    sc["rows_per_s"] = sc.n_rows / sc.median_s
    sc = sc.sort_values(["engine", "k_months"])
    sc[["engine", "k_months", "n_rows", "first_s", "median_s", "rows_per_s", "jvm_peak_mb",
    "py_peak_mb"]].to_csv(TAB / "t64_spark_scale.csv", index=False)

    # t65: lưu đệm
    ca = json.loads((SLOG / "cache.json").read_text())
    cr = pd.DataFrame(ca["runs"])
    cr.to_csv(TAB / "t65_spark_cache.csv", index=False)

    # t66: cắt tỉa phân vùng + Arrow
    pr = pd.DataFrame(json.loads((SLOG / "prune.json").read_text())["runs"])
    pr.to_csv(TAB / "t66_spark_pruning.csv", index=False)
    ar = pd.DataFrame(json.loads((SLOG / "arrow.json").read_text())["runs"])
    ar.groupby("arrow").agg(rows=("rows", "first"), cols=("cols", "first"),
                           median_s=("seconds", "median"), min_s=("seconds", "min"),
                           max_s=("seconds", "max")).to_csv(TAB / "t66b_spark_arrow.csv")

    # t67: luồng
    st = json.loads((SLOG / "stream.json").read_text())
    sb = pd.DataFrame(st["batches"])
    sb = sb[sb.rows > 0]
    sb.to_csv(TAB / "t67_stream_batches.csv", index=False)

```

```

# ---- hình
# f42: so sánh bộ máy + mở rộng
f, axes = fig(6.8, 3.0, ncols=2)
ax = axes[0]
lab = {"duckdb": "DuckDB", "spark_df": "Spark DataFrame", "spark_sql": "Spark SQL"}
x = range(len(eng))
ax.bar([i - 0.2 for i in x], eng.first_s, 0.4, color=C["neutral"], label="Lần 1")
ax.bar([i + 0.2 for i in x], eng.median_s, 0.4, color=C["s1"], label="Trung vị 3 lần")
ax.set_xticks(list(x), [lab[e] for e in eng.engine])
ax.set_ylabel("Giây")
ax.set_title("Cùng truy vấn, một tháng HVFHV")
ax.legend()
ax = axes[1]
for e, col in (("duckdb", C["s2"]), ("spark_df", C["s1"])):
    d = sc[sc.engine == e]
    ax.plot(d.n_rows / 1e6, d.median_s, marker="o", color=col, label=lab[e])
ax.set_xlabel("Triệu dòng Silver")
ax.set_ylabel("Giây (trung vị)")
ax.set_title("Mở rộng theo khối lượng dữ liệu")
ax.legend()
f.tight_layout()
save(f, "f42_spark_engine_scale")

# f43: shuffle partitions
f, ax = fig(6.0, 2.8)
for flag, col, lb in ((True, C["s1"], "Bật AQE"), (False, C["s2"], "Tắt AQE")):
    d = sh[sh.aqe == flag]
    ax.plot(d.shuffle.astype(str), d.median_s, marker="o", color=col, label=lb)
ax.legend()
ax.set_xlabel("spark.sql.shuffle.partitions")
ax.set_ylabel("Giây (trung vị)")
ax.set_title("Số phần vùng xáo trộn và thời gian truy vấn")
save(f, "f43_spark_shuffle")

# f44: cache
f, ax = fig(6.4, 2.9)
g = cr[cr["query"] != "vật chất hóa bộ đệm"].groupby(["query",
"phase"]).seconds.median().unstack()
xs = range(len(g))
ax.bar([i - 0.2 for i in xs], g["không lưu đệm"], 0.4, color=C["neutral"], label="Đọc lại từ
Parquet")
ax.bar([i + 0.2 for i in xs], g["lưu đệm"], 0.4, color=C["s1"], label="Từ bộ đệm trong bộ nhớ")
ax.set_xticks(list(xs), [q.split("_", 1)[1] for q in g.index])
ax.set_ylabel("Giây (trung vị 2 lần)")
ax.set_title("Hiệu quả lưu đệm DataFrame")
ax.legend()
save(f, "f44_spark_cache")

# f45: streaming - kết quả cửa sổ giờ
h = pd.read_parquet(STREAM / "stream_hourly.parquet")
h = h.groupby("hour")[["n", "n_crz", "n_cbd", "cbd"]].sum().reset_index().sort_values("hour")
h.to_csv(TAB / "t67b_stream_hourly.csv", index=False)
f, axes = fig(6.8, 4.2, nrows=2, sharex=True)
axes[0].plot(h.hour, h.n / 1e3, color=C["neutral_dark"], lw=1.2, label="Mọi chuyển")
axes[0].plot(h.hour, h.n_crz / 1e3, color=C["s1"], lw=1.2, label="Chuyển chậm CRZ")
axes[0].set_ylabel("Nghìn chuyển/giờ")
axes[0].legend(loc="upper left", ncol=2)
axes[0].set_title("Kết quả cửa sổ 1 giờ do Structured Streaming phát ra")
axes[1].plot(h.hour, h.n_cbd / h.n * 100, color=C["s2"], lw=1.2)
axes[1].set_ylabel("% chuyển có phí CBD")
import datetime as dt
for a in axes:
    policy_line(a, dt.datetime(2025, 1, 5), "") if a is axes[1] else a.axvline(
        dt.datetime(2025, 1, 5), color=C["text2"], lw=1, ls="--")
axes[1].xaxis.set_major_formatter(mdates.DateFormatter("%d/%m"))
f.tight_layout()
save(f, "f45_stream_hourly")

# f46: độ trễ lô vi mô
f, ax = fig(6.4, 2.8)
ax.bar(sb.batch.astype(str), sb.trigger_ms / 1000, color=C["s1"])
ax2 = ax.twinx()
ax2.plot(sb.batch.astype(str), sb.rows / 1e3, color=C["s2"], marker="o", lw=1.2)
ax2.set_ylabel("Nghìn dòng/lô", color=C["s2"])
ax2.grid(False)
ax.set_xlabel("Lô vi mô (mỗi lô = một ngày dữ liệu)")
ax.set_ylabel("Giây xử lý/lô")
ax.set_title("Thời gian xử lý từng lô vi mô")
save(f, "f46_stream_batches")
print(tot, eng, sh, sc, pr, sep="\n")

if __name__ == "__main__":
    part = sys.argv[1]

```

I.20. 15b_compare_outputs.py

I.21. 16_governance_risk.py

```

lineage          Phả hệ dữ liệu (lineage) trích tự động từ mã nguồn: bước nào đọc/ghi gì. -> t69,
f47
integrity [giây] Chuỗi cung ứng dữ liệu: băm SHA-256 mọi tệp Bronze (tăng dần, lũy đẳng). -> t70
reconcile        Đối soát số dòng Bronze = Silver + bị loại, và Silver = metadata Parquet. ->
t71
anomaly          Phát hiện bất thường theo ngày (z-score bền vững theo thứ trong tuần) và
biểu đồ kiểm soát tỷ lệ loại bỏ theo tháng (p-chart). -> t72,
f48, f49
tripanom        Phát hiện chuyển bất thường trên mẫu chuyển (Isolation Forest + quy tắc). -> t73,
f50
privacy         Rủi ro tái nhận dạng: k-ẩn danh theo các tổ hợp định danh gián tiếp. -> t74,
f51
dp              Quyền riêng tư vi phân: nhiễu Laplace lên số chuyển công bố và ảnh hưởng
đến ước lượng DiD chính (đánh đổi riêng tư - hữu dụng). -> t75,
f52
dr              Phục hồi sau sự cố: thời gian dựng lại từng lớp đo từ nhật ký (RT0). -> t76
Chạy: python code/16_governance_risk.py <phần>
"""
import hashlib
import json
import re
import sys
import time

import numpy as np
import pandas as pd

from config import GOLD, LOG, MONTHS, RAW, ROOT, SEED, SERVICES, SILVER, TAB, duck

GLOG = LOG / "governance"
GLOG.mkdir(parents=True, exist_ok=True)
CODE = ROOT / "code"

def wlog(name, rec):
    (GLOG / f"{name}.json").write_text(json.dumps(rec, indent=2, ensure_ascii=False, default=str))
    print(json.dumps(rec, ensure_ascii=False, default=str)[:800], flush=True)

# ----- catalog
def part_catalog():
    import pyarrow.parquet as pq
    rows = []

    def add(layer, name, files, owner):
        files = [f for f in files if f.exists()]
        if not files:
            return
        md = [pq.ParquetFile(f).metadata for f in files]
        sch = pq.ParquetFile(files[0]).schema_arrow
        fp = hashlib.md5(";".join(f"{f.name}:{f.type}" for f in sch).encode()).hexdigest()[:10]
        rows.append(dict(layer=layer, dataset=name, files=len(files), rows=sum(m.num_rows for m in
md),
                                columns=len(sch), row_groups=sum(m.num_row_groups for m in md),
                                size_mb=round(sum(f.stat().st_size for f in files) / 2**20, 1),
                                schema_fp=fp, producer=owner))

    for svc, pre in (("hvhv", "fhvhv"), ("yellow", "yellow")):
        for y in ("2024", "2025"):
            add("Bronze", f"{pre}_tripdata_{y}-*", sorted(RAW.glob(f"{pre}_tripdata_{y}-
*.parquet")), "NYC TLC")
            add("Silver", f"service={svc}/year={y}", sorted((SILVER / f"service={svc}" /
f"year={y}").rglob("*.parquet")),
                "03_silver_goldmonth.py")
            for f in sorted(GOLD.glob("*.parquet")):
                add("Gold", f.stem, [f], "02/04/09")
            t = pd.DataFrame(rows)
            # Lệnh lược đồ giữa các tệp cùng tập dữ liệu (số dấu vân tay khác nhau)
            drift = []
            for (layer, pre) in (("Bronze", "fhvhv"), ("Bronze", "yellow")):
                fps = {}
                for f in sorted(RAW.glob(f"{pre}_tripdata_*.parquet")):
                    s = pq.ParquetFile(f).schema_arrow
                    fps.setdefault(hashlib.md5(";".join(f"{x.name}:{x.type}" for x in
s).encode()).hexdigest()[:10], []).append(f.stem[-7:])
                drift.append(dict(layer=layer, source=pre, distinct_schemas=len(fps),
                                schemas={k: f"{v[0]}..{v[-1]} ({len(v)} tệp)" for k, v in fps.items()}))
            t.to_csv(TAB / "t68_data_catalog.csv", index=False)
            pd.DataFrame(drift).to_csv(TAB / "t68b_schema_fingerprints.csv", index=False)
            wlog("catalog", dict(datasets=len(t), total_rows=int(t.rows.sum()),
                                total_mb=float(t.size_mb.sum()),
                                drift=drift))

```

```

# ----- lineage
def part_lineage():
    """Trích phá hệ từ mã: tên bảng Gold, tệp bảng (tNN) và hình (fNN) mà mỗi bước đọc hoặc ghi."""
    gold_names = sorted({p.stem for p in GOLD.glob("*.parquet")} | {"zone_adjacency"})
    steps = sorted(p for p in CODE.glob("[0-9][0-9]*.py"))
    helpers = {"panels.py": (CODE / "panels.py").read_text(encoding="utf-8")}
    edges = []
    for p in steps:
        src = p.read_text(encoding="utf-8")
        name = p.stem
        # Bảng/hình được ghi
        w_tab = sorted(set(re.findall(r'TAB\s*/\s*f?(t\d+[a-z]?[_\^{}+]|a\d+[_\^{}+]', src)))
        w_fig = sorted(set(re.findall(r'save\s*\s*f\s*,\s*f?(f\d+[a-z]?[_\^{}+]', src)))
        uses_panels = "from panels import" in src
        read_gold = [g for g in gold_names if re.search(rf"\b{g}\b", src) or (uses_panels and
re.search(rf"\b{g}\b", helpers["panels.py"]))]
        writes_gold = []
        if name.startswith("02_"):
            writes_gold = ["dim_zone", "zone_adjacency", "zone_polygons"]
        elif name.startswith("04_"):
            writes_gold = [g for g in gold_names if g not in ("dim_zone", "zone_adjacency",
"zone_polygons", "dml_od_dataset")]
        elif name.startswith("09_"):
            writes_gold = ["dml_od_dataset"]
        reads = [g for g in read_gold if g not in writes_gold]
        edges.append(dict(step=name, reads_gold=";".join(reads), writes_gold=";".join(writes_gold),
reads_raw=int("raw_file(" in src or "RAW" in src),
reads_silver=int("SILVER" in src or "silver_file(" in src or "month_dir("
in src),
writes_silver=int(name.startswith("03_")),
n_tables=len(w_tab), n_figures=len(w_fig),
tables=";".join(w_tab), figures=";".join(w_fig)))

    t = pd.DataFrame(edges)
    t.to_csv(TAB / "t69_lineage.csv", index=False)

    # Hình phá hệ: các cột Bronze → Silver → Gold → bước phân tích → sản phẩm
    from viz import C, fig, save
    f, ax = fig(7.0, 6.2)
    ax.axis("off")
    ax.set_xlim(0, 100)
    ana = [r for r in edges if r["n_tables"] + r["n_figures"] > 0 and not
r["step"].startswith(("13_",))]
    n = len(ana)
    ys = np.linspace(95, 5, n)
    gold_y = {g: y for g, y in zip(gold_names, np.linspace(90, 10, len(gold_names)))}
    ax.set_ylim(0, 100)

    def node(x, y, txt, col, w=15, fs=6.2):
        ax.text(x, y, txt, ha="center", va="center", fontsize=fs, color=C["text"],
bbox=dict(boxstyle="round,pad=0.3", fc=col, ec=C["text2"], lw=0.5), zorder=3)

    node(6, 50, "Bronze\n48 tệp chuyển\n+ bảng vùng", "#e4d6c3")
    node(22, 50, "Silver\n120 tệp\nservice/year/month", "#d9dde3")
    for g, y in gold_y.items():
        node(44, y, g, "#f3e2a6", fs=5.8)
        ax.annotate("", xy=(40, y), xytext=(26.5, 50), arrowprops=dict(arrowstyle="-",
color=C["grid"], lw=0.6))
        ax.annotate("", xy=(18, 50), xytext=(10, 50), arrowprops=dict(arrowstyle="->",
color=C["text2"]))
    for r, y in zip(ana, ys):
        lab = r["step"].split("_", 1)[0] + " " + r["step"].split("_", 1)[1][:18]
        node(72, y, lab, "#eef3fb", fs=5.8)
        node(93, y, f"{r['n_tables']} bảng · {r['n_figures']} hình", "#ffffff", fs=5.6)
        for g in r["reads_gold"].split(";"):
            if g in gold_y:
                ax.annotate("", xy=(65, y), xytext=(48.5, gold_y[g]),
arrowprops=dict(arrowstyle="-", color=C["s1"], lw=0.45, alpha=0.6))
            if r["reads_silver"] or r["reads_raw"]:
                ax.annotate("", xy=(65, y), xytext=(26.5, 50),
arrowprops=dict(arrowstyle="-", color=C["s2"], lw=0.45, alpha=0.6))
                ax.annotate("", xy=(86, y), xytext=(79, y), arrowprops=dict(arrowstyle="->",
color=C["text2"], lw=0.5))
        ax.set_title("Phá hệ dữ liệu trích tự động từ mã nguồn", loc="left")
        save(f, "f47_lineage")
        wlog("lineage", dict(steps=len(edges), tables=int(t.n_tables.sum()),
figures=int(t.n_figures.sum())))

# ----- integrity
def part_integrity(budget):
    t0 = time.time()
    man = LOG / "sha256_manifest.json"
    done = json.loads(man.read_text()) if man.exists() else {}
    files = sorted(RAW.glob("*.parquet")) + sorted(RAW.glob("*.csv")) + sorted(RAW.glob("*.zip"))
    for f in files:

```

```

if f.name in done and done[f.name]["bytes"] == f.stat().st_size:
    continue
if time.time() - t0 > budget:
    break
t = time.perf_counter()
h = hashlib.sha256()
with open(f, "rb") as fh:
    for chunk in iter(lambda: fh.read(8 << 20), b''):
        h.update(chunk)
el = time.perf_counter() - t
done[f.name] = dict(sha256=h.hexdigest(), bytes=f.stat().st_size, seconds=round(el, 2))
man.write_text(json.dumps(done, indent=1))
left = [f.name for f in files if f.name not in done]
print("integrity: đã băm", len(done), "tệp; còn", len(left))
if not left:
    t = pd.DataFrame([dict(file=k, **v) for k, v in done.items()]).sort_values("file")
    t["mb_per_s"] = t.bytes / 2**20 / t.seconds.replace(0, np.nan)
    t.to_csv(TAB / "t70_sha256_manifest.csv", index=False)
    # Kiểm tra lại (xác minh) ngẫu nhiên 3 tệp: băm lại và so khớp
    rng = np.random.default_rng(SEED)
    chk = []
    for name in rng.choice(t.file.values, 3, replace=False):
        h = hashlib.sha256()
        with open(RAW / name, "rb") as fh:
            for chunk in iter(lambda: fh.read(8 << 20), b''):
                h.update(chunk)
        chk.append(dict(file=name, match=h.hexdigest() == done[name]["sha256"]))
    wlog("integrity", dict(files=len(t), total_gb=round(t.bytes.sum() / 2**30, 2),
        seconds=round(t.seconds.sum(), 1),
        throughput_mb_s=round(t.bytes.sum() / 2**20 / t.seconds.sum(), 1),
        reverify=chk))

# ----- reconcile
def part_reconcile():
    import pyarrow.parquet as pq
    q = pd.read_csv(TAB / "t06_quality_by_month.csv")
    man = pd.read_csv(TAB / "t01_bronze_manifest.csv")
    rows = []
    for _, r in q.iterrows():
        y, m = r.month.split("-")
        sd = SILVER / f"service={r.service}" / f"year={y}" / f"month={m}"
        meta_rows = sum(pq.ParquetFile(f).metadata.num_rows for f in sd.glob("*.parquet"))
        b = man[(man.service == r.service) & (man.month == r.month)]
        bronze_rows = int(b.n_rows.iloc[0]) if len(b) else None
        rows.append(dict(service=r.service, month=r.month, bronze_rows=bronze_rows,
            n_raw_processed=int(r.n_raw),
            n_rejected=int(r.n_rejected), n_silver_log=int(r.n_silver),
            n_silver_parquet=meta_rows,
            check_bronze=bool(bronze_rows == r.n_raw), check_balance=bool(r.n_raw ==
            r.n_rejected + r.n_silver),
            check_silver=bool(meta_rows == r.n_silver)))
    t = pd.DataFrame(rows)
    t.to_csv(TAB / "t71_reconciliation.csv", index=False)
    wlog("reconcile", dict(partitions=len(t), pass_bronze=int(t.check_bronze.sum()),
        pass_balance=int(t.check_balance.sum()),
        pass_silver=int(t.check_silver.sum())))

# ----- anomaly
def part_anomaly():
    from viz import C, fig, save, policy_line
    con = duck()
    d = con.execute(f"""SELECT service, d, pu_grp, sum(n) AS n FROM '{(GOLD /
'grp_hour_day.parquet').as_posix()}'
        GROUP BY ALL""").df()
    d["d"] = pd.to_datetime(d.d)
    out = []
    for (svc, grp), g in d.groupby(["service", "pu_grp"]):
        if grp not in ("CRZ", "MN_NORTH", "OUTER", "AIRPORT"):
            continue
        g = g.sort_values("d").set_index("d")
        s = np.log(g.n)
        # Kỳ vọng: trung vị của cùng thứ trong tuần trong cửa sổ ±28 ngày (không gồm chính ngày đó)
        exp, mad = [], []
        for day in s.index:
            win = s[(s.index >= day - pd.Timedelta(days=28)) & (s.index <= day +
            pd.Timedelta(days=28))
                & (s.index.dayofweek == day.dayofweek) & (s.index != day)]
            med = win.median()
            exp.append(med)
            mad.append(1.4826 * np.median(np.abs(win - med)))
        g["expected_log"] = exp
        g["mad"] = mad
        g["z"] = (s - g.expected_log) / g.mad.replace(0, np.nan)

```

```

        g["dev_pct"] = 100 * (np.exp(s - g.expected_log) - 1)
        g["service"], g["grp"] = svc, grp
        out.append(g.reset_index())
    a = pd.concat(out)
    a["flag"] = a.z.abs() > 3.5
    a.to_csv(TAB / "t72_daily_anomaly_scores.csv", index=False)
    fl = a[a.flag & (a.service == "hvfhv") & (a.grp == "CRZ")].sort_values("z")
    fl[["d", "n", "dev_pct", "z"]].to_csv(TAB / "t72b_anomaly_days_crz.csv", index=False)
    summ = a.groupby(["service", "grp"]).agg(days=("d", "count"), flagged=("flag", "sum"),
                                             flagged_low=("z", lambda z: int((z < -3.5).sum())),
                                             flagged_high=("z", lambda z: int((z >
3.5).sum()))).reset_index()
    summ.to_csv(TAB / "t72c_anomaly_summary.csv", index=False)
    # Hình f48
    h = a[(a.service == "hvfhv") & (a.grp == "CRZ")].sort_values("d")
    f, axes = fig(6.8, 4.2, nrows=2, sharex=True)
    axes[0].plot(h.d, h.n / 1e3, color=C["s1"], lw=0.9, label="Thực tế")
    axes[0].plot(h.d, np.exp(h.expected_log) / 1e3, color=C["neutral_dark"], lw=0.9, label="Kỳ vọng
(trung vị cùng thứ)")
    axes[0].scatter(h.d[h.flag], h.n[h.flag] / 1e3, color=C["s8"], s=14, zorder=3, label="Bất thường
|z|>3,5")
    axes[0].set_ylabel("Nghìn chuyến/ngày")
    axes[0].legend(loc="lower left", ncol=3, fontsize=7.5)
    axes[0].set_title("Phát hiện ngày bất thường: số chuyến HVFHV đón trong CRZ")
    axes[1].bar(h.d, h.z.clip(-15, 15), color=np.where(h.flag, C["s8"], C["neutral"]), width=1.0)
    axes[1].axhline(3.5, color=C["text2"], lw=0.7, ls=":")
    axes[1].axhline(-3.5, color=C["text2"], lw=0.7, ls=":")
    axes[1].set_ylabel("z bền vững (cắt ±15)")
    policy_line(axes[1], P_TS)
    f.tight_layout()
    save(f, "f48_anomaly_days")
    # Biểu đồ kiểm soát tỷ lệ loại bỏ theo tháng. Với n ~ 2e7 bản ghi mỗi tháng, giới hạn p-chart
nhị thức
    # rất hẹp nên hầu như tháng nào cũng "vượt kiểm soát" (quá phân tán). Biểu đồ p' của Laney
(2002) hiệu
    # chỉnh bằng độ lệch chuẩn của z-score ước lượng từ khoảng biến động di chuyển (moving range).
    q = pd.read_csv(TAB / "t06_quality_by_month.csv")
    rowsq = []
    f, axes = fig(6.8, 3.0, ncols=2)
    for ax, svc in zip(axes, SERVICES):
        s = q[q.service == svc].sort_values("month")
        pbar = s.n_rejected.sum() / s.n_raw.sum()
        sig = np.sqrt(pbar * (1 - pbar) / s.n_raw)
        p = s.n_rejected / s.n_raw
        z = (p - pbar) / sig
        sigma_z = np.mean(np.abs(np.diff(z))) / 1.128
        ucl, lcl = pbar + 3 * sig, pbar - 3 * sig
        ucl2, lcl2 = pbar + 3 * sig * sigma_z, np.maximum(pbar - 3 * sig * sigma_z, 0)
        out_c = (p > ucl) | (p < lcl)
        out_l = (p > ucl2) | (p < lcl2)
        rowsq.append(dict(service=svc, pbar_pct=100 * pbar, months=len(s),
out_p_chart=int(out_c.sum()),
                        sigma_z=float(sigma_z), out_laney=int(out_l.sum()),
                        laney_months=";".join(s.month[out_l].tolist()),
                        p_min_pct=100 * p.min(), p_max_pct=100 * p.max()))
        ax.plot(range(len(s)), 100 * p, marker="o", ms=3, color=C["s1"], label="Tỷ lệ loại")
        ax.plot(range(len(s)), 100 * ucl2, color=C["s8"], lw=0.8, ls="--", label="Giới hạn p'
(Laney)")
        ax.plot(range(len(s)), 100 * lcl2, color=C["s8"], lw=0.8, ls="--")
        ax.plot(range(len(s)), 100 * ucl, color=C["neutral_dark"], lw=0.6, ls=":", label="Giới hạn p
nhị thức")
        ax.plot(range(len(s)), 100 * lcl, color=C["neutral_dark"], lw=0.6, ls=":")
        ax.axhline(100 * pbar, color=C["text2"], lw=0.8)
        ax.set_xticks(range(0, len(s), 6), [m[2:] for m in s.month.values[::6]])
        ax.set_title("HVFHV" if svc == "hvfhv" else "Taxi vàng")
        ax.set_ylabel("% chuyến bị loại")
        axes[0].legend(fontsize=6.5, loc="upper left")
    f.tight_layout()
    save(f, "f49_pchart_reject")
    pd.DataFrame(rowsq).to_csv(TAB / "t72d_pchart_reject.csv", index=False)
    wlog("anomaly", dict(summary=summ.to_dict("records"), crz_flagged=len(fl), pchart=rowsq))

P_TS = pd.Timestamp("2025-01-05")

# ----- tripanom
def part_tripanom():
    from sklearn.ensemble import IsolationForest
    from viz import C, fig, save
    s = pd.read_parquet(GOLD / "trip_sample.parquet",
                        columns=["service", "company_code", "pu", "dl", "miles", "time_s", "fare",
"driver_pay",
                        "tips", "wait_min", "mph", "pu_grp", "do_grp", "cbd_fee", "d",
"hr"])

```

```

s = s[s.service == "hvfhv"].dropna(subset=["miles", "time_s", "fare", "driver_pay"]).copy()
s["fare_pm"] = s.fare / s.miles
s["pay_ratio"] = s.driver_pay / s.fare
s["tip_ratio"] = s.tips / s.fare
feats = ["miles", "time_s", "fare", "driver_pay", "mph", "fare_pm", "pay_ratio", "tip_ratio"]
X = s[feats].copy()
for c in ("miles", "time_s", "fare", "driver_pay", "fare_pm"):
    X[c] = np.log(X[c].clip(lower=1e-3))
X = X.replace([np.inf, -np.inf], np.nan).fillna(X.median())
t0 = time.perf_counter()
iso = IsolationForest(n_estimators=200, contamination=0.005, random_state=SEED, n_jobs=2).fit(X)
s["score"] = -iso.score_samples(X)
s["iso_flag"] = iso.predict(X) == -1
el = time.perf_counter() - t0
# Quy tắc nghiệp vụ minh bạch
rules = {
    "Thu nhập tài xế > giá cước + tip": s.driver_pay > s.fare + s.tips,
    "Giá cước / dặm > 30 USD": s.fare_pm > 30,
    "Tip > giá cước": s.tips > s.fare,
    "Tốc độ < 2 dặm/giờ và thời gian > 30 phút": (s.mph < 2) & (s.time_s > 1800),
    "Cùng vùng đón/trả và quãng đường > 10 dặm": (s.pu == s.dl) & (s.miles > 10),
}
rr = []
for k, m in rules.items():
    rr.append(dict(rule=k, n=int(m.sum()), pct=100 * m.mean(), overlap_iso_pct=100 * (m &
s.iso_flag).sum() / max(m.sum(), 1)))
    rr.append(dict(rule="Isolation Forest (ngưỡng 0,5%)", n=int(s.iso_flag.sum()), pct=100 *
s.iso_flag.mean(),
                    overlap_iso_pct=100.0))
pd.DataFrame(rr).to_csv(TAB / "t73_trip_anomaly_rules.csv", index=False)
prof = s.groupby("iso_flag")[["miles", "time_s", "fare", "driver_pay", "mph", "fare_pm",
"pay_ratio", "tip_ratio",
                        "wait_min"]].median().T
prof.columns = ["Bình thường" if not c else "Bất thường" for c in prof.columns]
prof.to_csv(TAB / "t73b_trip_anomaly_profile.csv")
comp = pd.crosstab(s.company_code, s.iso_flag, normalize="index") * 100
comp.to_csv(TAB / "t73c_trip_anomaly_by_company.csv")
grp = (s.assign(crz=(s.pu_grp == "CRZ") | (s.do_grp == "CRZ"),
                post=pd.to_datetime(s.d) >= P_TS)
        .groupby(["crz", "post"]).iso_flag.mean() * 100).reset_index()
grp.to_csv(TAB / "t73d_trip_anomaly_by_crz_period.csv", index=False)
f, ax = fig(6.4, 3.4)
nm = s[~s.iso_flag].sample(min(40000, (~s.iso_flag).sum()), random_state=SEED)
ab = s[s.iso_flag]
ax.scatter(nm.miles, nm.fare, s=1.5, color=C["neutral"], alpha=0.5, label="Bình thường (mẫu)",
rasterized=True)
ax.scatter(ab.miles, ab.fare, s=3, color=C["s8"], alpha=0.8, label="Bất thường (Isolation
Forest)", rasterized=True)
ax.set_xscale("log")
ax.set_yscale("log")
ax.set_xlabel("Quãng đường (dặm, thang log)")
ax.set_ylabel("Giá cước cơ sở (USD, thang log)")
ax.set_title("Chuyến bất thường trên mẫu 0,25% chuyển HVFHV")
ax.legend(markerscale=4)
save(f, "f50_trip_anomaly")
wlog("tripanom", dict(n=len(s), flagged=int(s.iso_flag.sum()), fit_score_s=round(el, 1),
rules=rr))

# ----- privacy
def part_privacy():
    """k-ẩn danh trên một tháng Silver HVFHV: với mỗi tổ hợp định danh gián tiếp (quasi-identifier),
    tính tỷ lệ chuyển nằm trong lớp tương đương có kích thước 1 (duy nhất), < 5 và < 10."""
    from viz import C, fig, save
    con = duck()
    y, m = "2025", "03"
    src = (SILVER / "service=hvfhv" / f"year={y}" / f"month={m}" / "*.parquet").as_posix()
    dz = (GOLD / "dim_zone.parquet").as_posix()
    con.execute(f"CREATE TEMP TABLE t AS SELECT s.pu, s.dl, s.d, s.hr, s.company_code,
s.pickup_ts, s.request_ts,
                s.dow, zp.Borough AS pb, zd.Borough AS db
                FROM read_parquet('{src}') s
                LEFT JOIN '{dz}' zp ON s.pu = zp.LocationID LEFT JOIN '{dz}' zd ON s.dl =
zd.LocationID")
    n = con.execute("SELECT count(*) FROM t").fetchone()[0]
    gis = [
        ("Quận đón, quận trả, tháng", "pb, db"),
        ("Quận đón, quận trả, ngày", "pb, db, d"),
        ("Quận đón, quận trả, ngày, giờ", "pb, db, d, hr"),
        ("Vùng đón, vùng trả", "pu, dl"),
        ("Vùng đón, vùng trả, thứ, giờ", "pu, dl, dow, hr"),
        ("Vùng đón, vùng trả, ngày", "pu, dl, d"),
        ("Vùng đón, vùng trả, ngày, giờ", "pu, dl, d, hr"),
        ("Vùng đón, vùng trả, ngày, giờ, hãng", "pu, dl, d, hr, company_code"),
        ("Vùng đón, vùng trả, phút đón", "pu, dl, date_trunc('minute', pickup_ts)),
    ]

```



```

        ("Vùng đón, vùng trả, giấy đón (như bản công bố)", "pu, dl, pickup_ts"),
    ]
    rows = []
    for lab, cols in qis:
        t = time.perf_counter()
        r = con.execute(f"""WITH g AS (SELECT count(*) AS k FROM t GROUP BY {cols})
            SELECT count(*) AS classes, sum(k) AS trips,
                sum(CASE WHEN k=1 THEN k ELSE 0 END) AS k1, sum(CASE WHEN k<5 THEN k ELSE 0 END)
AS k5,
                sum(CASE WHEN k<10 THEN k ELSE 0 END) AS k10, median(k) AS med_k FROM
g""").fetchone()
        rows.append(dict(qi=lab, columns=cols, classes=r[0], trips=r[1], unique_pct=100 * r[2] /
r[1],
                        lt5_pct=100 * r[3] / r[1], lt10_pct=100 * r[4] / r[1], median_class=r[5],
                        seconds=round(time.perf_counter() - t, 2)))
        print(rows[-1], flush=True)
    tb = pd.DataFrame(rows)
    tb.to_csv(TAB / "t74_privacy_kanonymity.csv", index=False)
    plot_privacy()
    wlog("privacy", dict(month=f"{y}-{m}", trips=n, results=rows))

def plot_privacy():
    from viz import C, fig, save
    tb = pd.read_csv(TAB / "t74_privacy_kanonymity.csv")
    f, ax = fig(6.8, 3.8)
    yy = range(len(tb))
    ax.barh([i + 0.27 for i in yy], tb.unique_pct, 0.27, color=C["s8"], label="k = 1 (duy nhất)")
    ax.barh(list(yy), tb.lt5_pct, 0.27, color=C["s4"], label="k < 5")
    ax.barh([i - 0.27 for i in yy], tb.lt10_pct, 0.27, color=C["s1"], label="k < 10")
    ax.set_yticks(list(yy), tb.qi, fontsize=7)
    ax.invert_yaxis()
    ax.set_xlabel("% chuyển trong lớp tương đương nhỏ")
    ax.set_title("Rủi ro tái nhận dạng theo mức chi tiết của định danh gián tiếp")
    ax.legend(loc="upper right")
    save(f, "f51_privacy_kanonymity")

# ----- dp
def part_dp():
    """Nhiều Laplace ( $\epsilon$ -DP ở mức chuyển, độ nhảy 1) lên từng ô vùng  $\times$  ngày của bảng công bố,
    sau đó dựng lại panel vùng  $\times$  tuần và ước lượng lại TWFE log số chuyển."""
    from causal import fe_ols
    from panels import W0, W_END, P, dim, MIN_DAILY
    from viz import C, fig, save
    z = pd.read_parquet(GOLD / "zone_day_pu.parquet", columns=["service", "d", "zone", "n"])
    z = z[z.service == "hvfhv"].copy()
    z["d"] = pd.to_datetime(z.d)
    z = z[(z.d >= W0) & (z.d <= W_END)]
    z["wk"] = z.d - pd.to_timedelta((z.d.dt.dayofweek + 1) % 7, unit="D")
    dm = dim()["LocationID", "grp"]
    z = z.merge(dm, left_on="zone", right_on="LocationID")
    z = z[z.grp.isin(["CRZ", "MN_NORTH", "OUTER"])]
    # Tập vùng cố định như bản không nhiễu (panels.zone_week)
    wk0 = z.groupby(["zone", "wk", "grp"]).n.sum().reset_index()
    pre = wk0[wk0.wk < P].groupby("zone").n.sum() / ((P - W0).days)
    keep = pre[pre >= MIN_DAILY["hvfhv"]].index
    full = wk0.groupby("zone").wk.nunique()
    keep = [k for k in keep if full.get(k, 0) == wk0.wk.nunique()]
    z = z[z.zone.isin(keep)].copy()

    def estimate(z):
        g = z.groupby(["zone", "wk", "grp"]).n.sum().reset_index()
        g["treat"] = (g.grp == "CRZ").astype(int)
        g["p"] = g.treat * (g.wk >= P).astype(int)
        g["ln_n"] = np.log(g.n.clip(lower=1))
        res, info, _ = fe_ols(g, "ln_n", ["p"], ["zone", "wk", "zone"])
        return res.coef.iloc[0], res.se.iloc[0], info["n_obs"]

    b0, se0, nobs = estimate(z)
    rng = np.random.default_rng(SEED)
    rows = [dict(eps=np.inf, rep=0, coef=b0, se=se0)]
    t0 = time.perf_counter()
    cell_small = z.n.quantile(0.05)
    for eps in (0.001, 0.005, 0.01, 0.05, 0.1, 1.0):
        for rep in range(40):
            zz = z.copy()
            zz["n"] = np.maximum(zz.n + rng.laplace(0, 1 / eps, len(zz)), 1)
            b, se, _ = estimate(zz)
            rows.append(dict(eps=eps, rep=rep + 1, coef=b, se=se))
    r = pd.DataFrame(rows)
    r.to_csv(TAB / "t75_dp_replications.csv", index=False)
    s = r[np.isfinite(r.eps)].groupby("eps").agg(mean_coef=("coef", "mean"), sd_coef=("coef",
"std"),
                                                mean_se=("se", "mean")).reset_index()

```

```

s["bias"] = s.mean_coef - b0
s["rmse"] = np.sqrt(s.bias ** 2 + s.sd_coef ** 2)
s["noise_sd_cell"] = np.sqrt(2) / s.eps
s["noise_rel_p5_cell_pct"] = 100 * s.noise_sd_cell / cell_small
s["pct_effect_mean"] = 100 * (np.exp(s.mean_coef) - 1)
s["baseline_coef"], s["baseline_se"] = b0, se0
s.to_csv(TAB / "t75b_dp_summary.csv", index=False)
f, ax = fig(6.4, 3.0)
ax.errorbar(s.eps, 100 * (np.exp(s.mean_coef) - 1), yerr=[100 * (np.exp(s.mean_coef) -
np.exp(s.mean_coef) - 1.96 * s.sd_coef)),
            100 * (np.exp(s.mean_coef) + 1.96 * s.sd_coef) - np.exp(s.mean_coef)],
            fmt="o-", color=C["s1"], capsize=3, label="Có nhiều Laplace (trung bình ± 1,96 độ
lệch chuẩn)")
ax.axhline(100 * (np.exp(b0) - 1), color=C["s2"], ls="--", lw=1, label="Không nhiều")
ax.set_xscale("log")
ax.set_xlabel("Ngân sách riêng tư ε (thang log; nhỏ hơn = riêng tư hơn)")
ax.set_ylabel("Tác động lên số chuyển (%)")
ax.set_title("Đánh đổi riêng tư - hữu dụng của bảng công bố vùng × ngày")
ax.legend(fontsize=7.5)
save(f, "f52_dp_tradeoff")
wlog("dp", dict(cells=len(z), zones=len(keep), obs=nobs, baseline=b0,
seconds=round(time.perf_counter() - t0, 1),
cell_p5=float(cell_small)))

# ----- dr
def part_dr():
    q = pd.read_csv(TAB / "t08_partition_runtime.csv")
    bronze = pd.read_csv(TAB / "t01_bronze_manifest.csv")
    g04 = json.loads((LOG / "04_gold_consolidate.json").read_text())["seconds"]
    steps = {}
    for f in LOG.glob("*.json"):
        try:
            d = json.loads(f.read_text())
            if isinstance(d, dict) and "seconds" in d:
                steps[f.stem] = d["seconds"]
        except Exception:
            pass
    ana = sum(v for k, v in steps.items() if k[:2] in ("06", "07", "08", "09", "10", "11", "14"))
    rows = [
        dict(scenario="Mất lớp Gold (còn Silver)", rebuild="Chạy lại phần Gold của bước 03 + bước
04",
            seconds=float(q.sec_gold.sum() + g04)),
        dict(scenario="Mất lớp Silver và Gold (còn Bronze)", rebuild="Chạy lại bước 03 toàn bộ +
bước 04",
            seconds=float(q.sec_total.sum() + g04)),
        dict(scenario="Mất một phần vùng tháng HVFHV", rebuild="Chạy lại 4 khúc của tháng đó",
            seconds=float(q[q.service == "hvfhv"].groupby("month").sec_total.sum().median())),
        dict(scenario="Mất toàn bộ kết quả phân tích (còn Gold)", rebuild="Chạy lại các bước 06-11,
14",
            seconds=float(ana)),
    ]
    t = pd.DataFrame(rows)
    t["minutes"] = t.seconds / 60
    sizes = dict(bronze_gb=bronze.size_mb.sum() / 1024)
    t.to_csv(TAB / "t76_recovery_rto.csv", index=False)
    wlog("dr", dict(rows=rows, **sizes))

if __name__ == "__main__":
    part = sys.argv[1]
    arg = sys.argv[2:]
    fn = {"catalog": part_catalog, "lineage": part_lineage, "reconcile": part_reconcile, "anomaly":
part_anomaly,
        "tripanom": part_tripanom, "privacy": part_privacy, "privacy_fig": plot_privacy, "dp":
part_dp, "dr": part_dr}
    if part == "integrity":
        part_integrity(float(arg[0]) if arg else 1e9)
    elif part in fn:
        fn[part]()
    else:
        raise SystemExit(__doc__)

```

I.22. 17_business_analytics.py

"""Bước 17 - Phân tích phục vụ quyết định kinh doanh và chiến lược dữ liệu.

Các phần:

company	Tác động theo hãng (Uber, Lyft) và thị phần trong CRZ.	-> t77
forecast	Dự báo nhu cầu: so sánh mô hình dự báo số chuyển CRZ theo ngày trên giai đoạn giữ lại trước chính sách; dùng mô hình tốt nhất làm phân thực tế sau chính sách (cách tiếp cận kiểu CausalImpact).	-> t78, t79,

f53

```

power      Độ lớn tác động nhỏ nhất phát hiện được (MDE) theo độ dài giai đoạn sau
           chính sách: quy mô dữ liệu cần cho một "thử nghiệm A/B" chính sách.      -> t80, f54
pricing     Độ nhạy của giá theo nhu cầu trong ngày (dấu hiệu định giá động) trước/sau. -> t81
tco         Hạch toán tài nguyên của pipeline: dung lượng từng lớp, thời gian tính toán,
           tỷ lệ nén, tài nguyên cho mỗi triệu dòng.      -> t82
Chạy: python code/17_business_analytics.py <phần>
"""
import json
import sys
import time

import numpy as np
import pandas as pd

from causal import fe_ols
from config import GOLD, LOG, SEED, TAB
from panels import P, zone_week

BLOG = LOG / "business"
BLOG.mkdir(parents=True, exist_ok=True)

def wlog(name, rec):
    (BLOG / f"{name}.json").write_text(json.dumps(rec, indent=2, ensure_ascii=False, default=str))
    print(json.dumps(rec, ensure_ascii=False, default=str)[:900], flush=True)

# ----- company
def part_company():
    zw = zone_week("hvfhv", extra=("n_uber", "n_lyft"))
    zw["tw"] = zw.treat.astype(str) + "_" + zw.woy.astype(str)
    zw["ln_uber"] = np.log(zw.n_uber.clip(lower=1))
    zw["ln_lyft"] = np.log(zw.n_lyft.clip(lower=1))
    zw["uber_share"] = 100 * zw.n_uber / (zw.n_uber + zw.n_lyft)
    rows = []
    for y, lab in (("ln_uber", "log số chuyển Uber"), ("ln_lyft", "log số chuyển Lyft"),
                  ("uber_share", "Thị phần Uber trong HVFHV (%)")):
        for sname, fes in (("TWFE", ["zone", "wk"]), ("DDD mùa vụ", ["zone", "wk", "tw"])):
            res, info, _ = fe_ols(zw, y, ["D"], fes, "zone")
            r = res.iloc[0]
            pre = zw.loc[(zw.treat == 1) & (zw.post == 0), y].mean()
            rows.append(dict(outcome=y, outcome_label=lab, spec=sname, coef=r.coef, se=r.se, p=r.p,
                             ci_low=r.ci_low, ci_high=r.ci_high,
                             pct=100 * (np.exp(r.coef) - 1) if y.startswith("ln_") else np.nan,
                             treated_pre_mean=pre, n_obs=info["n_obs"],
                             n_clusters=info["n_clusters"]))
    t = pd.DataFrame(rows)
    t.to_csv(TAB / "t77_company.did.csv", index=False)
    # Kiểm định chênh lệch Uber - Lyft: hồi quy xếp chồng, cụm theo vùng
    st = pd.concat([zw.assign(y=zw.ln_uber, firm=1), zw.assign(y=zw.ln_lyft, firm=0)])
    st["zf"] = st.zone.astype(str) + "_" + st.firm.astype(str)
    st["wf"] = st.wk.astype(str) + "_" + st.firm.astype(str)
    st["D_uber"] = st.D * st.firm
    res, info, _ = fe_ols(st, "y", ["D", "D_uber"], ["zf", "wf", "zone"])
    diff = res[res.term == "D_uber"].iloc[0].to_dict()
    pd.DataFrame([diff]).to_csv(TAB / "t77b_company_diff.csv", index=False)
    wlog("company", dict(rows=rows, diff=diff))

# ----- forecast
def daily_groups():
    z = pd.read_parquet(GOLD / "grp_hour_day.parquet")
    z = z[z.service == "hvfhv"]
    d = z.groupby(["d", "pu_grp"]).n.sum().unstack()
    d.index = pd.to_datetime(d.index)
    return d.sort_index()

def features(d):
    from pandas.tseries.holiday import USFederalHolidayCalendar
    hol = USFederalHolidayCalendar().holidays(d.index.min(), d.index.max())
    X = pd.DataFrame(index=d.index)
    X["ln_mn"] = np.log(d["MN_NORTH"])
    X["ln_out"] = np.log(d["OUTER"])
    for k in range(6):
        X[f"dow{k}"] = (d.index.dayofweek == k).astype(int)
    X["holiday"] = d.index.isin(hol).astype(int)
    X["hol_adj"] = (d.index.isin(hol + pd.Timedelta(days=1)) | d.index.isin(hol -
pd.Timedelta(days=1))).astype(int)
    doy = d.index.dayofyear
    X["xmas"] = ((d.index.month == 12) & (d.index.day >= 20)) | ((d.index.month == 1) & (d.index.day
<= 3))
    X["xmas"] = X.xmas.astype(int)
    X["trend"] = (d.index - d.index.min()).days / 365.0
    X["sin1"], X["cos1"] = np.sin(2 * np.pi * doy / 365.25), np.cos(2 * np.pi * doy / 365.25)

```

```

return X

def part_forecast():
    import lightgbm as lgb
    from sklearn.linear_model import RidgeCV
    from viz import C, fig, save, policy_line
    d = daily_groups()
    y = np.log(d["CRZ"])
    X = features(d)
    tr_end, ho_end = pd.Timestamp("2024-10-31"), P - pd.Timedelta(days=1)
    tr, ho = X.index <= tr_end, (X.index > tr_end) & (X.index <= ho_end)
    cal = [c for c in X.columns if c not in ("ln_mn", "ln_out", "trend")]
    variants = {
        "Ridge: chỉ lịch + xu hướng": ("ridge", cal + ["trend"]),
        "Ridge: lịch + MN phía bắc + quận ngoài + xu hướng": ("ridge", cal + ["ln_mn", "ln_out",
"trend"]),
        "Ridge: lịch + MN phía bắc + quận ngoài": ("ridge", cal + ["ln_mn", "ln_out"]),
        "Ridge: lịch + quận ngoài": ("ridge", cal + ["ln_out"]),
        "LightGBM: lịch + MN phía bắc + quận ngoài": ("lgb", cal + ["ln_mn", "ln_out"]),
    }

    def fit(kind, cols, mask):
        if kind == "ridge":
            return RidgeCV(alphas=np.logspace(-3, 3, 13)).fit(X[mask][cols], y[mask])
        return lgb.LGBMRegressor(n_estimators=400, learning_rate=0.03, num_leaves=15,
min_child_samples=10,
                                random_state=SEED, verbose=-1).fit(X[mask][cols], y[mask])

    pre = X.index < P
    acc, fits = [], {}
    naive = y.shift(7)
    e = np.exp(y[ho]) - np.exp(naive[ho])
    acc.append(dict(model="Naive theo tuần (t-7)", holdout_days=int(ho.sum()),
mape_pct=100 * np.mean(np.abs(e) / np.exp(y[ho])), rmse=float(np.sqrt(np.mean(e
** 2))),
                                bias_pct=100 * np.mean(e / np.exp(y[ho])), post_effect_pct=np.nan))
    for k, (kind, cols) in variants.items():
        p = pd.Series(fit(kind, cols, tr).predict(X[cols]), index=X.index)
        e = np.exp(y[ho]) - np.exp(p[ho])
        mfull = fit(kind, cols, pre)
        cf = pd.Series(mfull.predict(X[cols]), index=X.index)
        post_eff = 100 * (np.exp(np.mean((y - cf)[~pre])) - 1)
        fits[k] = (mfull, cols, cf)
        acc.append(dict(model=k, holdout_days=int(ho.sum()), mape_pct=100 * np.mean(np.abs(e) /
np.exp(y[ho])),
                                rmse=float(np.sqrt(np.mean(e ** 2))), bias_pct=100 * np.mean(e /
np.exp(y[ho])),
                                post_effect_pct=post_eff))
    acc = pd.DataFrame(acc).sort_values("mape_pct")
    acc.to_csv(TAB / "t78_forecast_accuracy.csv", index=False)
    # Quy tắc chọn định trước: mô hình có MAPE giữ lại thấp nhất (trừ naive, không dự báo xa được)
    best = acc[acc.model.isin(list(variants)).iloc[0].model
m, cols_ctrl, cf = fits[best]
    resid = (y - cf)[pre]
    out = pd.DataFrame(dict(actual=np.exp(y), counterfactual=np.exp(cf)))
    out["effect_pct"] = 100 * (out.actual / out.counterfactual - 1)
    out["month"] = out.index.to_period("M").astype(str)
    # Khoảng tin cậy bằng bootstrap khối (khối 7 ngày) trên phần dư trước chính sách
    rng = np.random.default_rng(SEED)
    r = resid.values
    B = 500
    mon = []
    post = out[out.index >= P]
    for mth, g in post.groupby("month"):
        L = len(g)
        sims = []
        for _ in range(B):
            starts = rng.integers(0, len(r) - 7, size=int(np.ceil(L / 7)))
            e = np.concatenate([r[s:s + 7] for s in starts])[L:]
            sims.append(np.mean(e))
        gap = np.mean(np.log(g.actual.values) - np.log(g.counterfactual.values))
        lo, hi = np.percentile(gap - np.array(sims), [2.5, 97.5])
        mon.append(dict(month=mth, days=L, effect_pct=100 * (np.exp(gap) - 1),
ci_low=100 * (np.exp(lo) - 1), ci_high=100 * (np.exp(hi) - 1)))
    mon = pd.DataFrame(mon)
    mon["model"] = best
    all_post = 100 * (np.exp(np.mean(np.log(post.actual) - np.log(post.counterfactual))) - 1)
    mon.to_csv(TAB / "t79_forecast_counterfactual_monthly.csv", index=False)
    out.reset_index(names="d").to_csv(TAB / "t79b_forecast_daily.csv", index=False)
    coef = pd.Series(getattr(m, "coef_", np.full(len(cols_ctrl), np.nan)), index=cols_ctrl)
    f, axes = fig(6.8, 4.4, nrows=2, sharex=True)
    wk = out.resample("W-SAT").mean(numeric_only=True)
    axes[0].plot(wk.index, wk.actual / 1e3, color=C["s1"], label="Thực tế")

```

```

axes[0].plot(wk.index, wk.counterfactual / 1e3, color=C["s2"], ls="--", label="Dự báo phản thực
tế")
axes[0].set_ylabel("Nghìn chuyển/ngày")
axes[0].legend(loc="lower left")
axes[0].set_title("Dự báo nhu cầu làm phản thực tế cho số chuyển đón trong CRZ")
policy_line(axes[0], P)
axes[1].bar(pd.to_datetime(mon.month) + pd.Timedelta(days=14), mon.effect_pct, width=20,
color=C["s1"])
axes[1].errorbar(pd.to_datetime(mon.month) + pd.Timedelta(days=14), mon.effect_pct,
yerr=[mon.effect_pct - mon.ci_low, mon.ci_high - mon.effect_pct], fmt="none",
color=C["text2"], lw=0.8)
axes[1].axhline(0, color=C["text2"], lw=0.7)
axes[1].set_ylabel("Thực tế so với dự báo (%)")
f.tight_layout()
save(f, "f53_forecast_counterfactual")
wlog("forecast", dict(best=best, accuracy=acc.to_dict("records"), post_effect_pct=all_post,
coef=coef.to_dict(), resid_sd=float(resid.std())))

# ----- power
def part_power():
    from viz import C, fig, save
    zw = zone_week("hvfhv")
    rows = []
    for L in (4, 8, 13, 26, 39, 52):
        sub = zw[(zw.k < L)]
        for y, lab in (("ln_n", "log số chuyển"), ("mph", "Tốc độ (dặm/giờ)"), ("wait", "Thời gian
chờ (phút)")):
            res, info, _ = fe_ols(sub, y, ["D"], ["zone", "wk"], "zone")
            r = res.iloc[0]
            rows.append(dict(post_weeks=L, outcome=y, outcome_label=lab, coef=r.coef, se=r.se,
p=r.p,
mde80=2.8 * r.se, n_obs=info["n_obs"]))
    t = pd.DataFrame(rows)
    t["mde80_pct"] = np.where(t.outcome == "ln_n", 100 * (np.exp(t.mde80) - 1), np.nan)
    t.to_csv(TAB / "t80_power_mde.csv", index=False)
    f, axes = fig(6.8, 2.9, ncols=3)
    for ax, (y, lab) in zip(axes, (("ln_n", "log số chuyển"), ("mph", "Tốc độ (dặm/giờ)"), ("wait",
"Chờ (phút)"))):
        d = t[t.outcome == y]
        ax.plot(d.post_weeks, d.coef.abs(), marker="o", color=C["s1"], label="|Ước lượng|")
        ax.plot(d.post_weeks, d.mde80, marker="s", color=C["s2"], label="MDE (80%, α=5%)")
        ax.set_title(lab, fontsize=9)
        ax.set_xlabel("Số tuần sau chính sách")
        axes[0].legend(fontsize=7)
    f.tight_layout()
    save(f, "f54_power_mde")
    wlog("power", dict(rows=rows))

# ----- pricing
def part_pricing():
    h = pd.read_parquet(GOLD / "zone_hour_month.parquet")
    h = h[h.service == "hvfhv"].copy()
    dm = pd.read_parquet(GOLD / "dim_zone.parquet")[["LocationID", "grp"]]
    h = h.merge(dm, left_on="zone", right_on="LocationID")
    rows = []
    for grp in ("CRZ", "MN_NORTH", "OUTER"):
        g = h[(h.grp == grp) & (h.n >= 200)].copy()
        g["ln_fpm"] = np.log(g.fare / g.miles)
        g["ln_n"] = np.log(g.n)
        g["ln_mph"] = np.log(g.miles / (g.time_s / 3600))
        g["zm"] = g.zone.astype(str) + "_" + g.ym
        for per, gg in (("2024", g[g.ym < "2025-01"]), ("2025", g[g.ym >= "2025-01"])):
            res, info, _ = fe_ols(gg, "ln_fpm", ["ln_n", "ln_mph"], ["zm", "zone"])
            for _, r in res.iterrows():
                rows.append(dict(group=grp, period=per, term=r.term, coef=r.coef, se=r.se, p=r.p,
n_obs=info["n_obs"], n_clusters=info["n_clusters"],
within_r2=info["within_r2"]))
    t = pd.DataFrame(rows)
    t.to_csv(TAB / "t81_price_demand_elasticity.csv", index=False)
    wlog("pricing", dict(rows=rows))

# ----- tco
def part_tco():
    man = pd.read_csv(TAB / "t01_bronze_manifest.csv")
    q = pd.read_csv(TAB / "t06_quality_by_month.csv")
    cat = pd.read_csv(TAB / "t68_data_catalog.csv")
    steps = {}
    for f in list(LOG.glob("*.json")):
        try:
            d = json.loads(f.read_text())
            if isinstance(d, dict) and "seconds" in d:
                steps[f.stem] = float(d["seconds"])

```

```

except Exception:
    pass
spark = pd.read_csv(TAB / "t60b_spark_repro_totals.csv")
rows = []
n_raw = int(man.n_rows.sum())
for layer in ("Bronze", "Silver", "Gold"):
    c = cat[cat.layer == layer]
    rows.append(dict(item=f"Dung lượng lớp {layer}", value=c.size_mb.sum() / 1024, unit="GB",
                    note=f"{int(c.rows.sum()):,} dòng; {int(c.files.sum())} tệp"))
    rows.append(dict(item="Thời gian lớp Silver + Gold (bước 03)", value=q.sec_total.sum() / 60,
                    unit="phút",
                    note="2 luồng, giới hạn bộ nhớ DuckDB 1,8 GB"))
    rows.append(dict(item="Thời gian hợp nhất Gold (bước 04)",
                    value=steps.get("04_gold consolidate", np.nan) / 60,
                    unit="phút", note=""))
    ana = {k: v for k, v in steps.items() if k[:2] in ("06", "07", "08", "09", "10", "11", "14")}
    rows.append(dict(item="Thời gian các bước phân tích 06-11, 14", value=sum(ana.values()) / 60,
                    unit="phút",
                    note=f"{len(ana)} nhật ký"))
    rows.append(dict(item="Tài nguyên xử lý Silver+Gold trên mỗi triệu dòng Bronze",
                    value=q.sec_total.sum() * 2 / (n_raw / 1e6), unit="lãi.giây", note="= thời gian
× 2 lãi / triệu dòng"))
    rows.append(dict(item="Tải lập zone_day_pu bằng Spark trên mỗi triệu dòng Silver",
                    value=spark.seconds.sum() * 2 / (spark.n_silver.sum() / 1e6), unit="lãi.giây",
                    note="local[2]"))
    rows.append(dict(item="Tỷ lệ Gold / Bronze theo dung lượng",
                    value=100 * cat[cat.layer == "Gold"].size_mb.sum() / cat[cat.layer ==
"Bronze"].size_mb.sum(),
                    unit="%", note="mức cô đặc thông tin cho phân tích"))
    t = pd.DataFrame(rows)
    t.to_csv(TAB / "t82_resource_accounting.csv", index=False)
    wlog("tco", dict(rows=rows))

if __name__ == "__main__":
    fn = {"company": part_company, "forecast": part_forecast, "power": part_power, "pricing":
part_pricing,
        "tco": part_tco}
    fn[sys.argv[1]]()

```

I.23. 18_theory_sensitivity.py

"""Bước 18 - Kiểm định các giả thuyết suy ra từ mô hình lý thuyết (mục 2.11 của báo cáo).

Kiểm định giả thuyết:

H1b Liều - đáp ứng theo tỷ trọng phí trong giá: DiD trên panel OD × tháng, tách cặp chạm CRZ theo ngũ phân vị của τ/p ($\tau = 1,50$ USD; p = chi phí hành khách mỗi chuyến năm 2024).
Độ co giãn ngụ ý $\varepsilon_q = -\beta_q / \ln(1 + \tau/p_q)$. -> t83
H2b Độ lỗi của đường tốc độ - lưu lượng: mức tăng tốc độ theo giờ × loại ngày (t57) hồi quy theo lưu lượng CRZ-CRZ năm 2024 của cùng giờ. -> t84
H3 Lan tỏa tỷ lệ với mức phơi nhiễm: trên các vùng không thuộc CRZ, tác động sau chính sách tương tác với tỷ trọng chuyến đi vào CRZ năm 2024 (liều liên tục). -> t85
H4 Thu nhập tài xế mỗi dặm giảm cơ học khi tốc độ tăng: thu nhập = a·dặm + b·phút, nên thu nhập/dặm = a + b/tốc độ. Ước lượng b từ biến thiên trong năm 2024 rồi dự báo thay đổi do tốc độ tăng, so với hệ số DiD. ->

t86
Phân tích độ nhạy Rambachan-Roth được làm ở bước 19, trên giai đoạn trước chính sách mở rộng 2022-2024,

vì với một năm trước chính sách, các hệ số trước bị mùa vụ chi phối.

Chạy: python code/18_theory_sensitivity.py

"""

import json

import time

import numpy as np

import pandas as pd

from causal import event_study, fe_ols

from config import GOLD, LOG, TAB

from panels import P, add_ratios, od_month, zone_week, SUMS

from viz import C, fig, save

t0 = time.time()

FEE = 1.5

meta = {}

===== H1b

od = od_month("hvfhv")

pre = od[od.post == 0].groupby("pair")[["rider_cost", "n", "miles"]].sum()

pre["p0"] = pre.rider_cost / pre.n

pre["miles0"] = pre.miles / pre.n

od = od.merge(pre[["p0", "miles0"]], left_on="pair", right_index=True)

tp = od[od.touch == 1].drop_duplicates("pair")[["pair", "p0"]]

```

tp["share"] = FEE / tp.p0
tp["q"] = pd.qcut(tp.share, 5, labels=False) + 1
od = od.merge(tp[["pair", "q"]], on="pair", how="left")
rows = []
for q in range(1, 6):
    sub = od[(od.touch == 0) | (od.q == q)]
    res, info, _ = fe_ols(sub, "ln_n", ["D"], ["pair", "ym", "pu"])
    r = res.iloc[0]
    s = tp[tp.q == q]
    p_mean = float(np.average(s.p0))
    miles = float(od[od.q == q].drop_duplicates("pair").miles0.mean())
    share = FEE / p_mean
    rows.append(dict(quintile=q, pairs=len(s), p0_mean=p_mean, fee_share=share, miles_mean=miles,
                    coef=r.coef, se=r.se, p=r.p, ci_low=r.ci_low, ci_high=r.ci_high,
                    implied_elasticity=-r.coef / np.log(1 + share), n_obs=info["n_obs"]))
h1 = pd.DataFrame(rows)
h1.to_csv(TAB / "t83_dose_response_fee_share.csv", index=False)
# kiểm định xu hướng: hồi quy có trọng số  $\beta_q$  theo  $\ln(1+\tau/p)$ 
x = np.log(1 + h1.fee_share)
w = 1 / h1.se ** 2
X = np.c_[np.ones(5), x]
beta = np.linalg.solve(X.T @ (X * w.values[:, None]), X.T @ (w * h1.coef))
cov = np.linalg.inv(X.T @ (X * w.values[:, None]))
meta["h1b"] = dict(slope=float(beta[1]), slope_se=float(np.sqrt(cov[1, 1])),
intercept=float(beta[0]))
print(h1, meta["h1b"], flush=True)

# ===== H2b
sp = pd.read_csv(TAB / "t57_speed_did_hour_daytype.csv")
g = pd.read_parquet(GOLD / "grp_hour_day.parquet")
g = g[(g.service == "hvfhv") & (g.pu_grp == "CRZ") & (g.do_grp == "CRZ")].copy()
g["d"] = pd.to_datetime(g.d)
g = g[g.d < P]
g["daytype"] = np.where(g.d.dt.dayofweek >= 5, "Cuối tuần", "Ngày thường")
vol = g.groupby(["daytype", "hr"]).agg(n=("n", "sum"), days=("d", "nunique")).reset_index()
vol["trips_per_hour"] = vol.n / vol.days
vol["mph_2024"] = (g.groupby(["daytype", "hr"]).miles.sum() / (g.groupby(["daytype",
"hr"]).time_s.sum() / 3600)).values
h2 = sp.merge(vol[["daytype", "hr", "trips_per_hour", "mph_2024"]], on=["daytype", "hr"])
h2["v_rel"] = h2.trips_per_hour / h2.trips_per_hour.max()
h2.to_csv(TAB / "t84_speed_gain_vs_flow.csv", index=False)
import statsmodels.api as sm
m1 = sm.OLS(h2.did_vs_outer, sm.add_constant(h2[["v_rel"]])).fit(cov_type="HC1")
m2 = sm.OLS(h2.did_vs_outer, sm.add_constant(pd.DataFrame({"v_rel": h2.v_rel, "v_rel2": h2.v_rel **
2}))).fit(cov_type="HC1")
m3 = sm.OLS(h2.did_vs_outer, sm.add_constant(pd.DataFrame({"v_rel": h2.v_rel,
"weekend": (h2.daytype == "Cuối tuần").astype(int)}))).fit(cov_type="HC1")
h2m = pd.DataFrame([
dict(model="Tuyến tính theo lưu lượng", term="v_rel", coef=m1.params["v_rel"],
se=m1.bse["v_rel"], p=m1.pvalues["v_rel"], r2=m1.rsquared, n=int(m1.nobs)),
dict(model="Bậc hai theo lưu lượng", term="v_rel", coef=m2.params["v_rel"], se=m2.bse["v_rel"],
p=m2.pvalues["v_rel"], r2=m2.rsquared, n=int(m2.nobs)),
dict(model="Bậc hai theo lưu lượng", term="v_rel2", coef=m2.params["v_rel2"],
se=m2.bse["v_rel2"], p=m2.pvalues["v_rel2"], r2=m2.rsquared, n=int(m2.nobs)),
dict(model="Tuyến tính + cuối tuần", term="v_rel", coef=m3.params["v_rel"], se=m3.bse["v_rel"],
p=m3.pvalues["v_rel"], r2=m3.rsquared, n=int(m3.nobs)),
dict(model="Tuyến tính + cuối tuần", term="weekend", coef=m3.params["weekend"],
se=m3.bse["weekend"], p=m3.pvalues["weekend"], r2=m3.rsquared, n=int(m3.nobs)),
])
h2m["spearman_rho"] = h2[["did_vs_outer", "v_rel"]].corr(method="spearman").iloc[0, 1]
h2m.to_csv(TAB / "t84b_speed_gain_vs_flow_models.csv", index=False)
print(h2m, flush=True)

# ===== H3
zw = zone_week("hvfhv", groups=("MN_NORTH", "OUTER", "CRZ_PARTIAL"), extra=("n_to_crz",))
ex = zw[zw.post == 0].groupby("zone")[["n_to_crz", "n"]].sum()
ex["exposure"] = ex.n_to_crz / ex.n
zw = zw.merge(ex[["exposure"]], left_on="zone", right_index=True)
zw["post_x_exp"] = zw.post * zw.exposure
rows = []
for lab, sub in (("Mọi vùng ngoài CRZ", zw), ("Bỏ vùng vắt ranh giới", zw[zw.grp != "CRZ_PARTIAL"]),
("Chỉ quận ngoài", zw[zw.grp == "OUTER"])):
    for y in ("ln_n", "mph"):
        res, info, _ = fe_ols(sub, y, ["post_x_exp"], ["zone", "wk", "zone"])
        r = res.iloc[0]
        rows.append(dict(sample=lab, outcome=y, coef=r.coef, se=r.se, p=r.p, ci_low=r.ci_low,
ci_high=r.ci_high,
n_zones=info["n_clusters"], n_obs=info["n_obs"],
exp_p10=float(sub.drop_duplicates("zone").exposure.quantile(.1)),
exp_p90=float(sub.drop_duplicates("zone").exposure.quantile(.9))))
h3 = pd.DataFrame(rows)
h3.to_csv(TAB / "t85_spillover_dose_response.csv", index=False)
# Đường liều - đáp ứng theo nhóm phơi nhiễm
zx = zw.drop_duplicates("zone")[["zone", "exposure"]].copy()
zx["bin"] = pd.qcut(zx.exposure, 5, labels=False) + 1

```

```

zw = zw.merge(zx[["zone", "bin"]], on="zone")
names = []
for b in range(2, 6):
    zw[f"pb{b}"] = ((zw.bin == b) & (zw.post == 1)).astype(float)
    names.append(f"pb{b}")
res, info, _ = fe_ols(zw, "ln_n", names, ["zone", "wk", "zone"])
res["bin"] = [2, 3, 4, 5]
res["exposure_mean"] = [zx[zx.bin == b].exposure.mean() for b in range(2, 6)]
res.to_csv(TAB / "t85b_spillover_by_exposure_bin.csv", index=False)
h3b = res.copy()
meta["h3_bin1_exposure"] = float(zx[zx.bin == 1].exposure.mean())
print(h3, res, flush=True)

# ===== H4
zc = zone_week("hvfhv")
z24 = zc[(zc.post == 0)].copy()
z24["inv_mph"] = 1 / z24.mph
z24["min_pm"] = (z24.time_s / 60) / z24.miles
res_b, info_b, _ = fe_ols(z24, "pay_pm", ["min_pm", ["zone", "wk", "zone"]])
b = float(res_b.coef.iloc[0])
did_mph = pd.read_csv(TAB / "t30_did_main.csv")
d0 = did_mph[(did_mph.service == "hvfhv") & (did_mph["sample"] == "vùng×tuần") & (did_mph.spec == "TWFE")].set_index("outcome")
m0 = float(d0.loc["mph", "treated_pre_mean"])
dm = float(d0.loc["mph", "coef"])
pred = b * 60 * (1 / (m0 + dm) - 1 / m0)
h4 = pd.DataFrame([dict(b_pay_per_minute=b, b_se=float(res_b.se.iloc[0]), mph_pre=m0, d_mph=dm,
                        predicted_d_pay_pm=pred, did_d_pay_pm=float(d0.loc["pay_pm", "coef"]),
                        did_d_pay_pm_se=float(d0.loc["pay_pm", "se"]),
                        pay_pm_pre=float(d0.loc["pay_pm", "treated_pre_mean"]),
                        within_r2=info_b["within_r2"], n_obs=info_b["n_obs"])]])
h4.to_csv(TAB / "t86_driver_pay_mechanical.csv", index=False)
print(h4.T, flush=True)

# ===== hình
f, axes = fig(7.4, 3.1, ncols=3)
ax = axes[0]
ax.errorbar(100 * h1.fee_share, 100 * (np.exp(h1.coef) - 1), yerr=196 * h1.se, fmt="o",
            color=C["s1"], capsize=3)
ax.set_xlabel("Phí / chi phí chuyển 2024 (%)", fontsize=8)
ax.set_ylabel("Tác động lên số chuyển (%)", fontsize=8)
ax.set_title("H1b: theo tỷ trọng phí", fontsize=8.5)
ax = axes[1]
for dt, col in (("Ngày thường", C["s1"]), ("Cuối tuần", C["s2"])):
    d = h2[h2.daytype == dt]
    ax.scatter(d.v_rel, d.did_vs_outer, s=14, color=col, label=dt)
ax.set_xlabel("Lưu lượng CRZ-CRZ 2024 (tương đối)", fontsize=8)
ax.set_ylabel("Tăng tốc độ (dặm/giờ)", fontsize=8)
ax.set_title("H2b: theo lưu lượng", fontsize=8.5)
ax.legend(fontsize=7)
ax = axes[2]
eb = h3b # kết quả theo nhóm phơi nhiễm
ax.errorbar(100 * np.r_[meta["h3_bin1_exposure"], eb.exposure_mean], 100 * (np.exp(np.r_[0,
eb.coef]) - 1),
            yerr=np.r_[0, 196 * eb.se], fmt="o-", color=C["s3"], capsize=3)
ax.set_xlabel("Tỷ trọng chuyển vào CRZ 2024 (%)", fontsize=8)
ax.set_ylabel("So với nhóm thấp nhất (%)", fontsize=8)
ax.set_title("H3: theo phơi nhiễm", fontsize=8.5)
for a_ in axes:
    a_.tick_params(labelsize=7)
f.tight_layout()
save(f, "f56_theory_tests")

meta["seconds"] = round(time.time() - t0, 1)
(LOG / "18_theory_sensitivity.json").write_text(json.dumps(meta, indent=2))
print(meta)

```

I.24. 19_long_preperiod.py

""""Bước 19 - Giai đoạn trước chính sách mở rộng (2022-2025): nghiên cứu sự kiện khử mùa vụ, giả được theo năm, điều chỉnh xu hướng và phân tích độ nhạy Rambachan-Roth.

Đầu vào: data/gold/long/zone_day_pu.parquet (bước 03 ext + 04 ext), panel vùng × tháng 01/2022-12/2025.

Nhóm vùng và ngưỡng lưu lượng giống panel chính (CRZ, Manhattan phía bắc, quận ngoài; ≥ 100 chuyển/ngày năm 2024), cân bằng đủ 48 tháng.

Đặc tả (cho mỗi biến kết quả y):

$y_{zm} = \alpha_z + y_m + \mu_{\{T(z), \text{tháng-trong-năm}(m)\}} + \sum_{\{m \geq 2023-01\}} \beta_m \cdot T_z \cdot 1[\text{tháng} = m] + \varepsilon_{zm}$
 Năm 2022 là năm gốc: hiệu ứng cố định nhóm × tháng-trong-năm hấp thụ mùa vụ riêng của CRZ, nên β_m đo chênh lệch CRZ - đối chứng của tháng m so với cùng tháng năm 2022.

Các đại lượng:

(1) Hệ số β_m cho 36 tháng (2023-2025) -> t89,

f57

(2) Giả được theo năm: $TB(\beta_{2024}) - TB(\beta_{2023})$ (chính sách giả 01/2024) và tác động thật $TB(\beta_{2025}) - TB(\beta_{2024})$; kiểm định Wald đồng thời các β của 2023-2024 bằng nhau ->

t90

(3) Tác động sau điều chỉnh xu hướng tuyến tính ước lượng từ 24 tháng 2023-2024 -> t90

(4) Độ nhảy Rambachan-Roth (phiên bản đơn giản hóa, bảo thủ) trên β đã khử mùa vụ:

$$RM: |\delta_t - \delta_{t-1}| \leq M \cdot \max_{pre} |\Delta\beta|; \quad SD: \text{ngoại suy xu hướng tuyến tính} + \text{sai phân bậc hai}$$

$\leq M$.

Với RM, tác động được chuẩn hóa so với tháng cuối trước chính sách (12/2024). ->

t91, t91b, f58

Chạy: python code/19_long_preperiod.py

```

"""
import json
import time

import numpy as np
import pandas as pd
from scipy import stats

from causal import fe_ols
from config import GOLD, LOG, TAB
from panels import MIN_DAILY, SUMS, add_ratios, dim
from viz import C, fig, save

t0 = time.time()
z = pd.read_parquet(GOLD / "long" / "zone_day_pu.parquet")
z = z[z.service == "hvfhv"].copy()
z["d"] = pd.to_datetime(z.d)
z = z[(z.d >= "2022-01-01") & (z.d <= "2025-12-31")]
z["ym"] = z.d.dt.to_period("M")
dm = dim()[["LocationID", "grp"]]
z = z.merge(dm, left_on="zone", right_on="LocationID")
z = z[z.grp.isin(["CRZ", "MN_NORTH", "OUTER"])]
g = z.groupby(["zone", "grp", "ym"])[SUMS].sum().reset_index()
pre24 = z[(z.d >= "2024-01-07") & (z.d < "2025-01-05")].groupby("zone").n.sum() / 364
keep = pre24[pre24 >= MIN_DAILY["hvfhv"]].index
cnt = g.groupby("zone").ym.nunique()
keep = [k for k in keep if cnt.get(k, 0) == 48]
g = g[g.zone.isin(keep)].copy()
g = add_ratios(g)
g["rider_ex_pt"] = (g.rider_cost - g.cbd) / g.n
g["treat"] = (g.grp == "CRZ").astype(int)
g["year"] = g.ym.dt.year
g["moy"] = g.ym.dt.month
g["ymc"] = g.ym.astype(str)
g["tm"] = g.treat.astype(str) + "_" + g.moy.astype(str)
months = sorted(g.ym.unique())
ev = [m for m in months if m.year >= 2023]
names = []
for m in ev:
    nm = f"e_{m}"
    g[nm] = ((g.ym == m) & (g.treat == 1)).astype(float)
    names.append(nm)
meta = dict(zones=int(g.zone.nunique()), treated=int(g[g.treat == 1].zone.nunique()),
obs=int(len(g)))

OUT = {"ln_n": "log số chuyến", "mph": "Tốc độ (dặm/giờ)", "wait": "Thời gian chờ (phút)",
"fare_pm": "Giá cước cơ sở/dặm (USD)", "pay_pm": "Thu nhập tài xế/dặm (USD)",
"rider_ex_pt": "Chi phí hành khách/chuyến trừ phí CBD (USD)", "pay_share": "Thu nhập tài xế/giá cước (%)",
"shared_pct": "Tỷ lệ yêu cầu đi chung (%)"
coef_rows, sum_rows, rm_rows, sd_rows = [], [], [], []
yrs = np.array([m.year for m in ev])
kidx = np.arange(len(ev)) # 0 = 2023-01
for y, lab in OUT.items():
    d = g.dropna(subset=[y])
    res, info, V = fe_ols(d, y, names, ["zone", "ymc", "tm", "zone"])
    b = res.coef.to_numpy()
    se = res.se.to_numpy()
    for m, bb, ss in zip(ev, b, se):
        coef_rows.append(dict(outcome=y, label=lab, ym=str(m), coef=bb, se=ss))
    G = info["n_clusters"]
    crit = stats.t.ppf(0.975, G - 1)

def lin(a):
    return float(a @ b), float(np.sqrt(a @ V @ a))
a23 = (yrs == 2023) / (yrs == 2023).sum()
a24 = (yrs == 2024) / (yrs == 2024).sum()
a25 = (yrs == 2025) / (yrs == 2025).sum()
plc, plc_se = lin(a24 - a23)
eff, eff_se = lin(a25 - a24)

```

```

acc, acc_se = lin((a25 - a24) - (a24 - a23)) # thay đổi năm 2025 trừ thay đổi năm 2024 (giả
định xu hướng năm không đổi)
# Wald: 24 hệ số 2023-2024 bằng nhau (không có biến động có hệ thống trước chính sách)
pre = np.where(yrs <= 2024)[0]
Lw = np.zeros((len(pre) - 1, len(b)))
for i in range(len(pre) - 1):
    Lw[i, pre[i]] = 1
    Lw[i, pre[i+1]] = -1
wv = Lw @ b
Wst = float(wv @ np.linalg.pinv(Lw @ V @ Lw.T) @ wv)
wp = float(stats.chi2.sf(Wst, len(pre) - 1))
# Điều chỉnh xu hướng tuyến tính ước lượng từ 2023-2024
Xp = np.c_[np.ones(len(pre)), kidx[pre]]
H = np.linalg.pinv(Xp.T @ Xp) @ Xp.T # 2 x n_pre
S = np.zeros((len(pre), len(b)))
S[np.arange(len(pre)), pre] = 1
CL = H @ S # 2 x K
post = np.where(yrs == 2025)[0]
trend_post = np.c_[np.ones(len(post)), kidx[post]] @ CL
trend_24 = np.c_[np.ones((yrs == 2024).sum()), kidx[yrs == 2024]] @ CL
a_tr = (a25 - a24) - (trend_post.mean(0) - trend_24.mean(0))
eff_tr, eff_tr_se = lin(a_tr)
slope, slope_se = float((CL @ b)[1]), float(np.sqrt((CL @ V @ CL.T)[1, 1]))
# Rambachan-Roth: đo so với TB 2024; ở tại tháng cuối trước chính sách (12/2024)
bp = b[pre]
dmax = float(np.max(np.abs(np.diff(bp))))
kpost = np.arange(1, len(post) + 1) # số bước kể từ 12/2024
# Theo Rambachan-Roth, tham số được chuẩn hóa so với tháng cuối trước chính sách (12/2024):  $\theta =$ 
 $TB(\beta_{2025}) - \beta_{2024-12}$ .
# Dưới RM, độ chệch của  $\theta$  bị chặn bởi  $\bar{M} \cdot \max|\Delta\beta_{pre}| \cdot TB(k)$ ,  $k$  = số tháng kể từ 12/2024.
a_last = np.zeros(len(b))
a_last[pre[-1]] = 1
eff_rr, eff_rr_se = lin(a25 - a_last)
w_rm = float(kpost.mean())
for M in (0, 0.25, 0.5, 0.75, 1.0, 1.5, 2.0):
    B = M * dmax * w_rm
    rm_rows.append(dict(outcome=y, label=lab, M=M, effect=eff_rr, se=eff_rr_se, bound=B,
                        ci_low=eff_rr - B - crit * eff_rr_se, ci_high=eff_rr + B + crit *
eff_rr_se))
    brk_rm = max((abs(eff_rr) - crit * eff_rr_se) / (dmax * w_rm), 0.0)
    w_sd = float(np.mean(kpost * (kpost + 1) / 2))
    for M in (0, 0.0025, 0.005, 0.01, 0.02, 0.05):
        B = M * w_sd
        sd_rows.append(dict(outcome=y, label=lab, M=M, effect_trend_adj=eff_tr, se=eff_tr_se,
                            bound=B,
                            ci_low=eff_tr - B - crit * eff_tr_se, ci_high=eff_tr + B + crit *
eff_tr_se))
        brk_sd = max((abs(eff_tr) - crit * eff_tr_se) / w_sd, 0.0)
        sum_rows.append(dict(outcome=y, label=lab, placebo_2024_vs_2023=plc, placebo_se=plc_se,
                            placebo_p=float(2 * stats.t.sf(abs(plc / plc_se), G - 1)),
                            effect_2025_vs_2024=eff, effect_se=eff_se, effect_p=float(2 *
stats.t.sf(abs(eff / eff_se), G - 1)),
                            pre_wald=Wst, pre_wald_df=len(pre) - 1, pre_wald_p=wp,
pre_slope_per_month=slope, pre_slope_se=slope_se,
                            effect_trend_adj=eff_tr, effect_trend_adj_se=eff_tr_se,
                            effect_trend_adj_p=float(2 * stats.t.sf(abs(eff_tr / eff_tr_se), G - 1)),
                            accel=acc, accel_se=acc_se, accel_p=float(2 * stats.t.sf(abs(acc / acc_se),
G - 1)),
                            effect_vs_last_pre=eff_rr, effect_vs_last_pre_se=eff_rr_se,
                            max_pre_delta=dmax, breakdown_RM=brk_rm, breakdown_SD=brk_sd,
                            pre_mean_2024=float(d[(d.treat == 1) & (d.year == 2024)][y].mean()),
                            n_obs=info["n_obs"], n_clusters=G))
        print(sum_rows[-1], flush=True)
co = pd.DataFrame(coef_rows)
co.to_csv(TAB / "t89_long_event_study.csv", index=False)
sm_ = pd.DataFrame(sum_rows)
sm_.to_csv(TAB / "t90_long_placebo_trend.csv", index=False)
pd.DataFrame(rm_rows).to_csv(TAB / "t91_rr_relative_magnitudes.csv", index=False)
pd.DataFrame(sd_rows).to_csv(TAB / "t91b_rr_smoothness.csv", index=False)

# Chuỗi mô tả: số chuyển/ngày theo tháng của CRZ và đối chứng, chỉ số 2022 = 100
desc = g.groupby(["ym", "treat"]).n.sum().unstack()
desc.columns = ["control", "crz"]
days = pd.Series({m: m.days_in_month for m in desc.index})
desc = desc.div(days, axis=0)
desc = desc / desc[desc.index.year == 2022].mean() * 100
desc.index = desc.index.astype(str)
desc.to_csv(TAB / "t89b_long_index.csv")

# Hình f57: hệ số theo tháng của 4 biến
f, axes = fig(6.8, 5.2, nrow=2, ncol=2, sharex=True)
for ax, y in zip(axes.flat, ["ln_n", "mph", "fare_pm", "pay_pm"]):
    d = co[co.outcome == y]
    x = pd.PeriodIndex(d.ym, freq="M").to_timestamp()
    ax.fill_between(x, d.coef - 1.96 * d.se, d.coef + 1.96 * d.se, color=C["s1"], alpha=0.2, lw=0)

```

```

        ax.plot(x, d.coef, color=C["s1"], lw=1.2)
        ax.axhline(0, color=C["text2"], lw=0.7)
        ax.axvline(pd.Timestamp("2025-01-01"), color=C["text2"], lw=0.8, ls="--")
        ax.axvline(pd.Timestamp("2024-01-01"), color=C["s2"], lw=0.8, ls=":")
        ax.set_title(OUT[y], fontsize=8.5)
        ax.tick_params(labelsize=7)
f.tight_layout()
save(f, "f57_long_event_study")

f, axes = fig(6.8, 4.6, nrows=2, ncols=4)
rm = pd.DataFrame(rm_rows)
for ax, (y, lab) in zip(axes.flat, OUT.items()):
    d = rm[rm.outcome == y]
    ax.fill_between(d.M, d.ci_low, d.ci_high, color=C["s1"], alpha=0.25, lw=0)
    ax.plot(d.M, d.effect, color=C["s1"], lw=1.2)
    ax.axhline(0, color=C["text2"], lw=0.8)
    ax.set_title(lab, fontsize=7)
    ax.tick_params(labelsize=6.5)
for ax in axes[1]:
    ax.set_xlabel("M", fontsize=8)
f.tight_layout()
save(f, "f58_rr_long")

meta["seconds"] = round(time.time() - t0, 1)
(LOG / "19_long_preperiod.json").write_text(json.dumps(meta, indent=2))
print(meta)

```

I.25. 00_download_data_2022_2023.ps1

```

# Tai du lieu bo sung 2022-2023 (HVFHV + taxi vang) cho giai doan truoc chinh sach dai hon
# Chay: powershell -ExecutionPolicy Bypass -File code\00_download_data_2022_2023.ps1
# Khoang 48 tep, ~12 GB. Bo qua tep da tai du; tu thu lai va tai tiep khi mat mang.
$dst = Join-Path (Split-Path $PSScriptRoot -Parent) "data\raw"
New-Item -ItemType Directory -Force -Path $dst | Out-Null
$base = "https://d37ci6vzurychx.cloudfront.net/trip-data"
$urls = @()
foreach ($y in 2022, 2023) { foreach ($m in 1..12) {
    $sym = "{0}-{1:D2}" -f $y, $m
    $urls += "$base/fhvhv_tripdata_$sym.parquet"
    $urls += "$base/yellow_tripdata_$sym.parquet"
}}
$i = 0
foreach ($u in $urls) {
    $i++
    $f = Join-Path $dst (Split-Path $u -Leaf)
    if ((Test-Path $f) -and (Get-Item $f).Length -gt 1MB) { continue }
    Write-Host ("[{0}/{1}] Tai {2}" -f $i, $urls.Count, $u)
    curl.exe -L --fail --retry 5 --retry-delay 5 -C - -o $f $u
    if ($LASTEXITCODE -ne 0) { Write-Host " LOI: $u" -ForegroundColor Red }
}
$n = (Get-ChildItem $dst -Filter "*_tripdata_202[23]-*.parquet").Count
Write-Host "Xong. So tep 2022-2023 da co: $n / 48"

```

I.26. run_all.sh

```

#!/usr/bin/env bash
# Chạy toàn bộ pipeline của đồ án theo đúng thứ tự.
# Dùng: bash code/run_all.sh (chạy từ thư mục gốc CongestionPricing_CaseStudy)
# Yêu cầu: Java 11+ cho bước 15; đã có 50 tệp dữ liệu thô 2024-2025 trong data/raw (xem
code/00_download_data.ps1 hoặc 00_download_data.py)
set -euo pipefail
cd "$(dirname "$0")/.."

python code/01_bronze_catalog.py # Bronze: danh mục metadata, lệch lược đồ
python code/02_zone_dimension.py # Bảng chiều vùng, xác định CRZ từ dữ liệu
python code/03_silver_gold_month.py all # Silver + Gold theo từng khúc tháng (120 phân vùng)
python code/04_gold_consolidate.py # Hợp nhất Gold, nhật ký chất lượng
python code/05_benchmark.py format # Thực nghiệm định dạng lưu trữ
python code/05_benchmark.py engine # Thực nghiệm bộ máy xử lý
python code/05_benchmark.py pruning # Cắt tỉa cột, đẩy điều kiện lọc
python code/06_eda.py # Phân tích khám phá
python code/07_did_main.py # DiD, DDD, nghiên cứu sự kiện, OD, không đồng nhất
python code/08_synthetic_control.py # Kiểm soát tổng hợp và giả được không gian
python code/09_dml_heterogeneity.py # DML, AIPW, CATE, BLP, GATES
python code/10_spillover_robustness.py all # Lan tỏa, giả được thời gian, hoán vị, độ vững
python code/11_appendix_tables.py # Bảng phụ lục
python code/12_pipeline_figures.py # Hình hiệu năng pipeline và sơ đồ kiến trúc
python code/14_extra_analysis.py # Phân tích bổ sung: tác động theo vùng, lan tỏa theo
quận, sân bay
# Bước 15: xử lý phân tán bằng Apache Spark (cần Java 11+ và pyspark). SPARK_WORK trở tới thư mục

```

```
# làm việc có quyền xóa tệp (Spark tạo và xóa thư mục _temporary, checkpoint).
export SPARK_WORK="${SPARK_WORK:-$PWD/data/_spark}"
python code/15_spark_pipeline.py repro # Tái lập bằng Gold zone_day_pu bằng Spark (48 tháng-
dịch vụ)
python code/04_gold_consolidate.py # (đã sửa lỗi ép kiểu phát hiện nhờ bước 15; chạy lại
là lũy đẳng)
python code/15_spark_pipeline.py validate # Đối chứng từng ô Spark với DuckDB
for e in duckdb spark_df spark_sql; do python code/15_spark_pipeline.py engine $e; done
for p in 1 2 4 8 16 32 64 200 1000; do
    python code/15_spark_pipeline.py shuffle $p; python code/15_spark_pipeline.py shuffle $p noaqe
done
for k in 1 2 3 4 6; do
    python code/15_spark_pipeline.py scale duckdb $k; python code/15_spark_pipeline.py scale spark_df
$k
done
python code/15_spark_pipeline.py cache
python code/15_spark_pipeline.py prune
python code/15_spark_pipeline.py arrow
python code/15_spark_pipeline.py stream_prep
python code/15_spark_pipeline.py stream
python code/15_spark_pipeline.py report
# Bước 16: quản trị dữ liệu, quyền riêng tư, rủi ro
for p in catalog lineage integrity reconcile anomaly tripanom privacy dp dr; do python
code/16_governance_risk.py $p; done
# Bước 17: phân tích phục vụ quyết định kinh doanh
for p in company forecast power pricing tco; do python code/17_business_analytics.py $p; done
python code/18_theory_sensitivity.py # Kiểm định giả thuyết lý thuyết (H1b, H2b, H3, H4)
# Bước 19: giai đoạn trước chính sách mở rộng 2022-2023 (cần 48 tệp thô của
00_download_data_2022_2023.ps1).
# Các bảng chính 2024-2025 không đổi: kết quả mở rộng ghi vào _parts_ext, partitions_ext và
gold/long/.
# DUCKDB_TMP trở tới thư mục có quyền xóa tệp (DuckDB tạo và xóa tệp tạm khi tràn bộ nhớ).
export DUCKDB_TMP="${DUCKDB_TMP:-$PWD/data/_duck_tmp}"
python code/01_bronze_catalog.py ext # Bronze 2022-2023: t01x, t02x, t03x
python code/03_silver_gold_month.py ext # Silver + Gold theo tháng 2022-2023 (một số tháng giữ
Silver trong bộ nhớ)
python code/04_gold_consolidate.py ext # Hợp nhất Gold 2022-2025 vào gold/long/, t06x-t08x
python code/19_long_preperiod.py # Nghiên cứu sự kiện 2022-2025, giả được, điều chỉnh xu
hướng, Rambachan-Roth
python code/13_build_report.py # Dựng báo cáo Word/PDF từ các bảng và hình ở trên
```

I.27. requirements.txt

```
duckdb==1.5.5
pyarrow==25.0.1
pandas==2.3.3
numpy
scipy
statsmodels==0.15.0
scikit-learn==1.7.2
lightgbm==4.7.0
matplotlib==3.10.9
pyshp
shapely==2.1.2
python-docx==1.2.0
pyspark==3.5.3
```